

第 5 周习题与参考解答

习题 1：一维 GD 的收敛因子

$f(x) = \frac{1}{2} \cdot 5x^2$ (即 $k = 5$), 初始点 $x_0 = 2$ 。

- (a) 写出 GD 的稳定性条件 (η 的范围)。
- (b) 分别计算 $\eta = 0.1, 0.2, 0.35, 0.42$ 时的收敛因子 $\rho = |1 - \eta k|$, 并判断每种情况是 **单调收敛** ($0 < 1 - \eta k < 1$)、**振荡收敛** ($-1 < 1 - \eta k < 0$) 还是 **发散** ($|1 - \eta k| \geq 1$)。
- (c) 对 $\eta = 0.2$, 写出 x_t 的通项公式 $x_t = x_0 \cdot (1 - \eta k)^t$, 并手算 x_0, x_1, x_2, x_3, x_4 。
- (d) 对 (b) 中的四个 η , 分别计算达到 $|x_t| < 0.01$ 需要多少步。(对发散的情形说明为什么无法达到。)

提示

$\rho^T < 0.01/2 = 0.005$ 意味着 $T > \log(0.005)/\log(\rho)$ 。

标准答案

(a) **稳定性条件** GD 的收敛条件是

$$|1 - 5\eta| < 1.$$

解得

$$-1 < 1 - 5\eta < 1 \iff 0 < \eta < \frac{2}{5} = 0.4.$$

因此稳定步长范围为

$$0 < \eta < 0.4.$$

(b) **四个步长的收敛因子与类型** 收敛因子定义为

$$\rho = |1 - 5\eta|.$$

逐一计算：

η	$1 - 5\eta$	$\rho = 1 - 5\eta $	结论
0.1	0.5	0.5	单调收敛
0.2	0	0	一步到达最优
0.35	-0.75	0.75	振荡收敛
0.42	-1.1	1.1	发散

说明：题目给出的三分类里没有单独列出 $1 - 5\eta = 0$ 的情形。这里 $\eta = 0.2$ 是一个特殊点：既不振荡也不发散，而是一步精确到达最优解。

(c) $\eta = 0.2$ 时的通项与前 5 项 此时

$$1 - 5\eta = 1 - 1 = 0,$$

故通项为

$$x_t = x_0(1 - 5\eta)^t = 2 \cdot 0^t.$$

更准确地写成分段形式：

$$x_0 = 2, \quad x_t = 0 \quad (t \geq 1).$$

因此

$$x_0 = 2, \quad x_1 = 0, \quad x_2 = 0, \quad x_3 = 0, \quad x_4 = 0.$$

(d) 达到 $|x_t| < 0.01$ 所需步数 由

$$|x_t| = |x_0|\rho^t = 2\rho^t$$

可知需要满足

$$2\rho^t < 0.01 \iff \rho^t < 0.005.$$

- 当 $\eta = 0.1$ 时, $\rho = 0.5$, 所以

$$t > \frac{\ln(0.005)}{\ln(0.5)} \approx 7.64.$$

最小整数步数为

$$\boxed{t = 8.}$$

- 当 $\eta = 0.2$ 时, $\rho = 0$, 一步后 $x_1 = 0$, 故

$$\boxed{t = 1.}$$

- 当 $\eta = 0.35$ 时, $\rho = 0.75$, 所以

$$t > \frac{\ln(0.005)}{\ln(0.75)} \approx 18.42.$$

最小整数步数为

$$t = 19.$$

- 当 $\eta = 0.42$ 时, $\rho = 1.1 > 1$, 迭代发散, 因此

$$\text{无法达到 } |x_t| < 0.01.$$

习题 2：二维最优步长

$f(x, y) = \frac{1}{2}(2x^2 + 50y^2)$, 即 $\mu = 2$, $L = 50$, $\kappa = 25$ 。

- 计算 GD 稳定上界 $\eta_{\max} = 2/L$ 。
- 计算最优步长 $\eta^* = 2/(\mu + L)$ 和最优收敛因子 $\rho^* = (\kappa - 1)/(\kappa + 1)$ 。
- 分别对 $\eta_A = 1/L$ (保守) 和 $\eta_B = \eta^*$ (最优), 计算两个方向的收敛因子 $\rho_x = |1 - \eta\mu|$, $\rho_y = |1 - \eta L|$, 以及整体 $\rho = \max(\rho_x, \rho_y)$ 。
- 从 $(x_0, y_0) = (1, 1)$ 出发, 用 η^* 手算 3 步迭代。每步写出 (x_t, y_t) 和 $f(x_t, y_t)$ 。y 方向是否振荡? 为什么?
- 将误差降到初始值的 0.1% 需要 $\rho^T < 0.001$ 。分别计算 η_A 和 η_B 所需的步数 T 。 η^* 比 $\eta = 1/L$ 快了多少倍?

标准答案

(a) 稳定上界 GD 的稳定性要求 $0 < \eta < 2/L$, 故

$$\eta_{\max} = \frac{2}{L} = \frac{2}{50} = 0.04.$$

所以

$$\eta_{\max} = 0.04.$$

(b) 最优步长与最优收敛因子 最优步长为

$$\eta^* = \frac{2}{\mu + L} = \frac{2}{52} = \frac{1}{26} \approx 0.0384615.$$

最优收敛因子为

$$\rho^* = \frac{\kappa - 1}{\kappa + 1} = \frac{24}{26} = \frac{12}{13} \approx 0.9230769.$$

故

$$\eta^* = \frac{1}{26} \approx 0.03846, \quad \rho^* = \frac{12}{13} \approx 0.92308.$$

(c) 比较 $\eta_A = 1/L$ 与 $\eta_B = \eta^*$ 情形 A: $\eta_A = 1/L = 0.02$

$$\rho_x = |1 - \eta_A \mu| = |1 - 0.04| = 0.96,$$

$$\rho_y = |1 - \eta_A L| = |1 - 1| = 0.$$

所以整体收敛因子

$$\rho_A = \max\{0.96, 0\} = 0.96.$$

情形 B: $\eta_B = \eta^* = 1/26$

$$\rho_x = \left|1 - \frac{2}{26}\right| = \frac{24}{26} = \frac{12}{13},$$

$$\rho_y = \left|1 - \frac{50}{26}\right| = \left|-\frac{24}{26}\right| = \frac{12}{13}.$$

因此

$$\rho_B = \frac{12}{13} \approx 0.92308.$$

总结如下:

步长	ρ_x	ρ_y	整体 ρ
$\eta_A = 0.02$	0.96	0	0.96
$\eta_B = 1/26$	12/13	12/13	12/13

(d) 从 $(1, 1)$ 出发, 用 η^* 手算 3 步 因为

$$x_{t+1} = \left(1 - \frac{2}{26}\right) x_t = \frac{12}{13} x_t, \quad y_{t+1} = \left(1 - \frac{50}{26}\right) y_t = -\frac{12}{13} y_t,$$

所以:

$$(x_0, y_0) = (1, 1), \quad f(x_0, y_0) = \frac{1}{2}(2 + 50) = 26.$$

第 1 步:

$$(x_1, y_1) = \left(\frac{12}{13}, -\frac{12}{13}\right),$$

$$f(x_1, y_1) = \frac{1}{2} \left(2 \cdot \frac{144}{169} + 50 \cdot \frac{144}{169}\right) = 26 \cdot \frac{144}{169} \approx 22.153846.$$

第 2 步:

$$(x_2, y_2) = \left(\left(\frac{12}{13}\right)^2, \left(\frac{12}{13}\right)^2\right) = \left(\frac{144}{169}, \frac{144}{169}\right),$$

$$f(x_2, y_2) = 26 \left(\frac{12}{13} \right)^4 \approx 18.876650.$$

第 3 步:

$$(x_3, y_3) = \left(\left(\frac{12}{13} \right)^3, - \left(\frac{12}{13} \right)^3 \right) \approx (0.786527, -0.786527),$$

$$f(x_3, y_3) = 26 \left(\frac{12}{13} \right)^6 \approx 16.084246.$$

y 方向会振荡, 因为其收缩因子为

$$1 - 50\eta^* = -\frac{12}{13} < 0,$$

符号每一步都会翻转; 但由于绝对值小于 1, 所以它是 **振荡收敛**。

(e) 误差降到初始值的 0.1% 所需步数 要求

$$\rho^T < 0.001.$$

对 $\eta_A = 0.02$:

$$0.96^T < 0.001 \implies T > \frac{\ln(0.001)}{\ln(0.96)} \approx 169.22.$$

故最小整数为

$$\boxed{T_A = 170.}$$

对 $\eta_B = 1/26$:

$$\left(\frac{12}{13} \right)^T < 0.001 \implies T > \frac{\ln(0.001)}{\ln(12/13)} \approx 86.30.$$

故最小整数为

$$\boxed{T_B = 87.}$$

所以最优步长带来的加速比约为

$$\frac{T_A}{T_B} \approx \frac{170}{87} \approx 1.95.$$

即大约快

$$\boxed{1.95 \text{ 倍 (约 2 倍) .}}$$

习题 3: SGD 无偏性与梯度方差

一维线性回归: $x \sim \mathcal{N}(0, \lambda)$, $y = \theta^* x + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2)$ 。定义参数误差 $e_t = a_t - \theta^*$ 。单样本随机梯度为 $g_t = e_t \cdot x_t^2 - \varepsilon_t \cdot x_t$ 。

- 计算条件期望 $\mathbb{E}[g_t | e_t]$ 。(利用 x_t, ε_t 与 e_t 独立, $\mathbb{E}[x^2] = \lambda$, $\mathbb{E}[\varepsilon] = 0$ 。)证明随机梯度是**无偏**的。
- 计算 $\mathbb{E}[g_t^2 | e_t]$ 。展开 $g_t^2 = e_t^2 x_t^4 - 2e_t x_t^3 \varepsilon_t + \varepsilon_t^2 x_t^2$, 然后取期望。需要用到高斯分布的矩: $\mathbb{E}[x^3] = 0$, $\mathbb{E}[x^4] = 3\lambda^2$ 。
- 由此推导梯度方差 $\text{Var}[g_t | e_t] = \mathbb{E}[g_t^2] - (\mathbb{E}[g_t])^2 = 2e_t^2 \lambda^2 + \lambda \sigma_\varepsilon^2$ 。
- 解释两项的物理意义: $2e_t^2 \lambda^2$ 在前期和后期哪个主导? $\lambda \sigma_\varepsilon^2$ 呢?
- 如果使用 mini-batch $B = 16$, 方差变为多少? 写出公式并代入 $\lambda = 4$, $\sigma_\varepsilon^2 = 0.01$, $e_t = 1$ 。

提示

$\mathbb{E}[x^4] = 3(\mathbb{E}[x^2])^2$ 对高斯分布成立 (四阶矩公式)。

标准答案

(a) 条件期望与无偏性 单样本随机梯度:

$$g_t = (a_t x_t - y_t) x_t.$$

由数据生成模型

$$y_t = \theta^* x_t + \varepsilon_t, \quad e_t = a_t - \theta^*,$$

可得

$$g_t = (a_t x_t - (\theta^* x_t + \varepsilon_t)) x_t = ((a_t - \theta^*) x_t - \varepsilon_t) x_t = e_t x_t^2 - \varepsilon_t x_t.$$

由于 e_t 与 (x_t, ε_t) 独立, 且

$$\mathbb{E}[x_t^2] = \lambda, \quad \mathbb{E}[\varepsilon_t] = 0, \quad \mathbb{E}[x_t] = 0,$$

所以

$$\mathbb{E}[g_t | e_t] = \mathbb{E}[e_t x_t^2 - \varepsilon_t x_t | e_t] = e_t \mathbb{E}[x_t^2] - \mathbb{E}[\varepsilon_t x_t].$$

又因为 ε_t 与 x_t 独立, 故

$$\mathbb{E}[\varepsilon_t x_t] = \mathbb{E}[\varepsilon_t] \mathbb{E}[x_t] = 0.$$

因此

$$\mathbb{E}[g_t | e_t] = \lambda e_t.$$

定义总体损失函数

$$L(a) = \frac{1}{2} \mathbb{E}[(y - ax)^2].$$

对参数 a 求导, 有

$$\nabla L(a) = \mathbb{E}[(ax - y)x].$$

在 $a = a_t$ 处,

$$\nabla L(a_t) = \mathbb{E}[(a_t x_t - y_t)x_t | e_t] = \mathbb{E}[g_t | e_t].$$

进一步代入 $y_t = \theta^* x_t + \varepsilon_t$, 得到

$$\nabla L(a_t) = \mathbb{E}[(a_t - \theta^*)x_t - \varepsilon_t)x_t | e_t] = e_t \mathbb{E}[x_t^2] - \mathbb{E}[\varepsilon_t x_t] = \lambda e_t.$$

所以

$$\nabla L(a_t) = \lambda e_t.$$

综上,

$$\mathbb{E}[g_t | e_t] = \nabla L(a_t),$$

即随机梯度的条件期望等于真实梯度, 因此随机梯度是**无偏的**。

(b) 计算 $\mathbb{E}[g_t^2 | e_t]$ 先展开:

$$g_t^2 = (e_t x_t^2 - \varepsilon_t x_t)^2 = e_t^2 x_t^4 - 2e_t x_t^3 \varepsilon_t + \varepsilon_t^2 x_t^2.$$

条件于 e_t 取期望:

$$\mathbb{E}[g_t^2 | e_t] = e_t^2 \mathbb{E}[x_t^4] - 2e_t \mathbb{E}[x_t^3 \varepsilon_t] + \mathbb{E}[\varepsilon_t^2 x_t^2].$$

对高斯变量有

$$\mathbb{E}[x_t^4] = 3\lambda^2, \quad \mathbb{E}[x_t^3] = 0.$$

同时, x_t 与 ε_t 独立, 因此

$$\mathbb{E}[x_t^3 \varepsilon_t] = \mathbb{E}[x_t^3] \mathbb{E}[\varepsilon_t] = 0,$$

$$\mathbb{E}[\varepsilon_t^2 x_t^2] = \mathbb{E}[\varepsilon_t^2] \mathbb{E}[x_t^2] = \sigma_\varepsilon^2 \lambda.$$

故

$$\mathbb{E}[g_t^2 | e_t] = 3e_t^2 \lambda^2 + \lambda \sigma_\varepsilon^2.$$

(c) 条件方差 由 (a) 可知

$$\mathbb{E}[g_t | e_t] = \lambda e_t.$$

因此

$$\text{Var}[g_t | e_t] = \mathbb{E}[g_t^2 | e_t] - (\mathbb{E}[g_t | e_t])^2 = (3e_t^2\lambda^2 + \lambda\sigma_\varepsilon^2) - e_t^2\lambda^2.$$

整理得

$$\boxed{\text{Var}[g_t | e_t] = 2e_t^2\lambda^2 + \lambda\sigma_\varepsilon^2.}$$

(d) 两项的物理意义

- 第一项 $2e_t^2\lambda^2$ 与当前参数误差 e_t^2 成正比，因此在训练前期 ($|e_t|$ 较大) 通常主导。这是 **由参数尚未收敛引起的梯度随机波动**。
- 第二项 $\lambda\sigma_\varepsilon^2$ 与 e_t 无关，是由观测噪声 ε 引起的 **不可约噪声底**。在训练后期，当 $e_t \rightarrow 0$ 时，这一项主导。

因此可以概括为：

前期：误差项主导； 后期：噪声项主导。

(e) mini-batch $B = 16$ 时的方差 若用 batch 平均梯度

$$\bar{g}_t = \frac{1}{B} \sum_{i=1}^B g_t^{(i)},$$

且样本独立，则方差缩小为原来的 $1/B$ ：

$$\text{Var}[\bar{g}_t | e_t] = \frac{1}{B} (2e_t^2\lambda^2 + \lambda\sigma_\varepsilon^2).$$

代入 $B = 16$ 、 $\lambda = 4$ 、 $\sigma_\varepsilon^2 = 0.01$ 、 $e_t = 1$ ：

$$2e_t^2\lambda^2 + \lambda\sigma_\varepsilon^2 = 2 \cdot 1^2 \cdot 4^2 + 4 \cdot 0.01 = 32 + 0.04 = 32.04.$$

所以

$$\text{Var}[\bar{g}_t | e_t] = \frac{32.04}{16} = 2.0025.$$

即

$$\boxed{\text{Var}[\bar{g}_t | e_t] = 2.0025.}$$

习题 4：稳态方差与偏差-方差分解

延续习题 3 的设置： $\lambda = 4$ ， $\sigma_\varepsilon^2 = 0.01$ ， $B = 1$ ， $\eta = 0.2$ ，初始误差 $e_0 = 5$ 。

(a) 写出误差二阶矩的递推公式（后期近似，忽略方差中与 e_t^2 相关的项）：

$$\mathbb{E}[e_{t+1}^2] = (1 - \eta\lambda)^2 \mathbb{E}[e_t^2] + \frac{\eta^2 \lambda \sigma_\varepsilon^2}{B}$$

计算 $(1 - \eta\lambda)^2$ 和噪声注入项 $\eta^2\lambda\sigma_\varepsilon^2/B$ 的数值。

(b) 求稳态方差 V_∞ 。列出完整推导：从不动点条件出发，展开 $1 - (1 - \eta\lambda)^2 = \eta\lambda(2 - \eta\lambda)$ ，解出 $V_\infty = \eta\sigma_\varepsilon^2/[B(2 - \eta\lambda)]$ 。代入数值。

(c) 计算稳态预测误差 $\lambda \cdot V_\infty$ 。

(d) 分别计算以下修改后的 V_∞ ，验证 $V_\infty \propto \eta/B$ ：

	$\eta = 0.2, B = 1$	$\eta = 0.1, B = 1$
V_∞	(来自 (b))	
	$\eta = 0.2, B = 1$	$\eta = 0.2, B = 2$
V_∞	(来自 (b))	

(e) 用偏差-方差分解公式填写下表 ($\rho = |1 - \eta\lambda| = |1 - 0.8| = 0.2$)：

$$\mathbb{E}[e_t^2] = \rho^{2t} e_0^2 + V_\infty(1 - \rho^{2t})$$

t	Bias ² = $0.04^t \times 25$	Variance = $V_\infty(1 - 0.04^t)$	总误差
0			
1			
3			
5			
10			

估算转折步数 (Bias² $\approx$ Variance 的 t)。在转折点之后，应该如何调整 η ？为什么？

标准答案

(a) 递推系数与噪声注入项 题目给出的后期近似递推为

$$\mathbb{E}[e_{t+1}^2] = (1 - \eta\lambda)^2 \mathbb{E}[e_t^2] + \frac{\eta^2\lambda\sigma_\varepsilon^2}{B}.$$

先算收缩因子：

$$1 - \eta\lambda = 1 - 0.2 \times 4 = 0.2,$$

因此

$$(1 - \eta\lambda)^2 = 0.2^2 = 0.04.$$

噪声注入项为

$$\frac{\eta^2\lambda\sigma_\varepsilon^2}{B} = \frac{0.2^2 \cdot 4 \cdot 0.01}{1} = 0.04 \cdot 4 \cdot 0.01 = 0.0016.$$

故

$$(1 - \eta\lambda)^2 = 0.04, \quad \frac{\eta^2 \lambda \sigma_\varepsilon^2}{B} = 0.0016.$$

(b) 稳态方差 V_∞ 稳态时满足不动点条件

$$V_\infty = (1 - \eta\lambda)^2 V_\infty + \frac{\eta^2 \lambda \sigma_\varepsilon^2}{B}.$$

移项得

$$\left[1 - (1 - \eta\lambda)^2\right] V_\infty = \frac{\eta^2 \lambda \sigma_\varepsilon^2}{B}.$$

利用恒等式

$$1 - (1 - \eta\lambda)^2 = 1 - (1 - 2\eta\lambda + \eta^2 \lambda^2) = \eta\lambda(2 - \eta\lambda),$$

所以

$$V_\infty = \frac{\eta^2 \lambda \sigma_\varepsilon^2 / B}{\eta\lambda(2 - \eta\lambda)} = \frac{\eta \sigma_\varepsilon^2}{B(2 - \eta\lambda)}.$$

代入数值:

$$V_\infty = \frac{0.2 \times 0.01}{1 \times (2 - 0.8)} = \frac{0.002}{1.2} = \frac{1}{600} \approx 0.0016667.$$

因此

$$V_\infty = \frac{1}{600} \approx 0.0016667.$$

(c) 稳态预测误差 预测误差为

$$\lambda V_\infty = 4 \times \frac{1}{600} = \frac{1}{150} \approx 0.0066667.$$

故

$$\lambda V_\infty \approx 0.0066667.$$

(d) 验证 $V_\infty \propto \eta/B$ 利用公式

$$V_\infty = \frac{\eta \sigma_\varepsilon^2}{B(2 - \eta\lambda)}.$$

情形 1: $\eta = 0.1, B = 1$

$$V_\infty = \frac{0.1 \times 0.01}{1 \times (2 - 0.4)} = \frac{0.001}{1.6} = 0.000625.$$

情形 2: $\eta = 0.2, B = 2$

$$V_\infty = \frac{0.2 \times 0.01}{2 \times (2 - 0.8)} = \frac{0.002}{2.4} = 0.0008333 \dots$$

汇总如下:

(η, B)	(0.2, 1)	(0.1, 1)	(0.2, 2)
V_∞	0.0016667	0.000625	0.0008333

可以看到：减小 η 或增大 B 都会减小稳态方差；在小步长近似下，确实近似满足

$$V_{\infty} \propto \frac{\eta}{B}.$$

(e) 偏差-方差分解表与转折步数 题目给出

$$\mathbb{E}[e_t^2] = \rho^{2t} e_0^2 + V_{\infty}(1 - \rho^{2t}), \quad \rho = |1 - \eta\lambda| = 0.2.$$

故

$$\rho^{2t} = 0.04^t, \quad e_0^2 = 25, \quad V_{\infty} = \frac{1}{600} \approx 0.0016667.$$

填写表格：

t	Bias ² = $25 \cdot 0.04^t$	Variance = $V_{\infty}(1 - 0.04^t)$	总误差
0	25	0	25
1	1	0.0016	1.0016
3	0.0016	0.00166656	0.00326656
5	2.56×10^{-6}	0.001666666496	0.001669226496
10	2.62×10^{-13}	0.001666666666666665	0.001666666666692879

转折点由

$$\text{Bias}^2 \approx \text{Variance} \iff 25 \cdot 0.04^t \approx \frac{1}{600}$$

给出，即

$$0.04^t \approx \frac{1}{15000}.$$

解得

$$t \approx \frac{\ln(1/15000)}{\ln(0.04)} \approx 2.99.$$

故转折大约发生在

$$t \approx 3.$$

在转折点之后，Bias 已经很小，Variance 开始主导，因此应当 **减小步长 η** 。原因是：更小的 η 会降低稳态方差，从而减小噪声平台，提高最终精度。

习题 5：线性缩放法则与临界 Batch Size

$d = 50$ 维线性回归，各向同性 $\lambda_i = 1$ ($\text{tr}(\Sigma) = 50$), $\sigma_{\varepsilon}^2 = 0.04$, 目标精度 $\epsilon = 10^{-3}$ 。

(a) 写出稳态预测误差的小步长近似：预测误差 _{∞} $\approx \frac{\eta \sigma_{\varepsilon}^2 \text{tr}(\Sigma)}{2B}$ 。

- (b) 当前 $\eta = 0.1$, $B = 32$ 。代入计算稳态预测误差。是否满足 $\leq \epsilon$?
- (c) 将 B 增大到 128。按线性缩放法则 $\eta/B = \text{const}$, η 应调到多少? 验证稳态误差不变。Bias 衰减速度如何变化?
- (d) 计算临界 batch size。取 $\eta_{\max} = 2/L = 2$ (各向同性时 $L = 1$):
- $$B_{\text{crit}} = \frac{\eta_{\max} \text{tr}(\Sigma) \sigma_{\epsilon}^2}{2\epsilon}$$
- (e) 令 $B = 10000 \gg B_{\text{crit}}$ 。此时 η 最大只能取 $\eta_{\max} = 2$ 。计算对应的稳态预测误差。与 $B = B_{\text{crit}}$ 时比较: B 增大了多少倍? 误差降低了多少倍? 说明收益递减。

标准答案

(a) 稳态预测误差的小步长近似 题目给出的公式为

$$\text{预测误差}_{\infty} \approx \frac{\eta \sigma_{\epsilon}^2 \text{tr}(\Sigma)}{2B}.$$

代入本题中的 $\sigma_{\epsilon}^2 = 0.04$ 与 $\text{tr}(\Sigma) = 50$:

$$\text{预测误差}_{\infty} \approx \frac{\eta \cdot 0.04 \cdot 50}{2B} = \frac{\eta \cdot 2}{2B} = \frac{\eta}{B}.$$

因此这里可简化为

$$\boxed{\text{预测误差}_{\infty} \approx \frac{\eta}{B}.$$

(b) 当 $\eta = 0.1, B = 32$ 时

$$\text{预测误差}_{\infty} \approx \frac{0.1}{32} = 0.003125.$$

与目标精度比较:

$$0.003125 > 0.001.$$

因此

$$\boxed{\text{不满足 } \leq \epsilon.}$$

(c) 把 B 增大到 128 后的线性缩放 线性缩放法则要求

$$\frac{\eta}{B} = \text{const}.$$

从 $(\eta, B) = (0.1, 32)$ 放大到 $B = 128$, batch 增大了 4 倍, 因此步长也应增大 4 倍:

$$\eta' = 0.4.$$

这时稳态误差为

$$\frac{\eta'}{B'} = \frac{0.4}{128} = 0.003125,$$

与原来相同，所以

稳态误差保持不变。

Bias 衰减速度由收缩因子控制。对于各向同性 $\lambda = 1$ ，收缩因子近似为

$$\rho = |1 - \eta|.$$

原来 $\eta = 0.1$ 时， $\rho = 0.9$ ；放大后 $\eta = 0.4$ 时， $\rho = 0.6$ 。因此 Bias 衰减更快。

(d) **临界 batch size** 各向同性时 $L = 1$ ，因此

$$\eta_{\max} = \frac{2}{L} = 2.$$

题目给出的临界 batch size 为

$$B_{\text{crit}} = \frac{\eta_{\max} \text{tr}(\Sigma) \sigma_{\epsilon}^2}{2\epsilon}.$$

代入数值：

$$B_{\text{crit}} = \frac{2 \cdot 50 \cdot 0.04}{2 \cdot 10^{-3}} = \frac{4}{0.002} = 2000.$$

故

$$B_{\text{crit}} = 2000.$$

(e) 当 $B = 10000 \gg B_{\text{crit}}$ 时 此时由于步长不能超过稳定上限，只能取

$$\eta = \eta_{\max} = 2.$$

对应稳态预测误差

$$\text{预测误差}_{\infty} \approx \frac{\eta \sigma_{\epsilon}^2 \text{tr}(\Sigma)}{2B} = \frac{2 \cdot 0.04 \cdot 50}{2 \cdot 10000} = \frac{4}{20000} = 0.0002.$$

所以

$$\text{预测误差}_{\infty} \approx 2 \times 10^{-4}.$$

而当 $B = B_{\text{crit}} = 2000$ ，且 $\eta = \eta_{\max} = 2$ 时，误差恰好为

$$\epsilon = 10^{-3}.$$

比较二者：

- Batch size 从 2000 增大到 10000，增大了

$$\frac{10000}{2000} = 5$$

倍；

- 稳态误差从 10^{-3} 降到 2×10^{-4} ，降低了

$$\frac{10^{-3}}{2 \times 10^{-4}} = 5$$

倍。

但一旦超过 B_{crit} ，就无法再通过继续增大 η 来加速 Bias 衰减了；也就是说，最终噪声会继续下降，但优化速度不再随 batch 线性提升，这就是收益递减。

习题 6: Regret 的计算与学习率衰减

一维问题: $\lambda = 1$, $\sigma_\epsilon^2 = 1$, $B = 1$, $e_0 = 10$ 。

(a) 对固定步长 η , 期望累积 regret 近似为:

$$\text{Regret}_T \approx \underbrace{\frac{e_0^2}{4\eta}}_{\text{Bias 总贡献}} + \underbrace{\frac{T\eta\lambda\sigma_\epsilon^2}{4}}_{\text{Variance 累积}}$$

解释两项的来源 (Bias 的几何级数求和、Variance 的线性累积)。

(b) 取 $T = 10000$, 分别计算 $\eta = 0.01$ 、 $\eta = 0.1$ 、 $\eta = 1.0$ 时的 Regret。填表:

η	Bias 项 $e_0^2/(4\eta)$	Var 项 $T\eta/(4)$	总 Regret
0.01			
0.1			
1.0			

哪个 η 最好? 最好的那个两项是否接近平衡?

(c) 对 η 求导令其为零, 推导最优固定步长 $\eta^* = e_0/(\sigma_\epsilon\sqrt{T\lambda})$ 。代入 $T = 10000$ 计算 η^* 和 Regret_T^* 。验证 $\text{Regret}^* = O(\sqrt{T})$ 。

(d) 对衰减步长 $\eta_t = 1/(\lambda t)$, 每步期望 excess loss $\approx c/t$ 。估算 $\text{Regret}_{10000} \approx c \sum_{t=1}^{10000} 1/t \approx c(\ln 10000 + 0.577)$ 。取 $c = L/(2\mu) = 1/2$, 计算结果。与 (c) 比较差多少倍?

(e) 如果训练开始前不知道 T (不知道要训练多久), 固定步长需要 T 来选 η^* , 而衰减步长 $\eta_t = 1/t$ 不需要。从实用角度, 你推荐哪种? 如果 T 已知呢?

标准答案

(a) 两项来源解释 题目给出的固定步长 regret 近似为

$$\text{Regret}_T \approx \underbrace{\frac{e_0^2}{4\eta}}_{\text{Bias 总贡献}} + \underbrace{\frac{T\eta\lambda\sigma_\epsilon^2}{4}}_{\text{Variance 累积}}.$$

- 第一项 $e_0^2/(4\eta)$ 来自 Bias 的几何衰减求和。因为较大的 η 会更快消除初始误差, 所以这一项随 η 增大而减小。
- 第二项 $T\eta\lambda\sigma_\epsilon^2/4$ 来自每一步噪声带来的稳态方差近似, 其在 T 步内线性累积, 因此随 η 增大而增大。

因此, 固定步长需要在“消 Bias 快”与“累积噪声大”之间权衡。

(b) 计算 $T = 10000$ 时的三个 regret 这里

$$\frac{e_0^2}{4\eta} = \frac{100}{4\eta} = \frac{25}{\eta}, \quad \frac{T\eta\lambda\sigma_\varepsilon^2}{4} = \frac{10000\eta}{4} = 2500\eta.$$

逐一代入：

η	Bias 项 $25/\eta$	Var 项 2500η	总 Regret
0.01	2500	25	2525
0.1	250	250	500
1.0	25	2500	2525

因此最好的固定步长是

$$\eta = 0.1.$$

它的两个部分正好相等，说明最优点处确实接近平衡。

(c) 最优固定步长与最优 regret 令

$$R(\eta) = \frac{e_0^2}{4\eta} + \frac{T\eta\lambda\sigma_\varepsilon^2}{4}.$$

对 η 求导：

$$R'(\eta) = -\frac{e_0^2}{4\eta^2} + \frac{T\lambda\sigma_\varepsilon^2}{4}.$$

令 $R'(\eta) = 0$ ，得

$$\frac{e_0^2}{\eta^2} = T\lambda\sigma_\varepsilon^2 \implies \eta^* = \frac{e_0}{\sigma_\varepsilon\sqrt{T\lambda}}.$$

本题中 $e_0 = 10$ ， $\sigma_\varepsilon = 1$ ， $T = 10000$ ， $\lambda = 1$ ，故

$$\eta^* = \frac{10}{\sqrt{10000}} = \frac{10}{100} = 0.1.$$

最优 regret 为

$$\text{Regret}_T^* = \frac{100}{4 \times 0.1} + \frac{10000 \times 0.1}{4} = 250 + 250 = 500.$$

即

$$\eta^* = 0.1, \quad \text{Regret}_{10000}^* = 500.$$

由于

$$\eta^* \propto T^{-1/2},$$

代回后可得

$$\text{Regret}_T^* = O(\sqrt{T}).$$

(d) **衰减步长 $\eta_t = 1/(\lambda t)$ 的 regret 估算** 题目给出每步 excess loss 近似为

$$\frac{c}{t}.$$

因此

$$\text{Regret}_{10000} \approx c \sum_{t=1}^{10000} \frac{1}{t} \approx c(\ln 10000 + 0.577).$$

取 $c = L/(2\mu) = 1/2$, 则

$$\text{Regret}_{10000} \approx \frac{1}{2}(\ln 10000 + 0.577).$$

又因为

$$\ln 10000 \approx 9.21034,$$

所以

$$\text{Regret}_{10000} \approx \frac{1}{2}(9.21034 + 0.577) = \frac{1}{2} \cdot 9.78734 \approx 4.89367.$$

故

$$\boxed{\text{Regret}_{10000} \approx 4.89.}$$

与 (c) 的 500 相比, 比例约为

$$\frac{500}{4.89367} \approx 102.17.$$

即这个近似下衰减步长小了大约

$$\boxed{102 \text{ 倍}.}$$

说明: 这两者来自不同层次的近似模型, 因此数值上不必机械过度解读; 但它确实反映出 **衰减步长在长时间训练时能更好抑制后期噪声累积**。

(e) **实用建议** 如果训练前 **不知道总步数 T** , 更推荐用衰减步长 (如 $1/t$ 或更平滑的 cosine decay), 因为它不依赖对 T 的精确预估, 鲁棒性更好。

如果 T **已知**, 则可以根据 T 设计更接近最优的固定步长或分段衰减策略; 这时固定步长在前期通常更激进, 后续再衰减, 实践中往往效果更好。

习题 7: Xavier 与 He 初始化的方差传播

3 层 MLP, 结构 $784 \rightarrow 256 \rightarrow 64 \rightarrow 10$ 。前两层用 ReLU 激活, 最后一层无激活。

(a) 计算每层的 Xavier 初始化方差 $\sigma_W^2 = 2/(n_{\text{in}} + n_{\text{out}})$:

层	n_{in}	n_{out}	Xavier σ_W^2
1	784	256	
2	256	64	
3	64	10	

(b) 计算每层的 He 初始化方差 $\sigma_W^2 = 2/n_{\text{in}}$:

层	n_{in}	He σ_W^2
1	784	
2	256	
3	64	

(c) 用 He 初始化, 假设输入方差 $\text{Var}[x] = 1$, 逐层计算前向方差。每层的放大因子为 $n_{\text{in}} \cdot \sigma_W^2 \cdot \frac{1}{2}$ (ReLU 减半), 最后一层无 ReLU 所以不乘 1/2:

层	$n_{\text{in}} \sigma_W^2$	ReLU?	放大因子	累积方差
输入	—	—	—	1
1		是		
2		是		
3		否		

(d) 如果错误地用固定 $\sigma_W^2 = 0.001$, 重复 (c) 的计算。输出方差是多少? 与 (c) 差多少倍?

(e) 将网络加深到 6 层 $784 \rightarrow 256 \rightarrow 256 \rightarrow 256 \rightarrow 256 \rightarrow 256 \rightarrow 10$ (前 5 层 ReLU, 最后一层无激活), 分别用 He 和固定 $\sigma_W^2 = 0.001$ 计算输出方差。深度如何放大初始化偏差?

提示

He 初始化下每层 (带 ReLU) 的放大因子 $= n_{\text{in}} \cdot (2/n_{\text{in}}) \cdot 1/2 = 1$, 所以方差严格保持。

标准答案

(a) Xavier 初始化方差 Xavier 初始化取

$$\sigma_W^2 = \frac{2}{n_{\text{in}} + n_{\text{out}}}.$$

逐层计算:

层	n_{in}	n_{out}	Xavier σ_W^2
1	784	256	$\frac{2}{784 + \frac{256}{2}} = \frac{2}{1040} \approx 0.00192308$
2	256	64	$\frac{2}{\frac{256}{2} + 64} = \frac{2}{320} = 0.00625$
3	64	10	$\frac{2}{64 + 10} = \frac{2}{74} \approx 0.0270270$

(b) He 初始化方差 He 初始化取

$$\sigma_W^2 = \frac{2}{n_{\text{in}}}.$$

逐层计算：

层	n_{in}	He σ_W^2
1	784	$\frac{2}{784} \approx 0.00255102$
2	256	$\frac{2}{256} = 0.0078125$
3	64	$\frac{2}{64} = 0.03125$

(c) 用 He 初始化计算前向方差传播 题目给出的放大因子为

$$n_{\text{in}} \sigma_W^2 \times \frac{1}{2}$$

(若该层后面有 ReLU)，最后一层无 ReLU，所以不乘 1/2。

输入方差取 $\text{Var}[x] = 1$ 。

- 第 1 层：

$$n_{\text{in}} \sigma_W^2 = 784 \cdot \frac{2}{784} = 2,$$

因为后面有 ReLU，放大因子为 $2 \times \frac{1}{2} = 1$ 。累积方差仍为 1。

- 第 2 层：

$$n_{\text{in}} \sigma_W^2 = 256 \cdot \frac{2}{256} = 2,$$

放大因子同样为 1。累积方差仍为 1。

- 第 3 层（无 ReLU）：

$$n_{\text{in}} \sigma_W^2 = 64 \cdot \frac{2}{64} = 2,$$

无 ReLU，因此放大因子为 2。输出方差变为 2。

整理成表：

层	$n_{\text{in}}\sigma_W^2$	ReLU?	放大因子	累积方差
输入	—	—	—	1
1	2	是	1	1
2	2	是	1	1
3	2	否	2	2

故输出方差为

$$\boxed{2.}$$

(d) 若错误地取固定 $\sigma_W^2 = 0.001$ 逐层计算：

- 第 1 层：

$$n_{\text{in}}\sigma_W^2 = 784 \times 0.001 = 0.784,$$

经 ReLU 后放大因子为

$$0.784 \times \frac{1}{2} = 0.392.$$

累积方差： $1 \times 0.392 = 0.392$ 。

- 第 2 层：

$$n_{\text{in}}\sigma_W^2 = 256 \times 0.001 = 0.256,$$

经 ReLU 后放大因子为

$$0.256 \times \frac{1}{2} = 0.128.$$

累积方差：

$$0.392 \times 0.128 = 0.050176.$$

- 第 3 层（无 ReLU）：

$$n_{\text{in}}\sigma_W^2 = 64 \times 0.001 = 0.064.$$

输出方差：

$$0.050176 \times 0.064 = 0.003211264.$$

因此输出方差为

$$\boxed{0.003211264.}$$

与 He 初始化下的输出方差 2 相比，差了

$$\frac{2}{0.003211264} \approx 622.81$$

倍。也就是说，固定过小方差会导致信号在前向传播中严重衰减。

(e) 加深到 6 层网络后的比较 新结构为

$$784 \rightarrow 256 \rightarrow 256 \rightarrow 256 \rightarrow 256 \rightarrow 256 \rightarrow 10,$$

前 5 层 ReLU，最后一层无激活。

He 初始化：每个带 ReLU 的层都有放大因子

$$256 \cdot \frac{2}{256} \cdot \frac{1}{2} = 1$$

(第一层也同理)。因此前 5 层都保持方差不变，最后一层无 ReLU：

$$256 \cdot \frac{2}{256} = 2.$$

所以输出方差仍为

$$\boxed{2.}$$

固定 $\sigma_W^2 = 0.001$ ：

- 第一层放大因子： $784 \times 0.001 \times \frac{1}{2} = 0.392$ ；
- 中间 4 个 $256 \rightarrow 256$ ReLU 层，每层放大因子：

$$256 \times 0.001 \times \frac{1}{2} = 0.128;$$

- 最后一层无 ReLU，放大因子：

$$256 \times 0.001 = 0.256.$$

因此输出方差为

$$1 \times 0.392 \times 0.128^4 \times 0.256 \approx 2.6938 \times 10^{-5}.$$

即

$$\boxed{\text{Var}_{\text{out}} \approx 2.69 \times 10^{-5}.}$$

与 He 初始化的 2 相比，差了

$$\frac{2}{2.6938 \times 10^{-5}} \approx 7.42 \times 10^4$$

倍。

这说明：**网络越深，初始化方差的微小偏差会被层层连乘，最终造成指数级放大或衰减。**这正是深层网络必须使用合适初始化（如 ReLU 对应 He）的根本原因。

习题 8：两层网络的 Warmup 体验

两层线性网络 $f(x; u, v) = v \cdot u \cdot x$ ，单样本 $(x, y) = (1, 1)$ ，MSE 损失 $L(u, v) = \frac{1}{2}(vu - 1)^2$ 。

梯度： $\partial L / \partial u = (vu - 1)v$ ， $\partial L / \partial v = (vu - 1)u$ 。

Hessian： $\mathbf{H} = \begin{pmatrix} v^2 & 2uv - 1 \\ 2uv - 1 & u^2 \end{pmatrix}$ 。

(a) 初始化 $u_0 = v_0 = 3$ 。计算：初始 Loss、梯度、Hessian 矩阵。求 Hessian 的特征值 ($\lambda = \frac{u^2+v^2}{2} \pm \sqrt{(\frac{u^2-v^2}{2})^2 + (2uv-1)^2}$ ，对称初始化时简化为 $v^2 \pm (2uv-1)$)。

(b) 计算 $\eta_{\max} = 2/\lambda_{\max}$ 。

(c) 用 $\eta = 0.05$ （满足稳定性），执行 3 步 GD。每步写出 (u_t, v_t) 、 L_t 。

(d) 用 $\eta = 0.15$ （不满足稳定性），执行 3 步 GD。Loss 是上升还是下降？

(e) Warmup 方案：前若干步用 $\eta_w = 0.03$ ，每步之后检查当前点的 $\lambda_{\max}$ 是否满足 $\eta = 0.15 < 2/\lambda_{\max}$ 。找到最早可以安全切换的步数 T_w ，然后切到 $\eta = 0.15$ 继续执行 2 步。

填写汇总表：

步	(u_t, v_t)	L_t	阶段
0	(3, 3)		
1			Warmup (η_w)
$\vdots$			
T_w			
$T_w + 1$			$\eta = 0.15$
$T_w + 2$			$\eta = 0.15$

对比：无 Warmup 的 $\eta = 0.15$ 在第 3 步的 Loss vs 有 Warmup 方案在同一步的 Loss。

标准答案

(a) 初始 Loss、梯度与 Hessian 特征值 初始化 $u_0 = v_0 = 3$ 。

初始 Loss：

$$L_0 = \frac{1}{2}(3 \cdot 3 - 1)^2 = \frac{1}{2} \cdot 8^2 = 32.$$

初始梯度：

$$\left. \frac{\partial L}{\partial u} \right|_{(3,3)} = (9-1) \cdot 3 = 24, \quad \left. \frac{\partial L}{\partial v} \right|_{(3,3)} = (9-1) \cdot 3 = 24.$$

故

$$\nabla L(u_0, v_0) = (24, 24).$$

初始 Hessian：

$$\mathbf{H}_0 = \begin{pmatrix} 9 & 17 \\ 17 & 9 \end{pmatrix}.$$

在对称初始化 $u = v = s$ 时，Hessian 的两个特征值可简化为

$$\lambda_{\pm} = s^2 \pm (2s^2 - 1).$$

当 $s = 3$ 时：

$$\lambda_+ = 9 + 17 = 26, \quad \lambda_- = 9 - 17 = -8.$$

因此

$$L_0 = 32, \quad \nabla L_0 = (24, 24), \quad \lambda_{\max} = 26, \quad \lambda_{\min} = -8.$$

(b) 局部稳定上界 依据局部二次近似，若只看最大正曲率方向，则 GD 的局部稳定步长上界可取

$$\eta_{\max} = \frac{2}{\lambda_{\max}} = \frac{2}{26} = \frac{1}{13} \approx 0.076923.$$

故

$$\eta_{\max} \approx 0.076923.$$

(c) 用 $\eta = 0.05$ 执行 3 步 GD 由于初始点对称且梯度也对称，所以迭代过程中始终有 $u_t = v_t = s_t$ 。此时更新可写为

$$s_{t+1} = s_t - \eta(s_t^2 - 1)s_t.$$

第 0 步：

$$(u_0, v_0) = (3, 3), \quad L_0 = 32.$$

第 1 步：

$$g_0 = (9-1) \cdot 3 = 24,$$

$$u_1 = v_1 = 3 - 0.05 \cdot 24 = 1.8.$$

故

$$L_1 = \frac{1}{2}(1.8^2 - 1)^2 = \frac{1}{2}(2.24)^2 = 2.5088.$$

第 2 步：

$$g_1 = (1.8^2 - 1) \cdot 1.8 = 2.24 \cdot 1.8 = 4.032,$$

$$u_2 = v_2 = 1.8 - 0.05 \cdot 4.032 = 1.5984.$$

故

$$L_2 = \frac{1}{2}(1.5984^2 - 1)^2 \approx 1.20883.$$

第 3 步：

$$g_2 = (1.5984^2 - 1) \cdot 1.5984 \approx 2.4853242839,$$

$$u_3 = v_3 \approx 1.5984 - 0.05 \cdot 2.4853242839 \approx 1.4741338.$$

故

$$L_3 = \frac{1}{2}(1.4741338^2 - 1)^2 \approx 0.688047.$$

因此 3 步结果为

$$(u_1, v_1) = (1.8, 1.8), \quad L_1 = 2.5088;$$

$$(u_2, v_2) = (1.5984, 1.5984), \quad L_2 \approx 1.20883;$$

$$(u_3, v_3) \approx (1.47413, 1.47413), \quad L_3 \approx 0.68805.$$

(d) 用 $\eta = 0.15$ 执行 3 步 GD 虽然 $0.15 > \eta_{\max} \approx 0.076923$ ，但这只是初始点附近的局部稳定界；由于本问题是非凸的，且 Hessian 会随位置迅速变化，所以违反这个局部界 **并不必然意味着 Loss 立刻爆炸**。

继续按对称递推：

第 1 步：

$$u_1 = v_1 = 3 - 0.15 \cdot 24 = -0.6.$$

故

$$L_1 = \frac{1}{2}((-0.6)^2 - 1)^2 = \frac{1}{2}(-0.64)^2 = 0.2048.$$

第 2 步：

$$g_1 = ((-0.6)^2 - 1)(-0.6) = (-0.64)(-0.6) = 0.384,$$

$$u_2 = v_2 = -0.6 - 0.15 \cdot 0.384 = -0.6576.$$

故

$$L_2 = \frac{1}{2}((-0.6576)^2 - 1)^2 \approx 0.161063.$$

第 3 步：

$$g_2 = ((-0.6576)^2 - 1)(-0.6576) \approx 0.373229,$$

$$u_3 = v_3 \approx -0.6576 - 0.15 \cdot 0.373229 \approx -0.713584.$$

故

$$L_3 = \frac{1}{2}((-0.713584)^2 - 1)^2 \approx 0.120441.$$

因此

$$L_t \text{ 仍在下降, 而不是上升。}$$

其原因是：第一步虽然跨出了初始点附近的线性稳定区，但同时把参数迅速带到了一个曲率更小、Loss 更低的区域。

(e) Warmup: 何时可安全切换到 $\eta = 0.15$ 当 $u = v = s$ 时，最大特征值为

$$\lambda_{\max} = 3s^2 - 1.$$

要安全使用 $\eta = 0.15$ ，需满足

$$0.15 < \frac{2}{\lambda_{\max}} \iff \lambda_{\max} < \frac{2}{0.15} = 13.333\dots$$

即

$$3s^2 - 1 < 13.333\dots \iff s^2 < 4.777\dots \iff |s| < 2.1858.$$

现在用 warmup 步长 $\eta_w = 0.03$:

步 0:

$$(s_0, L_0) = (3, 32), \quad \lambda_{\max} = 26,$$

此时显然不能切换。

步 1:

$$s_1 = 3 - 0.03 \cdot 24 = 2.28,$$

$$L_1 = \frac{1}{2}(2.28^2 - 1)^2 \approx 8.813281,$$

$$\lambda_{\max} = 3 \cdot 2.28^2 - 1 = 14.5952, \quad \frac{2}{\lambda_{\max}} \approx 0.1370 < 0.15.$$

仍不能切换。

步 2:

$$s_2 = 2.28 - 0.03(2.28^2 - 1)2.28 \approx 1.99282944,$$

$$L_2 = \frac{1}{2}(1.99282944^2 - 1)^2 \approx 4.414517,$$

$$\lambda_{\max} = 3 \cdot 1.99282944^2 - 1 \approx 10.9141, \quad \frac{2}{\lambda_{\max}} \approx 0.18325 > 0.15.$$

因此最早可在 第 2 步结束后切换，即

$$T_w = 2.$$

切换后继续用 $\eta = 0.15$ 两步:

步 3:

$$s_3 = s_2 - 0.15(s_2^2 - 1)s_2 \approx 1.104615,$$

$$L_3 \approx 0.0242382.$$

步 4:

$$s_4 = s_3 - 0.15(s_3^2 - 1)s_3 \approx 1.068134,$$

$$L_4 \approx 0.00992773.$$

汇总表如下:

步	(u_t, v_t)	L_t	阶段
0	(3, 3)	32	初始
1	(2.28, 2.28)	8.813281	Warmup ($\eta_w = 0.03$)
2	(1.992829, 1.992829)	4.414517	Warmup ($\eta_w = 0.03$)
3	(1.104615, 1.104615)	0.0242382	切换到 $\eta = 0.15$
4	(1.068134, 1.068134)	0.00992773	$\eta = 0.15$

比较第 3 步的 Loss:

- 无 Warmup、直接用 $\eta = 0.15$:

$$L_3 \approx 0.120441;$$

- 先 Warmup 2 步、再切换:

$$L_3 \approx 0.0242382.$$

因此 Warmup 方案在同样第 3 步时的 Loss 更低, 约为直接大步长方案的

$$\frac{0.0242382}{0.120441} \approx 0.201.$$

即大约低了 5 倍。

习题 9：归一化对收敛速度的影响

标准答案

问题回顾 考虑二维二次函数

$$f(x, y) = \frac{1}{2}(10000x^2 + y^2), \quad \nabla^2 f = \text{diag}(10000, 1).$$

故 $\mu = \lambda_{\min} = 1$, $L = \lambda_{\max} = 10000$, 条件数 $\kappa = L/\mu = 10000$ 。我们将沿用梯度下降 (GD) 的经典结论：

对强凸、 L -光滑的二次函数，最优固定步长

$$\eta^* = \frac{2}{\mu + L}, \quad \rho^* = \frac{\kappa - 1}{\kappa + 1},$$

每步误差按 ρ^* 收缩： $\|x_t - x^*\| \leq (\rho^*)^t \|x_0 - x^*\|$ 。达到相对精度 ε 所需步数为 $T \geq \frac{\log(1/\varepsilon)}{\log(1/\rho^*)}$ 。

(a) **原始问题的收敛步数** 代入 $\mu = 1$, $L = 10000$ ：

$$\eta^* = \frac{2}{\mu + L} = \frac{2}{1 + 10000} = \frac{2}{10001} \approx 1.9998 \times 10^{-4},$$

$$\rho^* = \frac{\kappa - 1}{\kappa + 1} = \frac{9999}{10001} \approx 0.99980002.$$

为得到 $\log(1/\rho^*)$ ，用 $\log(1+u) \approx u$ (当 u 充分小)：

$$\log \frac{1}{\rho^*} = \log \frac{10001}{9999} = \log \left(1 + \frac{2}{9999} \right) \approx \frac{2}{9999} \approx 2.0002 \times 10^{-4}.$$

于是达到 $\varepsilon = 0.01$ (即 1%) 所需步数

$$T_{(a)} = \frac{\log 100}{\log(1/\rho^*)} \approx \frac{4.6052}{2.0002 \times 10^{-4}} \approx 23\,024 \text{ 步}.$$

快速估计公式. 当 κ 较大时， $\log(1/\rho^*) \approx 2/\kappa$ ，因此

$$T \approx \frac{\kappa}{2} \log \frac{1}{\varepsilon} = \frac{10000}{2} \cdot \log 100 \approx 5000 \times 4.605 \approx 23\,026.$$

两者吻合良好。

(b) 归一化后的条件数 令 $\tilde{x} = 100x$, 则 $x = \tilde{x}/100$, 代入原函数:

$$f\left(\frac{\tilde{x}}{100}, y\right) = \frac{1}{2} \left(10000 \cdot \frac{\tilde{x}^2}{10000} + y^2 \right) = \frac{1}{2} (\tilde{x}^2 + y^2).$$

此时 Hessian 为 $\text{diag}(1, 1) = I$, 因此

$$\mu = 1, \quad L = 1, \quad \boxed{\kappa = 1.}$$

几何解释. 原函数的等高线是极扁的椭圆 (x 方向轴长是 y 方向的 $1/100$), 梯度下降呈严重 zigzag; 变量替换把坐标轴“拉长”到同一尺度, 等高线变成正圆, 各方向曲率完全一致。

(c) 归一化后的最优步长、收敛速率与步数 代入 $\mu = L = 1$:

$$\eta^* = \frac{2}{\mu + L} = \frac{2}{2} = 1, \quad \rho^* = \frac{\kappa - 1}{\kappa + 1} = \frac{0}{2} = 0.$$

由于 $\rho^* = 0$, 一次迭代就把误差变为零——事实上对于 $f(\tilde{x}, y) = \frac{1}{2} \|\mathbf{z}\|^2$, 步长 $\eta = 1$ 的梯度步正是

$$\mathbf{z}_1 = \mathbf{z}_0 - \nabla f(\mathbf{z}_0) = \mathbf{z}_0 - \mathbf{z}_0 = \mathbf{0}.$$

$$\boxed{T_{(c)} = 1 \text{ 步即达到精确解, 远优于 } 1\% \text{ 精度.}}$$

(严格按公式: $T = \log(100)/\log(1/0) = 0$ 步以内即可, 即第一步就收敛。)

(d) 加速比

$$\text{加速比} = \frac{T_{(a)}}{T_{(c)}} = \frac{23024}{1} \approx \boxed{2.3 \times 10^4}.$$

换言之, 仅仅对变量做一次线性缩放, 就把 GD 的计算量压缩了四个数量级。这从 (c) 的解释看非常自然: 归一化抹平了方向间的曲率差异, zigzag 完全消失。

从条件数看: 加速比约等于 $\kappa/2 \cdot \log(1/\varepsilon)/T_{(c)} \approx \kappa/2 \cdot \log(1/\varepsilon)$ 。也就是说, 每把 κ 减一半, GD 步数就减半——**条件数是 GD 成本的主要驱动量**。

(e) 推广到高维 设 $d = 100$, Hessian 的谱 $\lambda_{\max} = 10^6$, $\lambda_{\min} = 1$ 。

不归一化. $\kappa = 10^6$, 所以

$$T_{\text{raw}} \sim \frac{\kappa}{2} \log \frac{1}{\varepsilon} = \frac{10^6}{2} \cdot \log 100 \approx 5 \times 10^5 \times 4.605 \approx \boxed{2.3 \times 10^6 \text{ 步.}}$$

标准化后. 在每个坐标 i 上做替换 $\tilde{z}_i = \sqrt{\lambda_i} z_i$ (等价于对输入做白化 / 对权重做 μP 风格的按谱重缩放), 新 Hessian 变为单位阵, $\kappa \approx 1$ 。因此

$$T_{\text{norm}} \approx \boxed{1 \text{ 步.}}$$

加速比:

$$\frac{T_{\text{raw}}}{T_{\text{norm}}} \approx 2.3 \times 10^6.$$

结论汇总

问题	κ	η^*	ρ^*	降到 1% 的步数
(a) 原始 2D	10^4	$2/10001$	$9999/10001$	$\approx 23\,024$
(c) 归一化 2D	1	1	0	1
(e) 原始高维	10^6	$2/(1+10^6)$	$(\kappa-1)/(\kappa+1)$	$\approx 2.3 \times 10^6$
(e) 白化高维	≈ 1	≈ 1	≈ 0	≈ 1

关键教益.

1. 一阶方法的收敛步数几乎线性依赖于条件数 κ 。
2. 对二次问题，按谱对角化的线性预处理 = 完美白化 $\Rightarrow \kappa \rightarrow 1 \Rightarrow$ 一步收敛。
3. 实践中完整的 Hessian 不可知，但近似白化（BatchNorm / LayerNorm / 特征标准化 / Adam 的 $1/\sqrt{v}$ 自适应缩放 / μP 的按层重缩放）都可视作**近似条件数压缩**，这正是它们加速训练的理论来源。
4. 对于神经网络的非二次损失，上述结论对应到局部的 Hessian 特征谱；近年 Newton / Shampoo / Muon 等二阶/块对角方法本质上就在做“按谱归一化”，以逼近 $\kappa \approx 1$ 的理想情形。

习题 10：综合设计题

你拿到一个回归数据集： $d = 200$ 个特征， $n = 50000$ 个样本。经过初步分析：

- 特征未归一化，方差范围从 0.01 到 10^4
 - 观测噪声 $\sigma_\varepsilon^2 \approx 0.1$
 - 你打算用 5 层 MLP（隐藏层宽度 512）+ ReLU 训练
 - GPU 内存支持 micro-batch $B_{\text{micro}} = 128$
- (a) **条件数分析**：未归一化时 $\kappa \approx \lambda_{\max}/\lambda_{\min} = 10^4/0.01 = ?$ 。用最优步长 GD，消除 Bias 到 1% 需要 $\sim (\kappa/2) \log(100) \approx ?$ 步。
 - (b) **归一化**：标准化后各特征方差 ≈ 1 ， $\kappa \approx ?$ 。收敛步数变为多少？加速多少倍？
 - (c) **初始化**：ReLU 网络应选 Xavier 还是 He？写出每层的 σ_W^2 （结构 $200 \rightarrow 512 \rightarrow 512 \rightarrow 512 \rightarrow 512 \rightarrow 1$ ）。

- (d) **学习率估算**: 利用 $\lambda_{\max} \sim nL$ ($n = 512$, $L = 5$), 估算 $\eta_{\max} \sim 2/(nL)$ 。你会选择 $\eta_{\text{target}} \approx \eta_{\max}/3$ 到 $\eta_{\max}/4$ ——这是多少?
- (e) **Batch size 与线性缩放**: 你决定用 $B = 1024$ (gradient accumulation 8 步)。如果 $B = 128$ 时最优 $\eta = 0.001$, 线性缩放给出 $B = 1024$ 时 $\eta = ?$ 。
- (f) **临界 batch size**: $B_{\text{crit}} \approx d_{\text{eff}} \cdot \sigma_{\epsilon}^2 / \epsilon$ 。取 $d_{\text{eff}} \approx d = 200$, 目标 $\epsilon = 10^{-3}$ 。 $B_{\text{crit}} = ?$ 。
 $B = 1024$ 是否超过 B_{crit} ? 还有增大 B 的空间吗?
- (g) **完整训练方案**: 综合以上分析, 写出你的训练方案 (一段话即可):
- 数据预处理
 - 初始化方法
 - 学习率与 batch size
 - Warmup 策略 (步数、形状)
 - 学习率衰减 (Cosine/Step Decay)
 - 是否需要 Gradient Clipping

对每个选择, 用一句话说明理由 (引用本讲的哪个结论)。

标准答案

训练优化方案设计

已知数据维度 $d = 200$, 样本数 $n = 50000$, 观测噪声方差 $\sigma_{\epsilon}^2 \approx 0.1$ 。模型为 5 层 ReLU MLP, 隐藏层宽度为 512, GPU 支持的 micro-batch 为 128。

解答

1. 条件数分析

未归一化时, 特征方差范围为 0.01 到 10^4 , 所以

$$\kappa \approx \frac{\lambda_{\max}}{\lambda_{\min}} = \frac{10^4}{0.01} = 10^6.$$

对强凸二次问题, 使用最优步长的梯度下降, Bias 降到原来的 1% 大约需要

$$T_{\text{raw}} \approx \frac{\kappa}{2} \log(100) = \frac{10^6}{2} \times 4.605 \approx 2.30 \times 10^6$$

步。

这说明: 不归一化时, 不同方向的尺度差别太大, 梯度下降会被最慢的方向拖住。

2. 归一化的影响

标准化后，每个特征的方差约为 1。如果特征之间相关性不强，则协方差矩阵的特征值会集中在 1 附近，因此可以近似认为

$$\kappa_{\text{norm}} \approx 1.$$

此时 Bias 降到 1% 需要的步数约为

$$T_{\text{norm}} \approx \frac{1}{2} \log(100) \approx 2.30.$$

加速倍数约为

$$\frac{T_{\text{raw}}}{T_{\text{norm}}} \approx 10^6.$$

所以第一步必须做 Z-Score 标准化：

$$x_j \leftarrow \frac{x_j - \mu_j}{s_j}.$$

3. 初始化选择

该网络使用 ReLU，因此应选择 He 初始化，而不是 Xavier 初始化。原因很简单：ReLU 会把负半轴的激活变为 0，信号方差大约会损失一半；He 初始化把权重方差设大一倍，用来补回这部分损失。

He 初始化公式为

$$\sigma_W^2 = \frac{2}{n_{\text{in}}}.$$

网络结构为

$$200 \rightarrow 512 \rightarrow 512 \rightarrow 512 \rightarrow 512 \rightarrow 1.$$

因此每层的权重方差为：

层	n_{in}	$\sigma_W^2 = 2/n_{\text{in}}$
1	200	0.010000
2	512	0.003906
3	512	0.003906
4	512	0.003906
5	512	0.003906

4. 学习率估算

题目给出估算方式

$$\lambda_{\max} \sim nL,$$

其中隐藏层宽度 $n = 512$, 网络层数 $L = 5$, 所以

$$\lambda_{\max} \sim 512 \times 5 = 2560.$$

梯度下降稳定学习率大约满足

$$\eta_{\max} \sim \frac{2}{\lambda_{\max}} = \frac{2}{2560} \approx 7.81 \times 10^{-4}.$$

更稳妥的目标学习率可取

$$\eta_{\text{target}} \approx \frac{\eta_{\max}}{3} \sim \frac{\eta_{\max}}{4},$$

即

$$\eta_{\text{target}} \in [1.95 \times 10^{-4}, 2.60 \times 10^{-4}].$$

这个数值是从曲率角度得到的保守估计, 适合作为训练开始阶段的安全学习率。

5. Batch Size 与线性缩放

现在希望使用有效 batch size

$$B = 1024.$$

由于 GPU 一次只能放下

$$B_{\text{micro}} = 128,$$

所以可以使用梯度累积:

$$\text{accumulation steps} = \frac{1024}{128} = 8.$$

如果 $B = 128$ 时较好的学习率为 $\eta = 0.001$, 按照线性缩放规则

$$\frac{\eta}{B} = \text{常数},$$

得到

$$\eta_{1024} = 0.001 \times \frac{1024}{128} = 0.008.$$

因此 0.008 可以作为大 batch 训练的候选学习率。但它明显大于上一问中的保守稳定估计, 所以不建议一开始直接跳到 0.008, 而应配合 warmup 和训练监控使用。

6. 临界 Batch Size

取

$$d_{\text{eff}} \approx d = 200, \quad \sigma_{\varepsilon}^2 = 0.1, \quad \epsilon = 10^{-3}.$$

临界 batch size 近似为

$$B_{\text{crit}} \approx \frac{d_{\text{eff}} \sigma_{\varepsilon}^2}{\epsilon} = \frac{200 \times 0.1}{10^{-3}} = 20000.$$

当前

$$B = 1024 < B_{\text{crit}} = 20000.$$

所以 $B = 1024$ 还没有超过临界 batch size。若显存或多卡资源允许，继续增大 batch size 仍然有空间；但越接近 20000，收益会越小。

7. 完整训练方案

一个更稳妥、也更灵活的训练方案如下。

1. **数据预处理**：对每个输入特征做 Z-Score 标准化，使各维尺度接近，降低条件数，加快收敛。
2. **初始化**：使用 He 初始化，

$$W_{ij} \sim \mathcal{N}\left(0, \frac{2}{n_{\text{in}}}\right),$$

因为 ReLU 会损失一部分信号方差，He 初始化能让深层信号更稳定。

3. **Batch size**：使用有效 batch size

$$B = 1024,$$

通过 8 次 micro-batch 梯度累积实现：

$$128 \times 8 = 1024.$$

4. **学习率**：线性缩放给出的候选峰值学习率为

$$\eta_{\text{peak}} = 0.008.$$

但由于曲率估计给出的安全范围约为

$$2 \times 10^{-4} \sim 3 \times 10^{-4},$$

实际训练中采用“两段式”策略：先从 0 warmup 到 2.5×10^{-4} ，观察 loss 是否平稳；若平稳，再继续升到 0.008，否则峰值学习率保持在安全范围附近。

5. **Warmup**: 训练集大小为 50000, $B = 1024$, 每个 epoch 约有

$$\left\lceil \frac{50000}{1024} \right\rceil = 49$$

步。建议使用 5 到 10 个 epoch 的线性 warmup, 也就是约

$$245 \sim 490$$

步。这样可以避免训练初期因为曲率过大而发散。

6. **学习率衰减**: warmup 后使用余弦衰减:

$$\eta_t = \eta_{\min} + \frac{1}{2} (\eta_{\text{peak}} - \eta_{\min}) \left(1 + \cos \frac{\pi t}{T} \right).$$

它比阶梯式下降更平滑, 训练过程不容易突然抖动。

7. **梯度裁剪**: 建议使用梯度范数裁剪, 例如

$$\|\nabla_{\theta} \ell\|_2 \leq 1.0.$$

这样即使某一步梯度突然变大, 也不会把参数推到很差的位置。

8. **小型探测实验**: 正式长训练前, 先用 5% 的数据跑 1 到 2 个 epoch, 比较三个峰值学习率

$$2.5 \times 10^{-4}, \quad 10^{-3}, \quad 8 \times 10^{-3}.$$

选择 loss 下降最快且没有震荡的那个。这一步成本很低, 但能避免盲目使用过大的学习率。

最终推荐配置可以写成:

标准化输入特征;
He 初始化;
 $B = 1024$, $B_{\text{micro}} = 128$, 梯度累积 8 步;
 $\eta_{\text{peak}} \in [2.5 \times 10^{-4}, 0.008]$, 由 warmup 探测后确定;
5 ~ 10 epochs 线性 warmup;
warmup 后使用 cosine decay;
使用 gradient clipping, 阈值 1.0.

这套方案的核心想法是: 先把数据尺度调平, 再让网络初始信号稳定, 最后用较大的 batch 提高吞吐量; 学习率不盲目取最大, 而是通过 warmup 和小型探测实验来确认安全上限。

标准答案

(a) 未归一化时的条件数与 Bias 消除步数 未归一化时可粗略估计

$$\kappa \approx \frac{\lambda_{\max}}{\lambda_{\min}} = \frac{10^4}{0.01} = 10^6.$$

若用最优步长 GD，要把 Bias 压到 1%，步数近似为

$$\frac{\kappa}{2} \ln 100.$$

代入得

$$\frac{10^6}{2} \cdot 4.60517 \approx 2.3026 \times 10^6.$$

因此

$$\kappa \approx 10^6, \quad \text{所需步数约 } 2.3 \times 10^6.$$

(b) 标准化后的改善 若对每个特征做标准化，使方差都约为 1，则谱分布会显著变平，粗略可取

$$\kappa \approx 1.$$

理想二次模型下，此时最优 GD 约 1 步即可把 Bias 消除到极低水平；即使在真实网络中，也可理解为从“百万级病态”降为“常数级条件数”。

因此可写为

$$\kappa \approx 1, \quad \text{步数从约 } 2.3 \times 10^6 \text{ 降为 } O(1).$$

粗略加速倍数约为

$$2.3 \times 10^6 \text{ 倍 (理想化估计)}.$$

(c) 初始化选择与各层方差 由于隐藏层使用 ReLU，标准做法应选择 He 初始化来保持方差传播稳定。

对结构

$$200 \rightarrow 512 \rightarrow 512 \rightarrow 512 \rightarrow 512 \rightarrow 1$$

若对 ReLU 层采用 He 初始化，取

$$\sigma_W^2 = \frac{2}{n_{\text{in}}}.$$

则：

层	结构	建议初始化	σ_W^2
1	200 $\rightarrow$ 512	He	$2/200 = 0.01$
2	512 $\rightarrow$ 512	He	$2/512 = 0.00390625$
3	512 $\rightarrow$ 512	He	$2/512 = 0.00390625$
4	512 $\rightarrow$ 512	He	$2/512 = 0.00390625$
5	512 $\rightarrow$ 1	Xavier / He	$2/(512 + 1) \approx 0.00389864$

说明：最后一层无 ReLU，因此严格来说用 Xavier 更自然；但由于 $2/513$ 与 $2/512$ 数值几乎一致，工程实现中也常直接沿用 Kaiming/He。

(d) **曲率估计下的学习率上界** 按题目提示，用宽度 $n = 512$ 、层数 $L = 5$ 粗略估计

$$\lambda_{\max} \sim nL = 512 \times 5 = 2560.$$

因此

$$\eta_{\max} \sim \frac{2}{nL} = \frac{2}{2560} = 0.00078125.$$

若取目标学习率为其 $1/3$ 到 $1/4$ ，则

$$\eta_{\text{target}} \approx \frac{0.00078125}{3} \sim \frac{0.00078125}{4},$$

即

$$\eta_{\text{target}} \approx (1.95 \times 10^{-4}) \sim (2.60 \times 10^{-4}).$$

(e) **Batch size 线性缩放** 若在 $B = 128$ 时经验上最优学习率为

$$\eta = 0.001,$$

那么当全局 batch 增大到

$$B = 1024 = 8 \times 128$$

时，按线性缩放法则

$$\eta \propto B,$$

可得

$$\eta' = 0.001 \times \frac{1024}{128} = 0.008.$$

因此线性缩放给出

$$\eta = 0.008.$$

但要强调：这是 **经验缩放值**。它必须与 (d) 的稳定性估计一起看；若两者冲突，实践中应先采用更保守的学习率并配合 warmup，再逐步上调验证。

(f) **临界 batch size** 题目给出

$$B_{\text{crit}} \approx \frac{d_{\text{eff}} \sigma_{\epsilon}^2}{\epsilon}.$$

取 $d_{\text{eff}} \approx d = 200$ ， $\sigma_{\epsilon}^2 = 0.1$ ， $\epsilon = 10^{-3}$ ，则

$$B_{\text{crit}} \approx \frac{200 \times 0.1}{10^{-3}} = \frac{20}{0.001} = 20000.$$

即

$$B_{\text{crit}} \approx 20000.$$

现在使用的全局 batch 是 1024, 显然

$$1024 < 20000.$$

因此它 **没有超过** 临界 batch size, 仍然有继续增大 batch 的空间。大约还可再放大

$$\frac{20000}{1024} \approx 19.53$$

倍才接近临界区。

(g) **一个完整且自治的训练方案** 一个可执行的训练方案如下:

- **数据预处理:** 对 200 个特征全部做标准化 (零均值、单位方差)。理由: 标准化能大幅降低条件数, 显著加快 Bias 衰减, 避免某些方向梯度过大、某些方向梯度过小。
- **初始化:** 隐藏层使用 He 初始化, 输出层使用 Xavier (或近似等价的 He)。理由: ReLU 网络用 He 初始化可保持前向与反向信号方差稳定, 避免深层网络出现激活爆炸或消失。
- **Batch size:** 采用 micro-batch 128, 做 8 步 gradient accumulation, 得到全局 batch $B = 1024$ 。理由: 这在不超显存的前提下提高了有效 batch, 并降低了梯度方差; 且由于 $1024 \ll B_{\text{crit}}$, 仍处在线性缩放可能有效的区间内。
- **学习率:** 第一版实验建议采用保守峰值学习率

$$\eta_{\text{peak}} \approx 2 \times 10^{-4} \sim 3 \times 10^{-4},$$

而不直接机械使用 0.008。

理由: 0.008 是线性缩放得到的候选值, 但题目中的粗略曲率估计给出更紧的稳定上界, 因此更合理的做法是先用保守峰值跑通训练, 再根据验证集和训练稳定性尝试上调。

- **Warmup:** 使用 500 到 1000 步线性 warmup, 从接近 0 的学习率缓慢升到峰值学习率。

理由: 训练初期 Hessian 最大特征值常较大, warmup 可以避免一开始就用过大的步长导致不稳定; 这与前面 Warmup 题的分析一致。

- **学习率衰减：**warmup 结束后使用 cosine decay。

理由：后期应减小学习率以降低稳态方差和噪声平台；cosine 衰减比硬切换更平滑，通常更稳定。

- **Gradient Clipping：**建议使用，例如全局范数裁剪到 1.0。

理由：虽然标准化和 He 初始化已能显著改善稳定性，但 5 层 ReLU 网络在训练初期仍可能出现局部梯度尖峰；裁剪能防止偶发大梯度破坏优化轨迹。

综上，一套简洁的建议可以概括为：

先做特征标准化；隐藏层用 He 初始化；用全局 batch 1024；学习率从 0 线性 warmup 到 $2 \times 10^{-4} \sim 3 \times 10^{-4}$ ；随后用 cosine decay；并启用适度 gradient clipping。若训练完全稳定，再尝试逐步提高峰值学习率，验证线性缩放在该模型上的可用范围。