

第 7 讲习题：题目与解答

从范数约束看优化器：SGD $\rightarrow$ Muon

说明：本习题紧扣第 7 讲的五条主线——梯度/Hessian 的 Kronecker 结构、 ℓ_2 范数下的 GD/牛顿/动量、 ℓ_∞ 范数下的 SignGD 与权重衰减、谱范数下的 $UV^\top$ 与 Shampoo 恒等式、RMS $\rightarrow$ RMS 范数下的 Muon/Newton-Schulz。所有数值题都可手算完成，建议先算干净再想物理意义。

1 题 1：梯度的秩 1 结构与 Hessian 的 Kronecker 积 (§1)

1.1 题目

考虑一个 2 输出、2 输入的 ReLU 层

$$h = Wx, \quad z = \text{ReLU}(h), \quad L = \frac{1}{2} \|z - y\|^2.$$

取

$$W = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \quad x = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad y = \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

- (a) 计算 h 、 z 、 $\delta = \partial L / \partial h$ ，写出 $\nabla_W L = \delta x^\top$ 。验证它是秩 1 外积。
- (b) 用讲义给出的公式 $H = (xx^\top) \otimes H_h$ 写出完整 Hessian $H \in \mathbb{R}^{4 \times 4}$ （对 $\text{vec}(W)$ ）。给出它的秩并说明理由。
- (c) 把 W 的第二行改成 $(-1, -1)$ （其他不变）。重新计算 h ，指出哪个神经元变为不活跃， $D_{\sigma'}$ 长什么样， H_h 的秩从多少变到多少，整个 H 的秩变成多少。
- (d) (思考) mini-batch 大小 $B = 32$ 、 $\min(m, d) = 768$ 时，full-batch 梯度的秩上界是多少？这对诱导范数约束下的最优更新 $UV^\top$ 意味着什么？（提示： $UV^\top$ 的秩 = $\text{rank}(G)$ 。）

1.2 解答

1.2.1 (a)

$$h = Wx = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 1 \end{pmatrix}.$$

两个分量都为正, 所以

$$z = \text{ReLU}(h) = \begin{pmatrix} 3 \\ 1 \end{pmatrix}, \quad z - y = \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$$

由于两个神经元均处在 ReLU 的激活区间, $D_{\sigma'} = I_2$, 因此

$$\delta = \frac{\partial L}{\partial h} = D_{\sigma'}(z - y) = \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$$

于是

$$\nabla_W L = \delta x^\top = \begin{pmatrix} 2 \\ 1 \end{pmatrix} \begin{pmatrix} 2 & 1 \end{pmatrix} = \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix}.$$

这显然是一个外积矩阵, 并且第二行等于第一行的一半, 所以秩为 1。

1.2.2 (b)

在当前激活模式下, $H_h = I_2$, 且

$$xx^\top = \begin{pmatrix} 2 \\ 1 \end{pmatrix} \begin{pmatrix} 2 & 1 \end{pmatrix} = \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix}.$$

按题目给出的向量化约定,

$$H = (xx^\top) \otimes H_h = \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} \otimes I_2 = \begin{pmatrix} 4 & 0 & 2 & 0 \\ 0 & 4 & 0 & 2 \\ 2 & 0 & 1 & 0 \\ 0 & 2 & 0 & 1 \end{pmatrix}.$$

由于

$$\text{rank}(xx^\top) = 1, \quad \text{rank}(H_h) = 2,$$

而 Kronecker 积满足

$$\text{rank}(A \otimes B) = \text{rank}(A)\text{rank}(B),$$

所以

$$\text{rank}(H) = 1 \times 2 = 2.$$

1.2.3 (c)

修改权重为

$$W = \begin{pmatrix} 1 & 1 \\ -1 & -1 \end{pmatrix},$$

计算预激活

$$\mathbf{h} = W\mathbf{x} = \begin{pmatrix} 1 & 1 \\ -1 & -1 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ -3 \end{pmatrix}.$$

第一神经元 $h_1 = 3 > 0$ 处于活跃状态, 第二神经元 $h_2 = -3 < 0$ 变为不活跃。

ReLU 激活导数为

$$\sigma'(t) = \begin{cases} 1, & t > 0 \\ 0, & t < 0 \end{cases},$$

构造激活导数对角矩阵

$$D_{\sigma'} = \text{diag}(\sigma'(h_1), \sigma'(h_2)) = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}.$$

损失对预激活 $\mathbf{h}$ 的 Hessian 完整定义为

$$H_h \triangleq \nabla_{\mathbf{h}}^2 L = D_{\sigma'}^\top (\nabla_z^2 L) D_{\sigma'},$$

平方损失满足 $\nabla_z^2 L = \mathbf{I}_2$, 因此

$$H_h = D_{\sigma'}^\top \mathbf{I}_2 D_{\sigma'} = D_{\sigma'}^2.$$

代入矩阵计算得

$$H_h = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}.$$

H_h 的秩由原先 **2** 变为 **1**; 由克罗内克积秩性质 $\text{rank}(A \otimes B) = \text{rank}(A) \cdot \text{rank}(B)$, 结合 $\text{rank}(xx^\top) = 1$, 可得整体 Hessian 的秩变为 **1**。

1.2.4 (d)

单个样本的层梯度是一个外积 $\delta x^\top$, 秩最多为 1。mini-batch 梯度是 B 个外积的和, 因此

$$\text{rank}(G) \leq \min(B, m, d).$$

当 $B = 32$ 且 $\min(m, d) = 768$ 时,

$$\text{rank}(G) \leq \min(32, 768) = 32.$$

因此谱范数约束下的最优更新

$$\Delta W^* = -\eta UV^\top$$

也是低秩的, 并且

$$\text{rank}(UV^\top) = \text{rank}(G) \leq 32.$$

这说明小 batch 下的 $UV^\top$ 更新只作用在梯度实际张成的低维子空间中。

2 题 2: GD、Newton、Heavy Ball 在新起点上的对比

2.1 题目

仍用讲义贯穿全文的线性回归例子:

$$X = \begin{pmatrix} 2 & 1 \\ 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad y = \begin{pmatrix} 5 \\ 1 \\ 2 \end{pmatrix}, \quad H = X^\top X = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix}, \quad w^* = \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$$

特征值

$$\lambda_1 = 6, \quad \lambda_2 = 1, \quad \kappa = 6.$$

但换一个初始点:

$$w_0 = \begin{pmatrix} 5 \\ -1 \end{pmatrix}.$$

提示. 复数根判据:

$$a_i^2 < 4\mu, \quad a_i = 1 + \mu - \eta\lambda_i.$$

在复数根区域,

$$|z_\pm| = \sqrt{\mu}.$$

2.2 解答

已知

$$H = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix}, \quad w^* = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad w_0 = \begin{pmatrix} 5 \\ -1 \end{pmatrix}.$$

因此初始误差为

$$e_0 = w_0 - w^* = \begin{pmatrix} 5 \\ -1 \end{pmatrix} - \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ -2 \end{pmatrix}.$$

2.2.1 (a) 梯度方向、Newton 方向与一步收敛

二次型目标的梯度为

$$g_0 = H(w_0 - w^*) = He_0.$$

代入计算:

$$g_0 = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix} \begin{pmatrix} 3 \\ -2 \end{pmatrix} = \begin{pmatrix} 15 - 4 \\ 6 - 4 \end{pmatrix} = \begin{pmatrix} 11 \\ 2 \end{pmatrix}.$$

因此 GD 的下降方向为

$$-\frac{g_0}{\|g_0\|_2} = -\frac{1}{\sqrt{11^2 + 2^2}} \begin{pmatrix} 11 \\ 2 \end{pmatrix} = -\frac{1}{\sqrt{125}} \begin{pmatrix} 11 \\ 2 \end{pmatrix} = -\frac{1}{5\sqrt{5}} \begin{pmatrix} 11 \\ 2 \end{pmatrix}.$$

即

$$-\frac{g_0}{\|g_0\|_2} = \begin{pmatrix} -\frac{11}{5\sqrt{5}} \\ -\frac{2}{5\sqrt{5}} \end{pmatrix}.$$

Newton 方向为

$$-H^{-1}g_0.$$

由题目给出

$$H^{-1} = \frac{1}{6} \begin{pmatrix} 2 & -2 \\ -2 & 5 \end{pmatrix}.$$

所以

$$H^{-1}g_0 = \frac{1}{6} \begin{pmatrix} 2 & -2 \\ -2 & 5 \end{pmatrix} \begin{pmatrix} 11 \\ 2 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} 22 - 4 \\ -22 + 10 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} 18 \\ -12 \end{pmatrix} = \begin{pmatrix} 3 \\ -2 \end{pmatrix}.$$

因此 Newton 方向为

$$-H^{-1}g_0 = \begin{pmatrix} -3 \\ 2 \end{pmatrix}.$$

Newton 一步更新:

$$w_1^{\text{Newton}} = w_0 - H^{-1}g_0 = \begin{pmatrix} 5 \\ -1 \end{pmatrix} - \begin{pmatrix} 3 \\ -2 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix} = w^*.$$

所以

$$\text{Newton 方法一步收敛到 } w^*.$$




图 1: 四种方法在等高线上的轨迹对比 ($w_0 = (5, -1)$)。Newton 法 (绿色) 沿 $-H^{-1}g_0$ 一步抵达 w^* ; GD (红色, $\eta^* = 2/7$) 沿 Hessian 的长轴方向 Z 字形振荡; Heavy Ball 最优参数 (蓝色, $\mu^* \approx 0.177$) 单步沿主轴跨度更大但累计误差衰减最快; Heavy Ball 取 $\mu = 0.5$ 时 (紫色) 出现明显的过冲振荡, 这正是动量过大时复根区域 $|z_{\pm}| = \sqrt{\mu} \approx 0.707$ 的几何表现。

2.2.2 (b) 最优 GD 学习率下的一步收缩

最优固定步长 GD 学习率为

$$\eta^* = \frac{2}{\lambda_1 + \lambda_2} = \frac{2}{6 + 1} = \frac{2}{7}.$$

GD 更新为

$$w_1 = w_0 - \eta^* g_0.$$

代入:

$$w_1 = \begin{pmatrix} 5 \\ -1 \end{pmatrix} - \frac{2}{7} \begin{pmatrix} 11 \\ 2 \end{pmatrix} = \begin{pmatrix} 5 - \frac{22}{7} \\ -1 - \frac{4}{7} \end{pmatrix} = \begin{pmatrix} \frac{13}{7} \\ -\frac{11}{7} \end{pmatrix}.$$

于是

$$w_1 - w^* = \begin{pmatrix} \frac{13}{7} \\ -\frac{11}{7} \end{pmatrix} - \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} -\frac{1}{7} \\ -\frac{18}{7} \end{pmatrix}.$$

所以

$$\|w_1 - w^*\|_2 = \sqrt{\left(-\frac{1}{7}\right)^2 + \left(-\frac{18}{7}\right)^2} = \frac{1}{7} \sqrt{1 + 324} = \frac{\sqrt{325}}{7} = \frac{5\sqrt{13}}{7}.$$

而

$$\|w_0 - w^*\|_2 = \left\| \begin{pmatrix} 3 \\ -2 \end{pmatrix} \right\|_2 = \sqrt{3^2 + (-2)^2} = \sqrt{13}.$$

因此

$$\frac{\|w_1 - w^*\|_2}{\|w_0 - w^*\|_2} = \frac{\frac{5\sqrt{13}}{7}}{\sqrt{13}} = \frac{5}{7}.$$

所以

$$\boxed{\frac{\|w_1 - w^*\|_2}{\|w_0 - w^*\|_2} = \frac{5}{7}.$$

这正好等于

$$\frac{\kappa - 1}{\kappa + 1} = \frac{6 - 1}{6 + 1} = \frac{5}{7}.$$

因此满足

$$\boxed{\frac{\|w_1 - w^*\|_2}{\|w_0 - w^*\|_2} \leq \frac{5}{7}.$$

2.2.3 (c) Heavy Ball 的最优参数

讲义中给出 Heavy Ball 的最优参数满足

$$\sqrt{\mu^*} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}.$$

这里

$$\kappa = 6,$$

所以

$$\sqrt{\mu^*} = \frac{\sqrt{6} - 1}{\sqrt{6} + 1}.$$

因此

$$\mu^* = \left(\frac{\sqrt{6} - 1}{\sqrt{6} + 1} \right)^2.$$

展开得

$$\mu^* = \frac{(\sqrt{6} - 1)^2}{(\sqrt{6} + 1)^2} = \frac{7 - 2\sqrt{6}}{7 + 2\sqrt{6}}.$$

也可以有理化为

$$\mu^* = \frac{73 - 28\sqrt{6}}{25}.$$

因此

$$\mu^* = \left(\frac{\sqrt{6} - 1}{\sqrt{6} + 1} \right)^2 = \frac{73 - 28\sqrt{6}}{25}.$$

对应的学习率为

$$\eta^* = \frac{(1 + \sqrt{\mu^*})^2}{\lambda_{\max}}.$$

因为

$$\lambda_{\max} = 6, \quad \sqrt{\mu^*} = \frac{\sqrt{6} - 1}{\sqrt{6} + 1},$$

所以

$$1 + \sqrt{\mu^*} = 1 + \frac{\sqrt{6} - 1}{\sqrt{6} + 1} = \frac{2\sqrt{6}}{\sqrt{6} + 1}.$$

于是

$$(1 + \sqrt{\mu^*})^2 = \frac{24}{(\sqrt{6} + 1)^2}.$$

因此

$$\eta^* = \frac{1}{6} \cdot \frac{24}{(\sqrt{6} + 1)^2} = \frac{4}{(\sqrt{6} + 1)^2}.$$

又因为

$$(\sqrt{6} + 1)^2 = 7 + 2\sqrt{6},$$

所以

$$\eta^* = \frac{4}{7 + 2\sqrt{6}}.$$

有理化后也可以写成

$$\eta^* = \frac{4(7 - 2\sqrt{6})}{25}.$$

数值上,

$$\sqrt{\mu^*} \approx 0.4202, \quad \mu^* \approx 0.1766, \quad \eta^* \approx 0.3361.$$




图 2: 各算法的相对误差 $\|w_t - w^*\|_2 / \|w_0 - w^*\|_2$ 随迭代步数 t 的变化 (纵轴 $\log$ 尺度)。虚线为理论速率参考: GD 渐近斜率 $\log(5/7) \approx \log 0.714$; Heavy Ball 最优渐近斜率 $\log \frac{\sqrt{6}-1}{\sqrt{6}+1} \approx \log 0.420$, 比 GD 提高约一个数量级; 当 $\mu = 0.5$ 时复根区域决定速率 $\sqrt{\mu} \approx 0.707$, 数值上几乎与 GD 相同——动量过大相当于把加速优势抵消掉。

2.2.4 (d) 当 $\mu = 0.5$ 时的根类型与衰减率

Heavy Ball 在 Hessian 的每个特征方向上满足二阶递推

$$e_{t+1}^{(i)} = (1 + \mu - \eta\lambda_i)e_t^{(i)} - \mu e_{t-1}^{(i)}.$$

令

$$a_i = 1 + \mu - \eta\lambda_i,$$

则对应的特征方程为

$$z^2 - a_i z + \mu = 0.$$

判别式为

$$\Delta_i = a_i^2 - 4\mu.$$

如果

$$a_i^2 < 4\mu,$$

则是复数根区域，并且

$$|z_{\pm}| = \sqrt{\mu}.$$

这里取

$$\mu = 0.5, \quad \sqrt{\mu} = \frac{1}{\sqrt{2}}.$$

如果按照配套公式选择

$$\eta = \frac{(1 + \sqrt{\mu})^2}{\lambda_{\max}},$$

则

$$\eta = \frac{(1 + \frac{1}{\sqrt{2}})^2}{6}.$$

因为

$$\left(1 + \frac{1}{\sqrt{2}}\right)^2 = 1 + \sqrt{2} + \frac{1}{2} = \frac{3}{2} + \sqrt{2},$$

所以

$$\eta = \frac{\frac{3}{2} + \sqrt{2}}{6} = \frac{1}{4} + \frac{\sqrt{2}}{6}.$$

第一方向： $\lambda_1 = 6$. 此时

$$a_1 = 1 + \mu - \eta\lambda_1 = \frac{3}{2} - 6\left(\frac{1}{4} + \frac{\sqrt{2}}{6}\right).$$

计算得到

$$a_1 = \frac{3}{2} - \frac{3}{2} - \sqrt{2} = -\sqrt{2}.$$

因此

$$a_1^2 = 2, \quad 4\mu = 2.$$

所以

$$a_1^2 = 4\mu.$$

这是临界情形，即重根情形。对应根为

$$z = -\sqrt{\mu} = -\frac{1}{\sqrt{2}}.$$

因此该方向上的衰减率为

$$\rho_1 = \sqrt{\mu} = \frac{1}{\sqrt{2}} \approx 0.7071.$$

第二方向： $\lambda_2 = 1$. 此时

$$a_2 = 1 + \mu - \eta\lambda_2 = \frac{3}{2} - \left(\frac{1}{4} + \frac{\sqrt{2}}{6}\right) = \frac{5}{4} - \frac{\sqrt{2}}{6}.$$

数值上

$$a_2 \approx 1.0143.$$

于是

$$a_2^2 \approx 1.0288, \quad 4\mu = 2.$$

所以

$$a_2^2 < 4\mu.$$

因此第二个特征方向落在复数根区域。复数根的模长为

$$|z_{\pm}| = \sqrt{\mu} = \frac{1}{\sqrt{2}}.$$

所以该方向的衰减率为

$$\rho_2 = \sqrt{\mu} = \frac{1}{\sqrt{2}} \approx 0.7071.$$

总结。 当

$$\mu = 0.5$$

时，两个方向的主导衰减率都是

$$\rho = \sqrt{\mu} = \frac{1}{\sqrt{2}} \approx 0.7071.$$

而最优 GD 的收敛因子为

$$\frac{\kappa - 1}{\kappa + 1} = \frac{5}{7} \approx 0.7143.$$

可以看到

$$\frac{1}{\sqrt{2}} \approx 0.7071$$

已经非常接近

$$\frac{5}{7} \approx 0.7143.$$

因此，虽然 Heavy Ball 理论上可以加速，但当动量参数 μ 取得过大时，复数根区域中的衰减率由

$$\sqrt{\mu}$$

控制。此时 $\sqrt{\mu}$ 变大，导致收敛速度变慢。对于本题，

$$\sqrt{\mu} = 0.7071$$

已经接近 GD 的最优收敛率

0.7143.

所以结论是：

μ 取大后，Heavy Ball 的加速优势会消失，收敛率反而接近 GD。




图 3: Heavy Ball 在 (η, μ) 平面上的稳定性与根类型相图（左：大特征值方向 $\lambda_1 = 6$ ；右：小特征值方向 $\lambda_2 = 1$ ）。黑色虚线为 $a_i^2 = 4\mu$ 的判别曲线，下方为实根、上方为复根；红色实线 $\rho = 1$ 是稳定边界；灰色细线为谱半径 ρ 的等高线。工作点位置：GD（红圈）位于 $\mu = 0$ 轴；HB 最优参数（蓝三角）恰好落在大特征值方向的判别曲线 $a_1^2 = 4\mu$ 上；HB $\mu = 0.5$ （紫菱）在左图中正好压在临界曲线上（ $a_1^2 = 4\mu = 2$ ，重根），在右图中已经深入复根稳定区——这与正文 (d) 的代数结论完全吻合。

2.2.5 最终对比

方法	参数	一步或渐近表现
Newton	H^{-1}	一步到达 w^*
GD	$\eta^* = \frac{2}{7}$	一步误差比 $\frac{5}{7}$
Heavy Ball 最优	$\sqrt{\mu^*} = \frac{\sqrt{6}-1}{\sqrt{6}+1}$	理论收敛率 $\frac{\sqrt{6}-1}{\sqrt{6}+1} \approx 0.4202$
Heavy Ball, $\mu = 0.5$	$\sqrt{\mu} = \frac{1}{\sqrt{2}}$	收敛率 $\frac{1}{\sqrt{2}} \approx 0.7071 \approx \frac{5}{7}$

3 题 3: ℓ_∞ 范数、SignGD 与 AdamW 的平衡点 (§4–§5)

3.1 题目

仍用讲义的运行例子, $w_0 = (-1, 3)$, $g_0 = (-11, -2)$ 。

(a) 写出三个方向的更新 (单位化, 便于比较方向): GD 方向、SignGD 方向、Newton 方向。分别计算每个方向与最优方向 $w^* - w_0 = (3, -2)$ 的夹角 (用 $\cos \theta$ 给数值)。

(b) SignGD 的更新 $\Delta w = -\eta(\text{sign}(g_1), \text{sign}(g_2))$ 。在本题中 g_1, g_2 符号相同, SignGD 方向与 ℓ_2 方向的差距有多大? **设计一个反例**: 构造一个新的 g (保持 $\|g\|_2$ 不变), 使得 SignGD 方向优于 GD 方向 (即与牛顿方向夹角更小)。说明你的设计思路。

(c) (AdamW 的平衡点) 讲义 §5 指出, AdamW 在每方向上有平衡点 $|e_{\text{eq}}| = \eta/\lambda'$ (与 λ_i 无关)。直观上, Adam 的 $g/\sqrt{v}$ 把梯度幅值“抹平”成 $\text{sign}(g) \cdot 1$, 而权重衰减拉力 $\lambda'w$ 线性于 w 。在稳态下两者平衡:

$$\eta \cdot 1 = \lambda' \cdot |e_{\text{eq}}| \implies |e_{\text{eq}}| = \eta/\lambda'.$$

请在本例中: 设 $\eta = 0.01$, $\lambda' = 0.1$, 给出两方向的平衡点幅值。将其与 SGD + 权重衰减 (§3.4) 的偏差公式 $\alpha/(\lambda_i + \alpha) \cdot |\tilde{w}_i^*|$ 对比——**哪种优化器的偏差分布更“各向同性”?** **哪种更依赖 λ_i ?**

思考

这道题的核心观察: Adam 因为做了 $\sqrt{v}$ 归一化, 损失了 Hessian 的曲率信息——好处是稳定性不受 $\lambda_{\max}$ 约束 (可以用很大的 η), 坏处是权重衰减的偏差不再利用曲率信息。SGD 则相反。

3.2 解答

3.2.1 (a)

已知

$$w_0 = \begin{pmatrix} -1 \\ 3 \end{pmatrix}, \quad w^* = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad w^* - w_0 = \begin{pmatrix} 3 \\ -2 \end{pmatrix}.$$

最优方向, 也就是 Newton 方向, 为

$$d_N = \frac{1}{\sqrt{13}} \begin{pmatrix} 3 \\ -2 \end{pmatrix}.$$

GD 单位方向为

$$d_{\text{GD}} = -\frac{g_0}{\|g_0\|_2} = -\frac{1}{\sqrt{(-11)^2 + (-2)^2}} \begin{pmatrix} -11 \\ -2 \end{pmatrix} = \frac{1}{\sqrt{125}} \begin{pmatrix} 11 \\ 2 \end{pmatrix}.$$

SignGD 单位方向为

$$d_{\text{sign}} = -\frac{\text{sign}(g_0)}{\|\text{sign}(g_0)\|_2} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Newton 单位方向就是

$$d_{\text{N}} = \frac{1}{\sqrt{13}} \begin{pmatrix} 3 \\ -2 \end{pmatrix}.$$

三者与最优方向的夹角余弦分别为

$$\cos \theta_{\text{GD}} = d_{\text{GD}}^\top d_{\text{N}} = \frac{11 \cdot 3 + 2 \cdot (-2)}{\sqrt{125}\sqrt{13}} = \frac{29}{5\sqrt{65}} \approx 0.7194,$$

$$\cos \theta_{\text{sign}} = d_{\text{sign}}^\top d_{\text{N}} = \frac{3 - 2}{\sqrt{2}\sqrt{13}} = \frac{1}{\sqrt{26}} \approx 0.1961,$$

$$\cos \theta_{\text{N}} = 1.$$

因此本例中 SignGD 与最优方向偏差很大。

3.2.2 (b)

本题中 g_1, g_2 同号, 且都为负, 因此 SignGD 方向为

$$(1, 1),$$

而 GD 方向为

$$(11, 2).$$

二者的单位方向夹角余弦为

$$\frac{(11, 2) \cdot (1, 1)}{\sqrt{125}\sqrt{2}} = \frac{13}{\sqrt{250}} \approx 0.8222,$$

对应夹角约为 34.7° 。不过真正的问题是: 最优方向是 $(3, -2)$, 它在第四象限, 而 SignGD 方向 $(1, 1)$ 在第一象限, 所以 SignGD 在本例中非常差。

一个使 SignGD 优于 GD 的反例可以这样构造。保持

$$\|g\|_2 = \sqrt{125},$$

取

$$g = \begin{pmatrix} -\sqrt{124} \\ 1 \end{pmatrix}.$$

此时

$$\|g\|_2^2 = 124 + 1 = 125.$$

GD 更新方向为

$$-g = \begin{pmatrix} \sqrt{124} \\ -1 \end{pmatrix},$$

而 SignGD 更新方向为

$$-\text{sign}(g) = \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

SignGD 单位方向与 Newton 方向 $(3, -2)$ 的夹角余弦为

$$\frac{(1, -1) \cdot (3, -2)}{\sqrt{2}\sqrt{13}} = \frac{5}{\sqrt{26}} \approx 0.9806.$$

GD 单位方向与 Newton 方向的夹角余弦为

$$\frac{(\sqrt{124}, -1) \cdot (3, -2)}{\sqrt{125}\sqrt{13}} = \frac{3\sqrt{124} + 2}{\sqrt{1625}} \approx 0.8786.$$

因此这个例子中 SignGD 方向反而更接近 Newton 方向。设计思路是：让梯度符号给出正确象限，但让梯度幅值极度不均衡，从而使 GD 被一个坐标方向主导；SignGD 抹掉幅值后反而更接近目标方向。

3.2.3 (c)

AdamW 的方向平衡点满足

$$|e_{\text{eq}}| = \frac{\eta}{\lambda'}.$$

当

$$\eta = 0.01, \quad \lambda' = 0.1,$$

有

$$|e_{\text{eq}}| = \frac{0.01}{0.1} = 0.1.$$

所以两个方向的平衡点幅值都是

$$0.1,$$

与 Hessian 特征值 λ_i 无关。

相比之下，SGD + 权重衰减的偏差形式为

$$\frac{\alpha}{\lambda_i + \alpha} |\tilde{w}_i^*|.$$

它显式依赖 λ_i ：曲率越小， λ_i 越小，偏差比例越大；曲率越大，偏差比例越小。

因此 AdamW 的偏差分布更“各向同性”，因为不同方向的平衡点幅值相同；SGD + 权重衰减更依赖 λ_i ，因此偏差分布更“各向异性”。

4 题 4：谱范数约束、 $UV^\top$ 与 Shampoo 恒等式 (§7-§8)

4.1 题目

取

$$G = \begin{pmatrix} 0 & 4 & 0 \\ 3 & 0 & 0 \end{pmatrix} \in \mathbb{R}^{2 \times 3}.$$

(a) 直接从 $GG^\top$ 和 $G^\top G$ 的对角结构读出 SVD $G = U\Sigma V^\top$ 。给出 $U \in \mathbb{R}^{2 \times 2}$ 、 $\Sigma \in \mathbb{R}^{2 \times 2}$ 、 $V \in \mathbb{R}^{3 \times 2}$ (注意奇异值按从大到小排序, 所以第一列对应 $\sigma_1 = 4$, 第二列对应 $\sigma_2 = 3$)。

(b) 写出谱范数约束 $\|\Delta W\|_2 \leq \eta$ 下的最优更新 $\Delta W^* = -\eta UV^\top$ 。验证 $\|UV^\top\|_2 = 1$, 且两个方向上的更新幅度相同——这就是 $UV^\top$ 相对于 G 本身的”均衡化”效果。

(c) (Shampoo 恒等式) 用 moore-penrose 伪逆 ($G^\top G$ 有一个零特征值) 计算

$$(GG^\top)^{-1/4}, \quad (G^\top G)^{+,-1/4}$$

(即对非零特征值取 $-1/4$ 次幂, 零特征值保持为零)。然后验证

$$(GG^\top)^{-1/4} G (G^\top G)^{+,-1/4} = UV^\top.$$

(d) (诱导范数 vs Frobenius) G 的 Frobenius 范数下的”归一化”梯度为 $G/\|G\|_F$ 。写出 $\|G\|_F$, 并与 $UV^\top$ 对比三个方向上的更新幅度比 $\sigma_1 : \sigma_2 : \sigma_3$ 。根据讲义表格, F 范数给出 $4 : 3 : (0)$, 谱范数给出 $1 : 1 : (0)$ ——谱范数”保方向、削大值”, 为什么对条件数差的层有利?

提示: 对 2×3 矩阵, $GG^\top$ 的特征向量就是 U 的列, 特征值就是 σ_i^2 。本题 $GG^\top = \text{diag}(16, 9)$, 结构非常干净。

4.2 解答

4.2.1 (a) 从 $GG^\top$ 和 $G^\top G$ 的对角结构读出 SVD

题干 直接从 $GG^\top$ 和 $G^\top G$ 的对角结构读出 SVD $G = U\Sigma V^\top$ 。给出 $U \in \mathbb{R}^{2 \times 2}$ 、 $\Sigma \in \mathbb{R}^{2 \times 2}$ 、 $V \in \mathbb{R}^{3 \times 2}$ (注意奇异值按从大到小排序, 所以第一列对应 $\sigma_1 = 4$, 第二列对应 $\sigma_2 = 3$)。

解 首先计算 $GG^\top$ 与 $G^\top G$:

$$GG^\top = \begin{pmatrix} 0 & 4 & 0 \\ 3 & 0 & 0 \end{pmatrix} \begin{pmatrix} 0 & 3 \\ 4 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 16 & 0 \\ 0 & 9 \end{pmatrix},$$

$$G^{\top}G = \begin{pmatrix} 0 & 3 \\ 4 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 0 & 4 & 0 \\ 3 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 9 & 0 & 0 \\ 0 & 16 & 0 \\ 0 & 0 & 0 \end{pmatrix}.$$

由于 $GG^{\top} = \text{diag}(16, 9)$ 已经是对角矩阵, 其特征值为 $\sigma_1^2 = 16$, $\sigma_2^2 = 9$, 对应的单位特征向量恰好就是标准基向量。按奇异值从大到小排列, $\sigma_1 = 4$ 对应 $GG^{\top}$ 的第一个特征向量, $\sigma_2 = 3$ 对应第二个, 因此

$$U = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I_2.$$

类似地, $G^{\top}G = \text{diag}(9, 16, 0)$ 的非零特征值为 16 和 9, 对应的单位特征向量分别为 $\mathbf{e}_2 = (0, 1, 0)^{\top}$ 和 $\mathbf{e}_1 = (1, 0, 0)^{\top}$ 。注意排列顺序必须与奇异值一致: $\sigma_1 = 4$ 对应特征值 16, 其特征向量为 $\mathbf{e}_2$; $\sigma_2 = 3$ 对应特征值 9, 其特征向量为 $\mathbf{e}_1$ 。因此

$$V = \begin{pmatrix} 0 & 1 \\ 1 & 0 \\ 0 & 0 \end{pmatrix}.$$

奇异值矩阵为

$$\Sigma = \begin{pmatrix} 4 & 0 \\ 0 & 3 \end{pmatrix}.$$

验证:

$$U\Sigma V^{\top} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 4 & 0 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 4 & 0 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 4 & 0 \\ 3 & 0 & 0 \end{pmatrix} = G.$$

4.2.2 (b) 谱范数约束下的最优更新与 $UV^{\top}$ 的均衡化效果

题干 写出谱范数约束 $\|\Delta W\|_2 \leq \eta$ 下的最优更新 $\Delta W^* = -\eta UV^{\top}$ 。验证 $\|UV^{\top}\|_2 = 1$, 且两个方向上的更新幅度相同——这就是 $UV^{\top}$ 相对于 G 本身的**均衡化**效果。

解 对于 $G = U\Sigma V^{\top}$, 最优更新为

$$\Delta W^* = -\eta UV^{\top} = -\eta \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix}.$$

验证 $\|UV^{\top}\|_2 = 1$:

$$UV^{\top} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix}.$$

计算

$$(UV^\top)(UV^\top)^\top = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 1 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I_2.$$

因此 $UV^\top$ 的两个奇异值均为 1, 从而 $\|UV^\top\|_2 = 1$ 。

均衡化效果: 在原始梯度 G 中, 两个非零奇异方向的幅度分别为 $\sigma_1 = 4$ 和 $\sigma_2 = 3$, 比值为 $4:3$, 即大奇异值方向的更新幅度更大。而在 $UV^\top$ 中, 两个方向的奇异值均为 1, 更新幅度比为 $1:1$ 。这说明谱范数约束消除了各奇异方向之间的幅度差异, **保留了梯度的方向信息, 但将所有方向上的更新步长统一**——这就是所谓的均衡化效果。对于条件数较大的层, 这一性质可以有效防止某些方向上的更新过大而其他方向更新不足的问题。

4.2.3 (c) Shampoo 恒等式验证

题干 用 Moore–Penrose 伪逆 ($G^\top G$ 有一个零特征值) 计算

$$(GG^\top)^{-1/4}, \quad (G^\top G)^{+, -1/4}$$

(即对非零特征值取 $-1/4$ 次幂, 零特征值保持为零)。然后验证

$$(GG^\top)^{-1/4} G (G^\top G)^{+, -1/4} = UV^\top.$$

解 由 (a) 已知:

$$GG^\top = \text{diag}(16, 9), \quad G^\top G = \text{diag}(9, 16, 0).$$

计算 $(GG^\top)^{-1/4}$: $GG^\top$ 是 2×2 的满秩对角矩阵, 其特征值全部非零, 因此直接对每个特征值取 $-1/4$ 次幂:

$$(GG^\top)^{-1/4} = \text{diag}(16^{-1/4}, 9^{-1/4}) = \text{diag}\left(\frac{1}{2}, \frac{1}{\sqrt{3}}\right).$$

计算 $(G^\top G)^{+, -1/4}$: $G^\top G$ 有一个零特征值 (第三个对角元素), 伪逆意义下零特征值保持为零, 非零特征值取 $-1/4$ 次幂:

$$(G^\top G)^{+, -1/4} = \text{diag}(9^{-1/4}, 16^{-1/4}, 0) = \text{diag}\left(\frac{1}{\sqrt{3}}, \frac{1}{2}, 0\right).$$

验证 Shampoo 恒等式:

$$(GG^\top)^{-1/4} G (G^\top G)^{+, -1/4} = \text{diag}\left(\frac{1}{2}, \frac{1}{\sqrt{3}}\right) \begin{pmatrix} 0 & 4 & 0 \\ 3 & 0 & 0 \end{pmatrix} \text{diag}\left(\frac{1}{\sqrt{3}}, \frac{1}{2}, 0\right).$$

先算左乘：

$$\text{diag}\left(\frac{1}{2}, \frac{1}{\sqrt{3}}\right) \begin{pmatrix} 0 & 4 & 0 \\ 3 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 2 & 0 \\ \frac{3}{\sqrt{3}} & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 2 & 0 \\ \sqrt{3} & 0 & 0 \end{pmatrix}.$$

再右乘：

$$\begin{pmatrix} 0 & 2 & 0 \\ \sqrt{3} & 0 & 0 \end{pmatrix} \text{diag}\left(\frac{1}{\sqrt{3}}, \frac{1}{2}, 0\right) = \begin{pmatrix} 0 \cdot \frac{1}{\sqrt{3}} & 2 \cdot \frac{1}{2} & 0 \cdot 0 \\ \sqrt{3} \cdot \frac{1}{\sqrt{3}} & 0 \cdot \frac{1}{2} & 0 \cdot 0 \end{pmatrix} = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix}.$$

而 $UV^\top = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix}$ ，因此

$$(GG^\top)^{-1/4} G (G^\top G)^{+, -1/4} = UV^\top.$$

这个恒等式说明 Shampoo 预处理器 $(GG^\top)^{-1/4} \cdot (\cdot) \cdot (G^\top G)^{+, -1/4}$ 本质上对梯度 G 做了与 SVD 相同的归一化：将所有奇异值统一为 1，恢复出 $UV^\top$ 。

4.2.4 (d) Frobenius 范数归一化与谱范数归一化的对比

题干 G 的 Frobenius 范数下的归一化梯度为 $G/\|G\|_F$ 。写出 $\|G\|_F$ ，并与 $UV^\top$ 对比三个方向上的更新幅度比 $\sigma_1 : \sigma_2 : \sigma_3$ 。根据讲义表格， F 范数给出 4 : 3 : (0)，谱范数给出 1 : 1 : (0)——谱范数保方向、削大值，为什么对条件数差的层有利？

解 首先计算 Frobenius 范数：

$$\|G\|_F = \sqrt{\sum_{i,j} G_{ij}^2} = \sqrt{0^2 + 4^2 + 0^2 + 3^2 + 0^2 + 0^2} = \sqrt{16 + 9} = \sqrt{25} = 5.$$

Frobenius 范数归一化梯度为

$$\frac{G}{\|G\|_F} = \frac{1}{5} \begin{pmatrix} 0 & 4 & 0 \\ 3 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 4/5 & 0 \\ 3/5 & 0 & 0 \end{pmatrix}.$$

该矩阵的奇异值为 4/5 和 3/5，因此三个奇异方向上的更新幅度比为

$$\frac{G}{\|G\|_F} : \sigma_1 : \sigma_2 : \sigma_3 = \frac{4}{5} : \frac{3}{5} : 0 = 4 : 3 : 0.$$

而谱范数约束下的更新 $UV^\top$ 的奇异值均为 1（零空间方向仍为 0），幅度比为

$$UV^\top : \sigma_1 : \sigma_2 : \sigma_3 = 1 : 1 : 0.$$

对比总结：

范数约束	归一化更新	各奇异方向幅度比
Frobenius 范数 $\ \cdot\ _F$	$G/\ G\ _F$	4 : 3 : 0
谱范数 $\ \cdot\ _2$	$UV^\top$	1 : 1 : 0

分析：Frobenius 范数归一化仅仅将整个梯度矩阵缩放到单位 F 范数，保持了各奇异方向之间的原始幅度比例不变（4 : 3）。这意味着梯度较大的奇异方向（ $\sigma_1 = 4$ ）仍然主导更新，而梯度较小的方向（ $\sigma_2 = 3$ ）获得的更新相对更弱。

谱范数约束则不同：它将所有非零奇异值统一压缩为 1，使得各方向获得**等幅**更新。这一性质对条件数较大的层尤为关键。当一个层的权重矩阵条件数 $\kappa = \sigma_{\max}/\sigma_{\min}$ 很大时，梯度在最大奇异值方向上的分量远大于最小奇异值方向。若使用 F 范数归一化，大奇异值方向仍然会吸收绝大部分更新量，导致小奇异值方向上的参数几乎不更新，训练在该子空间中收敛极慢。而谱范数约束通过**保方向、削大值**的机制，强制所有方向等速更新，有效消除了条件数带来的学习速率不均匀问题，使得优化在整个参数空间中均匀推进，显著加速收敛。

5 题 5: RMS→RMS 范数与 Newton–Schulz 迭代 (§9–§10)

5.1 题目

第一部分：层形状自动进入缩放因子。

考虑 Transformer 中三类层：

$$W_Q \in \mathbb{R}^{64 \times 768}, \quad W_{\text{up}} \in \mathbb{R}^{3072 \times 768}, \quad W_{\text{down}} \in \mathbb{R}^{768 \times 3072}.$$

(a) 分别计算三类层的 Muon 缩放因子 $\sqrt{d_{\text{out}}/d_{\text{in}}}$ 。（注意：讲义的 $W \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$ 约定——行对应输出。）

(b) 解释为什么“窄 → 宽”层（如 W_{up} ）自动获得较大的更新幅度，而“宽 → 窄”层（如 W_{down} ）自动获得较小的更新幅度。从 RMS→RMS 诱导范数的定义 $\|A\|_{\text{RMS} \rightarrow \text{RMS}} = \sqrt{d_{\text{in}}/d_{\text{out}}} \|A\|_2$ 出发解释。

第二部分：Newton–Schulz 的手算。

(c) 讲义中使用经典 NS 多项式 $p(x) = \frac{3}{2}x - \frac{1}{2}x^3$ 。设已归一化后的奇异值为

$$(\hat{\sigma}_1, \hat{\sigma}_2, \hat{\sigma}_3) = (0.9, 0.5, 0.1).$$

手算两步：分别给出每个 $\hat{\sigma}_i$ 在第 1 步和第 2 步后的值（保留 4 位小数）。

(d) 对 $x = 1$ 的邻域做 Taylor 展开：令 $\varepsilon = 1 - \hat{\sigma}$ ，证明

$$1 - p(\hat{\sigma}) = \frac{3}{2}\varepsilon^2 - \frac{1}{2}\varepsilon^3.$$

即**误差每步平方**（超线性/二次收敛）。将此与 $\hat{\sigma} = 0.9$ ($\varepsilon = 0.1$) 的数值对照： $0.1 \rightarrow \sim 0.015 \rightarrow \sim 0.0003$ 。

(e)（对比小奇异值）对 $\hat{\sigma}$ 很小 ($\hat{\sigma} \ll 1$)， $p(\hat{\sigma}) \approx \frac{3}{2}\hat{\sigma}$ 。因此小奇异值是线性增长、因子 1.5。说明为什么这一“不对称”收敛速度对 Muon 是**有利的**（提示：梯度方向的小奇异值对应噪声方向或小 batch 秩不足方向）。

思考

Muon 论文实际用的是一个“调过”的多项式 $p(x) = 3.4445x - 4.7750x^3 + 2.0315x^5$ 。它放弃了 $p(1) = 1$ （不动点），换来在 $[0, 1]$ 上更快把全部奇异值推到 1 附近。这是一个经典权衡：不动点精度 vs 全区间收敛速度。你能想出一个简单的一维例子来说明这个权衡吗？

5.2 解答

5.2.1 (a)

Muon 的层缩放因子为

$$\sqrt{\frac{d_{\text{out}}}{d_{\text{in}}}}.$$

对三类层分别计算：

$$W_Q \in \mathbb{R}^{64 \times 768} : \quad \sqrt{\frac{64}{768}} = \sqrt{\frac{1}{12}} = \frac{1}{\sqrt{12}} \approx 0.2887.$$

$$W_{\text{up}} \in \mathbb{R}^{3072 \times 768} : \quad \sqrt{\frac{3072}{768}} = \sqrt{4} = 2.$$

$$W_{\text{down}} \in \mathbb{R}^{768 \times 3072} : \quad \sqrt{\frac{768}{3072}} = \sqrt{\frac{1}{4}} = 0.5.$$

5.2.2 (b)

RMS→RMS 诱导范数定义为

$$\|A\|_{\text{RMS} \rightarrow \text{RMS}} = \sqrt{\frac{d_{\text{in}}}{d_{\text{out}}}} \|A\|_2.$$

若要求不同层在 RMS→RMS 意义下具有相同的更新尺度，则矩阵谱范数尺度应满足

$$\|A\|_2 \propto \sqrt{\frac{d_{\text{out}}}{d_{\text{in}}}}.$$

因此窄 $\rightarrow$ 宽层, 例如 W_{up} , 有 $d_{\text{out}} > d_{\text{in}}$, 缩放因子大于 1, 自动获得更大的谱范数更新幅度; 宽 $\rightarrow$ 窄层, 例如 W_{down} , 有 $d_{\text{out}} < d_{\text{in}}$, 缩放因子小于 1, 自动获得更小的谱范数更新幅度。这不是手工调参, 而是 RMS 输入输出维度归一化自然带来的层形状修正。

5.2.3 (c)

经典 Newton–Schulz 多项式为

$$p(x) = \frac{3}{2}x - \frac{1}{2}x^3.$$

对三个初始奇异值分别迭代两步:

$$0.9 \xrightarrow{p} 0.9855 \xrightarrow{p} 0.9997,$$

$$0.5 \xrightarrow{p} 0.6875 \xrightarrow{p} 0.8688,$$

$$0.1 \xrightarrow{p} 0.1495 \xrightarrow{p} 0.2226.$$

整理成表格为

$\hat{\sigma}^{(0)}$	0.9	0.5	0.1
$\hat{\sigma}^{(1)}$	0.9855	0.6875	0.1495
$\hat{\sigma}^{(2)}$	0.9997	0.8688	0.2226

5.2.4 (d)

令

$$\hat{\sigma} = 1 - \varepsilon.$$

则

$$p(1 - \varepsilon) = \frac{3}{2}(1 - \varepsilon) - \frac{1}{2}(1 - \varepsilon)^3.$$

展开三次项:

$$(1 - \varepsilon)^3 = 1 - 3\varepsilon + 3\varepsilon^2 - \varepsilon^3.$$

因此

$$p(1 - \varepsilon) = \frac{3}{2} - \frac{3}{2}\varepsilon - \frac{1}{2}(1 - 3\varepsilon + 3\varepsilon^2 - \varepsilon^3).$$

化简得到

$$p(1 - \varepsilon) = 1 - \frac{3}{2}\varepsilon^2 + \frac{1}{2}\varepsilon^3.$$

所以

$$1 - p(\hat{\sigma}) = 1 - p(1 - \varepsilon) = \frac{3}{2}\varepsilon^2 - \frac{1}{2}\varepsilon^3.$$

这说明当 $\hat{\sigma}$ 接近 1 时, 误差主导项是 ε^2 , 即误差近似每步平方。

以 $\hat{\sigma} = 0.9$ 为例, 初始误差为

$$\varepsilon_0 = 0.1.$$

第一步后

$$1 - 0.9855 = 0.0145 \approx 1.5 \times 0.1^2.$$

第二步后

$$1 - 0.999686 \approx 0.000314.$$

这对应

$$0.1 \longrightarrow 0.0145 \longrightarrow 0.0003.$$

5.2.5 (e)

当 $\hat{\sigma} \ll 1$ 时, 三次项 $\hat{\sigma}^3$ 很小, 因此

$$p(\hat{\sigma}) = \frac{3}{2}\hat{\sigma} - \frac{1}{2}\hat{\sigma}^3 \approx \frac{3}{2}\hat{\sigma}.$$

也就是说, 小奇异值每步只按约 1.5 的因子线性增长, 而不是像接近 1 的奇异值那样快速二次收敛。

这种“不对称”对 Muon 是有利的。梯度矩阵中的大奇异值通常对应主要信号方向; 小奇异值则更可能对应噪声方向、欠采样方向, 或小 batch 导致的秩不足方向。如果算法立刻把所有小奇异值都强行拉到 1, 就会过度放大噪声。经典 Newton-Schulz 迭代先快速校正已经比较可靠的主方向, 同时温和地提升小奇异方向, 因此更稳定。

6 题 6: 谱范数约束下最优更新为 $-UV^\top$ 的分步证明

6.1 题目

讲义 §8.2 证明了:

$$\arg \min_{\|B\|_2 \leq 1} \text{tr}(G^\top B) = -UV^\top,$$

其中

$$G = U\Sigma V^\top \in \mathbb{R}^{m \times n}$$

是矩阵 G 的 SVD。下面给出分步证明。

说明. 严格来说, 当 G 不是满秩时, 最优解可能不唯一。这里要证明的是

$$B^* = -UV^\top$$

是一个最优解。若这里的 U, V 指紧 SVD 中的矩阵, 则

$$U = [u_1, \dots, u_r], \quad V = [v_1, \dots, v_r],$$

其中 $r = \text{rank}(G)$ 。

6.2 解答

6.2.1 预备知识: SVD 与记号

设 G 的紧 SVD 为

$$G = U \Sigma V^\top.$$

其中

$$U = [u_1, u_2, \dots, u_r] \in \mathbb{R}^{m \times r}, \quad V = [v_1, v_2, \dots, v_r] \in \mathbb{R}^{n \times r},$$

并且

$$\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r), \quad \sigma_i > 0.$$

这里 $r = \text{rank}(G)$ 。由于 U, V 的列向量都是标准正交向量, 所以

$$u_i^\top u_j = \delta_{ij}, \quad v_i^\top v_j = \delta_{ij}.$$

其中 δ_{ij} 是 Kronecker 符号:

$$\delta_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

由紧 SVD 可得求和形式:

$$G = \sum_{i=1}^r \sigma_i u_i v_i^\top.$$

因此

$$G^\top = \sum_{i=1}^r \sigma_i v_i u_i^\top.$$

6.2.2 (a) 用 SVD 展开目标函数

我们要证明

$$\text{tr}(G^\top B) = \sum_{i=1}^r \sigma_i u_i^\top B v_i.$$

由上面的 SVD 展开式, 有

$$G^\top = \sum_{i=1}^r \sigma_i v_i u_i^\top.$$

所以

$$G^\top B = \left(\sum_{i=1}^r \sigma_i v_i u_i^\top \right) B.$$

由矩阵乘法对加法的分配律，得到

$$G^\top B = \sum_{i=1}^r \sigma_i v_i u_i^\top B.$$

两边取迹：

$$\text{tr}(G^\top B) = \text{tr} \left(\sum_{i=1}^r \sigma_i v_i u_i^\top B \right).$$

由于迹函数具有线性性，即

$$\text{tr}(A + C) = \text{tr}(A) + \text{tr}(C), \quad \text{tr}(\alpha A) = \alpha \text{tr}(A),$$

所以

$$\text{tr}(G^\top B) = \sum_{i=1}^r \sigma_i \text{tr}(v_i u_i^\top B).$$

接下来证明

$$\text{tr}(v_i u_i^\top B) = u_i^\top B v_i.$$

利用迹的循环不变性：

$$\text{tr}(ABC) = \text{tr}(BCA) = \text{tr}(CAB),$$

可得

$$\text{tr}(v_i u_i^\top B) = \text{tr}(u_i^\top B v_i).$$

而 $u_i^\top B v_i$ 是一个 1×1 的标量，标量的迹等于它本身，因此

$$\text{tr}(u_i^\top B v_i) = u_i^\top B v_i.$$

于是

$$\boxed{\text{tr}(G^\top B) = \sum_{i=1}^r \sigma_i u_i^\top B v_i.}$$

直观理解. 这一步的作用是把原本比较抽象的目标函数

$$\text{tr}(G^\top B)$$

拆成了很多个简单项的加权和。每一项都是

$$\sigma_i u_i^\top B v_i.$$

其中 σ_i 是权重， $u_i^\top B v_i$ 是一个标量。

6.2.3 (b) 用谱范数约束给出下界

由 (a) 可知

$$\mathrm{tr}(G^\top B) = \sum_{i=1}^r \sigma_i u_i^\top B v_i.$$

现在利用约束

$$\|B\|_2 \leq 1$$

来限制每一项 $u_i^\top B v_i$ 的大小。

首先, 由 Cauchy–Schwarz 不等式, 有

$$|u_i^\top B v_i| = |u_i^\top (B v_i)| \leq \|u_i\|_2 \|B v_i\|_2.$$

因为 u_i 是单位向量, 所以

$$\|u_i\|_2 = 1.$$

因此

$$|u_i^\top B v_i| \leq \|B v_i\|_2.$$

再根据谱范数作为算子范数的定义, 任意向量 x 都满足

$$\|B x\|_2 \leq \|B\|_2 \|x\|_2.$$

取 $x = v_i$, 由于 v_i 也是单位向量, 有

$$\|B v_i\|_2 \leq \|B\|_2 \|v_i\|_2 \leq 1 \cdot 1 = 1.$$

所以

$$|u_i^\top B v_i| \leq 1.$$

等价地,

$$-1 \leq u_i^\top B v_i \leq 1.$$

又因为奇异值非负, 即

$$\sigma_i \geq 0,$$

所以

$$\sigma_i u_i^\top B v_i \geq -\sigma_i.$$

对 $i = 1, 2, \dots, r$ 求和, 得到

$$\sum_{i=1}^r \sigma_i u_i^\top B v_i \geq -\sum_{i=1}^r \sigma_i.$$

结合 (a) 的展开式, 得到

$$\text{tr}(G^\top B) \geq -\sum_{i=1}^r \sigma_i.$$

由于核范数定义为所有奇异值之和:

$$\|G\|_* = \sum_{i=1}^r \sigma_i,$$

因此也可写成

$$\text{tr}(G^\top B) \geq -\|G\|_*.$$

直观理解. 谱范数约束 $\|B\|_2 \leq 1$ 表示矩阵 B 不能把任何向量放大超过 1 倍。因此每个标量

$$u_i^\top B v_i$$

都只能落在 $[-1, 1]$ 中。因为 $\sigma_i \geq 0$, 每一项 $\sigma_i u_i^\top B v_i$ 的最低值就是 $-\sigma_i$ 。所以总和的下界就是

$$-\sum_{i=1}^r \sigma_i.$$

6.2.4 (c) 构造 B^* 使等号成立

由 (b) 知道, 对所有满足 $\|B\|_2 \leq 1$ 的矩阵 B , 都有

$$\text{tr}(G^\top B) \geq -\sum_{i=1}^r \sigma_i.$$

现在我们构造一个矩阵, 使这个下界能够取到。令

$$B^* = -UV^\top.$$

由于

$$UV^\top = \sum_{j=1}^r u_j v_j^\top,$$

所以

$$B^* = -\sum_{j=1}^r u_j v_j^\top.$$

下面验证两件事: 第一, B^* 满足约束; 第二, B^* 能取到下界。

6.2.5 (c1) 验证 B^* 满足谱范数约束

对任意 $x \in \mathbb{R}^n$, 有

$$B^*x = -\sum_{j=1}^r u_j v_j^\top x = -\sum_{j=1}^r (v_j^\top x) u_j.$$

因为 $\{u_j\}_{j=1}^r$ 是标准正交向量组, 所以

$$\|B^*x\|_2^2 = \left\| -\sum_{j=1}^r (v_j^\top x) u_j \right\|_2^2 = \sum_{j=1}^r (v_j^\top x)^2.$$

又因为 $\{v_j\}_{j=1}^r$ 也是标准正交向量组, 由 Bessel 不等式可得

$$\sum_{j=1}^r (v_j^\top x)^2 \leq \|x\|_2^2.$$

因此

$$\|B^*x\|_2^2 \leq \|x\|_2^2,$$

即

$$\|B^*x\|_2 \leq \|x\|_2.$$

由谱范数定义

$$\|B^*\|_2 = \max_{x \neq 0} \frac{\|B^*x\|_2}{\|x\|_2},$$

所以

$$\boxed{\|B^*\|_2 \leq 1.}$$

因此 B^* 是可行解。

进一步地, 如果 $r \geq 1$, 取 $x = v_1$, 则

$$B^*v_1 = -u_1,$$

所以

$$\|B^*v_1\|_2 = \|u_1\|_2 = 1, \quad \|v_1\|_2 = 1.$$

因此当 $G \neq 0$ 时, 实际上有

$$\boxed{\|B^*\|_2 = 1.}$$

6.2.6 (c2) 验证 B^* 取到下界

下面证明

$$u_i^\top B^*v_i = -1.$$

由

$$B^* = -\sum_{j=1}^r u_j v_j^\top,$$

可得

$$u_i^\top B^* v_i = u_i^\top \left(-\sum_{j=1}^r u_j v_j^\top \right) v_i.$$

把负号和求和号提出, 得到

$$u_i^\top B^* v_i = -\sum_{j=1}^r (u_i^\top u_j)(v_j^\top v_i).$$

由于 $\{u_j\}$ 和 $\{v_j\}$ 都是标准正交向量组, 所以

$$u_i^\top u_j = \delta_{ij}, \quad v_j^\top v_i = \delta_{ji}.$$

因此

$$u_i^\top B^* v_i = -\sum_{j=1}^r \delta_{ij} \delta_{ji}.$$

当且仅当 $j = i$ 时, $\delta_{ij} \delta_{ji} = 1$; 其余时候都等于 0。所以

$$\boxed{u_i^\top B^* v_i = -1.}$$

于是代入 (a) 的目标函数展开式:

$$\text{tr}(G^\top B^*) = \sum_{i=1}^r \sigma_i u_i^\top B^* v_i = \sum_{i=1}^r \sigma_i (-1).$$

所以

$$\boxed{\text{tr}(G^\top B^*) = -\sum_{i=1}^r \sigma_i.}$$

这正好达到了 (b) 中给出的下界。

6.2.7 (d) 综合结论

由 (b) 可知, 对于任意满足 $\|B\|_2 \leq 1$ 的矩阵 B , 都有

$$\text{tr}(G^\top B) \geq -\sum_{i=1}^r \sigma_i.$$

由 (c) 可知, 构造

$$B^* = -UV^\top$$

时, B^* 满足

$$\|B^*\|_2 \leq 1,$$

并且

$$\text{tr}(G^\top B^*) = -\sum_{i=1}^r \sigma_i.$$

因此 B^* 在可行域内, 并且达到了目标函数的最小值。

所以

$$B^* = -UV^\top$$

是原问题的一个最优解, 即

$$\arg \min_{\|B\|_2 \leq 1} \text{tr}(G^\top B) = -UV^\top.$$

如果更新量写成

$$\Delta W = \eta B,$$

那么对应的最优更新为

$$\Delta W^* = \eta B^* = -\eta UV^\top.$$

6.2.8 整体思路总结

这道题的证明核心可以概括为三步:

1. 用 SVD 把目标函数展开成

$$\text{tr}(G^\top B) = \sum_{i=1}^r \sigma_i u_i^\top B v_i.$$

2. 用谱范数约束证明

$$-1 \leq u_i^\top B v_i \leq 1,$$

从而得到目标函数下界

$$\text{tr}(G^\top B) \geq -\sum_{i=1}^r \sigma_i.$$

3. 构造

$$B^* = -UV^\top,$$

使得每一项都取到

$$u_i^\top B^* v_i = -1,$$

因此整体达到下界。

一句话理解. SVD 把目标函数拆成若干个由奇异值加权的方向项；谱范数约束让每个方向项最多只能取到 $[-1, 1]$ ；要让总和最小，就让每一项都取 -1 。矩阵 $B^* = -UV^\top$ 正好能做到这一点，所以它就是最优更新方向。