

HW9: 隐式偏好与极分解

深度学习优化理论

1 习题 9.1: 深度 2 的奇异值演化方程

1.1 题目

设 $W = W_2 W_1$, $W_1, W_2 \in \mathbb{R}^{d \times d}$, 损失

$$L = \frac{1}{2} \|W - Y\|_F^2,$$

残差

$$R = W - Y.$$

梯度流为

$$\dot{W}_j = -\frac{\partial L}{\partial W_j}.$$

(a) 用链式法则证明

$$\dot{W}_1 = -W_2^\top R, \quad \dot{W}_2 = -R W_1^\top.$$

(b) 用乘积法则计算

$$\dot{W} = \dot{W}_2 W_1 + W_2 \dot{W}_1,$$

证明

$$\dot{W} = -R W_1^\top W_1 - W_2 W_2^\top R.$$

(c) 假设平衡初始化

$$W_1^\top W_1 = W_2 W_2^\top =: \Sigma,$$

该条件在梯度流下守恒, 本题不要求证明。且 W 与 Y 在共同奇异基下对角化。设 W 第 r 个奇异值为 σ_r ,

$$y_r = u_r^\top Y v_r.$$

证明

$$\dot{\sigma}_r = -2\sigma_r(\sigma_r - y_r).$$

提示: 在该奇异基下

$$\Sigma = \text{diag}(\sigma_r),$$

R 的对角元为 $\sigma_r - y_r$ 。把 (b) 投影到 $u_r v_r^\top$ 方向。

1.2 解答

1.2.1 (a) 链式法则证明

记

$$L(W_1, W_2) = \frac{1}{2} \|W_2 W_1 - Y\|_F^2 = \frac{1}{2} \|R\|_F^2.$$

对 W_1, W_2 作微分, 有

$$dW = d(W_2 W_1) = W_2 dW_1 + dW_2 W_1.$$

因此

$$dL = \langle R, dW \rangle_F = \langle R, W_2 dW_1 \rangle_F + \langle R, dW_2 W_1 \rangle_F.$$

第一项为

$$\begin{aligned} \langle R, W_2 dW_1 \rangle_F &= \text{tr}(R^\top W_2 dW_1) \\ &= \text{tr}((W_2^\top R)^\top dW_1) \\ &= \langle W_2^\top R, dW_1 \rangle_F. \end{aligned}$$

第二项为

$$\begin{aligned} \langle R, dW_2 W_1 \rangle_F &= \text{tr}(R^\top dW_2 W_1) \\ &= \text{tr}((RW_1^\top)^\top dW_2) \\ &= \langle RW_1^\top, dW_2 \rangle_F. \end{aligned}$$

所以

$$\frac{\partial L}{\partial W_1} = W_2^\top R, \quad \frac{\partial L}{\partial W_2} = RW_1^\top.$$

由梯度流

$$\dot{W}_j = -\frac{\partial L}{\partial W_j}$$

得

$$\boxed{\dot{W}_1 = -W_2^\top R, \quad \dot{W}_2 = -RW_1^\top.}$$

1.2.2 (b) 乘积法则计算 $\dot{W}$

由乘积法则

$$\dot{W} = \dot{W}_2 W_1 + W_2 \dot{W}_1.$$

代入 (a) 中的梯度流方程:

$$\begin{aligned} \dot{W} &= (-RW_1^\top)W_1 + W_2(-W_2^\top R) \\ &= -RW_1^\top W_1 - W_2 W_2^\top R. \end{aligned}$$

因此

$$\boxed{\dot{W} = -RW_1^\top W_1 - W_2 W_2^\top R.}$$

1.2.3 (c) 奇异值演化方程

由平衡条件

$$W_1^\top W_1 = W_2 W_2^\top = \Sigma.$$

因此 (b) 可写为

$$\dot{W} = -R\Sigma - \Sigma R.$$

在共同奇异基下, 设

$$W = \text{diag}(\sigma_1, \dots, \sigma_d), \quad Y = \text{diag}(y_1, \dots, y_d),$$

则

$$R = W - Y = \text{diag}(\sigma_1 - y_1, \dots, \sigma_d - y_d), \quad \Sigma = \text{diag}(\sigma_1, \dots, \sigma_d).$$

因而第 r 个对角方向上的演化为

$$\begin{aligned} \dot{\sigma}_r &= -(\sigma_r - y_r)\sigma_r - \sigma_r(\sigma_r - y_r) \\ &= -2\sigma_r(\sigma_r - y_r). \end{aligned}$$

等价地, 将 $\dot{W}$ 投影到 $u_r v_r^\top$ 方向, 有

$$\dot{\sigma}_r = u_r^\top \dot{W} v_r = -2\sigma_r(\sigma_r - y_r).$$

所以

$$\boxed{\dot{\sigma}_r = -2\sigma_r(\sigma_r - y_r).}$$

2 习题 9.2: $N \rightarrow \infty$ 极限的奇异值动力学

2.1 题目

由讲义 §2.5.6, 深度 N 网络的奇异值方程为

$$\dot{\sigma}_r = -N \sigma_r^{2-2/N} (\sigma_r - y_r).$$

(a) 引入 $\tau = Nt$, 证明 $N \rightarrow \infty$ 极限方程为

$$\frac{d\sigma}{d\tau} = -\sigma^2(\sigma - y), \quad (\star)$$

其中省略下标 r 。并简述这个 rescale 的物理含义, 要求不超过 30 字。

(b) 对**任务无关方向** $y = 0$, $(\star)$ 退化为

$$\dot{\sigma} = -\sigma^3.$$

从 $\sigma(0) = \varepsilon$ 出发, 分离变量解出

$$\sigma(\tau) = \frac{\varepsilon}{\sqrt{1 + 2\varepsilon^2\tau}}.$$

说明: 当 ε 小时, $\sigma(\tau)$ 在任意有限 τ 内**永远** $\leq \varepsilon$ 。这就是无穷深网络的低秩偏好, 即无信号方向永久冻结在小值附近。

2.2 解答

2.2.1 (a) $N \rightarrow \infty$ 极限方程

原方程中的点表示对原时间 t 求导:

$$\frac{d\sigma}{dt} = -N\sigma^{2-2/N}(\sigma - y).$$

令

$$\tau = Nt, \quad \frac{d\tau}{dt} = N.$$

由链式法则

$$\frac{d\sigma}{dt} = \frac{d\sigma}{d\tau} \frac{d\tau}{dt} = N \frac{d\sigma}{d\tau}.$$

代回原方程并约去 N , 得到

$$\frac{d\sigma}{d\tau} = -\sigma^{2-2/N}(\sigma - y).$$

当 $N \rightarrow \infty$ 时,

$$2 - \frac{2}{N} \rightarrow 2.$$

因而极限方程为

$$\boxed{\frac{d\sigma}{d\tau} = -\sigma^2(\sigma - y).}$$

物理含义:

吸收深度导致的时间加速。

2.2.2 (b) 任务无关方向 $y = 0$

当 $y = 0$ 时, 极限方程变为

$$\frac{d\sigma}{d\tau} = -\sigma^3.$$

分离变量:

$$\sigma^{-3} d\sigma = -d\tau.$$

两边积分得

$$-\frac{1}{2\sigma^2} = -\tau + C.$$

等价地,

$$\frac{1}{\sigma^2} = 2\tau + C'.$$

由初值

$$\sigma(0) = \varepsilon,$$

有

$$\frac{1}{\varepsilon^2} = C'.$$

所以

$$\frac{1}{\sigma(\tau)^2} = \frac{1}{\varepsilon^2} + 2\tau.$$

进一步得到

$$\sigma(\tau)^2 = \frac{\varepsilon^2}{1 + 2\varepsilon^2\tau}, \quad \sigma(\tau) = \frac{\varepsilon}{\sqrt{1 + 2\varepsilon^2\tau}},$$

其中取正号是因为奇异值非负。

由于 $\tau \geq 0$ 时

$$1 + 2\varepsilon^2\tau \geq 1,$$

所以

$$\sigma(\tau) = \frac{\varepsilon}{\sqrt{1 + 2\varepsilon^2\tau}} \leq \varepsilon.$$

因此无信号方向从小初始化出发后不会被放大，而是一直停留在不超过初值的尺度上；这正对应无穷深网络的低秩隐式偏好。

3 习题 9.3: Newton-Schulz 与 Polar Express

3.1 题目

本题目的. 前两题研究训练动力学中的奇异值；这一题研究算法中如何主动改变奇异值。极分解把矩阵写成

$$X = UP,$$

其中 U 是正交因子， P 是半正定因子。许多现代优化器希望从梯度矩阵中提取类似 U 的方向，因为这样的方向尺度更均衡，不会被某些特别大的奇异值主导。

Newton-Schulz 迭代的作用可以理解为：对矩阵的每个奇异值 x 套用一个多项式 $p(x)$ ，希望把所有 x 都推向 1。如果所有奇异值都接近 1，矩阵就接近正交因子。Polar Express 的改进思想是：不要固定使用同一个多项式，而是根据当前奇异值所在区间，选一个在该区间上误差更均匀、更小的多项式。

Newton-Schulz 多项式为

$$p_{NS}(x) = \frac{3}{2}x - \frac{1}{2}x^3.$$

如果矩阵 X 的奇异值分解为

$$X = U \operatorname{diag}(x_i) V^\top,$$

那么对 X 施加奇多项式

$$p(X) = aX + bXX^\top X$$

时，有

$$\begin{aligned} XX^\top X &= U \operatorname{diag}(x_i) V^\top V \operatorname{diag}(x_i) U^\top U \operatorname{diag}(x_i) V^\top \\ &= U \operatorname{diag}(x_i^3) V^\top. \end{aligned}$$

因此

$$p(X) = U \operatorname{diag}(ax_i + bx_i^3)V^\top.$$

也就是说, 矩阵迭代在奇异值层面就是标量迭代

$$x_i \mapsto p(x_i).$$

所以本题只需要研究标量多项式如何把 x 推向 1。

(a) 验证恒等式

$$1 - p_{NS}(x) = \frac{1}{2}(1-x)^2(2+x),$$

并说明 Newton-Schulz 迭代的收敛性质。

(b) 设

$$p(x) = ax + bx^3.$$

在 0.5, 0.75, 1 三点施加等振条件

$$1 - p(0.5) = E, \quad 1 - p(0.75) = -E, \quad 1 - p(1) = E.$$

写出线性方程组并求解 a, b, E 。

3.2 解答

3.2.1 (a) 验证恒等式并说明收敛性质

直接展开右端:

$$\begin{aligned} \frac{1}{2}(1-x)^2(2+x) &= \frac{1}{2}(1-2x+x^2)(2+x) \\ &= \frac{1}{2}(2-3x+x^3) \\ &= 1 - \frac{3}{2}x + \frac{1}{2}x^3 \\ &= 1 - p_{NS}(x). \end{aligned}$$

因此

$$\boxed{1 - p_{NS}(x) = \frac{1}{2}(1-x)^2(2+x).}$$

若奇异值已归一化到 $0 \leq x \leq 1$, 且

$$|1-x| \leq \delta,$$

则

$$0 \leq 2+x \leq 3.$$

所以

$$\begin{aligned} |1 - p_{NS}(x)| &= \frac{1}{2}|1 - x|^2|2 + x| \\ &\leq \frac{1}{2}\delta^2 \cdot 3 \\ &= \frac{3}{2}\delta^2. \end{aligned}$$

这说明当 x 已经接近 1 时, 误差

$$e = 1 - x$$

在一步迭代后大约从 e 变成 $O(e^2)$ 。这就是 Newton-Schulz 迭代的二次收敛。

另一方面, 当 x 很小时,

$$p_{NS}(x) = \frac{3}{2}x - \frac{1}{2}x^3 = \frac{3}{2}x + O(x^3).$$

因而小奇异值每一步主要只被线性放大 1.5 倍, 这就是 Newton-Schulz 在小奇异值区间上的瓶颈。

3.2.2 (b) 三点等振线性方程组

设

$$p(x) = ax + bx^3.$$

题目要求在 0.5, 0.75, 1 三点满足

$$1 - p(0.5) = E, \quad 1 - p(0.75) = -E, \quad 1 - p(1) = E.$$

这叫“三点等振”: 误差函数

$$e(x) = 1 - p(x)$$

在三个采样点交替取 $+E, -E, +E$ 。这种设计想让最大正误差和最大负误差尽量均衡, 避免某个点误差特别大。

分别代入 $p(x) = ax + bx^3$ 。当

$$x = 0.5 = \frac{1}{2}$$

时,

$$p(0.5) = a \cdot \frac{1}{2} + b \cdot \left(\frac{1}{2}\right)^3 = \frac{1}{2}a + \frac{1}{8}b.$$

因此第一条条件给出

$$1 - \frac{1}{2}a - \frac{1}{8}b = E.$$

当

$$x = 0.75 = \frac{3}{4}$$

时,

$$p(0.75) = a \cdot \frac{3}{4} + b \cdot \left(\frac{3}{4}\right)^3 = \frac{3}{4}a + \frac{27}{64}b.$$

第二条条件给出

$$1 - \frac{3}{4}a - \frac{27}{64}b = -E.$$

当 $x = 1$ 时,

$$p(1) = a + b.$$

第三条条件给出

$$1 - a - b = E.$$

所以完整方程组是

$$\begin{cases} 1 - \frac{1}{2}a - \frac{1}{8}b = E, \\ 1 - \frac{3}{4}a - \frac{27}{64}b = -E, \\ 1 - a - b = E. \end{cases}$$

为了写成标准线性方程组, 把 a, b, E 放到左边。第一式

$$1 - \frac{1}{2}a - \frac{1}{8}b = E$$

等价于

$$\frac{1}{2}a + \frac{1}{8}b + E = 1.$$

第二式

$$1 - \frac{3}{4}a - \frac{27}{64}b = -E$$

等价于

$$\frac{3}{4}a + \frac{27}{64}b - E = 1.$$

第三式

$$1 - a - b = E$$

等价于

$$a + b + E = 1.$$

因而写成 3×3 线性方程组为

$$\begin{pmatrix} \frac{1}{2} & \frac{1}{8} & 1 \\ \frac{3}{4} & \frac{27}{64} & -1 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} a \\ b \\ E \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}.$$

下面手算求解。因为第一式和第三式右边同为 E , 所以二者左边相等:

$$1 - \frac{1}{2}a - \frac{1}{8}b = 1 - a - b.$$

消去常数项后得到

$$-\frac{1}{2}a - \frac{1}{8}b = -a - b.$$

即

$$\frac{1}{2}a + \frac{7}{8}b = 0.$$

因此

$$4a + 7b = 0, \quad a = -\frac{7}{4}b.$$

这一步把三个未知量中的 a 用 b 表示出来。

再由第三式

$$E = 1 - a - b.$$

将它代入第二式。因为第二式是

$$1 - \frac{3}{4}a - \frac{27}{64}b = -E,$$

代入 $E = 1 - a - b$ 后右边变为

$$-E = -(1 - a - b).$$

所以

$$1 - \frac{3}{4}a - \frac{27}{64}b = -(1 - a - b).$$

展开整理:

$$1 - \frac{3}{4}a - \frac{27}{64}b = -1 + a + b.$$

即

$$2 - \frac{7}{4}a - \frac{91}{64}b = 0.$$

乘以 64:

$$128 - 112a - 91b = 0.$$

代入

$$a = -\frac{7}{4}b,$$

得到

$$128 - 112\left(-\frac{7}{4}b\right) - 91b = 0.$$

因为

$$112 \cdot \frac{7}{4} = 196,$$

所以

$$128 + 196b - 91b = 0.$$

即

$$128 + 105b = 0.$$

因而

$$b = -\frac{128}{105}.$$

接着

$$a = -\frac{7}{4}b = -\frac{7}{4}\left(-\frac{128}{105}\right) = \frac{224}{105} = \frac{32}{15}.$$

最后

$$E = 1 - a - b = 1 - \frac{32}{15} + \frac{128}{105} = \frac{105 - 224 + 128}{105} = \frac{9}{105} = \frac{3}{35}.$$

因此，在题目给出的三点等振条件下，

$$a = \frac{32}{15} \approx 2.1333, \quad b = -\frac{128}{105} \approx -1.2190, \quad E = \frac{3}{35} \approx 0.0857.$$

对应多项式为

$$p(x) = \frac{32}{15}x - \frac{128}{105}x^3.$$

检验三点误差：

$$1 - p(0.5) = \frac{3}{35},$$


$$1 - p(0.75) = -\frac{3}{35},$$

$$1 - p(1) = \frac{3}{35}.$$

为了更直观看出 Polar Express 和 Newton-Schulz 的差别，下面画出误差函数

$$e(x) = 1 - p(x)$$

在区间 $[0.5, 1]$ 上的曲线。越接近 0，说明对应多项式越能把奇异值 x 推到目标值 1 附近。



图示：Newton-Schulz 在 $x = 0.5$ 处误差较大；Polar Express 让三个点的误差交替等振，从而把最大误差压低。

Newton-Schulz 在 $x = 0.5$ 处的误差为

$$\begin{aligned} 1 - p_{NS}(0.5) &= 1 - \left(\frac{3}{2} \cdot \frac{1}{2} - \frac{1}{2} \cdot \frac{1}{8} \right) \\ &= 1 - \left(\frac{3}{4} - \frac{1}{16} \right) \\ &= 1 - \frac{11}{16} \\ &= \frac{5}{16} = 0.3125. \end{aligned}$$

与 $E = 3/35$ 相比, 误差缩小倍数为

$$\frac{0.3125}{3/35} = \frac{5/16}{3/35} = \frac{175}{48} \approx 3.65.$$

说明。题面中若给出 $a \approx 1.95$, $b \approx -0.85$, $E \approx 0.06$, 这组三个数并不能同时满足上面的三条等振方程。例如

$$1 - a - b \approx 1 - 1.95 + 0.85 = -0.10,$$

这与 $E \approx 0.06$ 不一致。严格按题目列出的三点条件求解, 应得到本小问中的精确解。