

习题集与解答：第 10–11 周

变分法与最优控制 | 在线优化与 Regret 框架

约定与提示

本习题集共 10 题，平均覆盖第 10 周（变分法、最大熵、KL 散度、HJB/LQR）与第 11 周（MWU、Hoeffding、UCB、Thompson Sampling、KG）。所有题目均要求得出具体数值答案，请保留至少 3 位有效数字。

可能用到的标准正态值：

$$\begin{aligned}\Phi(0.167) &\approx 0.566, \quad \Phi(0.351) \approx 0.637, \quad \Phi(0.5) \approx 0.691, \quad \Phi(0.83) \approx 0.797, \\ \Phi(1.0) &\approx 0.841, \quad \Phi(1.5) \approx 0.933, \quad \Phi(2.0) \approx 0.977, \quad \Phi(2.34) \approx 0.990. \\ \phi(0) &= 0.399, \quad \phi(0.351) \approx 0.375, \quad \phi(0.5) \approx 0.352, \\ \phi(1.0) &\approx 0.242, \quad \phi(1.5) \approx 0.130, \quad \phi(2.0) \approx 0.054.\end{aligned}$$

其中 Φ 为标准正态 CDF， ϕ 为 PDF。

微积分常数： $\sinh 1 \approx 1.175$, $\cosh 1 \approx 1.543$, $\coth 1 \approx 1.313$, $\ln 2 \approx 0.693$, $\ln 3 \approx 1.099$, $\ln 14 \approx 2.639$ 。

第一部分：变分法与最优控制

第 1 题：Euler–Lagrange 方程基础

求泛函

$$J[y] = \int_0^1 \left((y')^2 + y^2 \right) dx$$

在边界条件 $y(0) = 0$, $y(1) = 1$ 下的极值函数 $y^*(x)$ 与最小值 J^* 。

- 写出 F 对应的 Euler–Lagrange 方程，化简为关于 y 的二阶常微分方程。
- 求通解，代入边界条件确定常数，给出 $y^*(x)$ 的解析表达式。
- 计算最小值 J^* （保留 3 位小数）。
- 用任意一个不满足 E-L 方程的简单试探函数（如 $y = x$ ）计算 J 值，验证它确实大于 J^* 。

解答

解答。

(a) 被积函数 $F(y, y', x) = (y')^2 + y^2$ 。各偏导为

$$\frac{\partial F}{\partial y} = 2y, \quad \frac{\partial F}{\partial y'} = 2y'.$$

Euler–Lagrange 方程：

$$\frac{\partial F}{\partial y} - \frac{d}{dx} \frac{\partial F}{\partial y'} = 2y - 2y'' = 0,$$

即

$$y'' - y = 0.$$

(b) 特征方程 $r^2 - 1 = 0$ 给出 $r = \pm 1$ ，通解为

$$y(x) = C_1 \sinh x + C_2 \cosh x.$$

代入边界条件：

- $y(0) = C_2 = 0$ ，故 $C_2 = 0$ ；
- $y(1) = C_1 \sinh 1 = 1$ ，故 $C_1 = 1/\sinh 1$ 。

因此

$$y^*(x) = \frac{\sinh x}{\sinh 1}.$$

(c) 计算 J^* ：

$$y^{*'}(x) = \frac{\cosh x}{\sinh 1}.$$

$$J^* = \int_0^1 \left(\frac{\cosh^2 x}{\sinh^2 1} + \frac{\sinh^2 x}{\sinh^2 1} \right) dx = \frac{1}{\sinh^2 1} \int_0^1 \cosh(2x) dx,$$

其中用到了恒等式 $\cosh^2 x + \sinh^2 x = \cosh(2x)$ 。

$$\int_0^1 \cosh(2x) dx = \frac{\sinh(2x)}{2} \Big|_0^1 = \frac{\sinh 2}{2}.$$

又 $\sinh 2 = 2 \sinh 1 \cosh 1$ ，所以

$$J^* = \frac{2 \sinh 1 \cosh 1}{2 \sinh^2 1} = \frac{\cosh 1}{\sinh 1} = \coth 1 \approx 1.313.$$

(d) 取试探函数 $y = x$ （满足边界条件但不满足 E-L 方程）：

$$J[x] = \int_0^1 (1 + x^2) dx = 1 + \frac{1}{3} = \frac{4}{3} \approx 1.333.$$

确实 $1.333 > 1.313 = J^*$ ，验证了 y^* 给出极小值。

第 2 题：约束下的最大熵分布

设 $x \in [0, \infty)$ ，已知 $\mathbb{E}[x] = 3$ 。

- 用拉格朗日乘子法（对归一化与均值约束）写出最大熵问题的变分方程。
- 解出最大熵分布 $p^*(x)$ 的解析形式（含待定参数）。
- 代入约束确定参数，给出 $p^*(x)$ 的具体表达式，并指出它属于哪一族经典分布。
- 计算 p^* 的微分熵 $H[p^*]$ （以 nats 为单位，保留 3 位小数）。

解答

解答。

(a) 最大熵问题为

$$\max_p H[p] = - \int_0^\infty p(x) \ln p(x) dx$$

subject to $\int_0^\infty p(x) dx = 1$ （归一化）和 $\int_0^\infty x p(x) dx = 3$ （均值约束）。

引入拉格朗日乘子 λ_0 （归一化）和 λ_1 （均值）：

$$\mathcal{L}[p] = - \int p \ln p dx - \lambda_0 \left(\int p dx - 1 \right) - \lambda_1 \left(\int x p dx - 3 \right).$$

对 p 取变分并令其为零：

$$\frac{\delta \mathcal{L}}{\delta p} = - \ln p(x) - 1 - \lambda_0 - \lambda_1 x = 0.$$

(b) 由变分方程解出：

$$p^*(x) = e^{-1-\lambda_0} \cdot e^{-\lambda_1 x} = C e^{-\lambda_1 x},$$

其中 $C = e^{-1-\lambda_0}$ 为归一化常数。

(c) 代入约束确定参数：

- 归一化： $\int_0^\infty C e^{-\lambda_1 x} dx = C/\lambda_1 = 1$ ，故 $C = \lambda_1$ 。
- 均值： $\int_0^\infty x \lambda_1 e^{-\lambda_1 x} dx = 1/\lambda_1 = 3$ ，故 $\lambda_1 = 1/3$ 。

因此

$$p^*(x) = \frac{1}{3} e^{-x/3}, \quad x \geq 0.$$

这是参数为 $\lambda = 1/3$ （均值为 3）的**指数分布**。

(d) 指数分布 $\text{Exp}(\mu)$ 的微分熵公式为 $H = 1 + \ln \mu$ ：

$$H[p^*] = 1 + \ln 3 \approx 1 + 1.099 = \boxed{2.099 \text{ nats.}}$$

第 3 题：高斯分布之间的 KL 散度

设 $p = \mathcal{N}(0, 1)$, $q = \mathcal{N}(1, 4)$ (即均值 $\mu_q = 1$ 、方差 $\sigma_q^2 = 4$)。

(a) 写出一维高斯之间 KL 散度的解析公式

$$D_{\text{KL}}(\mathcal{N}(\mu_1, \sigma_1^2) \parallel \mathcal{N}(\mu_2, \sigma_2^2)) = ?$$

(b) 计算 $D_{\text{KL}}(p \parallel q)$ (保留 3 位小数)。

(c) 计算 $D_{\text{KL}}(q \parallel p)$ (保留 3 位小数)。

(d) 比较两者大小, 并用一句话说明 KL 散度不对称性的实际含义 (zero-forcing vs. mean-seeking)。

解答

解答。

(a) 一维高斯之间的 KL 散度解析公式:

$$D_{\text{KL}}(\mathcal{N}(\mu_1, \sigma_1^2) \parallel \mathcal{N}(\mu_2, \sigma_2^2)) = \ln \frac{\sigma_2}{\sigma_1} + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2}.$$

(b) $D_{\text{KL}}(p \parallel q) = D_{\text{KL}}(\mathcal{N}(0, 1) \parallel \mathcal{N}(1, 4))$:

$$= \ln \frac{2}{1} + \frac{1 + (0 - 1)^2}{2 \times 4} - \frac{1}{2} = \ln 2 + \frac{2}{8} - \frac{1}{2} = 0.693 + 0.250 - 0.500 = \boxed{0.443}.$$

(c) $D_{\text{KL}}(q \parallel p) = D_{\text{KL}}(\mathcal{N}(1, 4) \parallel \mathcal{N}(0, 1))$:

$$= \ln \frac{1}{2} + \frac{4 + (1 - 0)^2}{2 \times 1} - \frac{1}{2} = -\ln 2 + \frac{5}{2} - \frac{1}{2} = -0.693 + 2.500 - 0.500 = \boxed{1.307}.$$

(d) $D_{\text{KL}}(q \parallel p) = 1.307 \gg D_{\text{KL}}(p \parallel q) = 0.443$, 体现了 KL 散度的不对称性。

实际含义: $D_{\text{KL}}(p \parallel q)$ 较小是因为 p (窄分布) 的质量都落在 q (宽分布) 有较高概率的区域; 而 $D_{\text{KL}}(q \parallel p)$ 很大是因为 q (宽分布) 在 p (窄分布) 的尾部仍有大量质量, 但 p 在那些区域的概率极低。在变分推断中: 最小化 $D_{\text{KL}}(q \parallel p)$ 倾向于让 q 集中在 p 的某个模态 (**mode-seeking** / **zero-forcing**), 而最小化 $D_{\text{KL}}(p \parallel q)$ 倾向于让 q 覆盖 p 的全部支撑 (**mean-seeking** / **zero-avoiding**)。

第 4 题：VAE 的 KL 正则项

VAE 编码器输出对角高斯

$$q_\phi(z|x) = \mathcal{N}(\mu, \text{diag}(\sigma^2)),$$

先验为标准高斯 $p(z) = \mathcal{N}(0, I)$ 。给定隐空间维度 $d = 3$,

$$\mu = (0.5, -0.5, 1.0), \quad \sigma^2 = (0.5, 1.5, 0.4).$$

- 写出 $D_{\text{KL}}(q_\phi \| p)$ 的逐分量解析公式。
- 计算每个分量的 KL 贡献 (保留 3 位小数)。
- 给出总 KL 值 (nats)。
- 哪个分量贡献最大? 结合 μ_j 和 σ_j^2 偏离 $(0, 1)$ 的程度与方向解释原因。

解答

解答。

(a) 对角高斯与标准高斯之间的 KL 散度逐分量分解:

$$D_{\text{KL}}(q_\phi \| p) = \frac{1}{2} \sum_{j=1}^d (\mu_j^2 + \sigma_j^2 - 1 - \ln \sigma_j^2).$$

(b) 逐分量计算:

分量 1 ($\mu_1 = 0.5, \sigma_1^2 = 0.5$):

$$\text{KL}_1 = \frac{1}{2}(0.25 + 0.5 - 1 - \ln 0.5) = \frac{1}{2}(-0.25 + 0.693) = \frac{1}{2}(0.443) = 0.222.$$

分量 2 ($\mu_2 = -0.5, \sigma_2^2 = 1.5$):

$$\text{KL}_2 = \frac{1}{2}(0.25 + 1.5 - 1 - \ln 1.5) = \frac{1}{2}(0.75 - 0.405) = \frac{1}{2}(0.345) = 0.173.$$

其中 $\ln 1.5 = \ln 3 - \ln 2 = 1.099 - 0.693 = 0.405$ 。

分量 3 ($\mu_3 = 1.0, \sigma_3^2 = 0.4$):

$$\text{KL}_3 = \frac{1}{2}(1.0 + 0.4 - 1 - \ln 0.4) = \frac{1}{2}(0.4 + 0.916) = \frac{1}{2}(1.316) = 0.658.$$

其中 $\ln 0.4 = \ln 2 - \ln 5 = 0.693 - 1.609 = -0.916$ 。

(c) 总 KL 值:

$$D_{\text{KL}} = 0.222 + 0.173 + 0.658 = \boxed{1.053 \text{ nats.}}$$

(d) 分量 3 贡献最大 (0.658, 占总量的 62.5%)。原因:

- $\mu_3 = 1.0$ 偏离先验均值 0 最远, 贡献 $\mu_3^2 = 1.0$ (其余分量只贡献 0.25);
- $\sigma_3^2 = 0.4$ 远小于先验方差 1, 后验过度集中, 产生大的 $-\ln \sigma_3^2 = 0.916$ 惩罚项。

即分量 3 同时在均值偏移和方差收缩两个方向上偏离标准高斯先验最严重。

第 5 题：LQR 与代数 Riccati 方程

连续时间一维线性系统

$$\dot{x} = -x + 2u,$$

无穷时域代价

$$J = \int_0^\infty (4x^2 + u^2) dt.$$

- (a) 写出对应的代数 Riccati 方程（即 $\dot{P} = 0$ 时的稳态方程）。
- (b) 求稳态正解 $P > 0$ （保留 3 位小数）。
- (c) 给出最优反馈控制律 $u^*(x) = Kx$ 的反馈增益 K 。
- (d) 计算闭环系统 $\dot{x} = (a + bK)x$ 的极点，并验证闭环稳定性。
- (e) 与开环（ $u \equiv 0$ ，注意原系统 $\dot{x} = -x$ 本就稳定）相比，闭环极点把“收敛速率”提速了多少倍？

解答

解答。

系统参数： $A = -1$ ， $B = 2$ ；代价参数：运行代价 $4x^2 + u^2$ 。设值函数 $V(x) = \frac{1}{2}Px^2$ ，则 $\nabla_x V = Px$ 。

(a) 由 HJB 方程（无穷时域稳态）：

$$0 = \min_u [4x^2 + u^2 + Px(-x + 2u)].$$

对 u 求一阶条件： $2u + 2Px = 0$ ，得 $u^* = -Px$ 。代回 HJB：

$$4x^2 + P^2x^2 - Px^2 - 2P^2x^2 = (4 - P - P^2)x^2 = 0.$$

因此代数 Riccati 方程（稳态）为

$$P^2 + P - 4 = 0.$$

(b) 解二次方程 $P^2 + P - 4 = 0$ ：

$$P = \frac{-1 + \sqrt{1 + 16}}{2} = \frac{-1 + \sqrt{17}}{2}.$$

 $\sqrt{17} \approx 4.123$ ，所以

$$P = \frac{-1 + \sqrt{17}}{2} \approx 1.562.$$

(c) 最优控制律 $u^* = -Px = Kx$, 反馈增益:

$$K = -P = \frac{1 - \sqrt{17}}{2} \approx -1.562.$$

(d) 闭环系统:

$$\dot{x} = (A + BK)x = (-1 + 2 \times (-1.562))x = (-1 - 3.123)x = -4.123x.$$

精确值: $A + BK = -1 + 2(-P) = -1 - 2P = -1 - (-1 + \sqrt{17}) = -\sqrt{17}$.

闭环极点为 $[-\sqrt{17} \approx -4.123]$, 为负实数, 因此闭环稳定。

(e) 开环 ($u \equiv 0$): $\dot{x} = -x$, 极点为 -1 , 收敛速率为 1。

闭环收敛速率为 $\sqrt{17} \approx 4.123$ 。提速倍数:

$$\frac{|\text{闭环极点}|}{|\text{开环极点}|} = \frac{\sqrt{17}}{1} = \sqrt{17} \approx 4.123 \text{ 倍}.$$

第二部分：在线优化与 Regret 框架

第 6 题：MWU 手算 3 轮

3 个专家, 学习率 $\eta = 0.4$, 初始权重 $w^{(1)} = (1, 1, 1)$ 。损失序列:

$$\ell_1 = (0.5, 0.2, 0.8)$$

$$\ell_2 = (0.3, 0.7, 0.4)$$

$$\ell_3 = (0.6, 0.3, 0.1)$$

(a) 写出每轮的概率分布 $p^{(t)}$ 与算法的期望损失 $L_t = \sum_i p_i^{(t)} \ell_t(i)$ 。

(b) 写出每轮乘法更新后的权重向量 $w^{(t+1)}$ 。

(c) 计算 3 轮的总期望损失 $\sum_{t=1}^3 L_t$ 。

(d) 找出最优固定专家 i^* 及其总损失 $L^* = \sum_t \ell_t(i^*)$ 。

(e) 计算 Regret, 并与 MWU 的理论上界 $\frac{\ln N}{\eta} + \eta T$ ($N = 3$, $T = 3$) 作对比。

解答

解答。

MWU 更新规则: $w_i^{(t+1)} = w_i^{(t)} \cdot e^{-\eta \ell_t(i)}$, 概率 $p_i^{(t)} = w_i^{(t)} / \sum_j w_j^{(t)}$ 。

(a) & (b) 逐轮计算:

第 1 轮: $\ell_1 = (0.5, 0.2, 0.8)$

$$p^{(1)} = \left(\frac{1}{3}, \frac{1}{3}, \frac{1}{3}\right), \quad L_1 = \frac{0.5 + 0.2 + 0.8}{3} = 0.500.$$

更新权重:

$$w^{(2)} = (e^{-0.2}, e^{-0.08}, e^{-0.32}) = (0.8187, 0.9231, 0.7261).$$

第 2 轮: $\ell_2 = (0.3, 0.7, 0.4)$ 权重和 = $0.8187 + 0.9231 + 0.7261 = 2.468$ 。

$$p^{(2)} = (0.332, 0.374, 0.294).$$

$$L_2 = 0.332 \times 0.3 + 0.374 \times 0.7 + 0.294 \times 0.4 = 0.100 + 0.262 + 0.118 = 0.479.$$

更新权重:

$$w^{(3)} = (0.8187 e^{-0.12}, 0.9231 e^{-0.28}, 0.7261 e^{-0.16}) = (0.726, 0.698, 0.619).$$

第 3 轮: $\ell_3 = (0.6, 0.3, 0.1)$ 权重和 = $0.726 + 0.698 + 0.619 = 2.043$ 。

$$p^{(3)} = (0.355, 0.342, 0.303).$$

$$L_3 = 0.355 \times 0.6 + 0.342 \times 0.3 + 0.303 \times 0.1 = 0.213 + 0.103 + 0.030 = 0.346.$$

更新后: $w^{(4)} = (0.726 e^{-0.24}, 0.698 e^{-0.12}, 0.619 e^{-0.04}) = (0.571, 0.619, 0.595)$ 。

(c) 3 轮总期望损失:

$$\sum_{t=1}^3 L_t = 0.500 + 0.479 + 0.346 = \boxed{1.325}.$$

(d) 各专家总损失:

$$\text{专家 1: } 0.5 + 0.3 + 0.6 = 1.4,$$

$$\text{专家 2: } 0.2 + 0.7 + 0.3 = 1.2,$$

$$\text{专家 3: } 0.8 + 0.4 + 0.1 = 1.3.$$

最优固定专家 $i^* = 2$, $L^* = 1.2$ 。

(e) Regret:

$$\text{Regret} = \sum_{t=1}^3 L_t - L^* = 1.325 - 1.200 = \boxed{0.125}.$$

MWU 理论上界 ($N = 3$, $T = 3$, $\eta = 0.4$):

$$\frac{\ln N}{\eta} + \eta T = \frac{\ln 3}{0.4} + 0.4 \times 3 = \frac{1.099}{0.4} + 1.2 = 2.747 + 1.200 = 3.947.$$

实际 Regret 0.125 远小于理论上界 3.947, 说明在具体实例上 MWU 的性能远好于最坏情况保证。

第 7 题: Hoeffding 不等式与样本量

要用样本均值 $\bar{X}$ 估计真实概率 $p \in [0, 1]$, 要求 95% 把握下误差不超过 ϵ , 即 $\Pr(|\bar{X} - p| > \epsilon) \leq 0.05$ 。

- 由 Hoeffding 不等式 $\Pr(|\bar{X} - p| \geq \epsilon) \leq 2e^{-2n\epsilon^2}$, 推导最少样本量 n 关于 ϵ 的表达式。
- 取 $\epsilon = 0.02$, 最少需要多少样本?
- 若把误差减半至 $\epsilon = 0.01$, 最少需要多少样本? 是 (b) 的多少倍? 这个倍数与 $1/\epsilon^2$ 的关系是什么?
- 反过来: 若只能做 $n = 200$ 次实验, 由 Hoeffding 给出”误差 ≤ 0.05 ”的概率下界。

解答

解答。

(a) 由 Hoeffding 不等式 $\Pr(|\bar{X} - p| \geq \epsilon) \leq 2e^{-2n\epsilon^2}$, 要求此上界 ≤ 0.05 :

$$2e^{-2n\epsilon^2} \leq 0.05 \implies e^{-2n\epsilon^2} \leq 0.025 \implies 2n\epsilon^2 \geq \ln 40.$$

因此最少样本量为

$$n \geq \frac{\ln 40}{2\epsilon^2} \approx \frac{3.689}{2\epsilon^2}.$$

(b) $\epsilon = 0.02$:

$$n \geq \frac{3.689}{2 \times 0.0004} = \frac{3.689}{0.0008} = 4611.3.$$

取整: $\boxed{n \geq 4612}.$

(c) $\epsilon = 0.01$:

$$n \geq \frac{3.689}{2 \times 0.0001} = \frac{3.689}{0.0002} = 18445.$$

即 $n \geq 18445$ ，是 (b) 的 $18445/4612 = 4$ 倍。

这恰好是 $(0.02/0.01)^2 = 4$ 倍，印证了样本量 $n \propto 1/\epsilon^2$ 的关系：误差减半需要四倍样本。

(d) $n = 200$, $\epsilon = 0.05$:

$$\Pr(|\bar{X} - p| > 0.05) \leq 2e^{-2(200)(0.05)^2} = 2e^{-1} = \frac{2}{e} \approx 0.736.$$

因此

$$\Pr(|\bar{X} - p| \leq 0.05) \geq 1 - 0.736 = 0.264 \approx 26.4\%.$$

这是一个相当弱的保证——Hoeffding 不等式是分布无关的保守上界，200 次实验仅能给出约 26.4% 的置信度。

第 8 题：UCB 决策

4 个 arm，已运行 $t = 14$ 轮，当前观测：

arm a	拉的次数 n_a	经验均值 $\hat{\mu}_a$
1	5	0.40
2	3	0.60
3	2	0.50
4	4	0.55

- 写出 UCB1 的表达式 $\text{UCB}_a(t) = \hat{\mu}_a + \sqrt{2 \ln t / n_a}$ ，并指出哪一项是“探索奖励”。
- 计算每个 arm 的 UCB 值（保留 3 位小数）。
- 给出第 15 轮的选择，并解释为什么经验均值最大的 arm 不一定被选中（用“探索-利用”的语言）。
- 假设真实差距向量为 $\Delta = (0.3, 0.0, 0.2, 0.1)$ （即 arm 2 是最优），由理论 Regret 上界

$$\text{Regret}_T \leq \sum_{a: \Delta_a > 0} \frac{8 \ln T}{\Delta_a}$$

估算 $T = 10000$ 时的总 Regret 上界。

解答

解答。

(a) UCB1 表达式：

$$\text{UCB}_a(t) = \hat{\mu}_a + \underbrace{\sqrt{\frac{2 \ln t}{n_a}}}_{\text{探索奖励}}.$$

第二项是”探索奖励”，随拉的次数 n_a 增大而减小（被充分探索的 arm 探索奖励低），随总轮数 t 增大而增大（轮次增大 arm 探索次数没变相当于探索充分度下降）。

(b) 计算 $2 \ln t = 2 \ln 14 \approx 2 \times 2.639 = 5.278$ 。

arm	$\hat{\mu}_a$	n_a	$\sqrt{5.278/n_a}$	UCB_a
1	0.40	5	$\sqrt{1.056} = 1.027$	1.427
2	0.60	3	$\sqrt{1.759} = 1.326$	1.926
3	0.50	2	$\sqrt{2.639} = 1.625$	2.125
4	0.55	4	$\sqrt{1.320} = 1.149$	1.699

(c) 第 15 轮选择 arm 3（UCB 值最大为 2.125）。

虽然 arm 2 有最高经验均值 $\hat{\mu}_2 = 0.60$ ，但 arm 3 仅被拉了 2 次，不确定性极大，探索奖励高达 1.625。UCB 策略通过”乐观面对不确定性”来平衡探索与利用——对于了解不足的 arm，给予额外的探索激励。

(d) 给定 $\Delta = (0.3, 0.0, 0.2, 0.1)$ ，arm 2 最优。 $T = 10000$ 时的 Regret 上界：

$$\text{Regret}_T \leq \sum_{a: \Delta_a > 0} \frac{8 \ln T}{\Delta_a} = \frac{8 \ln 10000}{0.3} + \frac{8 \ln 10000}{0.2} + \frac{8 \ln 10000}{0.1}.$$

$\ln 10000 = 4 \ln 10 \approx 9.210$ ， $8 \ln 10000 \approx 73.68$ 。

$$= 73.68 \times \left(\frac{1}{0.3} + \frac{1}{0.2} + \frac{1}{0.1} \right) = 73.68 \times (3.333 + 5 + 10) = 73.68 \times 18.33 \approx \boxed{1351}.$$

第 9 题：Thompson Sampling 后验比较

两个 Bernoulli arm，先验均为 $\text{Beta}(1, 1)$ ，已观测：

- arm A：8 次成功、2 次失败 $\Rightarrow$ 后验 $\text{Beta}(9, 3)$
- arm B：3 次成功、7 次失败 $\Rightarrow$ 后验 $\text{Beta}(4, 8)$

(a) 用公式

$$\mu = \frac{\alpha}{\alpha + \beta}, \quad \sigma^2 = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$$

分别写出 arm A 与 arm B 后验的均值 μ 与标准差 σ 。

(b) 用正态近似估计

$$\Pr(\theta_A > \theta_B \mid \text{data}),$$

即 Thompson Sampling 选 arm A 的近似概率。

(c) 假设再采样一次 arm A, 观测为成功 (后验更新为 Beta(10, 3), arm B 后验不变)。重新计算 (a) 与 (b), 并说明这次新观测如何改变了选择概率。

(d) 思考题 (无需数值): 若两个 arm 的差距 $\hat{\mu}_A - \hat{\mu}_B$ 不变, 但样本量都翻倍, $\Pr(\theta_A > \theta_B)$ 会怎么变? 请用一句话说明 (不需要严格证明)。

解答

解答。

(a) 用 Beta 分布的均值与方差公式 $\mu = \alpha/(\alpha + \beta)$, $\sigma^2 = \alpha\beta/[(\alpha + \beta)^2(\alpha + \beta + 1)]$:

Arm A: Beta(9, 3), $\alpha + \beta = 12$

$$\mu_A = \frac{9}{12} = 0.750, \quad \sigma_A^2 = \frac{9 \times 3}{144 \times 13} = \frac{27}{1872} = 0.01442, \quad \sigma_A = 0.1201.$$

Arm B: Beta(4, 8), $\alpha + \beta = 12$

$$\mu_B = \frac{4}{12} = 0.333, \quad \sigma_B^2 = \frac{4 \times 8}{144 \times 13} = \frac{32}{1872} = 0.01709, \quad \sigma_B = 0.1308.$$

(b) 正态近似下 $\theta_A - \theta_B \sim \mathcal{N}(\mu_A - \mu_B, \sigma_A^2 + \sigma_B^2)$:

$$\mu_A - \mu_B = 0.417, \quad \sigma_{\text{diff}} = \sqrt{0.01442 + 0.01709} = \sqrt{0.03151} = 0.1775.$$

$$\Pr(\theta_A > \theta_B) = \Phi\left(\frac{0.417}{0.1775}\right) = \Phi(2.35) \approx \boxed{0.990}.$$

(c) 新观测后 arm A 更新为 Beta(10, 3), $\alpha + \beta = 13$:

$$\mu'_A = \frac{10}{13} = 0.769, \quad \sigma'^2_A = \frac{10 \times 3}{169 \times 14} = \frac{30}{2366} = 0.01268, \quad \sigma'_A = 0.1126.$$

Arm B 不变。

$$\mu'_A - \mu_B = 0.436, \quad \sigma'_{\text{diff}} = \sqrt{0.01268 + 0.01709} = \sqrt{0.02977} = 0.1725.$$

$$\Pr(\theta_A > \theta_B) = \Phi\left(\frac{0.436}{0.1725}\right) = \Phi(2.53) \approx \boxed{0.994}.$$

新观测使选择 arm A 的概率从 0.990 增加到 0.994, 增量不大, 因为在观测前算法就已经非常确信 A 优于 B。

(d) 若 $\hat{\mu}_A - \hat{\mu}_B$ 不变但样本量都翻倍, 则各 arm 后验方差近似减半, σ_{diff} 减小为原来的 $1/\sqrt{2}$, z -score 增大 $\sqrt{2}$ 倍。因此 $\Pr(\theta_A > \theta_B)$ 会增大 (更接近 1)。更多数据使算法对哪个 arm 更优更加确信, 即使均值差距不变。

第 10 题：Knowledge Gradient 与最优学习

背景：在最优学习问题中，目标不是最小化累积 Regret，而是最大化**最终决策**的质量。Knowledge Gradient (KG) 衡量**下一次实验**带来的期望决策改进。

设定：4 个候选方案，当前后验 $\mu_a \sim \mathcal{N}(\hat{\mu}_a, \sigma_a^2)$ ，每次实验观测 $y \sim \mathcal{N}(\mu_a, \sigma_\epsilon^2)$ ，观测噪声 $\sigma_\epsilon = 0.1$ （对所有 arm 相同）。

arm a	后验均值 $\hat{\mu}_a$	后验标准差 σ_a
1	0.70	0.05
2	0.65	0.20
3	0.50	0.30
4	0.68	0.10

KG 公式：测量 arm a 后，更新后估计可写为 $\hat{\mu}_a^{\text{新}} = \hat{\mu}_a + \tilde{\sigma}_a Z$ ， $Z \sim \mathcal{N}(0, 1)$ ，其中

$$\tilde{\sigma}_a = \frac{\sigma_a^2}{\sqrt{\sigma_a^2 + \sigma_\epsilon^2}}.$$

KG 的解析形式：

$$\text{KG}(a) = \tilde{\sigma}_a \cdot g(z_0^{(a)}), \quad z_0^{(a)} = \frac{|\hat{\mu}_a - \nu_{-a}|}{\tilde{\sigma}_a}, \quad \nu_{-a} = \max_{a' \neq a} \hat{\mu}_{a'},$$

其中

$$g(z) = \phi(z) - z(1 - \Phi(z)), \quad z \geq 0.$$

(g 是”标准正态截断期望”，可由 $\mathbb{E}[(Z - z)^+] = \phi(z) - z(1 - \Phi(z))$ 推出。)

- 对每个 arm 计算有效后验更新标准差 $\tilde{\sigma}_a$ 与”对手最佳” ν_{-a} 。
- 计算每个 arm 的 $z_0^{(a)}$ 与 $\text{KG}(a)$ （保留 4 位小数）。
- 给出下一次实验应该选择的 arm（即 $\arg \max_a \text{KG}(a)$ ）。
- 对比贪心：**如果不再实验、立刻 commit，将选择 $\hat{\mu}_a$ 最大的 arm，决策值为 $\max_a \hat{\mu}_a$ 。这个值是多少？用 (b) 中最大的 KG 值**量化”再做一次实验的信息价值”**。
- 现象解释：**观察 (b) 的结果——是否存在 $\hat{\mu}_a$ 更低、但 KG 反而更大的 arm？指出是哪两个 arm 的对比，并解释为什么（从 $\tilde{\sigma}_a$ 与 $z_0^{(a)}$ 两个因素分析）。
- 噪声敏感性：**将观测噪声从 $\sigma_\epsilon = 0.1$ 增大到 $\sigma_\epsilon = 0.5$ （噪声很大），重新计算 arm 3 的 $\tilde{\sigma}_3$ 和 $\text{KG}(3)$ 。说明：当观测噪声远大于后验不确定性时，单次实验的信息价值会发生什么变化？

解答

解答。

(a) 有效后验更新标准差 $\tilde{\sigma}_a = \sigma_a^2 / \sqrt{\sigma_a^2 + \sigma_\epsilon^2}$ 与”对手最佳” $\nu_{-a} = \max_{a' \neq a} \hat{\mu}_{a'}$:

arm	σ_a	$\sigma_a^2 + \sigma_\epsilon^2$	$\tilde{\sigma}_a$	ν_{-a}
1	0.05	0.0125	$0.0025/0.1118 = 0.0224$	0.68
2	0.20	0.0500	$0.04/0.2236 = 0.1789$	0.70
3	0.30	0.1000	$0.09/0.3162 = 0.2846$	0.70
4	0.10	0.0200	$0.01/0.1414 = 0.0707$	0.70

(b) 计算 $z_0^{(a)} = |\hat{\mu}_a - \nu_{-a}| / \tilde{\sigma}_a$ 和 $\text{KG}(a) = \tilde{\sigma}_a \cdot g(z_0^{(a)})$, 其中 $g(z) = \phi(z) - z(1 - \Phi(z))$:**Arm 1:** $z_0 = |0.70 - 0.68| / 0.0224 = 0.894$

$$\phi(0.894) \approx 0.267, \quad \Phi(0.894) \approx 0.814.$$

$$g(0.894) = 0.267 - 0.894 \times 0.186 = 0.267 - 0.166 = 0.101.$$

$$\text{KG}(1) = 0.0224 \times 0.101 = \mathbf{0.0023}.$$

Arm 2: $z_0 = |0.65 - 0.70| / 0.1789 = 0.280$

$$\phi(0.280) \approx 0.384, \quad \Phi(0.280) \approx 0.610.$$

$$g(0.280) = 0.384 - 0.280 \times 0.390 = 0.384 - 0.109 = 0.275.$$

$$\text{KG}(2) = 0.1789 \times 0.275 = \mathbf{0.0492}.$$

Arm 3: $z_0 = |0.50 - 0.70| / 0.2846 = 0.703$

$$\phi(0.703) \approx 0.312, \quad \Phi(0.703) \approx 0.756.$$

$$g(0.703) = 0.312 - 0.703 \times 0.244 = 0.312 - 0.172 = 0.140.$$

$$\text{KG}(3) = 0.2846 \times 0.140 = \mathbf{0.0399}.$$

Arm 4: $z_0 = |0.68 - 0.70| / 0.0707 = 0.283$

$$\phi(0.283) \approx 0.383, \quad \Phi(0.283) \approx 0.611.$$

$$g(0.283) = 0.383 - 0.283 \times 0.389 = 0.383 - 0.110 = 0.273.$$

$$\text{KG}(4) = 0.0707 \times 0.273 = \mathbf{0.0193}.$$

汇总:

$$\text{KG}(1) = 0.0023, \quad \text{KG}(2) = 0.0492, \quad \text{KG}(3) = 0.0399, \quad \text{KG}(4) = 0.0193.$$

(c) 下一次实验选择 arm 2 (KG 值最大, 0.0492)。

(d) 若立刻 commit (贪心决策), 选 $\hat{\mu}_a$ 最大的 arm 1, 决策值为 $\max_a \hat{\mu}_a = 0.70$ 。再做一次实验 (选 arm 2) 的信息价值为 $\text{KG}(2) = 0.0492$, 即期望决策改进量约为 0.049 个单位。

(e) Arm 2 的 $\hat{\mu}_2 = 0.65 < \hat{\mu}_1 = 0.70$, 但 $\text{KG}(2) = 0.0492 \gg \text{KG}(1) = 0.0023$ 。

原因分析:

- $\tilde{\sigma}_2 = 0.1789 \gg \tilde{\sigma}_1 = 0.0224$: arm 2 的后验不确定性远大于 arm 1, 一次实验能带来大幅后验更新;
- $z_0^{(2)} = 0.280$ (很小): arm 2 的当前估计 0.65 距离对手最佳 0.70 仅差 0.05, 且 $\tilde{\sigma}_2 = 0.179$ 远大于此差距, 意味着一次好的观测很可能使 arm 2 反超成为新的最优。

而 arm 1 虽然是当前最优, 但 $\sigma_1 = 0.05$ 的不确定性已经很小 ($\tilde{\sigma}_1 = 0.022$), 继续测量它几乎不改变估计。

(f) 将 σ_ϵ 从 0.1 增大到 0.5, 重新计算 arm 3:

$$\tilde{\sigma}_3 = \frac{0.09}{\sqrt{0.09 + 0.25}} = \frac{0.09}{\sqrt{0.34}} = \frac{0.09}{0.583} = 0.1544.$$

$$z_0^{(3)} = \frac{0.20}{0.1544} = 1.295.$$

估算 $\phi(1.295) \approx 0.172$, $\Phi(1.295) \approx 0.895$:

$$g(1.295) = 0.172 - 1.295 \times 0.105 = 0.172 - 0.136 = 0.036.$$

$$\text{KG}(3) = 0.1544 \times 0.036 = \boxed{0.0056}.$$

对比原来的 $\text{KG}(3) = 0.0399$, 下降了约 7 倍。

物理解释: 当观测噪声 σ_ϵ 远大于后验标准差 σ_a 时, 单次观测主要被噪声淹没, 能传递的关于真实均值的信息量很小。有效更新幅度 $\tilde{\sigma}_a = \sigma_a^2 / \sqrt{\sigma_a^2 + \sigma_\epsilon^2}$ 趋近于 $\sigma_a^2 / \sigma_\epsilon$ (比 σ_a 本身小得多), 单次实验的信息价值大幅下降。此时若要获取有用信息, 需要多次重复测量来平均掉噪声。