第 2 讲：凸优化与 KKT 条件
习题集（实践向）

优化算法课程

题 1 [⋆ 计算]　**机器学习损失函数的凸性判断**

背景： 在设计学习算法时，损失函数是否为凸函数直接决定了梯度下降能否收敛到全局最优。

判断以下函数是否为凸函数（请用二阶条件，写出导数过程）：

(a) **逻辑回归损失**：$f(x) = \log(1 + e^x)$，$x \in \mathbb{R}$

(b) **带正则的二次损失**：$f(x) = \|Ax - b\|_2^2 + \lambda\|x\|_2^2$，其中 $A \in \mathbb{R}^{m\times n}$，$\lambda > 0$；写出 Hessian 并判断正半定性。

(c) **负对数似然（多元高斯）**：$f(X) = -\log\det(X)$，$X \in \mathbb{S}_{++}^n$；说明为何此函数是协方差矩阵估计中的核心。

(d) **非凸陷阱**：$f(x_1, x_2) = x_1^2 - x_2^2$；指出其鞍点位置，并解释为何神经网络优化中大量存在此类结构。

题 2 [⋆ 概念]　**可行域的凸性分析**

背景： 约束优化问题的可行域是否为凸集，直接影响求解器（如 CVXPY、Gurobi）能否保证找到全局最优。

判断以下集合是否为凸集；若不是，给出反例并说明对优化求解的影响：

(a) **功率预算约束**：$\{x \in \mathbb{R}^n : \|x\|_2 \le P\}$（总发射功率限制）

(b) **布尔松弛域**：$\{x \in \mathbb{R}^n : 0 \le x_i \le 1,\ \forall i\}$（整数规划的 LP 松弛可行域）

(c) **归一化非负分配**：$\{x \in \mathbb{R}^n : \mathbf{1}^\top x = 1,\ x \ge 0\}$（概率单纯形）

(d) **协方差矩阵集合**：$\{X \in \mathbb{R}^{n\times n} : X = X^\top,\ X \succeq 0\}$（半正定锥，协方差估计的自然约束）

题 3 [⋆⋆ 证明]　凸性保持运算：模型组合的理论基础

背景： 深度学习中常见操作（如 max-pooling、逐点 ReLU 后的损失、仿射变换后接凸损失）之所以保持凸性，源于以下一般性结论。

证明下列命题：

(a) 若 f_1, f_2 均为凸函数，则 $g(x) = \max\{f_1(x), f_2(x)\}$ 也是凸函数。（对应：多类分类中 hinge loss 对各类得分取最大值的操作）

(b) 若 f 是凸函数，A 是矩阵，b 是向量，则 $g(x) = f(Ax + b)$ 也是凸函数。（对应：线性层 $Ax + b$ 接凸损失，整体仍为凸）

(c) 若 $f(x, y)$ 关于 (x, y) 联合凸，则 $g(x) = \inf_y f(x, y)$ 关于 x 是凸函数。（对应：消去隐变量后目标仍凸——EM 算法下界凸性的基础）

题 4 [⋆⋆ 概念 + 应用]　Jensen 不等式与变分自编码器（VAE）的 ELBO

背景： 变分推断的核心是用一个易处理的分布 $q(z|x)$ 近似真实后验 $p(z|x)$。Jensen 不等式给出了对数似然 $\log p(x)$ 的下界，即 ELBO（Evidence Lower BOund），这是 VAE 训练目标的理论依据。

(a) 陈述 Jensen 不等式，并证明：对凸函数 f 和随机变量 Z，有 $f(\mathbb{E}[Z]) \le \mathbb{E}[f(Z)]$。

(b) 利用 Jensen 不等式，对 $-\log$（凸函数）推导以下不等式：

$$\log p(x) = \log \mathbb{E}_{q(z|x)}\left[\frac{p(x,z)}{q(z|x)}\right] \;\ge\; \mathbb{E}_{q(z|x)}\left[\log \frac{p(x,z)}{q(z|x)}\right] =: \mathrm{ELBO}(q)$$

指出等号成立的条件。

(c) 将 ELBO 改写为 $\mathrm{ELBO}(q) = \mathbb{E}_q[\log p(x|z)] - D_{\mathrm{KL}}(q(z|x) \,\|\, p(z))$，并解释两项分别对应 VAE 的哪个训练目标（重建误差 vs. 正则化）。

题 5 [⋆⋆ 计算]　资源分配中的 KKT 条件

背景： 考虑将单位总算力分配给 n 个任务，第 i 个任务分得算力 x_i 时产生效用 $u_i(x_i)$。当效用函数为严格凹函数时，最优分配由 KKT 条件完全刻画。

具体地，求解以下问题，要求**写出完整 KKT 条件**（稳定性、原始可行性、对偶可行性、互补松弛）并求出 x^* 和所有对偶变量：

$$\min_{x \in \mathbb{R}^2} \quad (x_1 - 1)^2 + (x_2 - 2)^2 \quad \text{s.t.} \quad x_1 + x_2 \le 2, \quad x_1 \ge 0, \quad x_2 \ge 0$$

(a) 写出 Lagrangian $L(x, \lambda)$，引入乘子 λ_1（对应 $x_1 + x_2 \le 2$），λ_2（对应 $-x_1 \le 0$），

λ_3（对应 $-x_2 \le 0$）。

(b) 列出全部 KKT 条件。

(c) 通过枚举互补松弛的活跃约束组合，求解 x^*、λ_1^*、λ_2^*、λ_3^*。

(d) 验证互补松弛条件均满足，并给出经济学直觉：哪条约束是”紧的”，其对偶变量的正值代表什么？

题 6 [⋆⋆ 推导]　岭回归的 Lagrange 对偶与正则化解释

背景： 岭回归（Ridge Regression）既可以写成带 ℓ_2 惩罚的无约束问题，也等价于一个带范数约束的最小二乘问题。两种形式通过 Lagrange 对偶联系，正则化系数 λ 正好是约束的”影子价格”。

考虑带等式约束的二次规划：

$$\min_{x\in\mathbb{R}^n} \quad \tfrac{1}{2}x^\top Qx + c^\top x \quad \text{s.t.} \quad Ax = b, \quad Q \succ 0$$

(a) 写出 Lagrangian $L(x,\nu)$，对 x 求极小（令 $\nabla_x L = 0$），得到最优 $x^*(\nu)$ 关于对偶变量 ν 的解析表达式。

(b) 将 $x^*(\nu)$ 代回，得到对偶函数 $g(\nu)$；写出对偶问题并化简。

(c) 说明强对偶性成立的依据（Slater 条件），并指出对偶变量 ν^* 的统计含义（在普通线性回归 $Q = A^\top A$，$c = -A^\top b$ 的特殊情形下说明）。

题 7 [⋆⋆ 综合推导]　支持向量机（SVM）对偶推导与支持向量的几何意义

背景： SVM 是凸二次规划的经典应用。其对偶形式不仅降低了问题维度（从特征维 d 降到样本数 m），更揭示了分类边界只由少数”支持向量”决定这一核心几何直觉。

原问题：

$$\min_{w,b} \quad \tfrac{1}{2}\|w\|^2 \quad \text{s.t.} \quad y_i(w^\top x_i + b) \ge 1, \quad i = 1,\dots,m$$

(a) 写出 Lagrangian $L(w,b,\alpha)$，对 w 和 b 分别求导令其为零，得到 $w = \sum_i \alpha_i y_i x_i$ 及关于 b 的条件。

(b) 将上述结果代回，推导出对偶问题：

$$\max_{\alpha\ge 0} \quad \sum_i \alpha_i - \tfrac{1}{2}\sum_{i,j}\alpha_i\alpha_j y_i y_j x_i^\top x_j \quad \text{s.t.} \quad \sum_i \alpha_i y_i = 0$$

(c) 利用互补松弛条件 $\alpha_i[y_i(w^\top x_i + b) - 1] = 0$ 解释：为何只有”压在间隔边界上”的样本才有 $\alpha_i > 0$？这些样本称为支持向量。

(d) 手算：给定 $x_1 = (1,0), y_1 = +1$；$x_2 = (0,1), y_2 = +1$；$x_3 = (-1,0), y_3 = -1$，求 w^*，b^* 和 α^*，并画出分类超平面示意图。

题 8 [⋆⋆⋆ 综合]　带风险约束的投资组合优化（QCQP）

背景： Markowitz 均值-方差模型是金融优化的基石。当引入”最大波动率”约束时，问题升级为带二次约束的二次规划（QCQP）。分析其对偶揭示了”风险预算”的影子价格。

考虑以下 QCQP（$\Sigma \succ 0$ 为协方差矩阵，μ 为期望收益向量）：

$$\min_{w \in \mathbb{R}^n} \quad w^\top \Sigma w \quad \text{s.t.} \quad \mu^\top w \geq r_{\min}, \quad \mathbf{1}^\top w = 1, \quad w \geq 0$$

(a) 写出 Lagrangian $L(w, \lambda, \nu, \gamma)$，列出 KKT 条件（稳定性条件需写出矩阵形式）。

(b) 证明对偶函数 $g(\lambda, \nu, \gamma)$ 是关于 (λ, ν, γ) 的凹函数。

(c) 设 $n = 2$，$\Sigma = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 2 \end{pmatrix}$，$\mu = (0.1, 0.2)^\top$，$r_{\min} = 0.12$。手算最优权重 w^* 和对偶变量 λ^*（收益约束的乘子）。

(d) 解释”影子价格”：若 $r_{\min}$ 从 0.12 提高到 $0.12 + \epsilon$，最优方差（目标值）将如何变化？用 λ^* 给出近似表达式。

题 9 [⋆⋆⋆ 证明 + 应用]　弱对偶定理与电力网络的输电容量定价

背景： 在电力系统最优潮流（OPF）问题中，输电线路容量约束对应的对偶变量称为”边际阻塞成本”（Locational Marginal Price, LMP）。弱对偶定理保证了 LMP 是发电成本的有效下界，强对偶（在凸 OPF 下成立）则保证这个下界是紧的。

(a) **证明弱对偶定理**：对一般优化问题

$$p^* = \min_x f(x) \quad \text{s.t.} \quad g_i(x) \leq 0,\ h_j(x) = 0$$

设 Lagrangian 为 $L(x, \lambda, \nu) = f(x) + \sum_i \lambda_i g_i(x) + \sum_j \nu_j h_j(x)$，对偶函数 $g(\lambda, \nu) = \inf_x L(x, \lambda, \nu)$。利用 $\lambda \geq 0$ 与 $g_i(x) \leq 0$，严格证明对所有对偶可行 (λ, ν) 有 $g(\lambda, \nu) \leq p^*$，从而 $d^* \leq p^*$。

(b) **对偶间隙与凸性的关系**：

(i) 给出一个非凸问题的简单例子，使得对偶间隙 $p^* - d^* > 0$。

(ii) 陈述 Slater 条件，解释为何对凸问题它保证强对偶（$p^* = d^*$）。

(c) **影子价格的精确表述**：设 $p^*(\epsilon)$ 是约束松弛为 $g_i(x) \le \epsilon_i$ 后的最优值函数。在强对偶和适当光滑性假设下，证明

$$\left.\frac{\partial p^*}{\partial \epsilon_i}\right|_{\epsilon=0} = -\lambda_i^*$$

并用电力市场语言解释：λ_i^* 为什么代表" 放松第 i 条输电线路容量一个单位所节省的发电成本"。

题 10 [⋆⋆⋆ **推导 + 计算**] **马尔可夫决策过程（MDP）的线性规划对偶**

背景：强化学习的理论基础之一是：值函数迭代（Value Iteration）本质上在求解一个线性规划，而该 LP 的对偶问题恰好对应" 状态-动作占用度量"（occupancy measure）的最优化。理解这一对偶关系，是连接经典 DP、线性规划与现代深度强化学习的关键桥梁。

考虑有限状态、有限动作的折扣 MDP，记为 $(\mathcal{S}, \mathcal{A}, P, r, \gamma)$：

- $\mathcal{S} = \{1, \dots, S\}$：状态空间；$\mathcal{A} = \{1, \dots, A\}$：动作空间
- $P(s'|s,a)$：转移概率；$r(s,a) \in \mathbb{R}$：即时奖励；$\gamma \in [0,1)$：折扣因子
- $\rho(s)$：初始状态分布，$\rho(s) > 0$

(a) **原始 LP（Primal LP）——值函数视角**

Bellman 最优方程要求对所有 $s \in \mathcal{S}$：

$$V(s) = \max_{a \in \mathcal{A}} \left[r(s,a) + \gamma \sum_{s'} P(s'|s,a) V(s') \right]$$

将此写成线性规划：

$$\min_{V \in \mathbb{R}^S} \quad \sum_s \rho(s) V(s) \quad \text{s.t.} \quad V(s) \ge r(s,a) + \gamma \sum_{s'} P(s'|s,a) V(s'), \quad \forall s \in \mathcal{S},\ a \in \mathcal{A}$$

(i) 说明决策变量数目和约束数目（分别用 S, A 表示）。

(ii) 证明：上述 LP 的最优解 V^* 恰好是 Bellman 最优方程的解（即最优值函数）。提示：设 V_{LP}^* 是 *LP* 最优解，V^* 是 *Bellman* 方程的解，分别证明 $V_{LP}^* \le V^*$ 和 $V_{LP}^* \ge V^*$。

(b) **对偶 LP（Dual LP）——占用度量视角**

引入对偶变量 $d(s,a) \ge 0$（对应每条约束 $V(s) \ge r(s,a) + \cdots$），写出原始 LP 的对偶问题：

$$\max_{d \ge 0} \quad \sum_{s,a} r(s,a)\, d(s,a) \quad \text{s.t.} \quad \sum_a d(s,a) - \gamma \sum_{s',a'} P(s|s',a')\, d(s',a') = \rho(s), \quad \forall s \in \mathcal{S}$$

(i) 推导该对偶问题（从 Lagrangian 出发，对 V 求极小并整理）。

(ii) 证明弱对偶：原始 LP 目标值 $\geq$ 对偶 LP 目标值（即 $\sum_s \rho(s)V(s) \geq \sum_{s,a} r(s,a)d(s,a)$ 对任意原始可行 V 和对偶可行 d 均成立）。

(iii) 指出强对偶成立的条件，并说明此时 $d^*(s,a)$ 的概率论含义：

$$d^*(s,a) = \sum_{t=0}^{\infty} \gamma^t \Pr(s_t = s,\ a_t = a \mid \pi^*,\ s_0 \sim \rho)$$

解释 $d^*(s,a)$ 为何称为" 折扣状态-动作占用度量"。

(c) **互补松弛与最优策略提取**

设原始 LP 最优解为 V^*，对偶 LP 最优解为 d^*，写出互补松弛条件：

$$d^*(s,a)\left[V^*(s) - r(s,a) - \gamma \sum_{s'} P(s'|s,a)V^*(s')\right] = 0, \quad \forall s,a$$

(i) 解释互补松弛的含义：若 $d^*(s,a) > 0$（该状态-动作对" 被访问"），则对应的 Bellman 约束必须以等号成立，即动作 a 在状态 s 下是最优的。

(ii) 由此给出从 d^* 中提取最优策略 π^* 的方法：

$$\pi^*(a|s) = \frac{d^*(s,a)}{\sum_{a'} d^*(s,a')}$$

说明为何这与直接从 V^* 贪心提取策略等价。

(d) **小型手算**

考虑一个两状态（s_1, s_2）、两动作（a_1, a_2）的 MDP，$\gamma = 0.9$，$\rho = (0.5, 0.5)$：

状态	动作	$r(s,a)$	$P(s_1\|s,a)$	$P(s_2\|s,a)$
s_1	a_1	1	0.8	0.2
s_1	a_2	0	0.1	0.9
s_2	a_1	0	0.5	0.5
s_2	a_2	2	0.3	0.7

(i) 写出原始 LP 的 4 个约束（$S \times A = 2 \times 2$），未知量为 (V_1, V_2)。

(ii) 通过值迭代（Value Iteration）迭代至收敛（误差 < 0.01），得到近似 $V^*(s_1)$，$V^*(s_2)$。

(iii) 对应写出对偶 LP，求解最优占用度量 $d^*(s_1,a_1), d^*(s_1,a_2), d^*(s_2,a_1), d^*(s_2,a_2)$。

(iv) 验证互补松弛条件，并提取最优策略 π^*。