第四周作业：**算法设计范式与 GPU 化**

分治、动态规划、贪心——及其在大模型中的应用

优化算法课程

2026 年 3 月 29 日

第一题：主定理与矩阵乘法复杂度

大模型背景：Transformer 中的矩阵乘法

大语言模型的注意力机制（Attention）核心操作为矩阵乘法：$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$。其中 $Q, K, V \in \mathbb{R}^{n\times d}$。分析矩阵乘法算法的时间复杂度对大模型推理效率至关重要。

(a) 用主定理求解下列递推式的时间复杂度（写出所用的主定理情形）：

i. $T(n) = 8T(n/2) + O(n^2)$ （朴素矩阵乘法的分治形式）

ii. $T(n) = 7T(n/2) + O(n^2)$ （Strassen 算法）

iii. $T(n) = 4T(n/2) + O(n^2)$

iv. $T(n) = 2T(n/2) + O(n \log n)$ （归并排序变体）

(b) 在 Transformer 的自注意力中，设序列长度为 n，模型维度为 d。

i. 计算 $QK^\top$ 的朴素算法（矩阵乘法）时间复杂度是多少？

ii. 若 $d = O(n)$，朴素算法 vs Strassen 算法，哪个渐近更快？给出理由。

iii. 实践中 Strassen 算法较少用于深度学习，请给出至少一个工程原因。

第二题：动态规划——最长公共子序列（LCS）与代码相似度检测

大模型背景：LLM 生成代码的抄袭/泄露检测

大语言模型生成的代码可能与训练数据中的代码高度相似，引发版权和隐私风险。**最长公共子序列（LCS）**是衡量两段序列结构相似度的经典方法：将代码 token 化后，计算生成序列与训练样本的 LCS 长度，可作为”记忆泄露”（memorization）程度的量化指标。

(a) 设 $dp[i][j]$ 为序列 $X[1..i]$ 与 $Y[1..j]$ 的最长公共子序列长度。写出：

i. 状态转移方程（分 $X[i] = Y[j]$ 和 $X[i] \neq Y[j]$ 两种情况讨论）

ii. 边界条件 $dp[i][0]$ 和 $dp[0][j]$

iii. 时间复杂度与空间复杂度

(b) 设某 LLM 生成的 token 序列为 $X = [\texttt{def}, \texttt{sort}, \texttt{list}, \texttt{return}, \texttt{sorted}, \texttt{list}]$（长度 6），训练集中的一段代码 token 序列为 $Y = [\texttt{def}, \texttt{merge}, \texttt{sort}, \texttt{return}, \texttt{list}]$（长度 5）。

手动填写完整的 DP 表格（7×6，含边界行列），给出 LCS 长度。

$dp[i][j]$	ε	def	merge	sort	return	list
ε	0	0	0	0	0	0
def	0					
sort	0					
list	0					
return	0					
sorted	0					
list	0					

回溯找出一个具体的 LCS，并计算相似度指标 $\text{sim} = \dfrac{2\,|\text{LCS}|}{|X| + |Y|}$。

(c) 用**剪切-粘贴论证法**证明 LCS 的最优子结构：

核心要求：待证命题

设 $Z = z_1 z_2 \cdots z_k$ 是 $X[1..m]$ 与 $Y[1..n]$ 的一个 LCS。若 $x_m = y_n$，则 $z_k = x_m = y_n$，且 $Z[1..k-1]$ 是 $X[1..m-1]$ 与 $Y[1..n-1]$ 的 LCS。

提示：先证 $z_k = x_m$（反证：若不是，可以将 x_m 附加到 Z 末尾得到更长公共子序列）；再证 $Z[1..k-1]$ 是最优的（若存在更长的公共子序列 W，可以粘贴 x_m 得到矛盾）。

第三题：分治法——用 FFT 加速卷积

大模型背景：卷积神经网络（CNN）中的卷积加速

卷积神经网络的核心操作是一维或二维离散卷积。朴素卷积的时间复杂度为 $O(n^2)$，而利用分治法和快速傅里叶变换（FFT）可将其降至 $O(n \log n)$，这在处理长序列（如语音、DNA 序列）时至关重要。

(a) 两个长度为 n 的多项式（序列）的卷积朴素算法为 $O(n^2)$。Cooley-Tukey FFT 算法采用分治策略，将 DFT 拆分为奇偶两部分：

$$F[k] = F_{\text{even}}[k] + e^{-2\pi ik/n} F_{\text{odd}}[k]$$

写出该算法的递推式，并用主定理求解其时间复杂度。

(b) 对长度 $n = 8$ 的序列，画出 FFT 蝴蝶操作的递归结构示意图（树形图），标注每一层的操作数量，并说明：第 ℓ 层（$\ell = 1, 2, \ldots, \log_2 n$）共有多少个独立的蝴蝶操作？

(c) 在 GPU 上并行执行 FFT 时：

i. 每一层的蝴蝶操作可以完全并行，假设 GPU 有足够的并行核心（$\geq n/2$），分析 GPU 上 FFT 的并行时间复杂度（按层数计）。

ii. 相比 CPU 上 $O(n \log n)$ 的顺序时间，GPU 上的加速比是多少？

iii. 用 FFT 加速 CNN 卷积时，实际并行效率受哪些因素影响？请列举两点。

第四题：动态规划——矩阵链乘法与最优括号化

大模型背景：Transformer 中的多矩阵乘法顺序优化

Transformer 推理时，一个注意力头的计算为 $((QK^\top)V)W_O$，涉及多个矩阵连乘。不同的括号化方式（计算顺序）会导致截然不同的计算量。对矩阵链乘法顺序进行优化，可显著降低推理时间。

(a) 写出矩阵链乘法的 DP 状态定义和转移方程：设 $m[i, j]$ 为计算矩阵 $A_i A_{i+1} \cdots A_j$ 所需的最少标量乘法次数，写出 $m[i, j]$ 的递推式（$i < j$ 时），以及时间复杂度。

(b) 给定如下 4 个矩阵（维度模拟 Transformer 注意力计算）：

$$A_1 \in \mathbb{R}^{64\times 512}, \quad A_2 \in \mathbb{R}^{512\times 64}, \quad A_3 \in \mathbb{R}^{64\times 512}, \quad A_4 \in \mathbb{R}^{512\times 1}$$

i. 用 DP 方法求计算 $A_1A_2A_3A_4$ 的**最优括号化方式**及最少标量乘法次数。请填写 $m[i,j]$ 的完整表格。

ii. 列举所有可能的括号化方式中，**最差**的括号化方式需要多少次标量乘法？与最优方案相差多少倍？

第五题：状态压缩 DP——Beam Search 路径规划

大模型背景：语言模型解码：Beam Search vs 贪心解码

语言模型自回归生成时，每步从词表 V 中选一个 token。**贪心解码**每步选概率最高的 token；**Beam Search** 保留 B 条候选路径，以期找到全局更优的序列。理解这两种解码策略的本质，需要动态规划的视角。

(a) 考虑一个简化问题：词表大小为 n，生成长度为 T 的序列，每步的对数概率为 $\log p(\text{token}_t|\text{context})$。

i. 将”找最大对数概率序列”形式化为 DP 问题，定义状态和转移方程。

ii. 暴力枚举所有长度为 T 的序列的时间复杂度是多少？DP 能否将其降低？为什么？（提示：注意这里的语言模型是自回归的，即 $p(x_t|x_{<t})$ 依赖全部历史。）

(b) 考虑如下反例：词表 $V = \{A, B, C\}$，生成长度 $T = 3$，各步概率如下表：

步骤	第 1 步			第 2 步（上步选 A）			第 3 步（前两步 AB）		
Token	A	B	C	A	B	C	A	B	C
概率	0.5	0.3	0.2	0.1	0.8	0.1	0.35	0.33	0.32
				第 2 步（上步选 B）			第 3 步（前两步 BA）		
Token				A	B	C	A	B	C
概率				0.6	0.3	0.1	0.1	0.8	0.1

i. 贪心解码给出的序列是什么？总概率是多少？

ii. 再计算序列 `BAB` 的总概率，并据此说明贪心解码**不一定**给出全局最优解。

(c) 经典 **TSP 状压 DP**（旅行商问题）：n 个城市，$dp[S][v]$ 表示从城市 0 出发，已访问城市集合为 S，当前在城市 v 的最短路径长度。

i. 写出 $dp[S][v]$ 的状态转移方程。

ii. 状态总数和总时间复杂度各是多少？

iii. 若每个城市代表一个候选解码步骤，这与 Beam Search 有何结构上的相似性？简要说明（3 句话以内）。

第六题：KV Cache 页分配——前缀共享下的树形背包 DP

大模型背景：vLLM 的 PagedAttention 与前缀共享

大模型推理引擎（如 vLLM）使用 **PagedAttention**：将 KV Cache 分成固定大小的**物理页**（block），按需分配给各请求。当多个请求共享**相同的前缀**（如相同的 system prompt）时，共享前缀对应的 KV Cache 页只需存储**一份**，多个请求可共用——这称为 **prefix sharing**（前缀共享），是 vLLM 的关键优化之一。在物理页总量有限时，如何选择服务哪些请求、利用前缀共享节省页数，可以建模为一个**树形依赖背包问题**。

问题形式化

系统中有若干推理请求，它们的 prompt 前缀关系构成一棵**前缀树**（trie）。树中的每个**内部节点**代表一段共享前缀，占用若干物理页；每个**叶节点**代表一个具体请求的独有后缀部分。

- 每个节点 v 有**页开销** $c(v)$（存储该段 KV Cache 所需的物理页数）
- 每个**叶节点**（请求）有**服务收益** $w(v)$（如用户优先级、预期收入）；内部节点的收益为 0（共享前缀本身不产生收益，仅为请求服务）
- **依赖约束**：要服务某个请求（叶节点），必须分配从根到该叶的**整条路径**上所有节点的页
- 前缀共享：若两个请求共享某段前缀，该前缀的页**只需分配一次**

目标：在总物理页预算 P 内，选择一些请求服务，使总收益最大化。

(a) **树形 DP 状态定义。**设 $dp[v][j]$ 为以 v 为根的子树中，分配 j 个物理页时可获得的最大收益。注意：**选择子树中的任何叶节点，都必须先为节点 v 本身分配 $c(v)$ 页。**

i. 写出叶节点（请求节点）的边界条件：

$$dp[v][j] = \begin{cases} ? & \text{if } j \geq c(v) \\ ? & \text{if } j < c(v) \end{cases}$$

ii. 写出内部节点 v（子节点集合为 $\mathrm{ch}(v) = \{u_1, u_2, \ldots\}$）的状态转移方程。

提示：先为 v 本身保留 $c(v)$ 页，剩余 $j - c(v)$ 页在各子树间分配。子树之间的页分配相互独立，等价于对子树做**分组背包合并**：依次合并每个子树的 DP 表。

(b) **手算例子。**下图为一个前缀树，共 5 个请求（叶节点 R_1–R_5）。每个节点标注为 $[w, c]$（收益, 页开销）。物理页预算 $P = 7$。

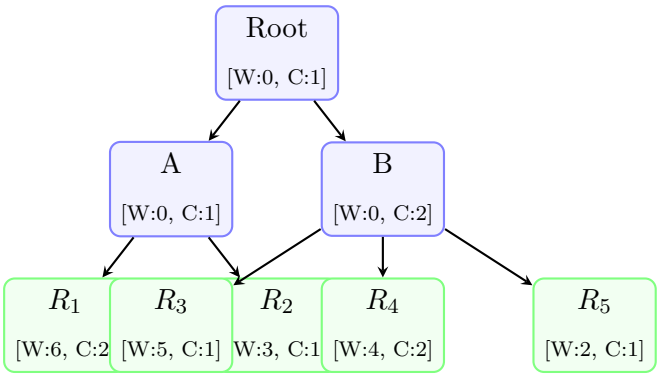

例如，服务请求 R_1 需要分配路径 root $\to A \to R_1$ 共 $1+1+2=4$ 页；若同时服务 R_1 和 R_2，共享 root 和 A 的页，总共只需 $1+1+2+1=5$ 页。

i. 自底向上计算每个节点的 $dp[v][j]$ 表。先算叶节点 R_1–R_5，再合并算内部节点 A、B，最后算 root。

ii. 在预算 $P = 7$ 下，最优方案服务哪些请求？最大总收益是多少？

iii. 验证前缀共享带来的节省：若不共享前缀（每个请求独立分配从根到叶的全部页），服务同样的请求集合需要多少页？节省了多少？

(c) **复杂度分析。**

i. 合并两个子树的 DP 表（大小分别为 s_1 和 s_2）需要 $O(s_1 \cdot s_2)$ 时间。说明整棵树的总合并时间为 $O(nP^2)$，其中 n 为节点数。

ii. 在实际 LLM serving 中，n 可达数百（请求数 + 共享前缀数），P 可达数千（GPU 显存页数）。$O(nP^2)$ 是否实际可行？若不可行，提出一种降低复杂度的思路。（提示：如果大部分子树的 dp 表是稀疏的，可以怎样优化？）

第七题：0-1 背包的 FPTAS——大模型推理预算分配

大模型背景：LLM Serving 中的请求选择

在大规模 LLM 服务中，当系统过载时，需要从等待队列中选择一批请求处理，使得在有限的计算预算（GPU 算力或 KV Cache 容量）内，总服务质量最高。每个请求的计算开销（token 数）和优先级（SLA 等级、付费用户权重）不同，这本质上是一个 **0-1 背包问题**。精确 DP 的复杂度 $O(nW)$ 在预算 W 很大时不可行，而 **FPTAS**（全多项式时间近似方案）通过值域缩放，能在 $O(n^2/\varepsilon)$ 时间内找到 $(1-\varepsilon)$ 近似解。

(a) **伪多项式时间与 NP 难的关系。** 0-1 背包的精确 DP 复杂度为 $O(nW)$。

i. 若输入中 W 用二进制表示，其编码长度为 $\lceil \log_2 W \rceil$ 位。说明 $O(nW) = O(n \cdot 2^{\lceil \log_2 W \rceil})$，即对输入编码长度而言是**指数级**的。这就是" 伪多项式时间" 的含义。

ii. 0-1 背包是**弱 NP 难**问题。解释" 弱 NP 难" 与" 强 NP 难" 的区别，并各举一个例子。

(b) **FPTAS 算法描述。**给定 $\varepsilon > 0$，FPTAS 通过以下步骤将 0-1 背包转化为多项式时间可解的问题：

i. 令 $V_{\max} = \max_i v_i$，缩放因子 $K = \dfrac{\varepsilon \cdot V_{\max}}{n}$。对每个物品计算缩放后的价值 $v'_i = \left\lfloor \dfrac{v_i}{K} \right\rfloor$。说明每个 v'_i 的取值范围（用 n, ε 表示上界）。

ii. 对缩放后的问题，运行**最小重量 DP**：$dp[v]$ 表示恰好达到总缩放价值 v 时的最小总重量。写出 $dp[v]$ 的状态转移方程和初始条件。

iii. DP 表的大小（v 的上界）是多少？（用 n, ε 表示）总时间复杂度是多少？验证这是关于 n 和 $1/\varepsilon$ 的多项式。

(c) **近似比证明。**设 OPT 为精确最优值，ALG 为 FPTAS 的输出值。

核心要求：待证命题

$\mathrm{ALG} \geq (1-\varepsilon)\,\mathrm{OPT}$。

提示：

i. 设 S^* 为最优解的物品集合。说明每个物品取整损失 $v_i - K \cdot v'_i < K$，因此总损失 $\mathrm{OPT} - K \cdot \sum_{i \in S^*} v'_i < n \cdot K = \varepsilon \cdot V_{\max}$。

ii. 说明 $V_{\max} \leq \mathrm{OPT}$（最优解至少包含一个物品），从而总损失 $< \varepsilon \cdot \mathrm{OPT}$。

iii. 设 FPTAS 的解为 S'，在缩放问题中 S' 是最优的。综合以上两步，完成证明：$\mathrm{ALG} \geq K \cdot \sum_{i \in S'} v'_i \geq K \cdot \sum_{i \in S^*} v'_i \geq (1-\varepsilon)\,\mathrm{OPT}$。

(d) **数值手算。** 5 个推理请求，计算预算 $W = 11$：

请求 i	计算开销 w_i	服务收益 v_i	v_i/K	缩放后 v'_i
1	5	35		
2	2	155		
3	6	50		
4	4	250		
5	2	30		

取 $\varepsilon = 0.4$。

i. 计算 $V_{\max}$、K、以及每个物品的缩放价值 v'_i（填入上表）。DP 表的大小（v' 的上界 $\sum_i v'_i$）是多少?

ii. 运行缩放后的最小重量 DP。**提示**：不需要填写全部表格，只需追踪 $dp[v']$ 中能够被 $W = 11$ 容纳的那些状态。找到 FPTAS 的近似解：选了哪些请求？近似总收益 ALG 是多少?

iii. 用暴力枚举($2^5 = 32$ 种子集)求出精确最优值 OPT 及最优方案。计算 ALG/OPT，验证是否 $\geq 1 - \varepsilon = 0.6$。

iv. 观察：FPTAS 的解与精确最优解有何不同？造成这种差异的原因是什么？（提示：比较两个方案在缩放后的价值 $\sum v'_i$ 和实际价值 $\sum v_i$。）

第八题：贪心算法——Huffman 编码与词表压缩

大模型背景：LLM 词表压缩与 Zipf 定律

大语言模型的词表通常包含数万个 token，且其频率分布遵循 **Zipf 定律**（极度不均匀）：少数高频词出现极为频繁，大量低频词极少出现。Huffman 编码可利用这种不均匀性压缩存储空间，是模型量化与压缩的理论基础之一。

(a) 给定 6 个高频 token 及其在语料中出现的相对频率（单位：千次）：

Token	`the`	`a`	`is`	`of`	`in`	`to`
频率	45	13	12	16	9	5

按 Huffman 算法构造最优前缀编码树，画出 Huffman 树（标注每条边的 0/1），并写出每个 token 的编码。

(b) 计算：

i. Huffman 编码的**平均编码长度**（按频率加权）；

ii. 若使用等长编码（$\lceil \log_2 6 \rceil$ 位），平均编码长度是多少？

iii. Huffman 编码相比等长编码节省了多少比例的空间？

(c) 用**交换论证法（exchange argument）**证明 Huffman 算法的贪心选择性质：

核心要求：待证命题

在最优前缀编码树中，频率最低的两个符号一定是兄弟节点（位于树的最深层）。

提示：假设最优树中频率最低的符号 x, y 不是深度最大的兄弟节点，构造一棵交换后的树，证明交换不会增加（反而可能减少）平均编码长度，从而导出矛盾。

第九题：贪心调度——GPU 推理请求的最小最大延迟

大模型背景：大模型推理服务的请求调度

在生产环境中，推理服务器（如 vLLM、TensorRT-LLM）同时接收大量用户请求，每个请求有不同的处理时间（由序列长度决定）和截止时间（用户的 SLA 要求）。合理调度请求顺序，可以最小化用户的最大等待超时时间。

(a) 设有 n 个推理请求，请求 i 的处理时间为 t_i，截止时间为 d_i。所有请求在时刻 0 均已到达，每次只处理一个请求（单 GPU）。定义请求 i 的**延迟**为 $L_i = C_i - d_i$，其中 C_i 为其完成时刻；若 $C_i \le d_i$ 则延迟为负（未超时）。目标是最小化最大延迟 $L_{\max} = \max_i L_i$。

证明：**最早截止时间优先（EDF）策略**（按 d_i 升序调度）最小化 $L_{\max}$。

提示：用交换论证法——若某调度 σ 中存在相邻两个请求 i, j 满足 $d_i > d_j$ 但 i 排在 j 之前，证明交换它们不会增大 $L_{\max}$。

(b) 对如下 4 个推理请求，按 EDF 策略调度，计算每个请求的完成时刻、延迟，以及最大延迟 $L_{\max}$：

请求	t_i（处理时间）	d_i（截止时间）	C_i（完成时刻）	L_i（延迟）
1	2	4		
2	1	2		
3	3	7		
4	2	5		

第十题：FlashAttention——分块、IO 复杂度与在线 softmax

大模型背景：FlashAttention：IO 感知的注意力算法

标准注意力需要将 $n \times n$ 的注意力矩阵 $S = QK^\top/\sqrt{d}$ 物化到 GPU 的 **HBM**（高带宽显存，容量大但带宽有限），再读回做 softmax 和乘 V。当序列长度 n 很大时，这 $O(n^2)$ 的 HBM 读写成为瓶颈。**FlashAttention**（Dao et al., 2022）采用分块策略：将 Q, K, V 按序列维度分成大小为 B 的块，在片上 **SRAM**（容量小但速度极快）中逐块计算注意力，并利用**在线 softmax** 技巧实时修正归一化，从而**无需物化完整注意力矩阵**，将额外显存从 $O(n^2)$ 降至 $O(n)$。

(a) **分块策略与显存分析。**标准注意力的中间结果 $S \in \mathbb{R}^{n\times n}$ 需要 $O(n^2)$ 显存。FlashAttention 将 Q 分成 $T_Q = \lceil n/B_r \rceil$ 个块，K, V 分成 $T_{KV} = \lceil n/B_c \rceil$ 个块，每次在 SRAM 中只存储一个 $B_r \times B_c$ 的局部注意力块。

i. 每次 SRAM 中需要存储的数据包括：一个 Q 块（$B_r \times d$）、一个 K 块（$B_c \times d$）、一个 V 块（$B_c \times d$）、局部注意力块（$B_r \times B_c$）、以及输出累加器（$B_r \times d$）。写出 SRAM 占用量关于 B_r, B_c, d 的表达式。若 $B_r = B_c = B$，SRAM 大小 M 需要满足什么条件？

ii. 解释为何 FlashAttention 的**额外显存**（不含输入 Q, K, V 和最终输出 O）只有 $O(n)$ 而非 $O(n^2)$。这 $O(n)$ 具体存储的是什么？

(b) **IO 复杂度分析。** FlashAttention 的核心收益在于减少 HBM 读写次数。

i. 标准注意力需要：(1) 从 HBM 读 Q, K 计算 $S = QK^\top$，将 S 写回 HBM；(2) 从 HBM 读 S 做 softmax，将 $P = \mathrm{softmax}(S)$ 写回；(3) 从 HBM 读 P, V 计算输出。写出标准注意力的总 HBM 读写量（用 n, d 表示，忽略常数）。

ii. FlashAttention 的外层循环遍历 T_{KV} 个 KV 块，内层循环遍历 T_Q 个 Q 块。每次内层迭代从 HBM 读取一个 Q 块和对应的输出块，写回更新后的输出块。每次外层迭代读取一个 KV 块。写出总 HBM 读写量关于 n, d, B_r, B_c 的表达式。

iii. 令 $B_r = B_c = B = \Theta(M/d)$（SRAM 约束），将 HBM 读写量用 n, d, M 表示。当 $M = \Theta(nd)$（SRAM 足够大）时，IO 量为多少？与标准注意力的 $O(n^2 d)$ 相比改善了多少？

(c) **在线 softmax 与经典分治的对比。**

分块计算 $\mathrm{softmax}(QK^\top) \cdot V$ 的核心难点在于：softmax 需要对第 i 个 query 的**全部** n 个 key 的得分做归一化，但每个块只看到 B_c 个 key。

i. 设前 j 个 K 块处理完后，第 i 个 query 已累积的局部结果为 $\tilde{o}_i^{(j)} = \sum_{k \le jB_c} e^{s_{ik} - m_i^{(j)}} v_k$ 和对应的 log-sum-exp $L_i^{(j)} = \log \sum_{k \le jB_c} e^{s_{ik} - m_i^{(j)}}$，其中 $m_i^{(j)}$ 为当前已见得分的最大值。当处理第 j+1 个 K 块后，新的最大值可能更新为 $m_i^{(j+1)} > m_i^{(j)}$。写出 $\tilde{o}_i^{(j+1)}$ 的更新公式（需要对旧的 $\tilde{o}_i^{(j)}$ 做什么修正?）。

ii. 经典分治（如 Merge Sort）的子问题**独立**求解后合并，合并时不修改子问题的内部结果。FlashAttention 的在线 softmax 与此有何本质区别？这种区别对 GPU 并行性有什么影响?