矩阵范数

优化算法讲义 · 研究生课程

目录

1 预备：向量范数 **2**

2 矩阵范数的公理 **2**

3 Frobenius 范数 **2**

4 奇异值分解与最优低秩逼近 **3**

4.1 奇异值分解 3

4.2 最优低秩逼近：Eckart-Young 定理 4

5 算子范数（谱范数） **4**

6 RMS→RMS 范数与步长安全性 **5**

7 低秩矩阵与 LoRA **5**

8 GaLore：梯度低秩投影 **6**

8.1 动机：LoRA 的局限 6

8.2 算法 6

8.3 从范数视角理解 GaLore 7

8.4 GaLore 与 LoRA 的对比 8

8.5 内存复杂度 8

1 预备：向量范数

给定向量 $x \in \mathbb{R}^d$，常用范数有三种：

名称	定义
ℓ_2 范数	$\|x\|_2 = \sqrt{\sum_i x_i^2}$
ℓ_1 范数	$\|x\|_1 = \sum_i \|x_i\|$
RMS 范数	$\|x\|_{\mathrm{RMS}} = \dfrac{\|x\|_2}{\sqrt{d}}$

三者关系的关键不等式：

$$\|x\|_{\mathrm{RMS}} \;\le\; \|x\|_2 \;\le\; \sqrt{d}\,\|x\|_{\mathrm{RMS}}$$

注意. RMS 范数对维度做了归一化，使得" 元素量级为 $O(1)$" 的向量其 RMS 范数也为 $O(1)$，而 ℓ_2 范数则为 $O(\sqrt{d})$。这一特性使 RMS 范数成为衡量深度学习中激活值与权重" 信号强度" 的自然尺度。

2 矩阵范数的公理

矩阵范数 $\|\cdot\| : \mathbb{R}^{m\times n} \to \mathbb{R}_{\ge 0}$ 需满足四条公理：

定义（矩阵范数公理）. 对任意 $A, B \in \mathbb{R}^{m\times n}$，$\alpha \in \mathbb{R}$：

(i) $\|A\| = 0 \iff A = 0$

(ii) $\|\alpha A\| = |\alpha|\,\|A\|$

(iii) $\|A + B\| \le \|A\| + \|B\|$

(iv) $\|AB\| \le \|A\|\,\|B\|$ （次乘性）

条件 (iv) 称为*次乘性*（submultiplicativity），是矩阵范数区别于一般向量范数的核心要求，保证了矩阵复合运算的稳定性。

3 Frobenius 范数

定义.

$$\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2} = \sqrt{\mathrm{tr}(A^\top A)}$$

Frobenius 范数本质上是将矩阵视为 mn 维向量后的 ℓ_2 范数。其与奇异值的关系由以下命题给出。

命题. 设 A 的奇异值为 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$，则

$$\|A\|_F = \sqrt{\sum_{i=1}^{r} \sigma_i^2}$$

直觉：$\|A\|_F$ 捕捉了矩阵的”总能量”，对所有奇异值一视同仁。

4 奇异值分解与最优低秩逼近

4.1 奇异值分解

定理（奇异值分解，SVD）. 设 $A \in \mathbb{R}^{m\times n}$，$\operatorname{rank}(A) = r$，则存在分解

$$A = U\Sigma V^\top$$

其中 $U \in \mathbb{R}^{m\times r}$ 列正交（$U^\top U = I_r$），$V \in \mathbb{R}^{n\times r}$ 列正交（$V^\top V = I_r$），$\Sigma = \operatorname{diag}(\sigma_1, \ldots, \sigma_r)$ 且 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$。

外积和展开. 将三个矩阵按列（行）写出：

$$U = \begin{bmatrix} u_1 & u_2 & \cdots & u_r \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}, \quad V^\top = \begin{bmatrix} v_1^\top \\ v_2^\top \\ \vdots \\ v_r^\top \end{bmatrix}$$

先计算 $\Sigma V^\top$：其第 i 行等于 $\sigma_i v_i^\top$。再左乘 U，按列分配得到

$$A \;=\; U\Sigma V^\top \;=\; \sum_{i=1}^{r} u_i \cdot \sigma_i v_i^\top \;=\; \sum_{i=1}^{r} \sigma_i\, u_i v_i^\top$$

其中 $u_i \in \mathbb{R}^m$ 为列向量，$v_i^\top \in \mathbb{R}^{1\times n}$ 为行向量，外积 $u_i v_i^\top \in \mathbb{R}^{m\times n}$ 的所有列均为 u_i 的倍数，因此秩恰好为 1。

几何直觉. 每一项 $\sigma_i u_i v_i^\top$ 描述一种独立的”模式”：将输入 x 投影到 v_i 方向（取内积 $v_i^\top x$），缩放 σ_i 倍，再沿输出方向 u_i 展开。矩阵 A 是 r 种模式的叠加，σ_i 越大，该模式在映射中贡献越重。截断 SVD 保留前 k 项，等价于只保留能量最大的 k 种模式，丢弃能量最小的尾部——这正是 Eckart-Young 定理的几何本质。

两种范数由此统一表达：

$$\|A\|_{\mathrm{op}} = \sigma_1, \qquad \|A\|_F = \sqrt{\sigma_1^2 + \cdots + \sigma_r^2}$$

4.2 最优低秩逼近：Eckart-Young 定理

给定秩预算 $k < r$，自然的问题是：用一个秩不超过 k 的矩阵逼近 A，最小误差是多少？

定理（Eckart-Young，1936）. 设 $A = U\Sigma V^\top$ 为 SVD，定义截断矩阵

$$A_k = \sum_{i=1}^{k} \sigma_i \, u_i v_i^\top = U_k \Sigma_k V_k^\top$$

其中 U_k, V_k 取前 k 列，$\Sigma_k = \mathrm{diag}(\sigma_1, \ldots, \sigma_k)$。则对 Frobenius 范数和谱范数，$A_k$ 均为最优秩-k 逼近：

$$A_k = \operatorname*{arg\,min}_{\mathrm{rank}(B) \le k} \|A - B\|_F = \operatorname*{arg\,min}_{\mathrm{rank}(B) \le k} \|A - B\|_{\mathrm{op}}$$

最优误差分别为

$$\|A - A_k\|_F = \sqrt{\sigma_{k+1}^2 + \cdots + \sigma_r^2}, \qquad \|A - A_k\|_{\mathrm{op}} = \sigma_{k+1}$$

直觉. Eckart-Young 定理告诉我们：在 Frobenius 和谱范数两种意义下，”丢掉小奇异值”恰好是最优策略，而非启发式选择。截断误差由第 $k+1$ 个奇异值完全刻画——谱快速衰减时，少量主成分即可高精度捕捉矩阵的全部”信息量”。

与 GaLore 的联系. GaLore（见 §8）正是将 Eckart-Young 定理应用于梯度矩阵 G_t：对 G_t 做截断 SVD，取前 r 个左奇异向量 $P_t = U_r$，得到 Frobenius 意义下的最优秩-r 投影子空间，从而在压缩优化器状态的同时最小化梯度信息的损失。

5 算子范数（谱范数）

算子范数从诱导范数的视角出发：矩阵 A 作为线性映射，最多能把单位球放大多少倍？

定义（诱导范数）. 给定向量范数 $\|\cdot\|_\alpha$（输入空间）和 $\|\cdot\|_\beta$（输出空间），诱导范数定义为

$$\|A\|_{\alpha\to\beta} = \sup_{x \ne 0} \frac{\|Ax\|_\beta}{\|x\|_\alpha} = \sup_{\|x\|_\alpha = 1} \|Ax\|_\beta$$

当输入输出均取 ℓ_2 范数时，即为谱范数（算子范数）：

$$\|A\|_{\mathrm{op}} = \|A\|_{\ell_2 \to \ell_2} = \sigma_{\max}(A)$$

命题（Frobenius 与谱范数的夹逼）.

$$\|A\|_{\mathrm{op}} \le \|A\|_F \le \sqrt{r}\,\|A\|_{\mathrm{op}}$$

其中 $r = \mathrm{rank}(A)$。右侧等号在 A 奇异值全相等时取到。

6 RMS→RMS 范数与步长安全性

将诱导范数的输入输出均换为 RMS 范数，得到深度学习中最自然的权重矩阵度量。

定义. 对 $A \in \mathbb{R}^{d_{\mathrm{out}} \times d_{\mathrm{in}}}$，

$$\|A\|_{\mathrm{RMS}\to\mathrm{RMS}} = \sup_{\|x\|_{\mathrm{RMS}}=1} \|Ax\|_{\mathrm{RMS}}$$

利用 $\|x\|_{\mathrm{RMS}} = 1 \iff \|x\|_2 = \sqrt{d_{\mathrm{in}}}$，代入化简：

$$\|A\|_{\mathrm{RMS}\to\mathrm{RMS}} = \sup_{\|x\|_2=\sqrt{d_{\mathrm{in}}}} \frac{\|Ax\|_2}{\sqrt{d_{\mathrm{out}}}} = \sqrt{\frac{d_{\mathrm{in}}}{d_{\mathrm{out}}}} \cdot \|A\|_{\mathrm{op}}$$

这一额外因子 $\sqrt{d_{\mathrm{in}}/d_{\mathrm{out}}}$ 直接决定了不同形状权重矩阵的安全学习率。

命题（安全步长）. 若以”梯度更新不超出 RMS 意义下的单位球”为标准，安全步长正比于

$$\eta_{\mathrm{safe}} \propto \frac{1}{\|G\|_{\mathrm{RMS}\to\mathrm{RMS}}} = \sqrt{\frac{d_{\mathrm{out}}}{d_{\mathrm{in}}}} \cdot \frac{1}{\|G\|_{\mathrm{op}}}$$

层形状	d_{in} vs d_{out}	$\sqrt{d_{\mathrm{in}}/d_{\mathrm{out}}}$	RMS→RMS 范数	安全步长
宽 → 窄	$d_{\mathrm{in}} \gg d_{\mathrm{out}}$	$\gg 1$	大	小
方阵	$d_{\mathrm{in}} = d_{\mathrm{out}}$	$= 1$	$= \|A\|_{\mathrm{op}}$	基准
窄 → 宽	$d_{\mathrm{in}} \ll d_{\mathrm{out}}$	$\ll 1$	小	大

直觉. RMS→RMS 范数度量的是”更新矩阵将输入信号放大多少倍”。宽 → 窄层有更强的输入聚合效应，同等大小的 ΔW 对输出扰动更大，因此必须用更小步长控制。这正是 μP（最大更新参数化）对不同层赋予不同学习率缩放的理论依据。

7 低秩矩阵与 LoRA

LoRA 将权重更新参数化为低秩分解：

$$\Delta W = BA, \quad B \in \mathbb{R}^{d_{\mathrm{out}} \times r},\ A \in \mathbb{R}^{r \times d_{\mathrm{in}}},\ r \ll \min(d_{\mathrm{in}}, d_{\mathrm{out}})$$

从范数的角度，低秩约束通过次乘性天然压制了更新幅度：

$$\|BA\|_{\mathrm{op}} \le \|B\|_{\mathrm{op}} \|A\|_{\mathrm{op}}$$

$$\|BA\|_{\mathrm{RMS}\to\mathrm{RMS}} = \sqrt{\frac{d_{\mathrm{in}}}{d_{\mathrm{out}}}} \|BA\|_{\mathrm{op}} \le \sqrt{\frac{d_{\mathrm{in}}}{d_{\mathrm{out}}}} \|B\|_{\mathrm{op}} \|A\|_{\mathrm{op}}$$

训练中冻结 W_0，仅优化 A, B，反向传播与普通矩阵链式法则完全一致：

$$\nabla_A \mathcal{L} = B^\top \delta \cdot x^\top, \qquad \nabla_B \mathcal{L} = \delta \cdot (Ax)^\top$$

其中 $\delta = \partial\mathcal{L}/\partial y$ 为输出端梯度，x 为输入。

推论（LoRA+ / μLoRA 的理论依据）. $A \in \mathbb{R}^{r\times d_{\mathrm{in}}}$ 为窄 $\to$ 宽映射，RMS→RMS 范数小，安全步长大；$B \in \mathbb{R}^{d_{\mathrm{out}}\times r}$ 为宽 $\to$ 窄映射，RMS→RMS 范数大，安全步长小。两者使用同一学习率（原版 LoRA）在维度失配时是次优的，最优比例约为

$$\frac{\eta_B}{\eta_A} \propto \sqrt{\frac{d_{\mathrm{in}}}{r}}$$

8 GaLore：梯度低秩投影

8.1 动机：LoRA 的局限

LoRA 在参数空间施加低秩约束：$\Delta W = BA$ 始终限于一个固定的秩-r 子空间。这带来两个问题：

1. 子空间在训练开始前就固定，无法跟随梯度信号的演化；
2. 权重更新本身是低秩的，全模型表达能力受限。

GaLore（Gradient Low-Rank Projection，Zhao et al. 2024）转换思路：不约束权重更新，而是在梯度空间施加低秩投影——权重保持全秩更新，节省内存的方式是压缩优化器的状态（Adam 的一阶、二阶矩）。

8.2 算法

设当前步梯度为 $G_t = \nabla_W \mathcal{L} \in \mathbb{R}^{d_{\mathrm{out}}\times d_{\mathrm{in}}}$。GaLore 的核心操作分三步。

步骤 1：寻找低秩子空间. 对 G_t 做截断奇异值分解：

$$G_t \approx U_t \Sigma_t V_t^\top, \quad U_t \in \mathbb{R}^{d_{\mathrm{out}}\times r},\ V_t \in \mathbb{R}^{d_{\mathrm{in}}\times r}$$

取左奇异向量 $P_t = U_t \in \mathbb{R}^{d_{\mathrm{out}}\times r}$ 作为投影矩阵。

Algorithm 1 GaLore（单层，简化版）

Require: 权重 W_0，秩 r，学习率 η，子空间更新周期 T_{sub}

for $t = 1, 2, \ldots$ **do**
  计算梯度 $G_t = \nabla_W \mathcal{L}$
  if $t \bmod T_{\text{sub}} = 0$ **then**
    $U_t, \Sigma_t, V_t \leftarrow \text{SVD}_r(G_t)$ （截断至秩 r）
    $P_t \leftarrow U_t$
  end if
  $\tilde{G}_t \leftarrow P_t^\top G_t$ （投影，$r \times d_{\text{in}}$）
  $\tilde{M}_t \leftarrow \text{Adam}(\tilde{G}_t)$ （低秩空间中更新）
  $W_{t+1} \leftarrow W_t - \eta \cdot P_t \tilde{M}_t$ （反投影）
end for

步骤 2：在低秩空间中运行优化器. 将梯度投影到低秩子空间：

$$\tilde{G}_t = P_t^\top G_t \in \mathbb{R}^{r \times d_{\text{in}}}$$

对 $\tilde{G}_t$ 运行 Adam（或任意自适应优化器），得到低秩更新量 $\tilde{M}_t \in \mathbb{R}^{r \times d_{\text{in}}}$。Adam 的一阶矩 m 和二阶矩 v 均在低秩空间中维护，维度为 $r \times d_{\text{in}}$ 而非 $d_{\text{out}} \times d_{\text{in}}$。

步骤 3：反投影，更新权重.

$$W_{t+1} = W_t - \eta \cdot P_t \tilde{M}_t$$

完整流程见算法 1。

8.3 从范数视角理解 GaLore

梯度的低秩结构. GaLore 的有效性依赖于一个经验观测：训练过程中，梯度矩阵 G_t 的奇异值谱迅速衰减，即梯度的”有效秩”远低于 $\min(d_{\text{out}}, d_{\text{in}})$。用 Frobenius 范数量化这一现象：设截断误差为

$$\varepsilon_r = \|G_t - P_t P_t^\top G_t\|_F = \sqrt{\sum_{i>r} \sigma_i(G_t)^2}$$

若谱快速衰减，ε_r 在较小的 r 下即可忽略不计。

投影不改变主方向的范数. 对于在低秩子空间 $\text{col}(P_t)$ 内的向量 v，有

$$\|P_t P_t^\top v\|_2 = \|v\|_2$$

即投影是等距的。因此，梯度在主方向上的信号完整保留，被丢弃的仅是”噪声子空间”中的分量。

命题（GaLore 的范数界）. 设 P_t 为 G_t 的前 r 个左奇异向量，则

$$\|P_t\tilde{G}_t\|_F = \|P_tP_t^\top G_t\|_F \le \|G_t\|_F$$

等号当 $\mathrm{rank}(G_t) \le r$ 时成立。反投影步长满足：

$$\|P_t\tilde{M}_t\|_{\mathrm{RMS}\to\mathrm{RMS}} = \sqrt{\frac{d_{\mathrm{in}}}{d_{\mathrm{out}}}} \cdot \|P_t\tilde{M}_t\|_{\mathrm{op}} \le \sqrt{\frac{d_{\mathrm{in}}}{d_{\mathrm{out}}}} \cdot \|\tilde{M}_t\|_{\mathrm{op}}$$

其中最后一步利用了 $\|P_t\|_{\mathrm{op}} = 1$（$P_t$ 为列正交矩阵）。

8.4 GaLore 与 LoRA 的对比

	LoRA	GaLore
低秩约束对象	权重更新 ΔW	优化器状态 m_t, v_t
权重更新秩	$\le r$（始终低秩）	全秩
子空间是否固定	是（训练全程）	否（每 T_{sub} 步更新）
新增参数	A, B（可学习）	无（投影矩阵不可学习）
内存节省来源	梯度和优化器状态	仅优化器状态
适用场景	微调（fine-tuning）	预训练或微调均可

核心区别. LoRA 的低秩约束是结构性的——它改变了模型能表达的函数类；GaLore 的低秩约束是计算性的——它只影响优化路径，不改变模型的表达能力。从范数角度看，LoRA 的 ΔW 秩最高为 r，而 GaLore 的 $\Delta W = \eta P_t\tilde{M}_t$ 在不同步之间累积后可以是全秩的。

8.5 内存复杂度

设 $W \in \mathbb{R}^{d_{\mathrm{out}}\times d_{\mathrm{in}}}$，Adam 需维护一阶矩 m 和二阶矩 v，各占 $d_{\mathrm{out}} \times d_{\mathrm{in}}$ 个浮点数。

方法	优化器状态内存	节省比例
全量 Adam	$2 \cdot d_{\mathrm{out}}d_{\mathrm{in}}$	—
GaLore	$2r \cdot d_{\mathrm{in}} + r \cdot d_{\mathrm{out}}$	$\approx 1 - r/d_{\mathrm{out}}$
LoRA	$2r(d_{\mathrm{out}} + d_{\mathrm{in}})$	$\approx 1 - r/d_{\mathrm{out}} - r/d_{\mathrm{in}}$

GaLore 额外需要存储投影矩阵 $P_t \in \mathbb{R}^{d_{\mathrm{out}}\times r}$（$O(d_{\mathrm{out}}r)$），以及每隔 T_{sub} 步进行一次 SVD（复杂度 $O(d_{\mathrm{out}}^2 r)$ 或用随机 SVD 降低）。实践中 $T_{\mathrm{sub}} = 200 \sim 1000$ 步，SVD 开销可以摊薄。