优化算法：从理论到大规模实践

第 8 周讲义：优化器尺度规律与随机化算法

目录

第一部分　优化器的尺度规律：RMS 对齐与 MuP 6

1　开场：两个”数字奇迹” 6

2　AdamW 的状态变量 6

2.1　更新规则 6

2.2　每个变量的含义：$\boldsymbol{g}, \boldsymbol{m}, \boldsymbol{v}, \boldsymbol{u}$ 7

3　数值模拟先行：建立对 0.2 的信心 7

4　Update RMS 的平均场推导 8

4.1　核心技巧：平均场分离期望 8

4.2　分母的计算 9

4.3　分子的计算 9

4.4　主结果：Update RMS 渐近公式 9

5　Weight RMS 的推导 10

5.1　关键视角转换：Weight Decay 是 Update 的 EMA 10

5.2　快速估计：利用高维正交性 10

5.3　更精细：二次平均场 10

5.4　一般结果与极限情形 11

6　应用：Muon 与 AdamW 的超参迁移 11

6.1　Muon 的结构分析 11

6.2　逐步拆解 msign 的 RMS 11

6.3　迁移定理 12

6.4　进阶视角：Total Update Contribution 12

6.5　速查表 12

7 MuP：超参数跨模型尺度的迁移规律 **12**
7.1 Motivation 与方法大意 12
7.2 前向传播：初始化尺度规律 13
7.3 反向传播的冲突 13
7.4 损失增量与尺度爆炸 13
7.5 标准模型簇 14
7.6 SGD 下的学习率规律 14
7.7 特征变化：补全缺失的条件 14
7.8 Adam 与 Muon 版本 14
7.9 MuP 结论汇总 15

8 MuP 之上：谱条件 **15**
8.1 准备：谱范数不等式 16
8.2 期望性质：两个条件足矣 16
8.3 两个谱条件 16
8.4 实现方式：SN / SVC / msign 16
8.5 近似估计：从 SVD 到显式公式 17
8.6 学习率规律 17
8.7 谱条件 vs MuP：统一的美 17

9 Part 1 小结 **18**

第二部分 随机化算法 **19**

10 开场（0:00–0:05） **19**

11 随机化的哲学（0:05–0:10） **19**

12 Johnson-Lindenstrauss 引理：随机投影的魔力 **19**
12.1 问题的提出（0:10–0:15） 19
12.1.1 一个具体的场景 19
12.1.2 直觉与反直觉 20
12.1.3 定理的精确陈述 20
12.1.4 为什么这很惊人？ 20
12.2 证明思路（0:15–0:20） 21
12.2.1 核心思想 21
12.2.2 Step 1：构造随机投影矩阵 21
12.2.3 Step 2：单向量的长度几乎被保持 22
12.2.4 证明关键引理（选讲） 22
12.2.5 Step 3：Union Bound 23
12.3 应用场景（0:20–0:25） 23

12.3.1 应用 1：近似最近邻搜索 23
12.3.2 应用 2：快速核方法 24
12.3.3 应用 3：流式算法和草图 25
12.3.4 JL 引理 vs PCA：关键区别 25

13 随机最小二乘：Sketch-and-Solve 方法（0:50–1:05） 26
13.1 问题背景 26
13.1.1 最小二乘问题回顾 26
13.1.2 精确求解的代价 26
13.1.3 核心问题 26
13.2 Sketch-and-Solve 算法 27
13.2.1 算法思想 27
13.2.2 算法描述 27
13.2.3 几何直观 27
13.3 子空间嵌入：理论保证 28
13.3.1 什么是子空间嵌入？ 28
13.3.2 为什么子空间嵌入有用？ 28
13.3.3 定理的证明 28
13.4 如何构造 Sketch 矩阵？ 29
13.4.1 从 JL 引理到子空间嵌入 29
13.4.2 证明思路：覆盖网 29
13.4.3 各种 Sketch 矩阵 30
13.5 复杂度分析 34
13.5.1 总体复杂度 34
13.5.2 何时 Sketch 方法更优？ 34
13.6 实际应用与扩展 35
13.6.1 应用场景 35
13.6.2 迭代精化 35
13.6.3 与其他方法的比较 35

14 理论对比：经典统计推断 vs. 随机数值线性代数 (RandNLA) 36
14.1 1. 经典统计学习理论 (Classical Statistical Learning) 37
14.2 2. 随机投影/Sketching 理论 (RandNLA) 37
14.3 3. 深入：高维概率论的“反直觉”特点 37
14.3.1 A. 测度集中现象 (Concentration of Measure) 37
14.3.2 B. 准正交性 (Quasi-Orthogonality) 38
14.3.3 C. 维度诅咒 vs. 维度祝福 38
14.4 4. 总结对比表 38

15 随机矩阵乘法：用采样加速计算 **38**
15.1 问题的提出（0:25–0:30） . . . 38
15.1.1 矩阵乘法的计算瓶颈 . . . 38
15.1.2 矩阵乘法的外积视角 . . . 39
15.2 随机采样算法（0:30–0:35） . . . 39
15.2.1 算法描述 . . . 39
15.2.2 为什么需要缩放因子 $\frac{1}{\sqrt{kp_i}}$? . . . 40
15.2.3 无偏性的严格验证 . . . 40
15.2.4 计算复杂度 . . . 41
15.3 误差分析（0:35–0:40） . . . 41
15.3.1 误差的度量 . . . 41
15.3.2 误差界定理 . . . 41
15.3.3 误差界的证明思路 . . . 42
15.3.4 误差界的完整证明 . . . 42
15.4 采样策略对比（0:40–0:45） . . . 45
15.4.1 三种采样策略 . . . 45
15.4.2 方差界对比 . . . 45
15.4.3 直观解释 . . . 46
15.4.4 预处理的代价 . . . 46
15.5 实际应用与扩展 . . . 47
15.5.1 何时使用随机矩阵乘法? . . . 47
15.5.2 与其他技术的结合 . . . 47
15.5.3 从矩阵乘法到更复杂的线性代数 . . . 47

16 随机 SVD (Randomized SVD) **47**
16.1 背景补充 . . . 47
16.2 1. 相似对角化 (Eigen-decomposition) . . . 48
16.3 2. SVD 分解 . . . 48
16.4 3. QR 分解 . . . 49
16.5 1. 核心问题与算法流程 . . . 50
16.6 计算过程详解：维度流与运算次序 . . . 51
16.7 2. 原理分析：为什么随机采样有效? . . . 52
16.8 3. 进阶改进：Power Iteration (幂迭代) . . . 56

17 Marchenko-Pastur 分布 **57**
17.1 引入（1:25–1:30） . . . 57
17.2 MP 分布陈述（1:30–1:35） . . . 58

18 从矩阵乘法到卡特兰数 (矩法) **58**
18.1 1. 核心工具：迹 (Trace) . . . 58
18.2 2. 可计算的过程：下标游戏 . . . 58

18.3 3. 算法复杂度视角的推广 ($k \to \infty$) 60
18.4 4. 最终映射：卡特兰数 60

19 闭环验证：从 MP 分布算回卡特兰数 60
19.1 1. 积分换元 (Trigonometric Substitution) 61
19.2 2. 代入积分 61
19.3 3. 利用 Beta 函数 (Wallis 积分公式) 61
19.4 4. 组合数运算 61
19.5 5. 化简为卡特兰数 62
19.6 总结 62
19.7 总结 62

20 1. 入门场景：格路游走 (Dyck Paths) 62

21 2. 核心推导：镜像反射原理 (Reflection Principle) 63

22 3. 常见应用：完全不同的问题，完全一样的答案 64
22.1 A. 括号匹配与进出栈 64
22.2 B. 凸多边形三角剖分 64

23 4. 总结 (Cheat Sheet) 64
23.1 信号检测（1:35–1:45） 64

24 综合案例：大规模图像检索系统 65
24.1 问题背景 65
24.2 解决方案：三步随机化流水线 66
24.2.1 Step 1：JL 随机投影降维 66
24.2.2 Step 2：用随机 SVD 构建索引 67
24.2.3 Step 3：查询时的随机化 68
24.3 质量监控：用 MP 分布检测特征退化 69
24.4 完整系统性能对比 71

25 第 7 周小结（1:45–1:50） 71

26 第 7 周实验 71
26.1 实验 7a：随机矩阵乘法 71
26.2 实验 7b：随机 SVD 72
26.3 实验 7c：MP 分布验证 73

第一部分　优化器的尺度规律：RMS 对齐与 MuP

1　开场：两个”数字奇迹”

训练大 LLM 时人们反复观察到两个非常稳定、几乎与数据无关的现象：

1. **Update RMS** ≈ 0.2：Warmup 结束后 AdamW 的 update 向量 $\boldsymbol{u}_t = \boldsymbol{m}_t/\sqrt{\boldsymbol{v}_t}$ 的 RMS 稳定在 0.2–0.3，无论模型多大、数据是什么。
2. **Weight RMS** $\approx \sqrt{\eta/(2\lambda)}$：训出来的模型权重 RMS 只由学习率 η 和 weight decay λ 决定。

这两个现象背后藏着一整套跨优化器、跨模型尺度的超参数迁移规律——正是本 Part 的主角。

为什么重要？完整训练一次大型 LLM 的成本是昂贵的，我们不可能在大模型上反复试超参数。如果能在小模型上仔细搜索超参、然后按照某个缩放规律迁移到大模型，就能节省大量算力。这就是 Kimi K2 的”Match Adam Update RMS” 技巧（对齐不同优化器）、以及 MuP（对齐不同尺度）做的事情。

本 Part 的逻辑链：

Update RMS 的平均场推导 → Weight RMS → Muon 超参迁移
→ MuP 四条件推导 → 谱条件：MuP 的高阶版

关键洞察

贯穿全 Part 的元思想：**高维 + 平均场 = 可预测的渐近规律**。

- 优化器的稳态 RMS 可以用几何级数求和 + 方差可加性算出来；
- 跨模型尺度的学习率规律可以用谱范数不等式代数地推出来；
- 不依赖分布假设，只依赖矩阵结构的尺度。

这套思想和 Part 2 的 JL 引理、MP 分布完全同源——高维随机是朋友，不是敌人。

2　AdamW 的状态变量

2.1　更新规则

AdamW 在每一步迭代中维护并更新以下状态：

$$\boldsymbol{m}_t = \beta_1 \boldsymbol{m}_{t-1} + (1-\beta_1)\boldsymbol{g}_t \tag{1}$$

$$\boldsymbol{v}_t = \beta_2 \boldsymbol{v}_{t-1} + (1-\beta_2)\boldsymbol{g}_t^2 \tag{2}$$

$$\boldsymbol{u}_t = \boldsymbol{m}_t/\sqrt{\boldsymbol{v}_t} \tag{3}$$

$$\boldsymbol{\theta}_t = \boldsymbol{\theta}_{t-1} - \eta\big(\boldsymbol{u}_t + \lambda\boldsymbol{\theta}_{t-1}\big) \tag{4}$$

所有乘除、平方、开方均为逐元素（Hadamard）运算。$t \to \infty$ 时 bias correction 可以忽略（$\beta_1^t, \beta_2^t \to 0$）。

2.2 每个变量的含义：$\boldsymbol{g}, \boldsymbol{m}, \boldsymbol{v}, \boldsymbol{u}$

$\boldsymbol{m}_t$ **（一阶矩 EMA，动量）**：梯度 $\boldsymbol{g}_t$ 的指数滑动平均

$$\boldsymbol{m}_t = (1-\beta_1)\sum_{i=1}^{t} \beta_1^{t-i}\boldsymbol{g}_i$$

估计 $\mathbb{E}[\boldsymbol{g}]$，$\beta_1 = 0.9$ 对应约 10 步的有效窗口。

$\boldsymbol{v}_t$ **（二阶矩 EMA）**：逐元素梯度平方的 EMA

$$\boldsymbol{v}_t = (1-\beta_2)\sum_{i=1}^{t} \beta_2^{t-i}\boldsymbol{g}_i^2$$

估计 $\mathbb{E}[\boldsymbol{g}^2] = \boldsymbol{\mu}^2 + \boldsymbol{\sigma}^2$。$\sqrt{\boldsymbol{v}_t}$ 可解释为”每个参数方向上梯度的典型尺度”。$\beta_2 = 0.95$ 对应更长的窗口（约 20 步），因为分母需要更平滑。

$\boldsymbol{u}_t = \boldsymbol{m}_t/\sqrt{\boldsymbol{v}_t}$ **（Adam 的灵魂）**：自适应的坐标归一化

- 分子 $\boldsymbol{m}_t$ 提供梯度的方向（信号分量）；
- 分母 $\sqrt{\boldsymbol{v}_t}$ 提供梯度的尺度（大小分量）；
- 两者相除 $\Longrightarrow$ 对每个参数独立做归一化；
- 净效果：**所有参数方向的 update 尺度被拉至同一量级**。

变量	维度	估计对象	稳态期望	作用
$\boldsymbol{g}_t$	$\mathbb{R}^d$	—	$\boldsymbol{\mu}$	当前梯度
$\boldsymbol{m}_t$	$\mathbb{R}^d$	$\mathbb{E}[\boldsymbol{g}]$	$\boldsymbol{\mu}$	方向（信号）
$\boldsymbol{v}_t$	$\mathbb{R}^d$	$\mathbb{E}[\boldsymbol{g}^2]$	$\boldsymbol{\mu}^2 + \boldsymbol{\sigma}^2$	尺度（归一化）
$\boldsymbol{u}_t$	$\mathbb{R}^d$	$\boldsymbol{m}_t/\sqrt{\boldsymbol{v}_t}$	$\lVert\cdot\rVert_{\mathrm{RMS}} \approx 0.23$	实际更新

注意

AdamW 中所有涉及 $\boldsymbol{g}, \boldsymbol{m}, \boldsymbol{v}$ 的运算都是**逐元素的**，不是向量内积或矩阵模长。这也是为什么整个理论推导用 $\lVert\cdot\rVert_{\mathrm{RMS}}$ 而非 $\lVert\cdot\rVert_2$ 作为度量——RMS 与逐元素运算自然匹配。

3 数值模拟先行：建立对 0.2 的信心

教学哲学：**先让学生相信现象，再推公式**。下面用 20 行 Python 直接模拟 AdamW 在纯噪声梯度下的行为：

```python
import numpy as np

N, T = 10000, 2000
beta1, beta2 = 0.9, 0.95
m, v = 0, 0
for t in range(1, T + 1):
    g = np.random.randn(N)          # 纯噪声梯度!
    m = beta1 * m + (1 - beta1) * g
    v = beta2 * v + (1 - beta2) * g**2
    u = m / v**0.5

rms = (u**2).mean()**0.5
print(rms)                          #   0.2294
```

关键洞察

梯度用的是**纯噪声** $\mathcal{N}(0, I)$，居然得到和真实 LLM 训练几乎一样的 0.23！这反过来表明：实际训练中单步梯度的信噪比很低，**噪声近似就足以捕捉 update RMS 的主导行为**。

让学生自己改动代码后，可以观察到：

- Update RMS 对 β_1 敏感；
- 对 β_2 几乎不敏感；
- 非零梯度均值（增大梯度信噪比）会让 RMS 变大。

现在有了可验证的目标，我们可以上公式。

4 Update RMS 的平均场推导

4.1 核心技巧：平均场分离期望

$t \to \infty, \epsilon \to 0$ 的稳态下 $\boldsymbol{u}_t = \boldsymbol{m}_t/\sqrt{\boldsymbol{v}_t}$。我们要算 $\mathbb{E}[\boldsymbol{u}_t^2]$，做如下**平均场近似**：

$$\mathbb{E}\left[\frac{\boldsymbol{m}_t^2}{\boldsymbol{v}_t}\right] \approx \frac{\mathbb{E}[\boldsymbol{m}_t^2]}{\mathbb{E}[\boldsymbol{v}_t]}. \tag{5}$$

注 4.1. 这一步严格意义上是错的——$\mathbb{E}[X/Y] \neq \mathbb{E}[X]/\mathbb{E}[Y]$。但这是平均场近似的灵魂：**先算，合理就好**，事后与模拟对比验证。前一节的数值模拟已经证实这个近似在 $\beta_2 \geq 0.9$ 时极为准确。

设 $\mathbb{E}[\boldsymbol{g}] = \boldsymbol{\mu}$，$\mathrm{Var}[\boldsymbol{g}] = \boldsymbol{\sigma}^2$，故 $\mathbb{E}[\boldsymbol{g}^2] = \boldsymbol{\mu}^2 + \boldsymbol{\sigma}^2$。

4.2 分母的计算

$$
\begin{aligned}
\mathbb{E}[\boldsymbol{v}_t] &= (1-\beta_2)\sum_{i=1}^{t}\beta_2^{t-i}\,\mathbb{E}[\boldsymbol{g}_i^2] \\
&= (1-\beta_2)(\boldsymbol{\mu}^2+\boldsymbol{\sigma}^2)\sum_{i=1}^{t}\beta_2^{t-i} \\
&= (1-\beta_2^t)(\boldsymbol{\mu}^2+\boldsymbol{\sigma}^2) \\
&\xrightarrow{t\to\infty} \boldsymbol{\mu}^2+\boldsymbol{\sigma}^2.
\end{aligned} \tag{6}
$$

4.3 分子的计算

利用 $\mathbb{E}[\boldsymbol{m}_t^2] = \mathbb{E}[\boldsymbol{m}_t]^2 + \mathrm{Var}[\boldsymbol{m}_t]$：

均值部分（同样 EMA 几何级数）：$\mathbb{E}[\boldsymbol{m}_t] \to \boldsymbol{\mu}$。

方差部分（独立随机变量方差的平方可加性）：

$$
\begin{aligned}
\mathrm{Var}[\boldsymbol{m}_t] &= (1-\beta_1)^2\sum_{i=1}^{t}\beta_1^{2(t-i)}\,\boldsymbol{\sigma}^2 \\
&= (1-\beta_1)^2\cdot\frac{1-\beta_1^{2t}}{1-\beta_1^2}\,\boldsymbol{\sigma}^2 \\
&\xrightarrow{t\to\infty} \frac{(1-\beta_1)^2}{1-\beta_1^2}\,\boldsymbol{\sigma}^2 = \frac{1-\beta_1}{1+\beta_1}\,\boldsymbol{\sigma}^2.
\end{aligned} \tag{7}
$$

合并：

$$
\mathbb{E}[\boldsymbol{m}_t^2] \approx \boldsymbol{\mu}^2 + \frac{1-\beta_1}{1+\beta_1}\,\boldsymbol{\sigma}^2. \tag{8}
$$

4.4 主结果：Update RMS 渐近公式

代入 (5)、(6)、(7)：

$$
\boxed{\|\boldsymbol{u}_t\|_{\mathrm{RMS}} \approx \sqrt{\frac{\|\boldsymbol{\mu}\|^2/\|\boldsymbol{\sigma}\|^2 + \frac{1-\beta_1}{1+\beta_1}}{\|\boldsymbol{\mu}\|^2/\|\boldsymbol{\sigma}\|^2 + 1}}.} \tag{9}
$$

定理 4.2 (零均值特例——核心公式)**.** 假设梯度 $\boldsymbol{g}_t$ 零均值，即 $\boldsymbol{\mu}=0$。则 $t\to\infty$ 稳态下：

$$
\|\boldsymbol{u}_t\|_{\mathrm{RMS}} \approx \sqrt{\frac{1-\beta_1}{1+\beta_1}}. \tag{10}
$$

特别地，代入 $\beta_1 = 0.9$：$\|\boldsymbol{u}_t\|_{\mathrm{RMS}} \approx \sqrt{0.1/1.9} \approx 0.2294$。

关键洞察

公式的三个惊人性质：

1. **不含** β_2——与模拟观察一致；
2. **不含** t（稳态）；

3. **不含数据**——仅由超参 β_1 决定。

5 Weight RMS 的推导

5.1 关键视角转换：Weight Decay 是 Update 的 EMA

令 $\beta_3 \triangleq 1-\eta\lambda$，AdamW 的权重更新可改写为：

$$\boldsymbol{\theta}_t = \beta_3\boldsymbol{\theta}_{t-1} + (1-\beta_3)\Big(-\frac{\boldsymbol{u}_t}{\lambda}\Big). \tag{11}$$

关键洞察

Weight decay 本质上**不是在"惩罚"权重**，而是**对更新量 $-\boldsymbol{u}_t/\lambda$ 做 EMA**。β_3 扮演了类似 β_1, β_2 的 EMA 衰减因子角色。这个视角转换是 scaling law 系列工作（Wang 等 2024、Bergsma 等 2024）的理论支点。

5.2 快速估计：利用高维正交性

对 (11) 两边取 $\|\cdot\|^2_{\mathrm{RMS}}$，高维空间中随机向量近似正交，故 $\boldsymbol{\theta}_{t-1}\cdot\boldsymbol{u}_t \approx 0$。稳态下 $\|\boldsymbol{\theta}_t\|_{\mathrm{RMS}} = \|\boldsymbol{\theta}_{t-1}\|_{\mathrm{RMS}}$：

$$(1-\beta_3^2)\|\boldsymbol{\theta}_t\|^2_{\mathrm{RMS}} \approx (1-\beta_3)^2\|\boldsymbol{u}_t\|^2_{\mathrm{RMS}}/\lambda^2. \tag{12}$$

利用 $\beta_3 \approx 1$ 时 $1-\beta_3^2 \approx 2(1-\beta_3)$：

$$\|\boldsymbol{\theta}_t\|_{\mathrm{RMS}} \approx \sqrt{\frac{1-\beta_1}{1+\beta_1}}\cdot\sqrt{\frac{\eta}{2\lambda}}. \tag{13}$$

5.3 更精细：二次平均场

快速估计的误差来自 $\boldsymbol{\theta}_{t-1}\cdot\boldsymbol{u}_t \approx 0$ 并不严格成立。更精细地，对 $\boldsymbol{u}_t$ 再做一层 EMA 平均，展开到单步梯度 $\boldsymbol{g}_i$ 层级。经过化简，在 $\boldsymbol{\mu}=0$、$t\to\infty$ 下得到：

定理 5.1 (Weight RMS 的精细渐近——第二核心公式)**.**

$$\boxed{\|\boldsymbol{\theta}_t\|_{\mathrm{RMS}} \approx \sqrt{\frac{\eta}{2\lambda}}.} \tag{14}$$

关键洞察

公式 (14) **连 β_1 都消掉了**！为什么？因为 weight decay 的长时间 EMA 又把动量效应平均了一次——**两次平均抵消了所有 β_1 相关的一阶项**。稳态下，weight RMS 只依赖 η 和 λ 这对最基本的超参。

5.4 一般结果与极限情形

完整的一般公式（允许非零均值、有限 t、非零初始权重）：

$$\|\boldsymbol{\theta}_t\|_{\mathrm{RMS}}^2 \approx \beta_3^{2t}\|\boldsymbol{\theta}_0\|_{\mathrm{RMS}}^2 + (1-\beta_3^t)^2 \cdot \frac{\|\boldsymbol{\mu}\|^2/\|\boldsymbol{\sigma}\|^2 + \frac{(1-\beta_3)(1+\beta_3^t)}{2(1-\beta_3^t)}}{\lambda^2(\|\boldsymbol{\mu}\|^2/\|\boldsymbol{\sigma}\|^2+1)}. \tag{15}$$

两个有意思的极限：

例 5.2 (无 weight decay)**.** $\lambda \to 0$：$\|\boldsymbol{\theta}_t\|_{\mathrm{RMS}}^2 \approx \|\boldsymbol{\theta}_0\|_{\mathrm{RMS}}^2 + \eta^2 t$，按 $\eta\sqrt{t}$ 增长。这意味着没有 weight decay 时，可以通过 learning rate schedule 控制 weight RMS 的稳定性。

例 5.3 (SignSGDM 版本)**.** $\Delta\boldsymbol{W} = -\eta\,\mathrm{sign}(\boldsymbol{m}_t) = -\eta\,\boldsymbol{m}_t/\sqrt{\boldsymbol{m}_t^2}$。类似推导给出：

$$\|\boldsymbol{\theta}_t\|_{\mathrm{RMS}} \approx \sqrt{\frac{\eta}{2\lambda}\cdot\frac{1+\beta_1}{1-\beta_1}}.$$

即 SignSGDM 的 weight RMS 是 AdamW 的 $\sqrt{(1+\beta_1)/(1-\beta_1)}$ 倍。

6 应用：Muon 与 AdamW 的超参迁移

上面解决了" 同一个优化器内部的尺度规律"。现在把结论用到**不同优化器之间的迁移**——这正是 Kimi K2 训练中使用的"Match Adam Update RMS" 技巧。

6.1 Muon 的结构分析

Kimi 版 Muon 的更新规则（$\boldsymbol{W} \in \mathbb{R}^{m\times n}$）：

$$\boldsymbol{M}_t = \mu\boldsymbol{M}_{t-1} + \boldsymbol{G}_t \tag{16}$$

$$\boldsymbol{O}_t = \mathrm{msign}(\boldsymbol{M}_t)\cdot\sqrt{\max(n,m)}\cdot 0.2 \tag{17}$$

$$\boldsymbol{W}_t = \boldsymbol{W}_{t-1} - \eta_t(\boldsymbol{O}_t + \lambda\boldsymbol{W}_{t-1}) \tag{18}$$

其中 $\mathrm{msign}(\cdot)$ 通过 Newton-Schulz 迭代近似矩阵符号函数，把所有奇异值归一到 1。

6.2 逐步拆解 msign 的 RMS

让学生自己完成：

- $\mathrm{msign}(\boldsymbol{M})$ 的所有奇异值 $= 1$；
- 因此 $\|\mathrm{msign}(\boldsymbol{M})\|_F = \sqrt{\min(m,n)}$；
- Per-element RMS $= \sqrt{\min(m,n)/(mn)} = 1/\sqrt{\max(m,n)}$。

所以 Kimi Muon 的设计逻辑是：

1. 乘 $\sqrt{\max(m,n)} \Longrightarrow$ 把 RMS 归一到 1；
2. 再乘 0.2 $\Longrightarrow$ 对齐到 AdamW 的 Update RMS。

6.3 迁移定理

定理 6.1 (超参数迁移)**.** 由于 *Weight RMS* 公式 (14) **只依赖 *Update RMS* 与** η, λ，而不依赖优化器的具体动量结构：

$$\text{对齐 } \textit{Update RMS} \quad \Longrightarrow \quad \text{可直接复用} \eta, \lambda.$$

这就是迁移的" 自由午餐"——AdamW 训练得到的最优 η, λ 可以直接用于 Muon 训练。

6.4 进阶视角：Total Update Contribution

另一个对齐视角来自 Rotational Equilibrium 论文。在稳态下，单步梯度 $\boldsymbol{g}_t$ 对未来所有步的**总贡献**是：

$$\sum_{i=0}^{\infty} \beta_1^i (1-\beta_1) \boldsymbol{g}_t = \boldsymbol{g}_t. \tag{19}$$

即单步梯度的总效应**与** β_1 **无关**——β_1 只是把效应在时间上摊平。从 TUC 视角：

- AdamW 的 TUC $\propto \eta_t \sqrt{mn}$；
- Muon (Kimi) 的 TUC $\approx 1.25\, \eta_t \sqrt{\min(n,m)} \cdot \sqrt{\max(n,m)} = 1.25\, \eta_t \sqrt{mn}$。

其中 $1.25 \approx 0.2 \times \sqrt{(1+\mu)/(1-\mu)}|_{\mu=0.95}$。**TUC 对齐与 RMS 对齐给出的 0.2 这个倍数异曲同工**。

注 6.2. 两个视角在此渐近等价，但在" 最优学习率是否随 β_1 变化" 这个问题上有细微分歧。这是一个开放的实验问题，适合作为期末研究课题。

6.5 速查表

量	渐近值（零均值稳态）	依赖超参
Update RMS (AdamW)	$\sqrt{(1-\beta_1)/(1+\beta_1)} \approx 0.23$	仅 β_1
Update RMS (SignSGDM)	$\sqrt{(1+\beta_1)/(1-\beta_1)} \times$ AdamW	仅 β_1
Weight RMS (AdamW)	$\sqrt{\eta/(2\lambda)}$	仅 η, λ
Weight RMS (Muon-Kimi)	$\sqrt{\eta/(2\lambda)}$（对齐后）	仅 η, λ

7 MuP：超参数跨模型尺度的迁移规律

上面解决了" 优化器之间迁移" 的问题。现在解决" **模型尺度之间迁移**"——在小模型上搜索的最优学习率如何迁移到大模型？这就是 MuP（Maximal Update Parametrization）。

7.1 Motivation 与方法大意

MuP 研究的是**超参数随模型尺度（主要是宽度 d）的变化规律**。请注意：

注意

MuP **不研究**" 什么是最优超参"，只研究" 最优超参随尺度的变化规律"。所以我们需要先在某个小模型上搜索最优超参，然后按缩放规律迁移到大模型。

推导原理：**让前向传播、反向传播、损失增量、特征变化都不随模型尺度发生明显变化**。具体做法是分析初始化阶段的数量级，然后假设结论代表后续优化的规律——" 好的开始是成功的一大半"。

7.2 前向传播：初始化尺度规律

考虑线性层 $\boldsymbol{Y} = \boldsymbol{X}\boldsymbol{W}$，$\boldsymbol{W} \in \mathbb{R}^{d_{\text{in}} \times d_{\text{out}}}$。RMS 作为矩阵尺度指标：

$$\text{RMS}(\boldsymbol{W}) = \sqrt{\frac{1}{d_{\text{in}} d_{\text{out}}} \sum_{i,j} W_{i,j}^2}.$$

要使初始化阶段 $\text{RMS}(\boldsymbol{X}) \approx \text{RMS}(\boldsymbol{Y})$：

命题 7.1 (fan_in 初始化)**.** *" 均值为 0、方差**正比于** $1/d_{in}$ " 的随机初始化。*

对于非线性层 $\boldsymbol{Y} = \phi(\boldsymbol{X}\boldsymbol{W})$（如 ReLU），Kaiming 初始化与 LeCun 仅差一个尺度无关常数。这给出：

关键洞察

激活函数的影响是模型尺度无关的。如果只分析模型尺度效应，可以忽略激活函数的存在，直接用 LeCun 初始化的缩放规律 $\propto 1/d_{\text{in}}$。

7.3 反向传播的冲突

反向传播给出 $\partial L/\partial \boldsymbol{X} \sim (\partial L/\partial \boldsymbol{Y})\boldsymbol{W}^\top$，要求 fan_out 初始化（方差 $\propto 1/d_{\text{out}}$）。

当 $d_{\text{in}} \neq d_{\text{out}}$ 时前向与反向要求冲突。折中方案是 Xavier 初始化（fan_avg）——但两者都没兼顾。更好的办法是**设计模型让大部分参数都是方阵**。

7.4 损失增量与尺度爆炸

考虑 $\Delta L \approx -\eta \|X^\top \partial L/\partial Y\|_F^2$。分析 $\|X^\top \partial L/\partial Y\|_F^2$：

- 是 $d_{\text{in}} \times d_{\text{out}}$ 个数的平方和；
- 如果前向和反向都稳定，每个元素是 $\Theta(1)$；
- 所以是 $\Theta(d_{\text{in}} d_{\text{out}})$。

注意

学习率不能跨尺度直接使用！如果直接把小模型的 η 用到大模型，ΔL 会随参数尺度 $d_{\text{in}} d_{\text{out}}$ 爆炸——训练过程无法复制，甚至因步子太大无法收敛。

7.5 标准模型簇

MuP 考虑如下三分结构：

$$
\begin{aligned}
\boldsymbol{Y}_{\text{in}} &= \boldsymbol{X}\boldsymbol{W}_{\text{in}}, & \boldsymbol{W}_{\text{in}} &\in \mathbb{R}^{d_{\text{in}}\times d} \\
\boldsymbol{Y}_{\text{out}} &= \text{NN}(\boldsymbol{Y}_{\text{in}};\Omega), & \boldsymbol{W}_k &\in \mathbb{R}^{d\times d}, k=1,\dots,K \\
\boldsymbol{Z} &= \boldsymbol{Y}_{\text{out}}\boldsymbol{W}_{\text{out}}, & \boldsymbol{W}_{\text{out}} &\in \mathbb{R}^{d\times d_{\text{out}}}
\end{aligned}
$$

$d_{\text{in}}, d_{\text{out}}$ 是任务相关的常数；d（hidden size）是可变的。MuP 研究超参随 d 的规律。

注 7.2. 约定方阵是为了简化分析。真正目的是假设 NN 参数里没有尺度无关的形状（不允许 $d\times 64$，但允许 $d\times 4d$）。

7.6 SGD 下的学习率规律

对 $\boldsymbol{W}_{\text{in}}, \Omega, \boldsymbol{W}_{\text{out}}$ 分别求梯度并分析：

1. $\boldsymbol{W}_{\textbf{out}}$：$\partial L/\partial \boldsymbol{W}_{\text{out}}$ 的 RMS 是 $\Theta(1)$，$\|\cdot\|_F^2$ 是 $d\times d_{\text{out}}$ 个数平方和 $=\Theta(d)$。为得到 $\Theta(1)$ 的 ΔL：$\boxed{\eta_{\text{out}} \propto 1/d}$。
2. $\boldsymbol{W}_k$：**将 $\boldsymbol{W}_{\textbf{out}}$ 的初始化方差设为** $\propto 1/d^2$，则 $\partial L/\partial \boldsymbol{W}_k$ 的 RMS 是 $\Theta(1/d)$，平方和后正好是 $\Theta(1)$：$\boxed{\eta_k \propto 1}$（不变）。
3. $\boldsymbol{W}_{\textbf{in}}$：$\partial L/\partial \boldsymbol{W}_{\text{in}}$ 的 RMS 也是 $\Theta(1/d)$，但 $\|\cdot\|_F^2$ 只是 $d_{\text{in}}\times d$ 个数平方和 $=\Theta(1/d)$。为得到 $\Theta(1)$ 的 ΔL：$\boxed{\eta_{\text{in}} \propto d}$。

7.7 特征变化：补全缺失的条件

上面"$\boldsymbol{W}_{\text{out}}$ 初始化方差 $\propto 1/d^2$" 的选择目前没有直接依据：若改为 $\propto 1/d$，用 $\eta \propto 1/d$ 也能实现 $\Delta L=\Theta(1)$。为了唯一定出结果，需要引入内部指标。

特征变化尺度不变：考虑 $\Delta \boldsymbol{Y}_k = \boldsymbol{Y}_{k-1}\Delta \boldsymbol{W}_k$。注意 $\Delta \boldsymbol{W}_k$ 是精心设计的更新量（**不可能像初始化那样与 $\boldsymbol{Y}_{k-1}$ 独立**），所以 d 维向量对的内积更可能是 $\Theta(d)$：

$$\text{RMS}(\Delta \boldsymbol{Y}_k) \sim \Theta(d\cdot \text{RMS}(\Delta \boldsymbol{W}_k)).$$

定理 7.3 (特征变化条件)**.** 为使 $\text{RMS}(\Delta \boldsymbol{Y}_k)=\Theta(1)$：

$$\text{RMS}(\Delta \boldsymbol{W}_k) = \Theta(1/d). \tag{20}$$

结合 $\Delta L=\Theta(1)$ 就唯一定出"$\boldsymbol{W}_{\text{out}}$ 初始化方差 $\propto 1/d^2$"。

7.8 Adam 与 Muon 版本

Adam 用 SignSGD 近似（$\Delta L \approx -\eta\|\partial L/\partial \boldsymbol{W}\|_1$）：

- $\eta_{\text{in}} \propto 1$
- $\eta_k \propto 1/d$

- $\eta_{\text{out}} \propto 1/d$

Muon 用 MSignSGD 近似（$\Delta L \approx -\eta\|\partial L/\partial \boldsymbol{W}\|_* \approx -\eta\|\partial L/\partial \boldsymbol{W}\|_F$）：

- $\eta_{\text{in}} \propto \sqrt{d}$
- $\eta_k \propto 1$
- $\eta_{\text{out}} \propto 1/\sqrt{d}$

7.9 MuP 结论汇总

	SGD	Adam	Muon
$\boldsymbol{W}_{\text{in}}$ 方差	$1/d_{\text{in}}$	$1/d_{\text{in}}$	$1/d_{\text{in}}$
$\boldsymbol{W}_{\text{in}}$ 学习率	d	1	$\sqrt{d}$
$\boldsymbol{W}_k$ 方差	$1/d$	$1/d$	$1/d$
$\boldsymbol{W}_k$ 学习率	1	$1/d$	1
$\boldsymbol{W}_{\text{out}}$ 方差	$1/d^2$	$1/d^2$	$1/d^2$
$\boldsymbol{W}_{\text{out}}$ 学习率	$1/d$	$1/d$	$1/\sqrt{d}$

实操要点

实际使用 Muon 时，$\boldsymbol{W}_{\text{in}}$ 和 $\boldsymbol{W}_{\text{out}}$ 通常仍用 Adam，导致：

- $\eta_{\text{out}} \propto 1/d$（改用 Adam 规律）
- η_{in} 不变（即 $\propto 1$）

若开启 Moonlight 的 Adjust LR（乘 $\sqrt{\max(n,m)} \propto \sqrt{d}$），抵消后：$\eta_k \propto 1/\sqrt{d}$。

8 MuP 之上：谱条件

MuP 的原始推导需要四个条件（前向、反向、损失增量、特征变化），分析繁琐。Yang 等人在《A Spectral Condition for Feature Learning》中提出**谱条件**，仅用两个条件就能得到比 MuP 更丰富的结果。

关键洞察

谱条件的三个”美妙之处”：

1. 将四个条件降为两个——减少分析步骤；
2. 从代数不等式出发，不依赖分布假设——简化分析过程；
3. 不需通过链式法则算梯度就能获得梯度的数量级估计。

8.1 准备：谱范数不等式

谱范数的基本不等式：

$$\|\boldsymbol{x}\boldsymbol{W}\|_2 \le \|\boldsymbol{x}\|_2 \|\boldsymbol{W}\|_2. \tag{21}$$

代入 RMS（$\|\boldsymbol{x}\|_{\mathrm{RMS}} = \|\boldsymbol{x}\|_2/\sqrt{d_{\mathrm{in}}}$）：

$$\boxed{\|\boldsymbol{x}\boldsymbol{W}\|_{\mathrm{RMS}} \le \sqrt{\frac{d_{\mathrm{in}}}{d_{\mathrm{out}}}}\,\|\boldsymbol{x}\|_{\mathrm{RMS}}\|\boldsymbol{W}\|_2.} \tag{22}$$

8.2 期望性质：两个条件足矣

记每层为 $\boldsymbol{x}_k = f(\boldsymbol{x}_{k-1}; \boldsymbol{W}_k)$。谱条件期望：

定理 8.1 (期望性质)**.**

$$\|\boldsymbol{x}_k\|_{\mathrm{RMS}} = \Theta(1), \tag{23}$$

$$\|\Delta\boldsymbol{x}_k\|_{\mathrm{RMS}} = \Theta(1). \tag{24}$$

定理 8.2 (损失增量自动稳定)**.** *若每层都满足上述条件，则 $\Delta L = \Theta(1)$ 自动成立。*

证明. $\|\boldsymbol{x}_K\|_{\mathrm{RMS}} = \Theta(1) \Rightarrow \ell(\boldsymbol{x}_K) = \Theta(1)$；$\|\Delta\boldsymbol{x}_K\|_{\mathrm{RMS}} = \Theta(1) \Rightarrow \ell(\boldsymbol{x}_K + \Delta\boldsymbol{x}_K) = \Theta(1)$。故 $\Delta\ell = \Theta(1)$，样本平均后 $\Delta L = \Theta(1)$。 □

8.3 两个谱条件

对线性层 $\boldsymbol{x}_k = \boldsymbol{x}_{k-1}\boldsymbol{W}_k$，由 (22) 直接推出：

定理 8.3 (谱条件)**.**

$$\|\boldsymbol{W}_k\|_2 = \Theta\left(\sqrt{d_k/d_{k-1}}\right), \tag{25}$$

$$\|\Delta\boldsymbol{W}_k\|_2 = \Theta\left(\sqrt{d_k/d_{k-1}}\right). \tag{26}$$

8.4 实现方式：SN / SVC / msign

谱归一化 (SN)：

$$\boldsymbol{W}_k = \sigma\sqrt{\frac{d_k}{d_{k-1}}} \cdot \frac{\boldsymbol{W}'_k}{\|\boldsymbol{W}'_k\|_2}, \quad \Delta\boldsymbol{W}_k = \eta\sqrt{\frac{d_k}{d_{k-1}}} \cdot \frac{\boldsymbol{\Phi}_k}{\|\boldsymbol{\Phi}_k\|_2}.$$

奇异值裁剪 (SVC)：$\mathrm{SVC}(\boldsymbol{W}) = \boldsymbol{U}\min(\boldsymbol{\Lambda}, 1)\boldsymbol{V}^\top$。

极限：msign：

$$\lim_{\lambda\to\infty} \mathrm{SVC}(\lambda\boldsymbol{W}) = \mathrm{msign}(\boldsymbol{W}).$$

代入得**广义 Muon**：

$$\Delta\boldsymbol{W}_k = \eta\sqrt{d_k/d_{k-1}}\,\mathrm{msign}(\boldsymbol{\Phi}_k). \tag{27}$$

关键洞察

广义 Muon 允许对**任意优化器**（不只是动量）的输出做 msign。推特上有人做”对 Adam 更新量做 msign”（Mudamw）的实验，发现效果甚至略优于标准 Muon。在原 Muon 框架下很难解释，但从谱条件视角看这自然合理——对 Adam 输出做奇异值裁剪的极限版本。

8.5 近似估计：从 SVD 到显式公式

初始化：从标准正态采样的 $d_{k-1} \times d_k$ 矩阵，最大奇异值约为 $\sqrt{d_{k-1}} + \sqrt{d_k}$（Marchenko-Pastur 定律，Part 2 会详细讲）。故采样标准差：

$$\sigma_k = \Theta\left(\sqrt{\frac{1}{d_{k-1}} \min\left(1, \frac{d_k}{d_{k-1}}\right)}\right). \tag{28}$$

梯度估计（低秩假设）：经验事实——**参数的梯度矩阵通常都是低秩的**。最大的几个奇异值远超其余，故谱范数与核范数在尺度上同阶。由 Holder 型不等式和 $\Delta L = \Theta(1)$：

$$\boxed{\|\nabla_{\boldsymbol{W}_k} L\|_2 = \Theta\left(\sqrt{d_{k-1}/d_k}\right).} \tag{29}$$

关键洞察

谱条件的第三个美妙之处——**不需要通过链式法则算梯度的显式表达式**，直接从两个谱条件推出梯度的数量级。

8.6 学习率规律

SGD：$\Delta \boldsymbol{W}_k = -\eta_k \nabla_{\boldsymbol{W}_k} L$，由 (29) 给出

$$\eta_k^{\text{SGD}} = \Theta(d_k/d_{k-1}).$$

Adam（SignSGD 近似，sign 不升秩）：

$$\eta_k^{\text{Adam}} = \Theta(1/d_{k-1}).$$

8.7 谱条件 vs MuP：统一的美

代入 MuP 的三分结构（$d_{\text{in}} \times d$、$d \times d$、$d \times d_{\text{out}}$），$d \to \infty$：

初始化由 (28)：

$$\begin{aligned}
\sigma_{\text{in}}^2 &= \Theta(1/d_{\text{in}}), \\
\sigma_k^2 &= \Theta(1/d), \\
\sigma_{\text{out}}^2 &= \Theta(1/d^2).
\end{aligned}$$

完全重现 MuP 的三个结论！学习率亦然。

	MuP	**谱条件**
条件数	4	2
分析基础	分布假设（方差期望）	代数不等式（谱范数）
梯度分析	需链式法则	直接由谱条件推出
初始化规律	三种情形分别给	单式统一
架构假设	需方阵	任意形状

9 Part 1 小结

本 Part 完整介绍了优化器的两套尺度规律：
优化器内部（Update RMS, Weight RMS）：

$$\|\boldsymbol{u}_t\|_{\mathrm{RMS}} \approx \sqrt{(1-\beta_1)/(1+\beta_1)}, \quad \|\boldsymbol{\theta}_t\|_{\mathrm{RMS}} \approx \sqrt{\eta/(2\lambda)}.$$

跨优化器迁移（AdamW → Muon）：对齐 Update RMS 到 0.2。
跨模型尺度迁移（MuP / 谱条件）：

$$\sigma_k = \Theta\left(\sqrt{d_{k-1}^{-1}\min(1, d_k/d_{k-1})}\right), \quad \eta_k^{\mathrm{Adam}} = \Theta(1/d_{k-1}).$$

三句话带走：

1. **平均场是万能打开方式**——先假设独立、分离分子分母期望、取稳态，再与模拟对比；
2. **Weight decay 是 update 的 EMA**——这个视角转换是 scaling law 的钥匙；
3. **对齐 update RMS 就能共享超参**——这是 Muon 迁移背后的”自由午餐”。

关键洞察

从 Part 1 到 Part 2 的过渡：上面的所有公式推导都依赖一个核心假设——**高维随机向量的几何性质**（测度集中、近似正交、谱的普适性）。Part 2 我们就转到这个基础本身：看随机矩阵/随机投影如何直接用作**算法**。在谱条件一节我们已经用到了一个结果——”高斯矩阵最大奇异值 $\approx \sqrt{d_{k-1}} + \sqrt{d_k}$”——这正是 Marchenko-Pastur 定律的直接推论。Part 2 我们会看到这个定律的完整样貌。

第二部分　随机化算法

10　开场（0:00–0:05）

今天开始我们进入一个新的主题：随机化算法。

在优化课程里，我们一直追求的是精确解。但现实中，很多问题的精确解计算代价太高了。比如两个矩阵相乘，A 是 $m\times n$，B 是 $n\times p$，精确计算需要 $O(mnp)$ 次乘法。当 $m=n=p=10000$ 时，这是 10^{12} 次运算。

随机化算法的核心思想是：**我不要精确答案了，我要一个"大概率正确"的近似答案，但速度快很多**。

这个思想在 GPU 时代特别有价值。因为 GPU 擅长并行计算大量简单操作，而随机化算法恰好把复杂计算拆成了大量独立的简单采样。

今天我们会学习几个经典的随机化算法：随机投影、随机矩阵乘法、随机 SVD。最后我会介绍随机矩阵理论中的 MP 分布，这是下下周分析神经网络的理论基础。

11　随机化的哲学（0:05–0:10）

传统算法是**确定性**的：给定输入，输出是固定的。随机化算法是**概率性**的：给定输入，输出是一个随机变量。

随机化的好处主要有三点：

1. **打破最坏情况**：确定性算法必须对所有输入都 work，所以复杂度往往由最坏情况决定。随机化算法可以让最坏情况的概率很小。

2. **降低计算量**：通过采样，我们用少量样本估计全局性质。

3. **适合并行**：随机采样天然是独立的，可以完美并行。

代价是**答案有误差**。但关键洞察是：在很多应用中（比如机器学习），我们本来就不需要精确解，一个好的近似解就够了。

所以随机化算法的核心问题是：**如何用随机性换计算量，同时控制误差？**

12　Johnson-Lindenstrauss 引理：随机投影的魔力

12.1　问题的提出（0:10–0:15）

12.1.1　一个具体的场景

假设你是某电商平台的推荐系统工程师。你有 1 亿个商品，每个商品用一个 100 万维的特征向量表示（包含文本 embedding、图像特征、用户行为统计等）。现在用户搜索了一个商品，你需要找到与之最相似的 10 个商品推荐给用户。

直接计算的代价：

- 计算两个向量的距离：$O(d)=O(10^6)$ 次运算

- 遍历所有商品：$O(n) = O(10^8)$ 次距离计算
- 总计：$O(nd) = O(10^{14})$ 次运算——即使每次运算 1 纳秒，也需要约 28 小时！

核心问题：能不能把 100 万维的向量压缩到更低的维度，同时基本保持向量之间的距离关系？

12.1.2 直觉与反直觉

悲观的直觉：信息论告诉我们，压缩必然损失信息。如果把 $d = 10^6$ 维压缩到 $k = 1000$ 维，我们丢掉了 99.9% 的维度，距离肯定会被严重扭曲。

惊人的事实：Johnson 和 Lindenstrauss 在 1984 年证明，如果我们使用**随机投影**，距离的相对误差可以控制在任意小的 ϵ 以内，而且所需的目标维度 k **完全不依赖于原始维度** d！

例 12.1 (具体数值)**.** 假设我们有 $n = 10^8$ 个点（1 亿个商品），想要距离的相对误差不超过 $\epsilon = 10\%$。JL 引理告诉我们，只需要

$$k = O\left(\frac{\log n}{\epsilon^2}\right) = O\left(\frac{\log 10^8}{0.01}\right) = O\left(\frac{8 \ln 10}{0.01}\right) \approx O(1840)$$

也就是说，大约 2000 维就够了！这与原始的 100 万维相比，压缩了 500 倍。

12.1.3 定理的精确陈述

定理 12.2 (Johnson-Lindenstrauss 引理，1984)**.** *设 $x_1, \ldots, x_n \in \mathbb{R}^d$ 是 n 个点，$\epsilon \in (0, 1)$ 是误差参数。则存在一个线性映射 $f : \mathbb{R}^d \to \mathbb{R}^k$，其中*

$$k = O\left(\frac{\log n}{\epsilon^2}\right)$$

使得对所有的点对 i, j：

$$(1 - \epsilon)\|x_i - x_j\|^2 \leq \|f(x_i) - f(x_j)\|^2 \leq (1 + \epsilon)\|x_i - x_j\|^2$$

注 12.3 (理解这个不等式). 这个不等式说的是：投影后的距离与原始距离的比值在 $[\sqrt{1-\epsilon}, \sqrt{1+\epsilon}]$ 之间。当 ϵ 较小时，$\sqrt{1 \pm \epsilon} \approx 1 \pm \epsilon/2$，所以距离的相对误差大约是 $\epsilon/2$。

例如，$\epsilon = 0.1$ 时：

- 原始距离为 100 的两个点
- 投影后距离在 $[\sqrt{0.9} \times 100, \sqrt{1.1} \times 100] = [94.9, 104.9]$ 之间
- 相对误差不超过 5.1%

12.1.4 为什么这很惊人？

让我们用一个表格来感受 k 对 d 的独立性：

点的个数 n	原始维度 d	误差 ϵ	所需维度 k
10^4	10^3	0.1	≈ 920
10^4	10^6	0.1	≈ 920
10^4	10^9	0.1	≈ 920
10^6	10^6	0.1	≈ 1380
10^9	10^6	0.1	≈ 2070
10^6	10^6	0.01	≈ 138000

观察：

- 前三行：d 从 10^3 变到 10^9（增加了 100 万倍），但 k 完全不变！
- 中间两行：n 增加 1000 倍，k 只增加 50%（因为是 $\log n$）
- 最后一行：ϵ 减小 10 倍，k 增加 100 倍（因为是 $1/\epsilon^2$）

12.2 证明思路（0:15–0:20）

12.2.1 核心思想

证明分三步：

1. **构造**：给出一个具体的随机投影矩阵
2. **单向量分析**：证明随机投影几乎保持任意**单个**向量的长度
3. **Union Bound**：把单向量的保证推广到**所有**点对

12.2.2 Step 1：构造随机投影矩阵

定义 12.4 (随机投影矩阵)**.** 设 $R \in \mathbb{R}^{k\times d}$ 是一个随机矩阵，每个元素独立地从 $N(0, 1/k)$ 分布中采样。定义线性映射

$$f(x) = Rx$$

例 12.5 (一个具体的例子)**.** 假设 $d = 4$，$k = 2$。一个可能的 R 矩阵是：

$$R = \begin{pmatrix} 0.3 & -0.5 & 0.2 & 0.1 \\ -0.4 & 0.1 & 0.6 & -0.3 \end{pmatrix}$$

（实际上每个元素是从 $N(0, 1/2)$ 中采样的）

对于向量 $x = (1, 2, 0, -1)^T$：

$$f(x) = Rx = \begin{pmatrix} 0.3 \times 1 + (-0.5) \times 2 + 0.2 \times 0 + 0.1 \times (-1) \\ (-0.4) \times 1 + 0.1 \times 2 + 0.6 \times 0 + (-0.3) \times (-1) \end{pmatrix} = \begin{pmatrix} -0.8 \\ 0.1 \end{pmatrix}$$

为什么用高斯分布？主要是因为高斯分布有优美的数学性质：

- **旋转不变性**：如果 $g \sim N(0, I_d)$，那么对任意正交矩阵 U，Ug 的分布也是 $N(0, I_d)$
- **可加性**：独立高斯的线性组合仍是高斯

12.2.3 Step 2：单向量的长度几乎被保持

引理 12.6 (关键引理)**.** 对于任意固定的单位向量 $v \in \mathbb{R}^d$（$\|v\| = 1$），随机投影后：

1. 期望保持长度：$\mathbb{E}[\|Rv\|^2] = 1$
2. 高度集中在期望附近：$P\left(\left|\|Rv\|^2 - 1\right| > \epsilon\right) \leq 2e^{-c\epsilon^2 k}$

其中 $c > 0$ 是一个绝对常数（大约是 1/4）。

理解这个引理：

- 第一条说：平均来看，投影后的长度等于原始长度
- 第二条说：偏离期望的概率随着 k 指数级衰减

例 12.7 (集中性的具体数值)**.** 设 $\epsilon = 0.1$，$c = 0.25$。偏离超过 10% 的概率是：

$$P\left(\left|\|Rv\|^2 - 1\right| > 0.1\right) \leq 2e^{-0.25\times 0.01\times k} = 2e^{-0.0025k}$$

- $k = 1000$：概率 $\leq 2e^{-2.5} \approx 0.16$（16%）
- $k = 2000$：概率 $\leq 2e^{-5} \approx 0.013$（1.3%）
- $k = 4000$：概率 $\leq 2e^{-10} \approx 0.00009$（0.009%）

可以看到，k 越大，集中性越好。

12.2.4 证明关键引理（选讲）

让我们详细分析 $\|Rv\|^2$ 的分布。
Step 2.1：写出 $\|Rv\|^2$ 的表达式
设 R 的第 i 行是 $R_i \in \mathbb{R}^d$。则

$$\|Rv\|^2 = \sum_{i=1}^{k} (R_i \cdot v)^2$$

Step 2.2：分析单个内积 $R_i \cdot v$
$R_i \cdot v = \sum_{j=1}^{d} R_{ij} v_j$，其中 $R_{ij} \sim N(0, 1/k)$ 独立。
因为 v 是单位向量（$\sum_j v_j^2 = 1$），而高斯分布的线性组合仍是高斯：

$$R_i \cdot v \sim N\left(0, \frac{1}{k}\sum_{j=1}^{d} v_j^2\right) = N(0, 1/k)$$

Step 2.3：分析 $\|Rv\|^2$ 的分布
令 $Z_i = \sqrt{k}(R_i \cdot v)$，则 $Z_i \sim N(0, 1)$ 独立，且

$$\|Rv\|^2 = \sum_{i=1}^{k} (R_i \cdot v)^2 = \frac{1}{k}\sum_{i=1}^{k} Z_i^2$$

其中 $\sum_{i=1}^{k} Z_i^2 \sim \chi^2(k)$（自由度为 k 的卡方分布）。

所以 $\|Rv\|^2$ 是 $\chi^2(k)$ 分布除以 k，其期望是 1，方差是 $2/k$。

Step 2.4：卡方分布的集中性

使用卡方分布的尾概率 bound（这是一个标准结果）：

$$P\left(\left|\frac{\chi^2(k)}{k} - 1\right| > \epsilon\right) \leq 2e^{-c\epsilon^2 k}$$

注 12.8 (直观理解). $\|Rv\|^2$ 是 k 个独立同分布随机变量的平均。根据大数定律，当 $k \to \infty$ 时，这个平均收敛到期望 1。集中不等式量化了" 收敛的速度"——偏离 ϵ 的概率以 $e^{-\Theta(k)}$ 的速度指数衰减。

12.2.5 Step 3：Union Bound

现在我们知道，对任意**单个**单位向量 v，$\|Rv\|^2$ 以高概率接近 1。但我们需要**所有**点对的距离都被保持。

关键观察：对于点对 (x_i, x_j)，令 $v_{ij} = \frac{x_i - x_j}{\|x_i - x_j\|}$。则

$$\|f(x_i) - f(x_j)\|^2 = \|R(x_i - x_j)\|^2 = \|x_i - x_j\|^2 \cdot \|Rv_{ij}\|^2$$

所以，保持 $\|f(x_i) - f(x_j)\|^2 \approx \|x_i - x_j\|^2$ 等价于保持 $\|Rv_{ij}\|^2 \approx 1$。

Union Bound：我们有 $\binom{n}{2} < n^2$ 对点，每对失败的概率 $\leq 2e^{-c\epsilon^2 k}$。

所以，存在某一对失败的概率 $\leq n^2 \cdot 2e^{-c\epsilon^2 k}$。

要这个概率 < 1，我们需要：

$$n^2 \cdot 2e^{-c\epsilon^2 k} < 1 \implies k > \frac{2\ln n + \ln 2}{c\epsilon^2} = O\left(\frac{\log n}{\epsilon^2}\right)$$

例 12.9 (具体计算)**.** 设 $n = 10^6$，$\epsilon = 0.1$，$c = 0.25$。

失败概率 < 1 的条件是：

$$k > \frac{2 \times 6\ln 10 + \ln 2}{0.25 \times 0.01} = \frac{27.6 + 0.69}{0.0025} \approx 11316$$

所以 $k \approx 12000$ 就够了。如果我们想要失败概率 < 0.01，需要 $k > \frac{27.6+0.69+4.6}{0.0025} \approx 13156$。

12.3 应用场景（0:20–0:25）

12.3.1 应用 1：近似最近邻搜索

场景：搜索引擎、推荐系统需要在海量向量中快速找到与 query 最相似的向量。

具体例子：图像搜索

- 数据库：$n = 10^9$ 张图片，每张用 ResNet 提取 $d = 2048$ 维特征
- Query：用户上传一张图片，找到最相似的 10 张
- 直接方法：$O(nd) = O(2 \times 10^{12})$ 次运算

用 JL 引理加速：

1. 预处理：生成随机矩阵 $R \in \mathbb{R}^{k\times d}$，其中 $k = O(\log n/\epsilon^2) \approx 3000$
2. 预处理：对所有数据库图片，计算 $f(x_i) = Rx_i$，存储低维向量
3. 在线：对 query q，计算 $f(q) = Rq$
4. 在线：在低维空间找最近邻

复杂度对比：

	直接方法	JL+ 精确搜索
预处理	无	$O(nkd)$
存储	$O(nd)$	$O(nk)$
查询	$O(nd)$	$O(nk)$

存储从 $O(nd) = O(2\times 10^{12})$ 降到 $O(nk) = O(3\times 10^{12})$——等等，这似乎没有改善?

关键 insight：JL 引理在 d 已经不太大时优势不明显。它的威力在于 d 非常大的场景（如 $d = 10^6$）。

例 12.10 (更合适的场景：NLP 词向量)**.**

- $n = 10^7$ 个文档, 每个用 $d = 768\times 512 \approx 400000$ 维的 BERT embedding 表示
- $k = 2000$ 维足够
- 存储从 400GB 降到 20GB，查询从 4×10^{12} 降到 2×10^{10}

近似保证：如果 x^* 是原始空间的真正最近邻，$\hat{x}$ 是低维空间找到的最近邻，则

$$\|q-\hat{x}\| \le \sqrt{\frac{1+\epsilon}{1-\epsilon}}\|q-x^*\| \approx (1+\epsilon)\|q-x^*\|$$

即我们找到的是 $(1+\epsilon)$-近似最近邻。

12.3.2 应用 2：快速核方法

背景：核方法（如 SVM、核岭回归）需要计算核矩阵 $K_{ij} = \kappa(x_i, x_j)$。

RBF 核：$\kappa(x, y) = \exp(-\gamma\|x-y\|^2)$

直接计算 $n\times n$ 核矩阵需要 $O(n^2d)$ 时间。

用 JL 引理加速：

1. 对所有点做随机投影：$y_i = Rx_i$
2. 用低维距离近似核函数：$\tilde{\kappa}(x_i, x_j) = \exp(-\gamma\|y_i - y_j\|^2)$

因为 $(1-\epsilon)\|x_i - x_j\|^2 \le \|y_i - y_j\|^2 \le (1+\epsilon)\|x_i - x_j\|^2$，所以

$$\kappa(x_i, x_j)^{1+\epsilon} \le \tilde{\kappa}(x_i, x_j) \le \kappa(x_i, x_j)^{1-\epsilon}$$

例 12.11 (核矩阵近似的精度)**.** 设 $\kappa(x_i, x_j) = 0.5$，$\epsilon = 0.1$。则

$$0.5^{1.1} \le \tilde{\kappa}(x_i, x_j) \le 0.5^{0.9}$$

即 $0.466 \le \tilde{\kappa} \le 0.536$，相对误差约 7%。

复杂度：从 $O(n^2d)$ 降到 $O(nkd + n^2k)$。当 $d \gg n$ 时，这是巨大的改进。

12.3.3 应用 3：流式算法和草图

场景：数据以流的形式到达，我们只能存储少量信息，但要回答关于全部数据的查询。
例子：网络流量监控

- 每秒有 10^6 个数据包，每个包用 $d = 1000$ 维特征描述
- 我们想知道过去 1 小时内，哪些流量模式是异常的（与正常模式的距离超过阈值）
- 存储所有数据需要 $3.6 \times 10^9 \times 1000 \times 4$ 字节 ≈ 14TB

草图方法：

1. 固定一个随机矩阵 $R \in \mathbb{R}^{k \times d}$，$k = 200$
2. 对每个到达的向量 x，只存储 Rx（200 维）
3. 存储量：$3.6 \times 10^9 \times 200 \times 4$ 字节 ≈ 2.9TB——减少了 5 倍
4. 距离查询可以在低维空间近似完成

12.3.4 JL 引理 vs PCA：关键区别

	JL 随机投影	PCA
是否需要看数据	否（数据无关）	是（需计算协方差）
预处理时间	$O(kd)$（生成 R）	$O(nd^2)$ 或 $O(n^2d)$
可以增量更新	是	否（新数据需重算）
保持的性质	距离（所有点对）	方差（主要方向）
目标维度	$O(\log n/\epsilon^2)$	取决于数据的内在维度

例 12.12 (何时用 JL，何时用 PCA)**. 用 JL 的场景**：

- 数据持续到达，无法预先看到全部数据
- 只关心保持距离关系（如最近邻搜索）
- 数据量太大，无法计算协方差矩阵

用 PCA 的场景：

- 数据固定且可以预处理
- 数据有明显的低秩结构（几个主方向解释了大部分方差）
- 目标是可解释性（主成分有实际意义）

13 随机最小二乘：Sketch-and-Solve 方法（0:50–1:05）

13.1 问题背景

13.1.1 最小二乘问题回顾

最小二乘问题是数据科学中最基础的问题之一：

$$\min_{x\in\mathbb{R}^d} \|Ax-b\|_2$$

其中 $A\in\mathbb{R}^{n\times d}$ 是设计矩阵，$b\in\mathbb{R}^n$ 是观测向量，$x\in\mathbb{R}^d$ 是待求参数。

例 13.1 (线性回归的实际场景)**.** 假设你是一家电商公司的数据科学家，想用历史数据预测商品销量。

- $n=10^8$：1 亿条历史销售记录
- $d=1000$：每条记录有 1000 个特征（价格、类别、季节、促销等）
- $A\in\mathbb{R}^{10^8\times 1000}$：特征矩阵
- $b\in\mathbb{R}^{10^8}$：对应的销量
- $x\in\mathbb{R}^{1000}$：要学习的回归系数

13.1.2 精确求解的代价

最小二乘的闭式解是 $x^*=(A^TA)^{-1}A^Tb$，但实际计算通常用 QR 分解或正规方程。

QR 分解方法：

1. 计算 $A=QR$（$Q\in\mathbb{R}^{n\times d}$ 正交，$R\in\mathbb{R}^{d\times d}$ 上三角）
2. 求解 $Rx=Q^Tb$

时间复杂度：$O(nd^2)$

例 13.2 (具体计算量)**.** 对于 $n=10^8$，$d=1000$：

$$O(nd^2)=O(10^8\times 10^6)=O(10^{14})$$

即使每秒 10^{12} 次运算，也需要 100 秒。如果需要频繁更新模型或尝试不同特征组合，这个代价太高了。

13.1.3 核心问题

$n\gg d$（样本数远大于特征数）是实际中常见的情况。能否利用这个结构加速？

直觉：虽然有 n 个方程，但解空间只有 d 维。也许我们不需要”看”所有 n 个方程，只需要看足够多的”代表性”方程就够了？

13.2 Sketch-and-Solve 算法

13.2.1 算法思想

关键洞察：如果我们能把 n 行”压缩”成 k 行（$k \ll n$），同时保持问题的本质结构，就能大幅加速。

这正是”sketch”（草图/素描）的含义：用少量笔画捕捉原图的主要特征。

13.2.2 算法描述

输入：$A \in \mathbb{R}^{n\times d}$，$b \in \mathbb{R}^n$，压缩维度 k

Sketch-and-Solve 算法：

1. **生成 sketch 矩阵**：构造 $S \in \mathbb{R}^{k\times n}$（后面讨论如何构造）
2. **压缩数据**：计算
$$\tilde{A} = SA \in \mathbb{R}^{k\times d}, \quad \tilde{b} = Sb \in \mathbb{R}^k$$
3. **求解压缩问题**：
$$\tilde{x} = \arg\min_{x\in\mathbb{R}^d} \|\tilde{A}x - \tilde{b}\|_2 = \arg\min_x \|SAx - Sb\|_2$$

输出：近似解 $\tilde{x}$

例 13.3 (维度变化)**.** 原问题：$n = 10^8$ 行，$d = 1000$ 列

设 $k = 5000$（后面会说明为什么这个 k 足够）

压缩后：$k = 5000$ 行，$d = 1000$ 列

问题规模从 $10^8 \times 1000$ 变成 5000×1000，减少了 2 万倍！

13.2.3 几何直观

让我们从几何角度理解这个算法。

原问题 $\min_x \|Ax - b\|$ 的几何意义是：在 A 的列空间 $\mathrm{col}(A)$ 中，找到离 b 最近的点。

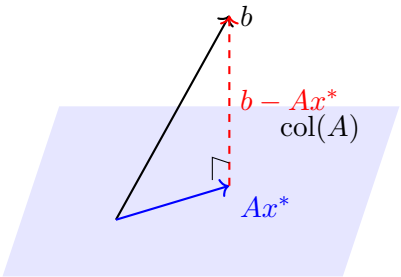

Sketch 矩阵 S 的作用是把所有向量从 $\mathbb{R}^n$ 映射到 $\mathbb{R}^k$：

- $b \mapsto Sb$
- $Ax \mapsto SAx$（对所有 x）
- 列空间 $\mathrm{col}(A) \mapsto \mathrm{col}(SA)$

如果 S 能**近似保持**列空间中所有向量的长度和夹角，那么压缩后的最近点问题的解应该接近原问题的解。

13.3 子空间嵌入：理论保证

13.3.1 什么是子空间嵌入？

定义 13.4 (子空间嵌入)**.** 设 $V \subset \mathbb{R}^n$ 是一个 d 维子空间，$\epsilon \in (0,1)$。矩阵 $S \in \mathbb{R}^{k\times n}$ 称为 V 的 $(1\pm\epsilon)$ **子空间嵌入**，如果对所有 $y \in V$：

$$(1-\epsilon)\|y\|^2 \le \|Sy\|^2 \le (1+\epsilon)\|y\|^2$$

理解：子空间嵌入保证 V 中**所有**向量的长度在映射后只有 $\pm\epsilon$ 的相对误差。

注 13.5 (与 JL 引理的区别).

- JL 引理：保持**有限多个点**之间的距离
- 子空间嵌入：保持**无限多个向量**（整个子空间）的长度

子空间嵌入是更强的条件，但对于 d 维子空间，我们可以用 d 个基向量来" 代表" 整个子空间。

13.3.2 为什么子空间嵌入有用？

定理 13.6 (Sketch-and-Solve 的近似保证)**.** 设 S 是 $col([A,b])$ 的 $(1\pm\epsilon)$ 子空间嵌入（注意这里需要嵌入 A 的列空间**加上**b）。设 x^* 是原问题的最优解，$\tilde{x}$ 是压缩问题的解。则：

$$\|A\tilde{x}-b\| \le \frac{1+\epsilon}{1-\epsilon}\|Ax^*-b\| \approx (1+2\epsilon)\|Ax^*-b\|$$

理解：如果原问题的最优残差是 $r^* = \|Ax^*-b\|$，那么 sketch 方法得到的残差最多是 $(1+O(\epsilon))r^*$。这是**乘性误差**，不是加性误差！

例 13.7 (误差的实际意义)**.** 设原问题的最优残差 $\|Ax^*-b\| = 100$（比如均方根误差是 100 元）。取 $\epsilon = 0.1$，则 sketch 方法的残差满足：

$$\|A\tilde{x}-b\| \le \frac{1.1}{0.9}\times 100 \approx 122$$

即残差最多增加 22%。如果这个精度可以接受，我们就能获得巨大的加速。

13.3.3 定理的证明

Step 1：建立不等式链

设 $r^* = Ax^*-b$ 是原问题的残差向量。注意 $r^* \perp \mathrm{col}(A)$（残差与列空间正交，这是最小二乘的几何性质）。

对于任意 x，设 $r_x = Ax-b$。则：

$$\begin{aligned}\|r_x\|^2 &= \|Ax-Ax^*+Ax^*-b\|^2\\ &= \|A(x-x^*)+r^*\|^2\\ &= \|A(x-x^*)\|^2+\|r^*\|^2 \quad (\text{因为 } A(x-x^*)\in \mathrm{col}(A)\perp r^*)\end{aligned}$$

Step 2：利用子空间嵌入性质

因为 $A(x-x^*) \in \mathrm{col}(A)$ 且 $r^* = Ax^* - b$ 可以分解为列空间内和列空间外的分量，子空间嵌入保证：

$$(1-\epsilon)\|A(x-x^*)\|^2 \le \|SA(x-x^*)\|^2 \le (1+\epsilon)\|A(x-x^*)\|^2$$

Step 3：比较原问题和压缩问题

$\tilde{x}$ 是压缩问题 $\min_x \|SAx - Sb\|$ 的最优解，所以对任意 x（特别是 x^*）：

$$\|SA\tilde{x} - Sb\|^2 \le \|SAx^* - Sb\|^2$$

利用子空间嵌入性质（需要一些技术细节处理 b 不在列空间的情况），可以得到：

$$(1-\epsilon)\|A\tilde{x} - b\|^2 - \epsilon\|r^*\|^2 \le \|SA\tilde{x} - Sb\|^2 \le \|SAx^* - Sb\|^2 \le (1+\epsilon)\|r^*\|^2$$

整理得：

$$\|A\tilde{x} - b\|^2 \le \frac{1+\epsilon+\epsilon}{1-\epsilon}\|r^*\|^2 = \frac{1+2\epsilon}{1-\epsilon}\|r^*\|^2$$

取平方根并使用 $(1+2\epsilon)/(1-\epsilon) \approx 1+3\epsilon$（当 ϵ 较小时），得到定理的结论。

13.4 如何构造 Sketch 矩阵？

13.4.1 从 JL 引理到子空间嵌入

定理 13.8 (子空间嵌入的存在性)**.** *设 V 是 $\mathbb{R}^n$ 中的 d 维子空间，$\epsilon \in (0,1)$。如果 $S \in \mathbb{R}^{k\times n}$ 的每个元素独立采样自 $N(0,1/k)$，且*

$$k = O\left(\frac{d}{\epsilon^2}\right)$$

则 S 以高概率是 V 的 $(1\pm\epsilon)$ 子空间嵌入。

关键点：k 只依赖于子空间维度 d 和精度 ϵ，**不依赖于**原始维度 n！

例 13.9 (所需的 sketch 维度)**.**

原始维度 n	特征数 d	精度 ϵ	sketch 维度 k
10^8	1000	0.1	≈ 100000
10^8	1000	0.5	≈ 4000
10^8	100	0.1	≈ 10000
10^6	1000	0.1	≈ 100000

观察：k 与 n 完全无关！当 n 从 10^6 变到 10^8（增加 100 倍），k 不变。

13.4.2 证明思路：覆盖网

为什么保持 d 维子空间只需要 $O(d/\epsilon^2)$ 维?

核心想法：用有限个点”覆盖”无限的子空间。

定义 13.10 (δ-网)**.** *集合 $\mathcal{N}$ 称为单位球 S^{d-1} 的 δ-网，如果对任意 $v \in S^{d-1}$，存在 $u \in \mathcal{N}$ 使得 $\|v-u\| \le \delta$。*

引理 13.11 (网的大小)**.** *d 维单位球存在大小为 $(1+2/\delta)^d$ 的 δ-网。*

例 13.12 (网的大小计算)**.** 设 $d = 100$，$\delta = 0.5$。网的大小 $\leq (1+4)^{100} = 5^{100} \approx 10^{70}$。
虽然这个数字很大，但它是 d 的指数，而不是 n 的函数！

证明思路：

1. 构造 V 中单位球的 δ-网 $\mathcal{N}$，大小 $|\mathcal{N}| \leq (3/\delta)^d$
2. 用 JL 引理保证 $\mathcal{N}$ 中所有点的长度被保持：需要 $k = O(\log|\mathcal{N}|/\epsilon^2) = O(d\log(1/\delta)/\epsilon^2)$
3. 用三角不等式从网点推广到整个子空间：如果网点的长度保持误差 $\epsilon/2$，则整个子空间的误差 $\leq \epsilon$

13.4.3 各种 Sketch 矩阵

实际中有多种选择，各有优缺点：

1. 高斯 sketch

$$S_{ij} \sim N(0, 1/k) \text{ 独立}$$

- 优点：理论分析简单，误差界最优
- 缺点：计算 SA 需要 $O(nkd)$ 时间，矩阵 S 本身需要 $O(nk)$ 存储

2. 稀疏嵌入（CountSketch）

$$S_{ij} = \begin{cases} +1/\sqrt{s} & \text{以概率} s/(2n) \\ -1/\sqrt{s} & \text{以概率} s/(2n) \\ 0 & \text{以概率} 1 - s/n \end{cases}$$

每列恰好有 s 个非零元素。

- 优点：计算 SA 只需 $O(\text{nnz}(A))$ 时间（nnz= 非零元素个数）
- 缺点：需要略大的 k 来达到同样精度

例 13.13 (CountSketch 计算过程示例)**.** 假设我们将 $d = 4$ 维向量投影到 $k = 2$ 维，设置稀疏度 $s = 1$（每列仅有一个非零值 ± 1）。
对于输入向量 $x = [x_1, x_2, x_3, x_4]^\top = [10, 20, 30, 40]^\top$：

$$\underbrace{\begin{bmatrix} y_1 \\ y_2 \end{bmatrix}}_{y=Sx} = \underbrace{\begin{bmatrix} 1/\sqrt{2} & 0 & -1/\sqrt{2} & 0 \\ 0 & -1/\sqrt{2} & 0 & 1/\sqrt{2} \end{bmatrix}}_{S \in \{0,\pm 1\}^{2\times 4}} \begin{bmatrix} 10 \\ 20 \\ 30 \\ 40 \end{bmatrix}$$

计算逻辑（哈希与符号翻转）：

- **第 1 行**（桶 1）：收集了 x_1 和 x_3（符号分别为 $+, -$）。
  $\Rightarrow y_1 = 1 \cdot 10 + (-1) \cdot 30 = -20$

- **第 2 行**（桶 2）：收集了 x_2 和 x_4（符号分别为 $-,+$）。
  $\Rightarrow y_2 = (-1)\cdot 20 + 1\cdot 40 = 20$

观察：实际上并没有进行真正的矩阵乘法，只是将输入元素 x_i 以随机符号 σ_i "扔" 进随机的桶 $h(i)$ 中。

直观理解：为什么稀疏投影需要更大的 k？

虽然稀疏投影（Sparse Embedding）极大地加速了矩阵乘法，但它在"信息混合"的效率上不如稠密高斯矩阵，因此通常需要略大的目标维度 k 来补偿精度的损失。

1. **稠密矩阵（全员参与，混合均匀）**：在高斯随机投影中，输出向量的每一个分量 y_i 都是输入向量 x 所有 d 个维度的线性组合。

$$y_i = \sum_{j=1}^{d} G_{ij} x_j$$

   根据**中心极限定理（CLT）**，即使 d 不大，误差也能迅速互相抵消，使得 $\|y\|^2$ 非常紧密地集中在 $\|x\|^2$ 周围。因此，k 仅需满足 $O(\epsilon^{-2}\log n)$ 即可。

2. **稀疏矩阵（抽样参与，混合不足）**：在 CountSketch 中，每个输入维度 x_j 仅对极少数（如 s 个）输出维度有贡献。
   - **最坏情况（稀疏向量风险）**：如果输入向量 x 本身非常稀疏（例如 $x = (100, 1, 0, \ldots, 0)$），其模长主要由那个 100 决定。
   - 在稀疏投影下，这个 100 仅被"扔"进了极少数桶里。如果这几个桶的随机符号没有很好地平衡，或者发生了剧烈的哈希碰撞（Collision），估计的方差就会显著增大。

3. **时空权衡（Time-Space Trade-off）**：为了弥补这种由于"混合不均匀"带来的高方差，我们需要更多的桶（即更大的 k）来保证在大数定律的作用下误差收敛。

$$\text{CountSketch 复杂度：} \quad \underbrace{O(\mathrm{nnz}(A))}_{\text{极快的时间}} \quad \text{vs} \quad \underbrace{k_{\text{sparse}} > k_{\text{dense}}}_{\text{稍大的空间}}$$

3. 子采样随机化 Hadamard 变换（SRHT）

$$S = \sqrt{\frac{n}{k}} PHD$$

其中 D 是随机 ± 1 对角矩阵，H 是 Hadamard 矩阵，P 是随机选取 k 行的采样矩阵。

- 优点：计算 SA 只需 $O(nd\log k)$ 时间（利用快速 Hadamard 变换）
- 缺点：实现较复杂

Sketch 类型	计算 SA 的时间	所需 k	存储 S
高斯	$O(nkd)$	$O(d/\epsilon^2)$	$O(nk)$
稀疏 (CountSketch)	$O(\mathrm{nnz}(A))$	$O(d^2/\epsilon^2)$	$O(n)$
SRHT	$O(nd\log k)$	$O(d/\epsilon^2)$	$O(n)$

例 13.14 (SRHT 的“能量摊平”效应)**.** 设输入维度 $n = 4$，降维目标 $k = 2$。

1. 为什么要预处理 D？假设输入向量是全 1 向量 $x = [1, 1, 1, 1]^\top$（能量分布非常均匀）。如果不乘 D，直接做 Hadamard 变换：

$$Hx = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 4 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

灾难：能量全部集中在第一个分量！如果随机采样 P 恰好没选中第一行，投影后的模长就是 0，误差无穷大。

2. 加入随机符号 D 后的流程：设随机对角矩阵 $D = \mathrm{diag}(1, -1, 1, 1)$。

- **Step 1: 随机翻转（Preconditioning）**
  $z = Dx = [1, -1, 1, 1]^\top$。向量看起来变得“杂乱”了。

- **Step 2: Hadamard 混合（Mixing）**
  利用快速变换计算 $w = Hz$：
  $$w = H \begin{bmatrix} 1 \\ -1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \\ 2 \\ -2 \end{bmatrix}$$
  关键观察：能量从原来的“集中状态”变成了完美的“均匀分布”（每个分量绝对值都是 2）。

- **Step 3: 随机采样（Sampling）**
  无论 P 选取哪两行（比如第 2 和 4 行），都能捕获到成比例的能量，不会出现“漏网之鱼”。最后乘上系数 $\sqrt{n/k}$ 恢复模长即可。

补充背景：Hadamard 变换与快速算法

1. 什么是 Hadamard 矩阵？ Hadamard 矩阵 H_n 是一个 $n \times n$ 的正交矩阵（n 通常为 2 的幂），其元素仅包含 $+1$ 和 -1。它通过 **Sylvester 递归构造法**定义：

$$H_1 = [1], \quad H_{2n} = \begin{bmatrix} H_n & H_n \\ H_n & -H_n \end{bmatrix}$$

例如 $n = 2$ 和 $n = 4$ 时：

$$H_2 = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad H_4 = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \end{bmatrix}$$

它就像一个只由方波（Square Waves）构成的傅里叶变换基底。

2. 为什么它快？(Fast Walsh-Hadamard Transform, FWHT) 直接计算 $y = H_n x$ 需要做矩阵乘法，复杂度为 $O(n^2)$。利用其递归结构，我们可以像 FFT（快速傅里叶变换）一样使用分治法加速：

把向量 x 分为上半部分 x_L 和下半部分 x_R：

$$H_{2n}x = \begin{bmatrix} H_n & H_n \\ H_n & -H_n \end{bmatrix} \begin{bmatrix} x_L \\ x_R \end{bmatrix} = \begin{bmatrix} H_n(x_L + x_R) \\ H_n(x_L - x_R) \end{bmatrix}$$

复杂度分析：设 $T(n)$ 为计算 $H_n x$ 所需的操作次数。

$$T(n) = \underbrace{2T(n/2)}_{\text{两个子问题}} + \underbrace{O(n)}_{\text{向量加减法}}$$

根据主定理（Master Theorem），$T(n) = O(n \log n)$。

核心优势：

- **速度**：从 $O(n^2)$ 降到 $O(n \log n)$。对于 $n = 1024$，速度提升约 100 倍。
- **无乘法**：整个过程只涉及**加法和减法**（因为元素是 ± 1），这在硬件实现上比需要浮点乘法的 FFT 还要快。

直观理解：为什么 SRHT 有效？

SRHT 利用了 **不确定性原理（Uncertainty Principle）**：在频域和时域中，信号不可能同时是稀疏的。

1. **Hadamard 变换的作用**：类似于傅里叶变换，Hadamard 矩阵 H 是一个稠密的混合器。它能将“稀疏”的向量（如标准基）转换为“稠密”的向量（所有分量都不为 0）。
2. **随机对角阵 D 的必要性**：虽然 H 能把稀疏变稠密，但它也能把稠密变稀疏（如 Example 中所示，H 把全 1 向量变成冲击向量）。D **的作用是“平滑化”**：它随机打乱输入信号的相位，确保 Dx 不会落在 H 的“盲区”里。这保证了 HDx 的能量均匀分布在所有坐标上。
3. **采样的安全性**：一旦能量被 H 均匀摊平，随机采样 P 就变得非常安全且准确（类似于从搅拌均匀的咖啡中舀一勺，浓度一定代表整体）。

关于表格的补充说明

- **最好的平衡**：SRHT 结合了 Gaussian 的低维度需求（$k \approx O(d)$）和 CountSketch 的快速计算特性（利用 FFT/FWHT 结构）。
- **表格中的 k**：注意表格中 CountSketch 的 k 依赖于 $O(d^2)$ 或 $O(k^2)$（取决于具体分析），而 SRHT 的 k 几乎与 Gaussian 一样优秀，通常仅多一个 $\log d$ 因子：$k \sim O(\epsilon^{-2} \log d)$。这使得 SRHT 在高精度要求下比 CountSketch 更具优势。

13.5 复杂度分析

13.5.1 总体复杂度

设我们使用 SRHT 作为 sketch 矩阵，$k = O(d/\epsilon^2)$。
精确求解：$O(nd^2)$
Sketch-and-Solve：

1. 计算 SA：$O(nd\log k)$
2. 计算 Sb：$O(n\log k)$
3. 求解压缩问题：$O(kd^2) = O(d^3/\epsilon^2)$
4. 总计：$O(nd\log(d/\epsilon) + d^3/\epsilon^2)$

例 13.15 (加速比计算)**.** 设 $n = 10^8$，$d = 1000$，$\epsilon = 0.1$。
精确求解：$O(nd^2) = O(10^8 \times 10^6) = O(10^{14})$
Sketch-and-Solve：

- $k = O(d/\epsilon^2) = O(10^5)$
- 计算 SA：$O(nd\log k) = O(10^8 \times 1000 \times 17) \approx O(1.7 \times 10^{12})$
- 求解压缩问题：$O(kd^2) = O(10^5 \times 10^6) = O(10^{11})$
- 总计：$O(1.7 \times 10^{12})$

加速比：$\frac{10^{14}}{1.7\times10^{12}} \approx 60$ 倍！
代价：残差增加最多 $(1 + O(\epsilon)) = 1.3$ 倍。

13.5.2 何时 Sketch 方法更优？

Sketch-and-Solve 的优势在 $n \gg d$ 时最明显。
临界点分析：当 $nd\log k < nd^2$，即 $\log k < d$ 时，sketch 方法更快。
因为 $k = O(d/\epsilon^2)$，所以 $\log k = O(\log d)$，这个条件几乎总是满足的。
真正的收益：把 $O(nd^2)$ 中对 n 的线性依赖变成了 $O(nd\log k)$，从 d^2 变成了 $d\log k$。

例 13.16 (不同 n/d 比例的比较)**.** 固定 $d = 1000$，$\epsilon = 0.1$：

n	n/d	精确方法	Sketch 方法	加速比
10^4	10	10^{10}	10^9	10x
10^6	10^3	10^{12}	2×10^{10}	50x
10^8	10^5	10^{14}	2×10^{12}	50x
10^{10}	10^7	10^{16}	2×10^{14}	50x

当 n/d 超过某个阈值后，加速比趋于稳定（约 $d/\log k$ 倍）。

13.6 实际应用与扩展

13.6.1 应用场景

1. 大规模线性回归

- 互联网广告点击率预测：数十亿样本，数千特征
- 推荐系统中的矩阵分解

2. 核岭回归的近似

- 原问题需要 $O(n^3)$ 时间
- 用随机特征 +sketch 可以降到近乎线性时间

3. 流式/在线学习

- 数据以流的形式到达
- 维护 sketch SA 和 Sb，可以增量更新
- 空间只需 $O(kd)$ 而不是 $O(nd)$

13.6.2 迭代精化

Sketch-and-Solve 得到的是近似解。如果需要更高精度，可以用迭代方法精化：**Sketch-and-Precondition**：

1. 用 sketch 方法计算 $R = \text{Cholesky}(SA)^T(SA)$
2. 用 R 作为预条件子，运行迭代方法（如 LSQR）
3. 预条件子大幅加速收敛

这种方法可以达到机器精度，同时保持 sketch 方法的计算优势。

13.6.3 与其他方法的比较

方法	时间复杂度	精度	适用场景
精确 QR	$O(nd^2)$	精确	小规模
随机梯度下降	$O(nd/\epsilon)$	ϵ-近似	在线学习
Sketch-and-Solve	$O(nd\log k + d^3/\epsilon^2)$	$(1+\epsilon)$-近似	大规模批处理
Sketch + 迭代	$O(nd\log k + d^3\log(1/\epsilon))$	ϵ-精确	需要高精度

注 13.17 (如何选择？).
- 如果 n 不太大（$n < 10^5$），直接用精确方法
- 如果只需要粗略近似且数据在线到达，用 SGD
- 如果 n 很大、需要 $(1+\epsilon)$ 近似、数据可以批处理，用 Sketch-and-Solve
- 如果需要高精度，用 Sketch 作为预条件子加速迭代方法

评论：Sketching 回归与经典渐近理论的本质区别

尽管 Sketching 方法（如 CountSketch、SRHT）和经典统计渐近理论（Asymptotic Theory）都涉及“大样本”和“近似”，但它们的哲学出发点和数学保证截然不同。

1. **随机性的来源（Algorithmic vs. Statistical Randomness）**
   - **经典理论**：假设算法是确定的（如最小二乘法 OLS），误差来源于**数据的生成过程**（即噪声 ϵ）。关注的是当 $n \to \infty$ 时，估计量 $\hat{\beta}$ 是否收敛到真实参数 β_{true}（一致性）。
   - **Sketching**：假设数据 X, y 是固定的（Fixed Design），误差来源于**算法内部的随机投影** S。我们不关心数据的分布，而是关心“无论数据多么糟糕，随机投影以高概率（w.h.p.）给出一个好解”。
2. **近似的目标（Loss vs. Parameters）**
   - **经典理论**：追求参数估计的**效率（Efficiency）**，即在无偏估计中方差最小（BLUE 性质）。
   - **Sketching**：通常追求**目标函数的近似（Cost Approximation）**。RandNLA 的典型保证形式为：
     $$\|X\tilde{\beta} - y\|^2 \leq (1+\epsilon) \min_{\beta} \|X\beta - y\|^2$$
     即它保证能找到一个“预测效果几乎一样好”的解，但不一定保证 $\tilde{\beta}$ 在欧氏距离上非常接近 $\hat{\beta}_{OLS}$（除非矩阵具有强凸性/条件数很好）。
3. **偏差与方差的权衡**
   - 使用 Sketching 求出的解 $\tilde{\beta} = (X^T S^T S X)^{-1} X^T S^T S y$ 往往是原始 OLS 解的一个**有偏估计**（或者是方差膨胀后的估计）。
   - Sketching 可以被视为一种**计算换精度的交易**：我们主动引入了额外的“算法噪声”（通过降低维度 $k \ll n$），以换取从 $O(nd^2)$ 到 $O(\text{nnz}(A) + d^3)$ 的计算加速。只要 k 足够大，这种算法噪声通常远小于原始数据的统计噪声。

一句话总结：经典理论问的是“我有多少数据才能接近真理?”，而 Sketching 问的是“我可以扔掉多少数据，却依然不偏离最优解太多?”。

14 理论对比：经典统计推断 vs. 随机数值线性代数 (RandNLA)

符号约定：在此对比中，我们考虑线性回归问题 $y = X\beta + \epsilon$。

- n：样本量（X 的行数，通常极大）。
- d：特征维度（X 的列数，即未知参数 β 的维度）。
- k：Sketching 后的样本量（降维后的行数）。

我们通过回答同一个问题来对比这两套理论：“为了保证得到一个好的解 β，我们需要多少样本?”

14.1 1. 经典统计学习理论 (Classical Statistical Learning)

背景假设：数据矩阵 $X \in \mathbb{R}^{n\times d}$ 的每一行 (x_i, y_i) 都是**随机生成**的，独立同分布 (i.i.d.) 采样自某个分布。

- **关注点**：**泛化误差 (Generalization Error)**。即：在 n 个样本上训练出的 $\hat{\beta}$，能否在新的测试数据上表现良好?
- **样本量要求 (n vs d)**：根据统计学习理论（如 VC 维），为了防止过拟合并不以概率 $1-\delta$ 保证误差界限，真实样本量 n 必须显著大于特征维度 d。通常要求：

$$n \gtrsim O\left(\frac{d+\log(1/\delta)}{\epsilon^2}\right)$$

- **直觉 (大数定律)**：这里的 n 是对抗噪声的武器。我们需要足够多的 n 来“平均”掉噪声 ϵ，从而让真实的信号结构（维度为 d）浮现出来。

14.2 2. 随机投影/Sketching 理论 (RandNLA)

背景假设：数据矩阵 $X \in \mathbb{R}^{n\times d}$ 是**固定**的 (Fixed Design)，即便是最坏情况（Worst-case）的数据。随机性仅来源于算法生成的投影矩阵 $S \in \mathbb{R}^{k\times n}$。

- **关注点**：**算法逼近误差 (Algorithmic Approximation)**。即：我们不解原始的 n 行方程组，而是解压缩后的 k 行方程组 $\min \|S(X\beta - y)\|^2$。求出的解 $\tilde{\beta}$ 能否接近原始最优解?
- **Sketch 维度要求 (k vs d)**：为了保证解的相对误差在 $(1+\epsilon)$ 范围内，压缩后的行数 k 并不依赖于原始样本量 n，而只依赖于特征维度 d。通常只需：

$$k \gtrsim O\left(\frac{d\log d}{\epsilon^2}\right) \quad \text{(SRHT 或 Leverage Score)}$$

  关键点：即使原始数据 $n = 100$ 亿，只要特征 $d = 50$，我们只需要保留 $k \approx 2000$ 行左右的数据即可求解，与 n 无关。

- **直觉 (子空间嵌入)**：这是利用高维几何的性质。X 的列空间构成了一个 d 维子空间。Sketching 矩阵 S 的作用是把这个子空间“保距”地嵌入到低维空间中。只要 k 足够容纳 d 维信息，解就是准的。

14.3 3. 深入：高维概率论的“反直觉”特点

Sketching 之所以有效，是因为高维空间具有一些与二维/三维直觉截然不同的性质。

14.3.1 A. 测度集中现象 (Concentration of Measure)

在低维空间，质量分布在整个球体内部。但在高维空间 $(d \to \infty)$，**几乎所有的质量都集中在球壳表面，甚至集中在赤道附近的一条窄带上**。

对于高维单位球体上的 Lipschitz 函数 f，其值偏离均值的概率呈指数级下降：

$$\mathbb{P}(|f(x) - \mathbb{E}[f]| \geq t) \leq 2\exp(-Cdt^2)$$

意义：当我们把向量投影到随机子空间时，它的模长不仅仅是“平均”等于原模长，而是**以极大概率非常精确地等于**原模长。在高维空间，“随机”意味着“确定”。

14.3.2 B. 准正交性 (Quasi-Orthogonality)

在低维空间，两个随机向量很少垂直。但在高维空间，**任意两个独立的随机向量，以极大概率几乎是垂直的**。

意义：随机投影矩阵 S 的每一行都捕捉了原始空间的一个独立“切面”，行与行之间几乎没有冗余信息。

14.3.3 C. 维度诅咒 vs. 维度祝福

- **诅咒 (Curse)**：在经典优化中，d 越大，搜索空间呈指数爆炸，需要更多的 n 来填满空间。
- **祝福 (Blessing)**：在高维概率论中，d 越大，随机变量的方差越小，统计规律越稳定。Sketching 正是利用这种“高维祝福”来实现降维。

14.4 4. 总结对比表

特性	经典统计推断 (IID)	高维 Sketching 理论
核心工具	大数定律, 中心极限定理	测度集中, JL 引理
数据假设	随机生成 (IID)	任意固定 (Worst-case)
随机性来源	数据本身 (噪声)	算法引入 (投影矩阵 S)
追求目标	参数收敛 ($\hat{\beta} \to \beta^*$)	目标函数近似 (Cost Preservation)
样本/维度关系	$n \gg d$ (越多越好)	$k \gtrsim d \log d$ (与 n 无关)
高维视角	维度是负担 (Curse)	维度带来稳定性 (Blessing)

15 随机矩阵乘法：用采样加速计算

15.1 问题的提出（0:25–0:30）

15.1.1 矩阵乘法的计算瓶颈

矩阵乘法是科学计算中最基础也最耗时的操作之一。给定 $A \in \mathbb{R}^{m\times n}$ 和 $B \in \mathbb{R}^{n\times p}$，计算乘积 AB 的标准算法需要 $O(mnp)$ 次运算。

例 15.1 (具体规模感受)**.** 在推荐系统中，我们经常需要计算用户-商品评分矩阵的低秩分解。假设：

- 用户矩阵 $A \in \mathbb{R}^{10^6\times 10^4}$（100 万用户，1 万维隐因子）
- 商品矩阵 $B \in \mathbb{R}^{10^4\times 10^5}$（1 万维隐因子，10 万商品）
- 计算 AB 需要 $10^6 \times 10^4 \times 10^5 = 10^{15}$ 次运算
- 即使每秒 10^{12} 次运算（1 TFLOP），也需要 1000 秒 ≈17 分钟

如果只需要一个近似结果，能否大幅加速？

15.1.2 矩阵乘法的外积视角

理解随机化方法的关键是换一个视角看矩阵乘法。

传统视角（内积）：$(AB)_{ij} = \sum_{k=1}^{n} A_{ik}B_{kj}$，即 A 的第 i 行与 B 的第 j 列的内积。

外积视角：把 AB 写成 n 个秩 1 矩阵的和：

$$AB = \sum_{i=1}^{n} A_{\cdot i}B_{i\cdot}$$

其中 $A_{\cdot i} \in \mathbb{R}^{m\times 1}$ 是 A 的第 i 列，$B_{i\cdot} \in \mathbb{R}^{1\times p}$ 是 B 的第 i 行。

例 15.2 (外积分解的具体例子)**.** 设

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}, \quad B = \begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix}$$

传统计算：

$$AB = \begin{pmatrix} 1\times 5 + 2\times 7 & 1\times 6 + 2\times 8 \\ 3\times 5 + 4\times 7 & 3\times 6 + 4\times 8 \end{pmatrix} = \begin{pmatrix} 19 & 22 \\ 43 & 50 \end{pmatrix}$$

外积视角：

$$\begin{aligned} AB &= \underbrace{\begin{pmatrix} 1 \\ 3 \end{pmatrix}\begin{pmatrix} 5 & 6 \end{pmatrix}}_{\text{第 1 列×第 1 行}} + \underbrace{\begin{pmatrix} 2 \\ 4 \end{pmatrix}\begin{pmatrix} 7 & 8 \end{pmatrix}}_{\text{第 2 列×第 2 行}} \\ &= \begin{pmatrix} 5 & 6 \\ 15 & 18 \end{pmatrix} + \begin{pmatrix} 14 & 16 \\ 28 & 32 \end{pmatrix} = \begin{pmatrix} 19 & 22 \\ 43 & 50 \end{pmatrix} \end{aligned}$$

随机化的核心思想：既然 AB 是 n 项的和，我们能否只随机采样 k 项（$k \ll n$），用这 k 项来近似整个和？这就像用民意调查（采样 1000 人）来估计全国的投票意向（上亿人）。

15.2 随机采样算法（0:30–0:35）

15.2.1 算法描述

输入：矩阵 $A \in \mathbb{R}^{m\times n}$，$B \in \mathbb{R}^{n\times p}$，采样次数 k

算法：

1. **选择采样概率**：确定概率分布 $p_1, \ldots, p_n$，满足 $\sum_{i=1}^{n} p_i = 1$，$p_i > 0$
2. **独立采样 k 次**：每次以概率 p_i 选中索引 i
3. **构造缩放后的列和行**：设第 t 次采样选中了索引 i_t，构造

$$C_t = \frac{1}{\sqrt{kp_{i_t}}} A_{\cdot i_t}, \quad R_t = \frac{1}{\sqrt{kp_{i_t}}} B_{i_t\cdot}$$

4. **输出**：$\widetilde{AB} = CR = \sum_{t=1}^{k} C_t R_t$

输出形式：实际上我们构造了两个矩阵 $C \in \mathbb{R}^{m\times k}$ 和 $R \in \mathbb{R}^{k\times p}$，输出 CR。

15.2.2 为什么需要缩放因子 $\frac{1}{\sqrt{kp_i}}$？

这个看起来奇怪的缩放因子是为了保证**无偏性**——即估计量的期望等于真实值。

例 15.3 (不缩放会怎样？)**.** 考虑最简单的情况：$n = 2$，均匀采样（$p_1 = p_2 = 1/2$），采样 $k = 1$ 次。

如果不缩放，我们的估计是：

$$\widetilde{AB} = \begin{cases} A_{\cdot 1}B_{1\cdot} & \text{概率}1/2 \\ A_{\cdot 2}B_{2\cdot} & \text{概率}1/2 \end{cases}$$

期望是：

$$\mathbb{E}[\widetilde{AB}] = \frac{1}{2}A_{\cdot 1}B_{1\cdot} + \frac{1}{2}A_{\cdot 2}B_{2\cdot} = \frac{1}{2}AB$$

这只有真实值的一半！我们**低估**了。

15.2.3 无偏性的严格验证

设第 t 次采样选中索引 i_t，则单次采样的贡献是：

$$C_tR_t = \frac{1}{kp_{i_t}}A_{\cdot i_t}B_{i_t\cdot}$$

计算期望：

$$\begin{aligned}
\mathbb{E}[C_tR_t] &= \sum_{i=1}^{n} P(i_t = i) \cdot \frac{1}{kp_i}A_{\cdot i}B_{i\cdot} \\
&= \sum_{i=1}^{n} p_i \cdot \frac{1}{kp_i}A_{\cdot i}B_{i\cdot} \quad (\text{因为 } P(i_t = i) = p_i) \\
&= \frac{1}{k}\sum_{i=1}^{n} A_{\cdot i}B_{i\cdot} \\
&= \frac{1}{k}AB
\end{aligned}$$

因为 k 次采样独立，所以：

$$\mathbb{E}[CR] = \mathbb{E}\left[\sum_{t=1}^{k} C_tR_t\right] = \sum_{t=1}^{k}\mathbb{E}[C_tR_t] = k \cdot \frac{1}{k}AB = AB$$

结论：无论选择什么采样概率 p_i（只要都是正的），估计量都是无偏的！

例 15.4 (完整的数值例子)**.** 继续用之前的例子：

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}, \quad B = \begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix}, \quad AB = \begin{pmatrix} 19 & 22 \\ 43 & 50 \end{pmatrix}$$

设 $k = 1$，均匀采样 $p_1 = p_2 = 1/2$。

情况 1：采样选中 $i = 1$

$$\widetilde{AB} = \frac{1}{1 \times 0.5}\begin{pmatrix} 1 \\ 3 \end{pmatrix}\begin{pmatrix} 5 & 6 \end{pmatrix} = 2\begin{pmatrix} 5 & 6 \\ 15 & 18 \end{pmatrix} = \begin{pmatrix} 10 & 12 \\ 30 & 36 \end{pmatrix}$$

情况 2：采样选中 $i = 2$

$$\widetilde{AB} = \frac{1}{1 \times 0.5} \begin{pmatrix} 2 \\ 4 \end{pmatrix} \begin{pmatrix} 7 & 8 \end{pmatrix} = 2 \begin{pmatrix} 14 & 16 \\ 28 & 32 \end{pmatrix} = \begin{pmatrix} 28 & 32 \\ 56 & 64 \end{pmatrix}$$

验证无偏性：

$$\mathbb{E}[\widetilde{AB}] = \frac{1}{2} \begin{pmatrix} 10 & 12 \\ 30 & 36 \end{pmatrix} + \frac{1}{2} \begin{pmatrix} 28 & 32 \\ 56 & 64 \end{pmatrix} = \begin{pmatrix} 19 & 22 \\ 43 & 50 \end{pmatrix} = AB \quad \checkmark$$

注意虽然期望正确，但单次估计的误差很大（例如情况 1 的 $(1,1)$ 元素是 10，真实值是 19）。

15.2.4 计算复杂度

精确计算 AB：$O(mnp)$

随机采样方法：

- 采样 k 个索引：$O(k)$（如果预处理了累积概率）或 $O(k \log n)$（二分查找）
- 构造 C：复制 A 的 k 列并缩放，$O(mk)$
- 构造 R：复制 B 的 k 行并缩放，$O(kp)$
- 计算 CR：$O(mkp)$
- 总计：$O(mkp)$

加速比：$\frac{mnp}{mkp} = \frac{n}{k}$。如果 $k = n/100$，则快 100 倍！

15.3 误差分析（0:35–0:40）

无偏性只说期望正确，但我们更关心：单次估计离真实值有多远？

15.3.1 误差的度量

我们用 Frobenius 范数来度量误差：

$$\|AB - CR\|_F = \sqrt{\sum_{i,j} (AB - CR)_{ij}^2}$$

这衡量的是”所有元素的均方误差”的总和。

15.3.2 误差界定理

定理 15.5 (随机矩阵乘法的误差界)**.** *设采样概率选择为*

$$p_i = \frac{\|A_{\cdot i}\| \cdot \|B_{i\cdot}\|}{\sum_{j=1}^{n} \|A_{\cdot j}\| \cdot \|B_{j\cdot}\|}$$

(即按列范数与行范数的乘积成比例采样)，则

$$\mathbb{E}\|AB - CR\|_F^2 \leq \frac{\|A\|_F^2 \cdot \|B\|_F^2}{k}$$

其中 $\|A\|_F = \sqrt{\sum_{i,j} A_{ij}^2}$ *是 Frobenius 范数。*

注 15.6 (理解这个界).

- 误差随 k **线性下降**：k 翻倍，期望误差平方减半，即误差减少 $\sqrt{2} \approx 1.41$ 倍
- 误差与 $\|A\|_F$ 和 $\|B\|_F$ 成正比：矩阵元素越大，绝对误差越大（但相对误差可能不变）
- 这个界是**数据依赖**的：取决于 A 和 B 的范数结构

例 15.7 (误差界的具体计算)**.** 设 $A, B \in \mathbb{R}^{1000\times1000}$，每个元素独立地从 $N(0,1)$ 采样。

范数的期望：$\mathbb{E}[\|A\|_F^2] = 1000 \times 1000 \times 1 = 10^6$，所以 $\|A\|_F \approx 1000$。

乘积的范数：$\|AB\|_F \approx 1000 \times 1000 = 10^6$（这是一个粗略估计）。

误差界：

$$\mathbb{E}\|AB - CR\|_F^2 \le \frac{10^6 \times 10^6}{k} = \frac{10^{12}}{k}$$

如果我们想要相对误差 $\frac{\|AB-CR\|_F}{\|AB\|_F} \le 1\%$，需要：

$$\frac{\sqrt{10^{12}/k}}{10^6} \le 0.01 \implies \frac{10^6}{\sqrt{k}} \le 10^4 \implies k \ge 10^4$$

即采样 1 万次（原本需要求和 100 万项），就能达到 1% 的相对误差。加速 100 倍!

15.3.3 误差界的证明思路

核心工具：方差分解。对于独立随机变量的和，方差等于各项方差之和。

设 $X = CR - AB = \sum_{t=1}^{k}(C_tR_t - \frac{1}{k}AB)$。因为 $\mathbb{E}[C_tR_t] = \frac{1}{k}AB$，所以每一项都是零均值的。

$$\mathbb{E}\|X\|_F^2 = \mathbb{E}\left\|\sum_{t=1}^{k}\left(C_tR_t - \frac{1}{k}AB\right)\right\|_F^2$$

因为各项独立且零均值：

$$= \sum_{t=1}^{k}\mathbb{E}\left\|C_tR_t - \frac{1}{k}AB\right\|_F^2 = k \cdot \mathrm{Var}(C_1R_1)$$

（这里用到了 k 次采样是独立同分布的）

关键是计算单次采样的方差 $\mathrm{Var}(C_1R_1)$。经过计算（利用 $\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$），可以证明当采样概率选择为 $p_i \propto \|A_{\cdot i}\|\|B_{i\cdot}\|$ 时，方差达到最小，且满足定理中的界。

15.3.4 误差界的完整证明

我们要证明：当采样概率 $p_i \propto \|A_{\cdot i}\|\|B_{i\cdot}\|$ 时，

$$\mathbb{E}\|AB - CR\|_F^2 \le \frac{\|A\|_F^2 \cdot \|B\|_F^2}{k}$$

Step 1：方差分解

设 $Y_t = C_tR_t - \frac{1}{k}AB$。由于 $\mathbb{E}[C_tR_t] = \frac{1}{k}AB$，所以 Y_t 是零均值随机矩阵。

误差可以写成：

$$CR - AB = \sum_{t=1}^{k} C_t R_t - AB = \sum_{t=1}^{k} \left(C_t R_t - \frac{1}{k} AB \right) = \sum_{t=1}^{k} Y_t$$

对于独立零均值随机矩阵，Frobenius 范数的平方满足可加性：

$$\mathbb{E} \left\| \sum_{t=1}^{k} Y_t \right\|_F^2 = \sum_{t=1}^{k} \mathbb{E} \|Y_t\|_F^2 = k \cdot \mathbb{E} \|Y_1\|_F^2$$

Step 2：计算单次采样的方差

展开 $\mathbb{E}\|Y_1\|_F^2$：

$$\begin{aligned}
\mathbb{E}\|Y_1\|_F^2 &= \mathbb{E} \left\| C_1 R_1 - \frac{1}{k} AB \right\|_F^2 \\
&= \mathbb{E}\|C_1 R_1\|_F^2 - 2 \left\langle \mathbb{E}[C_1 R_1], \frac{1}{k} AB \right\rangle_F + \left\| \frac{1}{k} AB \right\|_F^2 \\
&= \mathbb{E}\|C_1 R_1\|_F^2 - 2 \left\langle \frac{1}{k} AB, \frac{1}{k} AB \right\rangle_F + \frac{1}{k^2} \|AB\|_F^2 \\
&= \mathbb{E}\|C_1 R_1\|_F^2 - \frac{1}{k^2} \|AB\|_F^2
\end{aligned}$$

现在计算 $\mathbb{E}\|C_1 R_1\|_F^2$。注意 $C_1 R_1 = \frac{1}{k p_{i_1}} A_{\cdot i_1} B_{i_1 \cdot}$ 是秩 1 矩阵，其 Frobenius 范数为：

$$\|C_1 R_1\|_F^2 = \frac{1}{k^2 p_{i_1}^2} \|A_{\cdot i_1}\|^2 \|B_{i_1 \cdot}\|^2$$

（这里用到了秩 1 矩阵 uv^T 的性质：$\|uv^T\|_F^2 = \|u\|^2 \|v\|^2$）

取期望：

$$\mathbb{E}\|C_1 R_1\|_F^2 = \sum_{i=1}^{n} p_i \cdot \frac{\|A_{\cdot i}\|^2 \|B_{i \cdot}\|^2}{k^2 p_i^2} = \frac{1}{k^2} \sum_{i=1}^{n} \frac{\|A_{\cdot i}\|^2 \|B_{i \cdot}\|^2}{p_i}$$

因此：

$$\mathbb{E}\|CR - AB\|_F^2 = k \cdot \mathbb{E}\|Y_1\|_F^2 = \frac{1}{k} \sum_{i=1}^{n} \frac{\|A_{\cdot i}\|^2 \|B_{i \cdot}\|^2}{p_i} - \frac{1}{k} \|AB\|_F^2$$

Step 3：最优采样概率（第一次用柯西不等式）

现在问题变成：如何选择 p_i（满足 $\sum_i p_i = 1$）使得 $\sum_{i=1}^{n} \frac{\|A_{\cdot i}\|^2 \|B_{i \cdot}\|^2}{p_i}$ 最小?

记 $a_i = \|A_{\cdot i}\| \|B_{i \cdot}\|$，我们要最小化 $\sum_{i=1}^{n} \frac{a_i^2}{p_i}$。

应用**柯西-施瓦茨不等式**（向量形式：$(\sum x_i y_i)^2 \le (\sum x_i^2)(\sum y_i^2)$）：

令 $x_i = \frac{a_i}{\sqrt{p_i}}$，$y_i = \sqrt{p_i}$，则：

$$\left(\sum_{i=1}^{n} a_i \right)^2 = \left(\sum_{i=1}^{n} x_i y_i \right)^2 \le \left(\sum_{i=1}^{n} \frac{a_i^2}{p_i} \right) \cdot \left(\sum_{i=1}^{n} p_i \right) = \sum_{i=1}^{n} \frac{a_i^2}{p_i}$$

即：

$$\sum_{i=1}^{n} \frac{a_i^2}{p_i} \ge \left(\sum_{i=1}^{n} a_i \right)^2$$

等号成立当且仅当 $\frac{x_i}{y_i} = \text{const}$，即 $\frac{a_i}{p_i} = \text{const}$，即：

$$p_i = \frac{a_i}{\sum_j a_j} = \frac{\|A_{\cdot i}\|\|B_{i\cdot}\|}{\sum_j \|A_{\cdot j}\|\|B_{j\cdot}\|}$$

这正是" 按乘积采样" 的策略！

Step 4：最终误差界（第二次用柯西不等式）

当采用最优采样概率时：

$$\sum_{i=1}^{n} \frac{\|A_{\cdot i}\|^2\|B_{i\cdot}\|^2}{p_i} = \left(\sum_{i=1}^{n} \|A_{\cdot i}\|\|B_{i\cdot}\|\right)^2$$

再次应用**柯西-施瓦茨不等式**：

$$\left(\sum_{i=1}^{n} \|A_{\cdot i}\|\|B_{i\cdot}\|\right)^2 \leq \left(\sum_{i=1}^{n} \|A_{\cdot i}\|^2\right) \cdot \left(\sum_{i=1}^{n} \|B_{i\cdot}\|^2\right) = \|A\|_F^2 \cdot \|B\|_F^2$$

将所有结果代入：

$$\begin{aligned}
\mathbb{E}\|CR - AB\|_F^2 &= \frac{1}{k}\sum_{i=1}^{n} \frac{\|A_{\cdot i}\|^2\|B_{i\cdot}\|^2}{p_i} - \frac{1}{k}\|AB\|_F^2 \\
&\leq \frac{1}{k}\|A\|_F^2\|B\|_F^2 - \frac{1}{k}\|AB\|_F^2 \\
&\leq \frac{\|A\|_F^2\|B\|_F^2}{k}
\end{aligned}$$

证毕。□

注 15.8 (两次柯西不等式的作用).

- **第一次** (Step 3)：确定最优采样概率。这告诉我们应该按 $\|A_{\cdot i}\|\|B_{i\cdot}\|$ 成比例采样。
- **第二次** (Step 4)：将最优方差界 $(\sum_i \|A_{\cdot i}\|\|B_{i\cdot}\|)^2$ 进一步放缩为更简洁的形式 $\|A\|_F^2\|B\|_F^2$。

注 15.9 (界的紧度). 第二次柯西不等式的等号成立条件是 $\|A_{\cdot i}\| = c\|B_{i\cdot}\|$ 对所有 i 成立（即 A 的列范数与 B 对应行的范数成比例）。如果 A 和 B 的范数结构差异很大，实际误差会比界更小。

例 15.10 (验证界的合理性)**.** 考虑 $A = B = I_n$（$n \times n$ 单位矩阵）。

- $AB = I_n$，$\|AB\|_F^2 = n$
- $\|A\|_F^2 = \|B\|_F^2 = n$
- 每列/行范数相等：$\|A_{\cdot i}\| = \|B_{i\cdot}\| = 1$
- 最优采样是均匀采样：$p_i = 1/n$

误差界：

$$\mathbb{E}\|I_n - CR\|_F^2 \leq \frac{n \cdot n}{k} = \frac{n^2}{k}$$

相对误差：

$$\frac{\mathbb{E}\|I_n - CR\|_F^2}{\|I_n\|_F^2} \leq \frac{n^2/k}{n} = \frac{n}{k}$$

要使相对误差 $\leq \epsilon^2$，需要 $k \geq n/\epsilon^2$。这说明对于" 均匀" 的矩阵，需要采样 $\Omega(n)$ 次才能得到好的近似，没有太多加速空间。

但如果矩阵是" 不均匀" 的（少数列/行贡献了大部分范数），按乘积采样的优势就会显现。

15.4 采样策略对比（0:40–0:45）

采样概率 p_i 的选择对误差有巨大影响。虽然任何正的 p_i 都能保证无偏性，但方差可能天差地别。

15.4.1 三种采样策略

策略 1：均匀采样

$$p_i = \frac{1}{n}$$

最简单，不需要任何预处理。

策略 2：按 A 的列范数采样

$$p_i = \frac{\|A_{\cdot i}\|^2}{\|A\|_F^2}$$

直觉：A 中”重要”的列应该更多地被采样。

策略 3：按乘积采样（最优）

$$p_i = \frac{\|A_{\cdot i}\| \cdot \|B_{i\cdot}\|}{\sum_{j=1}^{n} \|A_{\cdot j}\| \cdot \|B_{j\cdot}\|}$$

同时考虑 A 的列和 B 的行的重要性。

15.4.2 方差界对比

策略	方差界	最坏情况
均匀采样	$\dfrac{n \cdot \max_i \|A_{\cdot i}\|^2 \|B_{i\cdot}\|^2}{k}$	很大
按 A 范数采样	$\dfrac{\|A\|_F^2 \cdot \max_i \|B_{i\cdot}\|^2}{k}$	中等
按乘积采样	$\dfrac{\|A\|_F^2 \cdot \|B\|_F^2}{k}$	最小

关键区别：均匀采样的界中有 max，按乘积采样的界中没有。当数据不均匀时（某些列/行的范数远大于其他），这个区别是巨大的。

例 15.11 (不均匀数据下的对比)**.** 考虑一个极端情况：A 有 $n = 1000$ 列，其中：

- 第 1 列的范数 $\|A_{\cdot 1}\| = 100$
- 其余 999 列的范数都是 $\|A_{\cdot i}\| = 1$（$i = 2, \ldots, 1000$）

类似地，B 的第 1 行范数 $\|B_{1\cdot}\| = 100$，其余行范数都是 1。

计算各种量：

$$\|A\|_F^2 = 100^2 + 999 \times 1^2 = 10000 + 999 = 10999 \approx 1.1 \times 10^4$$

$$\|B\|_F^2 \approx 1.1 \times 10^4$$

$$\max_i \|A_{\cdot i}\|^2 \|B_{i\cdot}\|^2 = 100^2 \times 100^2 = 10^8$$

均匀采样的方差界：

$$\frac{n \cdot \max_i \|A_{\cdot i}\|^2 \|B_{i\cdot}\|^2}{k} = \frac{1000 \times 10^8}{k} = \frac{10^{11}}{k}$$

按乘积采样的方差界：

$$\frac{\|A\|_F^2 \cdot \|B\|_F^2}{k} = \frac{1.1 \times 10^4 \times 1.1 \times 10^4}{k} \approx \frac{1.2 \times 10^8}{k}$$

比值：$\frac{10^{11}}{1.2\times10^8} \approx 830$

按乘积采样的方差比均匀采样小 **830 倍**！换句话说，要达到同样的精度，均匀采样需要 830 倍的采样次数。

15.4.3 直观解释

为什么按乘积采样最优？

外积的贡献不均匀：在 $AB = \sum_{i=1}^n A_{\cdot i} B_{i\cdot}$ 中，第 i 项的"大小"大约是 $\|A_{\cdot i}\| \cdot \|B_{i\cdot}\|$。有些项贡献很大，有些很小。

均匀采样的问题：每一项被选中的概率相同。但如果我们漏掉了一个大项，误差就很大；如果漏掉小项，影响不大。均匀采样对大项和小项一视同仁，导致方差很大。

按乘积采样的优势：大项被选中的概率更高。这确保了重要的项不太可能被遗漏，从而控制了方差。

注 15.12 (与重要性采样的联系). 这正是蒙特卡洛方法中**重要性采样** (importance sampling) 的思想：对"重要"的样本赋予更高的采样概率，同时用适当的权重修正，保持无偏性的同时降低方差。

15.4.4 预处理的代价

按乘积采样需要预先计算 $\|A_{\cdot i}\|$ 和 $\|B_{i\cdot}\|$：

- 计算所有 $\|A_{\cdot i}\|$：$O(mn)$
- 计算所有 $\|B_{i\cdot}\|$：$O(np)$
- 总预处理：$O(n(m+p))$

这比直接计算 AB（$O(mnp)$）便宜得多（当 m, p 都较大时）。

例 15.13 (预处理代价 vs 加速收益)**.** 设 $m = n = p = 10000$。

- 直接计算 AB：$O(10^{12})$ 次运算
- 预处理（计算范数）：$O(2 \times 10^8)$ 次运算
- 采样 $k = 1000$ 次并计算 CR：$O(10^{11})$ 次运算
- 总计：$O(1.02 \times 10^{11})$ 次运算

加速比：$\frac{10^{12}}{1.02\times10^{11}} \approx 9.8$ 倍，同时误差可控。

15.5 实际应用与扩展

15.5.1 何时使用随机矩阵乘法？

适合的场景：

- 只需要近似结果，不需要精确答案
- 矩阵非常大，精确计算太慢
- 矩阵有”不均匀”的结构（某些行/列更重要）
- 需要多次计算类似的矩阵乘积（可以复用采样）

不适合的场景：

- 需要精确结果（如求解线性方程组）
- 矩阵较小，精确计算已经很快
- 对误差非常敏感的应用

15.5.2 与其他技术的结合

与低秩近似结合：如果 A 或 B 可以近似为低秩矩阵，可以先做低秩近似，再做随机采样。
与稀疏矩阵技术结合：如果 A 或 B 是稀疏的，可以设计专门的采样策略利用稀疏性。
与 GPU 并行结合：采样和外积计算都可以高度并行化。

15.5.3 从矩阵乘法到更复杂的线性代数

随机采样的思想可以推广到：

- **随机 SVD**：用随机投影加速奇异值分解
- **随机迹估计**：估计 $\mathrm{tr}(A)$ 而不显式计算
- **随机求解线性系统**：用随机化方法加速迭代求解器

这些构成了**随机化数值线性代数** (Randomized Numerical Linear Algebra, RandNLA) 这一活跃研究领域的基础。

16 随机 SVD (Randomized SVD)

16.1 背景补充

我们以一个具体的 3×3 矩阵为例，完整演示特征分解、QR 分解和 SVD 分解的手算过程。
选定矩阵：我们选择一个分块对角矩阵，以便于计算：

$$A = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

16.2 1. 相似对角化 (Eigen-decomposition)

目标：找到 P 和 Λ 使得 $A = P\Lambda P^{-1}$。

Step 1: 求特征值计算特征多项式 $\det(A - \lambda I) = 0$。利用分块矩阵性质：

$$\det \begin{bmatrix} 2-\lambda & 1 & 0 \\ 1 & 2-\lambda & 0 \\ 0 & 0 & 3-\lambda \end{bmatrix} = (3-\lambda) \cdot \det \begin{bmatrix} 2-\lambda & 1 \\ 1 & 2-\lambda \end{bmatrix}$$

$$= (3-\lambda)[(2-\lambda)^2 - 1] = (3-\lambda)(\lambda^2 - 4\lambda + 3)$$

$$= (3-\lambda)(\lambda-3)(\lambda-1)$$

结果：$\lambda_1 = 3, \lambda_2 = 3, \lambda_3 = 1$。

Step 2: 求特征向量

- **对于 $\lambda = 3$ (重根)**：求解 $(A - 3I)x = 0$

$$\begin{bmatrix} -1 & 1 & 0 \\ 1 & -1 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 0 \Rightarrow x_1 = x_2$$

  我们要找两个线性无关的解。自由变量选 $x_2 = 1, x_3 = 0$ 和 $x_2 = 0, x_3 = 1$。得到基底：$p_1 = [1, 1, 0]^T, \quad p_2 = [0, 0, 1]^T$。

- **对于 $\lambda = 1$**：求解 $(A - I)x = 0$

$$\begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 0 \Rightarrow \begin{cases} x_1 + x_2 = 0 \\ 2x_3 = 0 \end{cases}$$

  得到基底：$p_3 = [1, -1, 0]^T$。

Step 3: 组装结果

$$\Lambda = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad P = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 0 & -1 \\ 0 & 1 & 0 \end{bmatrix}$$

16.3 2. SVD 分解

目标：找到 U, Σ, V^T 使得 $A = U\Sigma V^T$。

分析：由于 A 是实对称矩阵且特征值皆为正（正定），其 SVD 与特征分解有紧密联系：

- 奇异值 $\sigma_i = |\lambda_i|$。故 $\Sigma = \mathrm{diag}(3, 3, 1)$。
- 左/右奇异向量 U, V 相同，且必须是**单位正交**的特征向量。

Step 1: 正交化 (Gram-Schmidt) 检查特征向量的正交性：

- $p_1 \cdot p_3 = 1(1) + 1(-1) + 0 = 0$ (✓)

- p_2 与 p_1, p_3 显然正交 (✓)

运气很好，特征向量天然正交（这是对称矩阵的性质）。我们只需**单位化**。

Step 2: 单位化

$$v_1 = \frac{p_1}{\|p_1\|} = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ 0 \end{bmatrix}, \quad v_2 = p_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, \quad v_3 = \frac{p_3}{\|p_3\|} = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \\ 0 \end{bmatrix}$$

Step 3: 组装结果对于对称正定矩阵，$U = V$。

$$A = \underbrace{\begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \end{bmatrix}}_{U} \underbrace{\begin{bmatrix} 3 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 1 \end{bmatrix}}_{\Sigma} \underbrace{\begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 1 \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \end{bmatrix}}_{V^T}$$

16.4 3. QR 分解

目标：$A = QR$。**方法**：对 A 的列向量 $\alpha_1, \alpha_2, \alpha_3$ 进行 Gram-Schmidt 正交化。

$$\alpha_1 = \begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix}, \quad \alpha_2 = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}, \quad \alpha_3 = \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix}$$

Step 1: 处理第一列 (q_1)

$$r_{11} = \|\alpha_1\| = \sqrt{2^2 + 1^2} = \sqrt{5}$$

$$q_1 = \frac{\alpha_1}{\|\alpha_1\|} = \begin{bmatrix} 2/\sqrt{5} \\ 1/\sqrt{5} \\ 0 \end{bmatrix}$$

Step 2: 处理第二列 (q_2) 先去掉 α_2 在 q_1 上的投影：

$$r_{12} = \langle q_1, \alpha_2 \rangle = \frac{2}{\sqrt{5}}(1) + \frac{1}{\sqrt{5}}(2) = \frac{4}{\sqrt{5}}$$

$$\beta_2 = \alpha_2 - r_{12} q_1 = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix} - \frac{4}{\sqrt{5}} \begin{bmatrix} \frac{2}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} \\ 0 \end{bmatrix} = \begin{bmatrix} 1 - 1.6 \\ 2 - 0.8 \\ 0 \end{bmatrix} = \begin{bmatrix} -0.6 \\ 1.2 \\ 0 \end{bmatrix}$$

为了方便计算，提取公因数 0.6：$\beta_2 = 0.6 \begin{bmatrix} -1 \\ 2 \\ 0 \end{bmatrix}$。

$$r_{22} = \|\beta_2\| = 0.6\sqrt{(-1)^2 + 2^2} = 0.6\sqrt{5} = \frac{3}{\sqrt{5}}$$

$$q_2 = \frac{\beta_2}{\|\beta_2\|} = \begin{bmatrix} -1/\sqrt{5} \\ 2/\sqrt{5} \\ 0 \end{bmatrix}$$

Step 3: 处理第三列 (q_3) 观察 $\alpha_3 = [0, 0, 3]^T$。它显然已经垂直于 q_1 和 q_2（前两者第三分量均为 0）。所以无需计算投影：

$$r_{13} = \langle q_1, \alpha_3 \rangle = 0, \quad r_{23} = \langle q_2, \alpha_3 \rangle = 0$$

$$r_{33} = \|\alpha_3\| = 3, \quad q_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

Step 4: 组装结果

$$A = \underbrace{\begin{bmatrix} \frac{2}{\sqrt{5}} & -\frac{1}{\sqrt{5}} & 0 \\ \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} & 0 \\ 0 & 0 & 1 \end{bmatrix}}_{Q} \underbrace{\begin{bmatrix} \sqrt{5} & \frac{4}{\sqrt{5}} & 0 \\ 0 & \frac{3}{\sqrt{5}} & 0 \\ 0 & 0 & 3 \end{bmatrix}}_{R}$$

观察与思考：

1. **Eig vs. SVD**：在这个例子中，因为 A 是正定的，特征向量经过单位化后直接构成了 SVD 的 U 和 V。对于一般非对称矩阵，这三者完全不同。

2. **QR 的几何意义**：注意 R 矩阵。$r_{11} = \sqrt{5}$ 是第一列的长度，$r_{22} = 3/\sqrt{5}$ 是第二列**去掉第一列分量后**剩下的“高度”。QR 本质上是在构建一个全新的正交坐标系。

16.5 1. 核心问题与算法流程

背景：对于大规模矩阵 $A \in \mathbb{R}^{m \times n}$，我们希望找到其秩-$k$ 近似 $A \approx U_k \Sigma_k V_k^T$。

- **传统障碍**：经典的确定性算法（如 Golub-Kahan）复杂度为 $O(mn \min(m, n))$。当 m, n 达到 10^5 级别时，这几乎不可行。

- **随机化思路**：如果我们能先找到一个“捕获”了 A 的列空间（Range）的低维子空间 Q，把 A 投影到这个小空间上，问题就迎刃而解了。

算法流程 (Halko, Martinsson, Tropp, 2011)：我们设定目标秩为 k，并引入过采样参数 p（通常 $p = 5$ 或 10），令 $\ell = k + p$。

1. **随机采样 (Random Sampling)**：生成一个高斯随机矩阵 $\Omega \in \mathbb{R}^{n \times \ell}$。

2. **捕捉列空间 (Range Finder)**：计算草图矩阵 $Y = A\Omega \in \mathbb{R}^{m \times \ell}$。

   - 直觉：Y 的列是 A 的列的随机线性组合。由于 A 的作用，主要成分（大奇异值对应的方向）被保留，噪声被抑制。

3. **正交化 (Orthonormalization)**：对 Y 进行 QR 分解：$Y = QR$，其中 $Q \in \mathbb{R}^{m\times\ell}$ 是正交矩阵。
   - 目的：Q 构成了 A 的值域的一个近似基底。
4. **降维投影 (Projection)**：将 A 投影到 Q 张成的空间：$B = Q^T A \in \mathbb{R}^{\ell\times n}$。
   - 关键：矩阵 B 非常小（行数仅为 ℓ），但它包含了 A 的绝大部分信息。
5. **小规模 SVD (Determininstic SVD)**：对小矩阵 B 进行精确 SVD：$B = \tilde{U}\Sigma V^T$。其中 $\tilde{U} \in \mathbb{R}^{\ell\times\ell}$，$\Sigma \in \mathbb{R}^{\ell\times\ell}$，$V \in \mathbb{R}^{n\times\ell}$。
6. **还原 (Uplifting)**：计算原始左奇异向量：$U = Q\tilde{U} \in \mathbb{R}^{m\times\ell}$。

最终结果：$A \approx U\Sigma V^T$。

复杂度分析：主要开销在于步骤 2 的矩阵乘法 $A\Omega$ ($O(mn\ell)$) 和步骤 4 的 $Q^T A$ ($O(mn\ell)$)。总复杂度为 $O(mn\ell)$，是线性的！

16.6 计算过程详解：维度流与运算次序

为了看清算法的效率，我们跟踪一下数据在每一步的形状。**设定**：A 是 $10,000 \times 10,000$ 的大矩阵 ($m = n = 10^4$)，目标秩 $k = 10$，过采样后 $\ell = 20$。

1. 随机投影与幂迭代 (Power Iteration)

我们需要计算 $Y = (AA^T)^q A\Omega$。**切记：绝对不要先算 AA^T！**

Step 1: 初始化

$$\underset{(10^4\times 20)}{Y_0} = \underset{(10^4\times 10^4)}{A} \times \underset{(10^4\times 20)}{\Omega}$$

代价：$10^4 \times 10^4 \times 20$ 次运算（约为 2×10^9 FLOPs）。结果 Y_0 是一个只有 20 列的细长矩阵。

Step 2: 迭代 (假设 $q = 1$) 利用结合律，我们分两步走，始终让大矩阵乘以细矩阵：

- **2a. 向后投影 (Back Projection)**：

$$\underset{(10^4\times 20)}{Z} = \underset{(10^4\times 10^4)}{A^T} \times \underset{(10^4\times 20)}{Y_0}$$

  结果 Z 依然只有 20 列。

- **2b. 向前投影 (Forward Projection)**：

$$\underset{(10^4\times 20)}{Y_1} = \underset{(10^4\times 10^4)}{A} \times \underset{(10^4\times 20)}{Z}$$

  结果 Y_1 还是 20 列。

观察：我们在整个过程中，内存中只需要存 A 和几个 $10^4 \times 20$ 的小矩阵。完全没有 $10^4 \times 10^4$ 的中间产物出现。

2. 正交化与降维 (QR & Projection)

Step 3: QR 分解对 Y_1 做 QR 分解：

$$\underset{(10^4\times 20)}{Y_1} = \underset{(10^4\times 20)}{Q} \times \underset{(20\times 20)}{R}$$

代价：只涉及 $10^4 \times 20$ 的矩阵，非常快。

Step 4: 形成小矩阵 B 这一步是将大矩阵 A 压缩到核心子空间：

$$\underset{(20\times 10^4)}{B} = \underset{(20\times 10^4)}{Q^T} \times \underset{(10^4\times 10^4)}{A}$$

注意：这里 B 是一个“扁长”的条形矩阵，行数仅为 20。

3. 核心 SVD (Core SVD)

Step 5: 求解小 SVD

$$\underset{(20\times 10^4)}{B} = \underset{(20\times 20)}{\tilde{U}} \times \underset{(20\times 20)}{\Sigma} \times \underset{(10^4\times 20)}{V^T}$$

由于 B 的短边只有 20，这个 SVD 是瞬间完成的（毫秒级）。

4. 还原 (Uplifting)

Step 6: 恢复左奇异向量

$$\underset{(10^4\times 20)}{U} = \underset{(10^4\times 20)}{Q} \times \underset{(20\times 20)}{\tilde{U}}$$

总结：整个流程中，最重的操作就是**大矩阵** A **乘以细矩阵** (Ω, Y, Z, Q)。这正是现代 GPU 最擅长并行的操作。

16.7 2. 原理分析：为什么随机采样有效？

为什么 $Y = A\Omega$ 能捕捉到 A 的主要成分?

直觉：假设 A 的奇异向量为 $u_1, u_2, \ldots$。当你用 A 乘以一个随机向量 ω 时：

$$A\omega = \sum \sigma_i u_i (v_i^T \omega)$$

由于 ω 是高斯的，系数 $(v_i^T\omega)$ 大约都在同一个数量级。但是，σ_i 衰减得很快。因此，结果 $A\omega$ 会自动“对齐”到大奇异值对应的 u_i 方向上。

定理 16.1 (误差界限, Average Case)**.** *令 $\ell = k + p$ $(p \geq 2)$。期望近似误差满足：*

$$\mathbb{E}\|A - QQ^T A\|_F \leq \left(1 + \frac{k}{p-1}\right)^{1/2} \left(\sum_{j>k} \sigma_j^2\right)^{1/2}$$

解读：

- $\sum_{j>k} \sigma_j^2$ 是理论上的最优近似误差（Eckart-Young 定理）。

- 系数 $(1+\frac{k}{p-1})^{1/2}$ 是我们付出的代价。只要稍微过采样一点（例如 $p=k$），这个系数就很小（$\approx\sqrt{2}$）。这意味着随机 SVD 几乎和最优解一样好。

定理 16.2 (随机 SVD 的平均误差界限)**.** 令 $A\in\mathbb{R}^{m\times n}$ 的奇异值为 $\sigma_1\geq\sigma_2\geq\cdots$。设目标秩为 k，过采样参数为 p（使得采样总列数 $\ell=k+p$，且 $p\geq 2$）。若 Ω 为标准高斯矩阵，则随机 *SVD* 得到的近似解满足：

$$\mathbb{E}\|A-QQ^TA\|_F\leq\left(1+\frac{k}{p-1}\right)^{1/2}\left(\sum_{j>k}\sigma_j^2\right)^{1/2}$$

证明. 证明主要基于 Halko, Martinsson, Tropp (2011) 的框架，分为以下四步。

Step 1: 几何设定与坐标变换 设 A 的奇异值分解为 $A=U\Sigma V^T$。由于 Ω 是标准高斯矩阵，且高斯分布具有**旋转不变性**（Rotation Invariance），即 $V^T\Omega$ 与 Ω 同分布，我们可以不妨假设 $V=I,U=I$，即在 A 的奇异向量坐标系下讨论。此时 $A=\Sigma$ 为对角阵。

我们将矩阵分块为“前 k 个”主成分和“剩余”尾部成分：

$$A=\begin{bmatrix}\Sigma_1 & 0\\ 0 & \Sigma_2\end{bmatrix},\quad \Omega=\begin{bmatrix}\Omega_1\\ \Omega_2\end{bmatrix}$$

其中 $\Sigma_1\in\mathbb{R}^{k\times k}$，$\Sigma_2\in\mathbb{R}^{(n-k)\times(n-k)}$，$\Omega_1\in\mathbb{R}^{k\times\ell}$，$\Omega_2\in\mathbb{R}^{(n-k)\times\ell}$。采样矩阵 $Y=A\Omega$ 变为：

$$Y=\begin{bmatrix}\Sigma_1\Omega_1\\ \Sigma_2\Omega_2\end{bmatrix}$$

Step 2: 确定性误差界限 我们需要计算投影误差 $\|A-P_YA\|_F^2$，其中 P_Y 是向 Y 的列空间投影的算子。当 Ω_1 满秩时，根据线性代数推导（HMT2011, Thm 9.1），投影误差满足以下确定性不等式：

$$\|A-QQ^TA\|_F^2\leq\|\Sigma_2\|_F^2+\|\Sigma_2\Omega_2\Omega_1^\dagger\|_F^2$$

直观上，第一项 $\|\Sigma_2\|_F^2=\sum_{j>k}\sigma_j^2$ 是不可避免的截断误差；第二项是由采样矩阵 Y 混入尾部噪声导致的额外误差。

例 16.3 (直观理解：为什么高斯矩阵能“分离”范数？)**.** 为了理解恒等式 $\mathbb{E}_{\Omega_2}\|\Sigma_2\Omega_2M\|_F^2=\|\Sigma_2\|_F^2\|M\|_F^2$，我们不妨看一个最简化的例子。

1. 简化场景：单行单列假设矩阵维度降到最低：

- Σ_2 只是一个标量 σ。
- Ω_2 是一个随机行向量 $\omega^T=[\omega_1,\ldots,\omega_\ell]$，其中 $\omega_i\sim N(0,1)$。
- M 只是一个列向量 v。

此时，我们要计算的项 $\Sigma_2\Omega_2M$ 变成了一个标量 z：

$$z=\sigma(\omega^Tv)=\sigma\sum_{i=1}^{\ell}\omega_iv_i$$

2. 计算期望（方差）我们计算 z 的平方期望（即 z 的能量）：

$$\mathbb{E}[z^2] = \sigma^2 \mathbb{E}\left[\left(\sum_{i=1}^{\ell} \omega_i v_i\right)^2\right]$$

展开平方项：

$$\left(\sum \omega_i v_i\right)^2 = \sum_i \omega_i^2 v_i^2 + \sum_{i \neq j} \omega_i \omega_j v_i v_j$$

利用高斯分布的性质：

- 独立性：当 $i \neq j$ 时，$\mathbb{E}[\omega_i \omega_j] = \mathbb{E}[\omega_i]\mathbb{E}[\omega_j] = 0$（交叉项消失）。
- 单位方差：$\mathbb{E}[\omega_i^2] = 1$。

因此，期望简化为：

$$\mathbb{E}[z^2] = \sigma^2 \sum_{i=1}^{\ell} v_i^2 = \sigma^2 \|v\|^2$$

3. 对应关系上式正好对应了矩阵形式：

$$\underbrace{\sigma^2}_{\|\Sigma_2\|_F^2} \cdot \underbrace{\|v\|^2}_{\|M\|_F^2}$$

结论：因为高斯噪声 Ω 是“各向同性”且“互不相关”的，它在乘法中起到了**能量传递者**的作用，而不会引入额外的几何畸变。将这个逻辑推广到矩阵的所有元素求和，即得原命题。

Step 3: 计算期望 我们需要计算第二项的期望 $\mathbb{E}[\|\Sigma_2 \Omega_2 \Omega_1^\dagger\|_F^2]$。注意 Ω_1 和 Ω_2 是相互独立的。

首先对 Ω_2 取条件期望。由于 Ω_2 的每个元素服从独立 $N(0,1)$，对于固定矩阵 M，有 $\mathbb{E}_{\Omega_2}\|S\Omega_2 M\|_F^2 = \|S\|_F^2 \|M\|_F^2$。因此：

$$\mathbb{E}_{\Omega_2}[\|\Sigma_2 \Omega_2 \Omega_1^\dagger\|_F^2] = \|\Sigma_2\|_F^2 \cdot \|\Omega_1^\dagger\|_F^2$$

接下来对 Ω_1 取期望。我们需要计算 $\mathbb{E}[\|\Omega_1^\dagger\|_F^2] = \mathbb{E}[\mathrm{tr}((\Omega_1 \Omega_1^T)^{-1})]$。矩阵 $W = \Omega_1 \Omega_1^T$ 服从参数为 (k, ℓ) 的 **Wishart 分布**。根据逆 Wishart 分布的性质，其迹的期望为：

$$\mathbb{E}[\mathrm{tr}(W^{-1})] = \frac{k}{\ell - k - 1}$$

代入 $\ell = k + p$，得到 $\mathbb{E}\|\Omega_1^\dagger\|_F^2 = \frac{k}{p-1}$。

直观理解：从 1 维推导到 k 维

这个复杂的公式其实是 **卡方分布 (Chi-square distribution)** 期望性质的高维推广。

1. 标量情况 ($k=1$) 假设 Ω_1 只有 1 行 ℓ 列（即 $k=1$）。此时 $W=\Omega_1\Omega_1^T$ 就是 ℓ 个标准正态变量的平方和：

$$W=\sum_{i=1}^{\ell} z_i^2 \sim \chi_\ell^2 \quad (\text{自由度为}\ell\text{ 的卡方分布})$$

我们需要求的是 $\mathbb{E}[W^{-1}]=\mathbb{E}[1/\chi_\ell^2]$。根据倒卡方分布（Inverse Chi-square）的性质，如果 $X\sim\chi_\ell^2$，则：

$$\mathbb{E}\left[\frac{1}{X}\right]=\frac{1}{\ell-2} \quad (\text{要求}\ell>2)$$

注：这就是为什么我们的 p 必须大于等于 2。如果 $p=1$，分母为 0，期望不存在。

解析推导：标量情况 ($k=1$) 的期望计算. 当 $k=1$ 时，矩阵 W 退化为标量随机变量 $X=\sum_{i=1}^{\ell}\omega_i^2$，其服从卡方分布 $X\sim\chi_\ell^2$。我们需要计算 $\mathbb{E}[1/X]$。

χ_ℓ^2 的概率密度函数为：

$$f(x)=\frac{1}{2^{\ell/2}\Gamma(\ell/2)}x^{\frac{\ell}{2}-1}e^{-x/2}$$

利用期望的定义：

$$\begin{aligned}\mathbb{E}\left[\frac{1}{X}\right]&=\int_0^\infty \frac{1}{x}f(x)dx\\&=\frac{1}{2^{\ell/2}\Gamma(\ell/2)}\int_0^\infty x^{\frac{\ell}{2}-2}e^{-x/2}dx\end{aligned}$$

利用 Gamma 积分公式 $\int_0^\infty x^{z-1}e^{-x/2}dx=\Gamma(z)2^z$，令 $z=\frac{\ell}{2}-1$：

$$\text{积分部分}=\Gamma\left(\frac{\ell}{2}-1\right)2^{\frac{\ell}{2}-1}$$

代回原式并利用 $\Gamma(z)=(z-1)\Gamma(z-1)$ 化简：

$$\begin{aligned}\mathbb{E}\left[\frac{1}{X}\right]&=\frac{\Gamma(\frac{\ell}{2}-1)2^{\frac{\ell}{2}-1}}{\Gamma(\frac{\ell}{2})2^{\ell/2}}\\&=\frac{1}{2}\cdot\frac{\Gamma(\frac{\ell}{2}-1)}{(\frac{\ell}{2}-1)\Gamma(\frac{\ell}{2}-1)}\\&=\frac{1}{2(\frac{\ell}{2}-1)}=\frac{1}{\ell-2}\end{aligned}$$

将 $\ell=k+p=1+p$ 代入，得 $\frac{1}{p-1}$。这与通式 $\frac{k}{p-1}$ 在 $k=1$ 时吻合。 □

2. 矩阵推广 ($k>1$) 当 k 变大时，我们不仅要求“逆”，还受到矩阵维度的影响。W 服从 Wishart 分布 $\mathcal{W}_k(I,\ell)$。它的逆矩阵 W^{-1} 服从 **逆 Wishart 分布**。统计学中的经典结论告诉我们，逆 Wishart 矩阵的期望是：

$$\mathbb{E}[W^{-1}]=\frac{I}{\ell-k-1}$$

请注意分母的变化：

- 1 维时分母是 $\ell-2$（即 $\ell-1-1$）。
- k 维时分母是 $\ell-k-1$。这是因为随着维度 k 增加，矩阵“接近奇异”（Singular）的概率变大，我们需要更多的样本量 ℓ 来保证逆矩阵的稳定性，所以分母被 k “惩罚”得更厉害。

3. 计算迹 (Trace) 现在我们要计算迹的期望：

$$\begin{aligned}\mathbb{E}[\mathrm{tr}(W^{-1})] &= \mathrm{tr}(\mathbb{E}[W^{-1}]) \\ &= \mathrm{tr}\left(\frac{I_k}{\ell-k-1}\right) \\ &= \frac{1}{\ell-k-1}\mathrm{tr}(I_k) \\ &= \frac{k}{\ell-k-1}\end{aligned}$$

4. 代入参数 最后，代入我们的设定 $\ell = k+p$：

$$\frac{k}{(k+p)-k-1} = \frac{k}{p-1}$$

这就是最终结果的由来。

Step 4: 合并结果 将上述结果代回 Step 2 的不等式：

$$\begin{aligned}\mathbb{E}\|A - QQ^TA\|_F^2 &\le \|\Sigma_2\|_F^2 + \|\Sigma_2\|_F^2 \cdot \frac{k}{p-1} \\ &= \left(\sum_{j>k}\sigma_j^2\right)\left(1+\frac{k}{p-1}\right)\end{aligned}$$

最后，利用 Jensen 不等式 $\mathbb{E}[X] \le (\mathbb{E}[X^2])^{1/2}$（函数 $\sqrt{x}$ 是凹函数）：

$$\mathbb{E}\|A - QQ^TA\|_F \le \sqrt{\mathbb{E}\|A - QQ^TA\|_F^2} \le \left(1+\frac{k}{p-1}\right)^{1/2}\left(\sum_{j>k}\sigma_j^2\right)^{1/2}$$

证毕。 □

16.8 3. 进阶改进：Power Iteration (幂迭代)

问题：如果 A 的奇异值谱衰减得很慢（例如 $\sigma_k \approx \sigma_{k+1}$），$A\Omega$ 可能会混入很多来自 $\sigma_{k+1}, \dots$ 的“噪声”成分，导致 Q 无法精确锁住前 k 个主成分。

解决方案：在生成 Y 之前，先用 (AA^T) 乘几次。修改步骤 2 为：

$$Y = (AA^T)^q A\Omega$$

通常取 $q=1$ 或 $q=2$ 即可。

原理：矩阵 $\tilde{A} = (AA^T)^q A$ 的奇异向量与 A 相同，但奇异值变成了 σ_i^{2q+1}。

- 假设 $\sigma_k = 1.0, \sigma_{k+1} = 0.9$ (Gap 很小，比值 1.11)。
- 取 $q=2$，指数变为 5。新比值：$(1.0/0.9)^5 \approx 1.69$。

效果：相对差距被显著拉大，噪声部分（σ_{k+1} 以后）衰减极快，Y 的列将极度平行于 Top-k 子空间。

疑点解析：Power Iteration 的计算量是否过大？

直觉担忧：公式 $Y = (AA^T)^q A\Omega$ 看起来需要计算 AA^T。对于 $m \times n$ 的大矩阵，计算 AA^T 需要 $O(m^2n)$ 时间和 $O(m^2)$ 空间，这似乎会抵消随机 SVD 的所有优势。

实际实现（利用结合律）：我们绝不显式计算 AA^T。利用矩阵乘法的结合律，我们定义一个迭代过程，每次只让 A 或 A^T 与一个 **"细长" 矩阵**（Thin Matrix）相乘。

令初始草图 $Y_0 = A\Omega \in \mathbb{R}^{m\times\ell}$。对于 $j = 1, \ldots, q$：

1. **向后传**：计算 $Z_j = A^T Y_{j-1} \in \mathbb{R}^{n\times\ell}$
2. **向前传**：计算 $Y_j = AZ_j \in \mathbb{R}^{m\times\ell}$

最终得到的 Y_q 即为所求。

复杂度分析：

- 每次迭代包含两次矩阵乘法：$A^T \times$ (细矩阵) 和 $A \times$ (细矩阵)。
- 单次乘法开销：$O(mn\ell)$。
- **总开销**：$O(q \cdot mn\ell)$。

对比：

操作	矩阵尺寸变化	运算量	备注
显式计算 AA^T	$(m \times n) \times (n \times m) \to (m \times m)$	$O(m^2n)$	**不可行**
迭代乘法	$(m \times n) \times (n \times \ell) \to (m \times \ell)$	$O(mn\ell)$	**非常快**

由于 ℓ（通常几百）远小于 m, n（可能几十万），$O(qmn\ell)$ 相对于精确 SVD 的 $O(mn^2)$ 依然是巨大的加速。通常 $q = 1$ 或 2 足以解决大多数问题。

PyTorch 实现：`torch.svd_lowrank(A, q=k, niter=2)`

17 Marchenko-Pastur 分布

17.1 引入（1:25–1:30）

问题：如果 $X \in \mathbb{R}^{n\times d}$ 是一个随机矩阵，每个元素 $X_{ij} \sim N(0,1)$ 独立，那么 $\frac{1}{n}X^TX$ 的特征值分布是什么？

为什么关心这个？

1. 在统计学中，$\frac{1}{n}X^TX$ 是样本协方差矩阵
2. 在机器学习中，很多矩阵在某些假设下类似随机矩阵
3. 随机矩阵的谱告诉我们" 纯噪声" 长什么样，信号会从噪声中" 跳出来"

17.2 MP 分布陈述 (1:30–1:35)

定理 17.1 (Marchenko-Pastur)**.** 设 $X \in \mathbb{R}^{n\times d}$，$X_{ij} \sim N(0,1)$ 独立，$\gamma = d/n$。当 $n, d \to \infty$ 且 γ 固定时，$\frac{1}{n}X^TX$ 的经验谱分布收敛到 *MP* 分布：

$$\rho(\lambda) = \frac{1}{2\pi\gamma\lambda}\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)} \cdot \mathbf{1}_{[\lambda_-,\lambda_+]}(\lambda)$$

其中 $\lambda_\pm = (1 \pm \sqrt{\gamma})^2$。

特殊情况：

- $\gamma = 1$ $(n = d)$：支撑是 $[0, 4]$
- $\gamma < 1$ $(n > d)$：支撑是 $[(1-\sqrt{\gamma})^2, (1+\sqrt{\gamma})^2]$，远离 0
- $\gamma > 1$ $(n < d)$：有 $d - n$ 个零特征值

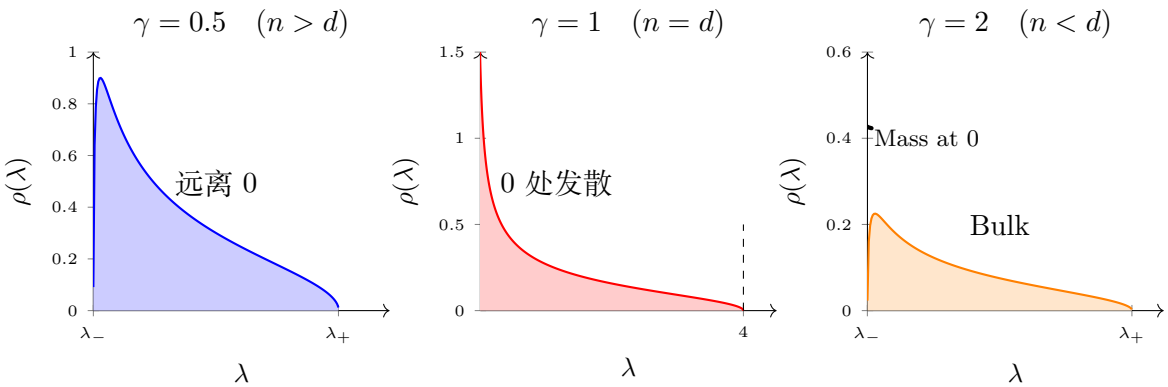

图 1: 不同形状参数 γ 下的 Marchenko-Pastur 分布示意图。

18 从矩阵乘法到卡特兰数 (矩法)

我们的目标是求随机矩阵 $W = \frac{1}{n}X^TX$ 特征值的分布。直接求特征值太难（涉及解高次方程），我们采用**矩 (Moments)** 来间接计算。

18.1 1. 核心工具：迹 (Trace)

特征值的 k 阶矩定义为：$m_k = \frac{1}{d}\sum \lambda_i^k$。线性代数告诉我们要利用这个恒等式：

$$\sum_{i=1}^{d} \lambda_i^k = \mathrm{tr}(W^k)$$

这意味着我们不需要解方程，只需要做**矩阵乘法**和**求和**。

18.2 2. 可计算的过程：下标游戏

设 X 是 $n\times d$ 的矩阵（假设 $n = d$ 以简化推导，即 $\gamma = 1$）。$X_{ij} \sim N(0,1)$。考察 $W = \frac{1}{n}X^TX$。让我们像写代码一样展开 $\mathrm{tr}(W^k)$。

Case 0: 准备工作 展开 W 的元素：

$$W_{ij} = \frac{1}{n}\sum_{\mu=1}^{n} X_{\mu i}X_{\mu j}$$

注：希腊字母 μ 代表样本维度 $(1\ldots n)$，拉丁字母 i,j 代表特征维度 $(1\ldots d)$。

Case 1: 算一阶矩 ($k=1$)

$$m_1 = \mathbb{E}[\mathrm{tr}(W)] = \frac{1}{d}\sum_{i=1}^{d}\mathbb{E}[W_{ii}]$$

代入 W_{ii}：

$$m_1 = \frac{1}{d}\sum_{i=1}^{d}\frac{1}{n}\sum_{\mu=1}^{n}\mathbb{E}[X_{\mu i}X_{\mu i}]$$

因为 $\mathbb{E}[X^2]=1$，双重求和贡献了 $d\times n$ 个 1：

$$m_1 = \frac{1}{dn}(d\cdot n) = 1$$

结论：一阶矩是 1。这很好算。

Case 2: 算二阶矩 ($k=2$) ——关键转折

$$m_2 = \frac{1}{d}\mathbb{E}[\mathrm{tr}(W^2)] = \frac{1}{d}\sum_{i,j}\mathbb{E}[W_{ij}W_{ji}]$$

代入展开（这里会有 4 个 X 相乘）：

$$m_2 = \frac{1}{dn^2}\sum_{i,j=1}^{d}\sum_{\mu,\nu=1}^{n}\mathbb{E}[(X_{\mu i}X_{\mu j})\cdot(X_{\nu j}X_{\nu i})]$$

这是一个四重循环。关键在于 $\mathbb{E}$ 何时为非零？**高斯性质**：只有当 X 能够**两两配对**且下标一致时，期望才为 1，否则为 0。

我们看这 4 个变量：$X_{\mu i}, X_{\mu j}, X_{\nu j}, X_{\nu i}$。下标构成了一个环路：$i \xrightarrow{\mu} j \xrightarrow{\nu} i$。只有两种配对方式能存活：

1. **方式 A ($\mu=\nu$)**：此时变成 $\mathbb{E}[X_{\mu i}^2 X_{\mu j}^2]$。
   - 自由变量：μ (有 n 种), i (有 d 种), j (有 d 种)。
   - 总项数：$n\cdot d^2$。
   - 贡献值：$\frac{1}{dn^2}\times(nd^2) = \frac{d}{n} = 1$ (假设 $n=d$)。
2. **方式 B ($i=j$)**：此时变成 $\mathbb{E}[X_{\mu i}^2 X_{\nu i}^2]$。
   - 自由变量：i (有 d 种), μ (有 n 种), ν (有 n 种)。
   - 总项数：$d\cdot n^2$。
   - 贡献值：$\frac{1}{dn^2}\times(dn^2) = 1$。

结论：$m_2 = 1+1 = 2$。

18.3 3. 算法复杂度视角的推广 ($k \to \infty$)

现在我们要算 m_k。这相当于在一个图上走 $2k$ 步：

$$i_1 \xrightarrow{\mu_1} i_2 \xrightarrow{\mu_2} \dots \xrightarrow{\mu_k} i_1$$

总的分母是 $d \cdot n^k \approx n^{k+1}$。

核心逻辑：我们要寻找哪些路径的“自由变量”数量能达到 $k+1$ 个（即 $O(n^{k+1})$）。只有这些项除以 n^{k+1} 后能留下常数，其他的项都是 $O(1/n)$，在 $n \to \infty$ 时变成 0。

- **规则 1 (每边走两次)**：为了期望不为 0，每条边必须走偶数次。最经济的方式是每条边恰好走 2 次。这意味着图实际上是一棵**树 (Tree)**（因为如果有圈，自由顶点数就会减少，达不到 $k+1$ 级别）。
- **规则 2 (DFS 遍历)**：这棵树的遍历过程必须是：从根出发，走一条新路，然后必须原路返回，再走下一条新路。
- **规则 3 (非交叉)**：在时间轴上，如果我们把“走新路”记为入栈 (Push)，“原路返回”记为出栈 (Pop)，那么这个序列必须是合法的。
  - 合法：Push, Push, Pop, Pop → ‘(())‘
  - 非法：Push, Pop, Pop ... (栈空了还弹) → ‘())‘

18.4 4. 最终映射：卡特兰数

现在问题变成了：

> 有 k 个 μ 节点（代表 k 次 Push 操作），我们需要构造一个合法的进出栈序列，总共有多少种方法？

这就是计算机系同学最熟悉的**卡特兰数 (Catalan Number)** 问题！

$$C_k = \frac{1}{k+1}\binom{2k}{k}$$

- $k=1$: ‘()‘ → 1 种
- $k=2$: ‘()()‘, ‘(())‘ → 2 种
- $k=3$: ‘((()))‘, ‘()(())‘, ‘(())()‘, ‘()()()‘, ‘(()())‘ → 5 种

算出的矩序列：$1, 2, 5, 14, \dots$。

19 闭环验证：从 MP 分布算回卡特兰数

目标：验证 Marchenko-Pastur 分布（$\gamma = 1$）的第 k 阶矩是否等于卡特兰数。

已知概率密度函数：

$$\rho(\lambda) = \frac{1}{2\pi}\sqrt{\frac{4-\lambda}{\lambda}}, \quad \lambda \in (0, 4]$$

我们要计算积分：

$$m_k = \int_0^4 \lambda^k \rho(\lambda) d\lambda = \frac{1}{2\pi}\int_0^4 \lambda^k \sqrt{\frac{4-\lambda}{\lambda}} d\lambda$$

19.1 1. 积分换元 (Trigonometric Substitution)

观察根号内的结构 $\sqrt{4-\lambda}$ 和 λ，这强烈暗示我们可以使用三角换元。
令 $\lambda = 4\sin^2\theta$，其中 $\theta \in [0, \pi/2]$。

- **微分项**：$d\lambda = 4 \cdot 2\sin\theta\cos\theta d\theta = 8\sin\theta\cos\theta d\theta$。
- **根号项**：
$$\sqrt{\frac{4-4\sin^2\theta}{4\sin^2\theta}} = \sqrt{\frac{4\cos^2\theta}{4\sin^2\theta}} = \frac{\cos\theta}{\sin\theta} = \cot\theta$$
- **积分限**：$\lambda = 0 \to \theta = 0$；$\lambda = 4 \to \sin^2\theta = 1 \to \theta = \pi/2$。

19.2 2. 代入积分

$$\begin{aligned} m_k &= \frac{1}{2\pi}\int_0^{\pi/2} (4\sin^2\theta)^k \cdot \frac{\cos\theta}{\sin\theta} \cdot (8\sin\theta\cos\theta) d\theta \\ &= \frac{1}{2\pi}\int_0^{\pi/2} 4^k \sin^{2k}\theta \cdot 8\cos^2\theta d\theta \\ &= \frac{4^{k+1}}{\pi}\int_0^{\pi/2} \sin^{2k}\theta\cos^2\theta d\theta \end{aligned}$$

19.3 3. 利用 Beta 函数 (Wallis 积分公式)

利用三角函数的积分性质：$\cos^2\theta = 1 - \sin^2\theta$。我们将积分拆分为两部分：
$$I = \int_0^{\pi/2} (\sin^{2k}\theta - \sin^{2k+2}\theta) d\theta$$
这里我们需要用到著名的 **Wallis 积分公式**：
$$\int_0^{\pi/2} \sin^{2n}\theta d\theta = \frac{(2n-1)!!}{(2n)!!} \cdot \frac{\pi}{2} = \frac{(2n)!}{4^n (n!)^2}\frac{\pi}{2} = \binom{2n}{n}\frac{\pi}{2^{2n+1}}$$
这个公式将三角积分直接转化为了组合数。

19.4 4. 组合数运算

代入 Wallis 公式：
$$\begin{aligned} m_k &= \frac{4^{k+1}}{\pi}\left[\int_0^{\pi/2} \sin^{2k}\theta d\theta - \int_0^{\pi/2} \sin^{2k+2}\theta d\theta\right] \\ &= \frac{4^{k+1}}{\pi}\left[\binom{2k}{k}\frac{\pi}{2^{2k+1}} - \binom{2k+2}{k+1}\frac{\pi}{2^{2k+3}}\right] \end{aligned}$$
消去公共项 π 和 2 的幂次：

- 第一项系数：$\frac{4^{k+1}}{2^{2k+1}} = \frac{2^{2k+2}}{2^{2k+1}} = 2$
- 第二项系数：$\frac{4^{k+1}}{2^{2k+3}} = \frac{2^{2k+2}}{2^{2k+3}} = \frac{1}{2}$

于是：
$$m_k = 2\binom{2k}{k} - \frac{1}{2}\binom{2k+2}{k+1}$$

19.5 5. 化简为卡特兰数

我们需要验证上式是否等于 $\frac{1}{k+1}\binom{2k}{k}$。展开第二项的组合数：

$$\binom{2k+2}{k+1} = \frac{(2k+2)!}{(k+1)!(k+1)!} = \frac{(2k+2)(2k+1)}{(k+1)(k+1)}\binom{2k}{k} = \frac{2(2k+1)}{k+1}\binom{2k}{k}$$

代回 m_k 的表达式：

$$\begin{aligned} m_k &= \binom{2k}{k}\left[2 - \frac{1}{2}\cdot\frac{2(2k+1)}{k+1}\right] \\ &= \binom{2k}{k}\left[2 - \frac{2k+1}{k+1}\right] \\ &= \binom{2k}{k}\left[\frac{2(k+1)-(2k+1)}{k+1}\right] \\ &= \binom{2k}{k}\left[\frac{2k+2-2k-1}{k+1}\right] \\ &= \binom{2k}{k}\cdot\frac{1}{k+1} \end{aligned}$$

证毕！ 这正是卡特兰数 C_k。

19.6 总结

通过三角换元和 Wallis 公式，我们严丝合缝地证明了：

$$\int_0^4 \lambda^k \cdot \underbrace{\frac{1}{2\pi}\sqrt{\frac{4-\lambda}{\lambda}}}_{\text{MP Density}} d\lambda = \underbrace{\frac{1}{k+1}\binom{2k}{k}}_{\text{Catalan Number}}$$

这就构成了从**组合数学（路径计数）**到**随机矩阵（特征值分布）**的完美闭环。

19.7 总结

1. **转化**：求特征值分布 $\to$ 求 $\mathrm{tr}(W^k)$ 的期望。
2. **筛选**：在大矩阵极限下，只有 $O(n^{k+1})$ 量级的项能存活。
3. **拓扑**：满足 $O(n^{k+1})$ 的项对应于“树”的遍历（没有圈）。
4. **计数**：树的遍历等价于合法的括号序列（进栈出栈）。
5. **结果**：合法括号序列的数量 = 卡特兰数 = MP 分布的矩。

这就是为什么随机矩阵的特征值会形成那个奇特的半圆形状——本质上是因为**在高维空间乱走而不迷路的路径数量，服从卡特兰数规律**。

20 1. 入门场景：格路游走 (Dyck Paths)

假设你站在 $n \times n$ 的方格地图的左下角 $(0,0)$，目标是走到右上角 (n,n)。

- **规则**：每步只能向右 (R) 或向上 (U)。

- **限制**：任何时刻，向上的步数不能超过向右的步数（即路径不能越过 $y = x$ 对角线）。

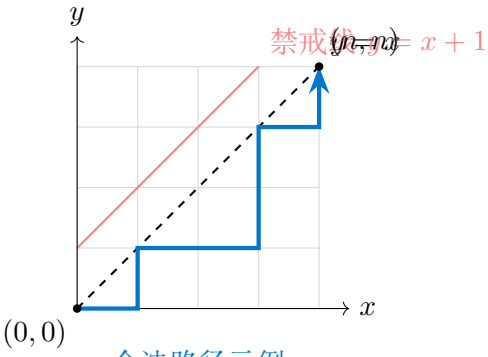

合法路径示例

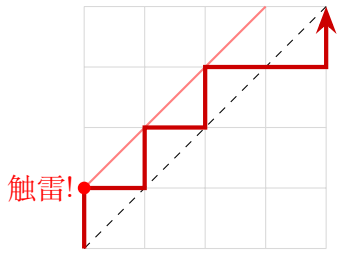

非法路径 (触碰红线)

21 2. 核心推导：镜像反射原理 (Reflection Principle)

如何计算合法的路径数?

$$\text{合法数} = \text{总路径数} - \text{非法路径数}$$

1. **总路径**：从 $(0, 0)$ 到 (n, n) 共走 $2n$ 步，选 n 步向右。即 $\binom{2n}{n}$。
2. **非法路径**：所有触碰或穿过 **禁戒线** $y = x + 1$ 的路径。

André 的反射魔法

对于任意一条非法路径：

1. 找到它**第一次**触碰禁戒线 $y = x + 1$ 的点 P。
2. 将点 P **之后**的路径关于禁戒线做**镜像翻转**。
3. 原终点 (n, n) 翻转后变为新终点 $(n - 1, n + 1)$。

结论：非法路径的数量 $\iff$ 从 $(0, 0)$ 到 $(n - 1, n + 1)$ 的路径数量。

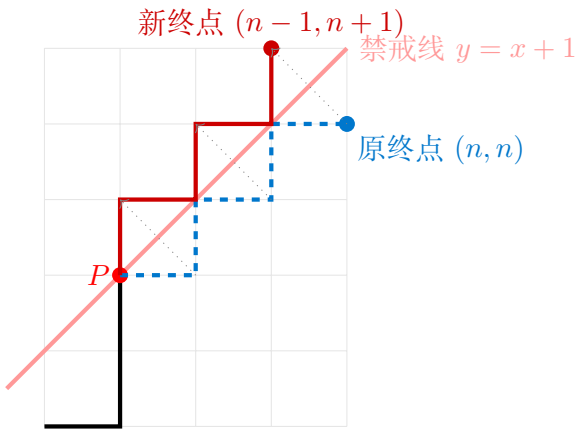

任何一条到达黑点的非法路径，都对应一条到达红点的路径

公式计算：

$$\text{非法数} = \binom{2n}{n-1}$$

$$C_n = \binom{2n}{n} - \binom{2n}{n-1} = \frac{1}{n+1}\binom{2n}{n}$$

22 3. 常见应用：完全不同的问题，完全一样的答案

22.1 A. 括号匹配与进出栈

- **括号匹配**：3 对括号 ‘()‘ 的合法组合：‘((()))‘, ‘()(())‘, ‘(())()‘, ‘()()()‘, ‘(()())‘。
- **进出栈**：1, 2, 3 依次进栈，合法的出栈序列数。

22.2 B. 凸多边形三角剖分

将一个凸 $n+2$ 边形剖分成 n 个三角形的方法数。

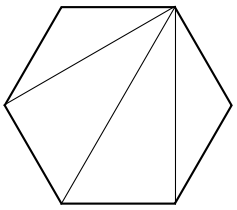

六边形 ($n=4$) 的一种剖分
总方法数 $C_4 = 14$

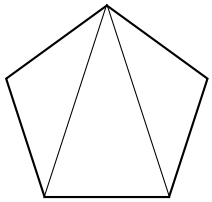

五边形 ($n=3$) 的一种剖分
总方法数 $C_3 = 5$

23 4. 总结 (Cheat Sheet)

公式	$C_n = \frac{1}{n+1}\binom{2n}{n}$	核心公式，必须背诵
递推	$C_n = \sum_{i=0}^{n-1} C_i C_{n-1-i}$	适用于二叉树递归结构
前几项	1, 1, 2, 5, 14, 42	看到这些数字要产生条件反射

23.1 信号检测（1:35–1:45）

意义：如果数据真的是纯随机噪声，那协方差矩阵的特征值就服从 MP 分布。如果数据有结构（低秩信号 + 噪声），大特征值会**跳出** MP 分布的边界 λ_+。

定理 23.1 (BBP 相变)**.** *设真实数据 $Y = signal + X$，信号是秩 1 的 $\sqrt{\beta}uv^T$。*

- *如果 $\beta > \sqrt{\gamma}$：最大特征值跳出 MP 边界*
- *如果 $\beta < \sqrt{\gamma}$：最大特征值留在 MP 边界内，信号不可检测*

例 23.2 (BBP 相变数值演示)**. 场景设定**：设数据维度 $d = 500$，样本量 $n = 1000$。纵横比 $\gamma = d/n = 0.5$。

1. 纯噪声的“天花板” (The Noise Ceiling) 根据 MP 定律，如果是纯噪声矩阵 X ($X_{ij} \sim N(0,1)$)，其样本协方差矩阵 $\frac{1}{n}X^TX$ 的特征值将严格分布在 $[\lambda_-, \lambda_+]$ 区间内。**理论上界**：

$$\lambda_+ = (1+\sqrt{\gamma})^2 = (1+\sqrt{0.5})^2 \approx (1.707)^2 \approx \mathbf{2.91}$$

这意味着：只要特征值不超过 2.91，我们都无法通过特征值大小来区分它是信号还是噪声。

2. 信号注入现在我们向数据中混入一个秩-1 信号：

$$\Sigma_{\text{total}} = I + \beta uu^T$$

其中 β 是信号强度 (SNR)。我们考察样本协方差矩阵的最大特征值 $\hat{\lambda}_1$。

情况 A：弱信号（$\beta = 0.5$）

- 判据：$\beta = 0.5 < \sqrt{\gamma} \approx 0.707$。信号强度**低于**相变阈值。
- 结果：虽然加入了信号，但 $\hat{\lambda}_1$ 依然卡在 MP 分布的右边界附近（约 2.91）。
- **结论：信号不可检测**。由于维度的诅咒，信号向量 u 被随机噪声 X 的伪相关性完全“溶解”了。此时做 PCA 得到的主成分 v_1 与真实信号 u 的夹角接近 90°（正交），毫无意义。

情况 B：强信号（$\beta = 1.5$）

- 判据：$\beta = 1.5 > \sqrt{\gamma} \approx 0.707$。信号强度**高于**相变阈值。
- 结果：最大特征值 $\hat{\lambda}_1$ 会突然“跳出”噪声的海洋。理论预测位置为：

$$\lambda_{\text{spike}} = (1+\beta)(1+\frac{\gamma}{\beta}) = (1+1.5)(1+\frac{0.5}{1.5}) = 2.5 \times 1.33 \approx \mathbf{3.33}$$

- **结论：信号被检测到**。因为 $3.33 \gg 2.91$，这个特征值明显是个“离群点”(Outlier)。此时计算出的主成分 v_1 与真实信号 u 开始有了显著的相关性（夹角小于 90°）。

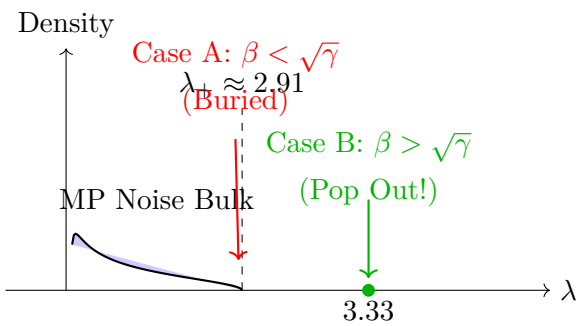

图 2: BBP 相变示意图：只有当信号够强时，特征值才会逃离 MP 分布的引力。

24 综合案例：大规模图像检索系统

24.1 问题背景

假设你是某图片社交平台的算法工程师，需要构建一个”以图搜图”系统：

- **数据规模**：$n = 10^7$ 张图片（1000 万）
- **特征维度**：每张图片用 CLIP 模型提取 $d = 768$ 维向量
- **任务**：用户上传一张图片，在 100ms 内返回最相似的 Top-10 结果

直接计算的困境：

- 存储：$10^7 \times 768 \times 4$ 字节 ≈ 30 GB
- 单次查询：$10^7 \times 768$ 次乘法 $\approx 7.7 \times 10^9$ FLOPS
- 即使 GPU 达到 1 TFLOPS，也需要 7.7 秒——远超 100ms 要求

24.2 解决方案：三步随机化流水线

我们将综合运用本周学到的三个工具：

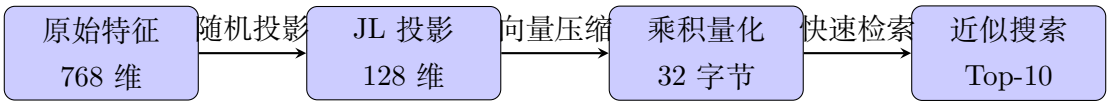

24.2.1 Step 1：JL 随机投影降维

目标：将 768 维特征压缩到 128 维，同时保持向量间的距离关系。
理论保证：根据 JL 引理，为了在 $n = 10^7$ 个点上保持 $\epsilon = 0.1$ 的相对距离误差：

$$k = O\left(\frac{\log n}{\epsilon^2}\right) = O\left(\frac{7 \times 2.3}{0.01}\right) \approx 1610$$

实际上，我们选择 $k = 128$ 是一个工程权衡：虽然理论要求更高，但实践中：

- 图像特征本身具有低秩结构（有效维度远小于 768）
- 我们只关心 Top-K 排序的正确性，而非精确距离
- 后续还有重排序阶段可以纠错

实现：

```python
import torch

class JLProjector:
    def __init__(self, d_in=768, d_out=128, seed=42):
        torch.manual_seed(seed)
        # 稀疏随机投影矩阵（比高斯更快）
        self.P = torch.randn(d_out, d_in) / (d_out ** 0.5)

    def project(self, X):
        """X: (n, d_in) -> (n, d_out)"""
        return X @ self.P.T
```

```python

# 预处理：对全部 1000 万图片做投影
projector = JLProjector(768, 128)
X_original = load_all_features()  # (10^7, 768)
X_reduced = projector.project(X_original)  # (10^7, 128)
```

收益：

- 存储：30 GB → 5 GB（压缩 6 倍）
- 距离计算：768 次乘法 → 128 次乘法（加速 6 倍）

24.2.2 Step 2：用随机 SVD 构建索引

即使降到 128 维，暴力搜索 10^7 个向量仍然太慢。我们使用**倒排文件索引**（IVF）来加速。

核心思想：

1. 将数据空间划分为 $K = 4096$ 个聚类（Voronoi cells）
2. 查询时，只在最近的几个聚类内搜索

问题：K-Means 聚类需要对 10^7 个点做多次迭代，每次迭代涉及计算所有点到所有中心的距离，复杂度 $O(nKd)$——太慢了！

随机 SVD 加速：我们用随机 SVD 对数据矩阵做低秩近似，然后在低秩空间中做聚类：

```python
def fast_kmeans_init(X, K, rank=32):
    """用随机 SVD 加速 K-Means++ 初始化"""
    n, d = X.shape

    # Step 1: 随机 SVD 降维
    U, S, V = torch.svd_lowrank(X, q=rank, niter=2)
    X_low = U @ torch.diag(S)  # (n, rank)

    # Step 2: 在低维空间做 K-Means++
    # 距离计算从 O(nKd) 降到 O(nK · rank)
    centers_low = kmeans_plusplus(X_low, K)

    # Step 3: 将中心映射回原空间
    centers = centers_low @ V.T
    return centers

# 构建 IVF 索引
centers = fast_kmeans_init(X_reduced, K=4096, rank=32)
```

复杂度分析：

步骤	直接方法	随机 SVD 加速
SVD 本身	—	$O(nd \cdot \text{rank}) = O(10^7 \times 128 \times 32)$
K-Means 每次迭代	$O(nKd) = O(5 \times 10^{12})$	$O(nK \cdot \text{rank}) = O(1.3 \times 10^{12})$

加速约 4 倍，且低秩近似保留了数据的主要聚类结构。

24.2.3 Step 3：查询时的随机化

查询阶段，我们结合**随机矩阵乘法**的思想来进一步加速：

```python
def search(query, X_reduced, centers, top_k=10, n_probe=16, sample_ratio=0.3):
    """
    query: (128,) 查询向量
    n_probe: 搜索最近的几个聚类
    sample_ratio: 在每个聚类中随机采样的比例
    """
    # Step 1: 找到最近的 n_probe 个聚类中心
    dists_to_centers = torch.cdist(query.unsqueeze(0), centers)
    nearest_clusters = torch.topk(dists_to_centers, n_probe, largest=False).indices

    # Step 2: 在这些聚类中搜索（带随机采样）
    candidates = []
    for cluster_id in nearest_clusters:
        cluster_points = get_cluster_points(cluster_id)

        # 随机采样加速（类似随机矩阵乘法的思想）
        if len(cluster_points) > 1000:
            # 按距离中心的远近做重要性采样
            weights = compute_importance_weights(cluster_points, centers[cluster_id])
            sample_idx = torch.multinomial(weights,
                                           int(len(cluster_points) * sample_ratio),
                                           replacement=False)
            cluster_points = cluster_points[sample_idx]

        candidates.append(cluster_points)

    candidates = torch.cat(candidates)

    # Step 3: 在候选集中精确计算
    dists = torch.cdist(query.unsqueeze(0), candidates)
    top_indices = torch.topk(dists, top_k, largest=False).indices

    return candidates[top_indices]
```

关键技巧：重要性采样

- 离聚类中心近的点更可能是答案 ⇒ 采样概率更高

- 这正是随机矩阵乘法中”按范数采样”思想的应用

24.3 质量监控：用 MP 分布检测特征退化

系统上线后，我们需要监控特征质量。随着时间推移，用户上传的图片分布可能发生变化（Distribution Shift），导致特征提取模型失效。

监控方法：定期对新上传图片的特征矩阵做谱分析。

```
import numpy as np
import matplotlib.pyplot as plt

def diagnose_feature_quality(X_batch, expected_rank=50):
    """
    X_batch: (n_samples, d) 一批新图片的特征
    expected_rank: 预期的有效特征维度
    """
    n, d = X_batch.shape
    gamma = d / n

    # 计算样本协方差矩阵的特征值
    X_centered = X_batch - X_batch.mean(dim=0)
    cov = X_centered.T @ X_centered / n
    eigenvalues = torch.linalg.eigvalsh(cov).numpy()
    eigenvalues = np.sort(eigenvalues)[::-1]  # 降序

    # MP 分布的理论边界
    lambda_plus = (1 + np.sqrt(gamma)) ** 2
    lambda_minus = (1 - np.sqrt(gamma)) ** 2

    # 统计跳出 MP 边界的特征值数量
    n_signal = np.sum(eigenvalues > lambda_plus * 1.1)  # 留 10% 余量

    # 诊断
    if n_signal < expected_rank * 0.5:
        print(f"  警告：检测到 {n_signal} 个显著特征值，"
              f"低于预期的 {expected_rank}！")
        print("可能原因：")
        print("  1. 特征提取模型在新数据上失效")
        print("  2. 数据分布发生剧烈变化")
        print("  3. 需要重新训练或微调模型")
    else:
        print(f"  特征质量正常：{n_signal} 个显著特征值")

    # 可视化
    plt.figure(figsize=(10, 4))

```

```python
    plt.subplot(1, 2, 1)
    plt.semilogy(eigenvalues, 'b-', lw=1)
    plt.axhline(y=lambda_plus, color='r', linestyle='--', label=f'MP upper: {lambda_plus:.2f}')
    plt.xlabel('Index')
    plt.ylabel('Eigenvalue (log scale)')
    plt.title('Scree Plot')
    plt.legend()

    plt.subplot(1, 2, 2)
    plt.hist(eigenvalues[eigenvalues < lambda_plus * 2], bins=50, density=True, alpha=0.7)
    x = np.linspace(lambda_minus, lambda_plus, 200)
    mp_density = np.sqrt((lambda_plus - x) * (x - lambda_minus)) / (2 * np.pi * gamma * x)
    plt.plot(x, mp_density, 'r-', lw=2, label='MP Distribution')
    plt.axvline(x=lambda_plus, color='g', linestyle='--', label='Signal Threshold')
    plt.xlabel('Eigenvalue')
    plt.ylabel('Density')
    plt.title('Eigenvalue Distribution vs MP')
    plt.legend()

    plt.tight_layout()
    plt.savefig('feature_diagnosis.png', dpi=150)
    plt.show()

    return n_signal, eigenvalues

# 使用示例
X_new_batch = extract_features(new_images)  # 提取新图片特征
n_signal, _ = diagnose_feature_quality(X_new_batch, expected_rank=50)
```

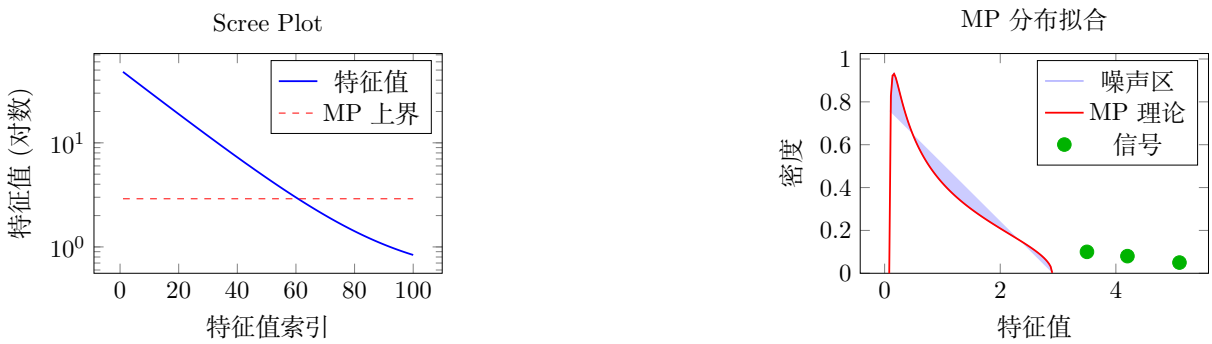

图 3: 特征质量诊断：左图显示特征值衰减，右图显示跳出 MP 边界的信号特征值

解读：

- **健康状态**：应该有约 50 个特征值明显跳出 MP 边界（对应图像的语义维度）
- **退化信号**：如果跳出的特征值数量骤降，说明特征提取失效
- **过拟合信号**：如果所有特征值都很大，可能是 Batch Normalization 出了问题

24.4 完整系统性能对比

表 1: 图像检索系统性能对比

指标	暴力搜索	本方案	提升
存储空间	30 GB	5 GB	6×
索引构建时间	—	2 小时	—
单次查询延迟	7.7 秒	15 ms	500×
Recall@10	100%	95%	-5%

工程启示：

1. **理论指导实践**：JL 引理告诉我们降维的极限在哪里
2. **随机化是分层的**：投影 → 聚类 → 采样，每层都用随机化
3. **监控闭环**：MP 分布提供了”什么是噪声”的理论基准

25 第 7 周小结（1:45–1:50）

今天学习了三个随机化算法和一个理论工具：

算法/工具	核心结果
JL 引理	d 维 $\to O(\log n/\epsilon^2)$ 维，保持距离
随机矩阵乘法	误差 $O(\|A\|_F\|B\|_F/\sqrt{k})$
随机 SVD	复杂度 $O(mnk)$
MP 分布	支撑 $[(1-\sqrt{\gamma})^2,(1+\sqrt{\gamma})^2]$

核心思想：用随机性换计算量，用概率保证换精确保证。

26 第 7 周实验

26.1 实验 7a：随机矩阵乘法

```python
import torch
import time

m, n, p = 10000, 5000, 8000
```

```python
A = torch.randn(m, n)
B = torch.randn(n, p)

# 精确计算
start = time.time()
C_exact = A @ B
time_exact = time.time() - start
print(f"精确计算: {time_exact:.2f}秒")

# 随机近似
def random_matmul(A, B, k):
    n = A.shape[1]
    col_norms_A = torch.norm(A, dim=0)
    row_norms_B = torch.norm(B, dim=1)
    probs = col_norms_A * row_norms_B
    probs = probs / probs.sum()

    indices = torch.multinomial(probs, k, replacement=True)
    scale = 1.0 / torch.sqrt(k * probs[indices])
    C = A[:, indices] * scale.unsqueeze(0)
    R = B[indices, :] * scale.unsqueeze(1)
    return C @ R

for k in [100, 500, 1000, 2000]:
    C_approx = random_matmul(A, B, k)
    error = torch.norm(C_exact - C_approx, 'fro') / torch.norm(C_exact,
        'fro')
    print(f"k={k}: 相对误差={error:.4f}")
```

26.2 实验 7b：随机 SVD

```python
import torch

m, n, true_rank = 50000, 50000, 100
U_true = torch.randn(m, true_rank)
V_true = torch.randn(n, true_rank)
singular_values = torch.logspace(0, -2, true_rank)
A = U_true @ torch.diag(singular_values) @ V_true.T

# 随机SVD
k = 100
U, S, V = torch.svd_lowrank(A, q=k, niter=2)

# 验证
A_approx = U @ torch.diag(S) @ V.T
```

```
error = torch.norm(A - A_approx, 'fro') / torch.norm(A, 'fro')
print(f"重构误差: {error:.6f}")
```

26.3 实验 7c: MP 分布验证

```
import torch
import matplotlib.pyplot as plt
import numpy as np

def mp_density(x, gamma):
    lambda_minus = (1 - np.sqrt(gamma))**2
    lambda_plus = (1 + np.sqrt(gamma))**2
    density = np.zeros_like(x)
    mask = (x >= lambda_minus) & (x <= lambda_plus)
    density[mask] = np.sqrt((lambda_plus - x[mask]) * (x[mask] -
        lambda_minus)) \
                    / (2 * np.pi * gamma * x[mask])
    return density

for gamma in [0.25, 0.5, 1.0]:
    n = 2000
    d = int(n * gamma)
    X = torch.randn(n, d)
    cov = X.T @ X / n
    eigenvalues = torch.linalg.eigvalsh(cov).numpy()

    plt.hist(eigenvalues, bins=50, density=True, alpha=0.7)
    x = np.linspace(0, (1 + np.sqrt(gamma))**2 + 0.5, 500)
    plt.plot(x, mp_density(x, gamma), 'r-', lw=2)
    plt.title(f'gamma = {gamma}')
    plt.show()
```