

第 9 周习题：隐式偏好与极分解

深度学习优化理论

习题 9.1：深度 2 的奇异值演化方程

设 $W = W_2 W_1$, $W_1, W_2 \in \mathbb{R}^{d \times d}$, 损失 $L = \frac{1}{2} \|W - Y\|_F^2$, 残差 $R = W - Y$ 。梯度流 $\dot{W}_j = -\partial L / \partial W_j$ 。

(a) 用链式法则证明

$$\dot{W}_1 = -W_2^\top R, \quad \dot{W}_2 = -R W_1^\top.$$

(b) 用乘积法则计算 $\dot{W} = \dot{W}_2 W_1 + W_2 \dot{W}_1$, 证明

$$\dot{W} = -R W_1^\top W_1 - W_2 W_2^\top R.$$

(c) 假设平衡初始化 $W_1^\top W_1 = W_2 W_2^\top =: \Sigma$ (这条件在梯度流下守恒, 本题不要求证明), 且 W 与 Y 在共同奇异基下对角化。设 W 第 r 个奇异值为 σ_r , $y_r = u_r^\top Y v_r$ 。证明

$$\dot{\sigma}_r = -2\sigma_r(\sigma_r - y_r).$$

提示：在该奇异基下 $\Sigma = \text{diag}(\sigma_r)$, R 的对角元为 $\sigma_r - y_r$ 。把 (b) 投影到 $u_r v_r^\top$ 方向。

习题 9.2： $N \rightarrow \infty$ 极限的奇异值动力学

由讲义 §2.5.6, 深度 N 网络的奇异值方程为

$$\dot{\sigma}_r = -N \sigma_r^{2-2/N} (\sigma_r - y_r).$$

(a) 引入 $\tau = Nt$, 证明 $N \rightarrow \infty$ 极限方程为

$$\frac{d\sigma}{d\tau} = -\sigma^2(\sigma - y), \quad (*)$$

(省略下标 r)。简述 (≤ 30 字) 这个 rescale 的物理含义。

(b) 对**任务无关方向** $y = 0$, $(*)$ 退化为 $\dot{\sigma} = -\sigma^3$ 。从 $\sigma(0) = \varepsilon$ 出发, 分离变量解出

$$\sigma(\tau) = \frac{\varepsilon}{\sqrt{1 + 2\varepsilon^2 \tau}}.$$

说明：当 ε 小时, $\sigma(\tau)$ 在任意有限 τ 内**永远** $\leq \varepsilon$ ——这就是无穷深网络的低秩偏好（无信号方向永久冻结在小值附近）。

习题 9.3: Newton-Schulz 与 Polar Express

Muon 用奇多项式迭代 $X_{t+1} = p[X_t]$ 计算极因子。Newton-Schulz 用 $p_{NS}(x) = \frac{3}{2}x - \frac{1}{2}x^3$ 。

(a) 直接展开右边，验证恒等式

$$1 - p_{NS}(x) = \frac{1}{2}(1-x)^2(2+x).$$

推出：当 $|1-x| \leq \delta$ 时 $|1 - p_{NS}(x)| \leq \frac{3}{2}\delta^2$ (**接近 1 时二次收敛**)。但当 x 小时 $p_{NS}(x) \approx \frac{3}{2}x$ ，**只线性放大 1.5 倍**——这是 NS 的瓶颈。

(b) Polar Express 的想法：每步根据当前奇异值区间重新选最优多项式 $p(x) = ax + bx^3$ 。对区间 $[0.5, 1]$ ，要求三点等振

$$1 - p(0.5) = +E, \quad 1 - p(0.75) = -E, \quad 1 - p(1) = +E.$$

写出 3×3 线性方程组求解 a, b, E 。

参考解： $a \approx 1.95$, $b \approx -0.85$, $E \approx 0.06$ 。对比 NS 在 $[0.5, 1]$ 上的最大误差 $1 - p_{NS}(0.5) = 0.3125$ ，PE 改善约 5 倍。