深度学习优化理论

隐式偏好、鞍点几何与训练动力学

第 9 周课程讲义

摘要

本周我们深入探讨深度学习优化中三个最反直觉的现象。第一，用线性代数解释为什么**过参数化**反而有助于泛化（隐式正则化），并把这个故事推广到 **Boosting**——同样的”训练误差到 0 后继续优化”的现象在另一种语言下重演为 margin maximization。第二，借助随机矩阵理论与置换对称性理解为什么高维空间中**几乎所有临界点都是鞍点**，以及如何逃离它们。第三，通过 Cohen 等人发现的 **Edge of Stability** 现象，看到神经网络如何系统性违反经典稳定性条件 $\eta < 2/\lambda_{\max}$ 而仍然成功训练。我们最后实际观察 Hessian 谱与权重谱，连接理论与实践。

目录

1 开场：经典理论的三大悖论 **4**

2 第一部分：过参数化与隐式正则化 **4**

2.1 问题设定：欠定线性回归 4

2.2 推导 A：GD 轨迹始终在 Row(X) 4

2.3 推导 B：SVD 坐标下的逐分量分析 6

2.4 最小范数解的意义 8

2.5 深度矩阵分解：更强的隐式正则化 9

2.5.1 问题设定 9

2.5.2 深度 2 的梯度流分析 9

2.5.3 平衡初始化的魔力 11

2.5.4 奇异值的演化方程 12

2.5.5 深度带来的低秩偏好 13

2.5.6 推广到深度 N 13

3 第二部分：AdaBoost——另一种隐式偏好 **15**

3.1 背景：VC 维与经典泛化理论的极限 15

3.1.1 证明 sketch 15
3.2 弱学习器能否变强？ 18
3.3 AdaBoost 算法 18
3.4 核心推导：AdaBoost = 指数损失上的坐标下降 19
3.5 训练误差的指数收敛 20
3.6 关键洞察：训练误差到 0 后会发生什么？ 21
3.6.1 Margin 的定义 21
3.6.2 关键事实：AdaBoost 持续提升 margin 22
3.7 Frank-Wolfe 视角 22
3.8 推广：梯度提升 23
3.9 现代实践：XGBoost 24
3.10 与深度学习的对比 24

4 第三部分：高维临界点统计 25
4.1 问题：为什么 SGD 不会卡住？ 25
4.2 低维直觉是错误的 25
4.3 随机矩阵理论：Wigner 半圆律 25
4.4 从网络对称性理解 Loss Landscape 26
4.5 神经元置换对称性 26
4.6 定量分析：有多少鞍点？ 27
4.7 基于对称性的概率论证 29
4.8 等价极小值之间必有鞍点：拓扑论证 30
4.9 定量分析：鞍点的 index 31
4.10 符号对称性 33
4.11 过参数化下的全局极小值流形 33
4.12 Mode Connectivity：实验验证 34
4.13 综合：对称性视角的优势 35
4.14 关键计算：成为极小值的概率 35
4.15 关键区分：结构性鞍点 vs 病理性鞍点 36
4.16 什么真正改善了优化？ 37

5 第四部分：逃离鞍点的理论 38
5.1 Strict Saddle 的定义 38
5.2 负曲率方向的逃逸 38
5.3 扰动梯度下降 38

6 第五部分：Hessian 谱的经验分析 39
6.1 计算挑战 39

6.2 为什么是 Bulk + Outliers? ——Gauss-Newton 视角 40
6.3 实验观察：Bulk + Outliers 结构 41
6.4 与随机矩阵理论的联系 42

7 第六部分：Edge of Stability——超越经典稳定性 43
7.1 经典稳定性条件回顾 43
7.2 反直觉观察：Cohen et al. (2021) 43
7.3 进入 EoS 后训练在做什么? 44
7.4 自稳定机制：板书推导 44
7.5 为什么会 Progressive Sharpening? 46
7.6 实践含义 46
7.6.1 大学习率为什么有效 46
7.6.2 Warmup 的解释 46
7.6.3 Sharpness-Aware Minimization (SAM) 47

8 第七部分：权重矩阵的谱 47
8.1 初始化时的谱 47
8.2 训练后的变化 47
8.3 直觉解释 48

9 总结 48

10 下周预告 49

11 参考文献 50

1 开场：经典理论的三大悖论

在开始技术内容之前，让我们先明确今天要解决的三个核心悖论：

经典：参数多必然过拟合	经典：非凸优化困难重重	经典：$\eta > 2/\lambda_{\max}$ 必然发散
↓	↓	↓
现实：过参数化泛化很好	现实：SGD 轻松找到好解	现实：$\eta\lambda_{\max} \approx 2$ 长期稳定
隐式偏好（三种）	**鞍点统计 + 对称性**	**Edge of Stability**

核心结论：本周的核心信息

不是参数多少决定泛化，是优化算法选择了什么解。
深度学习的成功不是”魔法”，而是高维几何与优化动力学的必然结果。

2 第一部分：过参数化与隐式正则化

2.1 问题设定：欠定线性回归

考虑最简单的过参数化场景：**欠定线性回归**。

定义 2.1 (欠定系统). 设数据矩阵 $X \in \mathbb{R}^{n\times d}$，标签 $y \in \mathbb{R}^n$，其中样本数 $n < d$ 参数数。优化问题为：

$$\min_{w\in\mathbb{R}^d} L(w) = \frac{1}{2}\|Xw - y\|_2^2$$

由于方程 $Xw = y$ 有无穷多解（解空间是 $d - n$ 维仿射子空间），问题是：**梯度下降会选择哪个解？**

这个问题的答案揭示了深度学习泛化的核心机制。

2.2 推导 A：GD 轨迹始终在 Row(X)

这是一个完全用线性代数和归纳法就能完成的证明。

完整推导：梯度在行空间，轨迹不离行空间

Step 1：写出梯度的显式表达

损失函数：

$$L(w) = \frac{1}{2}\|Xw - y\|_2^2$$

对 w 求梯度：

$$\nabla L(w) = X^\top (Xw - y)$$

Step 2：将梯度展开为行向量的线性组合

设 X 的第 i 行为 $x_i^\top \in \mathbb{R}^{1\times d}$，则 $X^\top$ 的第 i 列就是 $x_i \in \mathbb{R}^d$。

记 $r_i = x_i^\top w - y_i$（第 i 个残差），则：

$$\begin{aligned}
\nabla L(w) &= X^\top (Xw - y) \\
&= X^\top \begin{pmatrix} x_1^\top w - y_1 \\ \vdots \\ x_n^\top w - y_n \end{pmatrix} \\
&= \begin{pmatrix} | & & | \\ x_1 & \cdots & x_n \\ | & & | \end{pmatrix} \begin{pmatrix} r_1 \\ \vdots \\ r_n \end{pmatrix} \\
&= \sum_{i=1}^n r_i \cdot x_i
\end{aligned}$$

关键观察：$\nabla L(w)$ 是 $\{x_1, \ldots, x_n\}$ 的线性组合！

因此：

$$\boxed{\nabla L(w) \in \operatorname{span}\{x_1, \ldots, x_n\} = \operatorname{Row}(X), \quad \forall w}$$

Step 3：归纳证明轨迹始终在行空间

基础情况：$w_0 = 0 \in \operatorname{Row}(X)$（零向量在任何子空间中）

归纳假设：假设 $w_t \in \operatorname{Row}(X)$

归纳步骤：GD 更新为

$$w_{t+1} = w_t - \eta \nabla L(w_t)$$

由归纳假设，$w_t \in \operatorname{Row}(X)$。由 Step 2，$\nabla L(w_t) \in \operatorname{Row}(X)$。

由于 $\operatorname{Row}(X)$ 是线性子空间，它对线性组合封闭：

$$w_{t+1} = \underbrace{1 \cdot w_t}_{\in \operatorname{Row}(X)} + \underbrace{(-\eta) \cdot \nabla L(w_t)}_{\in \operatorname{Row}(X)} \in \operatorname{Row}(X)$$

结论：

$$\boxed{\forall t \geq 0, \quad w_t \in \operatorname{Row}(X)}$$

物理直觉：几何图像

想象 $\mathbb{R}^d$ 空间被分成两个正交的部分：$\operatorname{Row}(X)$（r 维）和 $\operatorname{Null}(X)$（$d - r$ 维）。

GD 从原点出发，但它的”推力”（梯度）永远只指向 $\mathrm{Row}(X)$ 内部。就像一个人被限制在一个平面上滑行，永远无法跳出这个平面。

2.3 推导 B：SVD 坐标下的逐分量分析

现在我们用 SVD 来精确看清 GD 在做什么——这会让伪逆解的出现变得自然而然。

完整推导：在 SVD 坐标系里看 GD

Step 1：SVD 分解

设 $X \in \mathbb{R}^{n\times d}$ 的 SVD 为：

$$X = U\Sigma V^\top$$

其中：

- $U \in \mathbb{R}^{n\times n}$ 是正交矩阵（左奇异向量）
- $V \in \mathbb{R}^{d\times d}$ 是正交矩阵（右奇异向量）
- $\Sigma \in \mathbb{R}^{n\times d}$ 是对角矩阵，$\Sigma = \mathrm{diag}(\sigma_1, \ldots, \sigma_r, 0, \ldots, 0)$
- $r = \mathrm{rank}(X)$，$\sigma_1 \geq \cdots \geq \sigma_r > 0$

Step 2：坐标变换

定义新坐标 $z = V^\top w \in \mathbb{R}^d$（由于 V 正交，$w = Vz$）。

将损失函数改写：

$$\begin{aligned} L(w) &= \frac{1}{2}\|Xw - y\|_2^2 \\ &= \frac{1}{2}\|U\Sigma V^\top w - y\|_2^2 \\ &= \frac{1}{2}\|U\Sigma z - y\|_2^2 \\ &= \frac{1}{2}\|U(\Sigma z - U^\top y)\|_2^2 \\ &= \frac{1}{2}\|\Sigma z - \tilde{y}\|_2^2 \quad (\text{其中 } \tilde{y} = U^\top y) \end{aligned}$$

最后一步用了 U 的正交性：$\|Uv\|_2 = \|v\|_2$。

Step 3：损失函数的分量形式

由于 Σ 是对角的，损失完全解耦：

$$L = \frac{1}{2}\sum_{k=1}^{r}(\sigma_k z_k - \tilde{y}_k)^2 + \frac{1}{2}\sum_{k=r+1}^{n}\tilde{y}_k^2$$

注意：

- 前 r 项依赖于 $z_1, \ldots, z_r$（非零奇异值对应的坐标）
- 后面的项是常数（与 z 无关）
- $z_{r+1}, \ldots, z_d$ 完全不出现在损失中！

Step 4：对每个坐标的 GD

对 $k \le r$（非零奇异值）：

$$\frac{\partial L}{\partial z_k} = \sigma_k(\sigma_k z_k - \tilde{y}_k)$$

GD 更新：

$$z_k^{(t+1)} = z_k^{(t)} - \eta \cdot \sigma_k(\sigma_k z_k^{(t)} - \tilde{y}_k)$$

令 $z_k^* = \tilde{y}_k/\sigma_k$（使得 $\sigma_k z_k^* = \tilde{y}_k$），则：

$$z_k^{(t+1)} - z_k^* = (1 - \eta\sigma_k^2)(z_k^{(t)} - z_k^*)$$

这是一维线性迭代！收敛条件：$|1 - \eta\sigma_k^2| < 1$，即 $0 < \eta < 2/\sigma_k^2$。
若 $\eta < 2/\sigma_{\max}^2$，则所有 $k \le r$ 都满足收敛条件：

$$z_k^{(t)} \to z_k^* = \frac{\tilde{y}_k}{\sigma_k}$$

对 $k > r$（零奇异值）：

$$\frac{\partial L}{\partial z_k} = 0$$

梯度为零，z_k 永不更新。若 $z_k^{(0)} = 0$，则 $z_k^{(t)} = 0, \forall t$。

Step 5：汇总极限解

GD 的极限解在 z 坐标下为：

$$z_k^* = \begin{cases} \tilde{y}_k/\sigma_k = (U^\top y)_k/\sigma_k, & k \le r \\ 0, & k > r \end{cases}$$

这正是 $z^* = \Sigma^+ \tilde{y}$，其中 Σ^+ 是 Σ 的伪逆：

$$\Sigma^+ = \mathrm{diag}(1/\sigma_1, \ldots, 1/\sigma_r, 0, \ldots, 0)$$

Step 6：回到原坐标

$$w^* = Vz^* = V\Sigma^+ U^\top y = X^+ y$$

这就是 Moore-Penrose 伪逆！也可以写成：

$$\boxed{w^* = X^\top (XX^\top)^{-1} y}$$

（当 X 行满秩时，$X^+ = X^\top(XX^\top)^{-1}$）

核心结论：SVD 视角的核心洞见

在 SVD 坐标系下，GD 对每个奇异值方向**独立**做一维迭代：

- **非零奇异值方向**（$k \le r$）：收敛到 $z_k^* = \tilde{y}_k/\sigma_k$
- **零奇异值方向**（$k > r$）：梯度为零，停留在初始值

从 $w_0 = 0$ 出发意味着 $z_0 = 0$，所以零奇异值方向永远是 0。
这就是为什么 GD 找到最小范数解——它**不在零空间方向移动**！

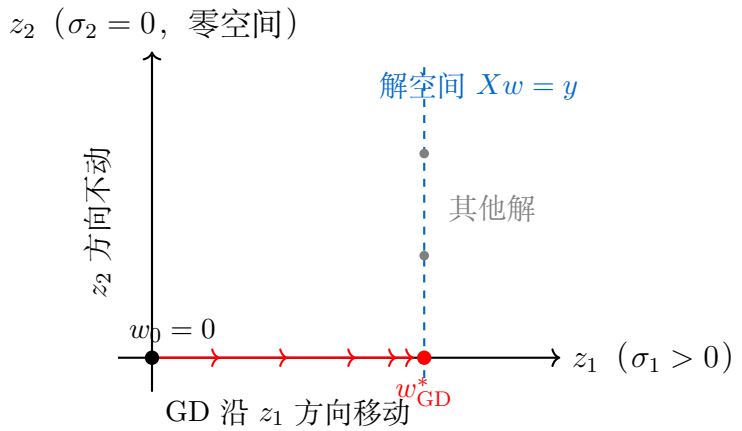

图 1: SVD 坐标下的 GD 轨迹：沿非零奇异值方向移动，零奇异值方向保持为 0，因此收敛到解空间中离原点最近的点。

2.4 最小范数解的意义

定理 2.2 (GD 的隐式正则化). *对于欠定线性回归问题，从 $w_0 = 0$ 出发的梯度下降收敛到最小 ℓ_2 范数解：*

$$w^* = X^\top (XX^\top)^{-1} y = \arg\min_{Xw=y} \|w\|_2$$

证明. 由推导 B，GD 极限解在 SVD 坐标下为 $z_k^* = 0$ 当 $k > r$。

对于任意满足 $Xw = y$ 的解 w，设其 SVD 坐标为 z。由于 $Xw = U\Sigma z = y$，我们有 $\sigma_k z_k = \tilde{y}_k$ 对 $k \le r$，即 $z_k = \tilde{y}_k/\sigma_k = z_k^*$。

但 z_k（$k > r$）可以是任意值。因此：

$$\|w\|_2^2 = \|z\|_2^2 = \sum_{k=1}^{r} (z_k^*)^2 + \sum_{k=r+1}^{d} z_k^2 \ge \sum_{k=1}^{r} (z_k^*)^2 = \|w^*\|_2^2$$

等号成立当且仅当 $z_k = 0$ 对所有 $k > r$，即 $w = w^*$。 □

物理直觉：GD 是”懒惰”的

梯度下降不仅在降低误差，它还在**走捷径**。从原点出发，它选择了一条最短路径直奔解空间。

- **显式正则化**：在 Loss 里加 $\lambda\|w\|^2$，强迫解小。
- **隐式正则化**：什么都不加，但 GD 的动力学本身决定了它偏好小范数解。

这解释了为什么过参数化模型即使没有正则项，也不会随意拟合噪声——因为**拟合噪声通常需要大范数**。

2.5 深度矩阵分解：更强的隐式正则化

当我们用多层网络 $W = W_N W_{N-1} \cdots W_1$ 来参数化一个矩阵时，隐式正则化会变得更强。这一节我们从最简单的**深度 2** 情况开始推导。

2.5.1 问题设定

矩阵分解问题

目标：给定目标矩阵 $Y \in \mathbb{R}^{m\times n}$，用低秩分解去拟合它。

浅层方法（深度 1）：直接优化

$$\min_{W\in\mathbb{R}^{m\times n}} L(W) = \frac{1}{2}\|W - Y\|_F^2$$

显然最优解就是 $W^* = Y$，没有任何正则化效果。

深层方法（深度 2）：用两个矩阵的乘积参数化

$$W = W_2 W_1, \quad W_2 \in \mathbb{R}^{m\times r}, \quad W_1 \in \mathbb{R}^{r\times n}$$

$$\min_{W_1,W_2} L(W_1, W_2) = \frac{1}{2}\|W_2 W_1 - Y\|_F^2$$

问题：这两种方法有什么本质区别?

2.5.2 深度 2 的梯度流分析

Step 1：写出梯度

设残差矩阵 $R = W_2 W_1 - Y$。

对 W_1 的梯度（链式法则）：

$$\frac{\partial L}{\partial W_1} = W_2^\top R = W_2^\top (W_2 W_1 - Y)$$

对 W_2 的梯度：

$$\frac{\partial L}{\partial W_2} = RW_1^\top = (W_2W_1 - Y)W_1^\top$$

Step 2：梯度流方程

离散 GD：$W_i \leftarrow W_i - \eta \nabla_{W_i} L$

梯度流（连续时间极限，$\eta \to 0$）：

$$\dot{W}_1 = -\frac{\partial L}{\partial W_1} = -W_2^\top (W_2W_1 - Y)$$

$$\dot{W}_2 = -\frac{\partial L}{\partial W_2} = -(W_2W_1 - Y)W_1^\top$$

为什么用梯度流？

- 分析更干净（微分方程 vs 差分方程）
- 当步长 η 很小时，离散 GD 近似梯度流
- 核心结论对离散情况也成立

Step 3：$W = W_2W_1$ 的演化

我们关心的是**端到端矩阵** $W = W_2W_1$ 如何演化。

用乘积法则：

$$\begin{aligned}\dot{W} &= \dot{W}_2W_1 + W_2\dot{W}_1 \\ &= -(W - Y)W_1^\top W_1 - W_2W_2^\top (W - Y) \\ &= -(W - Y)W_1^\top W_1 - W_2W_2^\top (W - Y)\end{aligned}$$

记 $A = W_1^\top W_1 \in \mathbb{R}^{r\times r}$（Gram 矩阵），$B = W_2W_2^\top \in \mathbb{R}^{m\times m}$。

则：

$$\boxed{\dot{W} = -B(W - Y) - (W - Y)A}$$

对比浅层：如果直接优化 W，梯度流是

$$\dot{W} = -(W - Y)$$

深层多了 A 和 B 两个”预条件”矩阵！

2.5.3 平衡初始化的魔力

Step 4：平衡初始化

定义：称初始化是**平衡的**（balanced），如果

$$W_1(0)^\top W_1(0) = W_2(0)W_2(0)^\top$$

即 $A(0) = B(0)$（在适当的维度意义下）。
关键引理：平衡性在梯度流下**保持**！
证明：定义 $\Delta = W_1^\top W_1 - W_2 W_2^\top$（假设 $r = m$ 简化讨论）。
计算 $\dot{\Delta}$：

$$\begin{aligned}\frac{d}{dt}(W_1^\top W_1) &= \dot{W}_1^\top W_1 + W_1^\top \dot{W}_1 \\ &= -R^\top W_2 W_1 - W_1^\top W_2^\top R \\ &= -R^\top W - W^\top R\end{aligned}$$

类似地：

$$\frac{d}{dt}(W_2 W_2^\top) = -WR^\top - RW^\top$$

由于 $R = W - Y$，可以验证：

$$\dot{\Delta} = 0 \quad 当\Delta(0) = 0$$

因此，如果初始化平衡，则**永远平衡**。

Step 5：平衡条件下的简化

设平衡初始化，记 $\Sigma = W_1^\top W_1 = W_2 W_2^\top$。
回到 W 的演化：

$$\dot{W} = -\Sigma(W - Y) - (W - Y)\Sigma = -\{\Sigma, W - Y\}$$

其中 $\{A, B\} = AB + BA$ 是**反对易子**（anticommutator）。
关键：演化由 Σ 调制，而 Σ 与 W 的奇异值有关！

2.5.4 奇异值的演化方程

Step 6：用 SVD 分析

设 W 的 SVD 为 $W = U\mathrm{diag}(\sigma_1, \ldots, \sigma_r)V^\top$。
关键观察：在平衡初始化下，W_1 和 W_2 有相同的奇异值。
设 $W_1 = V_1\mathrm{diag}(s_1, \ldots, s_r)U_1^\top$，$W_2 = U_2\mathrm{diag}(t_1, \ldots, t_r)V_2^\top$。
平衡条件 $W_1^\top W_1 = W_2 W_2^\top$ 意味着 $s_i^2 = t_i^2$，即 $s_i = t_i$。
而 $W = W_2 W_1$ 的奇异值满足 $\sigma_i = s_i \cdot t_i = s_i^2$。
因此：

$$\boxed{s_i = \sqrt{\sigma_i}}$$

即每个因子矩阵的奇异值是端到端矩阵奇异值的**平方根**。

Step 7：推导 $\dot{\sigma}_r$

设 Y 在 W 的奇异向量基下的投影系数为 $y_r = u_r^\top Y v_r$。
残差在第 r 个奇异方向的分量：

$$u_r^\top (W - Y) v_r = \sigma_r - y_r$$

奇异值的梯度流演化（技术细节略）：

$$\begin{aligned}
\dot{\sigma}_r &= u_r^\top \dot{W} v_r \\
&= -u_r^\top \{\Sigma, W - Y\} v_r \\
&= -2s_r^2(\sigma_r - y_r) \\
&= -2\sigma_r(\sigma_r - y_r)
\end{aligned}$$

深度 2 的结论：

$$\boxed{\dot{\sigma}_r = -2\sigma_r \cdot (\sigma_r - y_r)}$$

对比浅层（直接优化 W）：

$$\dot{\sigma}_r = -(\sigma_r - y_r)$$

深度 2 多了一个因子 $2\sigma_r$！

2.5.5 深度带来的低秩偏好

Step 8：理解 σ_r 因子的效果

浅层 $\dot{\sigma}_r = -(\sigma_r - y_r)$：

- 所有奇异值以相同速率向目标收敛
- 大的 σ_r 和小的 σ_r 收敛速度相同

深度 2 $\dot{\sigma}_r = -2\sigma_r(\sigma_r - y_r)$：

- 收敛速率被 σ_r 调制
- 大的奇异值变化**更快**
- 小的奇异值变化**更慢**

从零初始化的行为：
如果 $\sigma_r(0) = 0$（或很小），则 $\dot{\sigma}_r \approx 0$。
小的奇异值**被”冻结”**了！
这就是**低秩偏好**：只有已经较大的奇异值才会继续增长，小的奇异值保持接近零。

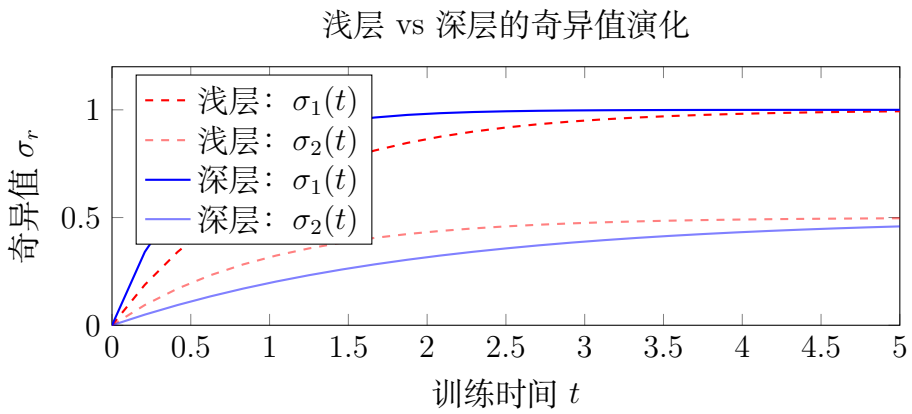

图 2: 深层网络中，大奇异值增长更快，小奇异值被”抑制”。

2.5.6 推广到深度 N

深度 N 的结果

对于深度 N 的分解 $W = W_N W_{N-1} \cdots W_1$：
在平衡初始化下，每个因子的奇异值是 $\sigma_r^{1/N}$。
类似的推导给出：

$$\boxed{\dot{\sigma}_r = -N \cdot \sigma_r^{2-2/N} \cdot (\sigma_r - y_r)}$$

验证：

- $N = 1$（浅层）：$\dot{\sigma}_r = -(\sigma_r - y_r)$
- $N = 2$：$\dot{\sigma}_r = -2\sigma_r(\sigma_r - y_r)$
- $N \to \infty$：$\dot{\sigma}_r \propto -\sigma_r^2(\sigma_r - y_r)$

物理意义：指数 $2 - 2/N$ 随深度增加。
深度越大，小奇异值越被抑制，**低秩偏好越强**。

核心结论：隐式正则化的谱系

模型	奇异值演化	隐式偏好
浅层（$N = 1$）	$\dot{\sigma}_r = -(\sigma_r - y_r)$	无特殊偏好
深度 2	$\dot{\sigma}_r = -2\sigma_r(\sigma_r - y_r)$	轻微低秩偏好
深度 N	$\dot{\sigma}_r \propto -\sigma_r^{2-2/N}(\sigma_r - y_r)$	更强低秩偏好
深度 ∞	$\dot{\sigma}_r \propto -\sigma_r^2(\sigma_r - y_r)$	最强低秩偏好

物理直觉：为什么深度有助于泛化

低秩解通常意味着：

- 更简单的结构
- 更好的压缩
- 更强的泛化能力（类似于隐式的核范数正则化）

深度网络不仅仅是”更多参数”——它们的**参数化方式**本身就带来了正则化效果！

核心结论：隐式正则化的谱系

模型	隐式偏好	数学机制
线性回归 + GD	最小 ℓ_2 范数	轨迹在行空间
深度矩阵分解	低秩	奇异值动力学
深度线性网络	更稀疏的奇异值	深度放大偏好

3 第二部分：AdaBoost——另一种隐式偏好

第一部分我们看到 GD 在欠定线性回归中偏好最小 ℓ_2 范数解，在深度矩阵分解中偏好低秩解。这一节我们看一个完全不同的设定——**Boosting**——同样的故事在另一种语言下重演：训练误差到零之后，算法继续在做 **margin maximization**。

3.1 背景：VC 维与经典泛化理论的极限

在进入 Boosting 算法之前，我们先用 **VC 维**把" 经典泛化直觉" 说精确。这样后面 margin theory 的" 反直觉" 才有清晰的对照背景——也直接回应了第一部分留下的悬念：" 为什么经典理论说参数多必过拟合，深度学习却不？ "

定义 3.1 (Shattering 与 VC 维)**.** *对二分类假设类 $\mathcal{H} \subseteq \{h : \mathcal{X} \to \{-1, +1\}\}$：*

*称 $\mathcal{H}$ **shatter** 点集 $\{x_1, \ldots, x_d\}$，若对任意标签 $(y_1, \ldots, y_d) \in \{\pm 1\}^d$，存在 $h \in \mathcal{H}$ 使 $h(x_i) = y_i$ 对所有 i 成立。*

***VC 维** $d_{VC}(\mathcal{H})$ 是最大可被 shatter 的点集大小。*

直觉：VC 维度量假设类的" 表达灵活性"——能任意标记多少个点。

经典例子：

假设类	VC 维
一维 threshold：$h(x) = \mathrm{sign}(x - \theta)$	2
$\mathbb{R}^d$ 中的线性分类器（仿射超平面）	$d + 1$
$\mathbb{R}^d$ 中的 axis-aligned 决策桩	$O(\log d)$
深度 h 的二叉决策树	$\Theta(2^h)$
W 参数的 ReLU 神经网络	$\tilde{O}(WL)$（深度 L）

$\mathbb{R}^2$ **直观**：直线分类器能 shatter 任意 3 个非共线点（$2^3 = 8$ 种标签都可实现），但 4 个点的 XOR 标签做不到 $\to$ VC 维 $= 3 = d + 1$。

定理 3.2 (VC 泛化界 (Vapnik-Chervonenkis))**.** *设 $\mathcal{H}$ 的 VC 维为 d_{VC}。则以概率 $\geq 1-\delta$，对所有 $h \in \mathcal{H}$ 同时成立：*

$$\underbrace{\Pr_{\mathcal{D}}[h(x) \neq y]}_{\text{真实测试误差}} \leq \underbrace{\widehat{\mathrm{err}}_n(h)}_{\text{训练误差}} + O\left(\sqrt{\frac{d_{VC}\log(n/d_{VC}) + \log(1/\delta)}{n}}\right)$$

3.1.1 证明 sketch

完整证明会出现在统计学习理论课中，这里给出关键构件，让大家看到 d_{VC} 是如何" 涌现" 在最终的复杂度项里的。

VC 界的三步证明

Step 1：单个 h 的集中（Hoeffding）

对固定 h，令 $Z_i = \mathbb{1}[h(x_i) \neq y_i] \in \{0,1\}$，则 $\widehat{\mathrm{err}}_n(h) = \frac{1}{n}\sum Z_i$，$\mathbb{E}[Z_i] = R(h)$（真实误差）。Hoeffding 给出

$$\Pr[|R(h) - \widehat{\mathrm{err}}_n(h)| > \epsilon] \leq 2e^{-2n\epsilon^2}$$

问题：我们要的是**所有** $h \in \mathcal{H}$ 同时成立的界（uniform convergence），不是单个 h。如果 $|\mathcal{H}|$ 有限，union bound 给出 $|\mathcal{H}| \cdot 2e^{-2n\epsilon^2}$，复杂度项 $\sim \sqrt{\log|\mathcal{H}|/n}$。但典型 $\mathcal{H}$ 是**无穷大**的（如所有线性分类器），naive union bound 失败。

Step 2：把”无穷”换成”在 n 个点上的有效假设数”——growth function

定义 $\mathcal{H}$ 限制到 n 个点上的**行为数**：

$$\Pi_{\mathcal{H}}(n) := \max_{x_1,\ldots,x_n} \left|\{(h(x_1),\ldots,h(x_n)) : h \in \mathcal{H}\}\right| \quad \leq 2^n$$

关键事实：在样本上，两个 h 如果给出相同标签向量 $(h(x_1),\ldots,h(x_n))$，它们就**无法被区分**。所以 union bound 只需对 $\Pi_{\mathcal{H}}(n)$ 个等价类做，不必对整个 $\mathcal{H}$。

Sauer-Shelah 引理（d_{VC} 控制 Π）：若 $d_{VC}(\mathcal{H}) = d$，则

$$\boxed{\Pi_{\mathcal{H}}(n) \leq \sum_{i=0}^{d} \binom{n}{i} \leq \left(\frac{en}{d}\right)^d}$$

Sauer-Shelah 的归纳证明：对 n 归纳。设 $\mathcal{H}|_S$ 是 $\mathcal{H}$ 限制到点集 $S = \{x_1,\ldots,x_n\}$。考虑**把** x_n **移除**得到 $S' = \{x_1,\ldots,x_{n-1}\}$ 上的 $\mathcal{H}|_{S'}$。每个 $\mathcal{H}|_{S'}$ 中的元素，要么对应 $\mathcal{H}|_S$ 中一个元素（x_n 上标签确定），要么对应两个（x_n 上 ± 1 都可达）。后者意味着这个标签向量在 S' 上还能被”x_n 翻转扩展”——这定义了一个新的假设类 $\mathcal{H}'$，且 $d_{VC}(\mathcal{H}') \leq d-1$（因为 $\mathcal{H}'$ 在 S' 上 shatter 一组点的话，加上 x_n 就在 S 上 shatter 多一个点）。归纳给出

$$|\mathcal{H}|_S| \leq |\mathcal{H}|_{S'}| + |\mathcal{H}'|_{S'}| \leq \sum_{i\leq d}\binom{n-1}{i} + \sum_{i\leq d-1}\binom{n-1}{i} = \sum_{i\leq d}\binom{n}{i} \quad \square$$

核心信息：从 2^n（粗）降到 n^d（精）——把指数 n 换成多项式 n^d。这个多项式增长是 d_{VC} 在最终界中出现的根本原因。

Step 3：Symmetrization（用 ghost sample）

直接对 $\mathcal{H}$ 的所有 h 做 union bound 还是不行——$\Pi_{\mathcal{H}}(n)$ 取决于具体样本，与 h 的真实误差 $R(h)$ 无关，但 Step 1 的 Hoeffding 涉及的是 $R(h)$。**Symmetrization 技巧**解决这个：

引入与训练样本独立同分布的”ghost sample” $\{(x_i', y_i')\}_{i=1}^n$，记其经验误差为 $\widehat{\mathrm{err}}_n'(h)$。则

$$\Pr\left[\sup_{h\in\mathcal{H}} |R(h) - \widehat{\mathrm{err}}_n(h)| > \epsilon\right] \leq 2\ \Pr\left[\sup_{h\in\mathcal{H}} |\widehat{\mathrm{err}}_n(h) - \widehat{\mathrm{err}}_n'(h)| > \epsilon/2\right]$$

（直觉：$R(h)$ 与 ghost sample 上的经验误差差不多，所以可以用 ghost 替代。）
右边的 sup 现在只涉及**两组样本上的** $2n$ **个点**，$\mathcal{H}$ 在其上的有效行为数 $\leq \Pi_{\mathcal{H}}(2n) \leq (2en/d)^d$。
对每个等价类应用 Hoeffding（双样本版本），union bound：

$$\Pr[\cdot] \leq \Pi_{\mathcal{H}}(2n) \cdot 2e^{-n\epsilon^2/2}$$

Step 4：合成最终界
令右边 $\leq \delta$，解出 ϵ：

$$\epsilon = O\left(\sqrt{\frac{\log \Pi_{\mathcal{H}}(2n) + \log(1/\delta)}{n}}\right) = O\left(\sqrt{\frac{d_{VC}\log(n/d_{VC}) + \log(1/\delta)}{n}}\right)$$

这就是 VC 界的复杂度项。d_{VC} **通过 Sauer-Shelah 进入界中——它是控制"有效假设数"指数增长率的参数**。

物理直觉：VC 界的本质

VC 界本质上是在做：
"*无限假设类 $\mathcal{H}$ 在 n 个样本上 effectively 看起来只有 $\Pi_{\mathcal{H}}(n)$ 个不同的分类器*"
加上 union bound + Hoeffding 就得到了泛化界。VC 维通过 Sauer-Shelah 给出 $\Pi_{\mathcal{H}}(n) \leq (en/d_{VC})^{d_{VC}}$，这就是为什么界中出现 $d_{VC}\log n$。

标准叙事（深度学习时代之前的主流观点）：

- 模型容量 $\leftrightarrow$ VC 维
- 容量越大 $\rightarrow$ 第二项（"复杂度惩罚"）越大
- 训练误差为 0 + 大容量 $\rightarrow$ 上界宽松甚至 **vacuous**（≥ 1，毫无信息）$\rightarrow$ 预测过拟合

VC 视角对 Boosting 的预测
经过 T 轮 boosting，组合假设类

$$\mathcal{F}_T = \left\{ \operatorname{sign}\left(\sum_{t=1}^{T} \alpha_t h_t\right) : \alpha_t \in \mathbb{R}, h_t \in \mathcal{H} \right\}$$

的 VC 维满足（Freund-Schapire 1997）

$$d_{VC}(\mathcal{F}_T) = O\big(T \cdot d_{VC}(\mathcal{H}) \cdot \log T\big)$$

关键预测：T 越大，VC 维近似线性增长 $\rightarrow$ 复杂度惩罚 $\rightarrow \infty \rightarrow$ **应当过拟合**。

物理直觉：即将出现的矛盾

但 Schapire et al. (1998) 的实验给出截然相反的结果：训练 $T = 10000$ 轮（远超训练误差为 0 的轮数 $T_0 \approx 5$–100），测试误差仍在**单调下降**。VC 视角对此完全无法解释。

接下来我们会看到，决定 boosting 泛化性能的不是 T，而是 **margin**：模型的"有效复杂度"由 $1/\theta^2$（margin 倒数平方）控制，**与 T 无关**。

这正是第一部分故事的另一面：**算法本身在做隐式正则化**，而 VC 维作为单一标量太粗糙，捕捉不到这种"算法相关"的复杂度。

深度学习版本的同一悖论：百亿参数大模型 VC 维巨大，按 VC 界预测应严重过拟合，但实际测试性能很好。这个悖论与 boosting 1998 年的悖论是**同一个数学事实在两个时代的化身**。

3.2 弱学习器能否变强？

动机问题（Kearns-Valiant 1988）：

设 $\mathcal{H}$ 是一个"弱"假设类——存在算法能找到比随机略好的分类器（错误率 $\epsilon < 1/2 - \gamma$，$\gamma > 0$）。能否将多个弱学习器组合成一个**强分类器**（任意小错误率）？

Schapire (1990) 给出了肯定回答，AdaBoost (Freund-Schapire 1997) 是最简单的实现。

3.3 AdaBoost 算法

Algorithm 1 AdaBoost

输入：训练集 $\{(x_i, y_i)\}_{i=1}^n$，$y_i \in \{-1, +1\}$；弱学习器类 $\mathcal{H}$；轮数 T
初始化权重：$w_i^{(1)} = 1/n$
for $t = 1, 2, \ldots, T$ **do**
  在加权数据上训练弱学习器：$h_t \in \arg\min_{h \in \mathcal{H}} \sum_i w_i^{(t)} \mathbb{1}[h(x_i) \neq y_i]$
  计算加权错误率：$\epsilon_t = \sum_i w_i^{(t)} \mathbb{1}[h_t(x_i) \neq y_i]$
  计算权重：$\alpha_t = \frac{1}{2} \log \frac{1-\epsilon_t}{\epsilon_t}$
  更新样本权重：$w_i^{(t+1)} \propto w_i^{(t)} \exp(-y_i \alpha_t h_t(x_i))$
end for
输出：$F_T(x) = \sum_{t=1}^T \alpha_t h_t(x)$，分类器 $\mathrm{sign}(F_T)$

第一眼看这个算法，权重更新规则、α_t 公式都像是"魔术"。我们接下来用一个推导让它**自然涌现**——AdaBoost 就是函数空间里的坐标下降。

3.4 核心推导：AdaBoost = 指数损失上的坐标下降

完整推导：从指数损失到 AdaBoost

Step 1：定义指数损失

$$L(F) = \sum_{i=1}^{n} \exp(-y_i F(x_i))$$

直觉：当 $y_i F(x_i) > 0$（分类正确且 margin 大）时，该样本贡献小；分类错误时贡献大且呈指数。这是 **0-1 损失的凸 surrogate**。

Step 2：贪婪坐标下降

我们想构造 $F = \sum_t \alpha_t h_t$，每轮加一个基函数 αh 来最小化 L。

设当前为 F_{t-1}，下一步最优化：

$$(\alpha_t, h_t) = \arg\min_{\alpha \in \mathbb{R},\, h \in \mathcal{H}} L(F_{t-1} + \alpha h)$$

展开：

$$\begin{aligned} L(F_{t-1} + \alpha h) &= \sum_i e^{-y_i F_{t-1}(x_i)} \cdot e^{-y_i \alpha h(x_i)} \\ &= \sum_i w_i^{(t)} \cdot e^{-y_i \alpha h(x_i)} \end{aligned}$$

其中我们**定义**权重 $w_i^{(t)} = e^{-y_i F_{t-1}(x_i)}$——它**自然涌现**于损失的链式分解！

Step 3：对二值 $h(x_i) \in \{-1, +1\}$ 化简

对每个样本，$y_i h(x_i) = +1$ 当 h 分类正确，$= -1$ 当错误。设

$$\epsilon = \frac{\sum_{i: h(x_i) \neq y_i} w_i^{(t)}}{\sum_i w_i^{(t)}} \quad \text{（加权错误率）}$$

把 $W = \sum_i w_i^{(t)}$ 提出来：

$$L(F_{t-1} + \alpha h) = W \left[(1-\epsilon)\, e^{-\alpha} + \epsilon\, e^{+\alpha} \right]$$

Step 4：对 α 一维线搜索

对 α 求导并令其为 0：

$$-(1-\epsilon)e^{-\alpha} + \epsilon e^{+\alpha} = 0 \implies e^{2\alpha^*} = \frac{1-\epsilon}{\epsilon}$$

$$\boxed{\alpha^* = \frac{1}{2} \log \frac{1-\epsilon}{\epsilon}}$$

这就是 AdaBoost 的 α_t 公式！它**不是公理**，是指数损失下的精确一维最优。

Step 5：最优 h 是最小 ϵ 的弱学习器

代回 α^*：

$$L^*(\epsilon) = W \cdot 2\sqrt{\epsilon(1-\epsilon)}$$

这关于 ϵ 是 $\epsilon = 1/2$ **时最大**（无信息），$\epsilon = 0$ **时最小**。所以选 h 时要**最小化加权错误率**——这就是”在加权数据上训练弱学习器”。

Step 6：权重更新规则自然涌现

$$\begin{aligned} w_i^{(t+1)} &= e^{-y_i F_t(x_i)} \\ &= e^{-y_i F_{t-1}(x_i)} \cdot e^{-y_i \alpha_t h_t(x_i)} \\ &= w_i^{(t)} \cdot e^{-y_i \alpha_t h_t(x_i)} \end{aligned}$$

具体来说：

- 分类**正确**（$y_i h_t = +1$）：$w_i^{(t+1)} = w_i^{(t)} e^{-\alpha_t} = w_i^{(t)} \sqrt{\epsilon_t/(1-\epsilon_t)}$，权重**下降**
- 分类**错误**（$y_i h_t = -1$）：$w_i^{(t+1)} = w_i^{(t)} e^{+\alpha_t} = w_i^{(t)} \sqrt{(1-\epsilon_t)/\epsilon_t}$，权重**上升**

这就是 AdaBoost 完整算法。**从一个凸损失上的坐标下降出发，所有”算法细节”都被推出来**。

核心结论：AdaBoost 的本质

AdaBoost 是**函数空间中的贪婪坐标下降**：

- 函数空间：$\mathcal{F} = \mathrm{span}(\mathcal{H})$
- 坐标方向：每个弱学习器 $h \in \mathcal{H}$ 是一个坐标
- 损失：指数损失 $L(F) = \sum_i e^{-y_i F(x_i)}$（凸！）
- 每轮：选一个坐标方向（最优 h）+ 一维线搜索（最优 α）

这个视角揭示：AdaBoost 不需要”魔法”，它就是凸优化在函数空间的体现。

3.5 训练误差的指数收敛

训练误差上界（Schapire-Freund）

由 Step 5：每轮 $L \to L \cdot 2\sqrt{\epsilon_t(1-\epsilon_t)}$。

由 $\mathbb{1}[u \le 0] \le e^{-u}$（指数函数 $\ge$ 阶跃函数），有

$$n \cdot \text{train err}(F_T) = \sum_i \mathbb{1}[y_i F_T(x_i) \le 0] \le \sum_i e^{-y_i F_T(x_i)} = L_T$$

所以：

$$\text{train err}(F_T) \le \frac{L_T}{n} = \prod_{t=1}^{T} 2\sqrt{\epsilon_t(1-\epsilon_t)}$$

定义 **edge**：$\gamma_t = 1/2 - \epsilon_t > 0$（弱学习假设）。则

$$2\sqrt{\epsilon_t(1-\epsilon_t)} = \sqrt{1-4\gamma_t^2}$$

如果所有 $\gamma_t \ge \gamma > 0$：

$$\boxed{\text{train err}(F_T) \le (1-4\gamma^2)^{T/2} \le e^{-2\gamma^2 T}}$$

结论：只要每个弱学习器比随机略好（$\gamma > 0$），训练误差**指数衰减**到 0。

3.6 关键洞察：训练误差到 0 后会发生什么？

物理直觉：反直觉的实验观察

经典 VC 理论预测：模型容量足够大、训练误差到 0 后，继续训练应该**过拟合**。
但 Schapire (1998) 观察：AdaBoost 训练误差达到 0 后（通常很早），**测试误差仍在下降**！甚至在 $T = 10000$ 轮以后，测试误差还能进一步降低。
这看起来违反了 Occam's razor。怎么解释？

答案是 margin theory——和我们第一部分的"训练误差为 0 后 GD 继续降低 $\|w\|$"是同一个故事。

3.6.1 Margin 的定义

对样本 (x, y)，归一化 margin 定义为：

$$\rho(x, y; F) = \frac{y \cdot F(x)}{\|\boldsymbol{\alpha}\|_1} = \frac{y \cdot \sum_t \alpha_t h_t(x)}{\sum_t |\alpha_t|}$$

这个量 $\in [-1, 1]$：

- $\rho > 0$：分类正确，ρ 越大越自信
- $\rho < 0$：分类错误
- 0-1 损失只关心 ρ 的**符号**，但泛化与 ρ 的**大小**相关

3.6.2 关键事实：AdaBoost 持续提升 margin

定理 3.3 (Schapire-Freund-Bartlett-Lee 1998)**.** *即使训练误差已经为 0，AdaBoost 继续运行会**单调提升 margin 分布**：对任意 $\theta < \gamma$（γ 是弱学习器的 edge），*

$$\Pr_n[\rho(x_i, y_i; F_T) \le \theta] \to 0 \quad as\ T \to \infty$$

其中 $\Pr_n$ 是经验分布。

*进而 **margin-based 泛化界**：*

$$\Pr_{\mathcal{D}}[yF(x) \le 0] \le \Pr_n[\rho(x, y) \le \theta] + \tilde{O}\left(\sqrt{\frac{\mathrm{VC}(\mathcal{H})}{n\,\theta^2}}\right)$$

重点：右边的复杂度项与训练轮数 T **无关**！只取决于 margin θ 和**基础**弱学习器类的 VC 维 $d_{VC}(\mathcal{H})$——这就是为什么 AdaBoost 跑很久也不过拟合。

与 VC 界的精确对照：把上面这条 margin 界与开头给出的 VC 界并列，区别一目了然：

VC 界（Freund-Schapire 1997）	复杂度项 $\sim \sqrt{T \cdot d_{VC}(\mathcal{H}) \log T / n}$
Margin 界（SFBL 1998）	复杂度项 $\sim \sqrt{d_{VC}(\mathcal{H}) / (n\theta^2)}$

差别：T 被 $1/\theta^2$ **替代**。后者随 T 增大**不变甚至变好**（因为 margin θ 在持续增长）。这就解决了开头的悖论——VC 界只是上界中的一种，并不是最紧的；margin 界对同一个分类器给出更紧的界。

核心结论：第三个隐式偏好

我们已经见过两个隐式偏好，现在加上第三个：

设定	算法	隐式偏好
线性回归（$d > n$）	GD from $w_0 = 0$	最小 ℓ_2 范数
深度矩阵分解	GD from 平衡初始化	低秩
AdaBoost 二分类	指数损失上的坐标下降	最大 ℓ_1-margin

统一观察：这些算法都能**超出训练误差为 0 的阶段**，继续向某种”简单”解收敛。**优化算法本身在做正则化**——这就是为什么过参数化不一定过拟合。

3.7 Frank-Wolfe 视角

把 AdaBoost 与凸优化经典算法 **Frank-Wolfe**（条件梯度法）联系起来，能更深刻理解它的隐式偏好。

AdaBoost 作为 ℓ_1 球上的 Frank-Wolfe

Frank-Wolfe 算法（一般形式）：对约束凸优化 $\min_{x\in C} f(x)$（C 为有界凸集），每步：

1. $s_t = \arg\min_{s\in C}\langle \nabla f(x_t), s\rangle$ （线性最小化 oracle）
2. $x_{t+1} = (1-\gamma_t)x_t + \gamma_t s_t$

应用到 boosting 设定：
考虑约束集 $C = B\cdot \mathrm{conv}(\mathcal{H}\cup -\mathcal{H})$（$B$ 倍的 ℓ_1 球）。
线性最小化在凸包顶点取到：

$$\arg\min_{F\in C}\langle \nabla L(F_t), F\rangle = \pm B\cdot h^*$$

其中 $h^* = \arg\max_{h\in\mathcal{H}}\left|\sum_i w_i^{(t)} y_i h(x_i)\right|$ = 最优弱学习器（最小化加权错误率）。
隐式偏好的来源：ℓ_1 球的极点（vertex）是**坐标方向**（$\pm B\cdot e_h$），所以 Frank-Wolfe **倾向于稀疏组合**。
这就是 boosting 的"ℓ_1 regularization for free"——不需要写 $\lambda\|\boldsymbol{\alpha}\|_1$，算法本身就会选稀疏组合。
对偶视角（Telgarsky 2013）：AdaBoost 的极限对偶问题是

$$\max_{F:\|F\|_{\mathcal{H}_1}=1}\ \min_i y_i F(x_i)$$

这正是 **ℓ_1-margin 最大化**。

3.8 推广：梯度提升

Friedman (2001) 把这套观点推广到任意可微损失：

Gradient Boosting

对一般损失 $L(y, F(x))$（如平方损失、log loss、Huber loss），每轮：

1. 计算"伪残差"（函数空间负梯度）：
$$r_i^{(t)} = -\left.\frac{\partial L(y_i, F)}{\partial F}\right|_{F=F_{t-1}(x_i)}$$
2. 训练 $h_t \approx r^{(t)}$（用回归弱学习器拟合伪残差，相当于把负梯度向 $\mathcal{H}$ 投影）
3. 一维线搜索：$\alpha_t = \arg\min_\alpha \sum_i L(y_i, F_{t-1}(x_i) + \alpha h_t(x_i))$
4. 更新：$F_t = F_{t-1} + \alpha_t h_t$

解释：函数空间中沿负梯度方向投影到 $\mathcal{H}$ 的最近邻。
特例：

- **平方损失**：伪残差 $r_i = y_i - F_{t-1}(x_i)$（普通残差）
- **指数损失**（二分类）：还原 AdaBoost
- **Logistic loss**：LogitBoost（Friedman-Hastie-Tibshirani 2000）

3.9 现代实践：XGBoost

XGBoost (Chen-Guestrin 2016) 是梯度提升的现代实现，关键改进：

- **二阶信息**：用 Newton 步而非梯度步（$h_t \approx -\nabla L/\nabla^2 L$）
- **显式正则化**：在树结构上加 $\lambda\|h\|^2 + \gamma|\text{leaves}(h)|$
- **近似贪婪分裂**：稀疏感知、并行化

XGBoost 在表格数据上至今仍是 SOTA，是**深度学习未能征服的领域**。这本身值得反思：在某些数据分布下，**显式 + 隐式正则化的组合**可能优于深度网络的端到端学习。

3.10 与深度学习的对比

物理直觉：两种范式的深层联系

Boosting：在固定的弱学习器空间 $\mathcal{H}$ 中做加权组合，**特征空间不变**。
深度学习：通过梯度下降**学习特征表示**，特征空间在演化。
但两者共享深刻的相似性：

- 都依靠**隐式正则化**（max margin / min norm / low rank）
- 都在**超出经典容量界限**时表现良好
- 都依靠某种**贪婪/局部**更新（一次一个 weak learner / 一次一步 GD）

理解 boosting 的隐式偏好让我们对深度学习的隐式偏好有了更深的概念框架。**margin maximization 不是 boosting 独有，而是凸 surrogate loss + 贪婪优化的普遍现象**（Soudry et al. 2018 在 logistic regression 上的工作正是这一思想在线性模型上的体现）。

4 第三部分：高维临界点统计

4.1 问题：为什么 SGD 不会卡住？

非凸函数有大量临界点（满足 $\nabla f = 0$ 的点）。它们可以是：

- **局部极小值**：所有方向向上弯曲
- **局部极大值**：所有方向向下弯曲
- **鞍点**：有些方向向上，有些向下

核心问题：在神经网络的 loss landscape 中，哪种临界点占主导?

4.2 低维直觉是错误的

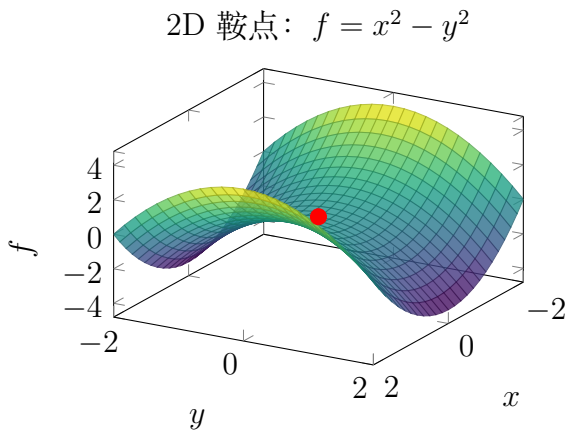

图 3: 二维鞍点：一个方向凸，一个方向凹。在低维空间，这种”平衡”看起来很特殊。

在 2D 或 3D 中，我们的直觉是：

- 极小值和极大值是”常见”的
- 鞍点是”特殊”的（需要曲率正好平衡）

但在高维空间，情况完全相反！

4.3 随机矩阵理论：Wigner 半圆律

为了理解高维临界点，我们需要一点随机矩阵理论。

定理 4.1 (Wigner 半圆律). *设 H 是 $d \times d$ 的随机对称矩阵，其上三角元素独立同分布，均值为 0，方差为 σ^2/d。当 $d \to \infty$ 时，H 的特征值经验分布收敛到**半圆分布**：*

$$\rho(\lambda) = \frac{1}{2\pi\sigma^2}\sqrt{4\sigma^2 - \lambda^2}, \quad \lambda \in [-2\sigma, 2\sigma]$$

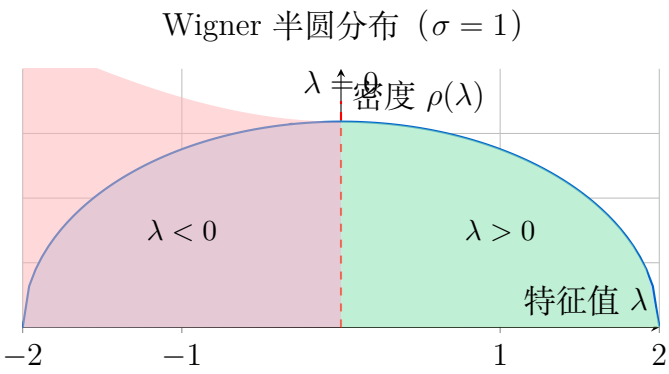

图 4: 半圆分布：特征值在 $[-2, 2]$ 对称分布，正负各占约一半。

4.4 从网络对称性理解 Loss Landscape

理解神经网络 loss landscape 最干净的视角是：直接从**神经网络的对称性**推出其结构。这套论证不依赖任何数据分布假设，也不需要把 NN 类比到统计物理模型上——结论纯粹来自网络结构本身。

数学要点：核心思想

神经网络有大量**置换对称性**：交换两个神经元的权重，网络输出不变。
这意味着：

- 如果 θ^* 是一个极小值，那么所有置换后的 $P\theta^*$ 也是极小值
- 这些等价的极小值之间必然由**鞍点**连接
- Loss landscape 的结构由对称性**完全决定**，与数据分布无关！

4.5 神经元置换对称性

最简单的例子：单隐层网络

考虑一个单隐层网络，m 个隐藏神经元：

$$f(x; W, v) = \sum_{j=1}^{m} v_j \cdot \sigma(w_j^\top x)$$

其中 $w_j \in \mathbb{R}^d$ 是第 j 个隐藏神经元的输入权重，$v_j \in \mathbb{R}$ 是输出权重。
关键观察：如果我们**交换**第 i 个和第 j 个神经元，即

$$(w_i, v_i) \leftrightarrow (w_j, v_j)$$

网络的输出**完全不变**！（因为求和可交换）

推论：对于任意 m 个神经元的排列 $\pi \in S_m$，定义置换后的参数

$$\theta^\pi = (w_{\pi(1)}, v_{\pi(1)}, \ldots, w_{\pi(m)}, v_{\pi(m)})$$

则 $f(x;\theta) = f(x;\theta^\pi)$，因此 $L(\theta) = L(\theta^\pi)$。

核心结论：对称性带来的极小值数量

如果 θ^* 是一个全局最小值，那么 θ^* 的所有 $m!$ 个置换都是全局最小值！

- $m = 10$：$10! = 3,628,800$ 个等价极小值
- $m = 100$：$100! \approx 10^{158}$ 个等价极小值

这些极小值在参数空间中是**离散**的不同点，但它们的 loss 值完全相同。

4.6 定量分析：有多少鞍点？

现在我们来精确计算鞍点的数量。

从对称群到鞍点计数

置换群的结构

m 个神经元的置换群是 S_m，它有 $m!$ 个元素。

群 S_m 可以由**相邻对换**生成：

$$S_m = \langle \tau_{12}, \tau_{23}, \ldots, \tau_{(m-1)m} \rangle$$

其中 τ_{ij} 表示交换第 i 和第 j 个神经元。

Cayley 图的视角

把每个等价极小值 θ^π 看作图的一个顶点，如果两个顶点通过一次相邻对换连接，就画一条边。

这就是置换群 S_m 关于相邻对换生成元的 **Cayley 图**。

关键事实：

- 顶点数 $= m!$（等价极小值的数量）
- 每个顶点的度数 $= m - 1$（可以做 $m - 1$ 种相邻对换）
- 边数 $= \frac{m! \cdot (m-1)}{2}$（每条边连接两个顶点）

每条边对应一个鞍点

核心论证：
考虑两个相邻的等价极小值 θ^* 和 $\tau_{ij}\theta^*$（只交换神经元 i 和 j）。
它们在参数空间中是**不同的点**，但 loss 值相同。
连接它们的路径上，loss 必须先升后降（否则违反极小值定义）。
因此路径上至少有一个 **index-1 鞍点**（恰好一个负特征值方向）。
鞍点数量的下界：

$$\#\{\text{index-1 鞍点}\} \geq \frac{m!(m-1)}{2}$$

更高 index 的鞍点

不仅有 index-1 鞍点，还有更高 index 的鞍点！
考虑同时交换多对神经元：
设 θ^* 是极小值，考虑置换 $\pi = \tau_{12}\tau_{34}$（同时交换 1-2 和 3-4）。
从 θ^* 到 $\pi\theta^*$ 的”直接”路径上，有一个 **index-2 鞍点**。
一般规律：
同时交换 k 对不相交的神经元，对应一个 **index-k 鞍点**。
最多可以同时交换 $\lfloor m/2 \rfloor$ 对，所以存在高达 index-$\lfloor m/2 \rfloor$ 的鞍点。

精确计数：index-k 鞍点的数量

问题：有多少种方式选择 k 对不相交的神经元进行交换？
组合计数：
从 m 个神经元中选 k 对不相交的：

$$N_k = \frac{1}{k!}\binom{m}{2}\binom{m-2}{2}\cdots\binom{m-2k+2}{2} = \frac{m!}{2^k k!(m-2k)!}$$

这是选择 k 个不相交对换的方式数。
index-k 鞍点数量：

$$\#\{\text{index-}k\text{ 鞍点}\} = m! \cdot N_k / |\text{稳定子}|$$

对于”一般位置”的极小值，稳定子是平凡的，所以：

$$\#\{\text{index-}k\text{ 鞍点}\} \approx \frac{(m!)^2}{2^k k!(m-2k)!}$$

核心结论：鞍点 vs 极小值的数量对比

极小值数量（来自对称性）：

$$\#\{\text{等价极小值}\} = m!$$

index-1 鞍点数量：

$$\#\{\text{index-1 鞍点}\} \approx \frac{m!(m-1)}{2}$$

比值：

$$\frac{\#\{\text{index-1 鞍点}\}}{\#\{\text{极小值}\}} = \frac{m-1}{2}$$

数值例子（$m = 100$ 个隐藏神经元）：

- 极小值：$100! \approx 10^{158}$ 个
- index-1 鞍点：$\approx 50 \times 100! \approx 5 \times 10^{159}$ 个
- 鞍点比极小值多 ≈ 50 倍！

而且这还只是 index-1 的鞍点，加上所有 index 的鞍点，比例更悬殊。

4.7 基于对称性的概率论证

从计数到概率

问题：随机采样一个临界点，它是极小值的概率是多少？

基于对称性的论证：

设 loss landscape 中（由对称性产生的）临界点总数为：

$$\#\{\text{临界点}\} = \#\{\text{极小值}\} + \sum_{k=1}^{\lfloor m/2 \rfloor} \#\{\text{index-}k\text{ 鞍点}\}$$

计算总鞍点数：

$$\begin{aligned}\sum_{k=1}^{\lfloor m/2 \rfloor} N_k &= \sum_{k=1}^{\lfloor m/2 \rfloor} \frac{m!}{2^k k!(m-2k)!} \\ &\approx m! \sum_{k=1}^{\lfloor m/2 \rfloor} \frac{1}{2^k k!} \quad (\text{当 } m \text{ 大时})\end{aligned}$$

注意到 $\sum_{k=0}^{\infty} \frac{1}{2^k k!} = e^{1/2} \approx 1.65$，所以：

$$\sum_{k=1}^{\lfloor m/2 \rfloor} N_k \approx m! \cdot (e^{1/2} - 1) \approx 0.65 \cdot m!$$

结论：

$$P(\text{临界点是极小值}) = \frac{m!}{m! + 0.65 \cdot m! \cdot m!} \approx \frac{1}{0.65 \cdot m!}$$

当 $m = 100$ 时，这个概率 $\approx 10^{-158}$！

物理直觉：对称性论证的力量

这个论证有几个值得强调的特点：

- **结构性**：只用了网络的置换对称性 S_m，没有用任何数据分布假设
- **可精确计算**：$m!$ 个等价极小值是**精确的**（不是渐近近似）
- **鞍点比极小值多 $O(m!)$ 倍**：当 m 不太小时这是天文数字

警示：对称性只能解释”对称产生的”鞍点，并不排除其他来源的鞍点（数据相关的、激活函数引入的等）。但仅这一类来源就已足够说明在过参数化网络中，鞍点是**结构性必然**，而非”运气不好”才碰到的特殊情况。

S_3 的 Cayley 图（$m = 3$ 个神经元）

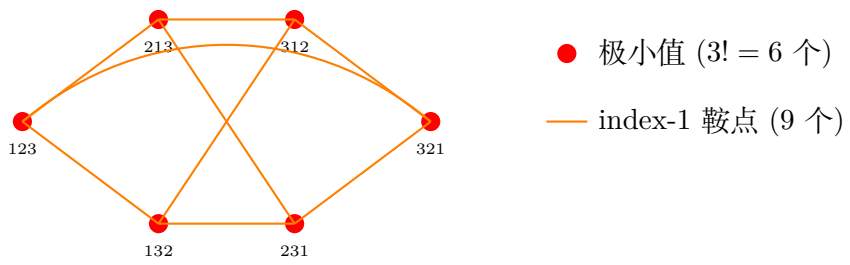

图 5: $m = 3$ 时的对称性结构：6 个等价极小值，9 个 index-1 鞍点连接它们。

4.8 等价极小值之间必有鞍点：拓扑论证

拓扑论证：为什么必有鞍点

设定：设 θ_A 和 $\theta_B = P\theta_A$ 是两个等价的全局最小值（P 是某个置换）。
问题：θ_A 和 θ_B 之间的 loss landscape 是什么样的？
论证：
考虑连接 θ_A 和 θ_B 的**任意连续路径** $\gamma : [0, 1] \to \mathbb{R}^d$，$\gamma(0) = \theta_A$，$\gamma(1) = \theta_B$。
沿路径的 loss 值 $L(\gamma(t))$ 是一个连续函数，满足：

- $L(\gamma(0)) = L(\gamma(1)) = L^*$（全局最小值）
- 如果 $\theta_A \neq \theta_B$（它们在参数空间中是不同的点）

两种情况：
情况 1：路径上 $L(\gamma(t)) = L^*$ 恒成立（整条路径都是全局最小值）
$\Rightarrow$ 全局最小值形成**连通集**
情况 2：路径上存在 t^* 使得 $L(\gamma(t^*)) > L^*$
$\Rightarrow$ 路径上必有一个**极大点**（局部极大或鞍点）
由于深度网络通常不会有”全局最小值的连续流形”（除非特殊退化情况），情况 2 更常见。
结论：等价极小值之间至少存在一个鞍点！

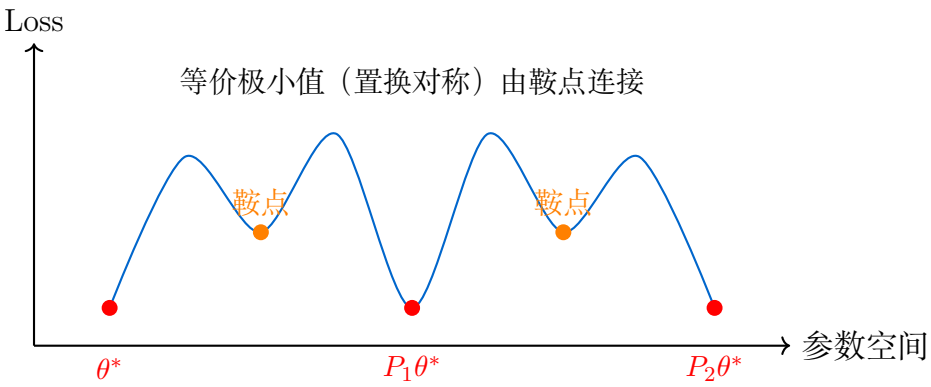

图 6: 置换对称性产生等价极小值，它们之间由鞍点连接。

4.9 定量分析：鞍点的 index

交换两个神经元的鞍点（Simsek et al. 2021）

考虑最简单的置换：交换神经元 i 和 j。
设 $\theta^* = (\ldots, w_i, v_i, \ldots, w_j, v_j, \ldots)$ 是极小值，$P_{ij}\theta^*$ 是交换后的等价极小值。
核心想法：直接看两者的**中点**（merged 配置）：

$$\theta_{ij}^{\text{mid}} := \tfrac{1}{2}\big(\theta^* + P_{ij}\theta^*\big)$$

具体地，在中点处：

$$w_i^{\text{mid}} = w_j^{\text{mid}} = \tfrac{1}{2}(w_i + w_j), \quad v_i^{\text{mid}} = v_j^{\text{mid}} = \tfrac{1}{2}(v_i + v_j)$$

其他神经元保持不变。**两个神经元”合并”了**。
为什么中点是临界点？——对称性论证
定义 **merged 子空间**：

$$M_{ij} = \{\theta : w_i = w_j,\ v_i = v_j\}$$

在 M_{ij} 上，loss 实际只看到 $m-1$ 个有效神经元——神经元 i,j 合并为单个有效神经元，输出贡献为 $(v_i+v_j)\sigma(w_i^\top x)$。
引入对称分解：把 i,j 的参数写成

$$w_i=\bar{w}+\delta_w,\quad w_j=\bar{w}-\delta_w;\quad v_i=\bar{v}+\delta_v,\quad v_j=\bar{v}-\delta_v$$

其中 $\bar{w},\bar{v}$ 是**对称分量**，δ_w,δ_v 是**反对称分量**。中点对应 $\delta_w=\delta_v=0$。
关键事实：交换 $i\leftrightarrow j$ 等价于 $(\delta_w,\delta_v)\to(-\delta_w,-\delta_v)$。由 loss 的置换不变性：

$$L(\bar{w},\bar{v},\delta_w,\delta_v)=L(\bar{w},\bar{v},-\delta_w,-\delta_v)$$

所以 loss 关于 (δ_w,δ_v) 是**偶函数**。
推论 1：临界条件
偶函数在 0 处的一阶导自动为零：

$$\left.\frac{\partial L}{\partial\delta_w}\right|_{\delta=0}=0,\quad \left.\frac{\partial L}{\partial\delta_v}\right|_{\delta=0}=0$$

加上对称方向（$\bar{w},\bar{v}$）上由原优化条件继承的 $\partial L/\partial\bar{w}=0$ 等，θ_{ij}^{mid} 是**临界点**。
推论 2：是鞍点而不是极小值
沿反对称方向二阶展开：

$$L(\theta_{ij}^{\text{mid}}+\delta)=L(\theta_{ij}^{\text{mid}})+\tfrac{1}{2}\delta^\top H_\perp\delta+O(\|\delta\|^4)$$

（偶函数没有奇数阶项。）
但注意：从 θ_{ij}^{mid} 出发，沿反对称方向走到 $(\delta_w,\delta_v)=\frac{1}{2}(w_i-w_j,\ v_i-v_j)$ 时**恰好回到** θ^*！
由 $L(\theta^*)<L(\theta_{ij}^{\text{mid}})$（假设原极小值非平凡且合并损失了表达能力），存在反对称方向使得 loss 减小 $\to H_\perp$ **至少有一个负特征值**。
所以 θ_{ij}^{mid} 是**至少 index-1 鞍点**。

物理直觉：一行总结

两个神经元”合并”得到的配置 θ_{ij}^{mid} 是临界点（由 $i\leftrightarrow j$ 对称性下 loss 的偶性强制），且合并通常降低模型表达力 $\to$ loss 升高 $\to$ 沿”分开两神经元”方向有负曲率 $\to$ 鞍点。
完全代数/对称性的论证，不需要任何动力学或随机性。

物理直觉：对称性鞍点的特殊性

这些由对称性产生的鞍点是**"好"的鞍点**：

1. 它们连接**等价**的全局最小值
2. 沿负曲率方向走，会到达另一个全局最小值
3. SGD 在这些鞍点附近不会"卡住"——随机扰动会推向某个极小值

这些鞍点有**明确的几何意义**：它们是参数空间中"两个神经元被强制相同"的子空间上的临界点。这与"随机鞍点"完全不同——它们是网络对称性的结构产物。

4.10 符号对称性

除了置换对称，还有另一种重要对称性。

ReLU 网络的符号对称性

如果同时翻转神经元 j 的输入和输出权重符号：

$$(w_j, v_j) \to (-w_j, -v_j)$$

对于 ReLU，这**不会**保持输出不变（因为 $\mathrm{ReLU}(-z) \neq -\mathrm{ReLU}(z)$）。
但对于 **Leaky ReLU** 或其他奇对称激活函数：

$$\sigma(-z) = -\sigma(z) \Rightarrow v_j \sigma(w_j^\top x) = (-v_j)\sigma((-w_j)^\top x)$$

推论：每个神经元有 2 种等价配置，m 个神经元共 2^m 种。
结合置换对称，总共有 $m! \times 2^m$ 个等价极小值！

4.11 过参数化下的全局极小值流形

当网络**过参数化**（参数量 $\gg$ 数据量）时，情况更加有趣。

过参数化的几何（Cooper 2018, Freeman & Bruna 2016）

设定：n 个训练样本，网络参数 d 维，$d \gg n$。
定理（非正式）：对于足够宽的网络，使得训练 loss $= 0$ 的参数集合是一个**连通的高维流形**。
直觉：

- 方程 $f(x_i; \theta) = y_i$（$i = 1, \ldots, n$）定义了 n 个约束
- 在 d 维参数空间中，解集通常是 $d - n$ 维

- 当 $d \gg n$ 时，这个流形是**高维且连通的**

结合对称性：

- 所有 $m! \times 2^m$ 个对称副本都在这个流形上
- 它们不再是孤立的点，而是流形上的不同区域
- 鞍点成为流形的”颈部”（连接不同区域）

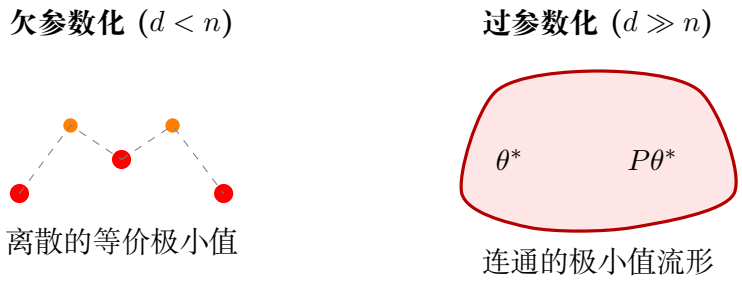

图 7: 欠参数化 vs 过参数化：后者的全局最小值形成连通流形。

4.12 Mode Connectivity：实验验证

Mode Connectivity 实验（Draxler et al. 2018, Garipov et al. 2018）

实验设计：

1. 从不同随机初始化训练同一网络，得到两个解 θ_A 和 θ_B
2. 寻找连接它们的**低 loss 路径**

发现：

- **直线路径** $\theta_A \to \theta_B$：通常有高 loss barrier
- **曲线路径**（Bezier 曲线或折线）：可以找到几乎平坦的路径！

解释：

- θ_A 和 θ_B 可能是某个 θ^* 的不同对称副本
- 或者它们在同一个连通的极小值流形上
- 直线路径”穿过”高 loss 区域，曲线路径”绕过”

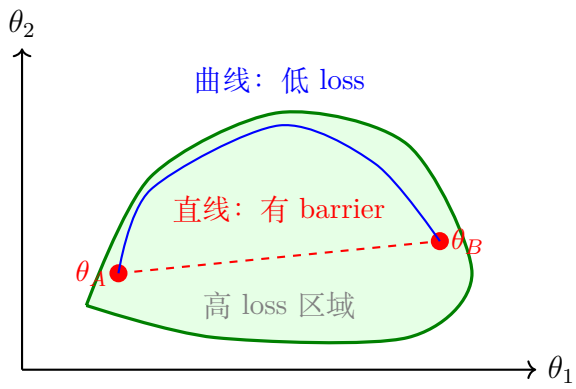

图 8: Mode Connectivity：直线路径穿过高 loss 区域，但存在沿着低 loss 流形的曲线路径。

4.13 综合：对称性视角的优势

核心结论：对称性视角的优势

这套对称性论证的几个关键特性：

1. **不依赖数据分布**：对称性是网络结构的性质，与数据无关
2. **可精确计算**：$m!$ 个等价极小值是精确的，不是渐近近似
3. **几何直觉清晰**：鞍点连接等价极小值，每个鞍点都有明确意义
4. **可实验验证**：Mode Connectivity 直接检验了这个图景

回答原始问题：
Q: 为什么 SGD 不会卡在鞍点？
A: 因为大部分鞍点是连接等价极小值的"通道"。SGD 的噪声会推动参数沿负曲率方向走，最终到达某个极小值。过参数化时，这些极小值形成连通流形，SGD 本质上是在流形上漫步。

4.14 关键计算：成为极小值的概率

板书推导：指数小的概率

问题：一个临界点是局部极小值的概率是多少?
条件：所有 d 个 Hessian 特征值都必须为正。
简化模型：假设特征值的正负性独立（半圆律给出 $P(\lambda_i > 0) \approx 0.5$）。

$$P(\text{Local Min}) = P(\lambda_1 > 0) \cdot P(\lambda_2 > 0) \cdots P(\lambda_d > 0) \approx 0.5^d = 2^{-d}$$

数值估计：

- $d = 100$: $P \approx 2^{-100} \approx 10^{-30}$
- $d = 1000$: $P \approx 10^{-300}$
- $d = 10^6$（典型神经网络）：$P \approx 10^{-300000}$ ！

结论：在高维空间中，**几乎所有临界点都是鞍点**！

物理直觉：维数诅咒变成祝福：但只是故事的一半

在二维空间，如果所有方向都正曲率（前面堵住了），我们就卡住了。
但在 $d = 10^6$ 维空间，只要有**一个**维度的曲率是负的，GD 就可以沿着这个方向"滑下去"。半圆律给出 $P(\text{所有}d\text{ 方向同时正}) = 2^{-d}$，这是天文小概率。
但故事远不止于此。"鞍点多"不直接等于"优化容易"——真正决定优化难度的是**鞍点的"质量"**和低 loss 解的几何结构。下面两小节展开这个更精细的图景。

4.15 关键区分：结构性鞍点 vs 病理性鞍点

到目前为止我们建立了"几乎所有临界点都是鞍点"的图景。但这个陈述**过于粗糙**——**鞍点之间也不一样**。

核心结论：鞍点的两种类型

结构性鞍点（"好鞍点"）：由网络对称性强制产生的鞍点：

- 神经元合并配置（$w_i = w_j$，$v_i = v_j$）——上一节我们刚证明过的中点
- Leaky ReLU 网络的符号翻转中点
- 缩放对称性下的退化配置

特征：

- 有**清晰的负曲率方向**（"分开两神经元"等具体几何方向）
- 沿负曲率方向走可达**等价极小值**
- SGD 噪声容易投影到逃离方向 → 不会卡住

病理性鞍点（"坏鞍点"）：高 loss、负曲率很弱、周围近似平坦的临界点：

- 没有强逃离方向
- loss 显著高于全局极小

- 真正可能拖慢优化的就是这种

核心区别：

$$\boxed{\text{鞍点多} \not\Longleftrightarrow \text{坏鞍点多}}$$

高维 + 对称性带来的”鞍点多”主要是结构性鞍点——它们**不是**优化障碍，更像是低 loss 区域之间的”山口”或”通道”。

4.16 什么真正改善了优化？

把以上观察统合起来，我们可以**重新定位**过参数化对优化的真正贡献。

一个常见的**错误叙事**是说：”大网络更好训练，因为鞍点更少。”事实恰恰相反——过参数化**增加**了结构性鞍点（更多对称性 → 更多等价极小值 → 更多连接它们的鞍点）。

正确的叙事是：

核心结论：大网络更好训练的真正原因

1. **鞍点数量更多，但它们也更易逃**：高 index 鞍点有许多负曲率方向，SGD 噪声容易投影到某个负方向上
2. **病理性极小值变得稀少**：训练约束 $f(x_i;\theta) = y_i$ 只有 n 个，参数 $d \gg n$ 时，”无解”或”高 loss 解”的情况罕见
3. **低 loss 解从孤立点变为高维流形**：解集维数 $\geq d - n$（下一节用 Hessian 秩精确刻画）
4. **Mode connectivity**：低 loss 区域之间通常**连通**，优化器在等价区域间几乎自由穿梭

综合结论：

$$\boxed{\text{大网络不是因为 landscape 更简单，而是因为 landscape 更冗余。}}$$

物理直觉：”冗余”的具体含义

”冗余”在这里有几层精确含义：

- **参数冗余**：同一个低 loss 状态对应 $\sim m! \cdot 2^m$ 个等价参数配置
- **解集冗余**：满足训练约束的解集是 $(d-n)$ 维流形，不是孤立点
- **路径冗余**：任意两个低 loss 解之间通常有低 loss 路径连通
- **曲率冗余**：Hessian 在解流形上有 $\geq d - n$ 个零特征值——大量平坦方向

核心直觉：优化器”撞上”低 loss 区域的目标空间是巨大的——**不需要精确导航到一个孤立点**。这是大网络相对小网络真正的优化优势。

5 第四部分：逃离鞍点的理论

既然高 loss 区域几乎都是鞍点，我们需要回答：**如何有效逃离鞍点？**

5.1 Strict Saddle 的定义

定义 5.1 (Strict Saddle)**.** 一个临界点 w^* 是 ***strict saddle***，如果：

1. $\nabla f(w^*) = 0$（是临界点）
2. $\lambda_{\min}(\nabla^2 f(w^*)) < 0$（*Hessian* 有负特征值）

根据上一节的随机矩阵理论分析，**高维空间中的鞍点几乎都是 strict saddle**（概率趋近于 1）。

5.2 负曲率方向的逃逸

板书推导：沿负曲率方向的指数增长

设 w^* 是一个 strict saddle，Hessian 最小特征值为 $\lambda_{\min} < 0$，对应特征向量为 v。考虑从 $w^* + \epsilon v$ 出发的 GD 轨迹（ϵ 很小）。

局部近似：在 w^* 附近，loss 可以二次近似为

$$f(w) \approx f(w^*) + \frac{1}{2}(w - w^*)^\top H(w - w^*)$$

沿 v 方向的动力学：

$$\frac{d}{dt}(w - w^*)^\top v = -\eta\lambda_{\min}(w - w^*)^\top v$$

由于 $\lambda_{\min} < 0$，这是一个**指数增长**！

设 $\delta_t = (w_t - w^*)^\top v$，则：

$$\delta_t = \delta_0 \cdot (1 - \eta\lambda_{\min})^t = \delta_0 \cdot (1 + \eta|\lambda_{\min}|)^t$$

结论：只要初始点在负曲率方向有微小分量，GD 会以指数速度逃离鞍点。

5.3 扰动梯度下降

Algorithm 2 Perturbed Gradient Descent

```
初始化 w_0
for t = 0, 1, 2, ... do
    if ||∇f(w_t)|| < ε（接近临界点） then
        w_t ← w_t + ξ，其中 ξ ~ Uniform(B_r)（在半径 r 的球内均匀采样）
    end if
    w_{t+1} = w_t − η∇f(w_t)
end for
```

定理 5.2 (Jin et al., 2017)**.** *对于满足 Lipschitz 条件的函数，Perturbed GD 在 $O(poly(d, 1/\epsilon))$ 时间内收敛到*二阶驻点（*满足 $\nabla f = 0$ 且 $\nabla^2 f \succeq -\epsilon I$*）。

物理直觉：SGD 的内置扰动

在实践中，我们很少需要显式添加扰动，因为 **SGD 的梯度噪声**已经自带扰动！Mini-batch 梯度的方差会在鞍点附近提供”随机推力”，帮助逃离。
这解释了为什么 SGD 在深度学习中比确定性 GD 更受欢迎——噪声不是 bug，是 feature！

6 第五部分：Hessian 谱的经验分析

从理论到实验：真实神经网络的 Hessian 谱长什么样？

6.1 计算挑战

数学要点：Hessian 的规模问题

对于参数量为 d 的神经网络：

- Hessian 矩阵 $H \in \mathbb{R}^{d\times d}$
- 现代网络 $d \sim 10^6 - 10^9$
- 存储 H 需要 d^2 个数，即 $10^{12} - 10^{18}$ 个浮点数
- **完全不可行！**

解决方案：随机 Lanczos 方法——只计算 Hessian-向量积，不存储完整 Hessian。

随机 Lanczos 算法简介

核心思想：我们只需要 Hessian 的特征值分布，不需要所有特征向量。
Hessian-向量积：对于损失函数 $L(\theta)$，可以通过两次反向传播计算 Hv：

$$Hv = \nabla_\theta(\nabla_\theta L \cdot v)$$

Lanczos 迭代：通过 k 次 Hessian-向量积，构建 k 维 Krylov 子空间，在其中近似特征值分布。
复杂度：$O(kd)$ 而非 $O(d^2)$！

6.2 为什么是 Bulk + Outliers？——Gauss-Newton 视角

实验观察到 Hessian 谱有 bulk + outliers 结构。我们可以从一个干净的代数事实理解这个结构的起源：在插值解附近，Hessian 的秩被**训练样本数** n 严格限制。

板书推导：插值解附近的 Hessian 秩

设定：考虑 MSE 损失

$$L(\theta) = \frac{1}{2}\sum_{i=1}^{n} r_i(\theta)^2, \quad r_i(\theta) := f(x_i;\theta) - y_i$$

设 Jacobian $J(\theta) \in \mathbb{R}^{n\times d}$，其第 i 行是 $\nabla_\theta r_i^\top$。
Step 1：Hessian 的 Gauss-Newton 分解
链式法则计算：

$$\nabla L = \sum_i r_i \nabla r_i = J^\top r$$

$$\nabla^2 L = \underbrace{J^\top J}_{\text{Gauss-Newton 项}} + \underbrace{\sum_i r_i \nabla^2 r_i}_{\text{残差项}}$$

Step 2：插值解附近的简化
在过参数化设定下，训练 loss 接近 0 意味着 $r_i(\theta) \approx 0$ 对所有 i。残差项消失：

$$\boxed{\nabla^2 L(\theta) \approx J(\theta)^\top J(\theta)}$$

Step 3：秩的硬约束
由于 $J \in \mathbb{R}^{n\times d}$ 且 $d \gg n$：

$$\operatorname{rank}(J^\top J) = \operatorname{rank}(J) \le \min(n, d) = n$$

所以 $\nabla^2 L$ 在插值解附近：

- 至多 n 个**非零正特征值**（来自 $J^\top J$ 的谱）

- 至少 $d-n$ 个**零特征值**

Step 4：零特征值的几何含义
设 $v \in \ker(J^\top J)$，等价于 $Jv = 0$。这意味着：

$$J(\theta)v = \begin{pmatrix} \nabla r_1^\top v \\ \vdots \\ \nabla r_n^\top v \end{pmatrix} = 0$$

即沿 v 方向走，所有残差 r_i 都**不变**（一阶近似下）——这正是**解流形** $M = \{\theta : f(x_i;\theta) = y_i, \forall i\}$ 在该点的**切空间**。
切空间维数 $\geq d-n$，与" 约束 n 维 + 参数 d 维 $\Rightarrow$ 解集 $(d-n)$ 维" 完全一致。

核心结论：Bulk + Outliers 的理论起源

Gauss-Newton 分解直接给出 Hessian 的两部分结构：

部分	特征值数量	含义
Bulk（$\lambda \approx 0$）	$\geq d-n$	解流形切空间——loss 平坦方向
Outliers（$\lambda > 0$）	$\leq n$	$J^\top J$ 谱——数据拟合曲率

关键预测：outlier 数量上界恰好是**训练样本数** n。这个理论预测与 Sagun, Papyan 等人的实验观察**定量吻合**。

物理直觉：与第三部分的呼应

我们在第三部分用对称性 + 流形论证说" 低 loss 解集是 $(d-n)$ 维流形"。Gauss-Newton 给出同一结论的**微分几何刻画**：
$d-n$ **维平坦方向** = 解流形的切空间 = Hessian 的零空间。
这就是" 过参数化让 landscape 更冗余" 的精确数学陈述：冗余的" 维度数量" 等于 $d-n$，恰好是 Hessian 零特征值的下界。

6.3 实验观察：Bulk + Outliers 结构

Sagun, Papyan 等人的实验揭示了神经网络 Hessian 的普遍结构：

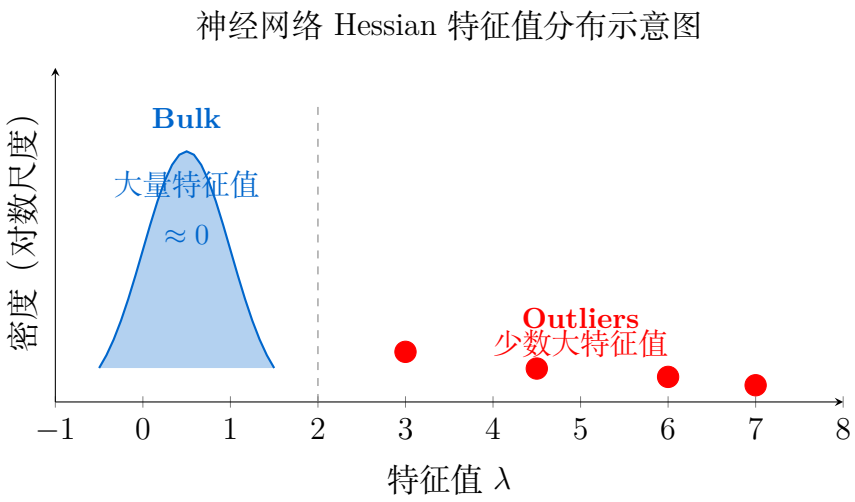

图 9: Hessian 谱的典型结构：大量特征值集中在 0 附近（Bulk），少数特征值很大（Outliers）。

核心结论：Hessian 谱的两部分

1. **Bulk**（主体）：
   - 绝大多数特征值接近 0
   - 对应 loss landscape 的”平坦方向”
   - 这些方向上参数变化对 loss 影响很小
2. **Outliers**（离群值）：
   - 少数（通常 $O(n)$ 个，n 是数据量）大特征值
   - 对应”学到的主要特征”的方向
   - 沿这些方向移动会显著改变网络输出

6.4 与随机矩阵理论的联系

数学要点：Bulk 与 Marchenko-Pastur 分布

当网络未充分训练时，Hessian 的 bulk 部分类似于 **Marchenko-Pastur 分布**——这是随机矩阵 $\frac{1}{n}X^\top X$ 特征值的渐近分布。
随着训练进行，outliers 从 bulk 中”跳出”，这对应于**信号从噪声中分离**。

$$\text{Outliers} \leftrightarrow \text{学到的特征}$$

7 第六部分：Edge of Stability——超越经典稳定性

第五部分我们看到 Hessian 谱有 bulk + outliers 结构。一个自然的问题是：在训练过程中，**最大特征值** $\lambda_{\max}(H_t)$ 怎么演化？经典优化理论会给一个明确预测——但实验告诉我们的，是另一个故事。

7.1 经典稳定性条件回顾

GD 在二次目标上的稳定性

考虑 $f(x) = \frac{1}{2}x^\top Hx$，$H \succ 0$ 对称正定。
GD 更新：$x_{t+1} = (I - \eta H)x_t$。
在 H 的特征基下：每个分量独立演化，$x_t^{(k)} = (1 - \eta\lambda_k)^t\, x_0^{(k)}$。
收敛条件：$|1 - \eta\lambda_k| < 1$ 对所有 k 成立，即

$$\boxed{\eta < \frac{2}{\lambda_{\max}(H)}}$$

如果 $\eta > 2/\lambda_{\max}$：最大特征值方向上 $|1 - \eta\lambda_{\max}| > 1$，分量**指数发散**。
这是凸优化教科书的标准结果。对一般强凸光滑函数，类似结论成立（用 L-smoothness 替代 $\lambda_{\max}$）。

7.2 反直觉观察：Cohen et al. (2021)

Cohen 等人在真实神经网络训练中测量 sharpness $S_t = \lambda_{\max}(\nabla^2 L(\theta_t))$，发现一个普遍现象：

核心结论：Edge of Stability 现象

对几乎所有 η 选择和模型架构（ResNet/Transformer/MLP）：

1. **Progressive Sharpening**（早期）：S_t **单调上升**，可能跨越 $2/\eta$
2. **Edge of Stability**（中后期）：$S_t \approx 2/\eta$，**自动稳定在边界**
3. 进入 EoS 后，loss 不再单调下降——会**振荡**，但平均仍下降

这违反了所有经典理论的预测：

- 经典 GD 理论：$\eta > 2/\lambda_{\max}$ 必然发散
- 实际神经网络：$\eta \cdot \lambda_{\max} \approx 2$ **长期稳定**，loss 仍下降

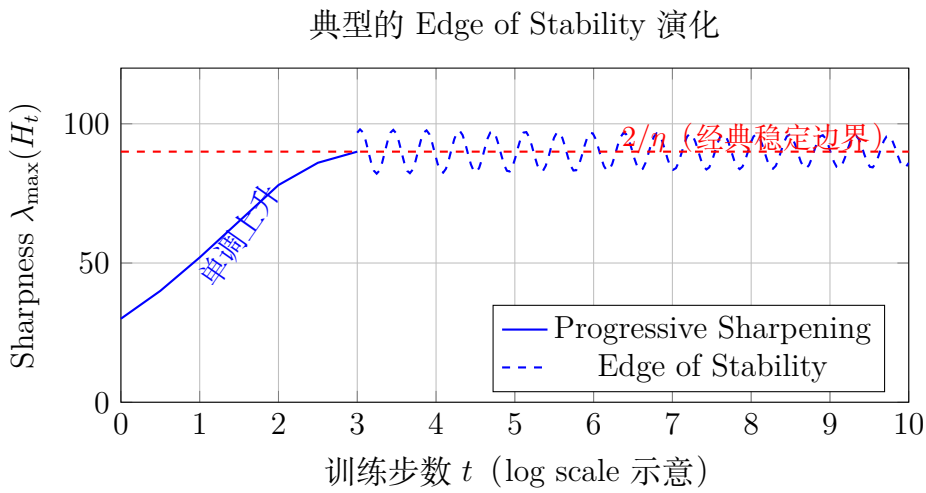

图 10: 神经网络训练中 sharpness 的典型演化：早期单调上升（Progressive Sharpening），跨过 $2/\eta$ 后维持在边界振荡（EoS）。

7.3 进入 EoS 后训练在做什么？

当 $\eta\lambda_{\max} > 2$，主特征值方向理应发散——为什么 loss 还在降？

物理直觉：两个时间尺度

EoS 状态下，参数动力学有**两个时间尺度**：

- **快尺度**（每步）：在 sharp 方向上振荡，幅度由不稳定性维持
- **慢尺度**（many steps）：在”平坦方向”上漂移，loss 真正下降

这有点像随机过程中的**平均化原理**（averaging）：快变量的振荡平均后，对慢变量产生一个**有效漂移**。这个漂移的方向恰好让系统稳定。

7.4 自稳定机制：板书推导

Damian-Nichani-Lee (2023) 给出了一个干净的简化模型，让自稳定机制变得透明。我们这里给出一个最小版本。

简化模型：sharpness 依赖于”慢”参数

考虑两个参数 (s, x)，loss 为：

$$L(s, x) = \frac{1}{2}\lambda(s) \cdot x^2 + V(s)$$

其中：

- x 是”sharp 方向”，x 方向 sharpness 是 $\lambda(s)$

- s 是"慢方向"（在最小处 $x \approx 0$ 附近的参数化）
- 假设 $\lambda'(s) > 0$：增加 s 增加 sharpness（"progressive sharpening" 的来源）

GD 更新：

$$x_{t+1} = x_t - \eta \cdot \lambda(s_t) x_t = (1 - \eta\lambda(s_t))\, x_t \tag{1}$$

$$s_{t+1} = s_t - \eta \left[\tfrac{1}{2}\lambda'(s_t)\, x_t^2 + V'(s_t)\right] \tag{2}$$

关键观察：x 的扩张因子 $|1 - \eta\lambda(s_t)|$ 依赖于慢变量 s_t。

Step 1：稳定阶段（$\eta\lambda(s) < 2$）

x 收缩到 0（指数衰减）。s 演化由 $-\eta V'(s)$ 主导，与 x^2 无关（因为 $x \to 0$）。

如果 $V'(s) < 0$：s 增加，$\lambda(s)$ 增加 $\to$ **progressive sharpening**。

Step 2：跨过边界（$\eta\lambda(s) = 2 + \delta$，$\delta > 0$ 小）

$x_{t+1} = -(1+\delta)x_t$——近似翻转 + 小幅增长。x 振荡，幅度按 $(1+\delta)^t$ 增长。

Step 3：振荡反作用于慢变量

x 振荡时，x^2 不再为零。考虑两步平均（注意振荡周期 ≈ 2）：

$$\bar{s}_{t+2} - \bar{s}_t \approx -2\eta \cdot \tfrac{1}{2}\lambda'(s)\, \overline{x^2} - 2\eta V'(s)$$

其中 $\overline{x^2}$ 是振荡幅度的均方。

关键：$\lambda'(s) > 0$ **且** $\overline{x^2} > 0$，所以振荡贡献了一个**额外漂移** $-\eta\lambda'(s)\overline{x^2}$ 让 s **减小**。

Step 4：自洽稳态

稳态条件：振荡贡献的漂移 + V' 的漂移恰好平衡，且 x 的振荡幅度稳定。

经过仔细计算（Damian-Nichani-Lee, Lemma 3.1）：稳态在 $\lambda(s^*) = 2/\eta$ 处达到。

物理图像：振荡幅度 $\overline{x^2}$ 充当了一个**反馈量**——一旦 sharpness 超过 $2/\eta$，振荡会增长，进而通过 $\lambda'(s)$ 项把 s 推向 sharpness 更小的方向，直到 sharpness 回到 $2/\eta$。

核心结论：Edge of Stability 的物理直觉

EoS 是一个**自动反馈控制系统**：

- **被控量**：sharpness $\lambda_{\max}$
- **执行器**：sharp 方向的振荡幅度 $\overline{x^2}$
- **控制律**：振荡幅度自动正比于 $\max(0, \eta\lambda - 2)$
- **设定点**：$\eta\lambda = 2$

GD 不”知道”自己在做反馈控制，但其动力学**自动**实现了这个反馈。这是高维非线性系统中 implicit dynamics 的一个绝佳例子。

7.5 为什么会 Progressive Sharpening？

EoS 假设 $\lambda(s)$ 在某些方向上递增。这是经验事实——**为什么神经网络的 sharpness 会自然增长？**

目前没有完全的理论解释，但有几条线索：

- **Loss-curvature relation**（Cohen et al.）：在 NN 中，loss 减小本身倾向于 sharpening，特别是在 cross-entropy + softmax 设置下
- **Catapult mechanism**（Lewkowycz et al. 2020）：大 LR 训练初期会”反弹”到更高 sharpness 区域
- **对 lazy training 的反驳**：一些理论框架（如 NTK）假设网络宽到一定程度后参数和 Hessian 谱近似不变；EoS 直接证伪了这一点——sharpness 在训练中显著演化，特征学习是真实发生的

7.6 实践含义

7.6.1 大学习率为什么有效

物理直觉：大 LR 的 implicit bias 视角

经典理论说 $\eta < 2/\lambda_{\max}$，但 $\lambda_{\max}$ 在训练中变化。如果 η 大：

- 训练自动**选择**让 $\lambda_{\max} = 2/\eta$ 的轨迹
- 这倾向于**平坦区域**（小 sharpness 兼容大 η）
- 平坦极小值通常**泛化更好**（Hochreiter-Schmidhuber 1997, Keskar et al. 2017）

结论：大 LR 不只是”快慢”的问题，而是 implicit bias 的问题——它选择更平坦的解。

7.6.2 Warmup 的解释

经典 LR warmup（线性增加 LR）的效果在 EoS 框架下变得清晰：

- 初期小 LR：让 sharpness 缓慢增长（progressive sharpening 完整发生）
- 后期大 LR：在已增长的 sharpness 上工作，选择平坦轨迹

如果直接用大 LR 而无 warmup：初期 $\lambda_{\max}$ 还很小，大 LR 不会触发 EoS——但可能因 stochastic gradient noise 直接跑出训练区域（NaN）。

7.6.3 Sharpness-Aware Minimization (SAM)

SAM (Foret et al. 2021) 显式优化

$$\min_{\theta} \max_{\|\delta\| \le \rho} L(\theta + \delta)$$

鼓励小 sharpness。从 EoS 视角看：

- EoS：**隐式地**让 GD 访问低 sharpness 区域
- SAM：**显式地**强制低 sharpness

两者方向一致，SAM 可以视为对 implicit bias 的强化。

8 第七部分：权重矩阵的谱

最后，我们从另一个角度观察训练：**权重矩阵的奇异值如何变化？**

8.1 初始化时的谱

数学要点：随机初始化的权重谱

对于随机初始化的权重矩阵 $W \in \mathbb{R}^{m \times n}$（元素 i.i.d. 高斯），其奇异值的平方（即 $W^\top W$ 的特征值）服从 **Marchenko-Pastur 分布**：

$$\rho(\lambda) = \frac{\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}}{2\pi\lambda\gamma\sigma^2}, \quad \lambda \in [\lambda_-, \lambda_+]$$

其中 $\gamma = n/m$，$\lambda_\pm = \sigma^2(1 \pm \sqrt{\gamma})^2$。

8.2 训练后的变化

核心结论：权重谱的演化规律

经验观察（Martin & Mahoney, 2019 等）：

1. **初始化**：奇异值服从 MP 分布，有明确的上界
2. **训练后**：分布出现 **heavy tail**（重尾），最大奇异值远超 MP 边界
3. **偏离程度与泛化相关**：偏离 MP 分布越多，通常学得越好

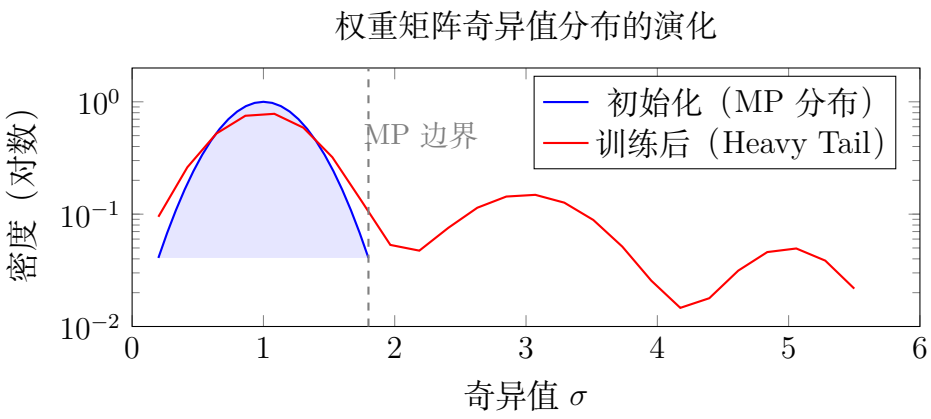

图 11: 训练使权重矩阵的奇异值分布产生重尾，超出 MP 分布预测的边界。

8.3 直觉解释

物理直觉：奇异值与特征学习

权重矩阵的大奇异值对应于网络学到的”主要特征方向”：

- 随机初始化时，没有特殊方向，所有奇异值相近
- 训练放大了数据中重要的方向，产生少数大奇异值
- 这些大奇异值编码了**学到的知识**

练习思考：如果你只能保留 top-k 个奇异值压缩一个训练好的层，性能下降会随 k 怎么变化？这就是低秩压缩（LoRA、SVD-based pruning）的理论基础。

9 总结

核心结论：本周的核心信息

深度学习的成功是高维几何与优化动力学的必然结果：

1. **隐式偏好**（三种）让过参数化不等于过拟合：ℓ_2、低秩、ℓ_1-margin
2. 高维 + 对称性让鞍点无处不在但**大多是结构性的”好鞍点”**
3. **大网络的优势不是 landscape 简单，而是 landscape 冗余**：低 loss 解从孤立点变为 $(d-n)$ 维流形
4. **Edge of Stability** 让大学习率训练自动收敛到平坦区域
5. Hessian/权重谱的 heavy-tail 演化是**真实特征学习**的指纹

表 1: 本周核心内容总结

现象	数学工具	核心直觉	关键结论
线性隐式正则化	线性代数（正交分解）	GD 沿最短路径走	偏好最小 ℓ_2 范数解
深度低秩偏好	平衡初始化 + SVD 动力学	大奇异值增长更快	深度放大隐式正则化
AdaBoost 偏好	函数空间坐标下降	凸 surrogate + 线性化 oracle	最大 ℓ_1-margin
鞍点统计	随机矩阵 + 对称群	高维全正概率极小	几乎所有临界点是鞍点
好/坏鞍点二分	对称性 + Hessian 几何	结构性鞍点 vs 病理性鞍点	鞍点多 $\neq$ 坏鞍点多
逃离鞍点	动力学分析	负曲率方向指数增长	SGD 噪声自带扰动
Hessian rank 约束	Gauss-Newton 分解	$\nabla^2 L \approx J^\top J$ at interp.	rank $\leq n$，flat dim $\geq d-n$
Edge of Stability	二尺度自稳定	振荡幅度做反馈	sharpness 自动卡在 $2/\eta$
权重谱	MP 分布	训练产生 heavy tail	偏离 MP = 特征学习

10 下周预告

本周我们看到，深度学习的”魔法”——过参数化下的良好泛化、SGD 在非凸地形上的稳健性——都可以被分解为干净的几何与代数事实。但我们一直在问”**优化算法找到了什么样的解**”，而尚未跳出”参数空间”看更大的图景。

下周：变分法与最优控制

我们将进入泛函优化的世界：

- Euler-Lagrange 方程与变分原理
- 最大熵原理与变分推断
- 最优控制与 HJB 方程
- Neural ODE：连续深度网络
- Adjoint 方法：$O(1)$ 显存反向传播

这将连接优化理论与强化学习，为后续 RL 部分奠定基础。

11 参考文献

1. Arora, S., Cohen, N., Golowich, N., & Hu, W. (2019). A convergence analysis of gradient descent for deep linear neural networks. *ICLR*.

2. Arora, S., Cohen, N., Hu, W., & Luo, Y. (2019). Implicit regularization in deep matrix factorization. *NeurIPS*.

3. Vapnik, V. N., & Chervonenkis, A. Y. (1971). On the uniform convergence of relative frequencies of events to their probabilities. *Theory of Probability & Its Applications*.

4. Vapnik, V. N. (1998). *Statistical Learning Theory*. Wiley.

5. Zhang, C., Bengio, S., Hardt, M., Recht, B., & Vinyals, O. (2017). Understanding deep learning requires rethinking generalization. *ICLR*.

6. Simsek, B., Ged, F., Jacot, A., Spadaro, F., Hongler, C., Gerstner, W., & Brea, J. (2021). Geometry of the loss landscape in overparameterized neural networks: Symmetries and invariances. *ICML*.

7. Draxler, F., Veschgini, K., Salmhofer, M., & Hamprecht, F. A. (2018). Essentially no barriers in neural network energy landscape. *ICML*.

8. Jin, C., Ge, R., Netrapalli, P., Kakade, S. M., & Jordan, M. I. (2017). How to escape saddle points efficiently. *ICML*.

9. Sagun, L., Bottou, L., & LeCun, Y. (2017). Eigenvalues of the Hessian in deep learning: Singularity and beyond. *arXiv:1611.07476*.

10. Martin, C. H., & Mahoney, M. W. (2019). Traditional and heavy-tailed self-regularization in neural network models. *ICML*.

11. Bray, A. J., & Dean, D. S. (2007). Statistics of critical points of Gaussian fields on large-dimensional spaces. *Physical Review Letters*.

12. Freund, Y., & Schapire, R. E. (1997). A decision-theoretic generalization of on-line learning and an application to boosting. *Journal of Computer and System Sciences*.

13. Mason, L., Baxter, J., Bartlett, P., & Frean, M. (1999). Boosting algorithms as gradient descent. *NeurIPS*.

14. Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*.

15. Schapire, R. E., Freund, Y., Bartlett, P., & Lee, W. S. (1998). Boosting the margin: A new explanation for the effectiveness of voting methods. *Annals of Statistics*.

16. Telgarsky, M. (2013). Margins, shrinkage, and boosting. *ICML*.

17. Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *KDD*.

18. Soudry, D., Hoffer, E., Nacson, M. S., Gunasekar, S., & Srebro, N. (2018). The implicit bias of gradient descent on separable data. *JMLR*.

19. Cohen, J. M., Kaur, S., Li, Y., Kolter, J. Z., & Talwalkar, A. (2021). Gradient descent on neural networks typically occurs at the edge of stability. *ICLR*.

20. Damian, A., Nichani, E., & Lee, J. D. (2023). Self-stabilization: The implicit bias of gradient descent at the edge of stability. *ICLR*.

21. Lewkowycz, A., Bahri, Y., Dyer, E., Sohl-Dickstein, J., & Gur-Ari, G. (2020). The large learning rate phase of deep learning: The catapult mechanism. *arXiv:2003.02218*.

22. Foret, P., Kleiner, A., Mobahi, H., & Neyshabur, B. (2021). Sharpness-Aware Minimization for efficiently improving generalization. *ICLR*.