

Adaptation 的优化理论与 LoRA 收敛性

从非稳态优化到低秩 fine-tuning

kf
Tongji University

2026

Contents

I	Adaptation 的优化理论	4
1	Warm-Start 凸优化的基本结果	4
1.1	设置与基本递推	4
1.2	固定步长: warm start 指数衰减 + 统计 floor	4
1.3	递减步长: $O(1/k)$ 速率	5
1.4	非凸情形: 梯度范数有 floor	5
2	Warm-Start 下的 Adaptation Rate	5
2.1	三因子分解	5
2.2	Drift 度量与初始 gap 的关系	6
2.3	Adaptation Rate 主公式	6
2.4	二次型 toy example (板书友好)	6
2.5	Adaptation Time 的工程估计	7
2.6	随机情形与统计 floor	7
3	非稳态优化的 Minimax 理论	8
3.1	Variation Budget 与 Dynamic Regret	8
3.2	Besbes-Gur-Zeevi 主结果	8
3.3	核心算法: Restarting Procedure	9
3.4	Tuned-LR 替代方案	9
3.5	Linear Variation $\Rightarrow$ Linear Regret	9
3.6	推广到 $L_{p,q}$ -Variation: 维数诅咒	9
3.7	Affinity Lemma: 分布距离 $\rightarrow$ 参数距离	10
4	动量在分布漂移下的 Provable Suboptimality	10
4.1	反直觉的核心主张	10
4.2	Tracking Error 的三项分解	10
4.3	Inertia Window	11
4.4	Minimax 下界匹配	11
4.5	Trade-off 形式化	11
4.6	对实践的预测	11

II LoRA 的逼近能力与收敛性	11
5 LoRA 的逼近能力	12
5.1 设置	12
5.2 线性模型奠基 (Lemma 1)	12
5.3 多层 ReLU FNN (Theorem 3)	12
5.4 随机 frozen 模型 (Corollary 4)	13
5.5 Rank 不够时的逼近误差 (Theorem 5)	13
5.6 LoRA vs Final Layers Tuning (Lemma 4)	13
5.7 Transformer (Theorem 7)	13
5.8 核心实践含义	13
6 LoRA 的优化几何与全局收敛	14
6.1 核心主张 (标题就是 abstract)	14
6.2 设置	14
6.3 关键假设: Restricted Strong Convexity / Smoothness	14
6.4 主定理: Theorem 1	15
6.5 Why LoRA Probably Won't Fail (§3.4)	15
6.6 实证 (§4)	15
6.7 与 NTK 分析的关系	15
6.8 多矩阵推广 (Theorem 2)	16
6.9 近似低秩全局最优 (Theorem 3)	16
7 LoRA+: 不对称 Learning Rate 的 Scaling 理论	16
7.1 两种合理初始化	16
7.2 Toy Model: 标准 LoRA 严格次优	16
7.3 LoRA+ Scaling	17
7.4 Adam 推广 (Theorem 1)	17
7.5 LoRA+ 算法	17
7.6 实证	17
8 A: Rank 与 Width 的双 Scaling 理论	17
8.1 A 框架	17
8.2 两种 Regime	18
8.3 LoRA $\rightarrow$ FFT 的 LR Transfer	18
8.4 统一既有变体	18
9 综合与未来方向	18
9.1 核心 Bound 总表	19
9.2 三个干净的故事	19
9.3 Open Problems	19
9.4 Reading List 优先级	20
9.5 对优化课程的整体建议	20

讲义说明

本讲义从纯优化理论角度回答两个问题:

1. 当数据分布发生变化时, 已经训练好的模型需要多久才能 adapt 到新数据上?

2. LoRA 这类 parameter-efficient fine-tuning 的逼近能力与收敛速度如何?

讲义分两部分:

- **第一部分 (§1–§4)** 围绕”adaptation rate” 问题, 从经典 SGD 收敛分析 (Bottou-Curtis-Nocedal) 出发, 建立 warm-start + drift 的统一框架, 然后给出非稳态优化的 minimax bound (Besbes-Gur-Zeevi, Chen-Wang-Wang), 最后讨论动量在分布漂移下的 provable suboptimality (Sahu-Hogan-Wells)。
- **第二部分 (§5–§8)** 围绕 LoRA, 先讲逼近能力 (Zeng-Lee), 再讲优化几何与全局收敛 (Kim-Kang-Ryu), 最后是 LR scaling 理论 (Hayou-Ghosh-Yu LoRA+ 与 Chen-Villar-Hayou A)。

每节末尾配有”Take-home” 总结。本讲义不重复证明每个定理, 仅给出关键结论、证明思路、与其他章节的关联, 以及实践含义。完整证明请查阅原文。

记号约定。 f, F 为目标函数; $w_t \in \mathbb{R}^d$ 为参数; θ 为模型参数 (与 w 等价, 依上下文); $g(w, \xi) \in \mathbb{R}^d$ 为随机梯度; ξ 为随机性来源 (数据 batch); $\eta_t > 0$ 为步长; L 为光滑常数, μ 为强凸常数 (或 PL 常数), $\kappa = L/\mu$ 为条件数; D 为漂移度量; V_T 为 variation budget; T 为时间 horizon; $X = AB^\top$ 为 LoRA 更新 ($A \in \mathbb{R}^{r \times m}, B \in \mathbb{R}^{n \times r}$, $\text{rank } r \ll \min(m, n)$); W_0 为冻结的预训练权重, $W = W_0 + X$ 为 fine-tuned 权重。

Part I

Adaptation 的优化理论

1 Warm-Start 凸优化的基本结果

本节提供后续所有讨论的优化理论基础：当从一个“warm start”出发优化一个新目标，多久能收敛？这一节的内容主要来自 Bottou-Curtis-Nocedal 2018 *Optimization Methods for Large-Scale Machine Learning* (SIAM Review)。

1.1 设置与基本递推

考虑一般 SGD: $w_{t+1} = w_t - \eta_t g(w_t, \xi_t)$, 其中 g 满足下面的标准假设。

Assumption 1.1 (光滑性). $F : \mathbb{R}^d \rightarrow \mathbb{R}$ 连续可微且 ∇F 是 L -Lipschitz: $\|\nabla F(w) - \nabla F(\bar{w})\| \leq L\|w - \bar{w}\|$.

Assumption 1.2 (一阶/二阶矩条件). 存在 $\mu_G \geq \mu > 0, M, M_V \geq 0$ 使得对所有 t :

$$\nabla F(w_t)^\top \mathbb{E}_{\xi_t}[g(w_t, \xi_t)] \geq \mu \|\nabla F(w_t)\|^2, \quad (1)$$

$$\|\mathbb{E}_{\xi_t}[g(w_t, \xi_t)]\| \leq \mu_G \|\nabla F(w_t)\|, \quad (2)$$

$$\text{Var}_{\xi_t}[g(w_t, \xi_t)] \leq M + M_V \|\nabla F(w_t)\|^2. \quad (3)$$

Assumption 1.3 (强凸性). 存在 $c > 0$ 使得 $F(w) \geq F(\bar{w}) + \nabla F(\bar{w})^\top (w - \bar{w}) + \frac{c}{2} \|w - \bar{w}\|^2$ 。唯一最优 w^* , 最优值 $F^* = F(w^*)$ 。

基本递推 (Lemma 4.4 of Bottou-Curtis-Nocedal): 在 1.1 + 1.2 下,

$$\mathbb{E}_{\xi_t}[F(w_{t+1})] - F(w_t) \leq -\left(\mu - \frac{1}{2}\eta_t LM_G\right)\eta_t \|\nabla F(w_t)\|^2 + \frac{1}{2}\eta_t^2 LM. \quad (4)$$

第一项 (步长足够小时为负) 刻画“优化进展”，第二项 $\frac{1}{2}\eta_t^2 LM$ 是噪声地板。整章后续结果都基于这个递推。

1.2 固定步长: warm start 指数衰减 + 统计 floor

Theorem 1.4 (强凸 + 固定步长). 在 1.1–1.3 下, 固定 $\eta_t = \bar{\eta} \in (0, \mu/(LM_G)]$ 。则

$$\mathbb{E}[F(w_t) - F^*] \leq \frac{\bar{\eta} LM}{2c\mu} + (1 - \bar{\eta} c\mu)^{t-1} \left[F(w_1) - F^* - \frac{\bar{\eta} LM}{2c\mu} \right]. \quad (5)$$

这是本讲义的“主公式”。物理解读:

- (i) **Warm-start 阶段** (t 较小): $\Delta_t \approx (1 - \bar{\eta} c\mu)^t \Delta_0$, 几何速率收敛, 速率常数为 $\rho = 1 - \bar{\eta} c\mu \approx 1 - 1/\kappa$ 。
- (ii) **统计 floor 阶段** (t 较大): $\Delta_t \rightarrow \bar{\eta} LM/(2c\mu)$ 。这是 noise 给定的不可逾越下界。
- (iii) **交叉时间**: $t^* \approx \frac{1}{\bar{\eta} c\mu} \log \left(\frac{2c\mu \Delta_0}{\bar{\eta} LM} \right) = O(\kappa \log(\kappa \cdot \Delta_0/M))$ 。在此时间后, warm start 的优势被噪声抹平。

1.3 递减步长: $O(1/k)$ 速率

Theorem 1.5 (强凸 + 递减步长). 在 1.1–1.3 下, 取 $\eta_t = \beta/(\gamma + t)$, $\beta > 1/(c\mu)$, $\eta_1 \leq \mu/(LM_G)$ 。则

$$\mathbb{E}[F(w_t) - F^*] \leq \frac{\nu}{\gamma + t}, \quad \nu = \max \left\{ \frac{\beta^2 LM}{2(\beta c\mu - 1)}, (\gamma + 1)\Delta_0 \right\}. \quad (6)$$

这是 Nemirovski-Yudin 1983 经典 minimax SGD 速率 (与下界匹配)。注意 $\beta > 1/(c\mu)$ 不可放宽: 若 c 估计过大、 β 太小, 可能 10^9 步都收敛不到。

1.4 非凸情形: 梯度范数有 floor

Theorem 1.6 (非凸 + 固定步长). 在 1.1–1.2 下 (无强凸假设), $\eta_t = \bar{\eta} \leq \mu/(LM_G)$, 则

$$\mathbb{E} \left[\frac{1}{T} \sum_{t=1}^T \|\nabla F(w_t)\|^2 \right] \leq \frac{\bar{\eta} LM}{\mu} + \frac{2(F(w_1) - F_{\inf})}{T\mu\bar{\eta}}. \quad (7)$$

平均梯度范数有 $O(\bar{\eta} LM/\mu)$ 的不可逾越下界。在 NN 训练中这对应“loss 不会归零、梯度也不会归零”——是 SGD 在非凸下的本质 limitation。

Take-home

- Warm-start 凸优化的”主公式”: $O(\rho^t \Delta_0 + \text{floor})$, 所有 adaptation 时间估算都从这里展开。
- Mini-batch 不能换大步长——(5) 中 $\bar{\eta} \leq \mu/(LM_G)$ 的上界与 batch size 无关, 所以 mini-batch 的优势是工程性的 (GPU、并行), 不是理论性的。
- 强凸 + 光滑给出 $O(\log(1/\epsilon))$ 几何收敛; 非凸只能给梯度范数的 average, 且有不可去除的 floor。




Figure 1: Theorem 1.4 的两个阶段: 早期 warm-start phase 中误差以 $(1 - \bar{\eta}c\mu)^t$ 几何衰减, 越过 crossover 时间 $t^* \approx \kappa \log(\Delta_0/\text{floor})$ 后被统计 floor 锁住。这张图刻画了讲义中所有 adaptation 时间估算的物理图景。

2 Warm-Start 下的 Adaptation Rate

把 §1 的工具应用到分布漂移：在 $t = \tau$ 时刻，目标函数从 f_1 切换到 f_2 ，初始点是 $\theta_\tau = w_1^* := \arg \min f_1$ 。问：从 θ_τ 出发用 GD 优化 f_2 ，多久能 adapt？

这一节没有”专门的论文”——结果是 §1 的 Theorem 1.4 与一些经典凸分析的组合。但作为讲义的承上启下，单独列出。

2.1 三因子分解

定义 **adaptation time**：

$$T_\epsilon := \min\{t : f_2(\theta_{\tau+t}) - f_2^* \leq \epsilon\}. \quad (8)$$

直接代入 §1 的 main bound： $T_\epsilon \leq \kappa \log(\Delta_0/\epsilon)$ ，其中 $\Delta_0 = f_2(\theta_\tau) - f_2^*$ 是初始 suboptimality gap。

接下来需要把 Δ_0 翻译成”分布漂移幅度”。

2.2 Drift 度量与初始 gap 的关系

Definition 2.1 (Drift).

$$D := \sup_{x \in \mathcal{X}} \|\nabla f_1(x) - \nabla f_2(x)\|. \quad (9)$$




Figure 2: Drift D 度量两个目标函数的梯度场之差。在 warm-start 处 $\theta_\tau = x_1^*$ ，由于 $\nabla f_1(x_1^*) = 0$ ，所以 $D \geq \|\nabla f_2(x_1^*)\|$ 。这把”分布漂移”翻译成了”在 warm-start 处的梯度大小”。

Lemma 2.2 (关键引理). 设 f_1, f_2 为 μ -强凸、 L -光滑。则

$$\|w_1^* - w_2^*\| \leq D/\mu, \quad \Delta_0 = f_2(w_1^*) - f_2^* \leq \frac{LD^2}{2\mu^2}. \quad (10)$$

Proof. $\|\nabla f_2(w_1^*)\| = \|\nabla f_2(w_1^*) - \nabla f_1(w_1^*)\| \leq D$ (因 $\nabla f_1(w_1^*) = 0$)。由 f_2 强凸： $\mu\|w_1^* - w_2^*\| \leq \|\nabla f_2(w_1^*)\| \leq D$ 。由 f_2 光滑： $\Delta_0 \leq \frac{L}{2}\|w_1^* - w_2^*\|^2 \leq LD^2/(2\mu^2)$ 。 $\square$

2.3 Adaptation Rate 主公式

代入 §1 的 Theorem 1.4 (确定情形对应 $M = 0$):

Theorem 2.3 (Adaptation Time).

$$T_\epsilon \leq \kappa \log\left(\frac{LD^2}{2\mu^2\epsilon}\right) = \kappa \log(\kappa) + 2\kappa \log(D) - \kappa \log \epsilon + O(1). \quad (11)$$

三个 takeaway (学生最容易记住的部分):

- (i) **漂移幅度 D 只在 $\log$ 里**: D 翻倍只多 $2\kappa \log 2$ 步。Adaptation 速度对漂移大小极不敏感。
- (ii) **目标精度 ϵ 也只在 $\log$ 里**: 精度翻倍代价同上。
- (iii) **唯一乘子是条件数 κ** : adapt 一个良态新任务 (小 κ) 比 adapt 病态任务 (大 κ) 容易得多——而这与新旧任务的相似度无关。

反直觉的核心结论:

预训练模型 adapt 快不快, 第一阶近似看新任务的条件数, 不看新旧任务有多像。

2.4 二次型 toy example (板书友好)

为了打开 Δ_0 的谱结构, 考虑:

$$f_i(x) = \frac{1}{2}(x - x_i^*)^\top H_i(x - x_i^*), \quad H_i \succeq \mu I, \quad i = 1, 2. \quad (12)$$

GD on f_2 from x_1^* :

$$x_t - x_2^* = (I - \eta H_2)^t (x_1^* - x_2^*). \quad (13)$$

按 $H_2 = \sum_k \lambda_k u_k u_k^\top$ 谱基展开: $x_1^* - x_2^* = \sum_k c_k u_k$, 则

$$\Delta_t = \frac{1}{2} \sum_k \lambda_k c_k^2 (1 - \eta \lambda_k)^{2t}. \quad (14)$$

两个极端情形对比:

- 谱对齐: $x_1^* - x_2^*$ 全在 H_2 的高 λ 方向 $\Rightarrow$ 高 λ 模式快速收缩, 几步就 adapt。
- 谱错位: $x_1^* - x_2^*$ 全在低 λ 方向 $\Rightarrow$ 收敛被 $\lambda_{\min}$ 卡住, $T \approx 1/(\eta \lambda_{\min}) = \kappa$ 。

Punchline: adapt 速度由“warm-start 误差在新 Hessian 谱上的分布”决定, 而不是由 $\|x_1^* - x_2^*\|$ 决定。

定义有效曲率 $\lambda_{\text{eff}} := \frac{\sum_k \lambda_k^2 c_k^2}{\sum_k \lambda_k c_k^2}$ (warm-start 误差在 H_2 谱上的 Rayleigh 商)。则

$$T_\epsilon \approx \frac{1}{\eta \lambda_{\text{eff}}} \log(\Delta_0/\epsilon). \quad (15)$$




Figure 3: 二次型 toy 上的 adaptation: 左图比较 spectral aligned vs misaligned 两种 warm-start 误差分布的收敛速度——同样的 $\|x_1^* - x_2^*\|$ 可以差几个数量级。右图展示 H_2 的特征值谱 (灰色), 以及 warm-start 残差 c_k^2 在两种情形下落在何处。

2.5 Adaptation Time 的工程估计

把 (11) 中的每个量都翻译成”可测、可估”的工程量:

1. Δ_0 的估计: 用梯度范数代理

$$\frac{\|\nabla f_2(\theta_\tau)\|^2}{2L} \leq \Delta_0 \leq \frac{\|\nabla f_2(\theta_\tau)\|^2}{2\mu}. \quad (16)$$

工程上: 在新数据 hold-out batch 上算 $\|\nabla f_2(\theta_\tau)\|$ 一次。免费。

2. L 的估计: Hessian-vector product + 幂迭代 (Pearlmutter trick)。10–30 次 HVP 即可。PyHessian (Yao et al. 2020) 直接可用。
3. μ 的估计:
 - PL 常数代理: $\mu_{\text{PL}} = \|\nabla f_2(\theta_\tau)\|^2 / (2(f_2(\theta_\tau) - \hat{f}_2^*))$
 - 从 loss curve 反推: 跑 $T_0 \sim 100$ 步后拟合 $\log(\Delta_t) \sim -t/\kappa$

4. D 的估计: 注意在 warm start 处 $\nabla f_1(\theta_\tau) = 0$, 所以 $D \approx \|\nabla f_2(\theta_\tau)\|$ ——与 Δ_0 是同一个量! (这一步学生通常会”啊”一下: 三个量里其实只有一个独立可测量。)

把上述合起来得 实用估计公式:

$$\hat{T}_\epsilon = \hat{\kappa} \cdot \log\left(\frac{\|\nabla f_2(\theta_\tau)\|^2}{2\hat{\mu}_{\text{PL}} \cdot \epsilon}\right). \quad (17)$$

2.6 随机情形与统计 floor

加上 mini-batch 噪声后:

$$\hat{T}_\epsilon \approx \underbrace{\hat{\kappa} \log(\Delta_0/\epsilon)}_{\text{warm-start phase}} + \underbrace{\frac{\hat{\sigma}^2}{\hat{\mu} \cdot \epsilon}}_{\text{stat floor phase}}. \quad (18)$$

第二项的 $\hat{\sigma}^2$ 是 batch 间梯度方差，在新数据上一次性测出。这给”加大 batch size 能换 adaptation 速度多少”的定量回答：

$$\frac{\partial \hat{T}_\epsilon}{\partial B} \approx -\frac{\hat{\sigma}^2}{B^2 \hat{\mu} \epsilon}. \quad (19)$$

即 stat floor 阶段把 batch 翻倍能省一半时间，warm-start 阶段无效。

Take-home

- **Adaptation 主公式：** $T_\epsilon \leq \kappa \log(LD^2/(\mu^2\epsilon))$ 。三个量级 (κ 主导、 D 次之、 ϵ 入 log)。
- **二次型谱视角：** warm-start 的”有用程度”等于 $x_1^* - x_2^*$ 在新 Hessian 谱上的 Rayleigh 商。
- **工程估计 protocol：** 梯度范数 + Hessian Lanczos + 双指数拟合，三件套覆盖所有量级估计。
- 这一节的内容是讲义后续所有 adaptation 讨论的基础。

3 非稳态优化的 Minimax 理论

§2 假设分布是”一次性切换”的。如果分布反复或缓慢变化呢？答案在 Besbes-Gur-Zeevi 2015 与 Chen-Wang-Wang 2018 的非稳态随机优化框架。

3.1 Variation Budget 与 Dynamic Regret

把每个时刻看作一个新目标 f_t 。Dynamic regret (动态 oracle 比较)：

$$R^\pi(\mathcal{F}, T) := \sup_{\{f_t\} \in \mathcal{F}} \left\{ \mathbb{E}^\pi \left[\sum_{t=1}^T f_t(X_t) \right] - \sum_{t=1}^T f_t(x_t^*) \right\}, \quad (20)$$

其中 $x_t^* = \arg \min_x f_t(x)$ 。

注意：这是和”每步知道 x_t^* 的 clairvoyant”比较，比 OCO 中的 static oracle (最佳固定动作) 严格更强。

Variation budget (Besbes-Gur-Zeevi 2015)：

$$\text{Var}(f_1, \dots, f_T) := \sum_{t=2}^T \|f_t - f_{t-1}\|_\infty, \quad \mathcal{F} = \{f : \text{Var}(f) \leq V_T\}. \quad (21)$$

3.2 Besbes-Gur-Zeevi 主结果

Theorem 3.1 (Minimax Regret, Besbes-Gur-Zeevi 2015). 在不同 feedback / 凸性下：

函数类	Feedback	Minimax Regret
Convex	noisy gradient	$\Theta(V_T^{1/3} T^{2/3})$
Strongly convex	noisy gradient	$\Theta(\sqrt{V_T T})$
Strongly convex	noisy function	$\Theta(V_T^{1/3} T^{2/3})$

对比：稳态情形对应 $\sqrt{T}$ (凸)、 $\log T$ (强凸)、 $\sqrt{T}$ (强凸 + zeroth-order)。

Price of non-stationarity： 从 $\sqrt{T}$ 到 $T^{2/3}$ ，从 $\log T$ 到 $\sqrt{T}$ 。这是 stationary 视角看不到的代价。

3.3 核心算法: Restarting Procedure




Figure 4: Restart meta-policy (Besbes-Gur-Zeevi 2015): 把时间轴切成长度 Δ_T 的 batch, 每个 batch 内部跑一个稳态 OCO 算法 $\mathcal{A}$ (如 OGD), batch 之间重置。 Δ_T 由 V_T 校准: $\Delta_T \sim (T/V_T)^{2/3}$ (凸) 或 $\sqrt{T/V_T}$ (强凸)。

Proposition 3.2 (Prop 2 of Besbes-Gur-Zeevi 2015). 取 OCO 算法 $\mathcal{A}$ (OGD 等), 每 Δ_T 步重启。则

$$R^\pi(\mathcal{F}, T) \leq \lceil T/\Delta_T \rceil \cdot G^{\mathcal{A}}(\mathcal{F}, \Delta_T) + 2\Delta_T V_T, \quad (22)$$

其中 $G^{\mathcal{A}}$ 是 $\mathcal{A}$ 在 OCO 中相对 *single best action* 的 *regret*。

Meta-principle: 把“OCO 中相对 static oracle 的好算法”通过 restart 转换为“非稳态下相对 dynamic oracle 的好算法”。Batch size Δ_T 由 V_T 校准:

- Convex + noisy gradient: $\Delta_T = \lceil (T/V_T)^{2/3} \rceil$, 用 OGD 子算法 $\Rightarrow \tilde{O}(V_T^{1/3} T^{2/3})$
- Strongly convex + noisy gradient: $\Delta_T = \lceil \sqrt{T/V_T} \rceil$, 用 OGD with $\eta_t = 1/(Ht)$ $\Rightarrow \tilde{O}(\sqrt{V_T T})$

3.4 Tuned-LR 替代方案

Proposition 3.3 (Prop 3 of Besbes-Gur-Zeevi 2015). 也可以不重启, 只调整 OGD 的步长:

$$\eta_t = \frac{r}{G} \left(\frac{V_T}{T} \right)^{1/3} \Rightarrow R^\pi \leq \tilde{O}(V_T^{1/3} T^{2/3}). \quad (23)$$

物理意义: 步长 $\eta \sim (V_T/T)^{1/3}$ 是非稳态最优 LR。 V_T 越大需要越大的步长——这是讲义里”为什么 fine-tuning 步长要根据漂移调”的理论基础。

3.5 Linear Variation $\Rightarrow$ Linear Regret

Proposition 3.4. 若 $V_T \geq C_1 T$, 则任何 *admissible policy* 都有 $R^\pi \geq C_2 T$ 。

即 $V_T = o(T)$ 是 sublinear regret 的必要条件。如果分布持续漂移、累计变化与 T 同阶, 没有任何 adapt 策略能赶上 dynamic oracle。

3.6 推广到 $L_{p,q}$ -Variation: 维数诅咒

Chen-Wang-Wang 2018 把 sup-norm 推广到 $L_{p,q}$ -variation:

$$\text{Var}_{p,q}(f) := \left(\frac{1}{T} \sum_{t=1}^{T-1} \|f_{t+1} - f_t\|_p^q \right)^{1/q}. \quad (24)$$

参数 p 控制空间局部性 (小 p 适合在小区域内变化), q 控制时间局部性 (小 q 适合只在少数时段变化)。

Theorem 3.5 (Chen-Wang-Wang 2018). 在 μ -强凸、 L -光滑、 d 维域上的 $\mathcal{F}_{p,q}(V_T)$ 类:

- *Noisy gradient*: $\inf_{\pi} \sup_f R^{\pi} = \tilde{\Theta}(T \cdot V_T^{2p/(4p+d)})$
- *Noisy function*: $\inf_{\pi} \sup_f R^{\pi} = \tilde{\Theta}(T \cdot V_T^{2p/(6p+d)})$

$p \rightarrow \infty$ 恢复 Besbes 2015 的 $V_T^{1/2}, V_T^{1/3}$ 。

核心新现象——维数诅咒: 当 $p < \infty$, regret 指数依赖于 d 。

- 高维 NN (d 大) 的 fine-tuning 受漂移影响远超 1D 直觉。
- Besbes 2015 的 sup-norm 隐藏了 d ; 用真实的 L_2 ($p = 2$) 会暴露出 d 依赖。

3.7 Affinity Lemma: 分布距离 $\rightarrow$ 参数距离

Lemma 3.6 (Affinity Lemma, Chen-Wang-Wang 2018, Lemma 4.2). 设 f_t, f_{τ} 都是 L -光滑 + M -强凸 (d 维域), 则

$$\max \{ |f_t(x_t^*) - f_t(x_{\tau}^*)|, |f_{\tau}(x_t^*) - f_{\tau}(x_{\tau}^*)| \} = O(\|f_t - f_{\tau}\|_p^r), \quad r = \frac{2p}{2p+d}. \quad (25)$$

直觉: 两函数 L_p 距离小 $\Rightarrow$ 最优解不会差太远。证明用反证 + 局部体积积分 (构造一个 $\Theta(\delta/D)^d$ 体积的 ball 让两函数差异足够大)。

讲义意义:

- 这是把 §2 中”分布距离 $D \rightarrow$ 参数距离 $\|w_1^* - w_2^*\|$ ”那一步的严格、 L_p -norm 版本, 且**显式**给出 d 的依赖。
- d 大时 $r = 2p/(2p+d)$ 接近 0, warm start 几乎无用。

Take-home

- Variation budget V_T 是分布漂移的合法度量; price of non-stationarity 给出 minimax 下界。
- Restart 把 OCO 算法转为非稳态算法是统一手术; batch size $\Delta_T \sim (T/V_T)^{2/3}$ 或 $\sqrt{T/V_T}$ 。
- 维数诅咒: 高维 NN 的 adaptation 比 1D 严重得多, $V_T^{2p/(4p+d)}$ 而非 $V_T^{1/2}$ 。
- Affinity lemma 把分布距离严格翻译为参数距离, 是现代 fine-tuning 理论的标准引理。

4 动量在分布漂移下的 Provable Suboptimality

§3 给的下界是 algorithm-agnostic 的。本节聚焦一个具体现象：动量在非稳态下严格次于 vanilla SGD。来源：Sahu, Hogan, Wells 2026 (arXiv 2601.12238)。

4.1 反直觉的核心主张

在确定的强凸优化中，动量给 $\sqrt{\kappa}$ vs κ 的加速。但在分布漂移下，动量**严格更差**——因为它积累的是过时梯度，造成系统性 lag。

4.2 Tracking Error 的三项分解

考虑 SGD ($\beta = 0$)、Polyak Heavy-Ball ($\beta \in (0, 1)$)、Nesterov 三者，强凸 + 光滑 + 时变最优 θ_t^* 。Sahu-Hogan-Wells 证明：

$$\mathbb{E}\|\theta_t - \theta_t^*\|^2 \leq \underbrace{T_t(\theta_0)}_{\text{初始化遗忘}} + \underbrace{N_t(\sigma^2)}_{\text{方差 floor}} + \underbrace{D_t(\beta, V_T)}_{\text{漂移引起的 lag}} . \quad (26)$$

关键发现：Drift term D_t 含动量系数 β 的放大因子：

- $\beta = 0$ (vanilla SGD): $D_t \sim V_T \cdot \mu^{-1}$ 。
- $\beta \rightarrow 1$ (强动量): $D_t \sim V_T/(1 - \beta)^2$ ，发散。

物理意义：动量越强，”惯性窗口”越长， θ_t 跟不上 θ_t^* 的变化。

4.3 Inertia Window

切换瞬间，动量优化器需要 $\sim 1/(1 - \beta)$ 步才能”忘记”旧任务的累积梯度。 $\beta = 0.999$ 对应 ~ 1000 步——这正是实践中 fine-tuning 必须 LR warmup 的微观机制。

4.4 Minimax 下界匹配

Sahu-Hogan-Wells 还给出 dynamic regret 的极小化下界 (gradient-variation 约束下)，证明：

动量诱导的 *tracking penalty* 不是分析 *artifact*，而是信息论 *barrier*。

即在 drift-dominated regime，任何带动量的算法都被 $1/(1 - \beta)$ 类因子放大，无法躲开。

4.5 Trade-off 形式化

动量的双面：

- **抑制噪声**：noise term N_t 中含 $1 - \beta$ 因子，动量越大 N_t 越小。
- **放大漂移**：drift term D_t 含 $1/(1 - \beta)^2$ ，动量越大 D_t 越大。

最优 β 由 σ^2 与 V_T 的比值决定。漂移占主导时 $\beta = 0$ 最优。




Figure 5: 动量在非稳态优化下的 trade-off。绿色虚线：noise term 关于 β 单调下降（动量平滑梯度）。红色点线：drift term 关于 β 单调上升（动量积累过时梯度）。两条蓝色实线是低/高漂移情形下的总误差，最优 β^* 随 V_T 增大向 0 移动——漂移强时应该完全关闭动量。

4.6 对实践的预测

1. RLHF / online forecasting / continual learning 中”动量越大越不稳”是有理论根据的。
2. Adam 的 $\beta_2 = 0.999$ 隐含时间常数 ~ 1000 ；切换分布后前 ~ 1000 步处于”stale 二阶矩”主导阶段。
3. 二阶方法（DAWN、Muon 风格的 randomized SVD）从当前 batch 估计 preconditioner，没有 EMA 滞后——分布漂移下天然更鲁棒。




Figure 6: Adam 的 v_t EMA 在分布切换后的滞后。左图：在 $t = 200$ 切换分布后，真实梯度幅度立即翻转（深色细线），但 Adam 的 v_t （深色粗线）需要 $\sim 1/(1-\beta_2)$ 步才”忘记”旧分布。右图：相应的 effective LR $1/\sqrt{v_t}$ 在 staleness window 内完全失准——这是 fine-tuning 必须 LR warmup 的微观机制。

Take-home

- 动量在分布漂移下**严格次于** SGD (强凸 + 光滑设定)。
 - Penalty 来自 stale-gradient lag, 下界匹配 $1/(1 - \beta)^2$ 。
 - Adam 的 v_t EMA 是同一类问题的 preconditioner 版本——这是 fine-tuning 必须 LR warmup 的最严格理论解释。
 - 这一节配合 §3 一起, 把”分布漂移下哪些优化器选择是错的”全部覆盖。
-

Part II

LoRA 的逼近能力与收敛性

第二部分聚焦低秩 fine-tuning (LoRA)。和第一部分不同, 这里我们**不再讨论分布漂移本身**, 而是聚焦于: 给定一个新任务, LoRA 用 rank- r 的更新能逼近多好, 以及在何种条件下能高效收敛。

LoRA 的优化分析有三条独立支柱:

1. **逼近能力**: 给定 rank r , LoRA 能表达哪些更新? 这是 expressivity 问题。
2. **优化几何**: 非凸 loss landscape 上, LoRA 训练能找到全局最优吗? 这是 landscape 问题。
3. **超参数 scaling**: η_A vs η_B 、rank r 、初始化怎么选? 这是 hyperparameter 问题。

§5 讲第一条 (Zeng-Lee 2024); §6 讲第二条 (Kim-Kang-Ryu 2025); §7-§8 讲第三条 (LoRA+ 与 A)。

5 LoRA 的逼近能力

来源: Zeng & Lee, ”The Expressive Power of Low-Rank Adaptation”, ICLR 2024 (arXiv 2310.17513)。

这是 LoRA 理论分析的奠基论文。专门分析”LoRA rank 多大才能表达目标”——**完全独立于优化和泛化, 只看 expressivity**。

5.1 设置

冻结网络 f_0 深度 L , 宽度 D ; 目标网络 $\bar{f}$ 深度 $\bar{L}$ ($L \geq \bar{L}$, 预训练通常更深)。每层加一个 rank- R LoRA adapter ΔW_l 。问: R 多大才能保证 $\hat{f} \equiv \bar{f}$?

LoRA: low-rank adaptation of a frozen weight matrix

$$W = W_0 + BA, \text{ with } \text{rank}(BA) \leq r \ll \min(m, n)$$

Trainable params: $r(m + n)$ (vs full FT: mn)




Figure 7: LoRA 的基本构造: 冻结的 $W_0 \in \mathbb{R}^{n \times m}$ 加上低秩可训练更新 BA ($B \in \mathbb{R}^{n \times r}$, $A \in \mathbb{R}^{r \times m}$, $r \ll \min(m, n)$)。可训练参数从 mn 降到 $r(m + n)$ 。

5.2 线性模型奠基 (Lemma 1)

先看完全线性的 toy: $f_0 = \prod_l W_l$, $\bar{f} = \bar{W}$ 。误差矩阵 $E = \bar{W} - \prod_l W_l$, 秩 R_E 。

Lemma 5.1 (Zeng-Lee Lemma 1). 在合适的 *non-singularity* 假设下,

$$\min_{\Delta W_l: \text{rank}(\Delta W_l) \leq R} \left\| \prod_{l=1}^L (W_l + \Delta W_l) - \bar{W} \right\|_2 = \sigma_{RL+1}(E). \quad (27)$$

且当 $R \geq \lceil R_E/L \rceil$ 时精确逼近。

核心洞察: 每层 rank- R 的 LoRA 累积起来, "effective rank" 是 RL (深度乘)。这是 Eckart-Young-Mirsky 定理向"矩阵乘积"的推广。




Figure 8: LoRA 的 effective expressive rank 随深度线性增长: 每层 rank R 的 adapter 叠 L 层后, 等效 rank RL 。当 $RL \geq D$ 时即可精确表达任意 D 维 target——这是 Lemma 5.1 的几何含义。

5.3 多层 ReLU FNN (Theorem 3)

Theorem 5.2 (Zeng-Lee Theorem 3). *target FNN* 深度 $\bar{L}$, *frozen* 深度 L , 宽度 D 。令 $M = \lfloor L/\bar{L} \rfloor$ 。在 *non-singularity* 假设下:

如果 $R \geq \lceil \max_{i \in [\bar{L}]} \text{rank}(\bar{W}_i - \prod_{l \in P_i^u} W_l) / M \rceil$, 则存在 *LoRA adapters* 使得 $\hat{f}(x) = \bar{f}(x), \forall x$ 。

5.4 随机 frozen 模型 (Corollary 4)

随机初始化的 frozen FNN, 当 $R \geq D/M$ 时, with prob 1 可精确逼近任意 target。

参数计数: LoRA 总参数 $\approx 2RDL = 2D^2\bar{L}$; target 参数 $D^2\bar{L}$ 。LoRA 仅用 2 倍于目标的参数即可完全表达。

这给出 LoRA 工程成功的第一个理论解释: 即使受 rank 约束、参数分散在多层, effective expressivity 也能接近最优。

5.5 Rank 不够时的逼近误差 (Theorem 5)

Theorem 5.3 (Zeng-Lee Theorem 5). 定义每层逼近误差 $E_i = \sigma_{RM+1}(\bar{W}_i - \prod_{l \in P_i^u} W_l)$ 。则

$$\mathbb{E} \|\hat{f}(x) - \bar{f}(x)\|_2 \leq \beta \sum_{i=1}^{\bar{L}} \left(\max_k \|\bar{W}_k\|_F + E_k \right)^{\bar{L}-i} E_i, \quad (28)$$

其中 β 包含模型参数和输入的 *magnitude*。

讲义意义:

- $E_i = \sigma_{RM+1}$ 直接给出 LoRA 的逼近 ceiling = (RM+1)-th 奇异值。这是 LoRA 永远逼近不了的 floor。
- 误差指数累积于深度 (外面是 $(\cdot)^{\bar{L}-i}$)，所以深网络的 LoRA 逼近误差累积非平凡。




Figure 9: LoRA 的逼近 floor 由最优更新 ΔW^* 的奇异值谱决定。左图: 两种 spectrum 衰减速度 (fast 表示低秩友好, slow 表示低秩难逼近)。右图: 随 r 增加, 逼近 floor $\sum_{k>r} \sigma_k^2$ 单调下降; 何时跨过目标精度 ϵ 决定了所需的最小 rank。这是 Theorem 5.3 的可视化。

5.6 LoRA vs Final Layers Tuning (Lemma 4)

Lemma 5.4. 随机 frozen 模型，仅调最后 $L - 1$ 层（保持第 1 层冻结）：with prob 1 无法精确逼近任意一层 target。

这是 LoRA 严格优于”只调最后几层”的理论证明。

5.7 Transformer (Theorem 7)

如果只对 self-attention 加 LoRA ($\text{rank} \geq D/2$)，即可精确逼近任意 target Transformer。FFN 不必调。

这与 Hu et al. LoRA 原文经验观察”只调 attention 矩阵就行”完美吻合，且给出严格阈值 $D/2$ 。

5.8 核心实践含义

1. **Rank 选择**：跑短期全 FT，对 ΔW 做 SVD 看谱衰减；选 r 使 $\sum_{k>r} \sigma_k^2 \leq \alpha \|\Delta W\|_F^2$ 。
2. **Frozen 模型质量决定 rank 需求**： $\bar{W}_i - \prod W_i$ 越接近低秩（即 frozen 已经”几乎对了”），所需 rank 越小。这给”为什么大模型 LoRA 比小模型 LoRA 容易”提供了理论根据。
3. **Approximation floor**：LoRA 逼近误差有 σ_{RM+1} 形式的下界，不可能突破。

Take-home

- LoRA 的 expressivity 由 effective rank RL 决定（rank 累积起来）。
- 随机 frozen 网络下， $R \geq D/M$ 即可精确表达任意 target；2 倍参数足够。
- Rank 不够时的逼近误差精确等于 σ_{RM+1} 形式的奇异值。
- LoRA $\succ$ Last-layer tuning 是严格定理 (Lemma 4)。
- Transformer 只调 attention， $\text{rank} \geq D/2$ 即可——给经验做法严格 backing。

6 LoRA 的优化几何与全局收敛

来源：Kim, Kang, Ryu, ”LoRA Training Provably Converges to a Low-Rank Global Minimum or It Fails Loudly”, ICML 2025 (arXiv 2502.09376)。

§5 解决了”LoRA 能不能表达”的问题；本节解决”LoRA 能不能找到”的问题。

6.1 核心主张（标题就是 abstract）

不依赖任何 *linearization*，对非凸 LoRA loss 直接证明：局部最优要么是**全局最优**（低 rank + 小 magnitude），要么是 **spurious 解**（高 rank + 大 magnitude）——后者”loudly fails”，肉眼可辨。

且 LoRA 标准训练（zero init + weight decay）的隐式偏置使得几乎不会陷入 spurious 解。

6.2 设置

LoRA: $X = AB^\top$, $A \in \mathbb{R}^{m \times r}$, $B \in \mathbb{R}^{n \times r}$ 。带 weight decay 的损失:

$$\hat{\mathcal{L}}_\lambda^{\text{loa}}(A, B) = \hat{\mathcal{L}}^{\text{full}}(AB^\top) + \frac{\lambda}{2}(\|A\|_F^2 + \|B\|_F^2). \quad (29)$$

经典等价 (Burer-Monteiro): 等价于 nuclear norm 正则化的 full FT

$$\hat{\mathcal{L}}_\lambda^{\text{full}}(X) = \hat{\mathcal{L}}^{\text{full}}(X) + \lambda\|X\|_*. \quad (30)$$

6.3 关键假设: Restricted Strong Convexity / Smoothness

Definition 6.1 (RSC, RSM). f 是 (α, r, D) -restricted strongly convex about X^* , 若对 $\|X - X^*\|_F \leq D$, $\text{rank}(X) \leq r$:

$$\langle \nabla f(X) - \nabla f(X^*), X - X^* \rangle \geq \alpha\|X - X^*\|_F^2. \quad (31)$$

RSM 类似定义, bound 二阶项。

这是放宽版的强凸 + 光滑——只在 $\text{rank}-r$ 矩阵和 X^* 邻域上成立。**实证验证**: 实际 NN fine-tuning 中 (小 r), RSC/RSM 确实成立。

6.4 主定理: Theorem 1

Theorem 6.2 (Kim-Kang-Ryu Theorem 1). 设 $\hat{\mathcal{L}}_\lambda^{\text{full}}$ 有 $\text{rank}-r_*$ 全局最优 X^* 。令 α, β 为 $\hat{\mathcal{L}}^{\text{full}}$ 在 X^* 附近的 RSC, RSM 常数。LoRA $\text{rank } r \geq r_*$ 。

则任何 SOS (second-order stationary point) (A, B) 满足 $X^\square = AB^\top$, $\|X^\square - X^*\|_F \leq D$ 必落入下面之一:

(a) **Special regime** ($2\alpha > \beta$): $X^\square$ 必为全局最优。

(b) **Generic regime** ($2\alpha \leq \beta$): 要么是全局最优, 要么 $X^\square$ 严格 $\text{rank } r$ 满足

$$\sigma_r(X^\square) \geq \frac{2\alpha}{\beta}\sigma_{r_*}(X^\square), \quad (32)$$

$$\|X^\square - X^*\|_F^2 \geq \frac{\|X^\square - \Pi_{\text{rank} \leq r_*}(X^\square)\|_F^2}{1 - 2\alpha\sigma_{r_*}/(\beta\sigma_r)}. \quad (33)$$

Spurious 解的特征 (Corollary 1 改写):

$$\|X^\square\|_F \geq \sqrt{\frac{\sum_{s>r_*} \sigma_s^2(X^\square)}{1 - 2\alpha\sigma_{r_*}/(\beta\sigma_r)}} - \|X^*\|_F. \quad (34)$$

即 spurious 解 norm 显著大于 $\|X^*\|_F$ 且 rank 充满 r 。

LoRA loss landscape regions (Kim-Kang-Ryu Thm 1)




Figure 10: Theorem 6.2 的几何图景：参数空间被分成两个不连通区域。**绿色区**：rank $\leq r_*$ 、norm 小，全局最优 X^* 所在地。**红色区**：rank = r 、norm 大，spurious 解可能存在的地方。LoRA 的 zero init 把优化轨迹（蓝色箭头）锚定在绿色区域附近，weight decay 进一步推向低秩——两者合力使训练几乎不进入红色区。

6.5 Why LoRA Probably Won't Fail (§3.4)

两个隐式偏置共同保证训练不陷入 spurious 解：

Zero initialization: $B_0 = 0 \Rightarrow X_0 = 0$ 。Spurious 解远离 0；优化从 0 出发，倾向于停留在低 norm 区域（即全局最优所在）。

加 weight decay 后可定量： $\|X^*\|_* \leq \hat{\mathcal{L}}(0)/\lambda$ 。若 fine-tuning 任务与预训练任务差不远， $\hat{\mathcal{L}}(0)$ 不大，所以 X^* 必小 norm。

Weight decay 的隐式低秩偏置 (Lemma 1, 引 Galanti et al. 2024)：

$$\text{rank}(X_\infty) \leq \frac{b \log(\epsilon/4)}{\log(1 - \mu\lambda)}, \quad (35)$$

其中 b 是 batch size, μ 是 LR, λ 是 weight decay。weight decay 把 X 推向低 rank, 远离 spurious (高 rank) 区。

6.6 实证 (§4)

- RSC/RSM 验证： $r = 8$ 时 $\beta/\alpha \approx 8$ ； $r = 16$ 时 ≈ 19 ； $r = 64$ 时 $\alpha < 0$ （理论失效）。
- 反直觉发现：小 rank 反而 landscape 更好。
- Zero init 验证：用大 random init 启动 LoRA，确实陷入 spurious 解（rank 大、norm 大、generalization 差）。

6.7 与 NTK 分析的关系

Jang-Lee-Ryu 2024 (NTK regime) 的结果是 Theorem 6.2 的特例：当 $2\alpha = 2\epsilon > \beta = \epsilon$ ，进入 special regime，自动无 spurious 解。Kim-Kang-Ryu 摆脱了 NTK 假设，把结论推广到非凸非线性 NN。

6.8 多矩阵推广 (Theorem 2)

完全平行结果：每层独立有 $(\alpha^{(l)}, \beta^{(l)})$ 。条件 $2\alpha^{(l)} > \beta^{(l)}$ 对所有 l 成立 $\Rightarrow$ special regime；否则至少一层在 generic regime。

6.9 近似低秩全局最优 (Theorem 3)

放宽 (A1) 到 “ δ -global minimizer” ($\delta = o(\epsilon^3)$)。结论仍成立，但 ϵ -意义下。这覆盖了 weight decay 较小、最优解只近似低秩的情形。

Take-home

- LoRA 收敛性的最强干净结果——不依赖 NTK / linearization。
- 小 rank $\rightarrow$ 更好的 landscape，与 “overparameterization helps” 直觉相反。
- Zero init + weight decay 是实践成功的关键，且都有定量理论 backing。
- Spurious 解 fails loudly：用 rank/norm 监控就能 diagnose。这是非常实用的工程建议。

7 LoRA+: 不对称 Learning Rate 的 Scaling 理论

来源：Hayou, Ghosh, Yu, “LoRA+: Efficient Low Rank Adaptation of Large Models”, ICML 2024 (arXiv 2402.12354)。

§5-§6 都假设给定 A, B 后能用某种 “标准优化” 达到目标。本节进一步：标准 LoRA 用同一 LR 训 A, B 在大宽度极限下 **严格次优**——必须 $\eta_B \gg \eta_A$ 才能 efficient。

7.1 两种合理初始化

LoRA 要求初始 $X = AB^\top = 0$ ，即 A 或 B 中至少一个为 0。结合 width n 的 stability 要求（标准 He init / LeCun init 风格），有两种合理方案：

- **Init[1]**: $\sigma_B = 0, \sigma_A^2 = \Theta(n^{-1})$ （标准 LoRA 默认）
- **Init[2]**: $\sigma_B^2 = \Theta(1), \sigma_A = 0$

7.2 Toy Model: 标准 LoRA 严格次优

考虑 $f(x) = (W_* + ba^\top)x$ ，rank-1 LoRA。GD 一步后特征更新：

$$\Delta f_t = -\eta b_{t-1}^2 U_{t-1} \|x\|^2 - \eta (a_{t-1}^\top x)^2 U_{t-1} + \eta^2 U_{t-1}^2 b_{t-1} (a_{t-1}^\top x) \|x\|^2. \quad (36)$$

三项分别记为 $\delta^1, \delta^2, \delta^3$ (δ^3 是 A, B 联合二阶项)。

Stable feature learning: $\Delta f_t = \Theta(1)$ 。 **Efficient learning**: 进一步要求 $\delta^1, \delta^2 = \Theta(1)$ (A 和 B 都被有效更新)。

Proposition 7.1 (Hayou-Ghosh-Yu Prop 1). $\eta_a = \eta_b = \Theta(n^c)$ 任意 c , 要 $\delta^1, \delta^2 = \Theta(1)$ 同时成立的方程组无解。

直觉: A 作用于宽度- n 输入, 要求 $\eta_a \sim 1/n$ 保证稳定; B 作用于宽度- r 中间向量, 可以 $\eta_b = \Theta(1)$ 。形状不对称导致 LR 不对称。

7.3 LoRA+ Scaling

Proposition 7.2 (Hayou-Ghosh-Yu Prop 2). 取 $\eta_a = \Theta(n^{-1}), \eta_b = \Theta(1)$, 则 $\delta_t^i = \Theta(1)$ 对 $i \in \{1, 2, 3\}$ 全部成立。

核心比例:

$$\boxed{\frac{\eta_B}{\eta_A} = \Theta(n)}. \quad (37)$$

7.4 Adam 推广 (Theorem 1)

把分析从 vanilla GD 推到 Adam 需要一个额外的 alignment 假设: Adam-processed gradient $g_A^t Z = \Theta(n)$ 。在 SignSGD 下严格成立, 对一般 Adam 凭借 sign 函数大致成立。结论一样: $\eta_B/\eta_A = \Theta(n)$ 是唯一 efficient 配置。

7.5 LoRA+ 算法

固定 $\lambda = \eta_B/\eta_A > 1$ (典型 $2^4 = 16$), 只调 η_A 。1D grid search, 与标准 LoRA 同样 cost。

7.6 实证

- Roberta-base / GPT-2 / Llama-7b 在 GLUE 和 flan-v2 上 fine-tune。
- 性能: 1%–2% 提升; 速度: 最高 $2\times$ SpeedUp at same compute。
- **Hard tasks 收益更大:** MNLI > SST2。原因: hard task 需要 efficient feature learning, benign task 不需要。

Take-home

- P 风格论证应用到 LoRA: $\eta_B/\eta_A = \Theta(n)$ 是唯一 efficient scaling。
- 标准 LoRA 严格 suboptimal——这是工程优化的低垂果实。
- Hard task 收益大、benign task 收益小, 与 task 的 feature learning 需求匹配。

8 A: Rank 与 Width 的双 Scaling 理论

来源: Chen, Villar, Hayou, "Learning Rate Scaling across LoRA Ranks and Transfer to Full Finetuning", arXiv 2602.06204 (2026)。

LoRA+ (§7) 只分析了 width n 上的 scaling; 本节进一步引入 rank r , 给出完整的 Maximal-Update Adaptation (A) 框架。




Figure 11: LoRA+ 实证图景的示意：在 (η_A, η_B) 平面上，最优 (η_A, η_B) 远离对角线（标准 LoRA 的 $\eta_A = \eta_B$ ）。LoRA+ 的 $\eta_B = 16\eta_A$ 线（蓝色）穿过最佳区，而 standard LoRA 的对角线只能到次优区。星号标记最优 LoRA+ 点，圆点标记 $\eta_A = \eta_B$ 约束下的最优。

8.1 A 框架

参照 Yang-Hu P, 要求 LoRA 更新满足：

1. **Stable:** 所有特征 $\leq O(1)$
2. **Non-vanishing:** feature update 不消失
3. **Feature learning:** $\Delta Z = \Theta(1)$

把 width n 和 rank r 都当作 scaling 参数，导出 LR 应有的形式。

8.2 两种 Regime

1. **Rank-invariant regime:** 某些配置下（如 $\text{Init}[A] + \text{常数 } \alpha$ ），最优 LR 不随 r 变。
工程意义：调好 LR 后可以自由换 r ，不必重新调。
2. **Rank-inverse regime:** 最优 LR $\propto 1/r$ 。换 rank 必须重调 LR（这覆盖了 Kalajdzievski 2023 的 rsLoRA 经验技巧）。

具体落入哪个 regime 取决于 α 是否随 r 缩放（ $\alpha = c$ vs $\alpha = c \cdot r$ ）。

8.3 LoRA $\rightarrow$ FFT 的 LR Transfer

最实用结果：某些配置下（具体： $\text{Init}[B] + \text{常数 } \alpha$ ），LoRA 的最优 LR scaling 与 **full fine-tuning 的最优 LR scaling 重合**。

工程意义：先在 LoRA（小 r ，便宜）上调 LR，调到的值可以**直接转移**到 FFT（大 r ，贵）。FFT 的 LR tuning cost 大幅降低。

8.4 统一既有变体

A 框架统一了 LoRA+ / rsLoRA / PiSSA / MiLoRA 的 LR 选择，给出从 first principles 推出每种变体的 LR 应有的 scaling。

Take-home

- A 是 P 在 fine-tuning 上的延伸——同时刻画 width 和 rank 两个 scaling 维度。
- Rank-invariant LR 配置 (Init[A] + 常数 α) 让换 r 无需重调 LR——是工程默认值的最佳选择。
- LoRA $\rightarrow$ FFT 的 LR transfer 是颠覆性的实践影响。

9 综合与未来方向

本节把全讲义内容串起来，并指向 open problems。

9.1 核心 Bound 总表

设定	上界 / 速率	下界 / 来源
凸 + 光滑 + warm start (确定)	$\kappa \log(LD^2/(\mu^2\epsilon))$	κ (first-order)
凸 + 光滑 + warm start (加速)	$\sqrt{\kappa} \log(LD^2/(\mu^2\epsilon))$	$\sqrt{\kappa}$ (Nesterov tight)
强凸 + 随机 SGD	$\sigma^2/(\mu\epsilon)$	$\sigma^2/(\mu\epsilon)$ (Nemirovski-Yudin)
非稳态 strongly convex (gradient)	$\sqrt{V_T T}$	$\sqrt{V_T T}$ (Besbes 2015)
非稳态 convex (gradient)	$V_T^{1/3} T^{2/3}$	$V_T^{1/3} T^{2/3}$ (Besbes 2015)
非稳态 strongly convex (L_p , d 维)	$T \cdot V_T^{2p/(4p+d)}$	$T \cdot V_T^{2p/(4p+d)}$ (Chen-Wang-Wang 2018)
动量 SGD 漂移 penalty	$\sim 1/(1-\beta)^2$	信息论 barrier (Sahu 2026)
LoRA expressivity	σ_{RM+1} floor	不可逾越 (Zeng-Lee 2024)
LoRA SOSP characterization	spurious 解 rank = r , 大 norm	(Kim-Kang-Ryu 2025)
LoRA+ LR scaling	$\eta_B/\eta_A = \Theta(n)$	P necessity

9.2 三个干净的故事

讲义可以浓缩成三句话：

1. **Adapt 速度由新任务的条件数决定** (§2 主公式 + §3 维数诅咒)。漂移幅度 D 和精度 ϵ 都只在 log 里。
2. **动量在分布漂移下严格次于 SGD** (§4)，原因是 stale-gradient lag 的信息论 barrier。Adam 的 v_t EMA 是同一现象的二阶版本。
3. **LoRA 收敛是三个独立事实的乘积** (§5-§8)：rank 给 expressivity ceiling，weight decay + zero init 给 landscape 偏置， η_B/η_A scaling 给 efficient feature learning。三者各自独立，缺一不可。

9.3 Open Problems

1. **非凸 + 自适应优化器 + 分布漂移 + 大模型**: 目前无 tight bound。Sahu-Hogan-Wells 2026 是第一步, 但还限于强凸。
2. **Adaptation Time 的 protocol** (§2 末): 把” 梯度范数 + Hessian Lanczos + 双指数拟合” 打包成一个工程工具, 在标准 benchmark 上验证 $\hat{T}_\epsilon$ 与真实 T_ϵ 的相对误差——一个有意义的 paper 题目。
3. **LoRA 收敛 rate 的精华**: Kim-Kang-Ryu 2025 证 landscape, arxiv 2512.18248 给 rate。把两者合起来给完整 rate + landscape 分析仍是 open。
4. **二阶方法在 LoRA 上的优势**: DAWN/Muon 风格的 randomized SVD 在 LoRA 的 $\text{rank-}r(m+n)$ 维度下计算成本下降; 理论分析 LoRA + 二阶的最优收敛 rate 是有趣方向。
5. **Restart 检测在不知 μ, L, V_T 时的 parameter-free 算法** (Cutkosky 系列工作的延伸)。

9.4 Reading List 优先级

如果只读 5 篇:

1. Bottou-Curtis-Nocedal 2018, §4–§6 (warm start 凸优化基础)
2. Besbes-Gur-Zeevi 2015 (非稳态优化奠基)
3. Sahu-Hogan-Wells 2026 (动量在漂移下失效)
4. Zeng-Lee 2024 (LoRA expressivity)
5. Hayou-Ghosh-Yu 2024 + Chen-Villar-Hayou 2026 (LoRA+ + A scaling)

9.5 对优化课程的整体建议

本讲义建议作为优化课” 高级章节” 的两节内容:

- 第一节 (Part I, §1–§4): 约 2.5 小时, 覆盖 warm start 凸分析、非稳态 minimax、动量失效。需要前置 SGD 收敛分析、Nesterov 加速、OCO 基础。
- 第二节 (Part II, §5–§8): 约 2 小时, 覆盖 LoRA 三大支柱。需要前置 Burer-Monteiro 矩阵分解、P scaling theory (可选用 §1 课的简化版)。

板书 demo 推荐:

1. §2.4 二次型 toy example 的谱衰减——画 Δ_t 在不同 c_k 分布下的衰减曲线。
2. §4 Adam 在切换瞬间的失效——一个对角 Hessian toy 的 Python 实验。
3. §5 LoRA 在 random frozen 模型上的精确逼近——直接复现 Zeng-Lee Figure 1。

参考文献

Adapt 时间方向:

1. Besbes, O., Gur, Y., Zeevi, A. "Non-stationary Stochastic Optimization." *Operations Research* 63(5):1227–1244, 2015. arXiv:1307.5449.
2. Chen, X., Wang, Y., Wang, Y.-X. "Non-stationary Stochastic Optimization under $L_{p,q}$ -Variation Measures." *Operations Research* 67(6):1752–1765, 2019. arXiv:1708.03020.
3. Sahu, S., Hogan, C. J., Wells, M. T. "On the Provable Suboptimality of Momentum SGD in Nonstationary Stochastic Optimization." arXiv:2601.12238, 2026.
4. Bottou, L., Curtis, F. E., Nocedal, J. "Optimization Methods for Large-Scale Machine Learning." *SIAM Review* 60(2):223–311, 2018. arXiv:1606.04838.

LoRA 方向:

5. Zeng, Y., Lee, K. "The Expressive Power of Low-Rank Adaptation." ICLR 2024. arXiv:2310.17513.
6. Kim, J., Kang, J., Ryu, E. K. "LoRA Training Provably Converges to a Low-Rank Global Minimum or It Fails Loudly (But it Probably Won't Fail)." ICML 2025. arXiv:2502.09376.
7. Hayou, S., Ghosh, N., Yu, B. "LoRA+: Efficient Low Rank Adaptation of Large Models." ICML 2024. arXiv:2402.12354.
8. Chen, N., Villar, S., Hayou, S. "Learning Rate Scaling across LoRA Ranks and Transfer to Full Finetuning." arXiv:2602.06204, 2026.

背景文献 (讲义中提及但未深入):

9. Hu et al. "LoRA: Low-Rank Adaptation of Large Language Models." ICLR 2022.
10. Yang, G., Hu, E. J. "Tensor Programs IV: Feature Learning in Infinite-Width Neural Networks." ICML 2021. (P)
11. Cohen, J. et al. "Gradient Descent on Neural Networks Typically Occurs at the Edge of Stability." ICLR 2021.
12. Yao, Z. et al. "PyHessian: Neural Networks Through the Lens of the Hessian." 2020.
13. Galanti, T. et al. "SGD and Weight Decay Secretly Minimize the Rank of Your Neural Network." NeurIPS Workshop 2024.
14. Jang, U., Lee, J. D., Ryu, E. K. "LoRA Training in the NTK Regime has No Spurious Local Minima." ICML 2024.
15. Frankle, J. et al. "Linear Mode Connectivity and the Lottery Ticket Hypothesis." ICML 2020.
16. Zinkevich, M. "Online Convex Programming and Generalized Infinitesimal Gradient Ascent." ICML 2003.