

流形上的最速下降

优化算法专题讲义

May 6, 2026

Abstract

本讲义系统介绍**矩阵参数 + 流形约束**下的最速下降问题。主线是把”最小作用量原理”扩展到带等式约束的情形：先给增量加范数约束（推出 SGD、SignSGD、Muon），再给参数本身加流形约束（推出超球面 / 正交 / Stiefel / 谱球面上的 Muon）；通用求解套路是”一阶近似 + 待定系数 + 不动点迭代/对偶梯度下降”。讲义穿插具体的低维数值算例，最后给出可在课堂演示的 NumPy 参考代码。

先修：矩阵分析（SVD、谱范数、核范数）、凸优化（拉格朗日乘子、Hölder 不等式）、深度学习常用优化器。

贯穿主线： $\min_{\Delta W} L(W + \Delta W)$ s.t. $\rho(\Delta W) \leq \eta$ ，并对参数 W 添加约束 $\mathcal{M}(W) = 0$ 。

Contents

1 引入：为什么要研究流形上的最速下降？	3
2 第一讲：最速下降的统一框架	3
2.1 最小作用量原理	3
2.2 一阶近似下的方向问题	3
2.3 若干基本范数下的最速下降	3
3 第二讲：流形上的几何语言	3
3.1 内蕴几何与外蕴几何	4
3.2 流形与切空间	11
3.3 李群、李代数与机器人控制	12
3.4 测地线与测地线距离	15
3.5 测地线方程：Lagrangian 推导	15
3.6 应用：语义嵌入空间的测地线距离	17
3.7 回缩 (retraction)	18
4 第三讲：矩阵参数与谱范数——Muon 优化器	18
4.1 矩阵参数的”自然”度量	18
4.2 谱范数约束下的最速下降：Muon	18
4.3 msign 的具体算例	20
4.4 Newton-Schulz 迭代实现 msign	21
5 第四讲：流形约束下的统一推导原则	22
6 第五讲：Riemannian 视角——投影梯度 + 回缩	22
6.1 标准三步	22
6.2 例子 A：球面上的相机朝向优化	23
6.3 KKT 与切空间投影的等价	23

6.4	例子 B: $SO(3)$ 上的姿态控制	23
6.5	与本讲义主线的关系	24
7	第六讲: 超球面上的 SGD	25
7.1	问题表述	25
7.2	一阶近似化简	25
7.3	待定系数求解	25
7.4	具体算例	25
7.5	几何意义	25
8	第七讲: 正交方阵流形上的 Muon	25
8.1	问题表述	25
8.2	一阶近似 = 切空间条件	26
8.3	待定系数法	26
8.4	方阵情形的闭式解	26
8.5	具体算例	26
8.6	回缩到正交群	27
9	第八讲: Stiefel 流形上的 Muon	27
9.1	困难何在	27
9.2	方法 A: 不动点迭代	27
9.3	Lyapunov 方程的两种求解	27
9.4	数值算例: 4×2 Stiefel 流形	27
9.5	方法 B: 对偶梯度下降	28
9.6	回缩	28
10	第九讲: 谱球面上的 Muon	29
10.1	问题与一阶近似	29
10.2	待定系数与不动点迭代	29
10.3	对偶梯度下降视角	29
10.4	数值算例: 3×3 谱球面	29
11	第十讲: 对偶梯度下降的统一视角	30
11.1	为什么核范数自然出现?	30
12	第十一讲: 实现细节与参考代码	30
12.1	精度问题	30
12.2	Stiefel 流形 Muon 参考实现	31
12.3	大模型训练中的实用建议	31
	结语	31
A	附录 A: 常用矩阵恒等式备忘	32
B	附录 B: 与相关研究方向的连接	32
C	附录 C: 练习题	33

1 引入：为什么要研究流形上的最速下降？

在深度学习训练中，对参数 W 施加额外约束的需求并不少见：

- **超球面约束** $\|w\|_2 = 1$ ：归一化方向向量、prototype-based 分类、speaker embedding。
- **正交约束** $W^\top W = I$ ：稳定的 RNN/SSM 转移矩阵、归一化流、防止表示坍塌、LoRA 的去冗余参数化。
- **Stiefel 约束** $W^\top W = I_m$ ($W \in \mathbb{R}^{n \times m}$, $n > m$)：半正交投影矩阵。
- **谱范数约束** $\|W\|_2 = 1$ ：Lipschitz 控制、谱归一化 GAN、稳定训练。

这一类问题传统上用 Riemannian SGD 求解，但流形上的指数映射往往昂贵。本讲义采用一种近期更为实用的视角——把约束统一进”最小作用量原理”：**先求最速下降方向 Φ ，再做回缩 (retraction) 把参数拉回流形**。该视角在 Muon 优化器 [1] 和 *Orthogonal Manifold* [2] 中得到了系统应用。

2 第一讲：最速下降的统一框架

2.1 最小作用量原理

设损失为 $L(\cdot)$ ，参数为 w ，更新量为 Δw 。一个”好”的优化器应当**又稳又快**：在一定步长内使损失下降最多。形式化为：

$$\min_{\Delta w} L(w + \Delta w) \quad \text{s.t.} \quad \rho(\Delta w) \leq \eta \quad (1)$$

其中 ρ 是衡量”步子”大小的某种范数。 ρ 的不同选择对应不同优化器。

2.2 一阶近似下的方向问题

当 η 充分小，做一阶展开 $L(w + \Delta w) \approx L(w) + \langle g, \Delta w \rangle$, $g = \nabla L(w)$ 。代入并令 $\Delta w = -\kappa \varphi$, $\rho(\varphi) = 1$ ，可得等价目标：

$$\max_{\varphi} \langle g, \varphi \rangle \quad \text{s.t.} \quad \rho(\varphi) = 1 \quad (2)$$

此即”最速下降方向”问题。 φ 的反方向就是损失下降最快的方向；该方向**依赖于 ρ 的选择**。

2.3 若干基本范数下的最速下降

例子 2.1 (L^2 范数：朴素 SGD)：当 $\rho(\varphi) = \|\varphi\|_2$ ，由柯西不等式 $\langle g, \varphi \rangle \leq \|g\|_2$ ，等号在 $\varphi \propto g$ 取得，故 $\varphi^* = g/\|g\|_2$, $\Delta w = -\eta g/\|g\|_2$ 。这正是规范化梯度下降。

例子 2.2 (L^p 范数：pbSGD)： $\rho(\varphi) = \|\varphi\|_p$ ，由 Hölder 不等式 $\langle g, \varphi \rangle \leq \|g\|_q \|\varphi\|_p$ ($1/p + 1/q = 1$)。等号条件 $\varphi^{[p]} \propto g^{[q]}$ ，其中 $g_i^{[\alpha]} := \text{sign}(g_i) |g_i|^\alpha$ ，解得 $\varphi^* = g^{[q/p]} / \|g^{[q/p]}\|_p$ 。两个特例： $p = 2$ 退化为 SGD； $p \rightarrow \infty$ 时 $q \rightarrow 1$, $\varphi^* = \text{sign}(g)$ ，即 SignSGD。

注记 2.3： ρ 是优化器中很本质的**先验** (inductive bias)。把它从 L^2 推广到矩阵的谱范数，正是 Muon 的来历——也是本讲义的真正起点。

3 第二讲：流形上的几何语言

在进入 Muon 与流形约束之前，先把后面要反复使用的几何概念厘清：**内蕴/外蕴视角、流形、切空间、测地线、回缩**。本讲也用了一个 NLP 中的具体应用例子说明”测地线距离”的实用价值。

3.1 内蕴几何与外蕴几何

进入形式定义之前，先把一个本质区分讲清楚——**同一个流形可以从两种视角看**：

- **外蕴 (extrinsic) 视角**：把流形看成嵌在某个大空间里的子集，关心它”长什么样”——形状、位置、坐标。
- **内蕴 (intrinsic) 视角**：只用流形内部能”摸到”的东西——长度、角度、面积——不引用流形外部的方向或坐标。

画面 1：圆筒 = 平纸 (内蕴上) 把 A4 纸卷成圆筒 (不撕、不拉伸)。外蕴上完全不同 (一平一弯)；内蕴上完全相同——纸面上画的所有距离、角度、三角形面积，卷起来后一个都没变。住在纸上的蚂蚁感觉不到任何差别。

画面 2：蚂蚁 vs 人的距离观 球面上的对径两点 p, q ：

- 外蕴距离 $\|p - q\| = 2R$ ：穿过球心的直线段——蚂蚁走不了。
- 内蕴距离 $d_g(p, q) = \pi R$ ：沿大圆走的最短弧——蚂蚁实际能走的最短路径。

度量张量 g_{ij} ：把内蕴几何形式化

光说”蚂蚁能测量的东西”还不够形式化。怎么把”住在面上能感知到的几何”写成数学？答案是给每点的切空间装一个内积——这个东西就叫 **Riemann 度量 (Riemannian metric)** 或**度量张量 g_{ij}** 。

定义：在每点 $p \in \mathcal{M}$ 的切空间 $T_p\mathcal{M}$ 上选一个内积 $\langle \cdot, \cdot \rangle_p$ ，使其随 p 光滑变化。在局部坐标 $(x^1, \dots, x^n)$ 下，

$$g_{ij}(p) := \langle \partial_i, \partial_j \rangle_p,$$

即坐标基向量的两两内积。 g_{ij} 是一个对称正定矩阵 (依赖 p)。

有了 g_{ij} 就有所有内蕴几何：

- 切向量 $u = u^i \partial_i$ 的长度： $\|u\|^2 = g_{ij} u^i u^j$ 。
- 两个切向量的夹角： $\cos \alpha = g_{ij} u^i v^j / (\|u\| \|v\|)$ 。
- 曲线 γ 的弧长： $L = \int \sqrt{g_{ij} \dot{x}^i \dot{x}^j} dt$ (这正是 §3.5 的弧长泛函)。
- 面积元： $dA = \sqrt{\det g} dx^1 \cdots dx^n$ 。
- 测地线、Christoffel 符号、曲率——全都从 g_{ij} 及其导数算出。

度量张量 g_{ij} 完全决定了流形的内蕴几何。两个流形若存在坐标使它们的 g_{ij} 相同，蚂蚁就分不清自己住在哪一个上——它们**内蕴等同 (isometric)**。

嵌入流形的诱导度量：若 $\mathcal{M} \subset \mathbb{R}^N$ 由参数 $\mathbf{r}(x^1, \dots, x^n)$ 给出，则继承自 $\mathbb{R}^N$ 的内积自动给出度量

$$g_{ij} = \langle \partial_i \mathbf{r}, \partial_j \mathbf{r} \rangle_{\mathbb{R}^N}.$$

这就是经典曲面论里的”**第一基本形式**”。

算例 1: 球面

$\mathbf{r}(\theta, \phi) = R(\sin \theta \cos \phi, \sin \theta \sin \phi, \cos \theta)$ 。算偏导内积 (用 SymPy 符号验过):

$$g_{\theta\theta} = R^2, \quad g_{\phi\phi} = R^2 \sin^2 \theta, \quad g_{\theta\phi} = 0.$$

即

$$g = \begin{pmatrix} R^2 & 0 \\ 0 & R^2 \sin^2 \theta \end{pmatrix}, \quad ds^2 = R^2 d\theta^2 + R^2 \sin^2 \theta d\phi^2.$$

用 g_{ij} 算东西 ($R = 1$):

- 北纬 30° 圆周长 ($\theta = \pi/3$ 固定): $\int_0^{2\pi} \sqrt{\sin^2(\pi/3)} d\phi = 2\pi \sin(\pi/3) \approx 5.44$ 。
- 赤道周长 ($\theta = \pi/2$): $2\pi \sin(\pi/2) = 2\pi \approx 6.28$ 。

两个数都跟外蕴坐标无关, 纯由 g_{ij} 决定。

算例 2: 圆筒 = 平面 (内蕴) 的代数证明

$\mathbf{r}(u, v) = (R \cos u, R \sin u, v)$ 。算诱导度量:

$$g_{uu} = R^2, \quad g_{vv} = 1, \quad g_{uv} = 0 \implies ds^2 = R^2 du^2 + dv^2.$$

做坐标变换 $u' = Ru$ (弧长参数化):

$$ds^2 = du'^2 + dv^2 \iff g_{i'j'} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

这完全等同于平面的度量! 所以圆筒和平面内蕴等同——上一节“卷纸”的直觉, 到这里有了精确的代数表述: 在合适坐标下度量张量逐点完全相同。蚂蚁的所有测量结果都不会区分两者。

Theorema Egregium: g_{ij} 决定一切

球面的“弯曲度”由高斯曲率 K 衡量。它看起来是个外蕴量——经典定义用第二基本形式 (描述曲面如何在 $\mathbb{R}^3$ 中弯)。但 Gauss 在 1827 年证明了一件惊人的事: K 只依赖 g_{ij} 及其导数, 与嵌入方式无关。具体公式 (正交坐标 $g_{12} = 0$ 时的 **Brioschi 公式**):

$$K = -\frac{1}{2\sqrt{EG}} \left[\partial_v \left(\frac{\partial_v E}{\sqrt{EG}} \right) + \partial_u \left(\frac{\partial_u G}{\sqrt{EG}} \right) \right], \quad E = g_{11}, G = g_{22}. \quad (3)$$

定理 3.1 (Theorema Egregium): 高斯曲率 K 是内蕴量: 仅由度量张量 g_{ij} 决定。

算例验证 (用 SymPy 符号验过):

(a) 球面 $g = \text{diag}(R^2, R^2 \sin^2 \theta)$: $E = R^2, G = R^2 \sin^2 \theta, \sqrt{EG} = R^2 \sin \theta$ 。

- $\partial_\phi E = 0$, 第一项消失。
- $\partial_\theta G = 2R^2 \sin \theta \cos \theta$, 故 $\partial_\theta G / \sqrt{EG} = 2 \cos \theta$ 。
- $\partial_\theta (2 \cos \theta) = -2 \sin \theta$ 。

- 合起来 $K = -\frac{1}{2R^2 \sin \theta} \cdot (-2 \sin \theta) = \boxed{\frac{1}{R^2}}$ 。

跟外蕴定义算出的 $K = 1/R^2$ 完全一致——而且整个推导没碰过 $\mathbb{R}^3$ 的“球内一点”。

(b) 圆筒 $g = \text{diag}(R^2, 1)$: 所有度量分量都是常数, 所有偏导都是零, 故 $K = 0$ 。

(c) 平面 (极坐标) $g = \text{diag}(1, \rho^2)$: 算下来也是 $K = 0$ 。

对比: 在 $\mathbb{R}^3$ 里看, 圆筒“明明是弯的” (视觉上), 但 $K = 0$ 跟平面一样——因为可以展开成平面。而球面 $K = 1/R^2 > 0$ 不能展开 (你不可能把橘子皮压平而不撕裂)。这就是为什么**地图必失真** (球面到平面没有保距映射)——这件事 Gauss 的定理给出了精确的内蕴判据。

对优化的启示

讲义后面把这个抽象图式翻译到优化语言：

- **最速下降方向的”几何”** 由切空间上的**度量**决定。换种度量 = 换种”最速”——

$$\rho(\Delta\theta) = \sqrt{(\Delta\theta)^\top G(\Delta\theta)}, \quad G \text{ 由优化器选择.}$$

SGD 取 $G = I$ (欧氏度量), natural gradient 取 $G = F$ (Fisher 度量), Muon 隐式取的是谱范数对应的”算子度量”。

- **Fisher 信息 F 就是分布流形的 Riemannian 度量 g_{ij}** 。这不是类比——上面提到 $F(\theta') = J^\top F(\theta) J$ 严格按 g_{ij} 张量变换规律。
- **曲率 (Hessian 减去预条件项)** 在最优化解里对应”下降方向被流形扭曲多少”——但这是另一层故事, 工程上常用对角/块对角近似处理。

注记 3.2 (历史插话): Gauss 把这条结果命名为 *Theorema Egregium* (拉丁文”绝妙定理”)——是他个人觉得最得意的工作。它直接孕育了黎曼几何、爱因斯坦广义相对论 (时空的几何由内蕴度量决定)、以及今天的流形学习与流形优化。下次你看到 Adam 的 $\hat{v}_t \propto F$ 估计、自然梯度的 F^{-1} 、Riemannian SGD 的切空间投影——它们的代数根都在这条 200 年前的定理上。

参数化的歧义

更深一步：**同一个流形，用不同参数描述时，”看起来”完全不同。**

例子 3.3 (同一条曲线的两种参数化): 单位圆 $\mathcal{M} = \{(x, y) : x^2 + y^2 = 1\}$ 可以这样参数化：

- $\phi_1(t) = (\cos t, \sin t)$, $t \in [0, 2\pi)$ ——等速画圆；
- $\phi_2(s) = (\cos(s^3), \sin(s^3))$, $s \in [0, (2\pi)^{1/3})$ ——非等速： s 接近 0 时跑得慢，接近 $(2\pi)^{1/3}$ 时跑得快。

图像 (点集) 完全相同；但在 t 坐标和 s 坐标里，”参数走一步 $\Delta = 0.1$ ”对应的圆上弧长差异巨大。**同一个流形，参数空间里的几何完全不同。**

优化的视角：在参数空间做”梯度下降等距前进”，到底是在流形上等距，还是在参数空间等距？取决于参数化——这件事并不显然。

Hessian 是外蕴的，Fisher 是内蕴的

把这件事在优化里说精确。考虑损失 $L(\theta)$ ，做参数变换 $\theta = \phi(\theta')$ ，记 Jacobian $J = \partial\theta/\partial\theta'$ 。

梯度变换： $\nabla_{\theta'} L = J^\top \nabla_\theta L$ ——像协变向量一样变换，干净。

Hessian 变换：

$$\nabla_{\theta'}^2 L = J^\top (\nabla_\theta^2 L) J + \sum_i (\partial_i L) \nabla_{\theta'}^2 \phi_i. \quad (4)$$

后一项一般**不为零**——这正是”非线性参数化引入的额外曲率项”。所以 Hessian **依赖参数化**，不是流形上的内蕴量。

例外是临界点 $\nabla_\theta L = 0$ 处，第二项消失，Hessian 像 $(0, 2)$ -张量一样变换——这是为什么 Morse 引理等理论结果只在临界点附近成立。

Fisher 信息则完全不同。对似然模型 $p_\theta(x)$,

$$F(\theta) := \mathbb{E}_x \left[\nabla_\theta \log p_\theta \nabla_\theta \log p_\theta^\top \right].$$

做参数变换，由链式法则

$$F(\theta') = J^\top F(\theta) J \quad (5)$$

没有第二项——因为 $\mathbb{E}[\nabla \log p_\theta] = 0$ ，相当于“在期望意义下永远处于临界点”。(5) 恰是 Riemann 度量张量在坐标变换下的标准行为。所以 F 在分布流形 $\mathcal{M} = \{p_\theta\}_\theta$ 上定义了一个内蕴 Riemann 度量：同一个分布，无论怎么参数化，它在 $\mathcal{M}$ 上的几何都一样。

这正是 natural gradient 的来源：

$$\Delta\theta = -\eta F(\theta)^{-1} \nabla_\theta L$$

是参数化无关的更新方向——换一种参数，在分布空间里走过的路径不变。

具体数值算例：Hessian 跑偏，Fisher 守恒

为了把上面抽象的张量公式落到实处，看一个最小的算例。

设置：模型 $p_\mu(x) = \mathcal{N}(\mu, 1)$ ，损失 $L(\mu) = -\log p_\mu(x_0) = \frac{1}{2}(x_0 - \mu)^2 + c$ ，观测 $x_0 = 2$ 。重参数化 $\mu = \phi(\theta) := \theta^3$ 。比较点 $\mu = 1$ （即 $\theta = 1$ ）。

第 1 步：在 μ 坐标下直接算

$$\begin{aligned} \nabla_\mu L &= -(x_0 - \mu) = -1, & \nabla_\mu^2 L &= 1, \\ F(\mu) &= \mathbb{E}_x[(x - \mu)^2] = 1 & & (\mathcal{N}(\mu, 1) \text{ 的方差}) . \end{aligned}$$

第 2 步：在 θ 坐标下直接算 $L(\theta) = \frac{1}{2}(x_0 - \theta^3)^2 + c$ ，求导得

$$\begin{aligned} \nabla_\theta L &= -3\theta^2(x_0 - \theta^3) = -3, \\ \nabla_\theta^2 L &= -6\theta(x_0 - \theta^3) + 9\theta^4 = -6 + 9 = \boxed{3}. \end{aligned}$$

另外 $\nabla_\theta \log p = 3\theta^2(x - \theta^3)$ ，故

$$F(\theta) = \mathbb{E}_x[(3\theta^2)^2(x - \theta^3)^2] = 9\theta^4 \cdot 1 = \boxed{9}.$$

第 3 步：用变换公式核对 $J = d\mu/d\theta = 3\theta^2 = 3$ ， $\phi'' = 6\theta = 6$ 。

Hessian 公式 (4)：

$$\nabla_\theta^2 L \stackrel{?}{=} J^2 \nabla_\mu^2 L + (\nabla_\mu L) \phi'' = 9 \cdot 1 + (-1) \cdot 6 = 9 - 6 = 3. \quad \checkmark$$

注意 $\boxed{-6}$ 这个第二项——它就是“非线性参数化引入的额外项”。

Fisher 公式 (5)：

$$F(\theta) \stackrel{?}{=} J^2 F(\mu) = 9 \cdot 1 = 9. \quad \checkmark$$

没有第二项。

第 4 步：意义对比表

量	μ 坐标	θ 坐标	张量纯变换预测	额外项
Hessian	1	3	9 (不对!)	-6
Fisher	1	9	9 (对)	0

解读：Hessian 在两套坐标里给出的“曲率”不只差一个 Jacobian 因子——还多出来一个 -6，** 这部分信息完全来自 ϕ 的非线性，与流形本身无关 **。Fisher 不会， $1 \rightarrow 9$ 是干净的张量变换，正是 Riemann 度量该有的行为。

第 5 步：参数化无关性测试

到这里我们已经看到 Hessian 跟 Fisher 在两套坐标里数值不同 ($\{1, 3\}$ vs $\{1, 9\}$)，但还没看出“这件事在优化里到底意味着什么”。下面的测试把这个意义具象化。

核心问题 同一个分布 $\mathcal{N}(\mu, 1)$ 朝目标 x_0 的更新，在 μ 坐标和 θ 坐标里各跑一步 SGD，会得到同一个“实际更新”吗？

更具体：分布是真实的对象，参数只是它的一种“标记方式”。用不同标记跑同一个算法，按理应给出同一个新分布——否则算法就被参数化绑架了，是工程师选择带来的人为伪影。

怎么比较 $\Delta\mu$ (分布空间里的步) 和 $\Delta\theta$ (参数空间里的步) 单位不同, 不能直接放一起比。要做苹果对苹果的比较, 必须翻译到**同一个空间**。我们选**分布空间 μ** 作为公共比较场所:

- μ 坐标的更新 $\Delta\mu$: 本来就在分布空间, 照搬。
- θ 坐标的更新 $\Delta\theta$: 通过链式法则一阶展开

$$\Delta\mu_{\text{induced}} := J \cdot \Delta\theta = 3\Delta\theta,$$

即 θ 走 $\Delta\theta$ 时, μ 实际发生的 (一阶) 变化。

$\Delta\mu$ vs $\Delta\mu_{\text{induced}}$ 是否相等 $\iff$ 算法是否参数化无关。

实测: 普通 SGD ($\eta = 1$)

- 在 μ 下: $\Delta\mu = -\nabla_{\mu}L = +1$ 。
(合理: 分布参数从 $\mu = 1$ 朝 $x_0 = 2$ 走一步。)
- 在 θ 下: $\Delta\theta = -\nabla_{\theta}L = +3$; 诱导 $\Delta\mu_{\text{induced}} = 3 \cdot 3 = 9$ 。

$$\Delta\mu = 1 \text{ vs } \Delta\mu_{\text{induced}} = 9 \implies \text{差 9 倍, 不一致}$$

结论: 同一个 $\eta = 1$, 分布在两套坐标里实际走的距离差 9 倍。SGD 的 η 是”参数空间步长”, 物理意义不稳定——**换种参数化你的优化器就变了一个**。

实测: natural gradient ($\eta = 1$) NGD 用 Fisher 的逆做预条件。

- 在 μ 下: $\Delta\mu = -F(\mu)^{-1}\nabla_{\mu}L = -1 \cdot (-1) = +1$ 。
- 在 θ 下: $\Delta\theta = -F(\theta)^{-1}\nabla_{\theta}L = -\frac{1}{9} \cdot (-3) = +\frac{1}{3}$; 诱导 $\Delta\mu_{\text{induced}} = 3 \cdot \frac{1}{3} = +1$ 。

$$\Delta\mu = 1 \text{ vs } \Delta\mu_{\text{induced}} = 1 \implies \text{完全一致}$$

结论: NGD 在分布空间里走的步子与参数化无关。NGD 的 η 是”分布空间步长”, 物理意义稳定——这正是上面”Fisher 是内蕴的”那句话的具体含义。

为什么 NGD 能不变? 代数上一行说清: 在 θ 下,

$$\Delta\mu_{\text{induced}} = J\Delta\theta = -JF(\theta)^{-1}\nabla_{\theta}L = -J(J^2F(\mu))^{-1}(J\nabla_{\mu}L) = -F(\mu)^{-1}\nabla_{\mu}L,$$

即 F^{-1} 把 Fisher 变换式 J^2F 中的两个 J 一起消掉。普通 SGD 没有这一步消去, 留下来的 J 在不同坐标里”乱跑”, 所以两条路给出不同的物理结果。

有了这个 1D 直觉, 下面把它搬到 2D 看看额外项变成矩阵后的效果。

高维算例: 2D 高斯 + 非线性混合参数化

把上面的 1D 例子搬到 2D, 让 Hessian 的”额外项”成为一个真正的矩阵, 看看这件事在多维里有多严重。

设置:

- 模型: $p_{\mu}(x) = \mathcal{N}(\mu, I_2)$, 参数 $\mu = (\mu_1, \mu_2) \in \mathbb{R}^2$ 。
- 损失: $L(\mu) = \frac{1}{2}\|x_0 - \mu\|^2 + c$ 。
- 观测: $x_0 = (3, 2)$ 。

- 重参数化（两个分量混在一起的非线性变换）：

$$\mu_1 = \theta_1^2 + \theta_2, \quad \mu_2 = \theta_1 \theta_2.$$

- 比较点： $\theta = (1, 1)$ ，对应 $\mu = (2, 1)$ 。

第 1 步：在 μ 坐标下

$$\nabla_{\mu} L = -(x_0 - \mu) = (-1, -1)^{\top}, \quad \nabla_{\mu}^2 L = I_2, \quad F(\mu) = I_2.$$

(Hessian 与 Fisher 都是 I_2 ，因为高斯模型 + 单位协方差。)

第 2 步：算 Jacobian 与各分量的 Hessian

$$J = \frac{\partial \mu}{\partial \theta} = \begin{pmatrix} 2\theta_1 & 1 \\ \theta_2 & \theta_1 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}, \quad \det J = 1.$$

$$\nabla^2 \phi_1 = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix}, \quad \nabla^2 \phi_2 = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

第 3 步：在 θ 坐标下直接求二阶导设残差 $r_1 = x_{0,1} - (\theta_1^2 + \theta_2) = 1$, $r_2 = x_{0,2} - \theta_1 \theta_2 = 1$ 。直接微分得

$$\nabla_{\theta} L = \begin{pmatrix} -2\theta_1 r_1 - \theta_2 r_2 \\ -r_1 - \theta_1 r_2 \end{pmatrix} = \begin{pmatrix} -3 \\ -2 \end{pmatrix},$$

$$\nabla_{\theta}^2 L = \begin{pmatrix} -2r_1 + 4\theta_1^2 + \theta_2^2 & 2\theta_1 - r_2 + \theta_1 \theta_2 \\ 2\theta_1 - r_2 + \theta_1 \theta_2 & 1 + \theta_1^2 \end{pmatrix} = \boxed{\begin{pmatrix} 3 & 2 \\ 2 & 2 \end{pmatrix}}.$$

另算 Fisher: $\nabla_{\theta} \log p = J^{\top} (x - \mu)$, 故

$$F(\theta) = \mathbb{E} \left[J^{\top} (x - \mu) (x - \mu)^{\top} J \right] = J^{\top} I J = J^{\top} J = \boxed{\begin{pmatrix} 5 & 3 \\ 3 & 2 \end{pmatrix}}.$$

第 4 步：用变换公式核对

Hessian (4):

$$J^{\top} \nabla_{\mu}^2 L \cdot J = J^{\top} J = \begin{pmatrix} 5 & 3 \\ 3 & 2 \end{pmatrix},$$

$$\sum_i (\nabla_{\mu} L)_i \nabla^2 \phi_i = (-1) \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix} + (-1) \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} = \boxed{\begin{pmatrix} -2 & -1 \\ -1 & 0 \end{pmatrix}},$$

$$\text{合计} = \begin{pmatrix} 5 & 3 \\ 3 & 2 \end{pmatrix} + \begin{pmatrix} -2 & -1 \\ -1 & 0 \end{pmatrix} = \begin{pmatrix} 3 & 2 \\ 2 & 2 \end{pmatrix} \checkmark$$

Fisher (5):

$$F(\theta) \stackrel{?}{=} J^{\top} F(\mu) J = J^{\top} J = \begin{pmatrix} 5 & 3 \\ 3 & 2 \end{pmatrix} \checkmark$$

依然没有第二项。

第 5 步：意义对比

量	张量纯变换 $J^{\top} M J$	实际
Hessian	$\begin{pmatrix} 5 & 3 \\ 3 & 2 \end{pmatrix}$	$\begin{pmatrix} 3 & 2 \\ 2 & 2 \end{pmatrix}$ (差出一个秩 2 的修正)
Fisher	$\begin{pmatrix} 5 & 3 \\ 3 & 2 \end{pmatrix}$	$\begin{pmatrix} 5 & 3 \\ 3 & 2 \end{pmatrix}$ (一致)

重要观察：在 1D 情形中”额外项”只是个标量 -6 ，到 2D 它变成一个 2×2 矩阵 $\begin{pmatrix} -2 & -1 \\ -1 & 0 \end{pmatrix}$ 。它是满秩、非对角的——也就是说非线性参数化不仅会改变 Hessian 的特征值（缩放），还会改变它的特征向量（旋转坐标轴）。优化器看到的”曲率主方向”从 μ 坐标到 θ 坐标，整个被参数化”扭”了一下。

第 6 步：参数化无关性测试

到这里我们已经看到 Hessian 跟 Fisher 在两套坐标里数值不同，但还没看出”这件事在优化里到底意味着什么”。下面的实验把这个意义具象化。

核心问题 同一个分布模型，从 μ 坐标和 θ 坐标各自跑一步 SGD，会得到同一个”实际更新”吗？

更具体地说，我们是在更新一个分布 p_μ ；分布是真实的对象，参数只是它的一种”标记方式”。用不同标记方式跑同一个算法（SGD），应该得到同一个新分布——否则算法的行为就被参数化绑架了，是工程师选择带来的人为伪影。

怎么比较 两条更新不能直接放一起比——一个是 $\Delta\mu$ （分布空间里的步），一个是 $\Delta\theta$ （参数空间里的步），单位都不同。要做苹果对苹果的比较，必须把两者翻译到同一个空间里。我们选分布空间 μ 作为公共比较场所：

- μ 坐标的更新 $\Delta\mu$ ：本来就在分布空间，照搬。
- θ 坐标的更新 $\Delta\theta$ ：通过链式法则一阶展开

$$\Delta\mu_{\text{induced}} := J \Delta\theta + O(\|\Delta\theta\|^2),$$

即 θ 走 $\Delta\theta$ 时，分布参数 μ 实际发生的（一阶）变化。

两个数 $\Delta\mu$ vs $\Delta\mu_{\text{induced}}$ 比较的意义：是否相等 $\iff$ 算法是否”参数化无关”。

实测：普通 SGD ($\eta = 1$)

- 在 μ 坐标跑 SGD： $\Delta\mu = -\nabla_\mu L = (1, 1)^\top$ 。
(直接告诉我们：分布参数应当从 $(2, 1)$ 走到约 $(3, 2) = x_0$ ，朝目标走一步——合理。)
- 在 θ 坐标跑 SGD： $\Delta\theta = -\nabla_\theta L = (3, 2)^\top$ 。翻译回分布空间：

$$\Delta\mu_{\text{induced}} = J \Delta\theta = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 3 \\ 2 \end{pmatrix} = (8, 5)^\top.$$

$$\Delta\mu = (1, 1)^\top \text{ vs } \Delta\mu_{\text{induced}} = (8, 5)^\top \implies \text{不一致}$$

结论：普通 SGD 不是参数化无关的。两套坐标跑同一算法，分布空间里出来的不是同一个更新——一个朝 $(1, 1)$ 走、另一个朝 $(8, 5)$ 走，方向偏差大、步长差 $\sim 8\times$ 。换种参数化你的优化器就变了一个，这是个 bug 不是 feature。

实测：natural gradient ($\eta = 1$) NGD 用 Fisher 的逆做预条件。在 θ 下 $\det F(\theta) = 1$ ， $F^{-1} = \begin{pmatrix} 2 & -3 \\ -3 & 5 \end{pmatrix}$ 。

- 在 μ 坐标： $\Delta\mu = -F(\mu)^{-1} \nabla_\mu L = -I \cdot (-1, -1)^\top = (1, 1)^\top$ 。
- 在 θ 坐标： $\Delta\theta = -F^{-1} \nabla_\theta L = -\begin{pmatrix} 2 & -3 \\ -3 & 5 \end{pmatrix} \begin{pmatrix} -3 \\ -2 \end{pmatrix} = (0, 1)^\top$ 。翻译回分布空间：

$$\Delta\mu_{\text{induced}} = J(0, 1)^\top = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = (1, 1)^\top.$$

$$\Delta\mu = (1, 1)^\top \text{ vs } \Delta\mu_{\text{induced}} = (1, 1)^\top \implies \text{完全一致}$$

结论：NGD 是参数化无关的。两套坐标跑出来的更新在分布空间里看是同一个——这正是“Fisher 是内蕴度量”那句话的具体含义。

为什么 NGD 能不变？ 代数上一行：在 θ 下，

$$\Delta\mu_{\text{induced}} = J \Delta\theta = -JF(\theta)^{-1}\nabla_{\theta}L = -J(J^\top F(\mu)J)^{-1}(J^\top \nabla_{\mu}L) = -F(\mu)^{-1}\nabla_{\mu}L,$$

最后一步因为 $J(J^\top FJ)^{-1}J^\top = F^{-1}$ (当 J 可逆时)。所以 F^{-1} 把 **Fisher 变换式 $J^\top FJ$ 中的两个 J 一起”约掉”**——Fisher 的张量变换性质是 NGD 不变性的代数根源。普通 SGD 缺这一步消去，Jacobian 留下来”乱跑”，所以两个坐标系跑出不同步。

总结 高维让”额外项是矩阵”这件事真正显形：

- Hessian 的额外项可以是**任意秩、非对角**，意味着不只是缩放，还有”旋转”——优化器以为重要的方向，其实是参数化人为造出来的方向。
- Fisher 严格按 $J^\top FJ$ 变换，是干净的内蕴张量。
- natural gradient $F^{-1}\nabla L$ 在分布流形上的更新方向参数化无关。

这正是 Adam (对角 Fisher 近似)、K-FAC、Shampoo 这些现代优化器的几何动机：**越靠近真正的 F^{-1} ，越接近内蕴下降。**

把所有优化器放到一个谱里

回到本讲义的主题。最速下降 $\min L(W + \Delta W) \text{ s.t. } \rho(\Delta W) \leq \eta$ 中， ρ 的选择就是在**参数空间上挑一种几何**：

范数 ρ 的选择	对应优化器	几何视角
$\ \cdot\ _2$ (Frobenius)	SGD	标准欧氏 (外蕴)
$\ \cdot\ _2$ (谱范数)	Muon	算子几何 (介于内外之间)
$(\Delta\theta)^\top F \Delta\theta$	natural gradient	Fisher (内蕴)
沿流形测地线	Riemannian SGD	完全内蕴

从外蕴到内蕴，精度递增、计算量也递增。Adam 的 $\hat{v}_t$ 是 Fisher 的对角近似；K-FAC、Shampoo 是块状近似；Muon 通过 `msign` 取了另一条几何路径——都是在用便宜的方法逼近某种内蕴几何。

讲义后面所有算法都可以放到这个谱里看：每个算法 = 一种 ρ 的选择 = 一种几何视角的工程折中。

3.2 流形与切空间

流形 (manifold) 直观上是一个”局部看起来像欧氏空间”的几何对象。本讲义只关心嵌入在 $\mathbb{R}^n$ 或 $\mathbb{R}^{n \times m}$ 中的子流形，由若干等式约束 $\mathcal{M}(W) = 0$ 给出。

例子 3.4 (常见流形)：

- 单位超球面 $S^{n-1} = \{w \in \mathbb{R}^n : \|w\|_2 = 1\}$ ，约束 1 个等式，维数 $n - 1$ 。
- 正交群 $O(n) = \{W \in \mathbb{R}^{n \times n} : W^\top W = I\}$ ，约束 $n(n + 1)/2$ 个等式，维数 $n(n - 1)/2$ 。
- Stiefel 流形 $\text{St}(n, m) = \{W \in \mathbb{R}^{n \times m} : W^\top W = I_m\}$ ($n \geq m$)，维数 $nm - m(m + 1)/2$ 。
- 谱球面 $\{W : \|W\|_2 = 1\}$ (最大奇异值唯一时是光滑流形)。

切空间 (tangent space) $T_W \mathcal{M}$ 是流形 $\mathcal{M}$ 在点 W 处的”瞬时变化方向”集合。形式上：若 $W(t)$ 是流形上一条经过 W 的光滑曲线 ($W(0) = W$)，则切向量是 $\dot{W}(0)$ 。把约束 $\mathcal{M}(W) = 0$ 微分得 $\nabla \mathcal{M}(W) \cdot \Delta = 0$ ，这就是切空间的线性方程。

例子 3.5 (超球面切空间)： $\mathcal{M}(w) = \|w\|_2^2 - 1$ ， $\nabla \mathcal{M}(w) = 2w$ 。所以切空间是 $T_w S^{n-1} = \{\varphi : \langle w, \varphi \rangle = 0\}$ ，即与 w 正交的超平面。

例子 3.6 (正交群切空间)： $\mathcal{M}(W) = W^\top W - I$ ，微分得 $W^\top \Delta + \Delta^\top W = 0$ 。所以切空间是 $T_W O(n) = \{\Delta : W^\top \Delta \text{ 反对称}\}$ 。

3.3 李群、李代数与机器人控制

我们前面看到的几个流形—— $O(n)$ 、 $\text{St}(n, m)$ 不只是流形，还**自带群结构**：两个正交矩阵相乘还是正交矩阵。这一类”流形 + 群结构”叫做**李群 (Lie group)**。它在物理、机器人控制、计算机图形里无处不在；对本讲义重要的是：**李群的切空间结构有惊人的简洁性——它把”局部”几何外包给一个固定的线性空间。**

李群元素 vs 李代数元素：动作结果 vs 动作生成器

最直观的例子是机器人在平面上的位姿。一个位姿（位置 + 朝向）可以表示为

$$T = \begin{pmatrix} R(\theta) & t \\ 0 & 1 \end{pmatrix} \in \text{SE}(2), \quad R(\theta) = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}, \quad t \in \mathbb{R}^2.$$

两个位姿合成 = 矩阵乘法，所以 $\text{SE}(2)$ 是 3 维李群（参数 θ, t_x, t_y ）。

对应的**李代数** $\mathfrak{se}(2)$ 是 $T = I$ 处的切空间，元素是

$$\xi = \begin{pmatrix} 0 & -\omega & v_x \\ \omega & 0 & v_y \\ 0 & 0 & 0 \end{pmatrix} \in \mathfrak{se}(2)$$

即”瞬时角速度 ω + 瞬时线速度 (v_x, v_y) ”——一个**速度向量 / 动作生成器**。

两者的关系 (极简版本)：

- **李群元素** $T \in G$ ：累积动作的”**结果**”——最终位姿。
- **李代数元素** $\xi \in \mathfrak{g}$ ：瞬时动作的”**生成器**”——速度向量。
- $\exp$ ： 生成器 $\rightarrow$ 动作结果。 $T(t) = \exp(t\xi)$ 是沿生成器匀速运动 t 时间到达的位姿。
- $\log$ ： 动作结果 $\rightarrow$ 生成器。”我现在的位姿要怎么由匀速运动从原点到达？”

李括号：两个生成器不对易时的”残差”

两个动作生成器 ξ, η 一般**不对易**：先做 ξ 再做 η 跟反过来结果不同。**李括号**度量这种不对易性：

$$[\xi, \eta] := \xi\eta - \eta\xi \in \mathfrak{g}.$$

其物理意义由 Baker–Campbell–Hausdorff 公式给出：

$$\exp(\epsilon\xi) \exp(\epsilon\eta) \exp(-\epsilon\xi) \exp(-\epsilon\eta) = \exp(\epsilon^2[\xi, \eta]) + O(\epsilon^3). \quad (6)$$

即”做 ξ 、做 η 、做 $-\xi$ 、做 $-\eta$ ”不会回到原点，会差出一个由 $[\xi, \eta]$ 生成的二阶残差动作。一句话：

李括号 = 两个生成器不交换时产生的”额外生成器”。

机器人例子：侧方停车

一辆普通小车有两个直接控制——前进速度 v 和转向角速度 ω 。状态空间是 $SE(2)$ (3 维)，但每点的可控方向只有 2 维：

$$X_1 = \cos \theta \partial_x + \sin \theta \partial_y \quad (" \text{前进}"), \quad X_2 = \partial_\theta \quad (" \text{旋转}").$$

没有侧向控制。但算李括号：

$$[X_2, X_1] = -\sin \theta \partial_x + \cos \theta \partial_y = " \text{侧向移动}."$$

即 [旋转, 前进] = 侧向！这正是侧方停车的几何来源：

前进 $\rightarrow$ 右转 $\rightarrow$ 倒车 $\rightarrow$ 回正 = 二阶小段侧向位移。

小车不能瞬间横移，但可以通过组合动作”挪”出来——这就是非完整 (nonholonomic) 系统的本质。

李括号的三种”接地气”算法

上面的 $[X_2, X_1]$ 用 ∂_x, ∂_y 这种微分算子写法，对学生不太友好。下面给出三种纯坐标 / 纯矩阵的等价算法，写代码就一行。

算法 A: Jacobian 公式 把 $\mathbb{R}^n$ 上的向量场看成 $\mathbb{R}^n \rightarrow \mathbb{R}^n$ 的函数，李括号写成两个 Jacobian 的换位：

$$[X, Y](p) = (DY)(p) X(p) - (DX)(p) Y(p) \quad (7)$$

其中 DX, DY 是普通的 $n \times n$ Jacobian 矩阵。

对小车， $p = (x, y, \theta) \in \mathbb{R}^3$ ：

$$X_1(p) = \begin{pmatrix} \cos \theta \\ \sin \theta \\ 0 \end{pmatrix}, \quad X_2(p) = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}, \quad DX_1 = \begin{pmatrix} 0 & 0 & -\sin \theta \\ 0 & 0 & \cos \theta \\ 0 & 0 & 0 \end{pmatrix}, \quad DX_2 = \mathbf{0}.$$

代公式 ($DX_2 = \mathbf{0}$ 让第二项消失)：

$$[X_2, X_1](p) = (DX_1)X_2 - \mathbf{0} = \begin{pmatrix} 0 & 0 & -\sin \theta \\ 0 & 0 & \cos \theta \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} -\sin \theta \\ \cos \theta \\ 0 \end{pmatrix}.$$

矩阵-向量乘法搞定，没有任何抽象算子。结果在 xy 平面里垂直于前进方向 $(\cos \theta, \sin \theta)$ ——侧方向。

算法 B: $SE(2)$ 矩阵代数 把姿态写成 3×3 矩阵 $T \in SE(2)$ ，李代数 $\mathfrak{se}(2)$ 是 $T = I$ 处的切空间——一族 3×3 矩阵。李括号 = 矩阵的对易子：

$$[\xi, \eta] = \xi\eta - \eta\xi \quad (8)$$

车体坐标系下：

$$\xi_1 = \begin{pmatrix} 0 & 0 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \quad (v_x = 1 \text{ 前进}), \quad \xi_2 = \begin{pmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \quad (\omega = 1 \text{ 旋转}).$$

算两次矩阵乘法相减：

$$\xi_2\xi_1 = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{pmatrix}, \quad \xi_1\xi_2 = \mathbf{0} \implies [\xi_2, \xi_1] = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{pmatrix}.$$

即车体坐标系下 $v_y = 1$ ，车自己看到的侧方。代码就一行：`xi2 @ xi1 - xi1 @ xi2`。

算法 A 与 B 的关系 A 给出 $(-\sin \theta, \cos \theta, 0)$ (世界坐标下的侧方向), B 给出 $v_y = 1$ (车体坐标下的侧方向)。两者差一个旋转 $R(\theta)$ ——车朝 θ 方向时, 体坐标 y 轴正是世界坐标 $(-\sin \theta, \cos \theta)$ 。这是李群中”左不变 vs 右不变”的具体体现。

算法 C: $\exp$ 的” 四步舞蹈” 数值验证 由 BCH (6):

$$\exp(\varepsilon \xi_2) \exp(\varepsilon \xi_1) \exp(-\varepsilon \xi_2) \exp(-\varepsilon \xi_1) = \exp(\varepsilon^2 [\xi_2, \xi_1]) + O(\varepsilon^3).$$

即” 旋转 $\rightarrow$ 前进 $\rightarrow$ 反旋转 $\rightarrow$ 后退” 四步动作产生 ε^2 阶的侧向位移。直接在 NumPy 里乘四个矩阵指数验证:

ε	实测 y 位移	理论 ε^2	比值 ($\rightarrow 1$?)
0.5	0.2397	0.2500	0.959
0.1	0.00998	0.01000	0.998
0.01	0.000100	0.000100	0.99998

$\varepsilon \rightarrow 0$ 时比值 $\rightarrow 1$, 三阶修正越来越小。侧方停车每次只能挪一点点的根本原因: 位移是 ε^2 阶, 比每个动作的 ε 阶小一个量级。

三种算法该用哪个

- **算法 A (Jacobian):** 控制理论 / 非完整规划首选—— $\dot{p} = u_1 X_1 + u_2 X_2$ 写在世界坐标, LARC 检查就是看这些 Jacobian 张成多少维。
- **算法 B (矩阵):** SLAM、姿态估计、 $SO(3)/SE(3)$ 等变神经网络首选——所有量都是矩阵, $\exp, \log, [\cdot, \cdot]$ 都是矩阵运算, 代码极简。
- **算法 C ($\exp$ 乘积):** 教学演示和 sanity check 用, 把” 二阶残差” 做成可看可摸的具体数。

三种算法结果完全等价——李代数的好处就是它在不同表示下都成立, 可以挑最方便的算。

LARC: 何时非完整系统可控?

Lie Algebra Rank Condition: 若控制向量场 $X_1, \dots, X_k$ 及它们的迭代李括号 $[X_i, X_j], [X_i, [X_j, X_k]], \dots$ 在每点张成整个切空间, 则系统局部可控。

LARC: 控制向量场 + 它们的李括号张成每点切空间 $\implies$ 局部可控。

小车: $\{X_1, X_2, [X_2, X_1]\}$ 张成 3 维 $= \dim SE(2)$, 故可控。”控制维度看起来不够” 但通过李括号补全——非完整机器人可达性的核心机理。

对本讲义的意义

为什么在优化讲义里讲李群?

1. **正交群与 Stiefel 的” 切空间反对称” 条件就是李代数。** 我们刚证过 $T_I O(n) = \{A : A^\top + A = 0\} = \mathfrak{o}(n)$ 。 $T_W O(n)$ 由” 左不变” 地搬运得到: $T_W O(n) = W \cdot \mathfrak{o}(n)$, 即 $\Delta = WA$ 当 A 反对称。这正是 §8 里 $W^\top \Phi$ 反对称条件的群论解释。

由此正交群 Muon 的更新方向

$$\Phi^* = W \cdot \text{msign}([W^\top G]_{\text{skew}})$$

有了清晰的几何含义: 先把欧氏梯度 G ”拉回到” 李代数 $\mathfrak{o}(n)$ 中 (取 skew 部分), 在李代数里做 **Muon** (对反对称矩阵做 msign), 再左乘 W 把方向”搬到” W 处。

2. $\exp$ 是李群上的”标准”回缩。对 $A \in \mathfrak{o}(n)$, 矩阵指数 $\exp(A) \in O(n)$ 严格位于群上。所以 $W \exp(\eta \Phi^*)$ 严格保正交, 比 msign 类回缩在数学上更”正确”(沿测地线走), 但矩阵指数计算上更贵。实践中常用 Cayley 变换 $\exp(A) \approx (I - A/2)^{-1}(I + A/2)$ 作为近似回缩。

3. $\mathfrak{so}(3) \cong \mathbb{R}^3$ 与叉积。 3×3 反对称矩阵与 $\mathbb{R}^3$ 一一对应: $\hat{\omega} \leftrightarrow \omega$ 。李括号

$$[\hat{\omega}_1, \hat{\omega}_2] = \widehat{\omega_1 \times \omega_2}$$

正是叉积——这是 SLAM、IMU 融合、SO(3) 等变神经网络里所有”小角度近似”公式的代数源头。

一句话总结: 流形上做优化时, **有群结构就用群结构**——它把切空间的几何复杂性外包给固定的线性空间(李代数), 让我们在线性空间里做计算(取 skew、做 msign 、做 SVD), 再用 $\exp$ 或左乘把结果搬到当前点。这是 $O(n)$ 上 Muon 比一般流形上的 Stiefel Muon 干净许多的根本原因。

3.4 测地线与测地线距离

测地线 (geodesic) 是流形上”最短”且”最直”的曲线, 可以视为欧氏直线在流形上的推广。形式上, 测地线是加速度始终垂直于流形的曲线。

测地线距离 (geodesic distance) $d_g(p, q)$ 是流形上 p, q 两点之间最短测地线的长度。

例子 3.7 (球面上的测地线): 单位球面上, 两点之间的测地线是过球心的大圆弧。两点 p, q 之间的测地线距离是 $d_g(p, q) = \arccos(\langle p, q \rangle)$, 而欧氏距离是 $\|p - q\|_2 = \sqrt{2 - 2\langle p, q \rangle}$ 。两者在 $p \approx q$ 时一致 ($d_g \approx \|p - q\|_2$), 但在远距离时差别显著: 地球南极到北极的测地线距离是 πR , 欧氏距离是 $2R$ 。

这给出一个重要事实: **在流形上, 欧氏距离仅在局部可信; 远距离要用测地线距离**。这点在很多机器学习场景下都重要。

3.5 测地线方程: Lagrangian 推导

测地线”最短”和”最直”是同一件事吗? 要把这两件事在数学上统一, 自然的工具是**变分法**。这正是把 min-action 原理(讲义主线)从离散步推广到连续轨迹的版本。

弧长泛函与能量泛函

设 $\mathcal{M}$ 配有 Riemann 度量 $g_{ij}(x)$ (每点切空间上的内积, 依赖于点的光滑函数)。一条曲线 $\gamma: [0, T] \rightarrow \mathcal{M}$, 用坐标记 $\gamma(t) = (x^1(t), \dots, x^n(t))$ 。两个候选泛函:

弧长 (”最短”):

$$L[\gamma] = \int_0^T \sqrt{g_{ij}(\gamma) \dot{x}^i \dot{x}^j} dt.$$

能量 (”最直 + 匀速”):

$$E[\gamma] = \int_0^T \frac{1}{2} g_{ij}(\gamma) \dot{x}^i \dot{x}^j dt.$$

二者关系: 由柯西不等式 $L[\gamma]^2 \leq 2T \cdot E[\gamma]$, 等号当且仅当 $\sqrt{g_{ij} \dot{x}^i \dot{x}^j} = \text{常数}$ (即**弧长参数化**)。所以

minimizing $E \iff$ minimizing L 在弧长参数下.

E 比 L 更友好——光滑、无平方根、极小子自动是匀速参数化的。下面对 E 做变分。

Euler–Lagrange 方程

Lagrangian $\mathcal{L}(x, \dot{x}) = \frac{1}{2}g_{ij}(x)\dot{x}^i\dot{x}^j$ 。Euler–Lagrange 方程 $\frac{d}{dt}\left(\frac{\partial\mathcal{L}}{\partial\dot{x}^k}\right) = \frac{\partial\mathcal{L}}{\partial x^k}$ 算下来：

$\partial\mathcal{L}/\partial\dot{x}^k = g_{kj}\dot{x}^j$ ， d/dt 后 $= (\partial_l g_{kj})\dot{x}^l\dot{x}^j + g_{kj}\ddot{x}^j$ ； $\partial\mathcal{L}/\partial x^k = \frac{1}{2}(\partial_k g_{ij})\dot{x}^i\dot{x}^j$ 。合并并对哑标对称化：

$$g_{kj}\ddot{x}^j + \frac{1}{2}(\partial_l g_{kj} + \partial_j g_{kl} - \partial_k g_{lj})\dot{x}^l\dot{x}^j = 0.$$

两侧乘逆度量 g^{km} 求和，得到**测地线方程**：

$$\ddot{x}^m + \Gamma_{lj}^m \dot{x}^l \dot{x}^j = 0 \quad (9)$$

其中 **Christoffel 符号**

$$\Gamma_{lj}^m = \frac{1}{2}g^{mk}(\partial_l g_{kj} + \partial_j g_{kl} - \partial_k g_{lj}). \quad (10)$$

物理直觉：协变加速度等于零

测地线方程的形式

$$\underbrace{\ddot{x}^m}_{\text{普通加速度}} + \underbrace{\Gamma_{lj}^m \dot{x}^l \dot{x}^j}_{\text{曲率修正}} = 0$$

有清晰的力学解读。在欧氏空间，“匀速直线运动” $= \ddot{x} = 0$ 。但在弯曲流形上，普通的 $\ddot{x}$ 不再是协变量——换坐标后会冒出 Γ 项。要写出一个真正“沿流形匀速直行”的方程，必须用**协变加速度**：

$$\frac{D\dot{x}^m}{Dt} := \ddot{x}^m + \Gamma_{lj}^m \dot{x}^l \dot{x}^j.$$

测地线就是协变加速度恒为零的曲线——在内蕴几何看来“不加速”。Christoffel 符号编码了流形的弯曲信息：它告诉我们“看起来加速、实际上是直走”和“真的在加速”之间的差额。

算例：球面 S^2 上的测地线方程

用球坐标 (θ, ϕ) ， $\theta \in [0, \pi]$ 极角、 $\phi \in [0, 2\pi)$ 方位角， $\mathbb{R}^3$ 嵌入 $(\sin\theta\cos\phi, \sin\theta\sin\phi, \cos\theta)$ 。诱导度量

$$ds^2 = d\theta^2 + \sin^2\theta d\phi^2, \quad g = \begin{pmatrix} 1 & 0 \\ 0 & \sin^2\theta \end{pmatrix}.$$

Lagrangian: $\mathcal{L} = \frac{1}{2}(\dot{\theta}^2 + \sin^2\theta\dot{\phi}^2)$ 。

对 θ 的 E–L: $\frac{d}{dt}\dot{\theta} - \sin\theta\cos\theta\dot{\phi}^2 = 0 \implies \boxed{\ddot{\theta} = \sin\theta\cos\theta\dot{\phi}^2}$ 。

对 ϕ 的 E–L: $\mathcal{L}$ 不显含 ϕ ，故 $\partial\mathcal{L}/\partial\phi = \sin^2\theta\dot{\phi}$ 守恒：

$$\boxed{\sin^2\theta\dot{\phi} = J \text{ (常数)}}$$

(绕极轴的“角动量”——Noether 守恒量)。

由 (10) 直接算 Christoffel 符号也得到一样的结果（用 SymPy 符号验过）：

$$\Gamma_{\phi\phi}^\theta = -\sin\theta\cos\theta, \quad \Gamma_{\theta\phi}^\phi = \Gamma_{\phi\theta}^\phi = \cot\theta, \quad \text{其余为零}.$$

验证赤道是测地线：取 $\theta(t) \equiv \pi/2$ ， $\phi(t) = \omega t$ 。

- θ 方程： $0 = \sin(\pi/2)\cos(\pi/2) \cdot \omega^2 = 0$
- ϕ 方程： $\sin^2(\pi/2) \cdot \omega = \omega = \text{常数}$

由球面对称性，所有大圆都是测地线（绕任意过球心的轴匀速旋转）。

算例：两个具体点的测地线距离

取 S^2 上两点 $p = (\theta_1, \phi_1) = (\pi/4, 0)$, $q = (\theta_2, \phi_2) = (\pi/4, \pi/2)$ 。

球面距离公式：

$$\begin{aligned}\cos d_g(p, q) &= \cos \theta_1 \cos \theta_2 + \sin \theta_1 \sin \theta_2 \cos(\phi_1 - \phi_2) \\ &= \cos^2(\frac{\pi}{4}) + \sin^2(\frac{\pi}{4}) \cos(-\frac{\pi}{2}) = \frac{1}{2} + \frac{1}{2} \cdot 0 = \frac{1}{2}.\end{aligned}$$

所以 $d_g = \arccos(1/2) = \pi/3 \approx 1.047$ 。

对比欧氏距离： $\mathbb{R}^3$ 中 $p = (\frac{\sqrt{2}}{2}, 0, \frac{\sqrt{2}}{2})$, $q = (0, \frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2})$; $\|p - q\|_2 = \sqrt{\frac{1}{2} + \frac{1}{2} + 0} = 1$ 。 **校验：**球面上 $\|p - q\|_2 = 2 \sin(d_g/2) = 2 \sin(\pi/6) = 1$ 。

d_g/d_{euc} 比值：

两点夹角 d_g	d_g (弧度)	d_{euc}	比值
$60^\circ (\pi/3)$	1.047	1.000	1.047
$90^\circ (\pi/2)$	1.571	$\sqrt{2} \approx 1.414$	1.111
180° (对径)	$\pi \approx 3.142$	2	1.571

小角度差不多，对径处差 $\pi/2 \approx 57\%$ ——”局部欧氏，全局非欧”的具体定量。

与本讲义主线的连接

本子节这套 $\min E[\gamma]$ 推导跟讲义主线的 min-action 完全是同一件事：

	连续时间 (本子节)	离散步 (讲义主线)
目标	$\min \int \frac{1}{2} \ \dot{\gamma}\ _g^2 dt$	$\min L(W + \Delta W)$
约束	端点 $\gamma(0) = p, \gamma(T) = q$	$\rho(\Delta W) \leq \eta$
解	测地线方程 (9)	$\Phi^* = \text{msign}(\cdot)$ 等
范数	度量 g_{ij}	范数 ρ

具体地，第五讲的 baseline $x_{k+1} = \mathcal{R}_{x_k}(-\eta \text{grad } f(x_k))$ 当 $\eta \rightarrow 0$ 、 $\mathcal{R} = \exp_x$ 时，连续极限是

$$\dot{\gamma}(t) = -\text{grad } f(\gamma(t)),$$

即”沿测地线流的梯度下降”。**Riemannian SGD** 在 $\eta \rightarrow 0$ 极限下的轨迹，恰好满足测地线方程加上一个”被损失梯度推着”的强迫项。所以测地线方程不只是几何里的一个对象——它是所有 *Riemannian* 优化算法的连续时间极限。

3.6 应用：语义嵌入空间的测地线距离


下面是一个具体的应用例子，来自无监督摘要研究 [4]。

背景：用对比学习训练得到的句向量 $v(t)$ ，欧氏（或余弦）距离 $d(v(t_1), v(t_2))$ 在两句话语义相近时比较准确，但在语义差异较大时往往不可靠：训练时所有”负样本对”都被打上同一标签”负”，无论它们是精挑的难样本还是随机两句不相关的话，于是模型对远距离区域的排序能力没什么保证。

后果：句子检索（要求召回相似度高的样本）效果尚可；但”句子 vs 主题”摘要类任务，要在较远的距离区间做相对排序，简单距离就不够用了。

思路：用流形假设——这些向量分布在某个低维流形上，欧氏距离仅局部可信。把它扩展为测地线距离即可。具体做法：

1. 对每个点 v_i ，找它在欧氏距离下最近的 k 个点（或按阈值），构造 k -邻近图。
2. 边权重为该局部欧氏距离。
3. 用 Dijkstra 算法求图上任意两点的最短路径，把路径长度作为测地线距离的近似。



注记 3.8 (与 Isomap 的关系): 这正是经典降维方法 Isomap 的核心思想: 先用 k -NN 图近似测地线距离, 再用 MDS 把它嵌入低维欧氏空间。在我们的场景下不做嵌入, 仅用测地线距离做排序。

3.7 回缩 (retraction)

最后是优化里最实用的概念: **回缩**是把切向量 (或附近一点) 映回流形的运算。形式上, $R_W : T_W \mathcal{M} \rightarrow \mathcal{M}$ 满足 $R_W(0) = W$ 且 $\frac{d}{dt} R_W(t\xi)|_{t=0} = \xi$ 。

例子 3.9 (球面上的回缩): 最简单的回缩是归一化: $R_w(\varphi) = (w + \varphi) / \|w + \varphi\|$ 。比指数映射 $\exp_w(\varphi)$ 便宜得多, 且在 φ 较小时与之吻合到一阶。

例子 3.10 (正交群上的回缩): QR 分解或 msign 都是常用回缩: 把 $W + \Delta$ 投影到离它最近的正交矩阵。

统一的优化策略: 先在切空间内找最速下降方向 φ^* (这是后面几讲的主题), 再用回缩 $W \leftarrow R_W(-\eta\varphi^*)$ 更新参数。

4 第三讲: 矩阵参数与谱范数——Muon 优化器

4.1 矩阵参数的”自然”度量

设 $W \in \mathbb{R}^{n \times m}$ ($n \geq m$) 是线性层权重, $G = \nabla_W L$ 。若 ρ 取 Frobenius 范数 (即把矩阵当向量), 最速下降仍是 $\Phi = G / \|G\|_F$, 本质上仍是 SGD。但 Frobenius 范数不”看见”矩阵的奇异值结构。

谱范数 $\|W\|_2 = \sigma_{\max}(W)$ 才是描述线性层放大率最紧的范数: 对任意输入 x , $\|Wx\|_2 \leq \|W\|_2 \|x\|_2$ 。所以谱范数是矩阵”稳定性”的天然度量。

4.2 谱范数约束下的最速下降: Muon

考虑:

$$\max_{\Phi} \operatorname{tr}(G^\top \Phi) \quad \text{s.t.} \quad \|\Phi\|_2 = 1 \quad (11)$$

设 $G = \sum_{i=1}^r \sigma_i u_i v_i^\top = U \Sigma V^\top$ 为 SVD, $r = \operatorname{rank}(G)$ 。这是问题的核心: 要回答这个问题, 需要先把”谱范数与核范数对偶”这件事讲透——它是后面所有 Muon 类推导的基石。

第一层: 从 Hölder 到 Schatten 范数

回忆向量 L^p 范数的 Hölder 不等式:

$$\sum_i a_i b_i \leq \|a\|_p \|b\|_q, \quad \frac{1}{p} + \frac{1}{q} = 1.$$

两个特殊情形:

- $p = q = 2$: Cauchy–Schwarz, L^2 自对偶。
- $p = 1, q = \infty$: $\sum a_i b_i \leq \|a\|_1 \|b\|_\infty$, 即 L^1 与 L^∞ 互为对偶。

矩阵情形把”奇异值”当成”向量”，这就得到 **Schatten p -范数**：

$$\|A\|_{S_p} := \left(\sum_i \sigma_i(A)^p \right)^{1/p}.$$

特别地：

- $p = 2$: $\|A\|_{S_2} = \sqrt{\sum_i \sigma_i^2} = \|A\|_F$ (**Frobenius 范数**)，自对偶。
- $p = 1$: $\|A\|_{S_1} = \sum_i \sigma_i = \|A\|_*$ (**核范数**)。
- $p = \infty$: $\|A\|_{S_\infty} = \sigma_1 = \|A\|_2$ (**谱范数**)。

矩阵版 Hölder 不等式 (von Neumann 迹不等式的推论)：

$$\boxed{\operatorname{tr}(A^\top B) \leq \sum_i \sigma_i(A) \sigma_i(B) \leq \|A\|_{S_p} \|B\|_{S_q}, \quad \frac{1}{p} + \frac{1}{q} = 1.} \quad (12)$$

对 $p = \infty, q = 1$ ，这就是**核-谱对偶**： $\operatorname{tr}(A^\top B) \leq \|A\|_* \|B\|_2$ 。

第二层：等号成立条件——Procrustes 配对

Hölder 不等式中第一步等号 $\operatorname{tr}(A^\top B) = \sum_i \sigma_i(A) \sigma_i(B)$ 需要 A 与 B 共享奇异向量 (同一组 u_i, v_i)；第二步等号需要奇异值序列匹配。对 $\|B\|_2 \leq 1$ 的约束，这意味着 B 的奇异值都 ≤ 1 ，等号要 $\sigma_i(B) = 1$ for $i \leq r$ ，即 $B = \sum_i u_i v_i^\top = UV^\top = \operatorname{msign}(A)$ 。

把这件事写成正式引理：

引理 4.1 (谱-核范数对偶)： 对任意 Φ 满足 $\|\Phi\|_2 \leq 1$,

$$\operatorname{tr}(G^\top \Phi) \leq \|G\|_* = \sum_i \sigma_i(G),$$

等号成立 $\iff \Phi = \operatorname{msign}(G) = \sum_{i=1}^r u_i v_i^\top$ (精简 SVD)。

初等证明. $\operatorname{tr}(G^\top \Phi) = \sum_i \sigma_i u_i^\top \Phi v_i$ 。由谱范数定义，对单位向量 v_i 有 $\|\Phi v_i\|_2 \leq \|\Phi\|_2 \leq 1$ ，于是 $u_i^\top \Phi v_i \leq \|u_i\| \|\Phi v_i\| \leq 1$ 。求和得 $\operatorname{tr}(G^\top \Phi) \leq \sum_i \sigma_i$ 。等号需要每个 $u_i^\top \Phi v_i = 1$ ，由 Cauchy-Schwarz 等号条件 $\Phi v_i = u_i$ ，即 $\Phi = UV^\top$ 在 G 的 range 上的作用唯一确定为 $\operatorname{msign}(G)$ 。□ □

第三层：具体算例——数值上看对偶到底有多紧

把上面” $\operatorname{tr}(G^\top \Phi) \leq \|G\|_*$ 当 $\|\Phi\|_2 \leq 1$ ” 在一个具体矩阵上跑一遍。

例子 4.2 (谱-核对偶的多 Φ 实测)： 取 $G = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$ (与例 4.4 同)，奇异值 $\sigma_1 = 3, \sigma_2 = 1$ ，所以

$$\|G\|_2 = 3, \quad \|G\|_F = \sqrt{10} \approx 3.162, \quad \|G\|_* = 4.$$

对偶引理给出的上界是 $\|G\|_* = 4$ 。下面尝试不同的 Φ ：

Φ 的选择	$\ \Phi\ _2$	$\operatorname{tr}(G^\top \Phi)$
I (单位阵)	1	$\operatorname{tr}(G) = 2$
$\operatorname{msign}(G) = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$	1	$4 = \ G\ _*$
$u_1 v_1^\top$ (仅顶秩 1 部分)	1	$\sigma_1 = 3$
随机 $\ \Phi\ _2 = 1$	1	2.46 (依种子)
$G/\ G\ _F$ (Frob 最优方向)	$\sigma_1/\ G\ _F = 0.949$	$\ G\ _F = 3.162$

解读：

- 单位阵 I 谱范数 = 1 但远未把 G 的能量”吃满”——只拿到 2。
- $\text{msign}(G)$ 唯一地达到上界 4。
- 仅取顶秩 1 部分 $u_1 v_1^\top$ 拿到 $\sigma_1 = 3$ (损失了 $\sigma_2 = 1$)。
- Frobenius 方向 $G/\|G\|_F$ 给出 $\|G\|_F$, 比 $\|G\|_*$ 严格小 (因为 $\sqrt{\sum \sigma_i^2} \leq \sum \sigma_i$ 当奇异值非负)。
- 谱范数没用满 (只有 0.949) 的 Φ 也可以带来不错的内积——但永远 $\leq \|G\|_*$ 。

数值告诉我们： 在 $\|\Phi\|_2 \leq 1$ 这一约束下， $\text{msign}(G)$ 是¹填满谱-核对偶上界的方向。这个事实是 Muon 优化器全部直觉的来源。

第四层：几何理解

把 Φ 看成谱单位球 $\{\Phi : \|\Phi\|_2 \leq 1\}$ 内的”方向”。这个集合在 $\mathbb{R}^{n \times m}$ 中是凸但非光滑的——它的”边界”是 $\{\|\Phi\|_2 = 1\}$ ，在 $\sigma_1 = \sigma_2$ 处有”棱”。线性目标 $\text{tr}(G^\top \Phi)$ 在此凸集上的最大值在边界（极点）取得，那些极点正是半正交矩阵（奇异值都是 0 或 1）。在所有半正交矩阵中， $\text{msign}(G)$ 是与 G ”同奇异向量”的那一个，所以它最大化内积。

有了这个对偶引理：

定义 4.3 (msign 算子)：对 $G = U\Sigma V^\top$ (精简 SVD, Σ 严格正)， $\text{msign}(G) := UV^\top = G(G^\top G)^{-1/2}$ ，即把 G 的所有非零奇异值替换为 1。 $\text{msign}(G)$ 也是离 G 最近的（半）正交矩阵 (Procrustes 问题的解)。

由引理 4.1，问题 (11) 的最优解为

$$\Phi^* = \text{msign}(G) \quad (13)$$

这就是 Muon 优化器的核心更新方向。

4.3 msign 的具体算例

例子 4.4 (msign 的逐步计算)：取

$$G = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}.$$

第 1 步：算 $G^\top G$ 。 $G^\top G = \begin{pmatrix} 5 & 4 \\ 4 & 5 \end{pmatrix}$ 。

第 2 步：特征分解。 特征值 $\lambda_1 = 9, \lambda_2 = 1$ ，对应的单位特征向量 $v_1 = \frac{1}{\sqrt{2}}(1, 1)^\top$ ， $v_2 = \frac{1}{\sqrt{2}}(1, -1)^\top$ 。故奇异值 $\sigma_1 = 3, \sigma_2 = 1$ 。

第 3 步：算左奇异向量。 $u_1 = Gv_1/\sigma_1 = \frac{1}{\sqrt{2}}(1, 1)^\top$ ， $u_2 = Gv_2/\sigma_2 = \frac{1}{\sqrt{2}}(-1, 1)^\top$ 。

第 4 步：组装。

$$\text{msign}(G) = u_1 v_1^\top + u_2 v_2^\top = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} + \frac{1}{2} \begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

直观感受： msign 把 G 替换为离它最近的正交矩阵——这里恰好是个置换矩阵。

验证： $\text{msign}(G)$ 是正交的 (列向量正交且单位长)，且 $\text{tr}(G^\top \text{msign}(G)) = 1 \cdot 0 + 2 \cdot 1 + 2 \cdot 1 + 1 \cdot 0 = 4 = \sigma_1 + \sigma_2 = \|G\|_*$ ，与引理 4.1 吻合。

¹当奇异值有重根时存在 $UV^\top$ 的”自由旋转”。

例子 4.5 (非方阵情形): 取 $G = \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{pmatrix} \in \mathbb{R}^{3 \times 2}$ 。 $G^\top G = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}$, 奇异值 $\sigma_1 = \sqrt{2}, \sigma_2 = 1$ 。
可算

$$\text{msign}(G) = \begin{pmatrix} 1/\sqrt{2} & 0 \\ 1/\sqrt{2} & 0 \\ 0 & 1 \end{pmatrix}.$$

两列正交且各自单位长——这正是**半正交 (Stiefel) 矩阵**。

4.4 Newton–Schulz 迭代实现 msign

实践中不调用 SVD (昂贵且不利于并行)。Newton–Schulz 迭代取一个多项式 p , 递推 $X_{k+1} = p(X_k)$ 作用在奇异值上把它们逐步压向 1。

经典版: $p(x) = \frac{3}{2}x - \frac{1}{2}x^3$

写成矩阵形式:

$$X_0 = G/\|G\|_F, \quad X_{k+1} = \frac{3}{2}X_k - \frac{1}{2}X_k X_k^\top X_k. \quad (14)$$

该多项式的关键性质:

- $p(1) = 1$, 且 $p'(1) = 0$ ——1 是吸引不动点, 二次收敛。
- $p(s) - 1 = -\frac{1}{2}(s-1)^2(s+2)$ 。对 $s \in (0, 1]$, $p(s) \leq 1$ 且 $|p(s) - 1| \sim \frac{3}{2}(1-s)^2$ 。
- 选 $X_0 = G/\|G\|_F$ 保证所有奇异值落在 $(0, 1]$ (因 $\|G\|_F \geq \|G\|_2 = \sigma_{\max}$)。

例子 4.6 (Newton–Schulz 收敛轨迹): 取 $G = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}$, $\|G\|_F = \sqrt{15} \approx 3.873$, 奇异值 $\sigma_1 \approx 3.618, \sigma_2 \approx 1.382$ 。

$X_0 = G/\|G\|_F$ 的奇异值是 (0.934, 0.357)。每步迭代后:

k	$\sigma_1(X_k)$	$\sigma_2(X_k)$	离 $\text{msign}(G)$ 的距离
0	0.9342	0.3568	—
1	0.9936	0.5125	—
2	0.99994	0.7015	—
3	1.000	0.8796	—
4	1.000	0.9791	—
5	1.000	0.99935	—
6	1.000	0.9999993	—
7	1.000	1.000	$\sim 10^{-16}$

观察:

- σ_1 (已接近 1) 二步内就被钉到 1.000, 二次收敛的特征。
- σ_2 (初值更小, 约 0.36) 需要更多步数走到 1, 但每步距离误差近似平方。
- 全部完成在 7 步内达到机器精度。

最终的矩阵 X_7 与真正的 $\text{msign}(G) = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ (恰好是单位阵, 因 G 正定) 误差 $\sim 10^{-16}$ 。

Muon 用的”快速版” $p(x) = ax + bx^3 + cx^5$

实际 Muon 实现中用五次多项式系数 $(a, b, c) = (3.4445, -4.7750, 2.0315)$ ，迭代格式为

$$X_{k+1} = aX_k + bX_kX_k^\top X_k + c(X_kX_k^\top)^2 X_k. \quad (15)$$

这组系数针对**低精度 (BF16/FP16)** 做过专门调优——它不是让 1 成为不动点，而是让多项式在 5–6 步迭代后把 $[0, 1.5]$ 区间内的奇异值都压到接近 1 的小窗口内 ($\approx [0.7, 1.3]$)，再让后续工作于 BF16 中保持稳定。代价：损失了二次收敛，但增益是在**低精度下不会震荡发散**。

注记 4.7 (实践口径)：课堂演示用经典的 (14) 即可 (FP32 下)，对应代码两行；上线训练 GPT-2/LLaMA 类模型用 (15) (BF16 下)，具体代码见第 12 讲。

注记 4.8 (与 Polar Express 等的联系)：msign 即矩阵的 polar factor 中的正交因子；Newton-Schulz 是有理逼近 sign 函数。Polar Express、DAWN 等近期二阶优化器在不同程度上利用了类似的 polar/谱分解结构，区别在于多项式选择与是否对头-尾谱分别处理。

5 第四讲：流形约束下的统一推导原则

下面给参数 W 也施加流形约束 $\mathcal{M}(W) = 0$ 。

统一推导套路

1. **原问题**： $\rho(\Phi) = 1$ 、 $\mathcal{M}(W) = 0$ 、 $\mathcal{M}(W - \eta\Phi) = 0$ 三约束下，最大化 $\text{tr}(G^\top \Phi)$ 。
2. **一阶近似**：把 $\mathcal{M}(W - \eta\Phi) = 0$ 用一阶 Taylor 展开成关于 Φ 的线性约束 $\langle T(W), \Phi \rangle = 0$ ，几何上即切空间 $T_W \mathcal{M}$ 。
3. **待定系数**：通过 Lagrange 乘子 λ 把切空间约束并入目标，化为无约束的范数对偶问题。
4. **解析或迭代求解**：根据范数选择，写出 $\Phi^* = \text{msign}(\cdot)$ 或类似形式；剩下的乘子通过解析解、不动点迭代或对偶梯度下降求得。
5. **回缩 (retraction)**：因仅准确到 $O(\eta^2)$ ，每步还需把 $W - \eta\Phi$ 拉回流形。

下面五讲依次落到具体场景。**第五讲先讲最朴素的 Riemannian SGD workflow (投影 + 回缩) 作为 baseline**，第六到第九讲再用 min-action 框架升级它 (不同 ρ 、不同流形)。

6 第五讲：Riemannian 视角——投影梯度 + 回缩

进入 Muon 类的精细推导之前，先把”流形上做梯度下降”最朴素的工作流走一遍。这个流程是后面所有讨论的基础——min-action 原理可以视为它的”换范数升级版”。

6.1 标准三步

设 $f: \mathcal{M} \rightarrow \mathbb{R}$ 是嵌入流形 $\mathcal{M} \subset \mathbb{R}^N$ 上的损失：

1. **算欧氏梯度** $\nabla f(x) \in \mathbb{R}^N$ (不考虑约束)。
2. **投影到切空间**： $\text{grad}_{\mathcal{M}} f(x) := \text{Proj}_{T_x \mathcal{M}}(\nabla f(x))$ 。
3. **走一步 + 回缩**： $x_{k+1} = \mathcal{R}_{x_k}(-\eta \text{grad}_{\mathcal{M}} f(x_k))$ 。

下面用两个完整的数值算例把每一步走通。

6.2 例子 A：球面上的相机朝向优化

设机器人相机朝向 $n \in S^2$ ，目标方向 $d = (0, 1, 0)^\top$ ，初值 $n_0 = (1, 0, 0)^\top$ （相机现朝 x ，目标在 y ）。损失：

$$f(n) = \frac{1}{2} \|n - d\|^2.$$

Step 1：算欧氏梯度。 $\nabla f(n) = n - d$ 。在 n_0 ：

$$\nabla f(n_0) = (1, -1, 0)^\top.$$

反例：直接欧氏 SGD 跑出流形。 取 $\eta = 0.5$ ：

$$\tilde{n} = n_0 - \eta \nabla f(n_0) = (0.5, 0.5, 0)^\top, \quad \|\tilde{n}\| = \sqrt{0.5} \neq 1.$$

$\tilde{n} \notin S^2$ ！这就是为什么必须做切空间投影 + 回缩。

Step 2：投影到切空间。 切空间 $T_{n_0}S^2 = \{v : n_0^\top v = 0\}$ 。投影矩阵

$$P = I - n_0 n_0^\top = \text{diag}(0, 1, 1).$$

所以

$$\text{grad}_{S^2} f(n_0) = P \nabla f(n_0) = (0, -1, 0)^\top.$$

x 分量被消掉——确实在切空间内 ($n_0^\top \text{grad}_{S^2} f = 0$)。

Step 3：走一步 + 回缩（这里用归一化）。 $\mathcal{R}_n(v) = (n + v) / \|n + v\|$ 。

$$\tilde{n} = n_0 - 0.5 \cdot (0, -1, 0)^\top = (1, 0.5, 0)^\top, \quad \|\tilde{n}\| = \sqrt{1.25} \approx 1.118,$$

$$n_1 = \tilde{n} / \|\tilde{n}\| \approx (0.894, 0.447, 0)^\top.$$

$\|n_1\| = 1$ ，方向已从 x 朝 y 转过去。

6.3 KKT 与切空间投影的等价

为什么“投影到切空间”是对的？回到约束优化：

$$\min f(n) \quad \text{s.t.} \quad n^\top n = 1.$$

拉格朗日函数 $L(n, \lambda) = f(n) + \frac{\lambda}{2}(n^\top n - 1)$ ，一阶条件

$$\nabla f(n) + \lambda n = 0 \iff \nabla f(n) \text{ 沿 } n \text{ 方向}.$$

两侧投影到切空间（用 $Pn = 0$ ）： $P\nabla f(n) = 0$ ，即**流形梯度为零**。

约束优化的一阶 KKT 条件 $\iff$ 切空间投影梯度为零 $\iff$ 流形梯度为零。

这跟第三、第七、第八讲的 min-action Lagrange 推导是**同一件事的不同包装**——切空间方程的左端 = 流形梯度的展开形式。

6.4 例子 B：SO(3) 上的姿态控制

把球面例子升级到完整姿态。令机器人当前姿态 $R \in SO(3)$ ，目标 $R_d \in SO(3)$ ，损失

$$f(R) = \frac{1}{2} \|R - R_d\|_F^2.$$

Step 1（欧氏梯度）： $\nabla f(R) = R - R_d$ 。

Step 2（投影到 $T_R SO(3)$ ）： 由 §3.3, $T_R SO(3) = R \cdot \mathfrak{so}(3)$ ，即合法切向必须形如 $R\hat{\omega}$ ($\hat{\omega}$ 反对称)。在 Frobenius 度量下投影公式为

$$\text{grad}_{SO(3)} f(R) = R \cdot \text{skew}(R^\top \nabla f(R)) = R \cdot \text{skew}(I - R^\top R_d) = -R \cdot \text{skew}(R^\top R_d).$$

其中 $\text{skew}(A) := \frac{1}{2}(A - A^\top)$ 。

Step 3 (用 exp 回缩): $R_{k+1} = R_k \exp(-\eta R_k^{-1} \text{grad}_{SO(3)} f(R_k))$ 。

数值算例: $R_0 = I$, 目标 R_d 为绕 z 轴 90° 。

$$R_d = \begin{pmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

欧氏梯度:

$$\nabla f(I) = I - R_d = \begin{pmatrix} 1 & 1 & 0 \\ -1 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}.$$

这不是反对称的! 如果直接走 $-\eta \nabla f$ 就跑出 $SO(3)$ 。

投影 ($R = I$ 时简化为 $\text{skew}(\cdot)$):

$$\text{grad}_{SO(3)} f(I) = \text{skew}(I - R_d) = \frac{1}{2}[(I - R_d) - (I - R_d)^\top] = \begin{pmatrix} 0 & 1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}.$$

用 $\hat{\omega}$ 与 $\omega \in \mathbb{R}^3$ 的对应 ($\mathfrak{so}(3) \cong \mathbb{R}^3$, 见 §3.3), 上式对应 $\omega_{\text{grad}} = (0, 0, -1)^\top$ 。所以下降方向 $-\text{grad}_{SO(3)} f(I)$ 对应 $\omega = (0, 0, +1)^\top$, 即”绕 z 轴正方向旋转”——与目标 $R_d = R_z(90^\circ)$ 完全一致。

回缩用矩阵指数。取 $\eta = \pi/4$:

$$R_1 = R_0 \exp(-\eta \text{grad}_{SO(3)} f(I)) = \exp\left(\frac{\pi}{4} \begin{pmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}\right) = \begin{pmatrix} 0.707 & -0.707 & 0 \\ 0.707 & 0.707 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

即 $R_1 = R_z(45^\circ)$ ——朝目标 $R_z(90^\circ)$ 走了一半, 且 $R_1^\top R_1 = I$ 。损失 $\|R_1 - R_d\|_F = 1.08$, 比初始 $\|R_0 - R_d\|_F = 2.00$ 减半左右。

6.5 与本讲义主线的关系

这套”投影 + 回缩”是 Riemannian SGD 的最简形式, 对应 min-action 框架下取

$$\rho = \|\cdot\|_F \quad (\text{Frobenius 范数})$$

的解。讲义后面把 ρ 换成更”几何”的范数, 得到一系列升级:

- **第六讲 (球面 SGD):** min-action 框架重新推导 §6.2, 证明 $\rho = L^2$ 时与”投影 + 归一化”完全等价;
- **第七讲 (正交方阵 Muon):** 把 ρ 换成谱范数, 得到

$$\Phi^* = W \text{msign}([W^\top G]_{\text{skew}}).$$

形式上跟本讲 $SO(3)$ 的 $-R \cdot \text{skew}(R^\top R_d)$ 几乎一样, 差别只是多了一步 msign ——把 skew 部分的奇异值都压成 1, 得到”几何上更均匀”的下降方向;

- **第八讲 (Stiefel):** W 非方阵, 闭式解失效, 需不动点迭代或对偶 GD;
- **第九讲 (谱球面):** 另一种参数约束。

核心信息: 所有这些算法共享”投影 + 回缩”的骨架; 不同的 ρ 选择只决定投影后那一步内部如何对方向再加工 (直接归一化、 msign 、Lyapunov 求解等)。把本讲的 baseline 装进脑子里, 后面所有公式都能视为它的”局部修饰”。

7 第六讲：超球面上的 SGD

7.1 问题表述

参数 $w \in \mathbb{R}^n$ ，约束 $\|w\|_2 = 1$ ，要求更新后仍在球面上：

$$\max_{\varphi} \langle g, \varphi \rangle \quad \text{s.t.} \quad \|\varphi\|_2 = 1, \|w\|_2 = 1, \|w - \eta\varphi\|_2 = 1. \quad (16)$$

7.2 一阶近似化简

$1 = \|w - \eta\varphi\|_2^2 = 1 - 2\eta\langle w, \varphi \rangle + \eta^2\|\varphi\|_2^2 \approx 1 - 2\eta\langle w, \varphi \rangle$ ，即 $\langle w, \varphi \rangle = 0$ (φ 在 w 的切空间内)。

7.3 待定系数求解

引入乘子 λ ： $\langle g, \varphi \rangle = \langle g + \lambda w, \varphi \rangle \leq \|g + \lambda w\|_2$ ，等号在 $\varphi \propto g + \lambda w$ 。结合 $\langle w, \varphi \rangle = 0$ 、 $\|w\|_2 = 1$ 解出 $\lambda = -\langle g, w \rangle$ ，故

$$\varphi^* = \frac{g - \langle g, w \rangle w}{\|g - \langle g, w \rangle w\|_2} \quad (17)$$

7.4 具体算例

例子 7.1 (球面 SGD 数值演算)：设 $w = (3/5, 4/5, 0)$ (验证： $9/25 + 16/25 = 1$ ，单位向量)， $g = (1, 0, 0)$ ， $\eta = 0.1$ 。


第 1 步：投影到切空间。 $\langle g, w \rangle = 3/5$ 。 $g - \langle g, w \rangle w = (1, 0, 0) - \frac{3}{5}(\frac{3}{5}, \frac{4}{5}, 0) = (\frac{16}{25}, -\frac{12}{25}, 0)$ 。

第 2 步：归一化。 模长 $= \frac{1}{25}\sqrt{16^2 + 12^2} = \frac{20}{25} = \frac{4}{5}$ 。 $\varphi^* = (\frac{16}{25}, -\frac{12}{25}, 0) \cdot \frac{5}{4} = (\frac{4}{5}, -\frac{3}{5}, 0)$ 。

第 3 步：检查。 $\langle w, \varphi^* \rangle = \frac{3}{5} \cdot \frac{4}{5} + \frac{4}{5} \cdot (-\frac{3}{5}) + 0 = 0$ (确实在切空间)。 $\|\varphi^*\|_2 = 1$ 。

第 4 步：更新与回缩。 $w' := w - \eta\varphi^* = (\frac{3}{5} - 0.08, \frac{4}{5} + 0.06, 0) = (0.52, 0.86, 0)$ 。 $\|w'\|_2 = \sqrt{0.2704 + 0.7396} = \sqrt{1.01} \approx 1.005$ ，与公式 $\sqrt{1 + \eta^2} = \sqrt{1.01}$ 完全一致。回缩后 $w \leftarrow w' / \sqrt{1.01} \approx (0.5174, 0.8557, 0)$ ，仍是单位向量。

7.5 几何意义



φ^* 即把梯度 g 投影到切空间。

8 第七讲：正交方阵流形上的 Muon

8.1 问题表述

$W \in \mathbb{R}^{n \times n}$ ， $W^\top W = WW^\top = I$ 。

$$\max_{\Phi} \text{tr}(G^\top \Phi) \quad \text{s.t.} \quad \|\Phi\|_2 = 1, W^\top W = I, (W - \eta\Phi)^\top (W - \eta\Phi) = I. \quad (18)$$

8.2 一阶近似 = 切空间条件

最后一个约束展开后，去掉 $O(\eta^2)$ 项，得 $W^\top \Phi + \Phi^\top W = 0$ ，即 $W^\top \Phi$ 是反对称矩阵——这就是 Stiefel/正交流形的切空间条件。

8.3 待定系数法

引入对称矩阵乘子 Λ ：

$$\text{tr}(G^\top \Phi) = \text{tr}((G + W(\Lambda + \Lambda^\top))^\top \Phi) \leq \|G + W(\Lambda + \Lambda^\top)\|_*.$$

记 $X = \Lambda + \Lambda^\top$ （任意对称矩阵），等号条件 $\Phi = \text{msign}(G + WX)$ 。剩下需要找到使 $W^\top \Phi$ 反对称的对称矩阵 X 。

8.4 方阵情形的闭式解

利用 msign 的两个性质：

1. 对正交方阵 W ： $W^\top \text{msign}(M) = \text{msign}(W^\top M)$ ；
2. msign 保持反对称性： M 反对称 $\Rightarrow \text{msign}(M)$ 反对称。

故 $W^\top \Phi = \text{msign}(W^\top G + X)$ 。要使其反对称，由于 X 对称，需 $W^\top G + X$ 反对称，即 $X = -[W^\top G]_{\text{sym}}$ ，其中 $[M]_{\text{sym}} := \frac{1}{2}(M + M^\top)$ 。

定理 8.1 (正交方阵流形上的 Muon)： 当 W 方阵正交时，最速下降方向为

$$\Phi^* = W \text{msign}([W^\top G]_{\text{skew}}), \quad [M]_{\text{skew}} := \frac{1}{2}(M - M^\top). \quad (19)$$

Proof. 代入 $X = -[W^\top G]_{\text{sym}}$ ： $\Phi^* = \text{msign}(G - W[W^\top G]_{\text{sym}}) = W \text{msign}(W^\top G - [W^\top G]_{\text{sym}}) = W \text{msign}([W^\top G]_{\text{skew}})$. $\square$

8.5 具体算例

例子 8.2 (2×2 旋转矩阵的 Muon 更新)： 取 $W = I$ （视作零角度旋转）、 $G = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$ 。

第 1 步：算 $W^\top G = G$ 。

第 2 步：取反对称部分。 $[G]_{\text{skew}} = \frac{1}{2}(G - G^\top) = \frac{1}{2} \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 0 & -1/2 \\ 1/2 & 0 \end{pmatrix}$ 。

第 3 步：算 msign 。 该矩阵记作 M ，则 $M^\top M = \frac{1}{4}I$ ， $(M^\top M)^{1/2} = \frac{1}{2}I$ ，故 $\text{msign}(M) = M \cdot 2 = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$ 。

第 4 步：组装。 $\Phi^* = I \cdot \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$ ，正是逆时针 90° 旋转！

解读：在正交群 $O(2)$ 上，更新方向必须是“反对称的指数 e^{tA} 在 $t=0$ 处的方向”，即“角速度方向”。所以 Φ^* 自然落到了旋转方向上。

第 5 步：更新与回缩。 $W - \eta \Phi^* = \begin{pmatrix} 1 & -\eta \\ \eta & 1 \end{pmatrix}$ 。这恰是 $\sqrt{1+\eta^2} \cdot R_\theta$ ($\tan \theta = \eta$)。除以 $\sqrt{1+\eta^2}$ 即得真正的旋转矩阵——回缩干净利落。

8.6 回缩到正交群

记 $O = \text{msign}([W^\top G]_{\text{skew}})$ (反对称矩阵)。则 $(W - \eta\Phi)^\top(W - \eta\Phi) = I + \eta^2 O^\top O$ 。当 $[W^\top G]_{\text{skew}}$ 满秩时 $O^\top O = I$, 只需除以 $\sqrt{1 + \eta^2}$; 不满秩时则更新规则要再做一次 msign (投影到正交群)。利用 $(O^\top O)^2 = O^\top O$ 可化简:

$$W \leftarrow W(I - \eta O) \left(I - O^\top O + \frac{O^\top O}{\sqrt{1 + \eta^2}} \right). \quad (20)$$

9 第八讲: Stiefel 流形上的 Muon

9.1 困难何在

设 $W \in \mathbb{R}^{n \times m}$, $n > m$ 。 $W^\top W = I_m$ 但 $WW^\top \neq I_n$, 故 $W^\top$ 无法吸收进 msign 。 X 不再有简单闭式解。 [2] 把这一情形列为 open problem。 给出两类数值算法。

9.2 方法 A: 不动点迭代

由 $\text{msign}(G + WX) = (G + WX)Q^{-1}$, $Q = ((G + WX)^\top(G + WX))^{1/2}$ 。 把切空间方程 $W^\top \Phi + \Phi^\top W = 0$ 改写后, 两侧乘 Q :

$$QX + XQ = -2[QW^\top G]_{\text{sym}} \quad (21)$$

这是关于 X 的连续型 Lyapunov 方程, Q 已知时是线性的。

迭代格式:

1. 初值 $X^{(0)} = -[W^\top G]_{\text{sym}}$ (方阵情形的解)。
2. 计算 $\Phi^{(k)} = \text{msign}(G + WX^{(k)})$, 得 $Q^{(k)} = (G + WX^{(k)})^\top \Phi^{(k)}$ 。
3. 解 (21) 得 $X^{(k+1)}$ 。
4. 收敛即停。

9.3 Lyapunov 方程的两种求解

思路 1 (mcsign): $X = \text{mcsign} \left(\begin{bmatrix} -Q & -[QW^\top G]_{\text{sym}} \\ 0 & Q \end{bmatrix} \right)_{[:m, m]}$ 其中 mcsign 是矩阵符号函数 (特征值替换为 ± 1)。 可用 Newton-Schulz 高效计算。

思路 2 (SVD): Q 正定对称, $Q = V\Sigma V^\top$ 。 (21) 变为 $\Sigma(V^\top XV) + (V^\top XV)\Sigma = -2V^\top[QW^\top G]_{\text{sym}}V$ 。 设 $S_{ij} = \sigma_i + \sigma_j$, 则 $X = -2V((V^\top[QW^\top G]_{\text{sym}}V) \oslash S)V^\top$, $\oslash$ 为 Hadamard 商。 **巧妙之处**: Q 的特征分解等价于 $G + WX$ 的 SVD, 所以一次 SVD 同时给出 $\text{msign}(G + WX)$ 和 X 。

9.4 数值算例: 4×2 Stiefel 流形

下面给出迭代法的实测运行结果。取

$$W = \begin{pmatrix} -0.627 & 0.128 \\ 0.204 & -0.594 \\ -0.334 & -0.789 \\ -0.674 & 0.092 \end{pmatrix}, \quad G = \begin{pmatrix} 0.319 & -0.249 \\ 1.462 & -2.060 \\ -0.322 & -0.384 \\ 1.134 & -1.100 \end{pmatrix}$$

(W 满足 $W^\top W = I_2$, 由对一个 4×2 标准高斯矩阵做 QR 得到)。

执行第 12 讲给出的 `muon_stiefel_svd` 函数，记每步的目标值 $\text{tr}(G^\top \Phi^{(k)})$ 与切空间残差 $\|W^\top \Phi^{(k)} + (\Phi^{(k)})^\top W\|_F$ ：

k	$\text{tr}(G^\top \Phi^{(k)})$	切空间残差
0	2.3592	1.12×10^0
1	2.4611	9.42×10^{-1}
3	2.5550	6.79×10^{-1}
5	2.7507	7.10×10^{-2}
8	2.7731	2.67×10^{-4}
10	2.7732	5.99×10^{-6}
12	2.7732	1.34×10^{-7}

观察：(1) 目标值 $\text{tr}(G^\top \Phi^{(k)})$ 严格单调上升（这正是约束最大化所期望的）；(2) 切空间残差几乎以超线性速率降至机器精度。

对比基准：

- 无约束最优： $\text{tr}(G^\top \text{msign}(G)) = \|G\|_* = 3.5541$ （不满足切空间约束）。
- 初值（方阵闭式解照搬到非方阵）：2.3592，比真正约束最优低约 15%。
- 迭代收敛值：2.7732。

非方阵 Stiefel 与方阵正交的差距正在于此——闭式解不再是真正的约束最优，必须迭代。

9.5 方法 B：对偶梯度下降

关键观察：核范数的梯度是 msign ： $\nabla_M \|M\|_* = \text{msign}(M)$ 。故对 $\|G + WX\|_*$ 关于 Λ ($X = \Lambda + \Lambda^\top$) 求梯度：

$$\nabla_\Lambda \|G + WX\|_* = W^\top \text{msign}(G + WX) + \text{msign}(G + WX)^\top W = W^\top \Phi + \Phi^\top W.$$

所以解切空间方程 $W^\top \Phi + \Phi^\top W = 0$ 等价于求 $\|G + WX\|_*$ 的（局部）极值！

对偶上升的来源——拉格朗日对偶

$$\max_{\|\Phi\|_2 \leq 1} \min_{\Lambda} \text{tr}(G^\top \Phi) + \text{tr}(\Lambda^\top (W^\top \Phi + \Phi^\top W)) = \min_{\Lambda} \|G + WX\|_*.$$

（用 Minimax 定理交换 $\min, \max$ 。）即原问题的**对偶问题**就是核范数最小化。

对偶梯度下降 + 在线参数同步

$$\begin{cases} \Phi = \text{msign}(G + WX), \\ W \leftarrow W - \eta_1 \Phi, \\ X \leftarrow X - \eta_2 (W^\top \Phi + \Phi^\top W). \end{cases} \quad (22)$$

不需要内层完全收敛—— X 与 W 同步更新即可。这正是 *Modular Manifolds* [3] 的用法。

9.6 回缩

若 $G + WX$ 满秩（数值上几乎总成立）： $(W - \eta\Phi)^\top (W - \eta\Phi) = (1 + \eta^2)I_m$ ，故只需归一化： $W \leftarrow (W - \eta\Phi)/\sqrt{1 + \eta^2}$ 。建议周期性做 $W \leftarrow \text{msign}(W)$ 把参数硬拉回 Stiefel 流形，且整个迭代建议 FP32 起步。

10 第九讲：谱球面上的 Muon

10.1 问题与一阶近似

希望参数的谱范数恒为 1: $\max_{\Phi} \text{tr}(G^{\top} \Phi)$ s.t. $\|\Phi\|_2 = 1, \|W\|_2 = 1, \|W - \eta\Phi\|_2 = 1$ 。

由 SVD 的导数 (见附录 A): $\nabla_W \|W\|_2 = u_1 v_1^{\top} =: \Theta$ (最大奇异向量外积)。一阶近似下两个谱范数条件等价于 $\text{tr}(\Theta^{\top} \Phi) = 0$ 。

通用形式:

$$\max_{\Phi} \text{tr}(G^{\top} \Phi) \quad \text{s.t.} \quad \|\Phi\|_2 = 1, \text{tr}(\Theta^{\top} \Phi) = 0. \quad (23)$$

10.2 待定系数与不动点迭代

$\text{tr}(G^{\top} \Phi) \leq \|G + \lambda\Theta\|_*$, $\Phi^* = \text{msign}(G + \lambda\Theta)$ 。 λ 是标量, 但满足 $\text{tr}(\Theta^{\top} \Phi) = 0$ 仍是非线性方程。利用与 Stiefel 类似技巧:

$$\lambda = \frac{\text{tr}(\Theta^{\top} \Phi Q) - \text{tr}(\Theta^{\top} \Phi) \text{tr}(Q)/m - \text{tr}(\Theta^{\top} G)}{\text{tr}(\Theta^{\top} \Theta)} \quad (24)$$

其中 $Q = (G + \lambda\Theta)^{\top} \Phi$ 。代入初值 $\lambda^{(0)} = -\text{tr}(\Theta^{\top} G)/\text{tr}(\Theta^{\top} \Theta)$, 反复迭代即可。

10.3 对偶梯度下降视角

由核范数梯度公式: $\nabla_{\lambda} \|G + \lambda\Theta\|_* = \text{tr}(\Theta^{\top} \text{msign}(G + \lambda\Theta)) = \text{tr}(\Theta^{\top} \Phi)$ 。所以解切空间方程 = 求 $\|G + \lambda\Theta\|_*$ 关于 λ 的最小值。可以做 $\Phi = \text{msign}(G + \lambda\Theta)$, $W \leftarrow W - \eta_1 \Phi$, $\lambda \leftarrow \lambda - \eta_2 \text{tr}(\Theta^{\top} \Phi)$ 。形式上是 Muon 的一种自适应权重衰减。

10.4 数值算例: 3×3 谱球面

取

$$W = \text{diag}(1, 0.7, 0.3), \quad G = \begin{pmatrix} 1.007 & 0.360 & 0.510 \\ 0.622 & 0.263 & 0.501 \\ 0.500 & -0.026 & 0.805 \end{pmatrix}.$$

$$\|W\|_2 = 1 \quad (\text{顶奇异值唯一, } \sigma_2 = 0.7 \text{ 与之分得很开}), \quad \Theta = u_1 v_1^{\top} = e_1 e_1^{\top} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}.$$

无约束基线: $\|G\|_* = 2.213$ (即 $\text{msign}(G)$ 与 G 的内积上限)。但这违反切空间约束 $\text{tr}(\Theta^{\top} \Phi) = 0$ 。

对偶 GD (步长 $\eta_2 = 0.1$): 解 $\min_{\lambda} \|G + \lambda\Theta\|_*$, 每步 $\lambda \leftarrow \lambda - 0.1 \cdot \text{tr}(\Theta^{\top} \Phi)$ 。

k	λ	$\ G + \lambda\Theta\ _*$	$\text{tr}(\Theta^{\top} \Phi)$ (梯度)
0	0	2.213	+0.991
1	-0.099	2.115	+0.989
2	-0.198	2.017	+0.987
3	-0.297	1.939	+0.231
4	-0.320	1.934	+0.205
5	-0.340	1.930	+0.181
8	-0.388	1.922	+0.126
14	-0.445	1.917	+0.061
解析最优		1.915	0

解读:

- **相变发生在 $k = 3$** : λ 越过某临界值后, 第三个奇异值 ($\sigma_3 \approx 0.097$) 开始成为约束的活跃方向, msign 的 Θ 分量从 ≈ 0.99 跳到 ≈ 0.23 。这是核范数函数**分段线性**的具体表现——每段对应一组奇异值排序。
- **第二段缓慢收敛**: 进入 $k \geq 3$ 后, 梯度幅值小 (~ 0.1), 所以收敛慢。换句话说, 分段函数不同段对应”快下降”和”慢下降”两个区域。
- **14 步后收敛到 1.917**, 与解析最优 1.915 误差 0.002。再小步长可继续逼近。

在最优点的奇异值: $\sigma(G + \lambda^* \Theta) = (1.452, 0.365, 0.097)$ 。第三奇异值很小但严格非零, 说明最优解在光滑区内 (不是奇异值简并点); 故 $\Phi^* = \text{msign}(G + \lambda^* \Theta)$ 良定义。

注记 10.1 (核范数函数的几何): $\lambda \mapsto \|G + \lambda \Theta\|_*$ 是 λ 的凸、分段线性函数, 分段处对应于 $G + \lambda \Theta$ 的某对奇异值相等或某个奇异值过零。最优 λ^* 几乎必落在分段点上 (即”棱”上) ——这是所有 ℓ_1 类问题的典型行为。所以对偶 GD 在最优解附近会震荡 (梯度跳变), 需要逐步衰减步长 $\eta_k = \eta_0/\sqrt{k}$ 或采用 proximal 方法才能精确收敛。

11 第十讲: 对偶梯度下降的统一视角

回过头看, 第 9 与第 10 讲都用到了同一个观察:

Modular Manifolds 核心观察

”切空间方程”恰好是某个核范数目标的梯度等于零的条件。所以解约束最速下降 $\Leftrightarrow$ 求核范数的极小值。

通用模板:

输入: 损失梯度 G , 参数 W , 约束 $\mathcal{C}$ 对应的切空间投影由乘子 λ 参数化。

算法:

1. $\Phi \leftarrow \text{msign}(G + (\text{乘子 } \lambda \text{ 的线性项}))$
2. $W \leftarrow W - \eta_1 \Phi$ (再做一次 retraction 拉回 $\mathcal{C}$)
3. $\lambda \leftarrow \lambda - \eta_2 \cdot (\text{切空间方程的左端})$

每步只比朴素 Muon 多一次几乎免费的乘子更新, 没有内层迭代, 工程实现简洁。

11.1 为什么核范数自然出现?

拉格朗日对偶: $\max_{\rho(\Phi) \leq 1} \min_{\lambda} \text{tr}(G^\top \Phi) + \langle \lambda, (\text{切空间方程}) \rangle = \min_{\lambda} \rho^*(G + W \cdot \lambda)$, 其中 ρ^* 是 ρ 的对偶范数。谱范数的对偶就是核范数, 故核范数出现是必然结果。

12 第十一讲: 实现细节与参考代码

12.1 精度问题

- **Muon (无流形约束)**: 可在 BF16 下做 Newton-Schulz, 对 GPT-2/LLaMA 类模型实测稳定。
- **流形约束情形**: 建议 **FP32**, 因为 $W^\top W = I$ 是 $m(m+1)/2$ 个等式约束, 低精度下漂移很快。一般受约束的参数数量小 (少数 attention 头/projection), 代价可接受。
- **回缩**: 除归一化外, 建议每 ~ 100 – 1000 步做一次 $W \leftarrow \text{msign}(W)$ 把参数硬拉回流形。

12.2 Stiefel 流形 Muon 参考实现


```
1 import numpy as np
2
3 def msign(g):
4     u, s, vh = np.linalg.svd(g, full_matrices=False)
5     return u @ np.diag(np.sign(s)) @ vh
6
7 def sym(x): return (x + x.T) * 0.5
8 def skew(x): return (x - x.T) * 0.5
9
10 def muon_stiefel_svd(g, w, steps=10):
11     """Stiefel 流形上的 Muon, 通过 SVD 路径求解 Lyapunov."""
12     x = -sym(w.T @ g) # 方阵情形的解作为初值
13     for k in range(steps):
14         z = g + w @ x
15         u, s, vh = np.linalg.svd(z, full_matrices=False)
16         phi = (u * np.sign(s)) @ vh
17         # 一次 SVD 同时给出 msign 和 Lyapunov 方程的右端处理
18         rhs = sym(z.T @ phi @ w.T @ g)
19         x = -2 * vh.T @ ((vh @ rhs @ vh.T) /
20                          (s + s[:, None] + 1e-12)) @ vh
21     return phi
22
23 def muon_stiefel_dual(g, w, x, eta_inner=0.1):
24     """Modular Manifolds 风格: 一次内层 dual ascent 步."""
25     phi = msign(g + w @ x)
26     grad_x = 2 * sym(w.T @ phi) # = w^T phi + phi^T w
27     x = x - eta_inner * grad_x
28     return phi, x
```

12.3 大模型训练中的实用建议

1. **选择性应用**: 只对真正需要正交/谱约束的层使用, 例如分类头、codebook、SSM 转移矩阵。
2. **热身策略**: 训练初期用普通 Muon, 参数稳定后再切换到流形版。
3. **对偶版 vs 不动点版**: 参数量大且只有少数受约束层 → 不动点版 (精度高); 约束层很多或对计算敏感 → 对偶版 (每步几乎免费)。
4. **动量**: 与原版 Muon 一致, 对 G 做 Nesterov 动量平均后再做 msign。

结语

整个讲义沿着一条非常清晰的逻辑链:



无论是经典的球面 SGD、Muon，还是新近的 Stiefel/Modular Manifolds，背后都共享同一个数学骨架。**这种”骨架性”的认识比任何单一算法都更重要**——以后碰到新的流形约束（低秩、稀疏、群结构），都可以套用：“写出切空间 → 列拉格朗日 → 找核范数对偶 → 不动点或对偶梯度下降”。

A 附录 A：常用矩阵恒等式备忘

- **迹的循环不变性**： $\text{tr}(AB) = \text{tr}(BA)$ ， $\text{tr}(A^\top B^\top) = \text{tr}(B^\top A^\top)$ 。
- **Frobenius 内积**： $\langle A, B \rangle_F = \text{tr}(A^\top B) = \sum_{ij} A_{ij} B_{ij}$ 。
- **对称-反对称分解**： $M = [M]_{\text{sym}} + [M]_{\text{skew}}$ 。
- **msign 性质**：
 - $\text{msign}(M) = M(M^\top M)^{-1/2} = (MM^\top)^{-1/2}M$ （列/行满秩时）。
 - $\|M\|_* = \text{tr}(M^\top \text{msign}(M)) = \text{tr}((M^\top M)^{1/2})$ 。
 - 方阵正交 W ： $W^\top \text{msign}(M) = \text{msign}(W^\top M)$ 。
 - M 反对称 $\Rightarrow \text{msign}(M)$ 反对称。
- **核范数梯度**： $\nabla_M \|M\|_* = \text{msign}(M)$ （所有奇异值非零时）。
- **谱范数梯度**： $\nabla_M \|M\|_2 = u_1 v_1^\top$ （最大奇异值唯一时）。
- **Hölder 不等式（矩阵版）**： $\text{tr}(A^\top B) \leq \|A\|_p \|B\|_q$ ， $1/p + 1/q = 1$ ；谱范数与核范数对偶（ $p = \infty, q = 1$ ）。

B 附录 B：与相关研究方向的连接

B.1 与各向同性 / Norm 层的联系

线性层 $Y = XW$ 的特征视角下， $\Delta Y = -\eta X X^\top \nabla_Y L$ 。当 $X X^\top \approx I$ （即输入各向同性），参数空间和特征空间的最速下降方向**一致**。BatchNorm/LayerNorm 等可视为对 $X X^\top \approx I$ 的强制施行——**都是希望优化器看到的几何更”标准”**。

B.2 与二阶优化器的联系

Adam 的 $\hat{v}_t \approx \mathbb{E}[g^2]$ 可解释为 Hessian 的对角近似。Muon 的 msign 则相当于 polar factor，与 Shampoo、SOAP、DAWN 等更显式的二阶/谱方法属于同一谱系。流形约束下的 Muon（本讲义主题）可视为二阶预条件 + 几何约束双重视角下的统一。

B.3 BBP 相变与随机化方法

当 G 是噪声扰动下的“低秩 + 噪声”结构时，前 k 个奇异值的稳定性由 BBP (Baik–Ben Arous–Péché) 相变控制。这意味着 msign 在低 SNR 区域可能不稳定，需要加阻尼或仅对前 k 大奇异值做处理——这正是头-尾谱分解类二阶优化器（如 DAWN）的设计动机。

B.4 测地线距离与本讲义优化主题的呼应

第 3 讲中介绍的 k -NN 图近似测地线距离的方法属于“流形学习”的经典工具。它和本讲义的优化主题共享同一种数学语言——**流形上的“局部欧氏，全局非欧”原则**：数值上， k -NN 图把局部欧氏距离拼成全局测地线距离；优化上，切空间投影把局部欧氏的最速下降方向拼成全局的流形下降轨迹。两者是同一思想在不同任务上的应用。

C 附录 C：练习题

练习 C.1： 证明：若 $M \in \mathbb{R}^{n \times n}$ 反对称 ($M^\top = -M$)，则 $\text{msign}(M)$ 也反对称。

提示： M 反对称 $\Rightarrow M^\top M = -M^2$ 与 M 可交换。

练习 C.2： 对超球面上的 L^p 范数最速下降，写出 $p \rightarrow \infty$ 的解，并解释其几何意义。

练习 C.3： 对正交方阵流形（定理 8.1），考虑 G 是反对称矩阵的特殊情形，化简 Φ^* 的表达式。

练习 C.4： 推导 Stiefel 流形上多重最大奇异值情形的迭代格式。

练习 C.5： 对偶梯度下降 (22) 的收敛性：证明在 W 不变的假设下， X 的更新会使 $\|G + WX\|_*$ 单调下降（取充分小步长 η_2 ）。

练习 C.6： 实现 k -NN 图测地线距离近似：

1. 在球面 S^2 上随机采样 $N = 500$ 个点；
2. 用 $k = 10$ 构造邻近图；
3. 用 Dijkstra 求所有两两测地线距离的近似值，与精确值 $\arccos(\langle p, q \rangle)$ 比较；
4. 探究 k 增大/减小时近似精度的变化。

练习 C.7 (实现题)： 基于第 12 讲的代码，在 GPT-2 (124M) 上比较：(a) 普通 Muon；(b) Stiefel-Muon（仅 attention 输出 projection）；(c) Modular-Manifolds 版。报告训练曲线、wall-clock 与最终 perplexity。

References

- [1] K. Jordan et al., *Muon: An optimizer for hidden layers in neural networks*, 2024.
- [2] J. Bernstein, *Orthogonal Manifold*, blog post, 2024.
- [3] Thinking Machines Lab, *Modular Manifolds*, 2025.
- [4] *Unsupervised Opinion Summarization Using Approximate Geodesics*, 2022.

- [5] 流形上的最速下降: 1. $SGD +$ 超球面, <https://spaces.ac.cn/archives/11196>.
- [6] 流形上的最速下降: 2. $Muon +$ 正交, <https://spaces.ac.cn/archives/11215>.
- [7] 流形上的最速下降: 3. $Muon + Stiefel$, <https://spaces.ac.cn/archives/11221>.
- [8] 流形上的最速下降: 4. $Muon +$ 谱球面, <https://spaces.ac.cn/archives/11241>.
- [9] 流形上的最速下降: 5. 对偶梯度下降, <https://spaces.ac.cn/archives/11388>.
- [10] 从局部到全局: 语义相似度的测地线距离, <https://spaces.ac.cn/archives/9368>.