

深度学习是否存在科学理论？

关于 Simon 等《There Will Be a Scientific Theory of Deep Learning》
(arXiv:2604.21691) 的阅读报告

阅读笔记

2026 年 5 月

摘要

本文是对 Simon 等人 2026 年综述论文 *There Will Be a Scientific Theory of Deep Learning* 的阅读报告。原文将散落在深度学习理论各处的进展——可解析模型、宽度/深度极限、神经标度律、超参数解耦、表征普适性——拢聚为一种被作者命名为**学习力学** (learning mechanics) 的统一图像，并主张其与经典力学、连续介质力学、统计力学、量子力学之间存在结构性的方法论同构。本报告按原文结构梳理其核心论点：第 1 节给出“学习力学”的定位与七项纲领；第 2 节展开五条证据线，对线性化、NTK、 μP 、边缘稳定性等关键概念以公式给出更明确的表述，便于读者把握其数学骨架；第 3 节讨论与统计、信息论、机制可解释性等其他视角的关系；第 4 节复述并评议作者对若干常见怀疑论的回应；第 5 节摘录十个开放方向并给出简评；最后给出阅读总结。

目录

作者背景	1
1 论文的核心主张：学习力学	2
1.1 学科史脉络：从“什么可表达”到“实际怎么学”	2
1.2 为什么称作“力学”	3
1.3 学习力学的七项纲领	4
1.4 为什么这门理论有可能成功	4
2 五条证据线	5
2.1 解析可解的简化设定	5
2.1.1 深度线性网络（在数据上线性化）	5
2.1.2 线性化网络与神经正切核（在参数上线性化）	6
2.1.3 超出线性化	7
2.2 富有洞察力的极限	8
2.2.1 宽度无穷与 lazy/rich 二分	8
2.2.2 深度无穷与残差网	9
2.2.3 其它无穷极限	10
2.2.4 联合标度极限	11

2.2.5 离散化假设 (Discretization Hypothesis)	11
2.3 捕捉宏观统计的简单经验定律	12
2.3.1 神经标度律	12
2.3.2 边缘稳定性 (Edge of Stability)	12
2.3.3 隐藏表征与权重的简单规律	14
2.4 超参数的解耦与理解	15
2.4.1 学习率与批量的线性标度律	16
2.4.2 学习率作为曲率正则	16
2.4.3 μP 与超参数迁移	16
2.5 跨设定的普适现象	17
3 与其他视角的关系	19
4 对常见怀疑论的回应	21
5 十大开放方向	22
6 阅读总结	24
6.1 一段话压缩	24
6.2 方法论复盘：五条证据线在做的同一件事	24
6.3 若干值得追的具体线索	25
6.4 对青年研究者的建议	26

作者背景

这篇综述由 14 位活跃在深度学习理论第一线的研究者联合署名。我不一一介绍，只点出几位有硬指标的核心作者，让读者对整组人的“分量”有个直接感觉。引用数大致截至 2026 年中。

- **Arthur Jacot** (NYU Courant 助理教授): **NTK 的提出者**。 *Neural Tangent Kernel: Convergence and Generalization in Neural Networks* (NeurIPS 2018 **spotlight**) 单篇被引约 **6,000+**，是深度学习理论近十年被引最多的论文之一，本文 §2.1 与 §2.2 lazy 极限的整段讨论都建立在它之上。
- **Jeremy Cohen** (Flatiron Institute): **Edge of Stability 现象的发现者**。 *Gradient Descent on Neural Networks Typically Occurs at the Edge of Stability* (ICLR 2021) 是本文 §2.3 中“sharpness 锁定在 $2/\eta$ ”的核心论文。更早的代表作 *Certified Adversarial Robustness via Randomized Smoothing* (ICML 2019) 单篇被引约 **2,500+**，是 adversarial robustness 领域的奠基工作之一。两条主线各自高引。2025 年又给出 central flow 框架。
- **Enric Boix-Adserà** (Wharton 助理教授): **COLT 主战场上的常客**。 *The Merged-Staircase Property* (COLT **2022**) + *SGD Learning on Neural Networks: Leap Complexity and Saddle-to-Saddle Dynamics* (COLT **2023**) 连续两年的 COLT 正会论文是本文 §2.1 关于 SGD 学

习稀疏目标讨论的直接来源；*GULP* (NeurIPS 2022 **oral**, **top 8%**)。MIT PhD 期间获 **Sprowls Best Thesis Award** (MIT EECS 最高博士论文奖)。

- **Eric J. Michaud** (Astera Institute): **标度律的 quantization 模型提出者**。*The Quantization Model of Neural Scaling* (NeurIPS 2023); *Towards Understanding Grokking* (NeurIPS 2022 **oral**); *Omnigrok* (ICLR 2023 **spotlight**) —— **连续三年顶会高级别接收**。本文 §2.3 关于标度律为何呈幂律的候选解释里就有他这条 quantization 路径。
- **Blake Bordelon** (Harvard CMSA postdoc): **动力学平均场理论 (DMFT) 的代表作者之一**。*Spectral Bias and Task-Model Alignment Explain Generalization in Kernel Regression and Infinitely Wide Neural Networks* (与 Canatar/Pehlevan, *Nature Communications* 2021); *Self-consistent Dynamical Field Theory of Kernel Evolution* (NeurIPS 2022); *A Dynamical Model of Neural Scaling Laws* (2024); *Depthwise Hyperparameter Transfer* (2023) 把 μP 推广到深度方向。**Google PhD Fellowship 获得者**。本文 §2.2 (rich 极限)、§2.3 (标度律动力学)、§2.4 (μP) 的多处讨论建立在他这一系列工作上。
- **Jamie Simon** (UC Berkeley & Imbue, 本文通讯作者): **核学习理论的”学习曲线预测”线**。*The Eigenlearning Framework* (TMLR 2023) 从核谱出发精确预测核回归与宽神经网络在任意目标函数上的学习曲线，是本文图 1b 的理论基础。

此外还有 **Daniel Kunin** (UC Berkeley Miller Postdoctoral Fellow, 深度学习守恒律工作)、**Mason Kamb** (Stanford, 扩散模型创造性解析理论, ICML 2025 **oral** / **spotlight**)、**Florentin Guth** (NYU, 扩散模型几何自适应表征)、**Alexander Atanasov** (Harvard, silent alignment effect) 等多位代表性作者，他们的工作分别支撑了本文 §2.3 守恒律、§2.5 扩散模型普适性、§2.2 lazy/rich 等具体章节。

可以看出这是一支把 NTK、DMFT、edge of stability、scaling laws、conservation laws、COLT 主战场理论等多条互补主线集中在一起的作者团；本文实际上是这群人共同的理论身份宣言。

1 论文的核心主张：学习力学

深度学习以工程奇迹的姿态进入了科学版图，但它至今没有获得像热力学之于蒸汽机、空气动力学之于飞机那样具有解释力的基础理论。Simon 等人的综述给出了一个克制而具有野心的判断：

深度学习理论不再仅是一个纯数学构造问题，而是一门关于复杂经验系统的科学。在训练动力学、隐藏表征、最终权重和测试性能中，可以辨认出若干稳定的、可重复测量的规律；这些规律之间的相互关联正凝结为关于学习过程的力学。

1.1 学科史脉络：从”什么可表达”到”实际怎么学”

理解作者的判断，先要理解深度学习理论是如何走到今天的。论文第 1 节把这段历史压缩为以下几次重心转移：

- **表达能力时代** (1940s–1980s): 从 McCulloch–Pitts 神经元、感知机到通用逼近定理。核心问题是什么函数可以被简单模型表示。
- **统计学习理论** (1980s–2000s): 把学习理解为统计推断, 发展出 VC 维、PAC 学习、Rademacher 复杂度等工具, 回答有限样本下何时能泛化。其经典结论形如

$$\mathbb{E}[\mathcal{L}_{\text{test}}] - \mathcal{L}_{\text{train}} \leq \mathcal{O}\left(\sqrt{\frac{\text{Complexity}(\mathcal{F})}{n}}\right),$$

其中 $\mathcal{F}$ 是假设类, n 是样本数。

- **凸优化时代**: 与统计学习配套发展的是凸优化的可证收敛速率, 给出“凸 + 平滑 $\rightarrow \mathcal{O}(1/t)$ ”等清洁的端到端保证。
- **统计物理传统** (Gardner, Seung–Sompolinsky–Tishby, Saad–Solla, Zdeborová 等): 从 1980s 末便已用统计力学方法研究“教师–学生”模型在高维极限下的平均情形泛化, 给出与样本复杂度有关的相变。

深度学习的成功——非凸、过参数化、却比统计理论“应该”允许的效果好——令以上每一种工具都失灵, 或至少不足以解释现象:

- VC 维与函数类容量在过参数化网络中以发散速度增长, 但泛化反而更好 (“双下降”现象);
- 凸优化的全局收敛保证不再适用于非凸损失景观, 但 SGD 仍然找到泛化解;
- 真正出人意料的是网络并非简单地拟合数据, 而是在中间层学到了有结构的、可被复用的表征。

这迫使深度学习理论从一门“纯数学化”的可证明性研究, 转向一门面对复杂经验系统的科学: 要先描述、再解释、再预测, 而非先证明再实施。Simon 等的综述正是要为这一已经悄然发生的范式转换正式命名。

1.2 为什么称作“力学”

作者将这门正在形成的学科命名为 **learning mechanics**。其与既有力学分支的对应关系如下:

- **经典力学**之于谐振子、氢原子 $\iff$ 深度线性网、核回归等可解模型;
- **统计/连续介质力学**之于热力学极限 $\iff$ 宽度、深度、批量趋于无穷的极限分析;
- **宏观经验定律** (Kepler、Snell、Boyle、Hooke、Ohm 等) $\iff$ 神经标度律、边缘稳定性、神经塌缩;
- **量纲分析与系统参数** $\iff$ 超参数的解耦与重缩放 (μP 、SGD 噪声温度等);
- **临界现象与重整化群下的普适类** $\iff$ 跨架构、跨模态趋同的内部表征。

核心要点

任何力学的核心都是关于**运动**和**相互作用**的科学。神经网络在参数空间中的更新轨迹、由数据-架构-学习规则共同塑造的损失景观、以梯度作为媒介的”力”，与物理力学的对应是结构性的。因此，物理学里为应对多体相互作用而发展出的工具——极限、相图、对称性、守恒律、普适类、重整化——在深度学习里有相当大的几率重新有效。

1.3 学习力学的七项纲领

作者明确给出了对这门理论的七项要求；下面在原文基础上对每条做略加展开的诠释：

1. **第一性 (fundamental)**：从训练过程的第一性原理出发。中间假设（关于权重统计、动力学结构、性能形态等）只能作为脚手架，最终都应当从基础对象（架构、数据、损失、学习规则）推出。
2. **数学性 (mathematical)**：作出明确的定量陈述。任何一门力学都不是定性科学；学习力学也绝不应是。
3. **可证伪 (predictive)**：能被简单可重复的实验检验。深度学习的可观测性极强，这条要求并不奢侈。
4. **综合性 (comprehensive)**：训练过程、隐藏表征、最终权重置于同一图像内。但作者也强调：地图不应等于疆域；理论应在合适的分辨率上换取洞察。
5. **直觉性 (intuitive)**：解释力胜于技术复杂度。一项工作如果他人无法快速吸收，便难有持久影响。
6. **可用性 (useful)**：能减少调参、指导数据集设计、为 AI 安全提供依据。物理之于工程的支撑作用，是学习力学最终应承担的角色。
7. **谦逊性 (humble)**：清楚地标注自身的适用边界。每一支物理学都有其失效区，并把这种失效连同理论本身一起教授；学习力学应当以同样的姿态出现。

作者反复强调的一个论点是：深度学习的所有”运动方程”在原则上是显式且可测的——架构 $f(\mathbf{x}; \boldsymbol{\theta})$ 、数据集 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ 、目标 $\mathcal{L}(\boldsymbol{\theta})$ 、学习规则

$$\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)} - \eta \nabla \mathcal{L}(\boldsymbol{\theta}^{(t)}), \quad \boldsymbol{\theta}_i^{(0)} \sim \mathcal{N}(0, \alpha_{\text{init}}^2),$$

中的所有量都可记录、可统计。阻碍我们的不是”黑箱”的不可观测，而是高维非线性耦合所带来的”复杂性”。这一区分对于理解后文五条证据线至关重要。

1.4 为什么这门理论有可能成功

许多复杂系统的科学化，往往受困于”运动方程未知”。神经科学要从锋电位记录中反推神经元的相互作用规则；流体力学的湍流模型要从有限测点拟合本构关系；金融市场的”动力学”实际上是一个不可见的博弈过程的副产品。深度学习与之相反：

- **运动方程显式**：架构 $f(\mathbf{x}; \boldsymbol{\theta})$ 与学习规则 $\boldsymbol{\theta} \mapsto \boldsymbol{\theta} - \eta \nabla \mathcal{L}$ 是研究者自己写下的，没有“未知力”。
- **初始条件可控**： $\boldsymbol{\theta}^{(0)}$ 由我们指定的分布生成，可重复。
- **全部状态可观测**：每一个权重、激活、梯度、损失值都可以无损记录；从中导出的任意统计量也都唾手可得。
- **实验成本低、迭代快**：相对于物理实验或临床试验，深度学习的实验开销小、可以大规模并行复现。

挑战只剩下一个，就是复杂性：高维、非线性、强耦合，再叠加数据分布本身的难以解析。然而正是为了驾驭这种复杂性，物理学积累了一整套强力工具——极限、相图、对称性、守恒律、普适类、重整化、量纲分析。论文用大量篇幅论证：这些工具在深度学习里有相当大几率重新有效，而过去几年的进展正是从这些工具所组织出的五条证据线。下一节我们就分别展开。

2 五条证据线

2.1 解析可解的简化设定

物理用谐振子和氢原子作为思考更复杂系统的“代表性可解情形”。深度学习里有两类对应物：在数据上线性化与在参数上线性化。

2.1.1 深度线性网络（在数据上线性化）

深度线性网络保留了网络在参数 $\boldsymbol{\theta} = \{\mathbf{W}_\ell\}_{\ell=1}^L$ 上的非线性，却在输入 $\mathbf{x}$ 上是线性的：

$$f(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{W}_L \mathbf{W}_{L-1} \cdots \mathbf{W}_1 \mathbf{x}, \quad L \geq 2.$$

为什么要“摘掉非线性激活”还能学到东西？端到端权重 $\mathbf{W} = \mathbf{W}_L \cdots \mathbf{W}_1$ 仍然受到非平凡的非凸优化动力学支配——它在数据上是线性映射，但作为参数 $\{\mathbf{W}_\ell\}$ 的函数是 L 次多项式。这意味着深度线性网没有非线性表达能力（输入-输出始终线性），但完整保留了非线性优化几何：鞍点、相变、深度依赖的隐式偏置在这里都还在。

Saxe ODE 的推导骨架。 取平方损失 $\mathcal{L} = \frac{1}{2} \mathbb{E} \|\mathbf{W} \mathbf{x} - y\|^2$ ，记输入协方差 $\Sigma_{xx} = \mathbb{E}[\mathbf{x} \mathbf{x}^\top]$ 、输入-输出相关 $\Sigma_{yx} = \mathbb{E}[y \mathbf{x}^\top]$ 。在白化输入 $\Sigma_{xx} = I$ 下，令 $\Sigma_{yx} = U \Lambda V^\top$ 为奇异值分解。对齐的初始化是说：选择 $\mathbf{W}_\ell(0)$ 使得端到端权重沿同一组奇异方向打开。在这种坐标下，每个奇异通道的“端到端奇异值” $s_i(t)$ 被解耦为标量梯度流。对 $L = 2$ 的两层网络，记 s_i 是 $\mathbf{W} = \mathbf{W}_2 \mathbf{W}_1$ 的第 i 个奇异值，按 gradient flow $\dot{\mathbf{W}}_\ell = -\partial \mathcal{L} / \partial \mathbf{W}_\ell$ 推导可得

$$\dot{s}_i = s_i (\sigma_i - s_i), \quad s_i(0) = s_{i,0} > 0,$$

其中 $\sigma_i = \Lambda_{ii}$ 是数据相关矩阵的第 i 个奇异值。这是一个伯努利型 ODE，其闭式解为

$$s_i(t) = \frac{\sigma_i}{1 + (\sigma_i / s_{i,0} - 1) e^{-\sigma_i t}}.$$

该解暴露出深度学习里非常稳健的一个图像：**贪婪低秩偏置**——奇异值 σ_i 越大的方向先被学到，呈现出一系列”阶梯式”的相变。当 $s_{i,0} \rightarrow 0$ 时学习曲线呈 sigmoid 形：长时间几乎不动，然后在 $t \sim \sigma_i^{-1} \log(\sigma_i/s_{i,0})$ 附近迅速跃升到 σ_i ，整段过程可被解释为”逃离原点鞍点”。

对 $L \geq 3$ 的更深线性网络，类比的 ODE 改为

$$\dot{s}_i \propto s_i^{2-2/L} (\sigma_i - s_i),$$

形式上”更扁”——这意味着**深度本身使学习更”贪婪”**：低于阈值的奇异通道被压抑得更彻底，高于阈值的奇异通道在跃升时变得更陡。这就是为什么”加深”在深度线性网中表现为更强的隐式低秩正则。

贪婪学习的现象学一致。 这一行为在非线性网络中以”由简入繁”的形式被反复观察到——简单频率/低阶函数先被学到，复杂细节后被学到。论文进一步指出，下列因素都会**增强**这种贪婪低秩偏置：**增大深度、减小初始化尺度、增大 mini-batch 噪声、显式 ℓ_2 正则化**。把这几条放在一起，就给”为什么神经网络泛化得好”提供了一个连贯的、与训练动力学耦合的解释路径——它并不是从 VC 维或函数类容量出发的，因此与经典统计学习理论的图像截然不同。

2.1.2 线性化网络与神经正切核（在参数上线性化）

另一种线性化，是把网络在初始参数 θ_0 处做一阶 Taylor 展开：

$$f_{\text{lin}}(\mathbf{x}; \boldsymbol{\theta}) = f(\mathbf{x}; \boldsymbol{\theta}_0) + \nabla_{\boldsymbol{\theta}} f(\mathbf{x}; \boldsymbol{\theta}_0)^\top (\boldsymbol{\theta} - \boldsymbol{\theta}_0).$$

此时 f_{lin} 在 $\boldsymbol{\theta}$ 上线性，但作为 $\mathbf{x}$ 的函数仍可以高度非线性（因为特征图 $\nabla_{\boldsymbol{\theta}} f(\cdot; \boldsymbol{\theta}_0)$ 自身是高度非线性的）。这与上一节正好对偶：深度线性网是输入线性、参数非线性，NTK 极限是参数线性、输入非线性。

从一阶展开到核回归。 将 f_{lin} 视作以 $\nabla_{\boldsymbol{\theta}} f(\mathbf{x}; \boldsymbol{\theta}_0)$ 为特征图的线性模型，其学习动力学等价于一个以**神经正切核**（NTK）为核函数的核线性回归：

$$K_{\text{NTK}}(\mathbf{x}, \mathbf{x}') = \nabla_{\boldsymbol{\theta}} f(\mathbf{x}; \boldsymbol{\theta}_0)^\top \nabla_{\boldsymbol{\theta}} f(\mathbf{x}'; \boldsymbol{\theta}_0).$$

对最小二乘损失 $\mathcal{L} = \frac{1}{2} \sum_i (f(x_i; \boldsymbol{\theta}) - y_i)^2$ 做梯度流，预测值 $\hat{f}_t(\mathbf{x})$ 服从

$$\dot{\hat{f}}_t(\mathbf{x}) = -K_{\text{NTK}}(\mathbf{x}, X) (\hat{f}_t(X) - Y).$$

这是一组关于函数值的线性 ODE，其稳态可以闭式写出。加入 ridge 正则化后，最终预测器是

$$\hat{f}(\mathbf{x}) = K_{\text{NTK}}(\mathbf{x}, X) (K_{\text{NTK}}(X, X) + \lambda I)^{-1} Y,$$


即一个固定核 K_{NTK} 下的核脊回归。

为什么这件事有用？ NTK 极限把”训练一个非线性深度网络”这个本质上非凸、超高维的过程，归约为”在某个固定 RKHS 中做线性回归”——一个有完整经典理论的对象。具体收益至少有三：


- **架构** → **归纳偏置**的映射是显式的：网络的 Jacobian 结构通过 NTK 的核谱分解直接给出归纳偏置。卷积、残差、attention 等架构选择都对应着 NTK 谱上不同的衰减率。

- **泛化误差可被预测**: 在数据分布的 NTK 谱基下展开真函数 f^* , 其在样本量 n 下的核回归泛化误差可被精确刻画, 并能解释 *double descent* 等”反直觉”现象。
- **标度律的 NTK 解释**: 在源/能力条件 $\|f^*\|_{K^s} < \infty$ 与谱衰减 $\lambda_k \sim k^{-\alpha}$ 下, 核回归的过剩风险呈幂律 $\mathcal{O}(n^{-\beta})$, 指数 β 由 α, s 显式给出。

为什么这还不够。 代价是放弃了特征学习: $\nabla_{\theta} f(\cdot; \theta_0)$ 是冻结的, 第一层权重在训练中几乎不变 (见后文 lazy/rich 的进一步讨论), 因此对那些”必须学到合适特征才能高效解决”的任务, 它在样本复杂度上对真实网络的预测往往**过于悲观**。这一点在多指标模型 (multi-index model) 等结构化目标上尤为突出: 完整非线性网络可以有限样本内学到正确的特征方向, 而 NTK 必须用 $n^{p/2}$ 量级的样本才能达到同样精度 (其中 p 是真函数的”阶”)。



(a) 深度线性网 (数据线性化)



(b) NTK 核回归 (参数线性化)

图 1: **两类线性化都得到了与实验严格匹配的解析解**。(a) Saxe 等 (2014) 证明, 在任务对齐的初始化与白化输入下, 深度线性网的梯度流动力学被解耦为一组独立的伯努利型 ODE, 导致奇异模按奇异值大小依次被学到。(b) 将非线性网络在初始参数处做 Taylor 展开后, 最小二乘训练等价于 NTK 核脊回归; 其谱结构刻画了架构 $\rightarrow$ 归纳偏置的映射, 可对测试性能给出定量预测。图改自 Saxe 等 (2014) 与 Simon 等 (2023a)。

2.1.3 超出线性化

作者把”既在数据上非线性又在参数上非线性”的可解模型作为开放方向之一 (见 Open Direction 1)。已有进展可以归为几类:

结构化目标 + 高斯输入: 考察 $y = g(\langle u_1, \mathbf{x} \rangle, \dots, \langle u_p, \mathbf{x} \rangle) + \xi$ 这样的”多指标模型”。已经能够证明: 完整非线性二层网络通过 SGD 可以在 $\mathcal{O}(d)$ 样本内学到正确的方向 $\{u_j\}$, 而所有核方法 (包括 NTK) 至少需要 $\mathcal{O}(d^{p/2})$ 样本。这把”特征学习相对核方法的优势”量化成了一个可证的样本复杂度差距。

二次激活两层网络: 使用 $\phi(z) = z^2$ 后, $f(\mathbf{x}) = \sum_i a_i (w_i^\top \mathbf{x})^2 = \mathbf{x}^\top (\sum_i a_i w_i w_i^\top) \mathbf{x}$, 可视作低秩二次型回归。这给出一个干净的”非线性但仍可解”的设置, 最近被用来推导精确的标度律与谱形式。

同质网络 + logistic 损失: Soudry 等证明, 在可分数据上做 gradient flow, 参数会在方向

上收敛到最大间隔解：

$$\frac{\boldsymbol{\theta}(t)}{\|\boldsymbol{\theta}(t)\|} \rightarrow \arg \max_{\|\boldsymbol{\theta}\|=1} \min_i y_i f(\mathbf{x}_i; \boldsymbol{\theta}).$$

这条结果为”为什么深度网络在分类任务上容易获得鲁棒边界”给出了第一性的解释。

教师-学生模型与低维总结统计：Saad-Solla 的经典工作把高维 SGD 的训练动力学约简为关于”序参数”（学生与教师权重的内积、各自的协方差等）的低维 ODE 组。这里有意思的地方在于：尽管原系统是 $\mathcal{O}(\text{nd})$ 维的，但有意义的统计量只有 $\mathcal{O}(p^2)$ 个（ p 是教师隐藏单元数）。这是统计物理”序参数约简”思想在深度学习中的直接对应。

算法结构的解析模型：Morwani、Gromov 等对模算术任务上的”grokking”给出 Fourier 特征解释；联想记忆模型（associative memory）允许对 transformer 中事实回忆做精确分析；attention 层的可解版本也开始出现。

但目前没有统一框架。每个工作都在用一套独特的简化捕获非线性的某一个侧面，把它们综合起来是 Open Direction 1 的目标。

2.2 富有洞察力的极限

复杂系统在被恰当地”取无穷”后常常显出简单结构。理想气体律 $PV = nRT$ 在粒子数 $\rightarrow \infty$ 的热力学极限里被精确导出，却仍可以解释体积有限的真实气体。深度学习里至少有以下重要极限。

2.2.1 宽度无穷与 lazy/rich 二分

考虑两层网络

$$f(\mathbf{x}) = \frac{\alpha}{n^c} \sum_{i=1}^n a_i \sigma(w_i^\top \mathbf{x}),$$

其中 n 是隐层宽度， σ 是逐元素激活， α 与 c 是要选定的标度参数。问”为什么需要标度”——是因为如果不缩放，前向激活会在 $n \rightarrow \infty$ 时按 $\sqrt{n}$ 量级发散。中心极限定理告诉我们：若 w_i, a_i 是独立同分布零均值随机变量，则

$$\frac{1}{n^c} \sum_{i=1}^n a_i \sigma(w_i^\top \mathbf{x}) \xrightarrow{n \rightarrow \infty} \mathcal{O}(n^{1/2-c}),$$

故 $c = 1/2$ 时输出有限， $c = 1$ 时输出趋于零。这两个临界值正好对应 lazy 与 rich 两个极限。

Lazy / NTK 极限 ($c = 1/2$)。此时初始化即满足 LeCun rule，前向激活有限。训练时权重的位移只能是 $\mathcal{O}(1/\sqrt{n})$ ——若不然，输出会在 $n \rightarrow \infty$ 时发散。关键观察是：尽管单个权重几乎不动，但 n 个隐神经元集体的微小位移会累计出 $\mathcal{O}(1)$ 的输出函数变化，因此训练看起来仍然有效。具体地，令 $\delta \boldsymbol{\theta}_t = \boldsymbol{\theta}_t - \boldsymbol{\theta}_0$ ，对函数做一阶 Taylor：

$$f(\mathbf{x}; \boldsymbol{\theta}_t) = f(\mathbf{x}; \boldsymbol{\theta}_0) + \nabla_{\boldsymbol{\theta}} f(\mathbf{x}; \boldsymbol{\theta}_0)^\top \delta \boldsymbol{\theta}_t + \mathcal{O}(\|\delta \boldsymbol{\theta}_t\|^2).$$

两层网络下 $\|\delta \boldsymbol{\theta}_t\|^2 = \mathcal{O}(1)$ 但 $\|\delta \boldsymbol{\theta}_t\|^2$ 在 f 的二阶项中被一个 $1/n$ 因子压制，因此 $n \rightarrow \infty$ 时高阶项消失，网络与其线性化完全等价。其行为正是上一节描述的 NTK 核回归——无特征学习。

Rich / 特征学习极限 ($c = 1$, **mean-field**)。若把最后一层换成 $1/n$ 标度 (这相当于把整个网络输出乘 α 后再除 n)，那初始函数 $f(\cdot; \theta_0)$ 在 $n \rightarrow \infty$ 时趋于零。然而这不是坏事：我们恰好希望最终函数主要由训练所学贡献，而非随机初始化。

把每一个隐神经元 (w_i, a_i) 视作 $\mathbb{R}^{d+1}$ 中的一个粒子，并令 ρ_t 为这些粒子的经验分布

$$\rho_t = \frac{1}{n} \sum_{i=1}^n \delta_{(w_i(t), a_i(t))}.$$

当 $n \rightarrow \infty$ 时 ρ_t 收敛到一个连续密度，其演化由 Wasserstein 梯度流给出：

$$\partial_t \rho_t = \nabla_{(w,a)} \cdot \left(\rho_t \nabla_{(w,a)} \frac{\delta \mathcal{L}[\rho_t]}{\delta \rho_t} \right),$$

其中 $\mathcal{L}[\rho] = \frac{1}{2} \mathbb{E}_{\mathbf{x}} (\mathbb{E}_{(w,a) \sim \rho} a \sigma(w^\top \mathbf{x}) - y \mathbf{x})^2$ 。这是一个对粒子分布的非线性 PDE——一个标准的 “mean-field” 对象。

这一极限里 “特征学习” 是显式可见的：训练让 ρ_t 在 w 空间中重新分布，把质量积聚到与目标函数相关的方向上。第一层权重不再是随机初始化的纯噪声——它们在数据指引下演化。

下表把两个极限的差异总结如下：

	Lazy / NTK	Rich / mean-field
最后一层标度	$1/\sqrt{n}$	$1/n$
权重位移	$\mathcal{O}(1/\sqrt{n})$	$\mathcal{O}(1)$
特征学习	无	有
等价模型	固定 NTK 的核回归	神经元分布的 Wasserstein 梯度流

Chizat 等 (2019) 做了一个非常重要的观察：即使在有限宽度，把网络输出整体乘以一个标量 α 也能起到相同作用——增大 α 推向 lazy (输出大，权重需移动小)，减小 α 推向 rich (输出小，权重需移动大)。这意味着 lazy/rich 不是宽度极限的人为产物，而是有限网络中真实存在的一种连续相图。论文把它类比为材料科学里的弹性形变 *vs.* 塑性形变：小外力下结构不变 (lazy)，大外力下结构重塑 (rich)。

为什么 rich 才是 “真正的” 极限。 深度学习的工程实践依赖于学到有用的特征——这正是 lazy 极限所不具备的。Yang 与 Hu 把这一点上升到方法论：在多层网络中要做出一个非平凡且允许特征学习的无穷宽度极限，必须按照特定方式标度每层——这就是后面 §2.4 要详细介绍的 Maximal Update Parameterization (μP)。

2.2.2 深度无穷与残差网

对深度为 L 的残差网，写成

$$\mathbf{x}^{(\ell+1)} = \mathbf{x}^{(\ell)} + \frac{1}{L^\beta} \mathcal{F}_\ell(\mathbf{x}^{(\ell)}; \theta^{(\ell)}), \quad \ell = 0, \dots, L-1.$$

这里 $\mathcal{F}_\ell$ 是每层残差块。 L 取很大时， $\mathbf{x}^{(\ell)}$ 沿层指数 ℓ 演化的方式由 β 决定。两类典型行为：




图 2: 网络输出乘子的大小直接决定了训练动力学是 **lazy** 还是 **rich**。对学生网络 $\hat{f}(x) = (\alpha/n) \sum_i a_i \text{ReLU}(w_i^\top x)$ ($n = 200$) 在二维输入下拟合一个三神经元教师, 画出训练过程中 w_i 的轨迹。左: $\alpha = 0.1$ (**rich**), 权重显著移动并向教师方向聚集——发生了特征学习。右: $\alpha = 30$ (**lazy**), 权重几乎不动, 损失却照样下降——典型的 NTK 行为。改自 Chizat 等 (2019)。

$\beta = 1$ (**ODE 极限**)。残差贡献按 $1/L$ 缩放。把 $\ell/L \in [0, 1]$ 视作“时间” t , 可以将上式看作 Euler 离散化

$$\mathbf{x}^{(\ell+1)} - \mathbf{x}^{(\ell)} = \frac{1}{L} \mathcal{F}_\ell(\mathbf{x}^{(\ell)}) \iff \frac{d\mathbf{x}(t)}{dt} = F(\mathbf{x}(t), t),$$

即一个神经常微分方程。残差流随深度光滑变化。

$\beta = 1/2$ (**SDE 极限**)。残差贡献按 $1/\sqrt{L}$ 缩放。如果各层参数的随机部分方差为 σ^2 , 那么累计扰动按

$$\sum_{\ell=0}^{L-1} \frac{1}{\sqrt{L}} \xi_\ell \xrightarrow{L \rightarrow \infty} \int_0^t dB(s)$$

转化为布朗驱动, 给出残差流的随机微分方程极限。这种“扩散式”极限在某些 transformer 形态下被验证——其特征在于残差流在层间有非平凡的“波动结构”。

不同的 β 在真实 transformer 上得到的解性质不同 (Dey 等 2025), 孰更接近实际仍是开放问题——这是 Open Direction 5 关心的“finite-depth 应当被理解为对哪种连续极限的离散化”问题在深度方向上的具体化。

2.2.3 其它无穷极限

对带 attention 与 MoE 的现代 transformer, 可标度的方向不止“宽度”和“深度”两条:

- attention 层有 **头数**、**每头宽度**、**上下文长度** 三种标度方向;
- MoE 有 **专家数**、**每专家宽度**、**激活稀疏度** 三种标度方向;
- RNN/状态空间模型则有时间维上的 mean-field 极限。

每一类都有学者在做对应的极限分析, 但如何把它们相互兼容地放进同一个理论框架仍是开放课题。论文把这件事放在 Open Direction 6 (“超参数能消多少”) 下讨论。

2.2.4 联合标度极限

许多现代设定要求多个维度同时趋于无穷而保持比例。这与随机矩阵理论里“ $P/N \rightarrow \gamma$ ”的设定完全一致。

比例标度的常见对象。 下面这些比值在各自的设定中决定了极限行为：

$$\frac{\#data}{\#input \ dim}, \quad \frac{\#data}{\#width}, \quad \frac{\#data}{\#params}, \quad \frac{\#width}{\#depth}, \quad \frac{\eta}{\#batch \ size}.$$

最后一个被称为 *SGD* 噪声温度，把 *SGD* 类比为带噪声的 *SDE*：

$$d\theta_t = -\nabla \mathcal{L}(\theta_t) dt + \sqrt{\frac{\eta}{B}} \Sigma(\theta_t) dW_t.$$

为什么联合极限重要。 Compute-optimal 标度律 (Chinchilla 工作) 发现最优配比是数据量与参数量同时增长 (约 1:20)，这就要求理论用联合极限而不是先取“参数无穷再看数据”或反之——这两种顺序通常不交换。如果先取参数无穷，会得到一个能完美拟合任意有限数据集的“过参数化”对象，看不到“参数量增加 $\rightarrow$ 损失下降”这种标度关系，因而无法刻画真实的标度律行为。

2.2.5 离散化假设 (Discretization Hypothesis)

作者把上述各种极限分析中浮现出的一个共同直觉，凝结成了一个值得反复审视的猜想：

核心要点

Discretization Hypothesis: 有限规模的神经网络应当被理解为对某个无穷规模理想模型的离散近似。正如 PDE 在时空上做有限差分得到数值解，宽度、深度、学习率、批量、训练时间，都对应着对某个连续/极限对象的“离散化”。增大模型、减小学习率，本质上是在减小离散化误差，但代价是增加计算。

为什么这个猜想值得严肃对待？因为它给整个理论提供了一个统一的语言：

- 宽度 n 之于 mean-field 流，类似有限元尺寸 h 之于 PDE 数值解；
- 深度 L 之于 ODE/SDE 极限，类似时间步长之于积分器；
- 学习率 η 之于 gradient flow 与 SDE 的“温度”控制；
- 批量 B 之于噪声方差控制；
- dataset 大小 D 之于经验风险与总体风险的差距。

如果 Discretization Hypothesis 正确，那它的可证伪含义是相当强的：**所有“取无穷反而变好”的现象都会被排除**。具体地说，“finite-size effects 总是带来代价、而不是带来收益”——它们让我们节省了计算资源，但代价是性能下降。任何能稳定地证明“小模型在某项指标上比对应的极限模型更好”的现象，都会让该假设破产。这在概念上是很优雅的：把“为什么大模型更好”这件事还原为“减小离散化误差，永远是单调的”。

实践上，这个假设暗示我们应当首先去理解“理想极限”，再把有限规模视作扰动。这正是最近几年 mean-field、 μP 、central flow 等研究的共同方法论底色。它仍未被严格证明 (见 Open Direction 5)，但它已经在事实上指导了大量工作。

2.3 捕捉宏观统计的简单经验定律

由于深度学习高度可测，直接寻找经验定律（top-down 路线）极为高效。

2.3.1 神经标度律

在固定架构家族内，最终损失 $\mathcal{L}$ 与 compute C 、数据量 D 、非嵌入参数量 N 都呈幂律关系：

$$\mathcal{L}(N) \approx \left(\frac{N}{N_0}\right)^{-\alpha_N}, \quad \mathcal{L}(D) \approx \left(\frac{D}{D_0}\right)^{-\alpha_D}, \quad \mathcal{L}(C) \approx \left(\frac{C}{C_0}\right)^{-\alpha_C}.$$

更细致的拟合（Hoffmann 等的 Chinchilla 工作）形式如

$$\mathcal{L}(N, D) = \mathcal{L}_\infty + \frac{A}{N^{\alpha_N}} + \frac{B}{D^{\alpha_D}}.$$

其中 $\mathcal{L}_\infty$ 是不可约误差（数据/任务的内禀复杂度下界）， A, B 是与训练流程相关的系数， α_N, α_D 是关键指数。Chinchilla 的核心结论是：在固定 compute 预算 $C \propto N \cdot D$ 下，最优配比近似为 $D/N \approx 20$ 而不是早先的 $D/N \approx 1.7$ （Kaplan）。

为什么 $\mathcal{L}$ 应该是幂律？ 最干净的直觉来自核回归：若数据分布在 RKHS 中诱导的核谱衰减为 $\lambda_k \sim k^{-\alpha}$ ，目标函数在该 RKHS 中的“光滑度”为 s ，则核脊回归的过剩风险服从

$$\mathcal{L}(n) \sim n^{-\beta}, \quad \beta = \frac{(2s-1)\alpha}{2s\alpha+1} \quad (\text{简化版}).$$

也就是说，幂律行为可以从“谱衰减是幂律”这一更基本的事实导出——而自然数据的核谱衰减（图像、语言）确实经验上接近幂律，其根源可能在于数据流形的内在维数、特征叠加、或潜在的层级结构。

但这并未告诉我们真实模型的 $\alpha_N, \alpha_D, \alpha_C$ 应该是多少。当前的候选解释包括：

- **数据流形维数**（Sharma–Kaplan）： $\alpha_N \sim 4/d_{\text{eff}}$ ，其中 d_{eff} 是数据所在低维流形的内禀维数。
- **特征叠加**（Liu 等）：在多语义重叠表征下，模型容量的增加能解锁新特征，幂律由“特征发现速率”决定。
- **任务结构幂律**（Michaud 等的 Quanta 模型）：任务由频率呈幂律分布的多个子任务组成，标度律来自子任务习得的累积。
- **特征学习增益**（Bordelon 等）：在 rich 极限下，特征学习把核回归的指数 β 提升到一个更大的值，给出更陡峭的幂律。

为何是幂律与指数从何而来至今没有第一性原理的预测——这是 Open Direction 7。一个真正的标度律理论应当能：(1) 给出每个候选机制成立的充分条件；(2) 在真实数据 + 真实架构上预测 α_N, α_D 的数值；(3) 解释为什么不同模态（图像、语言、代码）下的指数有差异。

2.3.2 边缘稳定性（Edge of Stability）

设损失曲面 Hessian 的最大特征值为 $\lambda_{\max}(\nabla^2 \mathcal{L})$ ，称为 sharpness。Cohen 等观察到：使用学习率 η 的全批量梯度下降，sharpness 经历两个阶段——

$$\text{阶段 1 (progressive sharpening): } \lambda_{\max} \uparrow, \quad \text{阶段 2 (edge of stability): } \lambda_{\max} \approx \frac{2}{\eta}.$$




图 3: 大型神经网络的损失沿着可预测的幂律下降。在 log-log 坐标下, 测试损失对 compute (左)、数据量 (中)、参数量 (右) 都近似呈线性, 对应于 $\mathcal{L} \propto X^{-\alpha}$ 形式的幂律。改自 Kaplan 等 (2020)。

这一现象在 fully-connected、CNN、ResNet 上都被观察到 (图 4), 与凸优化教科书完全相反: 教材告诉我们 GD 收敛要求 $\eta < 2/\lambda_{\max}$, 而真实训练里 $\lambda_{\max}$ 主动逼近 $2/\eta$ 这条理论稳定边界, 并在那里”挂着”。

为什么 $2/\eta$ 是临界? 对二次目标 $\mathcal{L}(\theta) = \frac{\lambda}{2}\theta^2$, GD 更新为 $\theta_{t+1} = (1 - \eta\lambda)\theta_t$ 。其中

$$|1 - \eta\lambda| < 1 \Leftrightarrow \lambda < \frac{2}{\eta} \quad (\text{稳定}), \quad |1 - \eta\lambda| > 1 \Leftrightarrow \lambda > \frac{2}{\eta} \quad (\text{发散}).$$

所以 $\lambda = 2/\eta$ 是稳定性的临界值。在这一点附近, 参数沿主方向每步反号 ($1 - \eta\lambda \approx -1$), 因此呈现持续振荡而幅度不发散。

自稳定化机制 (Damian 等)。 如何在非二次目标上把 sharpness 锁定在 $2/\eta$? 关键是第三阶曲率。把 GD 一步走的损失变化做 Taylor 展开:

$$\mathcal{L}(\theta - \eta\nabla\mathcal{L}) \approx \mathcal{L}(\theta) - \eta\|\nabla\mathcal{L}\|^2 + \frac{\eta^2}{2}\nabla\mathcal{L}^\top\nabla^2\mathcal{L}\nabla\mathcal{L} - \frac{\eta^3}{6}\nabla^3\mathcal{L}[\nabla\mathcal{L}, \nabla\mathcal{L}, \nabla\mathcal{L}].$$

当 sharpness 接近 $2/\eta$ 时, 沿 Hessian 顶方向 v 的振荡分量 δ_t 满足近似

$$\delta_{t+1} \approx -\delta_t + \eta^2 \langle \nabla^3\mathcal{L}, v \otimes v \otimes v \rangle \|\delta_t\|^2 + \dots$$

重要的事实是: 在大多数实际损失景观中, 三阶张量 $\nabla^3\mathcal{L}$ 的相关分量符号系统地把 sharpness 推下来。具体地, 可以证明在长时间平均意义下:

$$\mathbb{E}[\lambda_{\max}^{(t+1)}] \approx \lambda_{\max}^{(t)} - c\eta^2 \|\nabla\mathcal{L}\|^2 \cdot \langle \nabla^3\mathcal{L}, v \otimes v \otimes v \rangle,$$

即在 sharpness 已经超过 $2/\eta$ 时, 振荡幅度 $\|\delta\|^2$ 增长, 三阶项就把 sharpness 反向地拉回来——形成一个负反馈环。

Central flow: 把振荡平均掉。 Cohen 等 (2025) 把这个图像推得更远: 定义”中心流”为剔除振荡部分后的轨迹中心 $\bar{\theta}_t$, 则真实 GD 轨迹可以分解为

$$\theta_t = \bar{\theta}_t + (\text{沿不稳定方向的振荡}),$$

其中中心流 $\bar{\theta}_t$ 服从一个修正后的 *gradient flow*:

$$\dot{\bar{\theta}}_t = -\nabla(\mathcal{L}(\bar{\theta}_t) + c(\eta, B) \rho(\nabla^2 \mathcal{L}(\bar{\theta}_t))),$$

其中 $\rho(\cdot)$ 是某种曲率泛函（例如 $\|\cdot\|_*$ 或 $\lambda_{\max}$ ）， $c(\eta, B)$ 是依赖于学习率和批量的系数。这就是说，**学习率不再是动力学的”超参数”，而是一个曲率惩罚的强度调节器**。这一图像在多个真实架构上给出了非平凡的定量预测，并把 §2.4 将要讨论的”超参数解耦”问题直接连了起来。




图 4: **梯度下降发生在稳定性边缘附近**。三种架构（全连接网、VGG、ResNet）以全批量梯度下降在 CIFAR-10 上训练，学习率 η 不同。上行：训练损失。下行：Hessian 锐度 $\lambda_{\max}$ 。每条曲线都先经历 progressive sharpening，再稳定在 $2/\eta$ （虚线）附近。改自 Cohen 等 (2021a)。

2.3.3 隐藏表征与权重的简单规律

神经塌缩 (Neural Collapse)。考虑 C 类分类问题，最后一层激活 h_i 、最后一层线性分类器权重 w_c 。Papayan 等观察到，在训练终末阶段：

- **NC1 (类内塌缩)**：同一类样本的特征向量塌缩到该类均值 μ_c ，类内方差 $\rightarrow 0$ ；
- **NC2 (等距单形)**： C 个类均值向量构成一个等距等角紧框架 (ETF)，即

$$\langle \mu_a - \bar{\mu}, \mu_b - \bar{\mu} \rangle = \|\mu - \bar{\mu}\|^2 \cdot \left(\delta_{ab} - \frac{1}{C} \right);$$

- **NC3 (自对偶)**：分类器权重 w_c 与对应的 μ_c 平行；
- **NC4 (最近类均值)**：分类等价于在特征空间中寻找最近的 μ_c 。

为什么会塌缩到 ETF? Zhu 等 (2021) 在”无约束特征模型”下证明：交叉熵损失 + 弱权重衰减 λ 的最优解恰好就是 ETF 几何。直觉上，ETF 是 C 个等模长向量在欧氏空间中”两两等角且最大化最小角”的唯一构型，它把分类问题的 logits 几何刻画到了极致。这可视为 §2.1 中”贪婪低秩偏置”在分类终末的具体体现：网络在最后阶段把 C 类映射到刚好需要的 $C-1$ 维子空间，再无更多冗余。

神经特征拟设 (Neural Feature Ansatz, NFA)。Radhakrishnan 等 (2024) 观察到，训练后第一层权重的 Gram 矩阵与平均梯度外积成正比：

$$\mathbf{W}_1^\top \mathbf{W}_1 \propto \mathbb{E}_{x \sim \mathcal{P}_{\text{data}}} \left[\nabla_x f(x; \theta) \nabla_x f(x; \theta)^\top \right].$$

等式右侧叫做”平均梯度外积”(Average Gradient Outer Product, AGOP), 是一个完全由已训练的整网决定的对象。该启发式公式虽然不精确, 却能给出 $\mathbf{W}_1^\top \mathbf{W}_1$ 顶层特征向量的高精度预测, 并对深层 $\mathbf{W}_\ell^\top \mathbf{W}_\ell$ 也近似成立。

NFA 的物理直觉是这样的: 训练把第一层权重的方差集中到对网络函数最敏感的输入方向。如果 $\nabla_{\mathbf{x}} f$ 的某个方向 v 在数据分布上”幅度大”, 那么沿这个方向稍稍扰动 $\mathbf{x}$ 会显著影响输出, 因此值得让 $\mathbf{W}_1$ 在这一方向投以更多容量。理论解释只是部分的 (Boix-Adsera 等 2025 提出”Features at Convergence Theorem”给出了一种第一性的版本), 但作为可测的经验规律, 它已经被广泛用作”判断网络是否进入了特征学习”的指标。

梯度流守恒律。 深度学习里第一个被发现的守恒律来自 Saxe 等: 在 gradient flow 下, 深度线性网相邻两层之间,

$$\frac{d}{dt} (\mathbf{W}_\ell \mathbf{W}_\ell^\top - \mathbf{W}_{\ell+1}^\top \mathbf{W}_{\ell+1}) = 0.$$

这看似一个”线性网才有的怪事”, 但 Kunin、Tanaka 等把它解释为 **Noether 定理** 的直接结果。要点: 在线性网中, ”把 $\mathbf{W}_\ell$ 乘以可逆矩阵 A 、同时把 $\mathbf{W}_{\ell+1}$ 左乘 A^{-1} ” 是损失的一个连续对称——对应的 Noether 流就是上述守恒量。

更广泛地, 深度网络中存在大量类似的连续对称性, 每一种都给出可识别的守恒量:

- **ReLU 的逐神经元尺度对称:** 把第 i 个神经元入向量乘 c 、出向量除 c , 输出不变。守恒量是 $\|w_{\text{in},i}\|^2 - \|w_{\text{out},i}\|^2$ 之类的差。
- **归一化层前的尺度对称:** BatchNorm/LayerNorm 让前层权重的整体尺度不再影响输出。
- **Softmax 前 logits 的平移对称:** 所有 logits 同加一个常数不影响概率。
- **Attention 中 K, Q 的旋转对称:** $KQ^\top$ 在 $K \rightarrow KR$ 、 $Q \rightarrow QR$ 下不变 (R 正交)。

这些守恒量在 gradient flow 下严格保持, 被 SGD 的离散和噪声以可预测的方式弱破缺——这给训练动力学的近似分析提供了一组干净的”积分常数”。守恒律还提供了一种判别隐式正则化方向的工具: 知道哪些量是守恒的, 反过来就知道哪些量可以被改变, 进而判断训练会朝哪个方向走。

Top-down 路线对理论家的启示。 本节几个例子 (神经标度律、EoS、neural collapse、NFA、守恒律) 共同提示一种工作方式——**top-down 路线**: 先用大量实验在”宏观可测量”层面找出稳定规律, 再倒回去寻找解释。深度学习的可测性使这条路异常高效; 论文鼓励理论家更主动地用这种方式工作。需要注意的是, 这条路有两个常见陷阱: (1) 大多数宏观统计量并不服从简单定律——选对要追的量很关键; (2) 表面上的规律可能只是某种有限规模效应, 要在多种规模和设定下交叉验证。

2.4 超参数的解耦与理解

物理学里常通过量纲分析从一长串参数里剥离出真正”独立”的少数 (如雷诺数)。深度学习正在发生类似的事。

2.4.1 学习率与批量的线性标度律

把 SGD 视作一个噪声扰动的连续动力学的离散化。设 mini-batch 上的随机梯度 g_t 满足 $\mathbb{E}[g_t] = \nabla \mathcal{L}$ 、 $\text{Cov}[g_t] = \Sigma(\theta)/B$ (B 是 batch size)。则 SGD 更新

$$\theta_{t+1} = \theta_t - \eta g_t$$

在合适极限下被一个 SDE 近似：

$$d\theta_t = -\nabla \mathcal{L}(\theta_t) dt + \sqrt{\frac{\eta}{B} \Sigma(\theta_t)} dW_t.$$

这里”温度” $T = \eta/B$ 是控制噪声强度的唯一无量纲数。该 SDE 视角直接预言了 **linear scaling rule**：学习率 η 与批量 B 同步加倍而保持比 η/B 不变，则训练轨迹基本不变。这条经验法则在大模型预训练里被广泛使用——把单卡的 η 推广到多卡时，只要保持 η/B 不变即可保留训练曲线形态。

对自适应优化器（Adam 类），相应的 SDE 推导给出

$$\eta \propto \sqrt{B},$$

即 Adam 类下学习率应按 $\sqrt{B}$ 标度（Malladi 等）。直觉上是因为 Adam 的预条件 $\sqrt{\mathbb{E}[g^2]}$ 已经把噪声方差吸收进了”自适应步长”中，所以净效应不同于纯 SGD。

批量大小的选取：critical batch size。 SGD 的实际加速曲线呈”先线性、后饱和”的形态：把 B 从 1 增大到某个临界值 B^* 之前，达到给定损失所需的总训练步数大致按 $1/B$ 减少；超过 B^* 后增益快速衰减。McCandlish 等（2018）给出一个简单模型：

$$\frac{T(B)}{T_\infty} = 1 + \frac{B^*}{B},$$

其中 $T(B)$ 是达到目标损失所需的 SGD 步数， T_∞ 是 $B \rightarrow \infty$ 极限值。这个模型预言了**时间-计算前沿**是一条双曲线：训练时间和总计算量 $C = B \cdot T(B)$ 之间不存在 Pareto 改进的方向，二者在 B^* 附近达到”折衷点”。 B^* 本身依赖于损失景观与梯度噪声结构，是衡量”问题有多容易并行化”的核心量。

2.4.2 学习率作为曲率正则

一系列结果表明，对损失做三阶 Taylor 展开后可证明：振荡或随机的优化动力学等价于在原损失上加了一个曲率惩罚。Cohen 等（2025）把它写成 *central flow*：

$$\dot{\theta} = -\nabla(\mathcal{L}(\theta) + c(\eta, B) \|\nabla^2 \mathcal{L}(\theta)\|_*).$$

其中 $c(\eta, B)$ 是与超参相关的曲率惩罚系数。这意味着一旦”学习率”的角色被理解为”曲率正则强度”，我们就可以把学习率从动力学里消掉，转而研究更简单的 gradient flow + 曲率惩罚。

2.4.3 μP 与超参数迁移

Tensor Programs（Yang 等）框架把所有”宽度依赖的超参数”统一写成

$$\eta = \eta_0 \cdot n^{c_\eta}, \quad \alpha_{\text{init}}^{(\ell)} = \alpha_0^{(\ell)} \cdot n^{c_\alpha^{(\ell)}}, \quad \alpha_{\text{out}}^{(\ell)} = \beta_0^{(\ell)} \cdot n^{c_\beta^{(\ell)}},$$

其中 n 是隐藏宽度， $c_\eta, c_\alpha^{(\ell)}, c_\beta^{(\ell)}$ 是要确定的标度指数。要求是 $n \rightarrow \infty$ 时每一层的激活、梯度、权重更新都保持 $\Theta(1)$ ，这就给出关于这些指数的一组线性约束。

两个非平凡解。 解这组约束得到的非平凡（既非冻结也非发散）的标度只有两组：

- **NTP (Neural Tangent Parameterization)**: 对应 LeCun 初始化 + 输出层 $1/\sqrt{n}$ 标度。结果：特征冻结——前向激活的统计在训练中与初始化一致，等价于 NTK 核回归。
- **μ P (Maximal Update Parameterization)**: 对应输出层 $1/n$ 标度 + 学习率按层 $1/n$ 标度。结果：特征演化——每一层的激活在训练后获得 $\Theta(1)$ 的更新。

“Maximal Update”这个名字的含义是：在所有不让训练发散的参数化中， μ P 是允许特征更新最大的那个。

μ Transfer: 超参数的零样本迁移。 μ P 最具实用价值的推论是：在 μ P 下，**最优学习率 η_0 几乎不依赖于宽度 n** (图 5)。也就是说，在小宽度上调出最优 η_0 ，可以零样本迁移到大得多的宽度上仍然接近最优。这就是著名的“ μ Transfer”——用小代理模型调超参后直接用于生产规模模型，节省可观的计算成本。例如 Yang 等 (2022) 报告，从 13M 参数模型迁移到 6.7B 模型，只需 7% 的预训练 compute 来调参，便可超越 GPT-3 6.7B 的公开基准。

为什么 μ Transfer 工作？ 直觉是这样的：学习率的“角色”是控制每一步参数更新的相对幅度。在 NTP 下，由于输出层标度 $1/\sqrt{n}$ 已经把更新缩小了，学习率必须随 n 重缩放才能保持等价的更新；而在 μ P 下，标度的设计使“每一步 $\Theta(1)$ 的特征更新”独立于 n ，所以相同的 η_0 在不同 n 下产生等效的训练轨迹。

扩展与限制。 这一思路已被推广到深度方向 (depthwise hyperparameter transfer, Bordelon 等 2023; CompleteP, Dey 等 2025)，并部分推广到 attention 头数与 MoE 专家数等其它方向。但理论本身是渐近的——在数据-宽度比有限、训练时间有限的实际情形下， μ Transfer 的有效程度依赖于若干谱量 (如 NTK 谱稳定性, Noci 等; fast hyperparameter transfer 机制, Ghosh 等)。把 μ P 扩展到所有相关的标度方向，是 Open Direction 6 的核心内容。

2.5 跨设定的普适现象

深度学习用截然不同的架构、目标、数据集，却往往达到相似的最终表现与表征。论文从三方面呈现这一普适性的证据。这种现象在物理学里有深刻先例：临界普适类告诉我们，截然不同的物质（液-气、铁磁体、合金）在二阶相变附近表现出由同一组临界指数刻画的行为，背后是重整化群对微观细节的“清洗”——只有少数粗粒化变量在大尺度上保留下来。深度学习里看到的这种跨架构、跨模态趋同，提示一个相似的可能：在恰当的“放大尺度”上，模型选择的微观细节“被洗掉了”，剩下的只是少数几个由数据决定的宏观量。

(1) 架构间的归纳偏置普适。 ConvNet 与 ViT 在视觉任务上同等 compute、同等数据下表现接近；这在 ConvNeXt (Liu 等 2022) 与 Smith 等 2023 的研究中被反复验证。更引人注目的是，扩散模型用 UNet 和 transformer 在同一噪声种子下生成几乎一致的图像 (Zhang 等 2024, 图 6a)——这意味着收敛的不只是分布，而是逐样本的输入-输出映射。这强烈暗示：架构的归纳偏置归根结底由少数共享性质支配。Kadkhodaie 等 (2024) 与 Kamb & Ganguli (2025) 证明，假设两个核心偏置——**局部性**（卷积式的局部连接）与**对几何结构的自适应**（小波/分数阶处理）——便足以定量预测扩散模型的多种行为。这是把“普适性”从经验观察推向可推导命题的第一步。




图 5: μP 让最优学习率在不同宽度间稳定, 从而支持跨规模迁移。不同宽度的 transformer 在 WikiText-2 上训练, 左为标准参数化 (standard practice), 右为 μP 。在标准参数化下, 最优学习率随宽度增大而显著左移; 在 μP 下则几乎不变——使得用小模型调出的 η_0 可以迁移到大得多的生产模型。改自 Yang 等 (2022)。

(2) 数据中的普适统计结构。 no-free-lunch 定理告诉我们: 完全任意的数据上没有普适的学习算法。所以深度学习能成功, 必然依赖于真实数据的某些普适特征。这些特征跨模态出现:

- **幂律谱**: 图像与音频的功率谱呈 $S(\omega) \sim \omega^{-\alpha}$, 分别在 $\alpha \approx 2$ 与 $\alpha \approx 1$ 附近。
- **稀疏性与多尺度结构**: 自然图像与音频在小波基下天然稀疏。
- **Zipf 律**: 在自然语言乃至许多人造语言里, 单词频率随其排名呈幂律 $P(\text{rank} = r) \propto r^{-s}$, $s \approx 1$ 。
- **层级化组合结构**: 图像由部件构成对象, 文本由词构成短语再构成句——把这视为一类共有的“分层组合生成模型”已成为活跃研究领域。

这些共有的统计特征是单一架构 (如 transformer + SGD) 能横扫多模态的根本原因。

(3) 表征普适性。 不同架构、不同初始化、不同模态下训练得到的网络, 其内部表征出现了趋同——所谓“**Platonic Representation Hypothesis**” (Huh 等 2024, 图 6b): 随着模型规模与性能增加, 语言模型与视觉模型 DINOv2 的对齐度单调上升, 仿佛各路模型都在向某种“理念中的真表征”靠拢。

在随机特征模型中这是大数定律的直接结论

$$K_n(\mathbf{x}, \mathbf{x}') = \frac{1}{n} \sum_{i=1}^n \phi(\mathbf{x}; w_i) \phi(\mathbf{x}'; w_i) \xrightarrow{n \rightarrow \infty} \mathbb{E}_w[\phi(\mathbf{x}; w) \phi(\mathbf{x}'; w)] = K(\mathbf{x}, \mathbf{x}');$$

对深度线性网络, 可证明 SGD 的隐式正则化导致表征收敛 (Ziyan & Chuang 2025); 对一般情形, 这种普适性可能根源于数据本身的普适结构 (Karkada 等 2026) ——也就是说, 模型趋同最终只是数据决定了表征的同一句话的另一种说法。

在随机特征模型中这是大数定律的直接结论

$$K_n(\mathbf{x}, \mathbf{x}') = \frac{1}{n} \sum_{i=1}^n \phi(\mathbf{x}; w_i) \phi(\mathbf{x}'; w_i) \xrightarrow{n \rightarrow \infty} \mathbb{E}_w[\phi(\mathbf{x}; w) \phi(\mathbf{x}'; w)] = K(\mathbf{x}, \mathbf{x}');$$

对深度线性网络，可证明 SGD 的隐式正则化导致表征收敛 (Ziyin & Chuang 2025)；对一般情形，这种普适性可能根源于数据本身的普适结构 (Karkada 等 2026)——也就是说，模型趋同最终只是数据决定了表征的同一句话的另一种说法。

度量的陷阱。 论文也警告：是否“相似”在很大程度上取决于所用度量。CKA、stitching、邻近核对齐、Bures 距离、CCA 等指标会给出有时矛盾的结论。Gröger 等 (2026) 甚至指出，原始 PRH 的部分结论在不同度量下并不稳健。这就是为什么 Open Direction 10 把“找到合适的相似性度量、确定表征普适类的边界”放在一起作为关键问题——**先要解决“相似的标准是什么”，才能定量谈论“普适到什么程度”。**




图 6: 架构与模态都不同的模型趋于学到相似的表征。(a) 三种扩散模型架构 (DDPM、一致性模型、U-ViT) 在同一噪声种子下生成几乎一致的图像。(b) 随着语言模型性能增长 (横轴)，其内部表征与视觉模型 DINOv2 的对齐度也单调上升；模型越大趋势越显著。这一组观察被概括为“Platonic Representation Hypothesis”。改自 Zhang 等 (2024) 与 Huh 等 (2024)。

3 与其他视角的关系

作者在第 3 节强调，学习力学与若干其他视角是互补而非竞争的。理解这些关系，能帮助我们看清学习力学在整个深度学习理论生态中的位置。

统计视角。 经典学习理论 (Bartlett 等) 的核心问题是：任何统计预测方法都必须在三个目标间平衡——**表达力** (能否表征足够丰富的目标)、**复杂度控制** (能否在有限样本下不过拟合)、**计算效率** (能否被实际算法找到)。深度学习的“反常”在于：它的表达力极大、复杂度看似失控、损失景观非凸，却奇迹般地同时满足三者。现代统计观点给出两个候选回答：(1) **隐式偏置**使得 SGD 训练只在一个有效维度低得多的子空间中游动；(2) **过参数化**让损失景观局部“被压平”，使非凸

优化变得近似凸。这两条都需要进一步落地——而落地的方式必然是一个关于训练动力学的具体描述。这就是为什么统计视角不可避免地指向学习力学。

信息论视角。 另一种解释把学习理解为**压缩**：训练就是把数据集中“对预测有用的信息”压进权重或隐表征里，“无用信息”则被丢弃。Tishby 等的“信息瓶颈”假说提出了一个具体猜测：训练过程包含两阶段——先记忆（互信息上升），再压缩（互信息下降）。这条思路富有启发性，但要真正可操作，还需要明确：什么是“有用信息”、压缩沿什么方向发生、什么动力学机制实施这种压缩——所有这些问题都需要打开训练过程这个黑箱。

深度学习的物理学。 从 Hopfield 网络（1982）、Gardner 的复制对称分析（1988）、Saad-Solla 的教师-学生 SGD 动力学（1995），到当代的 Bahri、Pehlevan、Zdeborová、Ringel 等工作，统计物理学家已经持续做了四十年的“机器学习的物理”。本文实际上是这一传统的当代重命名与组织化——learning mechanics 这个名字承认了它的物理学血统。值得一提的是，2024 年诺贝尔物理学奖颁给 Hopfield 与 Hinton，正是对这条联结的官方背书。

神经科学视角。 “Bayesian brain”假说认为生物神经系统在做近似概率推断——它有时给出的预测在深度学习里得到了对应（如 Olshausen-Field 视觉皮层的稀疏编码与 ConvNet 早期层的边缘检测器）。系统神经科学也在研究“群体几何”，试图把神经活动的高维结构与具体认知任务关联——其方法论与机制可解释性高度相似。

发展可解释性 / 奇异学习理论。 Watanabe 的 Singular Learning Theory (SLT) 框架从损失曲面的代数几何出发，把训练理解为景观奇点结构所驱动的相关变序列。该社区 (Hoogland 等) 做的“developmental interpretability”与本文的目标重合（都希望先解释机制如何形成），但用了不同工具——这是良性互补，而非竞争。

学习力学 $\rightleftharpoons$ 机制可解释性

作者对这一对关系着墨最多，定调是**对称的相互滋养**。理解这种关系，需要先明白两个学科各自的方法论局限。

机制可解释性追求的是对单个具体模型的具体行为的细致逆向工程：identifying induction heads、画 attribution graph、寻找单义特征 (monosemantic features)。这是有效的，但其工具更接近自然历史 (natural history) ——大量精细的个案描述，对单个模型成立的结论未必对其它模型成立。它与**生物学**的方法论一致：先发现现象、给现象命名、再追问机制。

学习力学追求的是跨模型适用的、第一性的、定量的规律。它的方法是统一的：从动力学方程出发，在合适极限下推出可验证预测。这与**物理学**的方法论一致。

两个学科在不同抽象层工作，谁也无法离开对方。它们之间的滋养是双向的：

学习力学 $\rightarrow$ 机制可解释性。

- **形式化核心假设。** 机制可解释性依赖一些常被默认却未被证明的假设：线性可表征（特征对应激活空间中的方向）、定位性（特征/电路集中于特定层或子空间）、稀疏性（特征只在少数

输入上激活)、组合性(复杂行为由简单子机制组合)。学习力学有可能为这些假设给出可证伪的形式化版本——即在什么动力学条件下它们必然出现,又在什么条件下它们会失败。

- **解释机制如何形成。**机制可解释性主要描述已有什么,但回答不了怎么形成的: induction heads 为什么在训练中突然涌现? grokking 的相变是怎么发生的? 相变前后电路结构如何重组? 这些问题在本质上都是动力学问题,是学习力学应当回答的。

机制可解释性 → 学习力学。

- **提供”现象学清单”。**物理学的不少进步来自实验先发现现象(黑体辐射、超导)再促理论。机制可解释性发现的现象——induction heads、Fourier 特征在算术任务中的浮现、特征几何由数据相关性决定——为学习力学提供了具体的、定义良好的目标。
- **把数据结构推到前台。**经典理论的设定(高斯输入、教师-学生)回避了真实数据的结构。机制可解释性研究发现,数据结构(语言中的算法结构、视觉中的局部性)才是机制形成的根本驱动力。这把”理论必须容纳真实数据”这件事从一个软建议变成了硬要求——这正是 Open Direction 2 的内容。

核心要点

作者使用了一个很到位的类比: 机制可解释性是深度学习的”生物学”, 学习力学是它的”物理学”。两者各自工作于不同的抽象层,但谁也无法离开对方——**物理学告诉生物学”分子如何相互作用”,生物学告诉物理学”哪些分子的相互作用值得研究”。**

4 对常见怀疑论的回应

第 4 节回应了若干”理论不可能或不值得做”的常见质疑。这些质疑有真实分量,作者对每一条的回应也值得严肃对待。

”努力了几十年都没出来,为什么现在就行?” 这是最常见也最容易被高估的怀疑。作者给出三层回应:

- **对象变了:** 现代大规模深度学习是非常新的研究对象。许多关键现象(神经标度律、表征普适性、grokking 等)只有在最近 5-10 年才显现。一个尚未出现的对象,自然也无人能为它建立理论。
- **科学已经从”证明”转向”经验”:** 过去几十年的深度学习”理论”主要在尝试可证明的保证(PAC 界、收敛速率),这条路径在过参数化上失灵不奇怪。把任务重新定位为科学(描述-解释-预测),就可以利用深度学习极强的可测性这一巨大优势。
- **社区扩张:** 物理、数学、神经科学、统计的学者大量涌入。多学科混合通常是基础理论加速突破的前奏。

”被理解的对象太初等,配不上 LLM” 这条质疑承认基础研究有用,但怀疑它能否企及 LLM 这样的规模。作者的回应是**不必从一开始就解释 LLM:**

- 已有的”局部理论”已经在改变实践：神经标度律指导预算分配； μP 让超参数可零样本迁移；NTK 数据归因（如 TRAK）让”哪个训练样本贡献了哪个预测”可计算；理论激发的优化器（Shampoo, Muon）已在大模型训练里见到效益。
- 类似地，电磁学不需要解释每一台具体的雷达就能为雷达工程提供基础；学习力学也无需”解释每一个 LLM”才有用，它要做的是把构件理解清楚。

”重要的是模型的高层行为，微观理论看不见” 这条质疑反映了一个真实的多层次研究需求。作者借用 Marr’s three levels of analysis 的框架来组织：

- 物理实现层 (physics)：学习力学，关心训练动力学和参数演化；
- 算法实现层 (biology)：机制可解释性，关心模型在干什么；
- 计算目标层 (psychology)：模型行为科学，关心模型的能力、个性、目标。

三层各有其语言，相互不可替代，但相互支持。

”我们需要的是数据理论，不是深度学习理论” 作者完全同意”必须有数据理论”，但反对将其与”深度学习理论”对立。学习力学的目标本来就是数据-模型耦合，把数据结构作为不可分割的输入。Open Direction 2 是这一立场的具体宣言。

”AI 自己会先理解自己” 这是一个面向未来的怀疑。作者的回应朴素但有力：(1) 即便如此，理论已经有用，不必等到那一天；(2) 突破性进展更可能由使用 AI 工具的人类专家做出，而非完全自主的 AI；(3) 从 AI 安全角度，能被人类理解的理论本身就是必需的——否则我们等于把所有理解寄托在那些我们想要监管的对象身上。

5 十大开放方向

第 5 节集中给出十个被作者认为可在未来十年内取得显著进展的方向。下面摘录并对每条做一句简评。

Open Direction 1: 真正”深”且”非线性”的可解模型

当前两类主力可解模型——深度线性网（数据线性）与核方法（参数线性）——各自只覆盖一种非线性。统一框架尚未出现。可能的方向是结构化数据 + 单/多指标目标 + 二次激活的协调设定。这条路有望让我们第一次写出”既保留特征学习、又保留非线性表达力、还能精确求解”的玩具模型；它对验证 §2.2 中各种 mean-field 极限是否真正抓到了非线性核心至关重要。

Open Direction 2: 能容纳真实数据的理论

数据结构必须进入理论。少量充分统计量（如谱、稀疏度、层级深度）究竟是什么？是否随训练阶段而变？这是从”模型为中心”走向”数据-模型耦合”的关键。一个可能的工作模式是：用一个有限参数化的”数据模型”（例如分层组合模型、随机层级模型）作为合成数据集，使理论得以闭合，再以经验估计这些参数对应于真实数据集中的哪个位置——把”数

据特征”从一个模糊概念变成可拟合的若干个数。

Open Direction 3: 深度学习是否隐式最小化某种函数复杂度？

若是——是 Kolmogorov、电路、权范数还是别的？该极小化在哪些极限下精确？机制可解释性观察到的稀疏特征/电路是否是该极小化问题的解？这条线一旦走通，就为“过参数化为何不过拟合”提供了一个完全独立于经典 VC 维的理由——是动力学诱发的隐式正则让网络选择简单解，而非容量受限让它无法记住复杂解。

Open Direction 4: 如何形式化”特征”？

把”特征、电路、机制”这些机制可解释性的核心概念给出第一性原理的数学定义，并据此评估线性可表征、定位性、稀疏性、组合性等核心假设。一个有用的判定指标是：定义是否让我们预言某种特征会在何时出现——而不仅是识别它已经出现。

Open Direction 5: 有限网络是否就是无穷网络的离散近似？

即”离散化假设”。给宽度、深度、 η 、 B 、训练步数都找到对应的连续/极限对象，并把有限规模视作其离散误差。证明这一图像意味着：任何关于”小模型在某项指标上比大模型更好”的现象都不能再被接受为基础事实。这是一条强假设——它一旦成立，就为整个理论提供了”先解极限、再加修正”的标准范式。

Open Direction 6: 能否消去全部超参数？

μP 是把宽度与学习率解耦的代表。能否在所有维度上完成解耦——上下文长度、注意力头数、专家数、batch size、训练时间？最后剩下的”最小描述”是什么？是否存在不可约的超参数？这条问题的答案，决定了我们能在多大程度上消除大模型训练中”调参”这一暗黑艺术。

Open Direction 7: 能否预言标度律指数？

经验上 $\alpha_N, \alpha_D, \alpha_C$ 都不是平凡的有理数（如 $1/2, 1/4$ ），至今没有从架构 + 数据出发的可信第一性预测。这是检验所有标度律理论的金标准。一个具备说服力的解释，应当能从一个候选数据-架构假设出发算出这些指数，并在不同模态（视觉、语言、代码）下做出可分辨的区分预测。

Open Direction 8: 曲率与架构、特征、泛化的相互作用

为什么 progressive sharpening 普遍存在？曲率正则如何选择特征、又如何影响泛化？central flow 的图像能否被推广到随机与自适应优化器？这条问题的紧迫性在于：如果”学习率 = 曲率惩罚强度”这一图像在更广的优化器上成立，那么我们就有了一种把所有一阶 + 二阶优化器纳入同一坐标的方法——而这是把 Adam vs. SGD vs. Muon 之间的差异写成可证伪命题的前提。

Open Direction 9: 什么是”好”的优化器？

Muon、Shampoo、Adam 与 SGD 在大模型上的差异从何而来？自适应预条件（preconditioning）如何与架构、损失景观共谋？这是工程上”日日相见”却理论上仍很糙的问题。一个可能的切入是：把每个优化器视为某个度量下的 gradient flow（Adam 对应于”对角化的自然梯度”，Shampoo 对应于”Kronecker-分解的自然梯度”，Muon 对应于”谱范数下的最速下降”），再问**哪一种度量与神经网络的内禀几何最匹配**——这是把”优化器选择”还原为”几何选择”的纲领。

Open Direction 10: 表征普适性的意义

不同种子、宽度、架构、模态下学到的表征”相似”——但相似的度量是什么？哪些度量在训练过程中稳定？跨多大范围内能观察到收敛？是否存在表征的”普适类”？这一问题的解答会反过来影响理论的工作方式：如果普适类存在，则我们有理由用一个简化的代表性模型替代真实模型来研究普适特征——这正是物理学里凝聚态理论行之有效的工作模式。如果普适类不存在或边界模糊，则学习力学的每一个结论都需要更多的”模型族-架构-数据”组合上重新验证。

6 阅读总结

6.1 一段话压缩

核心要点

深度学习并非一个不可言说的黑箱。它的方程是显式的，所有量都可测量；横亘在我们与理论之间的不是不可见性，而是高维非线性耦合带来的复杂性。过去十几年里，针对这种复杂性，深度学习理论已悄悄积累了五类可观的成果：解析可解的玩具模型、宽度/深度/批量等极限分析、用幂律与稳定阈值等简洁定律刻画的宏观规律、把超参数从动力学中剥离的标度框架、以及跨架构与跨模态的表征趋同。这五条线放到一起，是一种关于学习过程的力学雏形——**learning mechanics**。它在精神气质上更接近物理学的连续介质力学和统计力学，而不是经典数学化的 PAC 学习理论。把它做扎实，不仅是科学好奇心的回报，也将让训练大模型从”试错”过渡到”工程化”。

6.2 方法论复盘：五条证据线在做的同一件事

把全文五条证据线放在一起，能看出它们其实在各自实现同一种方法论操作——**用对的简化把不可解问题变成可解问题**：

- **解析可解模型** (§2.1) 通过摘掉一种非线性——要么数据非线性、要么参数非线性——换取闭合解。用得最深时它揭示贪婪低秩偏置这种跨架构稳健的隐式现象。
- **极限分析** (§2.2) 通过取若干维度趋于无穷使有限维耦合系统变成 PDE/SDE/Gaussian process 等可解对象。它告诉我们 lazy/rich 二分、 μP 的存在性、深度的连续/扩散两种极限。

- **经验定律** (§2.3) 走相反方向——先寻找宏观稳定规律，再倒推机制。神经标度律、edge of stability、neural collapse、NFA 都是这条路径的产物。
- **超参数解耦** (§2.4) 通过把超参数解释为 *effective system parameters*——learning rate 是曲率惩罚强度、batch 是噪声温度、 μP 让 width 不再影响 lr——把”调参”约简为”理解效应”。
- **普适现象** (§2.5) 则告诉我们：上面几条线得到的结论不是只对某一具体模型成立，而是在合适的度量下跨架构、跨模态稳健——这是任何科学理论可推广性的前提。

把这五条线总结为一句话：深度学习的复杂性是**表观的**，在合适的极限、合适的标度、合适的度量下都会被压成简单系统——这正是物理力学的工作方式。

6.3 若干值得追的具体线索

下面给出几条读完后我认为最值得在中短期内继续追的线索：

1. **把”central flow”图像推广到随机与自适应优化器**。这条线一旦走通，就为我们提供了一种”先解 gradient flow、再用曲率惩罚改写真实优化器”的标准做法。它把 η 与 B 这两个最难写进理论的超参数变成了修饰项，使整个超参数空间在数学上塌缩到一个干净的低维流形上。
2. **μP 在深度、上下文长度、专家数等方向的扩展**。 μP 之所以有用，并非因为指数取得”漂亮”，而是因为它在数学上保证了无穷极限的存在性。把这种存在性论证推广到 transformer 的全部缩放维度 (width、depth、context、head、expert)，是连接理论与训练实践最直接的接口。这同时也是对” μ Transfer 在大规模上是否仍然有效”这一工程问题的最干净答复。
3. **标度律指数的第一性预测**。Open Direction 7 是检验所有候选理论（数据流形维数、特征叠加、特征学习增益、潜在任务分布幂律等）的金标准。一旦有一个框架能在真实模型上做出此类预测且被实证证实，它必将重新定义”成熟的深度学习理论”应是什么样子。这种里程碑会与 Planck 黑体辐射、Hubble 红移之类的工作具有可比的意义——从一个基本假设算出经验定律的指数。
4. **表征普适类的合理度量**。今天我们说”两个网络学到了相似表征”时，结论可能取决于所选度量 (CKA、stitching、NN 对齐、Bures 距离、CCA 等)。在度量统一之前，”相似”本身是开放的。在更深一层，这个问题指向一个数学问题：在过参数化模型空间上是否存在一个自然的度量，让”训练动力学”在该度量下成为良定义的几何流？
5. **把机制可解释性的核心假设——线性可表征、定位性、稀疏性、组合性——升级为可证伪命题**。这与 Open Direction 4 一致，是连接学习力学与机制可解释性的”翻译层”。可证伪意味着：给定假设的数学定义，应当有可设计的实验来检验它在何时成立、何时失败。
6. **把 NTK $\rightarrow$ mean-field 的过渡视作一个连续相图**。lazy/rich 二分是一种”两态描述”，但 Chizat 等已经表明，控制 α 可以在两态之间连续过渡。是否存在一个完整的”特征学习相图”，把当前已知的所有动力学 (NTK、mean-field、saddle-to-saddle、greedy low-rank) 作为不同区域的局部行为？这种相图视角会让深度学习的训练动力学第一次有了”凝聚态物理”式的可视化语言。

6.4 对青年研究者的建议

最后，作者在第 6 节给的几条建议平实但耐读。这些建议不是在告诉我们”如何快速发顶会”，而是在告诉我们”如何为一个尚在形成的科学做出长期可见的贡献”：

1. **频繁做实验**。深度学习实验便宜、迭代快——理论家应当主动用实验检验自己的假设、暴露模型的边界、发现新的可被解释的规律。
2. **追求简洁洞察而非技术复杂度**。一个让人理解的简单论点，比一个让人佩服的复杂证明影响更大。会议系统会奖励技术复杂度，但长期影响来自简洁。
3. **看重理解而非 SOTA**。把”自然引出工程收益”作为副产品而不是主目标。强行往科学论文里塞 benchmark 改进，常常稀释了科学贡献。
4. **不要单干**。深度学习有大量背景知识，独立做太慢。寻找合作者，看 talk (Physics Meets ML、Physics of Learning 系列) 会让你少走很多弯路。
5. **早期多换问题**。在确定主攻方向前，多领域涉猎能让你形成”高层视角”。
6. **投资基本工具**。统计物理、随机矩阵、最优控制、信息论、信号处理——这些经典工具一旦掌握，会反复用得着。

这是一份诚恳的入门指南。把这些建议结合本文五条证据线的方法论概貌，应当能让一个有数学基础的新人在 6–12 个月内进入到”能产出原创工作”的状态。

原文与延伸资料：作者团队同步建立了 learningmechanics.pub 作为社区门户，列举开放问题、整理引论资料并提供讨论区。