

第 11 周：在线优化与 Regret 框架

从 Multiplicative Weights 到 Bandit，再到贝叶斯最优学习

优化算法课程讲义

摘要

本讲我们进入一个**信息受限**的世界：边做决策边学习，甚至看不到”如果当时选了别的会怎样”。神奇的是，即使面对一个处心积虑要坑你的对手，我们的后悔值也只有 $O(\sqrt{T})$ ——平均每轮的后悔趋于零！

目录

1 开场：这门课在讲什么？	3
2 Regret：后悔值	3
3 Multiplicative Weights：指数惩罚	6
3.1 MWU 的 Regret 界	8
4 Hoeffding 不等式：估计有多准	11
5 Multi-Armed Bandit：探索与利用	13
5.1 ϵ -Greedy：最简单的方法	14
5.2 UCB：乐观面对不确定	15
5.3 UCB 的 Regret 证明	17
6 Thompson Sampling：贝叶斯方法	20
6.1 Beta 分布：硬币的后验	20
6.2 Thompson Sampling 算法	21
6.3 Thompson Sampling 的理论保证	23
7 最优学习：从累积收益到最终决策	24
7.1 问题形式化	25
7.2 信息的价值	25
7.3 从 VPI 到 Knowledge Gradient	27
7.4 KG 的计算	27
7.5 KG 策略	30

8 贝叶斯优化：连续空间的最优学习	30
8.1 问题设定	30
8.2 高斯过程：函数的后验	31
8.3 采集函数：连续空间的 KG	33
8.3.1 Expected Improvement (EI)	33
8.3.2 GP-UCB：乐观原则的连续版	34
8.4 采集函数的统一视角	35
9 应用：A/B 测试的最优停止	37
9.1 问题设定	37
9.2 贝叶斯分析	37
9.3 Expected Loss：决策的代价	38
9.4 何时停止：信息价值 vs 成本	39
10 为什么是 $\sqrt{T}$：信息论下界	40
10.1 下界定理	40
10.2 证明思路	40
10.3 从下界到 $\sqrt{T}$	42
10.4 $\log T$ vs $\sqrt{T}$ ：量词顺序的故事	43
11 总结	45

1 开场：这门课在讲什么？

大白话

想象你刚到一个新城市，要选餐厅吃饭。

情况 1：你有一本完整的点评手册，可以先看完所有餐厅评分再决定去哪家。这是**监督学习**——信息完整，决策简单。

情况 2：你没有手册，但每次吃完一家，你能看到当天所有餐厅的评分（比如朋友圈都在晒）。这是**在线学习**——信息逐步揭示，但你能看到”没选的那些怎么样”。

情况 3：你没有手册，吃完一家只知道这家好不好吃，其他餐厅今天表现如何完全不知道。这是 **Bandit 问题**——信息最少，最难！

今天的问题是：**在信息这么少的情况下，我们还能学得多好？**

例 1.1 (股票投资的三种视角). 3 只股票，10 天：

监督学习：先看完 10 天数据，选累计涨最多的。简单！

在线学习：第 1 天选 A，收盘看到 A 涨 5%，B 跌 2%，C 涨 1%。第 2 天可以换。

Bandit：第 1 天选 A，只知道 A 涨 5%。B 和 C 今天涨跌？不知道！

2 Regret：后悔值

大白话

Regret 就是**后悔程度**的数学定义。

想象游戏结束后，上帝告诉你：“其实你要是一直选专家 2，总共只亏 100 块；但你瞎选来选去，亏了 150 块。”

那 50 块的差距，就是你的 Regret。

注意：我们比的是”一直选某一个固定选项”的最佳结果，不是”每轮都选当时最好的”——后者是上帝视角，凡人做不到。

定义 2.1 (Regret).

$$\text{Regret}_T = \underbrace{\sum_{t=1}^T \ell_t(x_t)}_{\text{你的总损失}} - \underbrace{\min_{x \in \mathcal{X}} \sum_{t=1}^T \ell_t(x)}_{\text{最佳固定策略}}$$

Regret 的具体计算

2 个专家, 5 轮, 损失在 0 到 1 之间 (越小越好):

轮次	专家 1 损失	专家 2 损失	你选谁	你的损失
1	0.3	0.7	专家 1	0.3
2	0.8	0.4	专家 1	0.8
3	0.5	0.5	专家 2	0.5
4	0.9	0.2	专家 2	0.2
5	0.4	0.6	专家 1	0.4
总计	2.9	2.4	—	2.2

你的总损失 $= 0.3 + 0.8 + 0.5 + 0.2 + 0.4 = 2.2$

最佳固定策略: 一直选专家 2, 总损失 $= 0.7 + 0.4 + 0.5 + 0.2 + 0.6 = 2.4$

Regret $= 2.2 - 2.4 = -0.2$

负的! 说明你比”一直选专家 2” 还好。因为你能动态切换。

负的 Regret ?

Regret 可以是负的! 这说明动态切换比傻傻坚持一个选项更好。

但问题是: 如果对手知道你的策略, 专门设计损失来坑你呢?

被对手坑惨的例子

你的策略：“跟着赢家走”——谁昨天表现好，今天就选谁。

对手知道你的策略，故意这样设计损失：

轮次	专家 1 损失	专家 2 损失	你选谁（跟昨天赢家）	你的损失
1	1	0	随机选 1	1
2	0	1	选 2（昨天 2 赢了）	1
3	1	0	选 1（昨天 1 赢了）	1
4	0	1	选 2	1

对手让你**每轮都选错**！

$T = 1000$ 轮后：

- 你的总损失 = 1000
- 专家 1 的总损失 = 500
- 专家 2 的总损失 = 500
- **Regret = 1000 - 500 = 500**

Regret 是 $T/2$ ，线性增长！平均每轮后悔 0.5，永远不会变好。

Regret 的量级意味着什么

假设跑 $T = 10000$ 轮：

Regret 量级	具体值	平均每轮	含义
$O(T)$	5000	0.5	废了，没学到东西
$O(\sqrt{T})$	100	0.01	牛！ 平均后悔趋于 0
$O(\log T)$	9.2	0.00092	超牛，但需要更强假设

目标：设计算法，让 Regret 只有 $O(\sqrt{T})$ ，这样时间越长我们越接近最优！

3 Multiplicative Weights: 指数惩罚

大白话

核心思想很简单：给每个专家打分，表现差的扣分，扣分用乘法不用减法。

为什么用乘法？因为乘法是指数惩罚！

假设某专家连续表现差：

- 减法： $100 - 10 - 10 - 10 = 70$ （线性下降）
- 乘法： $100 \times 0.9 \times 0.9 \times 0.9 = 72.9$ ，继续乘下去很快趋于 0

乘法让差的专家很快被遗忘，好的专家权重相对越来越大。

Algorithm 1 Multiplicative Weights Update (MWU)

- 1: 每个专家初始权重 $w_i = 1$
 - 2: 选一个学习率 η （比如 0.1）
 - 3: **for** 每一轮 $t = 1, 2, \dots, T$ **do**
 - 4: 计算概率： $p_i = \frac{w_i}{\sum_j w_j}$ （权重归一化）
 - 5: 按概率随机选一个专家
 - 6: 看到所有专家的损失 $\ell_t(i)$ （0 到 1 之间）
 - 7: **乘法更新**： $w_i \leftarrow w_i \times (1 - \eta \cdot \ell_t(i))$
 - 8: **end for**
-

MWU 完整手算

3 个专家, $\eta = 0.5$, 初始权重 $w = (1, 1, 1)$ 。

第 1 轮: 损失 $\ell_1 = (0.8, 0.2, 0.5)$

概率 (归一化): $p = (1/3, 1/3, 1/3) = (0.33, 0.33, 0.33)$

更新权重:

$$w_1 = 1 \times (1 - 0.5 \times 0.8) = 1 \times 0.6 = 0.6$$

$$w_2 = 1 \times (1 - 0.5 \times 0.2) = 1 \times 0.9 = 0.9$$

$$w_3 = 1 \times (1 - 0.5 \times 0.5) = 1 \times 0.75 = 0.75$$

现在 $w = (0.6, 0.9, 0.75)$, 总权重 $W = 2.25$ 。

第 2 轮: 损失 $\ell_2 = (0.3, 0.9, 0.4)$

概率: $p = (0.6/2.25, 0.9/2.25, 0.75/2.25) = (0.27, 0.40, 0.33)$

专家 2 概率最高 (第 1 轮表现最好)。

更新权重:

$$w_1 = 0.6 \times (1 - 0.5 \times 0.3) = 0.6 \times 0.85 = 0.51$$

$$w_2 = 0.9 \times (1 - 0.5 \times 0.9) = 0.9 \times 0.55 = 0.495$$

$$w_3 = 0.75 \times (1 - 0.5 \times 0.4) = 0.75 \times 0.8 = 0.6$$

现在 $w = (0.51, 0.495, 0.6)$ 。

注意: 专家 2 第 2 轮损失 0.9 (很差), 权重从最高的 0.9 暴跌到最低的 0.495!

这就是乘法更新的威力: 一次大失误, 立刻惩罚到位。

指数惩罚有多狠

某专家**连续** k 轮损失都是 1 (最差), $\eta = 0.1$:

权重变化: $w = (1 - 0.1)^k = 0.9^k$

连续差的轮数 k	权重 0.9^k	占初始的比例
5	0.59	59%
10	0.35	35%
20	0.12	12%
50	0.005	0.5%
100	0.00003	0.003%

50 轮后权重只剩 0.5%, 这个专家几乎被**完全遗忘**了!

3.1 MWU 的 Regret 界

定理 3.1 (MWU 的 Regret). 如果选 $\eta \leq 1/2$, 则 MWU 的期望 Regret 满足:

$$\mathbb{E}[\text{Regret}_T] \leq \frac{\ln N}{\eta} + \eta T$$

取 $\eta = \sqrt{\frac{\ln N}{T}}$, 得到:

$$\mathbb{E}[\text{Regret}_T] \leq 2\sqrt{T \ln N}$$

证明的直觉

证明的核心是追踪**总权重** $W^{(t)} = \sum_i w_i^{(t)}$ 。

想象总权重是一个水池:

- **上界**: 你表现越差, 水流失越快
- **下界**: 但最好那个专家的水还在, 撑住底线

水池不能比最好专家那一份还少, 但你的损失在让水流失。这两个约束一夹, 就得出了 Regret 的界!

证明. 证明分四步。

Step 1: 两个关键不等式

引理 3.1. 对所有 $x < 1$: $\ln(1-x) \leq -x$

证明. 令 $g(x) = -x - \ln(1-x)$, 则 $g(0) = 0$, $g'(x) = -1 + \frac{1}{1-x} = \frac{x}{1-x} \geq 0$ 当 $x \geq 0$ 。

所以 $g(x) \geq 0$, 即 $\ln(1-x) \leq -x$ 。□

验证: $x = 0.1$ 时, $\ln(0.9) = -0.105$, $-x = -0.1$ 。确实 $-0.105 \leq -0.1$ 。✓

引理 3.2. 当 $x \leq 1/2$ 时: $\ln(1-x) \geq -x - x^2$

证明. Taylor 展开: $\ln(1-x) = -x - \frac{x^2}{2} - \frac{x^3}{3} - \dots$

当 $x \leq 1/2$ 时, $\frac{x^2}{2} + \frac{x^3}{3} + \dots \leq x^2(\frac{1}{2} + \frac{1}{4} + \dots) = x^2$ 。

所以 $\ln(1-x) \geq -x - x^2$ 。□

验证: $x = 0.3$ 时, $\ln(0.7) = -0.357$, $-x - x^2 = -0.39$ 。确实 $-0.357 \geq -0.39$ 。✓

Step 2: 总权重的上界

设 $L_t = \sum_i p_i^{(t)} \ell_t(i)$ 是你在第 t 轮的期望损失。

总权重的演化：

$$\begin{aligned}
W^{(t+1)} &= \sum_i w_i^{(t)} (1 - \eta \ell_t(i)) \\
&= \sum_i w_i^{(t)} - \eta \sum_i w_i^{(t)} \ell_t(i) \\
&= W^{(t)} - \eta W^{(t)} \underbrace{\sum_i \frac{w_i^{(t)}}{W^{(t)}} \ell_t(i)}_{=L_t} \\
&= W^{(t)} (1 - \eta L_t)
\end{aligned}$$

取对数：

$$\ln W^{(t+1)} = \ln W^{(t)} + \ln(1 - \eta L_t)$$

由引理 1（因为 $\eta L_t \leq \eta \leq 1/2 < 1$ ）：

$$\ln W^{(t+1)} \leq \ln W^{(t)} - \eta L_t$$

累加从 $t = 1$ 到 T ：

$$\ln W^{(T+1)} \leq \ln W^{(1)} - \eta \sum_{t=1}^T L_t = \ln N - \eta \sum_{t=1}^T L_t$$

Step 3: 总权重的下界

设最佳专家是 i^* ，其总损失为 $L^* = \sum_{t=1}^T \ell_t(i^*)$ 。

总权重至少包含最佳专家的权重：

$$W^{(T+1)} \geq w_{i^*}^{(T+1)} = \prod_{t=1}^T (1 - \eta \ell_t(i^*))$$

取对数：

$$\ln W^{(T+1)} \geq \sum_{t=1}^T \ln(1 - \eta \ell_t(i^*))$$

由引理 2（因为 $\eta \ell_t(i^*) \leq \eta \leq 1/2$ ）：

$$\ln W^{(T+1)} \geq \sum_{t=1}^T (-\eta \ell_t(i^*) - \eta^2 \ell_t(i^*)^2) \geq -\eta L^* - \eta^2 T$$

最后一步用了 $\ell_t(i^*)^2 \leq \ell_t(i^*) \leq 1$ 。

Step 4: 合并上下界

从 Step 2 和 Step 3：

$$-\eta L^* - \eta^2 T \leq \ln W^{(T+1)} \leq \ln N - \eta \sum_{t=1}^T L_t$$

整理：

$$\eta \sum_{t=1}^T L_t - \eta L^* \leq \ln N + \eta^2 T$$

$$\sum_{t=1}^T L_t - L^* \leq \frac{\ln N}{\eta} + \eta T$$

左边正是期望 Regret!

Step 5: 最优 η

令 $f(\eta) = \frac{\ln N}{\eta} + \eta T$, 求最小值:

$$f'(\eta) = -\frac{\ln N}{\eta^2} + T = 0 \implies \eta^* = \sqrt{\frac{\ln N}{T}}$$

代入:

$$\text{Regret}_T \leq \frac{\ln N}{\sqrt{\ln N/T}} + \sqrt{\frac{\ln N}{T}} \cdot T = \sqrt{T \ln N} + \sqrt{T \ln N} = 2\sqrt{T \ln N}$$

□

代数字感受一下

$N = 100$ 个专家, $T = 10000$ 轮:

$\ln N = \ln 100 = 4.6$

最优 $\eta = \sqrt{4.6/10000} = \sqrt{0.00046} = 0.021$

$\text{Regret} \leq 2\sqrt{10000 \times 4.6} = 2 \times 214 = 428$

平均每轮后悔 = $428/10000 = 0.043$

即使有 100 个专家, 对手随便怎么坑你, 你平均每轮也只比”事后看来最好的那个”多亏 0.043!

证明的直觉

证明的核心是追踪**总权重** $W = \sum_i w_i$ 。

想象总权重是一个水池:

- **上界:** 你表现越差, 水流失越快
- **下界:** 但最好那个专家的水还在, 撑住底线

水池不能比最好专家那一份还少, 但你的损失在让水流失。

这两个约束一夹, 就得出了 Regret 的界!

证明中的关键计算

关键不等式: $\ln(1-x) \leq -x$

验证: $x = 0.1$ 时, $\ln(0.9) = -0.105$, $-x = -0.1$ 。

确实 $-0.105 < -0.1$ 。不等式成立!

第二个: $\ln(1-x) \geq -x - x^2$ (当 $x \leq 0.5$)

验证: $x = 0.3$ 时, $\ln(0.7) = -0.357$, $-x - x^2 = -0.39$ 。

确实 $-0.357 > -0.39$ 。成立!

这两个不等式是证明的核心工具。

4 Hoeffding 不等式：估计有多准

大白话

现在我们要解决一个基本问题：采样 n 次，估计能有多准？

比如你投硬币 10 次，7 次正面，估计正面概率是 0.7。

但真实概率可能是 0.5、0.6、0.8... 你的估计离真实值有多远？

Hoeffding 不等式告诉我们：偏差大的概率指数级衰减！采样越多，估计越准。

定理 4.1 (Hoeffding 不等式). n 个独立样本 $X_i \in [0, 1]$ ，样本均值 $\bar{X} = \frac{1}{n} \sum X_i$ ，真实均值 μ ，则：

$$P(|\bar{X} - \mu| \geq \epsilon) \leq 2e^{-2n\epsilon^2}$$

证明思路

完整证明需要用到 Chernoff bound 技术，这里给出核心思路。

证明梗概. **Step 1: Markov 不等式**

对任意非负随机变量 Y 和 $a > 0$:

$$P(Y \geq a) \leq \frac{\mathbb{E}[Y]}{a}$$

Step 2: Chernoff 技巧

对任意 $s > 0$:

$$P(\bar{X} - \mu \geq \epsilon) = P(e^{s(\bar{X} - \mu)} \geq e^{s\epsilon}) \leq \frac{\mathbb{E}[e^{s(\bar{X} - \mu)}]}{e^{s\epsilon}}$$

Step 3: 关键引理 (Hoeffding 引理)

如果 $X \in [a, b]$ 且 $\mathbb{E}[X] = 0$ ，则对任意 $s > 0$:

$$\mathbb{E}[e^{sX}] \leq e^{s^2(b-a)^2/8}$$

证明要点: e^{sx} 是凸函数，可以用 $[a, b]$ 两端点的线性组合上界。然后对这个上界取期望，再用 $e^x \leq 1 + x + x^2$ 型不等式。

Step 4: 应用到样本均值

令 $Y_i = X_i - \mu$ ，则 $Y_i \in [-\mu, 1 - \mu] \subset [-1, 1]$ ， $\mathbb{E}[Y_i] = 0$ 。

$$\begin{aligned}\mathbb{E}[e^{s(\bar{X} - \mu)}] &= \mathbb{E}\left[e^{s \cdot \frac{1}{n} \sum_i Y_i}\right] = \mathbb{E}\left[\prod_i e^{sY_i/n}\right] \\ &= \prod_i \mathbb{E}[e^{sY_i/n}] \quad (\text{独立性}) \\ &\leq \prod_i e^{s^2/(8n^2)} = e^{s^2/(8n)}\end{aligned}$$

所以：

$$P(\bar{X} - \mu \geq \epsilon) \leq e^{s^2/(8n) - s\epsilon}$$

Step 5: 最优化 s

令 $f(s) = \frac{s^2}{8n} - s\epsilon$, 求最小值: $f'(s) = \frac{s}{4n} - \epsilon = 0 \implies s^* = 4n\epsilon$

代入:

$$P(\bar{X} - \mu \geq \epsilon) \leq e^{\frac{16n^2\epsilon^2}{8n} - 4n\epsilon^2} = e^{2n\epsilon^2 - 4n\epsilon^2} = e^{-2n\epsilon^2}$$

对 $P(\bar{X} - \mu \leq -\epsilon)$ 同理, 合并得:

$$P(|\bar{X} - \mu| \geq \epsilon) \leq 2e^{-2n\epsilon^2}$$

□

投硬币的例子

投 $n = 100$ 次硬币, 想知道估计误差超过 $\epsilon = 0.1$ 的概率。

$$P(|\hat{p} - p| \geq 0.1) \leq 2e^{-2 \times 100 \times 0.1^2} = 2e^{-2} = 2 \times 0.135 = 0.27$$

还有 27% 的概率误差超过 0.1, 不够准!

投 $n = 500$ 次:

$$P(|\hat{p} - p| \geq 0.1) \leq 2e^{-2 \times 500 \times 0.01} = 2e^{-10} = 2 \times 0.000045 = 0.00009$$

万分之一! 基本不可能误差超过 0.1。

投 $n = 1000$ 次:

$$P \leq 2e^{-20} \approx 4 \times 10^{-9}$$

十亿分之四, 几乎确定误差小于 0.1。

构造 95% 置信区间

反过来问: 我想要 95% 的把握误差不超过 ϵ , ϵ 是多少?

令 $2e^{-2n\epsilon^2} = 0.05$ (5% 的错误概率):

$$e^{-2n\epsilon^2} = 0.025$$

$$-2n\epsilon^2 = \ln(0.025) = -3.69$$

$$\epsilon = \sqrt{\frac{3.69}{2n}} = \sqrt{\frac{1.84}{n}}$$

样本数 n	95% 置信区间半宽	如果观测到 0.7
10	$\sqrt{1.84/10} = 0.43$	真值在 $[0.27, 1.0]$
100	$\sqrt{1.84/100} = 0.14$	真值在 $[0.56, 0.84]$
1000	$\sqrt{1.84/1000} = 0.04$	真值在 $[0.66, 0.74]$
10000	$\sqrt{1.84/10000} = 0.01$	真值在 $[0.69, 0.71]$

$1/\sqrt{n}$ 的收敛速度

置信区间宽度 $\propto 1/\sqrt{n}$ 。

这意味着：

- 想把误差减半，需要 4 倍样本
- 想把误差减到 1/10，需要 100 倍样本

这就是为什么 **Regret** 是 $O(\sqrt{T})$ ——因为我们获取信息的速度就是 $\sqrt{T}$ ！

5 Multi-Armed Bandit：探索与利用

大白话

Bandit 问题就像在赌场玩老虎机：

- 面前有 K 台老虎机，每台中奖概率不同（但你不知道）
- 每次只能选一台拉
- 拉完只知道这台中没中，其他台的情况不知道
- 目标：拉 T 次，总收益最大

核心困境：

- **探索** (Exploration)：多试试不熟悉的机器，可能发现宝藏
- **利用** (Exploitation)：一直拉目前看起来最好的，稳定收益

只探索 = 浪费时间在差机器上；只利用 = 可能错过真正最好的。
怎么平衡？

例 5.1 (5 台老虎机). 真实中奖概率（你不知道）： $\mu = (0.3, 0.5, 0.7, 0.4, 0.6)$

最优策略：一直拉机器 3，期望收益 $0.7 \times T$ 。

但你不知道机器 3 最好！你得边拉边猜。

Regret 的来源

假设 $T = 1000$ 轮，你的选择如下：

机器	真实 μ	拉了几次	期望收益	本该多得（机会成本）
1	0.3	50	$50 \times 0.3 = 15$	$50 \times (0.7 - 0.3) = 20$
2	0.5	100	$100 \times 0.5 = 50$	$100 \times (0.7 - 0.5) = 20$
3	0.7	700	$700 \times 0.7 = 490$	0
4	0.4	80	$80 \times 0.4 = 32$	$80 \times (0.7 - 0.4) = 24$
5	0.6	70	$70 \times 0.6 = 42$	$70 \times (0.7 - 0.6) = 7$
总计	—	1000	629	71

最优收益 $= 1000 \times 0.7 = 700$

你的收益 $= 629$

Regret $= 700 - 629 = 71$

这 71 就是你”探索”和”选错”付出的代价。

5.1 ϵ -Greedy：最简单的方法

大白话

ϵ -Greedy 超简单：

- 以 $1 - \epsilon$ 概率（比如 90%）：选目前估计最好的（**利用**）
- 以 ϵ 概率（比如 10%）：随机选一个（**探索**）

问题：你永远有 10% 在瞎选！即使已经很确定哪个最好了。

ϵ -Greedy 的问题

$\epsilon = 0.1$, 3 台机器, 当前估计 $\hat{\mu} = (0.35, 0.72, 0.68)$ 。

选择概率:

- 机器 1: $0.1/3 = 0.033$ (只靠随机探索)
- 机器 2: $0.9 + 0.033 = 0.933$ (利用 + 随机)
- 机器 3: 0.033 (只靠随机探索)

假设机器 2 确实最好 ($\mu_2 = 0.7$), 机器 1 和 3 差一点 ($\mu = 0.5$)。

$T = 10000$ 轮的期望 Regret:

ϵ -Greedy 有 10% 概率选到次优, 每次损失约 $0.7 - 0.5 = 0.2$ 。

$\text{Regret} \approx 10000 \times 0.1 \times 0.2 = 200$

这是 $O(\epsilon T)$ ——**线性增长!** 不好。

减小 ϵ ? 那探索不够, 可能一直选错的。

5.2 UCB: 乐观面对不确定

大白话

UCB 的核心思想: **不确定的东西, 先当它是好的!**

- 如果它真的好 $\rightarrow$ 你选对了, 太棒了
- 如果它其实不好 $\rightarrow$ 你试了一次, 现在知道它不好了, 也不亏

无论哪种情况, 你都在进步! 这叫 **Optimism in the Face of Uncertainty** (乐观原则)。

定义 5.1 (UCB 值)。

$$\text{UCB}_a = \underbrace{\hat{\mu}_a}_{\text{经验均值}} + \underbrace{\sqrt{\frac{2 \ln t}{n_a}}}_{\text{探索奖励}}$$

每次选 UCB 值最大的机器。

UCB 公式的直觉

- $\hat{\mu}_a$: 这台机器目前看起来有多好
- $\sqrt{\frac{2 \ln t}{n_a}}$: **不确定性奖励**——拉的次数 n_a 越少, 这项越大

拉的少 $\rightarrow$ 不确定性大 $\rightarrow$ UCB 高 $\rightarrow$ 会被选中 $\rightarrow$ 探索!

拉的多 $\rightarrow$ 不确定性小 $\rightarrow$ UCB 主要看 $\hat{\mu}$ $\rightarrow$ 利用!

探索和利用自动平衡了!

UCB 逐步执行

3 台机器，真实 $\mu = (0.3, 0.7, 0.5)$ 。

第 1-3 轮：每台各拉一次（初始化）

结果：机器 1 输 (0)，机器 2 赢 (1)，机器 3 赢 (1)

当前： $\hat{\mu} = (0, 1, 1)$ ， $n = (1, 1, 1)$

第 4 轮 ($t = 4$ ， $\ln 4 = 1.39$)：

$$\text{UCB}_1 = 0 + \sqrt{\frac{2 \times 1.39}{1}} = 0 + 1.67 = 1.67$$

$$\text{UCB}_2 = 1 + \sqrt{\frac{2 \times 1.39}{1}} = 1 + 1.67 = 2.67$$

$$\text{UCB}_3 = 1 + \sqrt{\frac{2 \times 1.39}{1}} = 1 + 1.67 = 2.67$$

机器 2 和 3 并列最高，随机选机器 2。结果：赢 (1)。

更新： $\hat{\mu}_2 = 2/2 = 1$ ， $n_2 = 2$

第 5 轮 ($t = 5$ ， $\ln 5 = 1.61$)：

$$\text{UCB}_1 = 0 + \sqrt{\frac{2 \times 1.61}{1}} = 0 + 1.79 = 1.79$$

$$\text{UCB}_2 = 1 + \sqrt{\frac{2 \times 1.61}{2}} = 1 + 1.27 = 2.27$$

$$\text{UCB}_3 = 1 + \sqrt{\frac{2 \times 1.61}{1}} = 1 + 1.79 = 2.79$$

选机器 3！虽然 $\hat{\mu}_2 = \hat{\mu}_3 = 1$ ，但机器 3 只被拉过 1 次，不确定性更大，UCB 更高。

这就是 UCB 的智慧：自动去探索那些“看起来不错但不太确定”的选项。

UCB 什么时候放弃差机器

机器 1 真实 $\mu_1 = 0.3$, 机器 2 真实 $\mu_2 = 0.7$, 差距 $\Delta = 0.4$ 。

问: UCB 要拉机器 1 多少次才会”放弃”它?

经过足够采样, $\hat{\mu}_1 \approx 0.3$, $\hat{\mu}_2 \approx 0.7$ 。

要让机器 1 不再被选, 需要 $UCB_1 < UCB_2$:

$$0.3 + \sqrt{\frac{2 \ln T}{n_1}} < 0.7$$

$$\sqrt{\frac{2 \ln T}{n_1}} < 0.4$$

$$\frac{2 \ln T}{n_1} < 0.16$$

$$n_1 > \frac{2 \ln T}{0.16} = 12.5 \ln T$$

当 $T = 10000$ 时, $\ln T = 9.2$:

$$n_1 > 12.5 \times 9.2 = 115$$

机器 1 被拉**约 115 次**后, UCB 就会低于机器 2, 不再被选!

这 115 次的 $\text{Regret} = 115 \times 0.4 = 46$ 。

UCB 的 Regret 界

$K = 5$ 台机器, $T = 10000$ 轮, $\Delta = (0.4, 0.2, 0, 0.3, 0.1)$ 。

理论界: $\text{Regret} \leq \sum_{a: \Delta_a > 0} \frac{8 \ln T}{\Delta_a}$

$$\begin{aligned} &= \frac{8 \times 9.2}{0.4} + \frac{73.6}{0.2} + 0 + \frac{73.6}{0.3} + \frac{73.6}{0.1} \\ &= 184 + 368 + 0 + 245 + 736 = 1533 \end{aligned}$$

另一个界: $O(\sqrt{KT \ln T}) = \sqrt{5 \times 10000 \times 9.2} \approx 678$

实际 Regret 通常比理论界小很多!

5.3 UCB 的 Regret 证明

定理 5.1 (UCB 的 Regret 界). UCB 算法的 Regret 满足:

$$\text{Regret}_T \leq \sum_{a: \Delta_a > 0} \frac{8 \ln T}{\Delta_a} + \left(1 + \frac{\pi^2}{3}\right) \sum_a \Delta_a$$

其中 $\Delta_a = \mu^* - \mu_a$ 是 arm a 的次优差距。

证明的核心思想

UCB 选错 arm 只有两种可能：

1. **最优 arm 被低估**： $\hat{\mu}^* + \text{bonus}^* < \mu^*$ （置信区间失效）
2. **次优 arm 被高估**： $\hat{\mu}_a + \text{bonus}_a > \mu^*$ （要么置信区间失效，要么 bonus 太大）

Hoeffding 告诉我们置信区间失效的概率很小 ($O(1/t^2)$)，所以主要代价来自 bonus 太大——这需要足够多次采样让 bonus 缩小到 Δ_a 以下。

证明. Step 1: 分解 Regret

设 $N_a(T)$ 是 arm a 在 T 轮内被选中的次数。

$$\text{Regret}_T = \sum_{a=1}^K \Delta_a \cdot \mathbb{E}[N_a(T)]$$

所以关键是 bound 每个次优 arm 的期望选中次数。

Step 2: UCB 选中次优 arm a 的条件

在时刻 t ，UCB 选中 arm a （而非最优 arm a^* ）意味着：

$$\text{UCB}_a(t) \geq \text{UCB}_{a^*}(t)$$

即：

$$\hat{\mu}_a + \sqrt{\frac{2 \ln t}{n_a}} \geq \hat{\mu}_{a^*} + \sqrt{\frac{2 \ln t}{n_{a^*}}}$$

定义事件：

- A_t ：最优 arm 的置信区间失效， $|\hat{\mu}_{a^*} - \mu^*| > \sqrt{\frac{2 \ln t}{n_{a^*}}}$
- B_t ：次优 arm 的置信区间失效， $|\hat{\mu}_a - \mu_a| > \sqrt{\frac{2 \ln t}{n_a}}$

Step 3: 置信区间失效的概率

由 Hoeffding 不等式，对任意固定的 n ：

$$P\left(|\hat{\mu} - \mu| > \sqrt{\frac{2 \ln t}{n}}\right) \leq 2e^{-2n \cdot \frac{2 \ln t}{n}} = 2e^{-4 \ln t} = \frac{2}{t^4}$$

对所有可能的 n 求和（union bound）：

$$P(A_t) \leq \sum_{n=1}^t \frac{2}{t^4} = \frac{2}{t^3}, \quad P(B_t) \leq \frac{2}{t^3}$$

Step 4: 如果置信区间都有效

假设 A_t 和 B_t 都不发生。那么：

$$\begin{aligned} \hat{\mu}_{a^*} &\geq \mu^* - \sqrt{\frac{2 \ln t}{n_{a^*}}} \\ \hat{\mu}_a &\leq \mu_a + \sqrt{\frac{2 \ln t}{n_a}} \end{aligned}$$

如果 arm a 被选中, 则:

$$\mu_a + 2\sqrt{\frac{2\ln t}{n_a}} \geq \hat{\mu}_a + \sqrt{\frac{2\ln t}{n_a}} \geq \hat{\mu}_{a^*} + \sqrt{\frac{2\ln t}{n_{a^*}}} \geq \mu^*$$

即:

$$2\sqrt{\frac{2\ln t}{n_a}} \geq \mu^* - \mu_a = \Delta_a$$

解得:

$$n_a \leq \frac{8\ln t}{\Delta_a^2}$$

Step 5: 总结

arm a 被选中当且仅当以下之一发生:

1. $n_a \leq \frac{8\ln T}{\Delta_a^2}$ (还没采样够)
2. A_t 或 B_t 发生 (置信区间失效)

所以:

$$\begin{aligned} \mathbb{E}[N_a(T)] &\leq \frac{8\ln T}{\Delta_a^2} + \sum_{t=1}^T P(A_t \cup B_t) \\ &\leq \frac{8\ln T}{\Delta_a^2} + \sum_{t=1}^T \frac{4}{t^3} \\ &\leq \frac{8\ln T}{\Delta_a^2} + \frac{\pi^2}{3} + 1 \end{aligned}$$

(用了 $\sum_{t=1}^{\infty} \frac{1}{t^3} < \frac{\pi^2}{6}$)

Step 6: 最终 Regret

$$\begin{aligned} \text{Regret}_T &= \sum_{a:\Delta_a>0} \Delta_a \cdot \mathbb{E}[N_a(T)] \\ &\leq \sum_{a:\Delta_a>0} \Delta_a \left(\frac{8\ln T}{\Delta_a^2} + O(1) \right) \\ &= \sum_{a:\Delta_a>0} \frac{8\ln T}{\Delta_a} + O(K) \end{aligned}$$

□

验证证明中的数值

$\Delta = 0.4$, $T = 10000$:

最多需要采样次数: $\frac{8\ln 10000}{0.4^2} = \frac{8 \times 9.2}{0.16} = 460$ 次

之后 UCB 值: $\mu_a + \sqrt{\frac{2 \times 9.2}{460}} = 0.3 + 0.2 = 0.5$

最优 arm ($\mu^* = 0.7$) 的 UCB 即使采样很多次也 ≥ 0.7 。

所以 460 次后, 次优 arm 不会再被选!

Regret 贡献: $460 \times 0.4 = 184$ (与前面的 $\frac{8\ln T}{\Delta} = 184$ 一致!)

6 Thompson Sampling: 贝叶斯方法

大白话

UCB 是”乐观派”：不确定就当它好。

Thompson Sampling 是”概率派”：不确定就**按概率赌**！

具体做法：

1. 对每台机器，根据历史数据，算出一个”可能的获奖概率分布”
2. 从每个分布里随机抽一个数
3. 选抽到最大数的那台机器

这样，**越可能是最好的机器，越容易被选中**！

6.1 Beta 分布：硬币的后验

Beta 分布是什么

假设一枚硬币，你对它正面概率 p 有一个**信念**。

一开始你啥都不知道，信念是” p 可能是 0 到 1 之间任何值”——这是 Beta(1,1)，均匀分布。

然后你投了几次，看到结果，就可以**更新信念**：

Beta 分布的更新规则超简单：

Beta(α, β) + 看到 s 次正面、 f 次反面 $\rightarrow$ Beta($\alpha + s, \beta + f$)

就是把成功次数加到第一个参数，失败次数加到第二个参数！

Beta 更新的例子

初始：Beta(1, 1)——对 p 一无所知

拉机器 5 次：3 次赢，2 次输

后验：Beta(1+3, 1+2) = Beta(4, 3)

后验均值（对 p 的最佳估计）：

$$\mathbb{E}[p] = \frac{\alpha}{\alpha + \beta} = \frac{4}{4 + 3} = \frac{4}{7} = 0.571$$

注意：这比直接算 $3/5 = 0.6$ 略小，因为先验把估计往 0.5 拉了一点。

数据越多，越确定

Beta(α, β) 的标准差: $\sigma = \sqrt{\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}}$

观测	后验	均值	标准差 (不确定性)
无	Beta(1,1)	0.50	0.289
3 赢 2 输	Beta(4,3)	0.57	0.175
30 赢 20 输	Beta(31,21)	0.60	0.067
300 赢 200 输	Beta(301,201)	0.60	0.022

数据从 5 个到 500 个，标准差从 0.175 降到 0.022——不确定性减少了 8 倍！
这就是为什么需要大量数据：不确定性以 $1/\sqrt{n}$ 降低。

6.2 Thompson Sampling 算法

Algorithm 2 Thompson Sampling

- 1: 每台机器初始化: $\alpha_a = 1, \beta_a = 1$ (Beta(1,1) 先验)
 - 2: **for** 每一轮 **do**
 - 3: 对每台机器 a , 从 Beta(α_a, β_a) 采样一个 θ_a
 - 4: 选择 θ 最大的机器
 - 5: 观察结果: 赢则 $\alpha_a \leftarrow \alpha_a + 1$, 输则 $\beta_a \leftarrow \beta_a + 1$
 - 6: **end for**
-

Thompson Sampling 执行

3 台机器，当前状态：

机器	赢	输	后验	后验均值
1	2	8	Beta(3, 9)	0.25
2	15	5	Beta(16, 6)	0.73
3	5	5	Beta(6, 6)	0.50

Thompson Sampling 的一步：

从每个后验采样：

- $\theta_1 \sim \text{Beta}(3, 9)$ ：可能采到 0.18
- $\theta_2 \sim \text{Beta}(16, 6)$ ：可能采到 0.68
- $\theta_3 \sim \text{Beta}(6, 6)$ ：可能采到 0.55

这轮 $\theta_2 = 0.68$ 最大，选机器 2。

再来一轮：

- θ_1 ：采到 0.22
- θ_2 ：采到 0.61
- θ_3 ：采到 0.72（运气好！）

这轮 $\theta_3 = 0.72$ 最大，选机器 3——探索发生了！

机器 3 虽然均值只有 0.5，但不确定性大（标准差 0.14），有时会采到高值。

Thompson Sampling 的选择概率

继续上面的例子，模拟 10000 次采样：

机器	后验	被选中的概率
1	Beta(3, 9)	0.2%
2	Beta(16, 6)	88%
3	Beta(6, 6)	12%

Thompson Sampling 实现了**概率匹配**：选择概率 $\approx$ 该机器是最优的概率！

UCB vs Thompson Sampling

	UCB	Thompson Sampling
哲学	乐观：不确定就当好的	概率：按可能性赌
探索方式	显式加 bonus	隐式通过采样
确定性	确定性算法	随机算法
实践效果	好	通常更好

6.3 Thompson Sampling 的理论保证

定理 6.1 (Thompson Sampling 的 Regret 界). 对于 K -armed Bernoulli bandit, Thompson Sampling 的期望 Regret 满足：

$$\mathbb{E}[\text{Regret}_T] \leq O\left(\sum_{a:\Delta_a>0} \frac{\ln T}{\Delta_a}\right)$$

与 UCB 同阶！

为什么 Thompson Sampling 有效

Thompson Sampling 看起来很随意（随机采样然后选最大），为什么能有理论保证？

关键洞察：**概率匹配**。

设 $\pi_a(t) = P(\text{arm } a \text{ 是最优} | \text{历史数据})$ 是 arm a 实际最优的后验概率。

Thompson Sampling 选中 arm a 的概率恰好约等于 $\pi_a(t)$ ！

这意味着：

- 越可能是最优的 arm，越常被选
- 不太可能最优的 arm，很少被选（但不是完全不选）
- 自动实现了探索-利用平衡

证明思路. 完整证明较技术性，这里给出核心思路。

Step 1: 定义”好事件”

定义 $E_a(t)$ 为”arm a 的后验集中在真值附近”：

$$E_a(t) = \left\{ |\hat{\mu}_a - \mu_a| \leq \sqrt{\frac{c \ln t}{n_a(t)}} \right\}$$

由 Hoeffding, $P(E_a(t)^c) \leq O(1/t^2)$ 。

Step 2: 条件于好事件

当所有 $E_a(t)$ 都发生时，后验分布集中在真值附近。

此时，Thompson Sampling 选中次优 arm a 的概率约为：

$$P(\theta_a > \theta_{a^*}) \approx P(\mu_a + \text{noise}_a > \mu^* + \text{noise}^*)$$

当 n_a 足够大时，噪声很小，这个概率趋于 0。

Step 3: 计算期望选中次数

类似 UCB 的分析，可以证明次优 arm a 的期望选中次数是 $O(\ln T / \Delta_a^2)$ 。

Step 4: 加权求和

$$\text{Regret}_T = \sum_a \Delta_a \cdot \mathbb{E}[N_a(T)] = O\left(\sum_a \frac{\ln T}{\Delta_a}\right)$$

□

Thompson Sampling vs UCB 的实际表现

模拟 $K = 10$ 个 Bernoulli arm, $\mu = (0.1, 0.2, \dots, 0.9, 1.0)$, $T = 10000$:

算法	平均 Regret	标准差
ϵ -Greedy ($\epsilon = 0.1$)	312	45
UCB	156	28
Thompson Sampling	98	31

Thompson Sampling 的实际 Regret 比 UCB 低约 40%!

原因: UCB 的 bonus 是 worst-case 设计，往往过于保守; Thompson Sampling 更”自适应”。

7 最优学习：从累积收益到最终决策

大白话

之前讲的 Bandit，目标是最小化**累积 Regret**——边学边用，每一步的损失都算数。但很多实际问题不是这样的：

- **药物研发**：做 20 次临床试验，最后选一种药上市。中间那 19 次的”损失”无所谓，关键是最终选对！
- **超参数调优**：试 20 组配置，最后用最好的那组。中间那 19 组的”损失”无所谓！

这类问题叫**最优学习** (Optimal Learning) 或**纯探索** (Pure Exploration)：

目标不是累积收益，而是最终选择的质量。

Bandit vs 最优学习

	Bandit	最优学习
目标	最小化 $\sum_t (\mu^* - \mu_{a_t})$	最小化 $\mu^* - \mu_{\text{最终选择}}$
关心的	每一步的损失	只关心最后决策
时间	可能无限长	固定预算 N 次
最优策略	UCB, Thompson Sampling	Knowledge Gradient

7.1 问题形式化

定义 7.1 (最优学习问题). K 个选项 (arm), 真实价值 $\mu_1, \dots, \mu_K$ 未知

- 预算: 最多做 N 次实验
- 每次实验选择一个 arm a , 观测 $y \sim \mathcal{N}(\mu_a, \sigma^2)$
- 实验结束后, 必须选择一个 arm 作为最终决策
- 目标: 最大化最终选择的 μ 值

为什么这和 Bandit 不同

在 Bandit 中, 如果你”探索”一个差的 arm, 你立刻承受损失。所以 UCB 要平衡探索和利用。

在最优学习中, 探索本身**不花钱** (中间结果不算)! 你只关心最后选对没有。
这意味着: **更激进的探索可能是最优的。**

7.2 信息的价值

定义 7.2 (最终决策价值). 设当前后验下, 对 μ_a 的估计是 $\hat{\mu}_a$ 。如果现在必须做决策:

$$V^{\text{当前}} = \max_a \hat{\mu}_a$$

这是你能期望得到的最大价值 (基于当前信息)。

定义 7.3 (完美信息的价值 (VPI)). 如果你能**完全知道**某个 arm a 的真实 μ_a , 决策会改进多少?

$$\text{VPI}(a) = \mathbb{E} \left[\max \{ \mu_a, \max_{a' \neq a} \hat{\mu}_{a'} \} \mid \mu_a \sim \text{后验} \right] - \max_{a'} \hat{\mu}_{a'}$$

VPI 在说什么

想象上帝告诉你 arm a 的真实价值:

- 如果 μ_a 比你当前最佳估计还高 $\rightarrow$ 你会改选 arm a , 收益增加
- 如果 μ_a 比当前最佳低 $\rightarrow$ 你不会改变选择, 收益不变

VPI 就是这个”可能的收益增加”的期望值。

VPI 的完整计算

3 个 arm, 当前后验:

- Arm 1: $\mu_1 \sim \mathcal{N}(0.5, 0.2^2)$ (估计 0.5, 不确定性大)
- Arm 2: $\mu_2 \sim \mathcal{N}(0.7, 0.1^2)$ (估计 0.7, 较确定)
- Arm 3: $\mu_3 \sim \mathcal{N}(0.6, 0.15^2)$ (估计 0.6, 中等不确定)

当前最佳: Arm 2, $V^{\text{当前}} = 0.7$

计算 VPI(Arm 1):

如果知道 μ_1 的真值, 什么时候会改选 Arm 1? 当 $\mu_1 > 0.7$ 时。

$$\text{VPI}(1) = \mathbb{E}[(\mu_1 - 0.7)^+] = \int_{0.7}^{\infty} (\mu_1 - 0.7) \cdot p(\mu_1) d\mu_1$$

其中 $p(\mu_1) = \mathcal{N}(0.5, 0.2^2)$ 。

标准化: $Z = \frac{\mu_1 - 0.5}{0.2}$, 当 $\mu_1 = 0.7$ 时 $Z = 1$ 。

$$\begin{aligned} \text{VPI}(1) &= \int_1^{\infty} (0.5 + 0.2z - 0.7)\phi(z)dz = \int_1^{\infty} (0.2z - 0.2)\phi(z)dz \\ &= 0.2 \int_1^{\infty} z\phi(z)dz - 0.2 \int_1^{\infty} \phi(z)dz = 0.2 \cdot \phi(1) - 0.2 \cdot (1 - \Phi(1)) \\ &= 0.2 \times 0.242 - 0.2 \times 0.159 = 0.048 - 0.032 = 0.016 \end{aligned}$$

等等, 让我用更直接的公式。对于 $X \sim \mathcal{N}(\mu, \sigma^2)$:

$$\mathbb{E}[(X - c)^+] = (\mu - c)\Phi\left(\frac{\mu - c}{\sigma}\right) + \sigma\phi\left(\frac{\mu - c}{\sigma}\right)$$

对 Arm 1, $\mu = 0.5$, $\sigma = 0.2$, $c = 0.7$:

$$Z = \frac{0.5 - 0.7}{0.2} = -1$$

$$\text{VPI}(1) = (0.5 - 0.7)\Phi(-1) + 0.2\phi(-1) = (-0.2)(0.159) + 0.2(0.242) = -0.032 + 0.048 = 0.016$$

类似计算 VPI(Arm 2) 和 VPI(Arm 3):

Arm 2: $\mu = 0.7$, $\sigma = 0.1$, $c = 0.7$ (需要超过自己, 参考第二高的 0.6)

实际上, 对当前最优 arm, VPI 的计算稍有不同:

$$\text{VPI}(2) = \mathbb{E}[(\max_{a \neq 2} \hat{\mu}_a - \mu_2)^+] = \mathbb{E}[(0.6 - \mu_2)^+]$$

(如果 μ_2 比 0.6 还低, 我们会改选)

$$Z = \frac{0.7 - 0.6}{0.1} = 1$$

$$\text{VPI}(2) = (0.6 - 0.7)\Phi(-1) + 0.1\phi(1) = (-0.1)(0.159) + 0.1(0.242) = 0.008$$

$$\text{Arm 3: } Z = \frac{0.6 - 0.7}{0.15} = -0.67$$

$$\text{VPI}(3) = (-0.1)\Phi(-0.67) + 0.15\phi(0.67) = (-0.1)(0.251) + 0.15(0.319) = -0.025 + 0.048 = 0.023$$

总结：

Arm	估计 $\hat{\mu}$	不确定性 σ	VPI
1	0.5	0.2	0.016
2	0.7	0.1	0.008
3	0.6	0.15	0.023

Arm 3 的 VPI 最高！ 虽然估计不是最好，但：

- 比 Arm 2 更不确定 $\rightarrow$ 更可能翻盘
- 比 Arm 1 估计更高 $\rightarrow$ 翻盘的门槛更低

VPI 的直觉

VPI 高的 arm 有两个特点：

1. **不确定性大**：可能比想象的好很多
2. **估计值接近最佳**：翻盘的门槛低

估计很低且确定的 arm $\rightarrow$ VPI 接近 0（没希望）

估计最高且很确定的 arm $\rightarrow$ VPI 也低（已经知道它好了）

7.3 从 VPI 到 Knowledge Gradient

VPI 的问题

VPI 假设你能**完全知道**真值。但实际上，一次实验只给你一个**有噪声的观测**！

Knowledge Gradient (KG) 解决这个问题：它衡量**一次实验**能带来多少决策改进。

定义 7.4 (Knowledge Gradient). 做一次实验测量 arm a ，观测到 y ，更新后验。KG 衡量期望的决策改进：

$$\text{KG}(a) = \mathbb{E}_y \left[\max_{a'} \hat{\mu}_{a'}^{\text{新}}(y) \mid \text{测量} a \right] - \max_{a'} \hat{\mu}_{a'}^{\text{当前}}$$

KG vs VPI

- **VPI**：如果完全知道真值，决策改进多少？（理想情况）
- **KG**：做一次实验（有噪声），决策改进多少？（现实情况）

显然， $\text{KG}(a) \leq \text{VPI}(a)$ ，因为一次有噪声的观测不可能比完美信息更有价值。

当实验噪声很小时，KG 接近 VPI；噪声很大时，KG 远小于 VPI。

7.4 KG 的计算

定理 7.1 (正态分布下的 KG 公式). 假设：

- Arm a 的当前后验: $\mu_a \sim \mathcal{N}(\hat{\mu}_a, \sigma_a^2)$
- 观测噪声: $y|\mu_a \sim \mathcal{N}(\mu_a, \sigma_\epsilon^2)$

则贝叶斯更新后的后验为 $\mathcal{N}(\hat{\mu}_a^{\text{新}}, (\sigma_a^{\text{新}})^2)$, 其中:

$$\hat{\mu}_a^{\text{新}} = \frac{\sigma_\epsilon^{-2}y + \sigma_a^{-2}\hat{\mu}_a}{\sigma_\epsilon^{-2} + \sigma_a^{-2}}, \quad (\sigma_a^{\text{新}})^2 = \frac{1}{\sigma_\epsilon^{-2} + \sigma_a^{-2}}$$

KG 有解析形式:

$$\text{KG}(a) = \tilde{\sigma}_a \cdot f\left(\frac{|\hat{\mu}_a - \nu_{-a}|}{\tilde{\sigma}_a}\right)$$

其中:

- $\nu_{-a} = \max_{a' \neq a} \hat{\mu}_{a'}$ 是除 a 外的最佳估计
- $\tilde{\sigma}_a = \frac{\sigma_a^2}{\sqrt{\sigma_a^2 + \sigma_\epsilon^2}}$ 是”有效标准差”
- $f(z) = z\Phi(z) + \phi(z)$

证明. Step 1: 理解更新后的估计

观测 y 是 μ_a 加噪声: $y = \mu_a + \epsilon$, $\epsilon \sim \mathcal{N}(0, \sigma_\epsilon^2)$ 。

由于 μ_a 本身是随机的 (后验 $\mathcal{N}(\hat{\mu}_a, \sigma_a^2)$), 从当前视角看:

$$y \sim \mathcal{N}(\hat{\mu}_a, \sigma_a^2 + \sigma_\epsilon^2)$$

Step 2: 更新后的估计作为 y 的函数

贝叶斯更新后:

$$\hat{\mu}_a^{\text{新}}(y) = \hat{\mu}_a + \frac{\sigma_a^2}{\sigma_a^2 + \sigma_\epsilon^2}(y - \hat{\mu}_a)$$

令 $\tilde{\sigma}_a = \frac{\sigma_a^2}{\sqrt{\sigma_a^2 + \sigma_\epsilon^2}}$, 则:

$$\hat{\mu}_a^{\text{新}} = \hat{\mu}_a + \tilde{\sigma}_a \cdot Z$$

其中 $Z = \frac{y - \hat{\mu}_a}{\sqrt{\sigma_a^2 + \sigma_\epsilon^2}} \sim \mathcal{N}(0, 1)$ 。

Step 3: 计算 KG

更新后的最佳估计:

$$\max_{a'} \hat{\mu}_{a'}^{\text{新}} = \max\{\hat{\mu}_a + \tilde{\sigma}_a Z, \nu_{-a}\}$$

所以:

$$\begin{aligned} \text{KG}(a) &= \mathbb{E}[\max\{\hat{\mu}_a + \tilde{\sigma}_a Z, \nu_{-a}\}] - \nu_{-a} \quad (\text{假设当前 } \hat{\mu}_a < \nu_{-a}) \\ &= \mathbb{E}[(\hat{\mu}_a + \tilde{\sigma}_a Z - \nu_{-a})^+] \\ &= \tilde{\sigma}_a \cdot \mathbb{E}\left[\left(Z - \frac{\nu_{-a} - \hat{\mu}_a}{\tilde{\sigma}_a}\right)^+\right] \end{aligned}$$

令 $z_0 = \frac{\nu_{-a} - \hat{\mu}_a}{\tilde{\sigma}_a}$, 利用之前推导的公式 $\mathbb{E}[(Z - c)^+] = \phi(c) - c(1 - \Phi(c)) = \phi(c) + c\Phi(-c)$:
当 $c = z_0 > 0$ 时:

$$\text{KG}(a) = \tilde{\sigma}_a \cdot (\phi(z_0) + z_0\Phi(-z_0)) = \tilde{\sigma}_a \cdot f(-z_0)$$

由 f 的对称性, $f(-z) = f(z) - z \dots$ 实际上更简洁的写法是:

$$\text{KG}(a) = \tilde{\sigma}_a \cdot f\left(\frac{|\hat{\mu}_a - \nu_{-a}|}{\tilde{\sigma}_a}\right)$$

其中 $f(z) = z\Phi(z) + \phi(z)$ 对 $z \geq 0$ 。

□

KG 的数值计算

2 个 arm:

- Arm 1: $\hat{\mu}_1 = 0.6, \sigma_1 = 0.2$
- Arm 2: $\hat{\mu}_2 = 0.5, \sigma_2 = 0.3$

观测噪声 $\sigma_\epsilon = 0.1$ 。当前最佳是 Arm 1。

计算 KG(Arm 2):

有效标准差:

$$\tilde{\sigma}_2 = \frac{0.3^2}{\sqrt{0.3^2 + 0.1^2}} = \frac{0.09}{\sqrt{0.10}} = \frac{0.09}{0.316} = 0.285$$

差距: $|\hat{\mu}_2 - \nu_{-2}| = |0.5 - 0.6| = 0.1$

归一化差距: $z = \frac{0.1}{0.285} = 0.35$

$f(0.35) = 0.35 \times \Phi(0.35) + \phi(0.35) = 0.35 \times 0.637 + 0.375 = 0.598$

$\text{KG}(2) = 0.285 \times 0.598 = 0.170$

计算 KG(Arm 1):

$$\tilde{\sigma}_1 = \frac{0.2^2}{\sqrt{0.2^2 + 0.1^2}} = \frac{0.04}{0.224} = 0.179$$

$$z = \frac{|0.6 - 0.5|}{0.179} = 0.56$$

$f(0.56) = 0.56 \times 0.712 + 0.341 = 0.740$

$\text{KG}(1) = 0.179 \times 0.740 = 0.132$

结论: $\text{KG}(\text{Arm 2}) = 0.170 > \text{KG}(\text{Arm 1}) = 0.132$

应该测量 Arm 2! 虽然当前估计较低, 但不确定性大, 一次测量的信息价值更高。

KG 的直觉

KG 公式 $\text{KG}(a) = \tilde{\sigma}_a \cdot f(z)$ 告诉我们:

- $\tilde{\sigma}_a$ 大 (不确定性高) $\rightarrow$ KG 高
- $z = \frac{|\text{差距}|}{\tilde{\sigma}}$ 小 (接近最优) $\rightarrow f(z)$ 大 $\rightarrow$ KG 高

最优的探索对象是: **不确定性大且有机会翻盘**的 arm。

7.5 KG 策略

Algorithm 3 Knowledge Gradient 算法

```
1: for  $n = 1, 2, \dots, N$  do (预算  $N$  次实验)
2:   对每个 arm 计算  $\text{KG}(a)$ 
3:   选择  $a^* = \arg \max_a \text{KG}(a)$ 
4:   观测  $y \sim \mathcal{N}(\mu_{a^*}, \sigma_\epsilon^2)$ 
5:   贝叶斯更新  $\hat{\mu}_{a^*}$  和  $\sigma_{a^*}$ 
6: end for
7: 最终决策: 选择  $\arg \max_a \hat{\mu}_a$ 
```

定理 7.2 (KG 的最优性). 当只剩一次实验机会时, KG 策略是**最优**的——它最大化了最终决策的期望价值。

证明. 只剩一次实验时, 决策价值为:

$$V = \mathbb{E}_y[\max_{a'} \hat{\mu}_{a'}^{\text{新}}(y)]$$

这正好是 $\text{KG}(a) + \max_{a'} \hat{\mu}_{a'}^{\text{当前}}$ 。

由于第二项是常数, 最大化 V 等价于最大化 KG。

□

KG 的局限

KG 是”一步最优”(myopic) 策略——它只看一次实验的价值。

当预算很多时, 可能存在”战略性”探索: 现在做一个低 KG 的实验, 是为了以后能做更好的实验。

但在实践中, KG 表现非常好, 尤其是预算有限时。

8 贝叶斯优化: 连续空间的最优学习

从离散到连续

前面的 KG 是在**离散**的 arm 之间选择。

但很多问题是**连续**的: 你要调的超参数是连续的 (学习率 0.001 到 0.1), 不是几个离散选项。

贝叶斯优化就是把 KG 的思想推广到连续空间。核心挑战:

1. 连续空间有无穷多点, 不能对每个点都维护一个后验
2. 解决方案: 用**高斯过程** (GP) 对整个函数建模

8.1 问题设定

定义 8.1 (黑箱优化). 目标: 找到 $x^* = \arg \max_{x \in \mathcal{X}} f(x)$

约束:

- $f(x)$ 是黑箱，没有公式，没有梯度
- 每次评估 $f(x)$ 很昂贵（训练一个模型、做一次实验）
- 允许的评估次数很少（10-100 次）

8.2 高斯过程：函数的后验

GP 的直觉

高斯过程给整个函数 $f(x)$ 建立一个概率模型：

- 在任意点 x ， $f(x)$ 服从正态分布
- 相近的点， f 值高度相关（函数是”光滑”的）
- 观测几个点后，可以预测任意位置的 f 值和不确定性

关键：GP 把**无穷维**的函数空间变成了可以计算的东西！

定义 8.2 (高斯过程). $f(x)$ 服从高斯过程 $\mathcal{GP}(m(x), k(x, x'))$ ，如果对任意有限点集 $\{x_1, \dots, x_n\}$ ：

$$(f(x_1), \dots, f(x_n))^T \sim \mathcal{N}(\mathbf{m}, K)$$

其中 $\mathbf{m}_i = m(x_i)$ ， $K_{ij} = k(x_i, x_j)$ 。

常用核函数（RBF/Squared Exponential）：

$$k(x, x') = \sigma_f^2 \exp\left(-\frac{\|x - x'\|^2}{2\ell^2}\right)$$

定理 8.1 (GP 后验). 给定观测 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ ，其中 $y_i = f(x_i) + \epsilon$ ， $\epsilon \sim \mathcal{N}(0, \sigma_n^2)$ 。

在新点 x_* 处的后验为：

$$\begin{aligned}\mu(x_*) &= k_*^T (K + \sigma_n^2 I)^{-1} \mathbf{y} \\ \sigma^2(x_*) &= k(x_*, x_*) - k_*^T (K + \sigma_n^2 I)^{-1} k_*\end{aligned}$$

其中 $k_* = (k(x_*, x_1), \dots, k(x_*, x_n))^T$ 。

GP 后验的完整计算

已有 2 个观测: $(x_1 = 0.2, y_1 = 0.5)$, $(x_2 = 0.8, y_2 = 0.3)$

使用 RBF 核, $\ell = 0.3$, $\sigma_f = 1$, 无噪声 ($\sigma_n = 0$)。

计算核矩阵:

$$k(0.2, 0.8) = \exp\left(-\frac{(0.6)^2}{2 \times 0.3^2}\right) = \exp(-2) = 0.135$$

$$K = \begin{pmatrix} 1 & 0.135 \\ 0.135 & 1 \end{pmatrix}$$

求逆:

$$K^{-1} = \frac{1}{1 - 0.135^2} \begin{pmatrix} 1 & -0.135 \\ -0.135 & 1 \end{pmatrix} = \frac{1}{0.982} \begin{pmatrix} 1 & -0.135 \\ -0.135 & 1 \end{pmatrix} = \begin{pmatrix} 1.018 & -0.137 \\ -0.137 & 1.018 \end{pmatrix}$$

预测 $x_* = 0.5$:

$$k(0.5, 0.2) = \exp\left(-\frac{0.3^2}{0.18}\right) = \exp(-0.5) = 0.607$$

$$k(0.5, 0.8) = \exp\left(-\frac{0.3^2}{0.18}\right) = 0.607$$

$$k_* = (0.607, 0.607)^T$$

后验均值:

$$\begin{aligned} \mu(0.5) &= k_*^T K^{-1} \mathbf{y} = (0.607, 0.607) \begin{pmatrix} 1.018 & -0.137 \\ -0.137 & 1.018 \end{pmatrix} \begin{pmatrix} 0.5 \\ 0.3 \end{pmatrix} \\ &= (0.607, 0.607) \begin{pmatrix} 0.468 \\ 0.237 \end{pmatrix} = 0.284 + 0.144 = 0.428 \end{aligned}$$

后验方差:

$$\begin{aligned} \sigma^2(0.5) &= 1 - k_*^T K^{-1} k_* = 1 - (0.607, 0.607) \begin{pmatrix} 1.018 & -0.137 \\ -0.137 & 1.018 \end{pmatrix} \begin{pmatrix} 0.607 \\ 0.607 \end{pmatrix} \\ &= 1 - (0.607, 0.607) \begin{pmatrix} 0.535 \\ 0.535 \end{pmatrix} = 1 - 0.649 = 0.351 \end{aligned}$$

所以在 $x = 0.5$ 处: $f(0.5) \sim \mathcal{N}(0.428, 0.351)$, 标准差 $\sigma = 0.59$ 。

直觉验证: $x = 0.5$ 在两个观测点中间, 均值是两个 y 值的加权平均 (接近 $(0.5 + 0.3)/2 = 0.4$), 不确定性较大。

8.3 采集函数：连续空间的 KG

从 KG 到采集函数

在离散 Bandit 中，KG 告诉我们选哪个 arm。

在连续空间中，我们需要一个**采集函数** $\alpha(x)$ ，告诉我们在哪个 x 处采样。

几种常见的采集函数，都是 KG 思想的变体！

8.3.1 Expected Improvement (EI)

定义 8.3 (Expected Improvement). 设当前最佳观测 $f^+ = \max_i y_i$ 。EI 衡量新点超过 f^+ 的期望改进：

$$\text{EI}(x) = \mathbb{E}[\max(f(x) - f^+, 0)]$$

定理 8.2 (EI 的解析形式). 在 GP 后验 $f(x) \sim \mathcal{N}(\mu, \sigma^2)$ 下：

$$\text{EI}(x) = (\mu - f^+) \Phi(Z) + \sigma \phi(Z), \quad Z = \frac{\mu - f^+}{\sigma}$$

证明. 设 $f \sim \mathcal{N}(\mu, \sigma^2)$ 。

$$\text{EI} = \mathbb{E}[\max(f - f^+, 0)] = \int_{f^+}^{\infty} (f - f^+) \cdot \frac{1}{\sigma} \phi\left(\frac{f - \mu}{\sigma}\right) df$$

换元 $z = \frac{f - \mu}{\sigma}$, $f = \mu + \sigma z$, $df = \sigma dz$ 。

当 $f = f^+$ 时, $z = \frac{f^+ - \mu}{\sigma} = -Z$ 。

$$\begin{aligned} \text{EI} &= \int_{-Z}^{\infty} (\mu + \sigma z - f^+) \phi(z) dz \\ &= (\mu - f^+) \int_{-Z}^{\infty} \phi(z) dz + \sigma \int_{-Z}^{\infty} z \phi(z) dz \\ &= (\mu - f^+) \Phi(Z) + \sigma \cdot \phi(Z) \end{aligned}$$

最后一步用了 $\int_{-Z}^{\infty} \phi(z) dz = \Phi(Z)$ 和 $\int_{-Z}^{\infty} z \phi(z) dz = \phi(-Z) = \phi(Z)$ 。

□

EI vs KG 的联系

比较 EI 和 KG 的公式：

- KG: $KG(a) = \tilde{\sigma}_a \cdot f\left(\frac{|\hat{\mu}_a - \nu - a|}{\tilde{\sigma}_a}\right)$, 其中 $f(z) = z\Phi(z) + \phi(z)$
- EI: $EI(x) = (\mu - f^+)\Phi(Z) + \sigma\phi(Z)$, 其中 $Z = \frac{\mu - f^+}{\sigma}$

它们**本质相同**！都是在衡量”超过当前最佳的期望改进”。

区别：

- KG 考虑的是**决策改进**（最佳估计变化）
- EI 考虑的是**观测改进**（超过当前最佳观测）

在很多情况下，两者给出相似的采样策略。

EI 的完整计算

继续前面的 GP 例子，当前最佳 $f^+ = 0.5$ （在 $x = 0.2$ 处）。

比较三个候选点：

点 A： $x = 0.5$, $\mu = 0.428$, $\sigma = 0.59$ （中间，不确定性大）

$$Z = \frac{0.428 - 0.5}{0.59} = -0.122$$

$$EI(A) = (-0.072)\Phi(-0.122) + 0.59\phi(-0.122) = (-0.072)(0.451) + 0.59(0.395) = -0.032 + 0.233 = 0.201$$

点 B： $x = 0.3$, 假设 $\mu = 0.48$, $\sigma = 0.3$ （接近好点，不确定性中等）

$$Z = \frac{0.48 - 0.5}{0.3} = -0.067$$

$$EI(B) = (-0.02)(0.473) + 0.3(0.398) = -0.009 + 0.119 = 0.110$$

点 C： $x = 0.25$, 假设 $\mu = 0.49$, $\sigma = 0.15$ （非常接近好点，较确定）

$$Z = \frac{0.49 - 0.5}{0.15} = -0.067$$

$$EI(C) = (-0.01)(0.473) + 0.15(0.398) = -0.005 + 0.060 = 0.055$$

结论： $EI(A) = 0.201 > EI(B) = 0.110 > EI(C) = 0.055$

选点 A！虽然均值低于当前最佳，但高不确定性带来了巨大的探索价值。

8.3.2 GP-UCB：乐观原则的连续版

定义 8.4 (GP-UCB).

$$\alpha_{UCB}(x) = \mu(x) + \beta_t \sigma(x)$$

其中 β_t 控制探索程度，理论建议 $\beta_t = 2\ln(t^{d/2+2}\pi^2/3\delta)$ 。

GP-UCB vs 离散 UCB

完全类似！

- 离散 UCB: $\hat{\mu}_a + \sqrt{\frac{2 \ln t}{n_a}}$
- GP-UCB: $\mu(x) + \beta \sigma(x)$

都是”乐观原则”：用均值加上不确定性的倍数。

β 的影响

同样三个点, $\beta = 2$:

$$\alpha(A) = 0.428 + 2 \times 0.59 = 1.608$$

$$\alpha(B) = 0.48 + 2 \times 0.3 = 1.08$$

$$\alpha(C) = 0.49 + 2 \times 0.15 = 0.79$$

选 A! $\beta = 1$ 时: $\alpha(A) = 1.018$, $\alpha(B) = 0.78$, $\alpha(C) = 0.64$, 仍选 A。

$\beta = 0.3$ 时: $\alpha(A) = 0.605$, $\alpha(B) = 0.57$, $\alpha(C) = 0.535$, 选 A 但差距缩小。

结论: β 越大越鼓励探索, 越小越倾向利用。

8.4 采集函数的统一视角

采集函数	公式	来源	特点
EI	$(\mu - f^+) \Phi(Z) + \sigma \phi(Z)$	KG 思想	平衡探索利用
GP-UCB	$\mu + \beta \sigma$	UCB 思想	可调探索度
PI	$\Phi\left(\frac{\mu - f^+}{\sigma}\right)$	概率	只看超过概率
KG	决策改进期望	最优学习	理论最优 (一步)

选哪个采集函数

- **EI**: 最常用, 简单有效, 有解析形式
- **GP-UCB**: 有理论保证 (Regret bound), β 可调
- **KG**: 理论上一步最优, 但计算稍复杂
- **PI**: 过于贪婪, 容易陷入局部最优

实践建议: 从 EI 开始, 效果不好再尝试 GP-UCB 调 β 。

EI 的数值计算

当前最佳 $f^+ = 0.5$ 。两个候选点：

点 A: $\mu_A = 0.6$, $\sigma_A = 0.1$ (高均值, 低不确定性)

$$Z_A = \frac{0.6-0.5}{0.1} = 1.0$$

$$\Phi(1.0) = 0.841, \phi(1.0) = 0.242$$

$$\text{EI}(A) = 0.1 \times 0.841 + 0.1 \times 0.242 = 0.084 + 0.024 = 0.108$$

点 B: $\mu_B = 0.45$, $\sigma_B = 0.3$ (低均值, 高不确定性)

$$Z_B = \frac{0.45-0.5}{0.3} = -0.167$$

$$\Phi(-0.167) = 0.434, \phi(-0.167) = 0.394$$

$$\text{EI}(B) = (-0.05) \times 0.434 + 0.3 \times 0.394 = -0.022 + 0.118 = 0.096$$

结论: 点 A 的 EI 略高 (0.108 vs 0.096), 选点 A。

但注意点 B 的 EI 也不低! 虽然均值低于当前最佳, 但高不确定性带来了潜在价值。

完整贝叶斯优化流程

优化 $f(x) = -x^2 + x$ 在 $[0, 1]$ 上 (真实最优 $x^* = 0.5$, $f^* = 0.25$)

初始: 随机采样 $x_1 = 0.1$, $y_1 = 0.09$; $x_2 = 0.9$, $y_2 = 0.09$

当前最佳 $f^+ = 0.09$

GP 预测几个候选点:

x	预测均值 μ	预测标准差 σ	EI
0.3	0.15	0.20	0.11
0.5	0.12	0.25	0.13
0.7	0.15	0.20	0.11

EI 在 $x = 0.5$ 最大 (不确定性高), 下一个采样 $x_3 = 0.5$ 。

观测 $y_3 = f(0.5) = 0.25$ 。

只用 3 次评估就找到了最优点!

9 应用：A/B 测试的最优停止

把理论用起来

前面讲了 VPI、KG、EI 这些”信息价值”的概念。现在来看一个最常见的应用：**A/B 测试**。

A/B 测试就是最优学习问题的典型例子：

- 有限预算（测试时间/流量）
- 最终要做一个决策（选 A 还是 B）
- 测试期间的”损失”（给用户看了可能更差的版本）是暂时的

关键问题：**什么时候停止测试？**

9.1 问题设定

例 9.1 (网站 A/B 测试). 测试新按钮颜色 (B) vs 原来的 (A)。

- 每天 10000 访客，一半看 A 一半看 B
- 如果 B 真的更好，早停可以早获益
- 如果停太早，可能选错

当前数据：A 的转化率 3.2% (5000 样本)，B 的转化率 3.5% (5000 样本)。
该停止吗？

9.2 贝叶斯分析

B 比 A 好的概率

用 Beta-Bernoulli 模型（和 Thompson Sampling 一样!）：

A: 160 成功/5000 $\rightarrow$ 后验 $\text{Beta}(161, 4841)$ ，均值 $\hat{p}_A = 0.0322$

B: 175 成功/5000 $\rightarrow$ 后验 $\text{Beta}(176, 4826)$ ，均值 $\hat{p}_B = 0.0352$

计算 $P(p_B > p_A | \text{数据})$ ：

Beta 分布在大样本下近似正态。

$$p_A \sim \mathcal{N}(0.0322, \sigma_A^2), \text{ 其中 } \sigma_A = \sqrt{\frac{0.0322 \times 0.9678}{5001}} = 0.0025$$

$$p_B \sim \mathcal{N}(0.0352, \sigma_B^2), \text{ 其中 } \sigma_B = \sqrt{\frac{0.0352 \times 0.9648}{5001}} = 0.0026$$

$$p_B - p_A \sim \mathcal{N}(0.003, 0.0025^2 + 0.0026^2) = \mathcal{N}(0.003, 0.0036^2)$$

$$P(p_B > p_A) = P(p_B - p_A > 0) = \Phi\left(\frac{0.003}{0.0036}\right) = \Phi(0.83) = 0.80$$

有 **80%** 把握 B 更好。但这够不够？

9.3 Expected Loss: 决策的代价

Expected Loss 的思想

如果现在必须停止并做决策，选错的**期望代价**是多少？

这正是前面 VPI 的逆向思考：

- VPI 问：知道真相能带来多少好处？
- Expected Loss 问：不知道真相可能造成多少损失？

定义 9.1 (Expected Loss). 如果选择 arm a 作为最终决策：

$$EL(a) = \mathbb{E}[(\mu^* - \mu_a)^+ | \text{数据}] = \mathbb{E}[\max(\mu^* - \mu_a, 0)]$$

其中 $\mu^* = \max_{a'} \mu_{a'}$ 是真实最优值。

Expected Loss 计算

继续 A/B 测试的例子。

如果选 A： 损失 = 当 B 更好时的损失

$$EL(\text{选 A}) = \mathbb{E}[(p_B - p_A)^+ | \text{数据}]$$

用之前推导的公式（和 EI 一样！）：

$$p_B - p_A \sim \mathcal{N}(\mu = 0.003, \sigma = 0.0036)$$

$$Z = \frac{0 - 0.003}{0.0036} = -0.83$$

$$EL(\text{选 A}) = (0.003)\Phi(0.83) + 0.0036\phi(0.83) = 0.003 \times 0.797 + 0.0036 \times 0.283 = 0.0034$$

如果选 B： 损失 = 当 A 更好时的损失

$$EL(\text{选 B}) = \mathbb{E}[(p_A - p_B)^+] = (-0.003)\Phi(-0.83) + 0.0036\phi(0.83) = -0.003 \times 0.203 + 0.001 = 0.0004$$

结论：

- 选 A 的期望损失 = 0.34% 转化率
- 选 B 的期望损失 = 0.04% 转化率

如果现在必须停，选 B！但应该停吗？

9.4 何时停止：信息价值 vs 成本

停止的决策框架

继续测试有**成本**：

- 测试期间，一半流量给了可能更差的版本
- 占用工程师时间和注意力

继续测试有**收益**：

- 降低 Expected Loss（更确定谁好）
- 避免选错的长期代价

停止条件：当继续测试的边际信息价值 < 边际成本时停止。

何时停止的完整分析

假设：

- 测试期间每天成本：一半流量给 B，如果 B 更差，损失约 $5000 \times 0.003 = 15$ 次转化/天（但 B 可能更好，期望成本更低）
- 实际期望成本 $\approx 0.2 \times 15 = 3$ 次转化/天（只有 20% 概率 B 更差）
- 测试结束后，选定的方案运行 1 年

继续测一天的收益：

当前 $EL(\text{选 B}) = 0.04\%$ 。假设再测一天后 EL 降到 0.02% 。

一年每天 10000 访客， EL 降低带来的收益：

$$(0.0004 - 0.0002) \times 10000 \times 365 = 730 \text{ 次转化}$$

继续测一天的成本：约 3 次转化

信息价值比： $730/3 = 243$ 倍！

结论：绝对应该继续测试！

什么时候停？

当 EL 降到很低，比如 0.001% 时：

$$\text{继续测试的收益} = 0.00005 \times 10000 \times 365 = 18 \text{ 次转化}$$

如果此时成本仍是 3 次/天，信息价值比 = 6，还是值得。

当 EL 降到 0.0001% ：收益 = 1.8 次，成本 = 3 次，不值得了，停止！

A/B 测试的最优停止规则

1. 计算当前的 Expected Loss
2. 估算继续测试能降低多少 EL
3. 比较：EL 降低的长期价值 vs 测试成本
4. 当价值 < 成本时停止

这正是**最优学习**的核心思想在实践中的应用！

10 为什么是 $\sqrt{T}$ ：信息论下界

大白话

无论是 MWU、UCB 还是 Thompson Sampling, Regret 都是 $O(\sqrt{T})$ 。巧合吗？不是！ $\sqrt{T}$ 是**信息积累速度**的本质限制。任何算法都不可能做得更好！

10.1 下界定理

定理 10.1 (Lai-Robbins 下界, 1985). 对于任何”一致”的 bandit 算法（即对所有问题实例都有次线性 Regret），存在问题实例使得：

$$\liminf_{T \rightarrow \infty} \frac{\mathbb{E}[\text{Regret}_T]}{\ln T} \geq \sum_{a: \Delta_a > 0} \frac{\Delta_a}{D_{KL}(\mu_a \| \mu^*)}$$

其中 D_{KL} 是 KL 散度。

这个下界在说什么

要区分两个 arm，你需要足够的**信息**。

信息积累的速度由 KL 散度决定：

- KL 散度大 $\rightarrow$ 两个分布差异大 $\rightarrow$ 容易区分 $\rightarrow$ 不需要很多样本
- KL 散度小 $\rightarrow$ 两个分布差异小 $\rightarrow$ 难以区分 $\rightarrow$ 需要很多样本

定理说的是：无论你用什么算法，至少需要 $O(\ln T / D_{KL})$ 次采样才能区分。这些”必需的探索”带来的 Regret 是不可避免的！

10.2 证明思路

证明梗概。 **核心思想**：构造两个”难以区分”的问题实例，证明任何算法在其中一个上必然有大 Regret。

Step 1: 构造两个实例

实例 1: arm 1 的 $\mu_1 = 0.5$, arm 2 的 $\mu_2 = 0.5 - \epsilon$

实例 2: arm 1 的 $\mu_1 = 0.5$, arm 2 的 $\mu_2 = 0.5 + \epsilon$

在实例 1 中, arm 1 是最优的; 在实例 2 中, arm 2 是最优的。

Step 2: 信息论约束

设算法在 T 轮内选中 arm 2 共 N_2 次。

由数据处理不等式和 KL 散度的链式法则:

$$D_{KL}(P_1 \| P_2) \leq \mathbb{E}_1[N_2] \cdot D_{KL}(\text{Ber}(0.5 - \epsilon) \| \text{Ber}(0.5 + \epsilon))$$

其中 P_1, P_2 是两个实例下观测数据的分布。

Step 3: 区分的必要条件

如果算法在两个实例上都有低 Regret, 它必须能区分这两个实例 (选对最优 arm)。

区分需要 $D_{KL}(P_1 \| P_2) \geq c$ (某个常数)。

由 Step 2, 这意味着:

$$\mathbb{E}_1[N_2] \geq \frac{c}{D_{KL}(\text{Ber}(0.5 - \epsilon) \| \text{Ber}(0.5 + \epsilon))}$$

Step 4: KL 散度的计算

对于 Bernoulli 分布, 当 ϵ 小时:

$$D_{KL}(\text{Ber}(p) \| \text{Ber}(p + \epsilon)) \approx \frac{\epsilon^2}{p(1-p)}$$

所以:

$$\mathbb{E}_1[N_2] \geq \frac{c \cdot 0.25}{\epsilon^2} = \frac{c'}{4\epsilon^2}$$

Step 5: Regret 下界

在实例 1 中, 每次选 arm 2 都有 Regret ϵ :

$$\text{Regret} \geq \epsilon \cdot \mathbb{E}[N_2] \geq \frac{c'}{4\epsilon}$$

取 $\epsilon = O(1/\sqrt{T})$ 来最大化这个下界... 等等, 这里需要更精细的分析。

实际上, 通过选择 $\epsilon = O(\sqrt{\ln T / T})$, 可以得到:

$$\text{Regret} \geq \Omega(\sqrt{T})$$

□

具体数值感受

两个 Bernoulli arm, $\mu_1 = 0.5$, $\mu_2 = 0.5 + \epsilon$ 。

KL 散度:

$$D_{KL} = 0.5 \ln \frac{0.5}{0.5 - \epsilon} + 0.5 \ln \frac{0.5}{0.5 + \epsilon} \approx \frac{\epsilon^2}{0.25} = 4\epsilon^2$$

当 $\epsilon = 0.1$ 时: $D_{KL} \approx 0.04$

要有 90% 把握区分两个 arm ($D_{KL}(P_1 \| P_2) \geq 2.3$), 需要:

$$N_2 \geq \frac{2.3}{0.04} = 57.5 \text{ 次}$$

当 $\epsilon = 0.01$ 时: $D_{KL} \approx 0.0004$

需要: $N_2 \geq \frac{2.3}{0.0004} = 5750$ 次!

差距越小, 需要的探索越多, 这是不可避免的。

10.3 从下界到 $\sqrt{T}$

为什么 worst-case 是 $\sqrt{T}$

考虑对手可以选择 Δ :

Regret 下界 $\geq \frac{c \ln T}{\Delta}$ (需要探索来区分)

同时, $\text{Regret} \geq \Delta \cdot T \cdot p$ (选错 arm 的代价), 其中 p 是选错概率。

当 Δ 很小时, 第一项主导; 当 Δ 大时, 选错的代价主导。

对手的最优策略: 选 Δ 使两项平衡。

令 $\frac{c \ln T}{\Delta} \approx \Delta \cdot T \cdot p$ (某些项)

解得 $\Delta^* \approx \sqrt{\frac{c \ln T}{T}}$

此时 $\text{Regret} \approx \sqrt{T \ln T}$

所以任何算法的 worst-case Regret 至少是 $\Omega(\sqrt{T})$!

$\sqrt{T}$ 的本质

1. 估计精度以 $1/\sqrt{n}$ 改善 (中心极限定理/Hoeffding)
2. 区分差距 Δ 的 arm 需要 $O(1/\Delta^2)$ 样本
3. 当 Δ 可以任意小时, worst-case 探索代价是 $O(\sqrt{T})$
4. 这是**信息论极限**, 没有算法能突破

10.4 $\log T$ vs $\sqrt{T}$: 量词顺序的故事

一个常见的困惑

等等！前面 5.3 节说 UCB 的 Regret 是 $O(\log T/\Delta)$ ，本节又说信息论下界是 $\Omega(\sqrt{T})$ 。 $\log T$ 比 $\sqrt{T}$ 慢得多——这两个不矛盾吗？

不矛盾。它们回答的是两个不同的问题，区别在量词顺序。

两种渐近

Instance-dependent (先固定问题，再让 $T \rightarrow \infty$):

$$\forall \text{ 问题 } \nu, \quad \limsup_{T \rightarrow \infty} \frac{\mathbb{E}_{\nu}[\text{Regret}_T]}{\log T} < \infty$$

这是**渐近**陈述。每个具体问题都有自己的固定 Δ ，让 T 增大，UCB 的 Regret 按 $\log T$ 增长。Lai-Robbins 下界也是这个口径。

Minimax (先取 worst-case 问题，再看 T):

$$\forall T, \quad \sup_{\nu} \mathbb{E}_{\nu}[\text{Regret}_T] = \Theta(\sqrt{KT})$$

这是**非渐近** (finite- T) 陈述。对每个 T ，对手现造一个最难的问题。

关键：“最难的问题”会随 T 移动！同一个固定问题，在两种分析里给出的 Regret 量级完全不同。

worst-case instance 如何随 T 移动

对手最优 $\Delta^*(T) = \sqrt{\log T/T}$ ，这随 T 增大而**减小**：

T	$\Delta^*(T)$	对手要求的问题难度
10^2	0.21	容易区分 (大 Δ)
10^4	0.030	中等
10^6	0.0037	几乎做不到
10^8	0.00043	极难区分 (极小 Δ)

对手每个 T 都**现造**一个“刚好让 UCB 这 T 轮内区分不出来的”问题。这种“动态对手”才能让 UCB 输到 $\sqrt{T \log T}$ 。

如果你拿一个**固定**的具体问题 (比如 $\Delta = 0.1$)，对手就没法这样调。

同一个固定问题在两种 regime 之间穿越

固定 $\Delta = 0.1$ 的具体问题，看不同 T 下 Regret 的实际量级：

T	$\sqrt{\log T/T}$ vs $\Delta = 0.1$	Regime	Regret 量级
10^2	$0.21 > 0.1$	仍在探索期	$\Delta T = 10$
10^4	$0.030 < 0.1$	已进入 log 期	$\frac{8 \log T}{\Delta} \approx 736$
10^6	$0.0037 \ll 0.1$	深入 log 期	$\frac{8 \log T}{\Delta} \approx 1105$
10^8	$0.00043 \ll 0.1$	极深 log 期	$\frac{8 \log T}{\Delta} \approx 1474$

注意从 $T = 10^4$ 到 $T = 10^8$ (T 增长 10^4 倍)，Regret 只从 736 涨到 1474 (约 2 倍) —— 这正是 $\log T$ 对固定问题的渐近行为。

但如果对手在 $T = 10^8$ 时把问题换成 $\Delta = 0.0004$ ，UCB 的 Regret 会被推到 $\sqrt{T \log T} \approx 43000$ 。固定的问题永远看不到 $\sqrt{T}$ 增长，要看到 $\sqrt{T}$ ，对手必须按 T 现挑问题。

一句话总结

- $\log T$ 在说：“给我足够长时间，我会看清这个固定问题” (statistical learner 视角)
- $\sqrt{T}$ 在说：“无论 T 多长，总有一个问题刚好让我看不清” (game theorist 视角)

工程意义：

- 跑一个具体 A/B 测试 (Δ 是固定的物理量) $\rightarrow$ instance-dependent，期待 $\log T$
- 设计鲁棒 bandit 算法 (要对未知 Δ 都好用) $\rightarrow$ minimax，天花板 $\sqrt{T}$

回看 9.3 节：那里“对手选 $\Delta = \Theta(\sqrt{\log T/T})$ ”这一步就是 game theorist 在按 T 现挑对手；跟 5.3 节 UCB 分析里把 Δ 当常数是两套完全不同的设定，所以一个得 $\log T$ 、一个得 $\sqrt{T}$ 。

UCB 是不是 minimax 最优？

不完全是。三档 bandit 算法的对比：

	Instance-dep 上界	Minimax 上界
UCB1	$\sum_a \frac{8 \log T}{\Delta_a} \checkmark$ (达到 Lai-Robbins)	$O(\sqrt{KT \log T})$
MOSS / KL-UCB	同上 $\checkmark$	$O(\sqrt{KT}) \checkmark$ (达到 minimax 下界)
Minimax 下界	$\Omega(\sum_a \frac{\log T}{D_{KL}})$	$\Omega(\sqrt{KT})$

UCB1 只差一个 $\sqrt{\log T}$ 因子；MOSS (Minimax Optimal Strategy in Stochastic case) 通过更精细的 confidence bonus 去掉这个因子，两个口径都达到下界。

11 总结

概念	公式	数值例子
Regret	$\sum_t \ell_t - \min_x \sum_t \ell_t(x)$	$2.2 - 2.4 = -0.2$
MWU 更新	$w \leftarrow w(1 - \eta \ell)$	$1 \times 0.6 = 0.6$
MWU 界	$2\sqrt{T \ln N}$	$2\sqrt{10000 \times 4.6} = 428$
Hoeffding	$P(\hat{\mu} - \mu > \epsilon) \leq 2e^{-2n\epsilon^2}$	$n = 100, \epsilon = 0.1: 27\%$
95% 置信区间	$\pm \sqrt{1.84/n}$	$n = 100: \pm 0.14$
UCB	$\hat{\mu} + \sqrt{2 \ln t / n}$	$0 + 1.67 = 1.67$
Beta 更新	$\text{Beta}(\alpha + s, \beta + f)$	$\text{Beta}(1,1)+3 \text{ 赢 } 2 \text{ 输 } = \text{Beta}(4,3)$
EI	$(\mu - f^+) \Phi(Z) + \sigma \phi(Z)$	$0.1 \times 0.841 + 0.1 \times 0.242 = 0.108$

神奇结果

本讲核心信息：

1. 即使对手故意坑你，Regret 也只有 $O(\sqrt{T})$ ——平均后悔趋于零
2. 乘法惩罚让差选项指数衰减
3. 乐观原则：不确定就当它好（UCB）
4. 概率匹配：按可能性分配探索（Thompson Sampling）
5. $\sqrt{T}$ 是信息积累速度的本质限制