

第 10 周：变分法与最优控制

从优化函数到优化路径——连续时间优化的统一视角

目录

1	泛函优化：从优化点到优化函数	3
2	Euler-Lagrange 方程：泛函的极值条件	5
3	最大熵原理：约束下的分布选择	14
4	KL 散度与变分推断	17
5	信息瓶颈	23
6	最优控制与 HJB 方程	25
7	本周总结	32
8	思考题	32

本讲导读

本周的核心洞察

之前的优化：

- 优化向量 $x \in \mathbb{R}^n$
- $\min_x f(x)$
- 梯度下降、牛顿法、SGD

本周的优化：

- 优化函数 $y(x)$ 或路径 $x(t)$
- $\min_{y(\cdot)} J[y] = \int F(y, y', x) dx$
- Euler-Lagrange 方程、HJB 方程

惊人联系：

- 最大熵 $\Rightarrow$ 指数族分布
- 变分推断 $\Rightarrow$ ELBO
- E-L 的 $\lambda \Rightarrow$ Pontryagin costate $\Rightarrow$ HJB 的 $\nabla_x V$ （贯穿全章的“ λ 主线”）

内容结构

第一部分：泛函优化基础（10min）

第二部分：Euler-Lagrange 方程（15min）

第三部分：最大熵原理（15min）

第四部分：KL 散度与变分推断（15min）

第五部分：信息瓶颈（15min）

第六部分：最优控制与 HJB（25min）

1 泛函优化：从优化点到优化函数

什么是泛函？

回顾：

- **函数** $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，输入向量，输出数
- 例： $f(x_1, x_2) = x_1^2 + x_2^2$

新概念：

- **泛函** $J: \mathcal{F} \rightarrow \mathbb{R}$ ，输入函数，输出数
- $\mathcal{F}$ 是某个函数空间（如所有连续函数）

例子：

$$J[y] = \int_a^b F(y(x), y'(x), x) dx$$

输入一个函数 $y(x)$ ，输出一个数（积分值）

泛函的具体例子

例 1：曲线长度

从 $(0, 0)$ 到 $(1, 1)$ 的曲线 $y(x)$ ，长度是多少？

$$L[y] = \int_0^1 \sqrt{1 + (y'(x))^2} dx$$

这里 $F(y, y', x) = \sqrt{1 + (y')^2}$

具体计算： 如果 $y(x) = x$ （直线）

$$y'(x) = 1, \quad L = \int_0^1 \sqrt{1 + 1} dx = \sqrt{2} \approx 1.414$$

如果 $y(x) = x^2$ （抛物线）


$$y'(x) = 2x, \quad L = \int_0^1 \sqrt{1 + 4x^2} dx \approx 1.479$$

直线更短！（符合直觉）

泛函的具体例子（续）

例 2：最速降线（Brachistochrone）

小球从 $(0, 0)$ 滑到 $(1, -1)$ ，哪条路径最快？



时间泛函： $T[y] = \int_0^1 \frac{\sqrt{1+(y')^2}}{\sqrt{-2gy}} dx$

答案：摆线 (Cycloid)! 不是直线也不是抛物线

泛函的具体例子 (续)

例 3：信息熵

给定概率分布 $p(x)$ ，熵是多少？

$$H[p] = - \int p(x) \log p(x) dx$$

输入一个概率密度函数 $p(x)$ ，输出一个数（熵值）

例 4：KL 散度

两个分布 p, q 的“距离”：

$$D_{\text{KL}}[p||q] = \int p(x) \log \frac{p(x)}{q(x)} dx$$

这些都是泛函！

泛函优化的目标

问题：在所有满足某些条件的函数中，找使泛函取极值的函数

普通优化：

$$\min_{x \in \mathbb{R}^n} f(x) \Rightarrow \nabla f(x^*) = 0$$

泛函优化：

$$\min_{y(\cdot) \in \mathcal{F}} J[y] \Rightarrow ??$$

需要回答：

“泛函的梯度”是什么？

“泛函的极值条件”是什么？

答案：Euler-Lagrange 方程！

2 Euler-Lagrange 方程：泛函的极值条件

策略：泛函优化作为约束优化

E-L 方程有两条推导路线。我们先走有限维约束优化那条（拉格朗日乘子法），再用经典变分法 $\delta J = 0$ 验证。

为什么这么排？

- 离散化把问题降回有限维——大一多元微积分就够用
- 乘子 λ_k 不是辅助记号——连续极限下它就是物理动量 $p = \partial L / \partial \dot{q}$
- 这套机器后面 HJB 节直接复用： $\lambda \rightarrow \text{costate}$

目标：泛函

$$J[q] = \int_{t_0}^{t_1} L(q, \dot{q}, t) dt$$

取极值的必要条件。

Step 1: 时间离散化，位置与速度独立成变量

时间剖分： $t_k = t_0 + k \Delta t$, $k = 0, 1, \dots, N$, $\Delta t = (t_1 - t_0)/N$ 。

变量：位置 $q_k \approx q(t_k)$ ，速度 $v_k \approx \dot{q}(t_k)$ 。

关键：把 q_k 和 v_k 当作独立变量处理。它们之间的关系

$$v_k = \frac{q_{k+1} - q_k}{\Delta t}$$

现在变成显式约束，而不是定义。这一招就是后面 λ_k 出场的舞台。

离散作用量：

$$J(\{q_k\}, \{v_k\}) = \sum_{k=0}^{N-1} L(q_k, v_k, t_k) \Delta t$$

运动学约束（每个时间间隔一条）：

$$g_k := q_{k+1} - q_k - \Delta t v_k = 0, \quad k = 0, 1, \dots, N-1$$

共 N 条等式约束。边界 q_0, q_N 由初/末位置固定。

Step 2: 拉格朗日乘子绑定运动学约束

每条约束 $g_k = 0$ 引入一个乘子 λ_k ，构造有限维拉格朗日函数：

$$\mathcal{L}(\{q_k\}, \{v_k\}, \{\lambda_k\}) = \sum_{k=0}^{N-1} L(q_k, v_k, t_k) \Delta t + \sum_{k=0}^{N-1} \lambda_k (q_{k+1} - q_k - \Delta t v_k)$$

这是一个标准的大一级别多元函数——变量数 $3N+1$ ($N+1$ 个 q_k , N 个 v_k , N

个 λ_k)。做的事情和”用拉格朗日乘子求带约束极值”一模一样。
接下来只有一件事：**对每个变量求偏导，设为零。**

Step 3: KKT 条件——三组方程

对 v_k 求偏导 ($k = 0, \dots, N-1$):

$$\frac{\partial \mathcal{L}}{\partial v_k} = \frac{\partial L}{\partial v_k} \Big|_k \Delta t - \lambda_k \Delta t = 0 \implies \boxed{\lambda_k = \frac{\partial L}{\partial v_k} \Big|_k}$$

这就是共轭动量。 λ 在这一步从”约束乘子”获得了物理身份。

对内部点 q_k 求偏导 ($1 \leq k \leq N-1$, q_k 同时出现在第 k 项 L 和约束 g_{k-1}, g_k 里):

$$\frac{\partial \mathcal{L}}{\partial q_k} = \frac{\partial L}{\partial q_k} \Big|_k \Delta t - \lambda_k + \lambda_{k-1} = 0$$

整理:

$$\boxed{\frac{\lambda_k - \lambda_{k-1}}{\Delta t} = \frac{\partial L}{\partial q_k} \Big|_k}$$

乘子的离散时间导数等于 L 对位置的偏导——这就是即将浮现的 E-L 方程。

对 λ_k 求偏导:

$$\frac{\partial \mathcal{L}}{\partial \lambda_k} = q_{k+1} - q_k - \Delta t v_k = 0$$

恢复运动学约束 (这一组等式只是把 v_k 和 q_k 关联起来)。

Step 4: 连续极限 $\rightarrow$ Euler-Lagrange 方程

$\Delta t \rightarrow 0$ 时:

$$\lambda_k \rightarrow p(t), \quad v_k \rightarrow \dot{q}(t), \quad \frac{\lambda_k - \lambda_{k-1}}{\Delta t} \rightarrow \dot{p}(t)$$

KKT 三式分别变成:

$$\begin{aligned} \text{(I)} \quad p &= \frac{\partial L}{\partial \dot{q}} && \text{(共轭动量定义)} \\ \text{(II)} \quad \dot{p} &= \frac{\partial L}{\partial q} && \text{(动量演化)} \\ \text{(III)} \quad \dot{q} &= v && \text{(运动学约束)} \end{aligned}$$

把 (I) 代入 (II) 消去 p :

$$\frac{d}{dt} \frac{\partial L}{\partial \dot{q}} = \frac{\partial L}{\partial q}$$

即

$$\boxed{\frac{d}{dt} \frac{\partial L}{\partial \dot{q}_i} - \frac{\partial L}{\partial q_i} = 0}$$

这就是 Euler-Lagrange 方程。物理读法：动量随时间的变化率等于 L 对位置的偏导——广义牛顿第二定律。

核心结论：本质洞察：E-L 方程是拉格朗日乘子的演化方程

我们不是“凑出”了 E-L 方程，而是把约束优化的 KKT 条件取了连续极限。其中乘子 $\lambda_k \rightarrow p(t)$ 是核心——它在五种语言里有五个名字：

语言	λ 的名字
约束优化	拉格朗日乘子
经典力学	共轭动量 $p = \partial L / \partial \dot{q}$
变分法	作用量梯度 $\partial S / \partial q$
最优控制	costate / 伴随变量 (HJB / PMP 节)

这门课接下来所有的“ λ ”都是这一个 λ 。

另一种推导：经典变分法 ($\delta J = 0$)

完整起见，给出经典推导。这条路不离散化，直接在函数空间求极值。

变分概念：普通微分扰动 $x \rightarrow x + \epsilon$ ；泛函变分则扰动整个函数 $q(t) \rightarrow q(t) + \epsilon \eta(t)$ ，端点固定 $\eta(t_0) = \eta(t_1) = 0$ 。

一阶变分：

$$\delta J = \epsilon \int_{t_0}^{t_1} \left(\frac{\partial L}{\partial q} \eta + \frac{\partial L}{\partial \dot{q}} \dot{\eta} \right) dt$$

第二项分部积分（端点项因 $\eta(t_0) = \eta(t_1) = 0$ 而消失）：

$$\int \frac{\partial L}{\partial \dot{q}} \dot{\eta} dt = - \int \frac{d}{dt} \frac{\partial L}{\partial \dot{q}} \eta dt$$

合并：

$$\delta J = \epsilon \int_{t_0}^{t_1} \eta \left(\frac{\partial L}{\partial q} - \frac{d}{dt} \frac{\partial L}{\partial \dot{q}} \right) dt$$

对所有满足边界条件的 η ， $\delta J = 0 \implies$ 括号内必为零：

$$\frac{d}{dt} \frac{\partial L}{\partial \dot{q}} - \frac{\partial L}{\partial q} = 0 \quad \checkmark$$

和拉格朗日乘子法殊途同归。

两种推导方法对比

	拉格朗日乘子法	经典变分法
起点	离散化 + 显式运动学约束	函数空间的扰动
工具	KKT 条件	分部积分
λ 角色	共轭动量 p (核心物理量)	不显式出现
连续极限	$\Delta t \rightarrow 0$	无 (直接得到)
后续衔接	直通 HJB / costate / 伴随	适合纯理论分析

选哪条？ 两条都得到同一个 E-L 方程，但拉格朗日乘子法 **保留了 $\lambda = p$ 这条物理线索**——后面 Hamilton 力学、最优控制 (HJB / PMP) 都用得到。经典变分法更简洁，但 λ 隐藏在分部积分里没有显式出现。

例 1：最短路径

问题： 从 $(0, y_0)$ 到 $(1, y_1)$ ，哪条曲线最短？

$$L[y] = \int_0^1 \sqrt{1 + (y')^2} dx$$

这里 $F = \sqrt{1 + (y')^2}$

计算偏导：

$$\frac{\partial F}{\partial y} = 0 \quad (F \text{ 不显含 } y)$$

$$\frac{\partial F}{\partial y'} = \frac{y'}{\sqrt{1 + (y')^2}}$$

Euler-Lagrange 方程：

$$0 - \frac{d}{dx} \left(\frac{y'}{\sqrt{1 + (y')^2}} \right) = 0$$

$$\Rightarrow \frac{y'}{\sqrt{1 + (y')^2}} = C \quad (\text{常数})$$

$$\Rightarrow y' = \text{常数} \Rightarrow y = ax + b \quad (\text{直线!})$$

例 1 数值验证

边界条件： $(0, 0) \rightarrow (1, 1)$

E-L 解： $y = x$ (直线)

$$L = \int_0^1 \sqrt{1 + 1} dx = \sqrt{2} \approx 1.414$$

尝试其他曲线：

$$y = x^2: \quad y' = 2x$$

$$L = \int_0^1 \sqrt{1 + 4x^2} dx = \frac{1}{4} [2x\sqrt{1 + 4x^2} + \sinh^{-1}(2x)]_0^1 \approx 1.479$$

$$y = \sin\left(\frac{\pi x}{2}\right): \quad y' = \frac{\pi}{2} \cos\left(\frac{\pi x}{2}\right)$$

$$L = \int_0^1 \sqrt{1 + \frac{\pi^2}{4} \cos^2\left(\frac{\pi x}{2}\right)} dx \approx \mathbf{1.534}$$

结论： 直线确实最短！

例 2：最速降线

问题： 小球从原点滑到 (x_1, y_1) ，重力场中，哪条路最快？

速度 $v = \sqrt{2gy}$ （能量守恒），时间：

$$T[y] = \int_0^{x_1} \frac{\sqrt{1 + (y')^2}}{\sqrt{2gy}} dx$$

这里 $F = \frac{\sqrt{1 + (y')^2}}{\sqrt{2gy}}$

E-L 方程的解： 摆线（Cycloid）参数形式

$$x = r(\theta - \sin \theta), \quad y = r(1 - \cos \theta)$$

历史： 1696 年，Johann Bernoulli 提出，Newton、Leibniz、L'Hôpital、Jakob Bernoulli 都给出了解答

例 2 数值验证

边界： $(0, 0) \rightarrow (1, 1)$ ， $g = 10$

直线 $y = x$ ：

$$T_{\text{直线}} = \int_0^1 \frac{\sqrt{2}}{\sqrt{20x}} dx = \frac{\sqrt{2}}{\sqrt{20}} \cdot 2\sqrt{x} \Big|_0^1 = \frac{2\sqrt{2}}{\sqrt{20}} \approx \mathbf{0.632 \text{ s}}$$

摆线（数值积分）：

$$T_{\text{摆线}} \approx \mathbf{0.584 \text{ s}}$$

摆线比直线快约 8%！

直觉： 摆线开始时更陡，小球先获得更大速度

Beltrami 恒等式：特殊情况

当 F 不显含 x 时 ($\frac{\partial F}{\partial x} = 0$)，有更简单的形式：

$$F - y' \frac{\partial F}{\partial y'} = C \quad (\text{常数})$$

证明（选读）：


$$\frac{d}{dx} \left(F - y' \frac{\partial F}{\partial y'} \right) = \frac{\partial F}{\partial y} y' + \frac{\partial F}{\partial y'} y'' - y'' \frac{\partial F}{\partial y'} - y' \frac{d}{dx} \frac{\partial F}{\partial y'}$$

$$= y' \left(\frac{\partial F}{\partial y} - \frac{d}{dx} \frac{\partial F}{\partial y'} \right) = 0$$

应用：最速降线、测地线等问题可以用这个简化

例 3：悬链线 (Catenary)

问题：两端固定的柔软链条，在重力下的形状是什么？



悬链线

物理：链条在势能最低的位置平衡

泛函：势能 $= \int \rho g y \, ds = \int \rho g y \sqrt{1 + (y')^2} \, dx$

这里 $F = y \sqrt{1 + (y')^2}$

悬链线的求解

用 Beltrami 恒等式 (F 不显含 x):

$$F - y' \frac{\partial F}{\partial y'} = C$$

计算:

$$\frac{\partial F}{\partial y'} = \frac{y \cdot y'}{\sqrt{1 + (y')^2}}$$

$$F - y' \frac{\partial F}{\partial y'} = y \sqrt{1 + (y')^2} - \frac{y(y')^2}{\sqrt{1 + (y')^2}} = \frac{y}{\sqrt{1 + (y')^2}} = C$$

解出: $y = C \sqrt{1 + (y')^2}$

令 $y' = \sinh(t)$, 则 $y = C \cosh(t)$

悬链线方程: $y = a \cosh\left(\frac{x}{a}\right)$

悬链线数值验证

边界: $(-1, 1.5) \rightarrow (1, 1.5)$

悬链线: $y = a \cosh(x/a)$, 其中 $a \cosh(1/a) = 1.5$

数值求解: $a \approx 0.83$

$y(x) = 0.83 \cosh(x/0.83)$

势能 (取 $\rho g = 1$):

$$E_{\text{悬链线}} = \int_{-1}^1 y \sqrt{1 + (y')^2} dx \approx \mathbf{3.52}$$

对比抛物线: $y = 0.5x^2 + 1$ (同样经过两 endpoint)

$$E_{\text{抛物线}} = \int_{-1}^1 (0.5x^2 + 1) \sqrt{1 + x^2} dx \approx \mathbf{3.58}$$

悬链线势能更低! ($3.52 < 3.58$)

例 4: 等周问题 (Isoperimetric)

问题: 给定周长 L , 围成最大面积的曲线是什么?

约束: $\oint ds = L$ (周长固定)

目标: $\max A = \frac{1}{2} \oint (x dy - y dx)$

这是带约束的泛函优化!

用拉格朗日乘子:

$$\mathcal{L} = A - \lambda(\quad - L)$$

结论: 曲率恒定 $\Rightarrow$ 圆!

数值验证: 周长 $L = 2\pi$

圆: 半径 $r = 1$, 面积 $= \pi \approx \mathbf{3.14}$

正方形：边长 = $\pi/2$ ，面积 = $(\pi/2)^2 \approx 2.47$

正六边形：面积 ≈ 2.72

圆确实最大！

多变量推广

多个函数： $J[y_1, \dots, y_n] = \int F(y_1, \dots, y_n, y'_1, \dots, y'_n, x) dx$

E-L 方程（对每个 y_i ）：

$$\frac{\partial F}{\partial y_i} - \frac{d}{dx} \frac{\partial F}{\partial y'_i} = 0, \quad i = 1, \dots, n$$

高阶导数： $J[y] = \int F(y, y', y'', x) dx$

E-L 方程：

$$\frac{\partial F}{\partial y} - \frac{d}{dx} \frac{\partial F}{\partial y'} + \frac{d^2}{dx^2} \frac{\partial F}{\partial y''} = 0$$

Hamilton 原理：动力学源于变分

E-L 之前的例子都是**几何/静力泛函**（路径长度、势能极小化）。但 E-L 真正诞生于**经典力学**——这是 Lagrange 1788 年的工作。

Hamilton 原理 (1834)： 物理系统的真实轨迹 $q(t)$ 使**作用量泛函**取极值

$$S[q] = \int_{t_0}^{t_1} L(q, \dot{q}, t) dt, \quad L = T - V$$

其中 T 是动能、 V 是势能——都是**标量**。运动方程就是 E-L：

$$\frac{d}{dt} \frac{\partial L}{\partial \dot{q}_i} - \frac{\partial L}{\partial q_i} = 0$$

奇迹： 你只要写出两个**标量**（ T 和 V ），求几次偏导，运动方程就自动浮现——不画受力图、不分解矢量、不算约束反作用力。

例 5：单摆——牛顿 vs 拉格朗日（热身）

长度 ℓ 、质量 m 的单摆，求 $\theta(t)$ 。

牛顿法： 画受力图。重力 mg 竖直、张力 $T_{\text{绳}}$ 沿绳指向支点。

- 切向分解： $m\ell\ddot{\theta} = -mg \sin \theta$
- 径向： $T_{\text{绳}} - mg \cos \theta = m\ell\dot{\theta}^2$ （要算，但和运动方程无关）

必须选对分解方向，**必须**手动丢掉张力。

拉格朗日法： 广义坐标 θ ，位置 $(\ell \sin \theta, -\ell \cos \theta)$ ，速度平方 $\dot{x}^2 + \dot{y}^2 = \ell^2 \dot{\theta}^2$ 。直接

写：

$$T = \frac{1}{2}m\ell^2\dot{\theta}^2, \quad V = -mg\ell \cos \theta, \quad L = \frac{1}{2}m\ell^2\dot{\theta}^2 + mg\ell \cos \theta$$

代 E-L：

$$\frac{d}{dt}(m\ell^2\dot{\theta}) + mg\ell \sin \theta = 0 \quad \Rightarrow \quad \ddot{\theta} = -\frac{g}{\ell} \sin \theta \quad \checkmark$$

张力压根没出现——约束 $|r| = \ell$ 被广义坐标 θ 内化掉了。单摆里两种方法难度差不多；下一个例子（双摆）会把差距拉开一个量级。

单摆数值：非线性的真实影响

$\ell = 1 \text{ m}$, $g = 9.81 \text{ m/s}^2$ 。小角度周期 $T_0 = 2\pi\sqrt{\ell/g} = 2.006 \text{ s}$ 。

数值积分 $\ddot{\theta} = -\frac{g}{\ell} \sin \theta$ ：

初始角 θ_0	数值周期	偏差
10°	2.010 s	+0.2%
30°	2.041 s	+1.7%
60°	2.165 s	+7.9%
90°	2.368 s	+18.1%
150°	3.498 s	+74.4%

大角度更慢——非线性的实证。E-L 方程本身没变，但解的行为远离了小角度线性化的图景。

直觉：衔接 HJB：从 Lagrangian 到 Hamiltonian

连续极限下 $\lambda \rightarrow p$ 。做 **Legendre 变换** 定义 Hamiltonian：

$$H(q, p, t) := p^\top \dot{q} - L(q, \dot{q}, t) \Big|_{\dot{q}=\dot{q}(q,p,t)}$$

（自治保守系统： $H = T + V$ 就是总能量。）E-L 方程化为对称的一阶系统：

$$\dot{q} = \frac{\partial H}{\partial p}, \quad \dot{p} = -\frac{\partial H}{\partial q}$$

后面第 6 节的 HJB 方程

$$-\frac{\partial V}{\partial t} = \min_u \{ \ell(x, u) + \nabla_x V \cdot f(x, u) \}$$

就是这套对偶推到**最优控制**的版本：

$$L \leftrightarrow \ell(x, u), \quad p \leftrightarrow \nabla_x V, \quad H \leftrightarrow \min_u \{ \ell + p \cdot f \}.$$

变分法、约束优化、Hamilton 力学、最优控制——同一个故事的四种语言。你现在写的 λ_k ，就是这个故事的开头。

3 最大熵原理：约束下的分布选择

熵的回顾

离散熵： $H(p) = -\sum_i p_i \log p_i$

连续熵（微分熵）： $H[p] = -\int p(x) \log p(x) dx$

熵的含义：

- 不确定性的度量
- 信息量的期望
- 分布的“扩散程度”

熵最大的分布：最“均匀”、最“无偏”

最大熵原理

问题：已知某些约束（如均值、方差），应该选哪个分布？

最大熵原理（Jaynes, 1957）：

选择满足约束的熵最大的分布

理由：

- 不引入额外假设
- 最“保守”的选择
- 信息论上最优

数学形式：

$$\max_p H[p] = -\int p(x) \log p(x) dx$$

subject to 约束条件

例 1：无约束最大熵

问题：在 $[a, b]$ 上，哪个分布熵最大？

约束： $\int_a^b p(x) dx = 1$ （归一化）

Lagrangian：

$$\mathcal{L}[p] = -\int p \log p dx - \lambda \left(\int p dx - 1 \right)$$

变分： $\frac{\delta \mathcal{L}}{\delta p} = -\log p - 1 - \lambda = 0$

$\Rightarrow p(x) = e^{-1-\lambda} = \text{常数}$

归一化： $p(x) = \frac{1}{b-a}$ （均匀分布！）

例 1 数值验证

区间 $[0, 1]$

均匀分布: $p(x) = 1$

$H = -\int_0^1 1 \cdot \log 1 dx = 0$ (以 e 为底)

换成 bits: $H = \log_2(1) = 0$ bits... 不对!

更正: 微分熵可以是负数! 对于均匀分布:

$$H = -\int_0^1 1 \cdot \ln 1 dx = 0 \text{ nats}$$

对比三角分布: $p(x) = 2x$ ($x \in [0, 1]$)

$$\begin{aligned} H &= -\int_0^1 2x \ln(2x) dx = -\int_0^1 2x(\ln 2 + \ln x) dx \\ &= -\ln 2 - \int_0^1 2x \ln x dx = -\ln 2 - 2 \cdot \left(-\frac{1}{4}\right) = -\ln 2 + 0.5 \approx -0.193 \end{aligned}$$

均匀分布熵更大 ($0 > -0.193$)

例 2: 给定均值的最大熵

问题: $x \geq 0$, 已知 $\mathbb{E}[x] = \mu$, 哪个分布熵最大?

约束:

- $\int_0^\infty p(x) dx = 1$
- $\int_0^\infty x \cdot p(x) dx = \mu$

Lagrangian:

$$\mathcal{L} = -\int p \log p dx - \lambda_0 \left(\int p dx - 1 \right) - \lambda_1 \left(\int xp dx - \mu \right)$$

变分: $-\log p - 1 - \lambda_0 - \lambda_1 x = 0$

$\Rightarrow p(x) = e^{-1-\lambda_0} \cdot e^{-\lambda_1 x} = Ce^{-\lambda_1 x}$

这是指数分布! $p(x) = \frac{1}{\mu} e^{-x/\mu}$

例 2 数值验证

给定 $\mu = 2$

指数分布: $p(x) = 0.5e^{-x/2}$

熵: $H = -\int_0^\infty p \ln p dx = 1 + \ln \mu = 1 + \ln 2 \approx \mathbf{1.693}$ nats

对比 Gamma 分布: $p(x) = \frac{x}{\theta^2} e^{-x/\theta}$, 均值 $= 2\theta = 2 \Rightarrow \theta = 1$

$$p(x) = xe^{-x}$$

熵： $H = 2 - \ln(1) - \psi(2) = 2 - 0 - (1 - \gamma) \approx 2 - 0.423 = \mathbf{1.577}$ nats

指数分布熵更大 ($1.693 > 1.577$)

例 3：给定均值和方差的最大熵

问题： $x \in \mathbb{R}$ ，已知 $\mathbb{E}[x] = \mu$ ， $\text{Var}(x) = \sigma^2$

约束：

- $\int p \, dx = 1$
- $\int xp \, dx = \mu$
- $\int (x - \mu)^2 p \, dx = \sigma^2$

变分： $-\log p - 1 - \lambda_0 - \lambda_1 x - \lambda_2 (x - \mu)^2 = 0$

$\Rightarrow p(x) \propto \exp(-\lambda_1 x - \lambda_2 (x - \mu)^2)$

配方得： $p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$

这是高斯分布！

最大熵与指数族

核心结论：最大熵分布的一般形式

约束 $\mathbb{E}[f_k(x)] = \alpha_k$ ， $k = 1, \dots, K$ 下的最大熵分布是：

$$p(x) = \frac{1}{Z} \exp\left(-\sum_{k=1}^K \lambda_k f_k(x)\right)$$

这正是**指数族分布**的形式！

经典结果：

约束	最大熵分布	名称
无	均匀	Uniform
$\mathbb{E}[x] = \mu$ ($x \geq 0$)	指数	Exponential
$\mathbb{E}[x], \text{Var}(x)$	高斯	Gaussian
$\mathbb{E}[\log x], \mathbb{E}[x]$	Gamma	Gamma
$p_i \geq 0, \sum p_i = 1$	离散均匀	Categorical

为什么高斯分布如此常见？

最大熵解释：

如果只知道均值和方差，高斯是“最保守”的选择

中心极限定理解释：

大量独立随机变量之和趋向高斯

两者的联系：

CLT 说高斯是“最可能”出现的

MaxEnt 说高斯是“最少假设”的

都指向同一个分布！

4 KL 散度与变分推断

KL 散度的定义

KL 散度 (Kullback-Leibler Divergence)：

$$D_{\text{KL}}(p\|q) = \int p(x) \log \frac{p(x)}{q(x)} dx = \mathbb{E}_p \left[\log \frac{p(x)}{q(x)} \right]$$

性质：

- $D_{\text{KL}}(p\|q) \geq 0$ (非负)
- $D_{\text{KL}}(p\|q) = 0$ 当且仅当 $p = q$
- **不对称**： $D_{\text{KL}}(p\|q) \neq D_{\text{KL}}(q\|p)$

直觉：用 q 编码来自 p 的数据，平均多花多少 bits

Huffman 例子 (一)：先看最优编码长什么样

设定：4 个符号 $\{A, B, C, D\}$ 。

真实分布 p 和误以为的分布 q ：

	A	B	C	D
p	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{8}$
q	$\frac{1}{8}$	$\frac{1}{8}$	$\frac{1}{4}$	$\frac{1}{2}$

(注意 q 把 A, B 当稀有事件， D 当最常见——和 p 几乎反着来。)

根据 p 构造 Huffman 编码：合并两个最小 $\frac{1}{8} \rightarrow \frac{1}{4}$ ，再合并两个 $\frac{1}{4} \rightarrow \frac{1}{2}$ ，再合并两个 $\frac{1}{2}$ ：

码表 (p-optimal)： $A : 0, B : 10, C : 110, D : 111$

平均长度（在 p 上）：

$$\bar{\ell}_p = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = 1.75 \text{ bits} = H(p) \checkmark$$

（恰好相等： p 是 **dyadic 分布**，Huffman 严格达到熵下界。）

Huffman 例子（二）：用错码本要多花多少 bits

根据 q 构造 Huffman 编码：同样的算法，但合并顺序变了——两个 $\frac{1}{8}$ (A, B) 合并成 $\frac{1}{4}$ ，再和 $\frac{1}{4}$ (C) 合并成 $\frac{1}{2}$ ，再和 $\frac{1}{2}$ (D) 合并：

码表 (q-optimal)： $D : 0, C : 10, A : 110, B : 111$

码长： $A:3, B:3, C:2, D:1$ 。

用这套（错的） q -码本编码 p 的数据——这正是 KL 描述的场景。平均比特数（在 p 上）：

$$\bar{\ell}_q^{(p)} = \frac{1}{2} \cdot 3 + \frac{1}{4} \cdot 3 + \frac{1}{8} \cdot 2 + \frac{1}{8} \cdot 1 = \frac{3}{2} + \frac{3}{4} + \frac{1}{4} + \frac{1}{8} = 2.625 \text{ bits}$$

多花的 bits：

$$\bar{\ell}_q^{(p)} - \bar{\ell}_p = 2.625 - 1.75 = \boxed{0.875 \text{ bits / 符号}}$$

直接算 $D_{\text{KL}}(p||q)$ 验证：

$$\begin{aligned} D_{\text{KL}}(p||q) &= \sum_i p_i \log_2 \frac{p_i}{q_i} = \frac{1}{2} \log_2 4 + \frac{1}{4} \log_2 2 + \frac{1}{8} \log_2 \frac{1}{2} + \frac{1}{8} \log_2 \frac{1}{4} \\ &= 1 + \frac{1}{4} - \frac{1}{8} - \frac{1}{4} = \boxed{0.875 \text{ bits}} \quad \checkmark \end{aligned}$$

两个 0.875 完全一致——KL 散度的操作含义。

核心结论：为什么是 $\log(p/q)$ ？

Shannon 编码定理：用分布 q 编码时，最优码长是 $\ell_i = -\log_2 q_i$ 。

- 用 p 的码本编 p 的数据：每符号 $-\log_2 p_i$ bits，平均 $H(p)$
- 用 q 的码本编 p 的数据：每符号 $-\log_2 q_i$ bits，平均 $\mathbb{E}_p[-\log_2 q] = H(p, q)$ （交叉熵）

两者之差就是 KL：

$$D_{\text{KL}}(p||q) = H(p, q) - H(p) = \mathbb{E}_p \left[\log_2 \frac{p}{q} \right]$$

操作翻译：每 1000 个 p -符号，用 q -码本要比用 p -码本多花 $1000 \times 0.875 = 875$ bits——这就是”知识错位”的客观代价。

深度学习挂钩：分类问题里的交叉熵损失 $-\sum y_i \log \hat{p}_i$ 就是 $H(p, q)$ 减去常数 $H(p)$ 后剩下的 $D_{\text{KL}}(p||q)$ ——最小化交叉熵 = 最小化 KL。

KL 散度的数值例子

两个高斯分布： $p = \mathcal{N}(0, 1)$, $q = \mathcal{N}(\mu, \sigma^2)$

$$D_{\text{KL}}(p||q) = \frac{1}{2} \left(\frac{1}{\sigma^2} + \frac{\mu^2}{\sigma^2} - 1 - \log \frac{1}{\sigma^2} \right)$$

数值： $p = \mathcal{N}(0, 1)$, $q = \mathcal{N}(1, 1)$

$$D_{\text{KL}}(p||q) = \frac{1}{2}(1 + 1 - 1 - 0) = \mathbf{0.5 \text{ nats}}$$

反过来： $D_{\text{KL}}(q||p) = \frac{1}{2}(1 + 1 - 1 - 0) = \mathbf{0.5 \text{ nats}}$

(这个特例下恰好相等，因为方差相同)

不同方差： $p = \mathcal{N}(0, 1)$, $q = \mathcal{N}(0, 2)$

$$D_{\text{KL}}(p||q) = \frac{1}{2}(0.5 + 0 - 1 - \ln 0.5) = \frac{1}{2}(-0.5 + 0.693) = \mathbf{0.097}$$

$$D_{\text{KL}}(q||p) = \frac{1}{2}(2 + 0 - 1 - \ln 2) = \frac{1}{2}(1 - 0.693) = \mathbf{0.153}$$

不对称！

变分推断的动机

贝叶斯推断问题：

已知观测 $\mathbf{x}$ ，求后验 $p(\mathbf{z}|\mathbf{x})$

$$p(\mathbf{z}|\mathbf{x}) = \frac{p(\mathbf{x}|\mathbf{z})p(\mathbf{z})}{p(\mathbf{x})} = \frac{p(\mathbf{x}|\mathbf{z})p(\mathbf{z})}{\int p(\mathbf{x}|\mathbf{z})p(\mathbf{z}) d\mathbf{z}}$$

问题：分母的积分通常无法计算！

例： $\mathbf{z}$ 是 1000 维，积分是 1000 重积分

解决方案：

- MCMC：采样近似，但慢
- **变分推断：**用简单分布 $q(\mathbf{z})$ 近似 $p(\mathbf{z}|\mathbf{x})$

变分推断：核心思想

目标：找 $q(\mathbf{z})$ 使得 $q(\mathbf{z}) \approx p(\mathbf{z}|\mathbf{x})$

度量近似好坏：KL 散度

$$D_{\text{KL}}(q||p) = \int q(\mathbf{z}) \log \frac{q(\mathbf{z})}{p(\mathbf{z}|\mathbf{x})} d\mathbf{z}$$

展开：

$$\begin{aligned} D_{\text{KL}}(q||p) &= \int q \log q \, d\mathbf{z} - \int q \log p(\mathbf{z}|\mathbf{x}) \, d\mathbf{z} \\ &= \int q \log q \, d\mathbf{z} - \int q \log \frac{p(\mathbf{x}, \mathbf{z})}{p(\mathbf{x})} \, d\mathbf{z} \\ &= \int q \log q \, d\mathbf{z} - \int q \log p(\mathbf{x}, \mathbf{z}) \, d\mathbf{z} + \log p(\mathbf{x}) \end{aligned}$$

ELBO: Evidence Lower Bound

整理上式：

$$\log p(\mathbf{x}) = D_{\text{KL}}(q||p) + \underbrace{\int q \log \frac{p(\mathbf{x}, \mathbf{z})}{q(\mathbf{z})} \, d\mathbf{z}}_{\text{ELBO}(q)}$$

因为 $D_{\text{KL}} \geq 0$ ：

$$\log p(\mathbf{x}) \geq \text{ELBO}(q)$$

核心结论：ELBO

$$\text{ELBO}(q) = \mathbb{E}_q[\log p(\mathbf{x}, \mathbf{z})] - \mathbb{E}_q[\log q(\mathbf{z})]$$

最小化 KL $\Leftrightarrow$ 最大化 ELBO

ELBO 的两种形式：同一量的两副面孔

形式 1（能量 + 熵 / 自由能视角）：

$$\text{ELBO}(q) = \mathbb{E}_q[\log p(\mathbf{x}, \mathbf{z})] + H[q]$$

形式 2（重构 - 正则 / 自编码器视角）：

$$\text{ELBO}(q) = \mathbb{E}_q[\log p(\mathbf{x}|\mathbf{z})] - D_{\text{KL}}(q(\mathbf{z})||p(\mathbf{z}))$$

数学上完全等价——一行就推完。把联合写成条件 $\times$ 先验： $\log p(\mathbf{x}, \mathbf{z}) = \log p(\mathbf{x}|\mathbf{z}) + \log p(\mathbf{z})$ ，代入形式 1：

$$\underbrace{\mathbb{E}_q[\log p(\mathbf{x}|\mathbf{z})]}_{\text{重构项}} + \underbrace{\mathbb{E}_q[\log p(\mathbf{z})] - \mathbb{E}_q[\log q(\mathbf{z})]}_{= -D_{\text{KL}}(q||p(\mathbf{z}))}$$

就是形式 2。但强调的东西完全不同——下面三页详谈。

形式 1 vs 形式 2：四个维度的对照

	形式 1（能量 + 熵）	形式 2（重构 - 正则）
物理类比	Helmholtz 自由能 $F = U - TS$	率失真：rate = KL, distortion = $-\mathbb{E}[\log p(\mathbf{x} \mathbf{z})]$
需要的输入	只需联合 $p(\mathbf{x}, \mathbf{z})$	必须显式分解 $p(\mathbf{x} \mathbf{z}) \cdot p(\mathbf{z})$
$\mathbf{z}$ 的地位	普通隐变量，无先验区分	”潜变量”，有显式先验 $p(\mathbf{z})$
易算的那一项	$H[q]$ ：指数族 q 有闭式（高斯 $\frac{1}{2} \log \det \Sigma + c$ ）	$D_{\text{KL}}(q p(\mathbf{z}))$ ：高斯-高斯有闭式（VAE 招牌）
难算的那一项	$\mathbb{E}_q[\log p(\mathbf{x}, \mathbf{z})]$ ：MC 方差大	$\mathbb{E}_q[\log p(\mathbf{x} \mathbf{z})]$ ：需要 reparameterization

两种形式的”易算项”是同一个东西的两种切法——都是”关于 q 自己或 q 与先验之间的解析项”。指数族 q 下这一项必有闭式；涉及生成模型的那一项必须采样。

形式 1 vs 形式 2：优化时的行为差异

形式 1：能量低 + q 散开。没有显式的” q 要靠近某个固定分布”压力—— q 只被联合似然牵引。

形式 2：重构好 + $q(\mathbf{z}|\mathbf{x})$ 不离先验 $p(\mathbf{z})$ 太远。这个”靠近先验”压力是 VAE 的双刃剑：

- **后验崩溃** (posterior collapse)：当解码器足够强（如 PixelCNN/Transformer）时，KL 项把 $q(\mathbf{z}|\mathbf{x})$ 拉到等于 $p(\mathbf{z})$ ， $\mathbf{z}$ 不传递任何关于 $\mathbf{x}$ 的信息——VAE 退化成无 latent 的纯生成模型
- **β -VAE** (Higgins 2017)：给 KL 项加权重 β ； $\beta > 1$ 鼓励 disentangled latent, $\beta < 1$ 缓解后验崩溃
- **KL annealing**：训练早期把 KL 项权重从 0 缓升到 1，让重构先学起来

为什么形式 1 没有这个病？形式 1 的熵项 $-\mathbb{E}_q[\log q]$ 鼓励 q 散开，但不指定散向哪里。形式 2 把它拆成 $-\mathbb{E}_q[\log q] + \mathbb{E}_q[\log p(\mathbf{z})]$ ，第二项引入了”瞄准 $p(\mathbf{z})$ ”的指向性。后验崩溃是形式 2 视角放大出来的工程问题——不是 ELBO 本身的问题。

核心结论：选哪个？

场景	用哪个形式
理论分析、连接 KL/MaxEnt/统计力学	形式 1
平均场 VI ($q = \prod_i q_i$, 每个 $H[q_i]$ 独立)	形式 1
能量基模型 (EBM)、Boltzmann 机	形式 1
Friston 自由能原理 (神经科学)	形式 1
写 VAE 代码 / 实现 encoder-decoder	形式 2
β -VAE、disentanglement 研究	形式 2
Diffusion model (每步 KL 是相邻 timestep 间)	形式 2
任何”有 encoder 和 decoder 两个网络”的设定	形式 2

助记：形式 1 长得像物理（能量减熵 = 自由能），形式 2 长得像工程（信号 - 正则）。做理论用 1，写代码用 2。

这正是 VAE 的损失函数（形式 2）——下一页给出完整 VAE 损失。

VAE 损失函数的来源

变分自编码器 (VAE)：

编码器： $q_\phi(\mathbf{z}|\mathbf{x})$ （用神经网络参数化）

解码器： $p_\theta(\mathbf{x}|\mathbf{z})$

损失函数：

$$\mathcal{L}(\theta, \phi) = -\text{ELBO} = -\mathbb{E}_{q_\phi}[\log p_\theta(\mathbf{x}|\mathbf{z})] + D_{\text{KL}}(q_\phi(\mathbf{z}|\mathbf{x})||p(\mathbf{z}))$$

第一项：重构损失（让解码器能还原输入）

第二项：KL 正则（让编码分布接近先验）

变分推断给出了 VAE 的理论基础！

数值例子：高斯 VAE**设置：**先验 $p(\mathbf{z}) = \mathcal{N}(0, I)$ 编码器输出 $q_\phi(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mu_\phi(\mathbf{x}), \text{diag}(\sigma_\phi^2(\mathbf{x})))$ **KL 项**（解析形式）：对于 d 维高斯

$$D_{\text{KL}}(q||p) = \frac{1}{2} \sum_{j=1}^d (\mu_j^2 + \sigma_j^2 - 1 - \log \sigma_j^2)$$

数值： $d = 2$, $\mu = (1, 0.5)$, $\sigma^2 = (0.5, 0.8)$

$$D_{\text{KL}} = \frac{1}{2}[(1 + 0.5 - 1 - \ln 0.5) + (0.25 + 0.8 - 1 - \ln 0.8)]$$

$$= \frac{1}{2}[(0.5 + 0.693) + (0.05 + 0.223)] = \frac{1}{2}[1.193 + 0.273] = \mathbf{0.733}$$

5 信息瓶颈

信息瓶颈的动机**问题：** 给定输入 X 和目标 Y ，如何找最好的表示 Z ？**好的表示应该：**

- 保留关于 Y 的信息（预测能力）
- 压缩 X 的冗余信息（简洁性）

信息论度量：

- $I(Z; Y)$: Z 关于 Y 的信息（越大越好）
- $I(X; Z)$: Z 关于 X 的信息（越小越好，压缩）

信息瓶颈目标**Tishby et al., 1999:**

$$\min_{p(z|x)} I(X; Z) - \beta I(Z; Y)$$

 $\beta > 0$ **控制权衡：**

- β 大：更看重预测能力
- β 小：更看重压缩

等价形式：

$$\max_{p(z|x)} I(Z; Y) \quad \text{s.t.} \quad I(X; Z) \leq R$$

在压缩预算 R 下最大化预测信息

信息瓶颈与深度学习

深度网络： $X \rightarrow h_1 \rightarrow h_2 \rightarrow \dots \rightarrow h_L \rightarrow Y$

每一层 h_l 可以看作 X 的表示

Shwartz-Ziv & Tishby, 2017:

训练过程中：

- 初期： $I(X; h_l)$ 增加（学习特征）
- 后期： $I(X; h_l)$ 减少， $I(h_l; Y)$ 保持（压缩无关信息）

这叫“信息平面”分析

（虽然后来有争议，但思想很有影响力）

信息瓶颈的数值例子

简单设置：

$X \in \{0, 1, 2, 3\}$ （4 个值）， $Y \in \{0, 1\}$ （2 个值）

$$p(x, y) = \begin{cases} 0.2 & (x, y) \in \{(0, 0), (1, 0), (2, 1), (3, 1)\} \\ 0.1 & (x, y) \in \{(0, 1), (1, 1), (2, 0), (3, 0)\} \end{cases}$$

完美表示： $Z = X$

$I(X; Z) = H(X) \approx 2$ bits（完全保留）

$I(Z; Y) = I(X; Y) \approx 0.28$ bits

压缩表示： $Z = \mathbf{1}[X \geq 2]$

$I(X; Z) = H(Z) = 1$ bit（压缩一半）

$I(Z; Y) = I(X; Y)$ （如果 Z 与 Y 关系不变）

变分信息瓶颈（VIB）

问题： $I(X; Z)$ 难以计算

VIB (Alemi et al., 2017)：用变分方法近似

$$\mathcal{L}_{\text{VIB}} = \mathbb{E}_{p(x, y)} \left[\mathbb{E}_{q_\phi(z|x)} [-\log p_\theta(y|z)] + \beta D_{\text{KL}}(q_\phi(z|x) \| r(z)) \right]$$

比较 VAE：

- VAE: 重构 x , 正则化到先验
- VIB: 预测 y , 正则化到先验

VIB 用于分类: 更鲁棒、更好的泛化

6 最优控制与 HJB 方程

统一图景：地毯与高度图

先放下推导，看一个画面。

想象 state-time 空间里有一张”最优地毯”：

- 每个起点 (x_0, t_0) 发出一条最优轨迹
- 所有这些轨迹填满整个 (x, t) 平面
- 这就是”最优场” (field of extremals)

描述这张地毯有两种方式：

(1) 一根线一根线地描述——EL / PMP

跟着一条最优轨迹走，告诉你它每一刻应该往哪偏。这是 **Lagrangian** 的视角：拿着 $(x, \dot{x})$ 沿时间往前推。

(2) 给地毯画”高度图”——HJB

在每个 (x, t) 点标上”从这里出发的最小代价” $V(x, t)$ 。高度图的**斜坡**决定了每根线该怎么走。这是 **Hamiltonian** 的视角：拿着 $(x, p = \nabla_x V)$ 看全空间。

关键观察：

同一张地毯，两种坐标。

Track A 告诉你”线怎么走”，*Track B* 告诉你”高度怎么分布”。

它们最后必然给出同一个答案——因为是同一张地毯。

那个 costate λ ? 它就是高度图在轨迹脚下的斜坡：

$$\lambda(t) = \nabla_x V(x^*(t), t) = \text{高度图斜率}$$

不是巧合，是定义。

最优控制问题

问题设置：

状态： $\mathbf{x}(t) \in \mathbb{R}^n$

控制： $\mathbf{u}(t) \in \mathbb{R}^m$

动力学： $\dot{\mathbf{x}} = f(\mathbf{x}, \mathbf{u}, t)$

目标：最小化代价

$$J = \phi(\mathbf{x}(T)) + \int_0^T L(\mathbf{x}, \mathbf{u}, t) dt$$

ϕ : 终端代价, L : 运行代价

找最优控制 $\mathbf{u}^*(t)$ 使 J 最小

两条独立推导路线

E-L 方程我们走了两条路（拉格朗日乘子法 + 经典变分法）。HJB 同样有两条路，但角色不同：

- **Track A (变分法 / PMP)**: 延续 E-L 节的乘子思路——把动力学约束 $\dot{x} = f$ 当作“无穷多条等式约束”，用 $\lambda(t)$ 配对。一阶必要条件给出 **Pontryagin 最大值原理**——一组 ODE。
- **Track B (动态规划 / HJB)**: 从 Bellman 最优性原理出发，定义值函数 $V(x, t)$ ，对其 Taylor 展开取连续极限。得到一个 PDE。

两条路殊途同归：最后通过身份 $\lambda(t) = \nabla_x V(x(t), t)$ 汇合——**PMP 的 costate 就是 HJB 的 value 梯度**。这是前面 E-L 节那个 λ 在控制问题里的化身。

为什么要走两条？

- PMP 给**单条最优轨迹**（ODE，无维度灾难）——model-based RL / DDP / iLQR / 神经 ODE
- HJB 给**整个 value 场**（PDE，有维度灾难）——value-based RL / Bellman / TD / Q-learning

现实工程里两者都用。本节让你看见它们的统一性。

具体例子：LQR 问题

线性动力学： $\dot{\mathbf{x}} = A\mathbf{x} + B\mathbf{u}$

二次代价：

$$J = \frac{1}{2} \mathbf{x}(T)^T Q_f \mathbf{x}(T) + \frac{1}{2} \int_0^T (\mathbf{x}^T Q \mathbf{x} + \mathbf{u}^T R \mathbf{u}) dt$$

数值例子：一维情况

$\dot{x} = x + u$ (不稳定系统)

$$J = \frac{1}{2}x(T)^2 + \frac{1}{2} \int_0^T (x^2 + u^2) dt$$

目标：控制 x 到 0，同时不用太大的 u

Track A · Step 1: 增广作用量与 Hamiltonian

E-L 节我们把“ $v_k = (q_{k+1} - q_k)/\Delta t$ ”用乘子 λ_k 绑定。现在把“ $\dot{x} = f(x, u, t)$ ”用乘子 $\lambda(t)$ 绑定——**连续时间版本**。

增广作用量：

$$\bar{J}[x, u, \lambda] = \phi(x(T)) + \int_0^T [L(x, u, t) + \lambda(t)^\top (f(x, u, t) - \dot{x})] dt$$

定义 Hamiltonian：

$$H(x, u, \lambda, t) := L(x, u, t) + \lambda^\top f(x, u, t)$$

分部积分把 $\dot{x}$ 上的导数挪到 λ 上 (保留端点项)：

$$\bar{J} = \phi(x(T)) - \lambda(T)^\top x(T) + \lambda(0)^\top x_0 + \int_0^T [H(x, u, \lambda, t) + \dot{\lambda}^\top x] dt$$

自由变量： $x(t), u(t), \lambda(t)$ 加上终端 $x(T)$ (终端状态不固定)； $x(0) = x_0$ 固定。

Track A · Step 2: 变分 $\rightarrow$ Pontryagin 最大值原理 (PMP)

对每组变量求变分、设为零：

对 $x(t)$ 的变分 ($0 < t < T$):

$$\frac{\partial H}{\partial x} + \dot{\lambda} = 0 \implies \dot{\lambda} = -\frac{\partial H}{\partial x} \quad (\text{costate 方程, 反向时间})$$

对 $u(t)$ 的变分：

$$\frac{\partial H}{\partial u} = 0 \implies u^*(t) = \arg \min_u H(x(t), u, \lambda(t), t)$$

(一般 PMP 是“最小值原理”—— u^* 让 H 取最小，即便控制有界等不可导情形也成立。)

对 $\lambda(t)$ 的变分：恢复动力学 $\dot{x} = f(x, u, t)$ 。

对 $x(T)$ 的变分 (终端自由)：

$$\nabla_x \phi|_T - \lambda(T) = 0 \implies \lambda(T) = \nabla_x \phi(x(T)) \quad (\text{横截性条件})$$

合起来——PMP：在最优轨迹上存在 $\lambda(t)$ 使

$$\dot{x} = \frac{\partial H}{\partial \lambda}, \quad \dot{\lambda} = -\frac{\partial H}{\partial x}, \quad u^* = \arg \min_u H, \quad \lambda(T) = \nabla_x \phi.$$

这是 **Hamilton 方程组 + 控制最小化**——E-L 在带控制问题上的精确推广。

Track B · Step 1: Bellman 最优性原理

关键洞察 (Bellman, 1957):

“最优策略的子策略也是最优的”

数学表述: 定义值函数

$$V(\mathbf{x}, t) = \min_{\mathbf{u}(\cdot)} \left[\phi(\mathbf{x}(T)) + \int_t^T L(\mathbf{x}, \mathbf{u}, s) ds \right]$$

从状态 $(\mathbf{x}, t)$ 出发的最小代价

最优性原理:

$$V(\mathbf{x}, t) = \min_{\mathbf{u}} [L(\mathbf{x}, \mathbf{u}, t) dt + V(\mathbf{x} + f(\mathbf{x}, \mathbf{u}, t) dt, t + dt)]$$

Track B · Step 2: Taylor 展开 $\rightarrow$ HJB PDE

Taylor 展开:

$$V(\mathbf{x} + f dt, t + dt) \approx V + \frac{\partial V}{\partial t} dt + \nabla_x V \cdot f dt$$

代入最优性原理:

$$V = \min_{\mathbf{u}} \left[L dt + V + \frac{\partial V}{\partial t} dt + \nabla_x V \cdot f dt \right]$$

消去 V , 除以 dt :

$$0 = \min_{\mathbf{u}} \left[L + \frac{\partial V}{\partial t} + \nabla_x V \cdot f \right]$$

Hamilton-Jacobi-Bellman 方程

核心结论: HJB 方程

$$-\frac{\partial V}{\partial t} = \min_{\mathbf{u}} [L(\mathbf{x}, \mathbf{u}, t) + \nabla_x V \cdot f(\mathbf{x}, \mathbf{u}, t)]$$

边界条件: $V(\mathbf{x}, T) = \phi(\mathbf{x})$

这是一个偏微分方程 (PDE)

从终端 $t = T$ 向初始 $t = 0$ 求解 (反向!)

难点：维度灾难—— V 定义在状态空间上，高维时难以求解

桥接： $\lambda(t) = \nabla_x V(x^*(t), t)$

断言：PMP 的 costate $\lambda(t)$ 恰好等于 HJB 的值函数梯度 $\nabla_x V$ 在最优轨迹上的取值。

推导（沿最优轨迹）：把 $V(x^*(t), t)$ 对时间微分

$$\frac{dV}{dt} = \frac{\partial V}{\partial t} + \nabla_x V \cdot \dot{x}^*$$

HJB 方程在最优 u^* 处取等（min 实现）：

$$\frac{\partial V}{\partial t} + L(x^*, u^*, t) + \nabla_x V \cdot f(x^*, u^*, t) = 0$$

两式相减：

$$\frac{dV}{dt} = -L(x^*, u^*, t)$$

即 V 沿最优轨迹以瞬时代价 L 在被消耗——这正是值函数的定义。

识别 λ ：HJB 写成 $L + V_t + \nabla_x V \cdot f = 0$ ，对比 PMP 的 Hamiltonian $H = L + \lambda^\top f$ 和 costate 方程 $\dot{\lambda} = -\partial H / \partial x$ ，可以证明（沿任意小扰动）

$$\lambda(t) = \nabla_x V(x^*(t), t)$$

更精确地：

- PMP 的 costate ODE $\dot{\lambda} = -\partial H / \partial x$ 就是 HJB 的特征线方程
- HJB 沿最优轨迹”投影”成 PMP——一条 PDE 在一条曲线上塌缩成 ODE
- 终端 $\lambda(T) = \nabla_x \phi$ 和 $V(\cdot, T) = \phi$ 的梯度完全一致

所以两条路得到的是同一个 λ ——继承自 E-L 节运动学约束的乘子。

核心结论：PMP vs HJB：维度对偶

	PMP (Track A)	HJB (Track B)
对象	一条最优轨迹 (x^*, λ^*)	整个值场 $V(x, t)$
类型	ODE 系统于 $\mathbb{R}^{2n}$	PDE 于 $\mathbb{R}^{n+1}$
求解方向	两点边值 ($x(0)$ 前, $\lambda(T)$ 后)	反向时间 (终值 $V(\cdot, T) = \phi$)
维度灾难	无——只算单条轨迹	有—— V 在全空间存储
在 RL 里	model-based / DDP / iLQR / 神经 ODE	value-based / Bellman / TD / Q-learning
λ 的化身	乘子 (继承自 E-L 节)	$\nabla_x V$ (值函数梯度)

这俩是 Legendre 变换的一对——PMP 是 Lagrangian 视角 ($x, \dot{x}$ 配对), HJB 是 Hamiltonian 视角 (x, p 配对, $p = \nabla_x V$)。和单摆那节铺的 Lagrange–Hamilton 二象性是同一个东西, 搬到了带控制的情形。

LQR 的 HJB 解

猜测: $V(\mathbf{x}, t) = \frac{1}{2} \mathbf{x}^T P(t) \mathbf{x}$

代入 HJB:

$$\nabla_x V = P\mathbf{x}$$

$$\frac{\partial V}{\partial t} = \frac{1}{2} \mathbf{x}^T \dot{P} \mathbf{x}$$

最小化对 $\mathbf{u}$:

$$\mathbf{u}^* = -R^{-1} B^T P \mathbf{x} \text{ (线性反馈!)}$$

代入得 Riccati 方程:

$$-\dot{P} = Q + A^T P + P A - P B R^{-1} B^T P$$

边界条件: $P(T) = Q_f$

Track A 应用: LQR via PMP (得到同一个 Riccati)

把 PMP 套到 LQR。Hamiltonian:

$$H = \frac{1}{2} (x^\top Q x + u^\top R u) + \lambda^\top (A x + B u)$$

PMP 三条件：

$$\begin{aligned}\dot{\lambda} &= -\partial_x H = -Qx - A^\top \lambda \\ \partial_u H &= Ru + B^\top \lambda = 0 \implies u^* = -R^{-1} B^\top \lambda \\ \dot{x} &= Ax + Bu = Ax - BR^{-1} B^\top \lambda\end{aligned}$$

横截性： $\lambda(T) = Q_f x(T)$ 。

Ansatz: $\lambda(t) = P(t) x(t)$ (类比 HJB 那一支的 $V = \frac{1}{2} x^\top P x$)。

代入 $\dot{\lambda} = \dot{P} x + P \dot{x}$, 并结合上面的 ODE:

$$\dot{P} x + P(Ax - BR^{-1} B^\top P x) = -Qx - A^\top P x$$

x 任意, 约去得到同一个 **Riccati 方程**:

$$-\dot{P} = Q + A^\top P + PA - PBR^{-1} B^\top P$$

边界 $P(T) = Q_f$ ——和 Track B 完全一致。

$\lambda = \nabla_x V$ 在 **LQR** 上的具象:

$$\underbrace{\lambda = Px}_{\text{PMP 的 ansatz}} = \underbrace{\nabla_x V = \nabla_x \left(\frac{1}{2} x^\top P x \right)}_{\text{HJB 那条线}} = Px$$

同一个 P , 同一个 λ ——两条路真的汇合了。

LQR 数值例子

一维: $\dot{x} = x + u$, $Q = R = Q_f = 1$

Riccati 方程: $-\dot{P} = 1 + 2P - P^2$

稳态 ($\dot{P} = 0$): $P^2 - 2P - 1 = 0$

$P = 1 + \sqrt{2} \approx 2.414$

最优控制: $u^* = -Px = -2.414x$

闭环动力学: $\dot{x} = x - 2.414x = -1.414x$

稳定! (极点在 -1.414)

不加控制: $\dot{x} = x$, 指数增长, 不稳定

7 本周总结

核心结论：核心公式

1. Euler-Lagrange 方程：

$$\frac{\partial F}{\partial y} - \frac{d}{dx} \frac{\partial F}{\partial y'} = 0$$

2. 最大熵分布：

$$p(x) \propto \exp \left(- \sum_k \lambda_k f_k(x) \right)$$

3. ELBO：

$$\text{ELBO} = \mathbb{E}_q[\log p(\mathbf{x}|\mathbf{z})] - D_{\text{KL}}(q\|p)$$

4. HJB 方程：

$$-\frac{\partial V}{\partial t} = \min_u [L + \nabla V \cdot f]$$

5. Pontryagin 最大值原理 (PMP)：

$$\dot{\lambda} = -\partial_x H, \quad u^* = \arg \min_u H, \quad H = L + \lambda^\top f$$

其中 $\lambda(t) = \nabla_x V(x^*(t), t)$ 把 PMP 和 HJB 桥接。

核心结论：核心联系

概念	联系
E-L 方程	泛函优化的必要条件 (KKT 的连续极限)
最大熵	→ 指数族分布
变分推断	$\min \text{KL} \Leftrightarrow \max \text{ELBO}$
HJB 方程	= PMP 的“值场”对偶； $\lambda = \nabla_x V$

统一视角：拉格朗日乘子 λ 贯穿全章——力学的共轭动量、控制的 costate、HJB 的 value 梯度，是同一个对象的不同语言。

8 思考题

课后思考

概念题：

- 为什么高斯分布在给定均值和方差下熵最大？直觉解释？
- KL 散度为什么不对称？ $D_{\text{KL}}(p\|q)$ 和 $D_{\text{KL}}(q\|p)$ 分别在什么场景下使用？
- 解释 $\lambda(t) = \nabla_x V(x^*(t), t)$ ：为什么 PMP 的 costate 等于 HJB 的值梯度？

计算题：

4. 求解最短路径问题：从 $(0,0)$ 到 $(1,2)$ 的最短曲线
5. 给定 $\mathbb{E}[x] = 1$, $\mathbb{E}[x^2] = 2$, 求最大熵分布
6. 对于 LQR: $\dot{x} = 2x + u$, $J = \int_0^\infty (x^2 + u^2)dt$, 分别用 HJB 和 PMP 推导最优控制, 验证两者给出同一个 u^*

编程题：

7. 用变分信息瓶颈训练分类器, 比较与普通分类器在带噪声测试集上的鲁棒性