

强化学习作业

第 12 周：MDP / 深度策略梯度 / PPO 及其变体

优化算法课程

说明：本次作业共 10 题，覆盖 *lecture12* (MDP 与 Tabular RL)、*deepRL* (策略梯度与 TRPO)、*PPOwithFriends* (PPO 及其变体) 三讲。**每道题都已拆成若干小步**，每步只需做一次代入、求导或代数化简——按顺序推一遍即可，不需要自己设计证明结构。**每题末尾的紫色「结论」框点出这道题真正要理解的核心思想**，请务必读完并思考其中的追问。

Part I. MDP 与 Tabular RL (lecture12)

题 1 (手算 Bellman 方程)。考虑一个 3 状态 MDP， $\gamma = 0.5$ (折扣很大，方便手算)。状态 $\{1, 2, 3\}$ ，每个状态只有一个动作 (即“无控制”，直接评估)：

- 状态 1：奖励 $R_1 = 2$ ，确定转到状态 2；
- 状态 2：奖励 $R_2 = 0$ ，确定转到状态 3；
- 状态 3：奖励 $R_3 = 4$ ，确定转到状态 1。

按下列步骤求 $V(1), V(2), V(3)$ ：

- 写出三条 Bellman 期望方程 (每条形如 $V(i) = R_i + \gamma V(\text{下一个状态})$)。
- 把方程 (a) 写成矩阵形式 $V = R + \gamma PV$ ，明确列出 $R \in \mathbb{R}^3$ 与 $P \in \mathbb{R}^{3 \times 3}$ 。
- 解线性方程组 $(I - \gamma P)V = R$ ，得到 $V(1), V(2), V(3)$ 的数值。
- 直接展开 $V(1) = R_1 + \gamma R_2 + \gamma^2 R_3 + \gamma^3 R_1 + \dots$ 计算前 6 项的部分和，验证与 (c) 一致 (误差应在 $\gamma^6 \cdot R_{\max}/(1 - \gamma)$ 量级)。

涉及内容

lecture12 §3: Bellman 期望方程

★ 你应该带走的结论

Bellman 方程把一个**无限期的求和** ($\sum_{t=0}^{\infty} \gamma^t r_t$) 变成了**有限个联立线性方程**——这正是 RL 可计算的根本原因。(d) 中“展开求和”和 (c) 中“解方程”得到同一个答案，说明递归式 $V = R + \gamma PV$ 和无穷级数是**等价**的两种视角。

一句话追问：这个递归之所以成立，依赖于哪条性质？(提示：未来只取决于当前状态，与

如何到达无关——马尔可夫性。)

题 2 (亲手跑值迭代, 看误差几何衰减). 考虑 2 状态 MDP $\{A, B\}$, $\gamma = 0.5$, 单动作 (即策略评估):

- 状态 A : 奖励 2, 确定转到 B ;
- 状态 B : 奖励 0, 确定转到 A 。

Bellman 更新即 $V_{k+1}(A) = 2 + 0.5 V_k(B)$, $V_{k+1}(B) = 0 + 0.5 V_k(A)$ 。

(a) **先求真解**: 解联立方程 $V(A) = 2 + 0.5V(B)$, $V(B) = 0.5V(A)$, 得到 $V^*(A), V^*(B)$ 。

(b) **手动迭代**: 从 $V_0 = (0, 0)$ 开始, 逐步代入更新公式, 填出下表 (每步只是两次乘加):

k	$V_k(A)$	$V_k(B)$	误差 $\ V_k - V^*\ _\infty$
0	0	0	?
1	?	?	?
2	?	?	?
3	?	?	?
4	?	?	?

(c) **看见收缩**: 算出相邻两步的**误差比** $\frac{\|V_{k+1} - V^*\|_\infty}{\|V_k - V^*\|_\infty}$ 。它应该约等于多少? 与 γ 比较——这就是“ γ -收缩”的字面含义: 每次迭代误差缩小到原来的 γ 倍。

(d) **由收缩到速度界**: 既然误差每步 $\times \gamma$, 从 $\|V_0 - V^*\|_\infty$ 出发, 写出 $\|V_k - V^*\|_\infty \leq \gamma^k \|V_0 - V^*\|_\infty$ 。取一般的 $\gamma = 0.9$ 、初始误差 $\leq R_{\max}/(1 - \gamma) = 10$, 要使误差 $\leq 10^{-2}$ 至少需多少次迭代? (解 $0.9^k \cdot 10 \leq 10^{-2}$ 。)

(e) **有效视野**: 定义 $H_{\text{eff}} = 1/(1 - \gamma)$ 。分别算 $\gamma = 0.9, 0.99, 0.999$ 的 H_{eff} 。 γ 每靠近 1 一个数量级, 视野放大几倍?

涉及内容

lecture12 §4: Banach 不动点与值迭代

★ 你应该带走的结论

(c) 中你会亲眼看到误差序列 $\approx 2.67, 1.33, 0.67, 0.33, \dots$ ——每步几乎正好减半, 正是 $\gamma = 0.5$ 。这就是**收缩映射**: 不需要知道真解在哪, 每次迭代都**保证**靠近一个固定比例。

但收敛**速度**由 γ 决定: $\gamma \rightarrow 1$ 时所需迭代次数 $\sim \frac{1}{1-\gamma}$ 爆炸。这个量 $H_{\text{eff}} = \frac{1}{1-\gamma}$ 是 RL 最重要的量级之一, 几乎出现在所有误差界里 (如 Simulation Lemma 的 $\frac{1}{(1-\gamma)^2}$)。

为什么重要: 它解释了“长期信用分配”为何是 RL 最难的部分——越在乎远期 (γ 越大), 问题越难。

题 3 (手算 Monte Carlo 评估). 你跑了一条轨迹 (无折扣前的纯奖励流), $\gamma = 0.5$:

$$s_1 \xrightarrow{r_1=1} s_2 \xrightarrow{r_2=2} s_3 \xrightarrow{r_3=0} s_1 \xrightarrow{r_4=3} \text{终止}.$$

(注意: 状态 s_1 被访问了两次, 分别在 $t = 1$ 和 $t = 4$ 。)

(a) **算 return**: 按定义 $G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots$ 计算

$$G_1, \quad G_2, \quad G_3, \quad G_4.$$

(提示: 从后往前算更省力—— $G_4 = 3$, $G_3 = 0 + 0.5 \times G_4$, 依此类推。)

(b) **Every-visit MC**: 把每次访问 s 时的 G_t 都拿来平均。用 (a) 中的结果填表:

状态	访问发生在	$V(s)$ 的 every-visit 估计
s_1	$t = 1, 4$	$(G_1 + G_4)/2 = ?$
s_2	$t = 2$	$G_2 = ?$
s_3	$t = 3$	$G_3 = ?$

(c) **First-visit MC**: 每条轨迹中只用**首次**访问的 G_t 。给出 $V(s_1), V(s_2), V(s_3)$ 的 first-visit 估计。哪一个状态的估计与 (b) 不同? 为什么?

(d) **增量平均**: 又跑了第二条轨迹, 得到 s_1 的一个新的 return $G^{(2)} = 5$ 。要把它合并到 (c) 的 first-visit 估计上。增量平均公式: $V_{\text{new}}(s_1) = V_{\text{old}}(s_1) + \frac{1}{n}(G^{(2)} - V_{\text{old}}(s_1))$, 其中 n 是 s_1 累计的样本数 (这里 $n = 2$)。计算 $V_{\text{new}}(s_1)$ 。

(e) **对比 MC 与 TD**: MC 必须等到 episode 结束才能更新, TD(0) 每步就能更新。举一个 episode 极长 (甚至无终止) 的场景, 说明 MC 不能用而 TD 可以用。

涉及内容

lecture12 §5: Monte Carlo 评估

★ 你应该带走的结论

MC 和 TD 代表 RL 价值估计的两个极端, 差别体现在两个维度:

(1) **偏差-方差**: MC 用真实回报 $G_t \rightarrow$ **无偏但高方差**; TD 用 $r + \gamma V(s')$ 自举 (bootstrap) $\rightarrow$ **有偏 (依赖当前 V 的猜测) 但低方差**。

(2) **更新时机**: MC 必须等 episode 结束 (要完整 G_t); TD 每步就能更新。

这正是 (e) 中“无终止任务只能用 TD”的原因。后面 GAE (题 7) 就是用一个旋钮 λ 在 MC 和 TD 之间**连续插值**。

题 4 (Baseline 到底降了多少方差). 考虑单状态、标量参数的简化情形。设 score $\psi = \nabla_{\theta} \log \pi_{\theta}(a|s)$, 回报 G , 记 $\mu = \mathbb{E}[G]$, $\sigma^2 = \text{Var}[G]$ 。策略梯度估计 $\hat{g} = \psi \cdot G$, 加 baseline 后 $\hat{g}_b = \psi \cdot (G - b)$ 。为简化, 假设: (i) score 与回报独立 ($\psi \perp G$); (ii) score 零均值 $\mathbb{E}[\psi] = 0$ (这是 score 的普遍性质); (iii) $\mathbb{E}[\psi^2] = I$ (标量 Fisher 信息)。

- (a) **期望不变**: 用 (ii) 证明 $\mathbb{E}[\hat{g}_b] = \mathbb{E}[\hat{g}]$ 。(提示: $\mathbb{E}[\psi b] = b \mathbb{E}[\psi] = 0$, 故减去 b 不改变期望。)
- (b) **无 baseline 的方差**: 从 $\text{Var}[\hat{g}] = \mathbb{E}[\psi^2 G^2] - (\mathbb{E}[\psi G])^2$ 出发, 用独立性 (i) 把 $\mathbb{E}[\psi^2 G^2] = \mathbb{E}[\psi^2] \mathbb{E}[G^2]$ 拆开, 用 (ii)(iii) 证明

$$\text{Var}[\hat{g}] = I \cdot \mathbb{E}[G^2] = I(\sigma^2 + \mu^2).$$

(提示: $\mathbb{E}[G^2] = \text{Var}[G] + (\mathbb{E}[G])^2$; 又 $\mathbb{E}[\psi G] = \mathbb{E}[\psi] \mathbb{E}[G] = 0$ 。)

- (c) **有 baseline 的方差**: 把 G 换成 $G - b$ 重复 (b), 证明

$$\text{Var}[\hat{g}_b] = I(\sigma^2 + (\mu - b)^2).$$

- (d) **最优 baseline**: 把 (c) 看成关于 b 的二次函数, 求使方差最小的 b^* 。应得到 $b^* = \mu = V$ (即状态值函数)。代回 (c) 得最小方差 $\text{Var}[\hat{g}_{b^*}] = I\sigma^2$ 。
- (e) **数值感受**: 取 $\mu = 100, \sigma = 10, I = 1$ 。计算: 无 baseline 的方差、最优 baseline ($b^* = 100$) 的方差、以及方差降低的倍数。(这解释了讲义里”方差降低上百倍”的现象。)

涉及内容

deepRL §4.2: baseline 与方差缩减; 最优 baseline $\approx V$

★ 你应该带走的结论

(d) 推出的 $b^* = V(s)$ 是 Actor-Critic 的**全部理论依据**: Critic 之所以学状态值函数 V , 就是因为 V 是最优 baseline。

用 $A(s, a) = Q(s, a) - V(s)$ 替换 Q , 相当于把梯度信号**零均值化**——只保留”这个动作比平均**好多少**”, 丢掉与动作无关的公共项 V 。(e) 中”方差降 101 倍”就是这个零均值化的威力。

一句话追问: 为什么 baseline 只能依赖状态 s 、不能依赖动作 a ? (提示: 否则 (a) 中”期望不变”会被破坏。)

题 5 (Q-learning vs SARSA: 手算更新). 设环境有 2 个状态 $\{s_1, s_2\}$, 每个状态有 2 个动作 $\{a_1, a_2\}$ 。初始 Q 表全 0。学习率 $\alpha = 0.5$, $\gamma = 0.9$ 。当前样本:

$$(s_t, a_t, r_t, s_{t+1}, a_{t+1}) = (s_1, a_1, 1, s_2, a_2).$$

假设我们**已经知道** $Q(s_2, a_1) = 2, Q(s_2, a_2) = 1$ (其他为 0)。

- (a) 写出 SARSA 的更新公式 $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_t + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)]$, 代入数值计算 SARSA 更新后的 $Q(s_1, a_1)$ 。
- (b) 写出 Q-learning 的更新公式 $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)]$, 代入数值计算 Q-learning 更新后的 $Q(s_1, a_1)$ 。

(c) (a)(b) 的结果应当不同——具体相差多少? 解释为什么 Q-learning 给出更大的更新: SARSA 用的”下一动作”是 $a_{t+1} = a_2$ (Q 值较小), Q-learning 用的是 $\arg \max_{a'} Q(s_2, a')$ (即 a_1 , Q 值较大)。

(d) 这两个算法分别是 on-policy 还是 off-policy? 用一句话说明理由。

涉及内容

lecture12 §9: TD control (SARSA 与 Q-learning)

★ 你应该带走的结论

一个 max 的差别, 造就了两种本质不同的算法:

SARSA (on-policy): 用实际采的下一动作 $a_{t+1} \rightarrow$ 评估的是**行为策略本身** (含探索的 ϵ -greedy)。

Q-learning (off-policy): 用 $\max_{a'} \rightarrow$ 评估的是**贪婪策略** $\rightarrow$ 直接学 Q^* , 与你用什么探索策略无关。

经典的”悬崖行走”现象: Q-learning 学到贴悬崖的最短路 (最优但训练中常摔下去), SARSA 学到绕远的安全路 (次优但稳)。

延伸: Q-learning 的 max 还会带来**系统性过估计** (总是高估 Q), 这正是 Double Q-learning 要修的问题。

题 6 (策略梯度定理的 log-trick). 策略梯度定理写作 $\nabla_{\theta} J(\theta) = \mathbb{E}_{s \sim d^{\pi}, a \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) \cdot Q^{\pi}(s, a)]$ 。其中” $\nabla_{\theta} \log \pi$ ”是 log-trick 的产物。按以下步骤理解:

(a) 设 $f(\theta) > 0$ 是可微函数。证明 $\nabla_{\theta} \log f(\theta) = \nabla_{\theta} f(\theta) / f(\theta)$ (用链式法则)。

(b) 把 (a) 应用到 $f = \pi_{\theta}(a|s)$, 得到 $\nabla_{\theta} \pi_{\theta}(a|s) = \pi_{\theta}(a|s) \cdot \nabla_{\theta} \log \pi_{\theta}(a|s)$ 。

(c) 考虑期望 $\mathbb{E}_{a \sim \pi_{\theta}} [h(a)] = \sum_a \pi_{\theta}(a|s) h(a)$ 。对 θ 求导 (h 不依赖 θ): $\nabla_{\theta} \mathbb{E}[h(a)] = \sum_a \nabla_{\theta} \pi_{\theta}(a|s) \cdot h(a)$ 。

(d) 把 (b) 代入 (c): 得到 $\nabla_{\theta} \mathbb{E}_{a \sim \pi_{\theta}} [h(a)] = \mathbb{E}_{a \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) \cdot h(a)]$ 。这就是 log-trick: 原本写不出的” ∇ 一个抽样分布的期望”被转化为可采样估计的形式。

(e) **对比**: 为什么不直接用 $\nabla \pi / \pi$ 而要用 $\nabla \log \pi$? (提示: 考虑当 $\pi(a|s)$ 趋近 0 时数值稳定性。)

(f) **手算一个真实的 score function**: 考虑 softmax 策略 $\pi_{\theta}(a) = \frac{e^{\theta_a}}{\sum_b e^{\theta_b}}$ (3 个动作)。对 $\log \pi_{\theta}(a) = \theta_a - \log \sum_b e^{\theta_b}$ 关于 θ_c 求偏导, 证明

$$\frac{\partial \log \pi_{\theta}(a)}{\partial \theta_c} = \mathbb{I}[a = c] - \pi_{\theta}(c), \quad \text{即} \quad \nabla_{\theta} \log \pi_{\theta}(a) = e_a - \pi,$$

其中 e_a 是第 a 个标准基向量, $\pi = (\pi_1, \pi_2, \pi_3)^{\top}$ 。(提示: $\frac{\partial}{\partial \theta_c} \log \sum_b e^{\theta_b} = \frac{e^{\theta_c}}{\sum_b e^{\theta_b}} = \pi_c$ 。)

- (g) **代数值验证零均值**：取 $\pi = (0.5, 0.3, 0.2)$ 。写出三个动作各自的 score 向量 $e_1 - \pi$, $e_2 - \pi$, $e_3 - \pi$ ，然后验证 $\mathbb{E}_{a \sim \pi}[\nabla \log \pi] = \sum_a \pi_a (e_a - \pi) = 0$ （逐分量算）。

涉及内容

deepRL §3.2：策略梯度定理与 log-trick；softmax 的 score function

★ 你应该带走的结论

log-trick 解决了一个根本困难：我们想优化 $J(\theta) = \mathbb{E}_{a \sim \pi_\theta}[\dots]$ ，但分布本身依赖 θ ——“对一个随 θ 变化的采样分布求梯度”无法直接采样。(d) 的恒等式把它变成对同一分布的期望，于是可采样估计——这是所有策略梯度算法（REINFORCE、A2C、TRPO、PPO）的前提。

而 (f) 算出的 $\nabla \log \pi = e_a - \pi$ 是一个反复出现的核心公式：它就是“把被选中的动作往上推、其余按概率往下压”。它还直接构成 Fisher 信息 $F = \mathbb{E}[(e_a - \pi)(e_a - \pi)^\top] = \text{diag}(\pi) - \pi\pi^\top$ ，以及 DPO 的梯度。(g) 验证的 $\mathbb{E}[\nabla \log \pi] = 0$ 正是题 4 中 baseline 不改变期望的根源。

题 7 (GAE 的几何级数化简)。回忆 TD 误差 $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ （题 3、题 4 都见过）。把若干个 δ 累加，就得到 n 步优势估计 $\hat{A}_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l \delta_{t+l}$ ： n 越小越像单步 TD（低方差、依赖 V ）， n 越大越像 MC（无偏、高方差）。与其在“用几步”上二选一，GAE 干脆把所有 n 步估计做一个加权平均，权重按 λ 几何衰减（ $(1 - \lambda)$ 是归一化常数，让权重之和为 1）：

$$\hat{A}_t^{\text{GAE}(\lambda)} = (1 - \lambda) \sum_{n=1}^{\infty} \lambda^{n-1} \hat{A}_t^{(n)}.$$

这个双重求和看着吓人，但能化简成一个极简洁的单重和。本题就是一步步做这个化简，目标是证明

$$\hat{A}_t^{\text{GAE}(\lambda)} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l}.$$

- (a) 把 $\hat{A}_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l \delta_{t+l}$ 代入上面 GAE 的定义，写出双重求和形式：

$$\hat{A}_t^{\text{GAE}(\lambda)} = (1 - \lambda) \sum_{n=1}^{\infty} \lambda^{n-1} \sum_{l=0}^{n-1} \gamma^l \delta_{t+l}.$$

- (b) **交换求和顺序**：对每个固定的 l ，问 δ_{t+l} 出现在哪些 n 项里？（答： $n - 1 \geq l$ ，即 $n \geq l + 1$ 。）交换后变成：

$$\hat{A}_t^{\text{GAE}(\lambda)} = (1 - \lambda) \sum_{l=0}^{\infty} \gamma^l \delta_{t+l} \sum_{n=l+1}^{\infty} \lambda^{n-1}.$$

- (c) 计算内层几何级数 $\sum_{n=l+1}^{\infty} \lambda^{n-1}$ 。（提示：设 $m = n - 1$ ，求 $\sum_{m=l}^{\infty} \lambda^m = \lambda^l / (1 - \lambda)$ 。）

- (d) 代入 (b) 化简，得到 $\hat{A}_t^{\text{GAE}(\lambda)} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l}$ 。

- (e) **极限检查**：把 $\lambda = 0$ 和 $\lambda = 1$ 代入这个简洁形式，分别得到什么？是否与 TD(0) 误差和 MC 残差对应？

涉及内容

deepRL §4.3: GAE 的简洁形式

★ 你应该带走的结论

GAE 用一个旋钮 λ 把题 3 里 MC 与 TD 的两个极端**连续连接**起来:

$\lambda = 0 \rightarrow \hat{A} = \delta_t$ (单步 TD, 低方差高偏差); $\lambda = 1 \rightarrow \hat{A} = G_t - V(s_t)$ (MC 残差, 无偏高方差)。

化简后的 $\sum_l (\gamma\lambda)^l \delta_{t+l}$ 极其优雅: $\gamma\lambda$ 是一个**统一的有效衰减率**, 而且可以从后往前一次遍历 $O(T)$ 算完。

为什么重要: PPO 默认 $\lambda \approx 0.95$, 就是在偏差和方差之间取一个甜点——这是把 RL 理论直接落到工程默认值的典型例子。

题 8 (手算 PPO-Clip). 设 $\epsilon = 0.2$, 故 clip 区间为 $[0.8, 1.2]$ 。对下表中每个样本, 按 $L^{\text{CLIP}} = \min(rA, \text{clip}(r, 0.8, 1.2) \cdot A)$ 计算目标值。

样本	r	A	rA	$\text{clip}(r) \cdot A$	L^{CLIP}
1	1.5	+2	?	?	?
2	0.6	+1	?	?	?
3	1.5	-1	?	?	?
4	0.5	-2	?	?	?
5	1.0	+1	?	?	?

- 填完表格中每一格。
- 对每个样本, 回答: clipping 是**激活** (实际改变了目标) 还是**未激活**?
- 观察规律——总结: 什么时候 clip 会激活? (提示: 分 $A > 0$ 和 $A < 0$ 两种情况。 $A > 0$ 时 r 落在哪侧会被 clip? $A < 0$ 时呢?)
- 对样本 1 ($r = 1.5, A = +2, L^{\text{CLIP}} = 2.4$): 如果继续增大 r 到 $r = 2$, 目标 L^{CLIP} 会变化吗? 说明梯度 $\partial L^{\text{CLIP}} / \partial r$ 在 $r > 1 + \epsilon$ 区域等于多少。

涉及内容

PPOwithFriends §4: PPO-Clip 目标函数

★ 你应该带走的结论

Clip 的本质: 当策略更新**过激** (r 跑出 $[1 - \epsilon, 1 + \epsilon]$) 时, 目标函数被”压平”, 梯度变为零 (题 (d)) ——于是策略**不会一步步走太远**。

这等价于一个**隐式的 KL 约束**, 但不需要真的计算 KL、不需要二阶信息 (对比 TRPO 要解 $F^{-1}g$)。正是这个”廉价又有效”的技巧让 PPO 成为最常用的 RL 算法。

一句话追问: 为什么用 min 而不是直接 clip? (提示: min 保证 clip 只在”对自己有利的

方向”生效，是个保守的下界。)

题 9 (GRPO 的相对优势与零均值性). GRPO 对每个 prompt x 采样 G 个回答 $\{y_1, \dots, y_G\}$, 奖励 $R_i = R(x, y_i)$. 定义 $\bar{R} = \frac{1}{G} \sum_j R_j$, $\sigma_R = \sqrt{\frac{1}{G} \sum_j (R_j - \bar{R})^2}$, 相对优势 $\hat{A}_i = (R_i - \bar{R})/\sigma_R$.

- 给定数据 $G = 4, R = (0.8, 0.6, 0.9, 0.5)$, 手算 $\bar{R}, \sigma_R$, 再算每个 $\hat{A}_i$. (参考: $\bar{R} = 0.7, \sigma_R = \sqrt{0.025} \approx 0.158$.)
- 验证 $\sum_i \hat{A}_i = 0$. (提示: $\sum_i (R_i - \bar{R}) = \sum_i R_i - G\bar{R} = G\bar{R} - G\bar{R} = 0$.)
- 为什么”群体平均”是合理的 baseline**: 解释 $\bar{R}$ 可以视为 $V(x) = \mathbb{E}_{y \sim \pi}[R(x, y)]$ 的蒙特卡罗估计. 用一句话说明 $\mathbb{E}[\bar{R}] = V(x)$ 成立.
- 与 PPO 的对比**: PPO 用 critic 网络 $V_\phi(s)$ 给 advantage, GRPO 用群体均值 $\bar{R}$ 给 advantage. 分别列出两种做法各自的优缺点 (建议每项 1 行):
 - 训练成本 (需要训额外网络吗?)
 - 样本效率 (每个 prompt 需要采多少个 y ?)
 - 适用任务 (小模型 vs LLM)

涉及内容

PPOwithFriends §9: GRPO 与 critic-free 策略优化

★ 你应该带走的结论

GRPO 的核心 idea 一句话: 用”群体平均奖励” $\bar{R}$ 当 baseline, 省掉 critic 网络. 对 LLM 来说 critic 是另一个巨大的模型, 省掉它能大幅降低显存和训练成本.

而它能成立的理由, 和题 4 完全一样——baseline 只要不依赖被采的那个动作就不改变期望的方向, 而 $\bar{R}$ 恰好是 $V(x)$ 的无偏蒙特卡罗估计.

把题 4 和本题连起来看: 从”最优 baseline = V ” (理论) $\rightarrow$ ”用网络估 V ” (PPO/AC) $\rightarrow$ ”用群体均值估 V ” (GRPO), 是同一个原理在不同算力约束下的三种实现.

题 10 (KL 正则化 RL 的闭式解 (RLHF 最优策略)). RLHF 第二阶段优化的目标是

$$\max_{\pi(\cdot|x)} \mathbb{E}_{y \sim \pi(\cdot|x)} [R(y|x)] - \beta D_{KL}(\pi(\cdot|x) \parallel \pi_{\text{ref}}(\cdot|x)),$$

满足 $\sum_y \pi(y|x) = 1$. 下面用 Lagrange 乘子法求闭式解.

- 把 KL 展开: $D_{KL}(\pi \parallel \pi_{\text{ref}}) = \sum_y \pi(y) \log \frac{\pi(y)}{\pi_{\text{ref}}(y)}$. 把目标完整写出 (省略 x):

$$\max_{\pi} \sum_y \pi(y) R(y) - \beta \sum_y \pi(y) \log \frac{\pi(y)}{\pi_{\text{ref}}(y)}.$$

(b) 写出 Lagrangian (带乘子 λ 处理归一化约束):

$$\mathcal{L}(\pi, \lambda) = \sum_y \pi(y) R(y) - \beta \sum_y \pi(y) \log \frac{\pi(y)}{\pi_{\text{ref}}(y)} + \lambda \left(1 - \sum_y \pi(y) \right).$$

(c) 对 $\pi(y)$ 求偏导 (注意 $\frac{\partial}{\partial \pi(y)} \pi(y) \log \pi(y) = \log \pi(y) + 1$), 令其等于零:

$$R(y) - \beta \log \pi(y) + \beta \log \pi_{\text{ref}}(y) - \beta - \lambda = 0.$$

(d) 整理 (c) 解出 $\pi(y)$:

$$\pi(y) = \pi_{\text{ref}}(y) \exp\left(\frac{R(y) - \beta - \lambda}{\beta}\right) = \pi_{\text{ref}}(y) \cdot e^{-1-\lambda/\beta} \cdot e^{R(y)/\beta}.$$

把前面与 y 无关的常数记为 $1/Z(x)$, 得到 $\pi^*(y|x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp(R(y|x)/\beta)$ 。

(e) 由归一化条件 $\sum_y \pi^*(y|x) = 1$, 写出 $Z(x) = \sum_y \pi_{\text{ref}}(y|x) \exp(R(y|x)/\beta)$ 。

(f) **反解 reward**: 对 (d) 两边取 $\log$, 整理得到

$$R(y|x) = \beta \log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x).$$

这是 DPO 的关键代换。

(g) **手算 β 的物理意义**: 考虑 2 个回答 y_1, y_2 , 参考策略 $\pi_{\text{ref}} = (0.5, 0.5)$, reward $R(y_1) = 1$, $R(y_2) = 0$ 。用 $\pi^*(y) \propto \pi_{\text{ref}}(y) e^{R(y)/\beta}$ 分别算 $\beta = 0.1, 1, 10$ 三种情况下的最优分布 $\pi^*(y_1), \pi^*(y_2)$ 。(提示: 先算未归一化的 $\pi_{\text{ref}}(y_i) e^{R(y_i)/\beta}$, 再除以两者之和。例如 $\beta = 1$ 时 $\pi^*(y_1) \propto 0.5e^1 = 1.359$, $\pi^*(y_2) \propto 0.5e^0 = 0.5$ 。)

(h) **观察规律**: 把 (g) 三个 β 的结果排在一起。 β 小时 π^* 偏向哪边? β 大时呢? 用一句话总结 β 控制的是什么权衡。

涉及内容

PPOwithFriends §6.1: RLHF 的闭式最优解 (DPO 推导的基础)

★ 你应该带走的结论

$\pi^*(y|x) \propto \pi_{\text{ref}}(y|x) e^{R(y|x)/\beta}$ 是整个对齐领域的根公式——RLHF、DPO、以及讲义里所有 PO 方法都从它派生。(g)(h) 让你亲眼看到 β 是一个旋钮:

β 小 $\rightarrow e^{R/\beta}$ 放大 reward 差异 $\rightarrow \pi^*$ 几乎全压到高 reward 的 y_1 (对齐强, 但易过拟合/遗忘原能力);

β 大 $\rightarrow$ 指数项趋于 1 $\rightarrow \pi^* \approx \pi_{\text{ref}}$ (保守, 几乎不动)。

另一层深意: (f) 的反解说明 **reward 与最优策略一一对应**——策略里已“编码”了 reward, 所以 DPO 能把这个 R 直接代进 Bradley-Terry、让 $\log Z$ 在差分中消掉, 从而**跳过 reward model**。

提交要求

- 每道题按 (a)(b)(c)... 顺序写步骤，每步只需 1-3 行。
- 手算/数值题（题 1、2、3、5、8、9，以及题 10 的 (g)(h)）要求写出代入过程，不只是最后数值。
- 推导题（题 4、6、7、10）按提示一步一步走即可，不要跳步。