

从 TRPO 到 PPO、DPO、GRPO

大语言模型后训练中的策略优化:一条以「期望换分布」为线索的推导

研究生强化学习课程讲义

Abstract

本讲把现代 LLM 后训练的四个主流算法——TRPO、PPO、DPO、GRPO——放在同一个框架下推导。贯穿全篇的核心观点有两条。其一,它们优化的是同一个 KL 正则目标,都在参考策略附近的 KL 邻域里寻找回报最高的策略,有同一个解析最优解。其二,所有的技术差异都可以归结为对一个期望的不同处理:这个期望本该在新策略的状态-动作分布下取,但我们手里只有旧(参考)策略的数据,于是需要换分布——TRPO 用信任域控制换分布的代价,PPO 把硬约束换成裁剪,DPO 干脆解析地把「找最优策略」变成监督学习而不再采样,GRPO 则回到在线策略梯度但用组内蒙特卡洛基线替掉价值网络。我们尽量把每个期望写成显式的「时间 $\times$ 状态 $\times$ 动作」三层求和,并用小规模数字算例验证关键等式。

Contents

1 统一视角:在参考策略的 KL 邻域里找最优	1
2 TRPO:用信任域控制「换分布」的代价	2
2.1 Performance Difference Lemma	2
2.2 纯改进:绕开状态分布的一步	3
2.3 两步换分布:代理目标	3
2.4 每个期望在什么意义下算:总表	4
2.5 近似界与信任域	4
2.6 求解:自然梯度与共轭梯度	4
3 PPO:把信任域换成裁剪	5
3.1 裁剪代理目标	5
3.2 RLHF 中的 token 级奖励	5
4 DPO:把「找最优策略」解析地变成监督学习	6
4.1 从最优解反解奖励	6
4.2 梯度与难例加权	6
4.3 离线的代价:似然位移	6
4.4 同族变体:换 loss 即换方法	7
5 GRPO:回到在线策略梯度,但用组内基线替价值网络	7
5.1 组内归一化优势	7
5.2 目标函数	7
5.3 训练框架:三模型、五阶段	8
5.4 RL 框架对照	8
6 统一谱系与选型	8
习题	9

1 统一视角:在参考策略的 KL 邻域里找最优

四个算法表面差别很大——TRPO/PPO 要在线采样、要奖励模型,DPO 只在静态偏好数据上做监督学习, GRPO 介于其间——但它们优化的目标可以写成同一个式子。给定提示分布 $\mathcal{D}$ 、奖励 $r(x, y)$ 和参考策略 π_{ref} (通常是 SFT 模型),KL 正则的策略优化目标为

$$\max_{\pi} \mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim \pi(\cdot | x)} [r(x, y)] - \beta \mathbb{E}_{x \sim \mathcal{D}} [D_{\text{KL}}(\pi(\cdot | x) \| \pi_{\text{ref}}(\cdot | x))]. \quad (1)$$

第一项要回报高,第二项把策略拉住、不许离 π_{ref} 太远; β 控制邻域半径。

定理 1.1 (KL 正则目标的最优解). 对固定的 x ,目标 (1) 的最优策略为玻尔兹曼(Gibbs)形式

$$\pi^*(y | x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y | x) \exp\left(\frac{1}{\beta} r(x, y)\right), \quad Z(x) = \sum_y \pi_{\text{ref}}(y | x) \exp\left(\frac{1}{\beta} r(x, y)\right). \quad (2)$$

Proof. 固定 x ,把目标看成关于分布 $\pi(\cdot | x)$ 的泛函,加上归一化约束 $\sum_y \pi = 1$ 的拉格朗日乘子 λ :

$$\mathcal{L} = \sum_y \pi(y) r(y) - \beta \sum_y \pi(y) \log \frac{\pi(y)}{\pi_{\text{ref}}(y)} + \lambda \left(\sum_y \pi(y) - 1 \right).$$

对 $\pi(y)$ 求偏导并令其为零: $r(y) - \beta (\log \frac{\pi(y)}{\pi_{\text{ref}}(y)} + 1) + \lambda = 0$, 解得 $\pi(y) \propto \pi_{\text{ref}}(y) \exp(r(y)/\beta)$,归一化即得 (2)。二阶项 $-\beta/\pi(y) < 0$ 保证是极大。□

一句话主线. 式 (2) 就是「以 π_{ref} 为中心、被奖励指数加权拉偏」的分布。 $\beta \rightarrow \infty$ 贴死参考策略, $\beta \rightarrow 0$ 纯追奖励。**所有四个算法都是在求这个 π^* , 区别只在求解方式:**PPO/GRPO 用策略梯度在邻域里爬;DPO 注意到 (2) 可以反解出奖励, 于是解析地把问题变成监督学习。

后文统一约定记号(单步 MDP 或 token 级序贯 MDP 通用):状态 s 、动作 a 、策略 $\pi(a | s)$ 、转移 $P(s' | s, a)$ 、折扣 γ 、初始分布 ρ_0 。价值与优势

$$V^\pi(s) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a)], \quad Q^\pi(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim P} [V^\pi(s')], \quad A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s).$$

性能指标 $J(\pi) = \mathbb{E}_{s_0 \sim \rho_0} [V^\pi(s_0)] = \mathbb{E}_{\tau \sim \pi} [\sum_t \gamma^t r(s_t, a_t)]$ 。

注 1.2 (一切期望都是三层求和). 本讲反复出现形如 $\mathbb{E}_{s \sim d, a \sim \pi} [f]$ 的期望。请始终把它读成显式的三层结构

$$\mathbb{E}_{s \sim d, a \sim \pi} [f] = \underbrace{\sum_t \gamma^t}_{\text{时间}} \underbrace{\sum_{s_t} P_t(s_t)}_{\text{谁的访问分布}} \underbrace{\sum_{a_t} \pi(a_t | s_t)}_{\text{谁选动作}} f(s_t, a_t),$$

其中折扣访问分布 $d(s) = (1 - \gamma) \sum_t \gamma^t P_t(s)$ 把前两层打包成一个概率分布, 那个常数 $1/(1 - \gamma)$ 就是它的归一化因子。读任何一个期望,只需问三句:时间折扣是 γ^t ; 状态分布是谁的(谁在走);动作分布是谁的(谁在选)。

2 TRPO:用信任域控制「换分布」的代价

TRPO 要回答两个问题:(1) 如何保证 $\pi \rightarrow \pi'$ 确实更好?(2) 如何只用旧策略 π 的数据评估新策略 π' ? 答案的骨架是:写出精确的性能差,发现它需要新策略的数据;于是分两步把期望「换」到旧策略上;换分布有代价,代价由 KL 信任域控制。

2.1 Performance Difference Lemma

引理 2.1 (Performance Difference Lemma, Kakade–Langford 2002). 对任意两个策略 π, π' ,

$$J(\pi') - J(\pi) = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^{\pi'}, a \sim \pi'} [A^\pi(s, a)]. \quad (3)$$

证明的核心是一个对任意轨迹都成立的望远镜(telescoping)恒等式。

望远镜恒等式. 沿任意一条轨迹 $(s_0, a_0, s_1, a_1, \dots)$,

$$\sum_t \gamma^t A^\pi(s_t, a_t) = \underbrace{\sum_t \gamma^t r(s_t, a_t)}_{\text{这条轨迹的折扣回报}} - V^\pi(s_0). \quad (4)$$

即「旧策略优势沿轨迹的折扣和」恰等于「实际回报减去起点处旧策略的预期回报」。

式 (4) 的证明. 用 $A^\pi = Q^\pi - V^\pi$ 与 $Q^\pi(s_t, a_t) = r(s_t, a_t) + \gamma V^\pi(s_{t+1})$ (在轨迹上无偏) 展开:

$$\sum_t \gamma^t A^\pi(s_t, a_t) = \sum_t \gamma^t [r(s_t, a_t) + \gamma V^\pi(s_{t+1}) - V^\pi(s_t)].$$

价值项 $\sum_t [\gamma^{t+1} V^\pi(s_{t+1}) - \gamma^t V^\pi(s_t)]$ 首尾相消, 只剩 $-V^\pi(s_0)$, 即得 (4)。 $\square$

引理 2.1 的证明. 对 π' 生成的轨迹取期望: (4) 左边 = $\mathbb{E}_{\tau \sim \pi'} [\sum_t \gamma^t A^\pi]$; 右边 = $\mathbb{E}_{\tau \sim \pi'} [\sum_t \gamma^t r] - \mathbb{E}_{s_0 \sim \rho_0} [V^\pi(s_0)] = J(\pi') - J(\pi)$ 。再把「沿 π' 轨迹的折扣求和」用访问分布 $d^{\pi'}$ 写成 $\frac{1}{1-\gamma} \mathbb{E}_{s \sim d^{\pi'}, a \sim \pi'} [A^\pi]$ 即可。 $\square$

例 2.1(望远镜的数字验证). 取 $\gamma = 0.9$, 一条 π' 走出的轨迹 $s_0 \rightarrow s_1 \rightarrow s_2$ (终止)。给定旧策略价值 $V^\pi(s_0) = 10, V^\pi(s_1) = 5, V^\pi(s_2) = 0$, 实际奖励 $r_0 = 8, r_1 = 4$ 。逐步优势

$$A^\pi(s_0, a_0) = 8 + 0.9 \cdot 5 - 10 = +2.5, \quad A^\pi(s_1, a_1) = 4 + 0.9 \cdot 0 - 5 = -1.0.$$

左边 $\sum_t \gamma^t A^\pi = 2.5 + 0.9 \cdot (-1.0) = 1.6$; 右边折扣回报 $8 + 0.9 \cdot 4 = 11.6$, 减 $V^\pi(s_0) = 10$ 得 1.6。两边一致。含义: 这条 π' 轨迹比「从 s_0 按 π 本应拿到的 10」多挣 1.6。

2.2 纯改进: 绕开状态分布的一步

把 (3) 按「先动作、后状态」嵌套写开:

$$J(\pi') - J(\pi) = \frac{1}{1-\gamma} \sum_s d^{\pi'}(s) \underbrace{\mathbb{E}_{a \sim \pi'(\cdot|s)} [A^\pi(s, a)]}_{=: h(s)}. \quad (5)$$

推论 2.2 (策略改进条件). 若对所有状态 s 都有 $h(s) = \mathbb{E}_{a \sim \pi'(\cdot|s)} [A^\pi(s, a)] \geq 0$, 则 $J(\pi') \geq J(\pi)$ 。

Proof. (5) 中权重 $d^{\pi'}(s) \geq 0$ (它是概率)。若被加权的 $h(s) \geq 0$, 则逐项 $d^{\pi'}(s)h(s) \geq 0$, 求和非负, 故 $J(\pi') \geq J(\pi)$ 。 $\square$

为什么这步优雅. 推论 2.2 完全不需要知道 $d^{\pi'}$ 长什么样 (它最难算)。只要 $h(s)$ 逐状态非负, 无论非负权重如何分配, 加起来都非负——状态分布这个最棘手的部分被直接绕开了。这正是策略迭代单调改进的理论根基。代价是条件太强 (要在每个状态都不变差), 实践做不到, 所以 TRPO 退而求其次: 不要求逐状态非负, 改成「最大化加权和」并用 KL 锁住近似有效性。

2.3 两步换分布:代理目标

定义 2.3 (代理目标).

$$L_{\pi}(\pi') = J(\pi) + \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^{\pi}, a \sim \pi'} [A^{\pi}(s, a)]. \quad (6)$$

注意状态分布已由 $d^{\pi'}$ 换成 d^{π} (旧策略,我们有数据),动作分布仍是 π' 。

第一步(换状态,付近似误差). 把 (3) 里的 $d^{\pi'}$ 换成 d^{π} ,等价于假设 $d^{\pi'} \approx d^{\pi}$ 。这是 TRPO 唯一的「硬」近似,仅当 $\pi' \approx \pi$ 时成立。

第二步(换动作,精确,付方差). 用重要性采样把动作期望也搬到 π 上,记 $\rho(a | s) = \pi'(a | s) / \pi(a | s)$:

$$\mathbb{E}_{a \sim \pi'} [A^{\pi}] = \mathbb{E}_{a \sim \pi} [\rho(a | s) A^{\pi}] \Rightarrow L_{\pi}(\pi') = J(\pi) + \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^{\pi}, a \sim \pi} [\rho A^{\pi}]. \quad (7)$$

这一步是精确恒等式(IS 无偏),不是近似;但 π' 离 π 越远, ρ 越极端,估计方差越大。到这里状态与动作全是旧策略的,完全可用旧数据估计——这才是 TRPO 真正去最大化的目标。

引理 2.4 (代理目标与真目标在 π 处一阶吻合). $L_{\pi}(\pi) = J(\pi)$, 且 $\nabla_{\pi'} L_{\pi}(\pi')|_{\pi'=\pi} = \nabla_{\pi'} J(\pi')|_{\pi'=\pi}$ 。

要点. 对 π' 求导时,真目标 J 含两项:状态分布变化项(I)与动作分布变化项(II)。在 $\pi' = \pi$ 处, (I) 的系数 $h(s) = \mathbb{E}_{a \sim \pi} [A^{\pi}(s, a)] = 0$ (优势在 π 下均值为零),故 (I) 消失; (II) 恰是 ∇L_{π} 。所以代理目标「扔掉」的正是状态分布变化项,而它在 π 处因 $\mathbb{E}_{\pi} [A^{\pi}] = 0$ 而无害——这就是一阶吻合的来源。□

例 2.2(两步换分布的数字验证). 单状态、三动作。旧策略 $\pi = (0.5, 0.3, 0.2)$, 优势 $A^{\pi} = (0.6, 0, -1.5)$ (满足 $\mathbb{E}_{a \sim \pi} [A^{\pi}] = 0.5 \cdot 0.6 + 0.2 \cdot (-1.5) = 0$)。新策略把质量挪向优势动作: $\pi' = (0.7, 0.3, 0)$ 。

- 纯改进 h : $h = 0.7 \cdot 0.6 + 0.3 \cdot 0 + 0 \cdot (-1.5) = +0.42 \geq 0$, 本状态改进。
- 直接用 π' : $\mathbb{E}_{a \sim \pi'} [A^{\pi}] = 0.42$ 。
- 重要性采样: $\rho = \pi' / \pi = (1.4, 1.0, 0)$, $\mathbb{E}_{a \sim \pi} [\rho A^{\pi}] = 0.5 \cdot 1.4 \cdot 0.6 + 0 + 0 = 0.42$ 。

两种算法都得 0.42, 印证 (7) 的精确性。覆盖要求也清晰: 若某 $\pi(a) = 0$ 而 $\pi'(a) > 0$, $\rho = \pi' / \pi$ 发散——旧策略没采到的动作 IS 无法估计。

例 2.3(换状态的代价). 两状态。设 $d^{\pi} = (0.6, 0.4)$ 、 $d^{\pi'} = (0.3, 0.7)$, 每状态优势均值 $h(s_1) = +0.4$, $h(s_2) = -0.2$, $\gamma = 0.9$ ($1/(1-\gamma) = 10$)。

精确(用 $d^{\pi'}$): $0.3 \cdot 0.4 + 0.7 \cdot (-0.2) = -0.02$, 代理(用 d^{π}): $0.6 \cdot 0.4 + 0.4 \cdot (-0.2) = +0.16$ 。

真实 $\Delta J \approx 10 \cdot (-0.02) = -0.2$ (其实变差), 代理却预测 +1.6 (方向都反)。差异来自新策略大量改去访问 劣势状态 s_2 ($0.4 \rightarrow 0.7$), 而这一状态分布漂移完全没被代理目标看到。这正是必须把 KL 锁小、逼 $d^{\pi'} \approx d^{\pi}$ 的原因。

2.4 每个期望在什么意义下算:总表

2.5 近似界与信任域

定理 2.5 (Kakade–Langford 界). 设 $\epsilon = \max_s |\mathbb{E}_{a \sim \pi'} [A^{\pi}(s, a)]|$, $D_{TV}^{\max} = \max_s D_{TV}(\pi(\cdot | s) \| \pi'(\cdot | s))$, 则

$$J(\pi') \geq L_{\pi}(\pi') - \frac{4\gamma\epsilon}{(1-\gamma)^2} (D_{TV}^{\max})^2 \geq L_{\pi}(\pi') - C D_{KL}^{\max}(\pi \| \pi'), \quad (8)$$

末步用 Pinsker 不等式 $D_{TV} \leq \sqrt{\frac{1}{2} D_{KL}}$ 。

期望	状态 s	动作 a	评分量	可用旧数据估?
PDL(精确)(3)	$d^{\pi'}$ 新	π' 新	A^π	否
纯改进 $h(s)$ (5)	钉死 s	π' 新	A^π	——(绕开 s 分布)
代理①换状态	d^π 旧	π' 新	A^π	半(近似)
代理② IS (7)	d^π 旧	π 旧	ρA^π	是(精确变换)
KL 约束	d^π 旧	——	逐状态 KL	是
g, F	d^π 旧	π 旧	$\nabla \log \pi \cdot A^\pi$ / 外积	是

Table 1: TRPO 推导中各期望的「意义」。从上到下读,就是「状态新→旧、动作新→旧」被逐格换掉的过程。

界的含义:右边是 $J(\pi')$ 的下界;只要 π' 与 π 足够接近(D_{KL} 小),最大化代理目标 就能保证真目标改进。这把例 2.2(IS 方差)和例 2.3(状态分布漂移)两个代价同时兜住——二者都随 D_{KL} 增长。于是 TRPO 的优化问题为

$$\max_{\theta'} L_\theta(\theta') \quad \text{s.t.} \quad \mathbb{E}_{s \sim d^\pi} [D_{\text{KL}}(\pi_\theta(\cdot | s) \| \pi_{\theta'}(\cdot | s))] \leq \delta. \quad (9)$$

2.6 求解:自然梯度与共轭梯度

把代理目标一阶展开、KL 约束二阶展开(F 为 Fisher 信息矩阵):

$$\max_{\Delta\theta} g^\top \Delta\theta \quad \text{s.t.} \quad \frac{1}{2} \Delta\theta^\top F \Delta\theta \leq \delta, \quad g = \nabla_\theta L, \quad F = \mathbb{E}_{s \sim d^\pi, a \sim \pi} [\nabla \log \pi_\theta \nabla \log \pi_\theta^\top].$$

用拉格朗日乘子求解(约束取等),得自然梯度方向

$$\Delta\theta^* = \sqrt{\frac{2\delta}{g^\top F^{-1} g}} F^{-1} g. \quad (10)$$

其中 $g = \mathbb{E}_{s \sim d^\pi, a \sim \pi} [\nabla \log \pi_\theta(a | s) A^\pi(s, a)]$ ——这就是策略梯度, F 是 KL 的局部二阶度量;两者都在旧策略数据下估计。神经网络中 F 是 $10^6 \times 10^6$ 量级,不可显式求逆;只需 $F^{-1}g$,用共轭梯度法迭代,每步只算 Fisher-向量乘积 $Fv = \mathbb{E}[\nabla \log \pi (\nabla \log \pi^\top v)]$, 复杂度 $O(Nd)$, 10-20 步即足够。

注 2.6 (TRPO 的代价). 单调改进保证漂亮,但每步要近似 Fisher、跑共轭梯度、再做线搜索,工程繁重。PPO 的全部动机就是 用一个一阶、无约束、可直接 SGD 的目标近似这套信任域机制。

3 PPO:把信任域换成裁剪

TRPO 的 (9) 用一个二次 KL 约束界定信任域,求解要算 Fisher、跑共轭梯度。PPO 的思想是: 不显式约束 KL,而是直接在目标函数里裁剪重要性比率,让策略一旦偏离太远就停止从该方向继续获益——用一阶、无约束、可直接 SGD 的目标近似信任域。

3.1 裁剪代理目标

记 token(或单步)级比率 $\rho_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}$, 优势估计 $\hat{A}_t$ (通常用 GAE)。PPO-Clip 最大化

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min(\rho_t \hat{A}_t, \text{clip}(\rho_t, 1 - \varepsilon, 1 + \varepsilon) \hat{A}_t) \right]. \quad (11)$$

min 取的是「悲观下界」。它的作用分两种情形:

- $\hat{A}_t > 0$ (好动作):想推高 ρ_t , 但一旦 $\rho_t > 1 + \varepsilon$, clip 把它压回 $1 + \varepsilon$, min 选中被裁项,目标变常数,梯度归零——不再继续推高。
- $\hat{A}_t < 0$ (坏动作):想压低 ρ_t , 一旦 $\rho_t < 1 - \varepsilon$, 同理目标变常数、梯度归零——不再继续猛压。

例 3.1(裁剪的数字感受). 取 $\varepsilon = 0.2$ 。

$\hat{A}$	ρ	$\rho\hat{A}$	$\text{clip}(\rho)\hat{A}$	min	裁剪?
+1	1.35	1.35	1.2	1.20	是(上行被截)
-1	0.60	-0.60	-0.80	-0.80	是(下行被截)
-1	0.90	-0.90	-0.90	-0.90	否(信赖域内)

被裁的两行,目标项是常数, $\partial/\partial\theta = 0$,该 token 在那个方向上的策略梯度被掐断; 未裁的一行梯度照常。这就给每个 token 的概率变化套了一个 $[1 - \varepsilon, 1 + \varepsilon]$ 的信赖域。

注 3.1 (第一个 epoch 裁剪不生效). PPO 通常对一份 rollout 做多次小批量更新($\mu > 1$)。第一个 epoch 中 $\theta = \theta_{\text{old}}$, 所有 $\rho_t = 1$, clip 永不触发,此时就是普通策略梯度;只有从第二个 epoch 起 θ 已动、 $\rho_t \neq 1$, 裁剪才有意义。这是「复用昂贵 rollout」与「控制偏移」之间的权衡。

3.2 RLHF 中的 token 级奖励

把 PPO 用于 LLM 时,MDP 取:状态 $s_t = (x, y_{<t})$ 、动作 $a_t = y_t$ 、确定性转移 $s_{t+1} = s_t \oplus a_t$ 、 $\gamma = 1$ 。奖励模型 $R(x, y)$ 只在终止符 EOS 给一个标量,中间 token 没有内容奖励。实际喂给 PPO 的逐 token 奖励为

$$r_t = -\beta(\log \pi_\theta(a_t | s_t) - \log \pi_{\text{ref}}(a_t | s_t)) + \underbrace{R(x, y) \cdot \mathbb{I}[t = T]}_{\text{仅最后一个 token}}. \quad (12)$$

即:每个 token 的奖励几乎全是对 π_{ref} 的逐 token KL 惩罚(防偏移),真正的「好坏」信号是序列级、稀疏地加在末尾;再由 GAE 把末尾标量沿轨迹分配回每个 token。这正是 (1) 的 $r - \beta D_{\text{KL}}$ 目标在 token 级的展开。

4 DPO:把「找最优策略」解析地变成监督学习

DPO 的出发点是定理 1.1:既然最优策略 (2) 把奖励和策略绑定,那就反解出奖励,代入偏好模型,从而完全跳过「学奖励模型 + 在线 RL」,直接在静态偏好数据上做监督学习。

4.1 从最优解反解奖励

对 (2) 取对数重排:

$$r(x, y) = \beta \log \frac{\pi^*(y | x)}{\pi_{\text{ref}}(y | x)} + \beta \log Z(x). \quad (13)$$

把它代入 Bradley-Terry 偏好模型 $P(y_w \succ y_l | x) = \sigma(r(x, y_w) - r(x, y_l))$ 。关键:配分函数 $Z(x)$ 只依赖 x ,在相减时抵消:

$$r(x, y_w) - r(x, y_l) = \beta \log \frac{\pi^*(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi^*(y_l | x)}{\pi_{\text{ref}}(y_l | x)}.$$

把待求策略 π_θ 代替 π^* ,得到 DPO 的极大似然损失:

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\underbrace{\beta \log \frac{\pi_\theta(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_\theta(y_l | x)}{\pi_{\text{ref}}(y_l | x)}}_{=: u} \right) \right]. \quad (14)$$

DPO 没有显式奖励、没有采样. 隐式奖励是 $\hat{r}(x, y) = \beta \log \frac{\pi_\theta(y | x)}{\pi_{\text{ref}}(y | x)}$, 即「当前策略相对参考策略把多少概率质量挪到了这条回答上」。 $\mathcal{L}_{\text{DPO}}$ 与 (1) 同解 π^* , 但求解变成了在固定偏好数据

4.2 梯度与难例加权

记 $u = \beta(\text{chosen logratio} - \text{rejected logratio})$ 。损失梯度有干净形式:

$$\nabla_{\theta} \mathcal{L}_{\text{DPO}} = -\beta \underbrace{\sigma(-u)}_{\text{难例权重}} [\nabla_{\theta} \log \pi_{\theta}(y_w | x) - \nabla_{\theta} \log \pi_{\theta}(y_l | x)]. \quad (15)$$

方向是「推高 chosen、压低 rejected」,力度由 $\sigma(-u)$ 调制:当前差距小(u 小)给近满额梯度,差距已拉大(u 大)梯度自动趋零——这是 DPO 自带的难例加权。

例 4.1(DPO 一步更新的数字). 设序列级对数概率

$$\text{chosen logratio} = \underbrace{(-1.1)}_{\text{policy}} - \underbrace{(-1.6)}_{\text{ref}} = +0.5, \quad \text{rejected logratio} = (-2.0) - (-1.7) = -0.3.$$

则 logits = $0.5 - (-0.3) = 0.8$, 取 $\beta = 0.1$: $u = 0.08$, $\mathcal{L} = -\log \sigma(0.08) \approx 0.654$ 。难例权重 $\sigma(-0.08) \approx 0.480$, 梯度系数 $\beta \cdot 0.480 = 0.048$ 。隐式奖励 $\hat{r}_w = 0.1 \cdot 0.5 = +0.05$, $\hat{r}_l = 0.1 \cdot (-0.3) = -0.03$, 余量 0.08。理想化地对每个 token 的 logp 施加 ± 0.048 一步后(取学习率 1 作示意), chosen 四个 token 之和由 -1.1 升到 -0.908 , rejected 由 -2.0 降到 -2.192 , 新 logits = $1.184 > 0.8$, 损失降到 ≈ 0.636 ——差距被拉开, 方向正确。

4.3 离线的代价:似然位移

标准 DPO 的偏好对是预先标好的静态数据,与正在更新的 π_{θ} 脱钩(off-policy)。训练后期 π_{θ} 已漂离生成偏好数据的分布,chosen/rejected 对当前策略都成了分布外样本,常见后果是 chosen 的概率也被一起压低(likelihood displacement):DPO 只保证 chosen 比 rejected 高,不保证 chosen 本身被推高。这正是「数据与策略脱钩」的代价,也是 Online/Iterative DPO 的动机。

4.4 同族变体:换 loss 即换方法

DPO 这一族框架几乎相同(见 § 6),只换损失函数与是否需要参考模型:

- **IPO**: 用平方损失 $(u/\beta - \frac{1}{2})^2$ 代替 $\log \sigma$, 缓解过拟合。需要 π_{ref} 。
- **CPO / SimPO**: 去掉 π_{ref} (省一个网络)。SimPO 用长度归一化的对数概率加 margin。
- **ORPO**: 把 SFT 损失与 odds-ratio 偏好项合并,单阶段完成,无需 π_{ref} 。
- **KTO**: 不需成对偏好,单条回答 + 二值好/坏标签,用前景理论的价值函数。

5 GRPO:回到在线策略梯度,但用组内基线替价值网络

GRPO 重新回到在线采样的策略优化(像 PPO),但删掉 critic:不学价值函数 V_{ϕ} , 而用对同一提示多次采样的组内平均回报作为基线。

5.1 组内归一化优势

对每个提示 x , 从当前策略采 G 条回答 $\{y_i\}_{i=1}^G$, 各得标量回报 $R_i = R(x, y_i)$ (可验证奖励或奖励模型)。优势为组内标准化分数:

$$\hat{A}_i = \frac{R_i - \text{mean}(\{R_j\})}{\text{std}(\{R_j\}) + \epsilon}. \quad (16)$$

从 RL 看,这是把同一初始状态 s_0 的 G 条蒙特卡洛回报均值当作基线 $b \approx V(s_0)$ ——省掉了 critic 网络。因 $\gamma = 1$ 且奖励仅在末尾,整条回答的每个 token 共享同一个 $\hat{A}_i$ (轨迹级优势,无 token 级信用分配)。

例 5.1(组内优势). 一个提示采 $G = 4$ 条,回报 $R = [1, 1, 0, 1]$ 。mean = 0.75, std = 0.5,故 $\hat{A} = [+0.5, +0.5, -1.5, +0.5]$ 。答对的三条每 token 拿 +0.5,答错那条每 token 拿 -1.5。

5.2 目标函数

GRPO 最大化(逐 token)裁剪代理目标减 KL 正则, $\rho_{i,t} = \pi_{\theta}(y_{i,t})/\pi_{\theta_{\text{old}}}(y_{i,t})$:

$$\mathcal{J}_{\text{GRPO}} = \mathbb{E} \left[\frac{1}{G} \sum_i \frac{1}{|y_i|} \sum_t \left(\min(\rho_{i,t} \hat{A}_i, \text{clip}(\rho_{i,t}, 1-\varepsilon, 1+\varepsilon) \hat{A}_i) - \beta \text{KL}_{i,t} \right) \right], \quad (17)$$

其中 KL 用 k_3 低方差无偏估计 $\text{KL}_{i,t} = e^{z^{\text{ref}}-z} - (z^{\text{ref}} - z) - 1, z = \log \pi_{\theta}$ 。

例 5.2(裁剪与梯度的逐 token 验证). $\varepsilon = 0.2, \beta = 0.04$ 。记 $z_{\text{old}}, z, z^{\text{ref}}$ 为旧/当前/参考 logp。

$\hat{A}$	z_{old}	z	$r = e^{z-z_{\text{old}}}$	min 选	$\partial S / \partial z$	$\partial \mathcal{J} / \partial z$
+0.5	-0.2	+0.1	1.350	裁剪	0	-0.0132
-1.5	-0.5	-1.0	0.607	裁剪	0	+0.0260
-1.5	-0.5	-0.6	0.905	不裁	-1.357	-1.353

其中未裁项 $\partial S / \partial z = r \hat{A}$, 裁剪项 $\partial S / \partial z = 0$ (只剩 $-\beta \partial \text{KL} / \partial z$, $\partial \text{KL} / \partial z = 1 - e^{z^{\text{ref}}-z}$)。可见: 好 token 涨过 $1 + \varepsilon$ 、坏 token 跌破 $1 - \varepsilon$ 时 策略梯度被掐断,只留微弱 KL 回拉;信赖域内的坏 token ($r = 0.905$) 梯度照常 (-1.353, 继续压低)。

5.3 训练框架:三模型、五阶段

GRPO 在工程上是「三类模型角色 + 五阶段主循环」(PPO 多一个 critic,共四角色):

角色 actor π_{θ} (唯一更新权重)、ref π_{ref} (冻结,算 KL)、reward (函数或 RM); **无 critic / value 网络**;另有推理引擎(vLLM 等)做高吞吐采样。

阶段 1 Rollout 用当前 actor 权重对每个提示采 G 条 —— on-policy 数据收集。

阶段 2 Experience actor / ref 各前向一遍,记录 $\log \pi_{\theta_{\text{old}}}, \log \pi_{\text{ref}}$;reward 打分,存入 buffer。

阶段 3 Advantage 组内归一化 (16) —— 无 critic、无 GAE,纯函数。

阶段 4 Update 一份 rollout 复用 μ 次小批量,按 (17) 更新 actor; $\mu > 1$ 时 $\rho \neq 1$,裁剪生效。

阶段 5 Weight sync 把训练好的权重推回推理引擎,否则下一轮仍用旧策略采样。

5.4 RL 框架对照

6 统一谱系与选型

把四个算法按「数据是否随策略闭环移动」排开,本质区别一目了然。强化学习区别于监督学习的标志不是有没有奖励,而是数据分布是否随策略移动(闭环 vs 开环)。

闭环程度谱系。



	REINFORCE	PPO(actor-critic)	GRPO
基线 $b(s)$	常数/滑动均值	学到的 critic $V_\phi(s)$	组内蒙特卡洛均值
优势 Ψ_t	$R - b$	GAE(时序信用分配)	$(R - \text{mean})/\text{std}$, token 间常数
第二网络	否	是(value head)	否
信赖域	无	PPO-clip	PPO-clip
对 π_{ref} 的 KL	无	RLHF 版有	有
信用分配	无	GAE 沿轨迹	无, 整条平摊

Table 2: 从 RL 组件看三种方法。GRPO 用「对同一初始状态多次采样取平均」的蒙特卡洛基线替掉了 critic。

- **标准 DPO**: 偏好对预先标定、训练全程不变, 与 π_θ 脱钩 —— 开环, 本质是分类, 不是 RL。
- **PPO/GRPO**: 阶段 1 用最新权重采样、阶段 5 同步权重, 数据分布跟着策略走 —— 闭环, 是 RL。
- **Iterative DPO**: 用 DPO 的损失, 但偏好对在线采样 + 现场标注, 数据部分跟随策略 —— 正从监督学习滑向 RL。

选型. 工程量从左到右递增。能用静态偏好数据就优先 DPO 族(框架约等于 SFT, 省掉推理引擎与权重同步整套基建); 当需要模型自我探索、或只有可验证的终末奖励(数学/代码判对错)而无现成偏好对时, 才上 PPO/GRPO 族。本质上是在问: 你的数据能不能跟得上策略的移动。

方法	在线采样	奖励模型	参考模型	数据格式	框架复杂度
DPO / IPO	否	否	是	成对偏好	$\approx$ SFT
CPO / SimPO / ORPO	否	否	否	成对偏好	$\approx$ SFT
KTO	否	否	是	单条 + 二值	$\approx$ SFT
Iterative DPO	是	RM/judge	是	在线成对	中
PPO	是	是	是	仅提示	高(含 critic)
GRPO / RLOO / GSPO	是	是	是	仅提示	高(无 critic)

Table 3: 偏好对齐与策略优化方法的框架对照。

延伸方向. (i) 把终末奖励换成**过程奖励**(PRM, 中间 $r_t \neq 0$)可恢复 token 级信用分配; (ii) **GSPO** 用序列级重要性比率(在轨迹上聚合 ρ)重新定义信赖域作用的粒度; (iii) **VESPO** 等用变分重塑核缓解 off-policy 复用导致的不稳定。它们都在前述统一框架内, 只改动其中一个组件。

习题

1. 由定理 1.1 的 π^* 出发, 证明此时 (1) 第二项 $D_{\text{KL}}(\pi^* \parallel \pi_{\text{ref}})$ 与第一项之和等于 $\beta \log Z(x)$ 的期望; 据此说明 $Z(x)$ 为何在 DPO 推导中可消去。
2. 用例 2.1 的轨迹, 把 γ 改为 0.5, 重新验证望远镜恒等式 (4)。
3. 证明: 当 $\varepsilon \rightarrow 0$ 时 PPO-Clip (11) 退化为只在 $\rho_t = 1$ 邻域有效的一阶策略梯度; 当 $\delta \rightarrow 0$ 时 TRPO (9) 退化为自然梯度下降。
4. 推导 DPO 梯度 (15), 并说明 $\sigma(-u)$ 作为难例权重在 $u \rightarrow +\infty$ 与 $u \rightarrow -\infty$ 两端的行。
5. 在例 5.1 中把 $G = 4$ 的回报改为 $[1, 0, 0, 0]$, 重新计算组内优势 (16), 并讨论当组内回报全相同时优势退化为何值、对训练有何影响。
6. (框架题) 给定一份固定的人类偏好数据集与有限算力, 论证应选 DPO 族还是 GRPO 族, 从「数据是否随策略闭环」「是否需要推理引擎与权重同步」两个角度分析。